

Table of contents

Cours détaillé	1
Motivation et Contexte	2
Qu'est-ce que la Data Science ?	2
Pipeline typique de données	2
Espaces de Représentation (<i>Representation Spaces</i>)	2
Définition formale	2
Propriétés de l'espace	3
Questions fondamentales	3
Malédiction de la Dimensionnalité (<i>Curse of Dimensionality</i>)	4
1. Parcimonie des Données (<i>Data Sparsity</i>)	4
2. Sphère Vide et Cube Épineux (<i>Empty Sphere & Spiky Cube</i>)	5
3. Distribution du Volume	7
4. L'œuf gaussien (<i>Gaussian Egg</i>)	8
5. Concentration des Distances	9
6. Quasi-Orthogonalité	10
7. Hubness (Présence de <i>Hubs</i>)	12
8. Inégalités de Concentration	13
Bénédiction de la Dimensionnalité (<i>Blessing of Dimensionality</i>)	14
1. Lois des Grands Nombres	14
2. Projections Aléatoires (<i>Random Projections</i>)	15
Importance en Data Science	16
1. Échantillonnage (<i>Sampling</i>)	16
2. Indexation (<i>Indexing</i>)	16
3. Apprentissage (<i>Learning</i>)	16
4. Pourquoi la Data Science fonctionne-t-elle quand même ?	18
Résumé Global	18
+ Aspects positifs	18
- Aspects négatifs (Curse)	19
Solution	19

Cours détaillé

Motivation et Contexte

Qu'est-ce que la Data Science ?

La **Data Science** étudie :

- La modélisation de phénomènes en données numériques (quantitatives)
- Les propriétés géométriques et statistiques de ces données
- Les propriétés des espaces dans lesquels vivent ces données
- L'analyse des données et le développement d'outils pour cette analyse
- Les hypothèses sous-jacentes dans la conception de ces outils

Relation avec le Machine Learning : La Data Science étudie les espaces de représentation dans lesquels le Machine Learning opère.

Révision Rapide : Motivation

Data Science = ML : Étude des espaces de représentation où agit le ML.

Pipeline : Processus $\rightarrow$ Capteur $\rightarrow$ Données brutes $\rightarrow$ Représentation (matrice dans $\mathbb{R}^D$).

Focus sur propriétés géométriques ET statistiques.

Pipeline typique de données

Flux général : Processus $\rightarrow$ Capteur $\rightarrow$ Données brutes $\rightarrow$ Représentation

Exemples concrets :

- Caméra $\rightarrow$ pixels d'image $\rightarrow$ matrice
- Population $\rightarrow$ résultats de sondage $\rightarrow$ matrice
- Documents texte $\rightarrow$ occurrences de mots $\rightarrow$ matrice
- Réseau social $\rightarrow$ relations $\rightarrow$ matrice
- Environnement $\rightarrow$ mesures $\rightarrow$ matrice

Espaces de Représentation (*Representation Spaces*)

Définition formale

On obtient des données $X = \{x_1, \dots, x_N\}$ où $x_i \in \Omega \subseteq \mathbb{R}^D$ pour tout $i \in \llbracket N \rrbracket$.

Vision statistique :

- X est un échantillon de taille N de la fonction de densité sous-jacente $f_X : \Omega \rightarrow \mathbb{R}^+$ à D variables
- On déclare N variables aléatoires i.i.d. $\{X_i\}_{i \in \llbracket N \rrbracket}$ où $X_i \sim f_X$
- Chaque donnée x_i est une réalisation (échantillon) de X_i

Vision algébrique :

- On forme la matrice $X = \begin{bmatrix} | & & | \\ x_1 & \cdots & x_N \\ | & & | \end{bmatrix} \in \mathbb{R}^{D \times N}$
- Les colonnes $X_{:,j} = x_j$ sont les vecteurs de données

Propriétés de l'espace

L'espace de représentation Ω est généralement un sous-ensemble de $\mathbb{R}^D$:

- C'est un **espace vectoriel** qui peut être muni d'un produit scalaire $\langle \cdot, \cdot \rangle$
- Le produit scalaire induit une **norme** $\| \cdot \|$
- La norme induit une **fonction de distance** $d(\cdot, \cdot)$
- Cas favorable : (Ω, d) est un **espace métrique** où l'apprentissage peut être effectué

Note : Ω est aussi la base d'un espace mesurable sur lequel les variables aléatoires peuvent être définies.

Révision Rapide : Espaces de Représentation

$X = \{x_1, \dots, x_N\}$ avec $x_i \in \Omega \subseteq \mathbb{R}^D$.

Deux visions :

- Statistique : échantillon de f_X , variables i.i.d.
- Algébrique : matrice $X \in \mathbb{R}^{D \times N}$.

Structure : espace vectoriel $\rightarrow$ produit scalaire $\rightarrow$ norme $\rightarrow$ distance $\rightarrow$ espace métrique.

Questions fondamentales

Que se passe-t-il quand :

- D augmente ? (dimensionnalité)
- N augmente ? (nombre d'échantillons)

Impact sur :

- La modélisation des données

- L'apprentissage automatique

Curse of Dimensionality et Blessing of Dimensionality

Malédiction de la Dimensionnalité (*Curse of Dimensionality*)

1. Parcimonie des Données (*Data Sparsity*)

Problème de l'estimation de densité

Contexte :

- Population sur hypercube $\Omega = [a, b]^D$
- Échantillon X de cette population
- Objectif : estimer la pdf empiriquement via histogramme

Méthode :

- Quantification uniforme : b bins par dimension
- Qualité souhaitée : n échantillons par bin en moyenne

Question : Combien d'échantillons N sont nécessaires ?

Réponse :

- $D = 1 \rightarrow N \approx n \cdot b$
- $D = 2 \rightarrow N \approx n \cdot b^2$
- D quelconque $\rightarrow N \approx n \cdot b^D$

Exemple catastrophique : $b = 10, n = 10, D = 6 \rightarrow N \approx 10^7$ échantillons !

Qualité d'estimation avec N fixé

Si on fixe le nombre d'échantillons à N :

Question : Quelle qualité d'estimation peut-on espérer ?

- $D = 1 \rightarrow n = \frac{N}{b} \rightarrow \mathbb{E}[P(x_i \in \text{bin}_j)] \approx \frac{1}{b}$
- D quelconque $\rightarrow n = \frac{N}{b^D} \rightarrow \mathbb{E}[P(x_i \in \text{bin}_j)] \approx \frac{1}{b^D}$

Conséquence : La plupart des bins sont probablement vides

Révision Rapide : Data Sparsity

Pour estimer une densité avec qualité, besoin de $N \approx n \cdot b^D$ échantillons (croissance exponentielle).

Si N fixé : $n = N/b^D \rightarrow$ la plupart des bins **vides**.

Exemple : $D = 6, b = 10, n = 10 \rightarrow N \approx 10^7$.

2. Sphère Vide et Cube Épineux (*Empty Sphere & Spiky Cube*)

Volume de l'hypersphère

Formule pour une hypersphère $B_D(r)$ de rayon r centrée à l'origine :

$$\text{vol}(B_D(r)) = \frac{2r^D \pi^{D/2}}{D\Gamma(D/2)}$$

Relation de récurrence (pour $D > 1$) :

$$\text{vol}(B_D(r)) = \frac{2\pi r^2}{D} \text{vol}(B_{D-2}(r))$$

Propriété importante :

$$\frac{\text{area}(B_D(r))}{\text{vol}(B_D(r))} = \frac{\pi^{1/2} D\Gamma(D/2)}{\Gamma(\frac{D+1}{2})}$$

Question : Comment évolue le volume de la sphère quand D augmente ?

Phénomène de la sphère vide

Configuration : Hypersphère $B_D(r)$ inscrite dans hypercube $C_D(r) = [-r, r]^D$.

Tirer N échantillons uniformes du cube (i.e. de $\mathcal{U}(C_D(r))$).

Question : Quelle proportion d'échantillons tombe dans $B_D(r)$?

Calcul :

- $\text{vol}(B_D(r)) = \frac{2r^D \pi^{D/2}}{D\Gamma(D/2)}$
- $\text{vol}(C_D(r)) = (2r)^D$

Ratio :

$$\frac{\text{vol}(B_D(r))}{\text{vol}(C_D(r))} = \frac{\pi^{D/2}}{D \cdot 2^{D-1} \Gamma(D/2)}$$

Limite asymptotique :


$$\lim_{D \rightarrow \infty} \frac{\text{vol}(B_D(r))}{\text{vol}(C_D(r))} = 0$$

Note : $\Gamma(n)$ se comporte comme $n! \sim n^n$

Conséquences :

- Tous les échantillons vont dans la partie du cube **hors de la sphère** (les coins)
- Le volume du cube est **concentré dans ses coins**
- Tous les échantillons **s'échappent du centre**
- Le volume relatif de l'hypersphère tend vers zéro

La sphère est probablement vide



Coins de l'hypercube

Configuration : Hypercube unitaire centré $C_D(1) = [-\frac{1}{2}, \frac{1}{2}]^D$ avec $\text{vol}(C_D(1)) = 1$.

Propriétés des coins :

- Nombre de coins : $n = 2^D$
- Chaque coin x_i a D coordonnées : $|x_i(j)| = \frac{1}{2}$ pour tout j
- Distance à l'origine : $\|x_i\|_2 = \frac{\sqrt{D}}{2}$

Table des distances :

D	1	2	4	5	100
$\frac{\sqrt{D}}{2}$	$\frac{1}{2}$	$\frac{\sqrt{2}}{2}$	1	$\frac{\sqrt{5}}{2}$	5

Observation : La distance aux coins **croît avec** $\sqrt{D} \rightarrow$ les coins s'éloignent du centre !

Révision Rapide : Sphère Vide & Cube Épineux

Ratio sphère/cube : $\frac{\text{vol}(B_D(r))}{\text{vol}(C_D(r))} = \frac{\pi^{D/2}}{D \cdot 2^{D-1} \Gamma(D/2)} \rightarrow 0$.

Volume concentré aux **coins** du cube (distance centre-coin = $\sqrt{D}/2$).

Échantillonnage uniforme $\rightarrow$ sphère **vide**.

3. Distribution du Volume

Pour l'hypercube

Question : Comment le volume se distribue-t-il dans une forme de mesure r ?

Ratio de volumes entre hypercubes de côté r et $(1 - \varepsilon)r$ pour $\varepsilon \in]0, 1[$:

$$\frac{\text{vol}(C_D((1 - \varepsilon)r))}{\text{vol}(C_D(r))} = \frac{((1 - \varepsilon)r)^D}{r^D} = (1 - \varepsilon)^D$$

Limite :

$$\lim_{D \rightarrow \infty} \frac{\text{vol}(C_D((1 - \varepsilon)r))}{\text{vol}(C_D(r))} = 0$$

Pour l'hypersphère

Ratio de volumes entre hypersphères de rayon r et $(1 - \varepsilon)r$:

$$\frac{\text{vol}(B_D((1 - \varepsilon)r))}{\text{vol}(B_D(r))} = \frac{2((1 - \varepsilon)r)^D \pi^{D/2}}{D \Gamma(D/2)} \cdot \frac{D \Gamma(D/2)}{2r^D \pi^{D/2}} = (1 - \varepsilon)^D$$

Limite :

$$\lim_{D \rightarrow \infty} \frac{\text{vol}(B_D((1 - \varepsilon)r))}{\text{vol}(B_D(r))} = 0$$

Note technique : $1 - \varepsilon \leq e^{-\varepsilon}$ donc $(1 - \varepsilon)^D \leq e^{-D\varepsilon} \rightarrow 0$ si $D \rightarrow \infty$

Généralisation à tout volume

Principe : Décomposer le volume en voxels (hyper-)cubiques arbitrairement petits.

Réduction : Si on réduit la longueur d'un côté de voxel par facteur $(1 - \varepsilon)$:

- Volume du voxel réduit par $(1 - \varepsilon)^D$
- Volume complet réduit par $(1 - \varepsilon)^D$

Ratio de volumes :

$$\lim_{D \rightarrow \infty} \frac{\text{vol}(V_D(r)) - \text{vol}(V_D((1 - \varepsilon)r))}{\text{vol}(V_D(r))} = \lim_{D \rightarrow \infty} 1 - (1 - \varepsilon)^D = 1$$

Conclusion fondamentale : Le volume est concentré près de la surface de la forme

Révision Rapide : Distribution du Volume

Pour **toute forme** : ratio de volumes $(1 - \varepsilon)^D \rightarrow 0$ quand $D \rightarrow \infty$.

Méthode : décomposition en voxels hypercubiques.

Résultat : le volume est **concentré à la surface** (différence $\rightarrow 1$).

4. L'œuf gaussien (*Gaussian Egg*)

Densité le long du rayon

Question : Étant donnée une distribution Normale $\mathcal{N}(\mu, \Sigma)$, quelle est sa densité le long du rayon r ?

Contexte : Les coordonnées sont D v.a. i.i.d. $X_i \sim \mathcal{N}(0, 1)$.

Intégration le long de r = prendre la norme. R est la v.a. attachée au rayon :

$$R^2 = \|X\|_2^2 = \sum_{i=1}^D X_i^2 \sim \chi^2(D)$$

Espérance :

$$\mathbb{E}[R^2] = D \implies \mathbb{E}[R] \approx \sqrt{D}$$

On peut considérer la distribution centrée et réduite (i.e. $\mathcal{N}(0, \text{Id}_D)$) avec $\sigma = 1$.

La densité est concentrée au rayon $\sigma\sqrt{D}$



Théorème de l'anneau gaussien (*Gaussian Annulus Theorem*)

Étant donné $X \sim \mathcal{N}(0, \text{Id}_D)$, pour tout $\beta \leq \sqrt{D}$:

$$P\left[\left|\|X\|_2 - \sqrt{D}\right| > \beta\right] \leq 3e^{-c\beta^2}$$

où $c > 0$ est une constante.

Interprétation : La norme est **concentrée exponentiellement** autour de $\sqrt{D}$.

Formulation alternative :

$$P\left[\left|\frac{\|X\|}{\sqrt{D}} - 1\right| \leq \varepsilon\right] \approx 1$$

La quasi-totalité de la densité est dans un **anneau fin** autour du rayon $\sqrt{D}$

Révision Rapide : Œuf Gaussien

Pour $X \sim \mathcal{N}(0, \text{Id}_D)$: $R^2 = \|X\|_2^2 \sim \chi^2(D)$ donc $\mathbb{E}[R^2] = D$.

Gaussian Annulus Theorem : $P[|\|X\|_2 - \sqrt{D}| > \beta] \leq 3e^{-c\beta^2}$.

Densité concentrée au rayon $\sigma\sqrt{D}$ (anneau fin).

5. Concentration des Distances

Contexte : Données $X \subset \Omega$, sélectionner une donnée x et ses k plus proches voisins $V_X^k(x)$.

Soit $D_{\min}$ et $D_{\max}$ les v.a. associées aux distances du voisin le plus proche et le plus éloigné parmi les k voisins.

Théorème de concentration

Théorème : Si $\lim_{D \rightarrow \infty} \text{Var} \left[\frac{d(x,y)^p}{\mathbb{E}[d(x,y)^p]} \right] = 0$ pour $0 < p < \infty$, alors pour tout $\varepsilon > 0$:

$$\lim_{D \rightarrow \infty} P \left[\frac{D_{\max} - D_{\min}}{D_{\min}} \leq \varepsilon \right] = 1$$

Conséquences :

- Tous les voisins sont vus à distance $D_{\min}$ de x
- Le pouvoir de discrimination **décroît exponentiellement**
- Les structures KNN (*k-nearest neighbors*) et ε NN deviennent **non significatives**

Révision Rapide : Concentration des Distances

Si variance de distance normalisée $\rightarrow 0$, alors $\frac{D_{\max} - D_{\min}}{D_{\min}} \rightarrow 0$.

Tous les voisins sont **équidistants**.

KNN et ε NN **perdent leur sens**.

6. Quasi-Orthogonalité

Concentration des angles entre vecteurs aléatoires

Question : En tirant des vecteurs d'un espace D -dimensionnel, quel est leur angle attendu ?

Méthode : Déclarer 4 v.a. i.i.d. W, X, Y, Z sur $\Omega \subset \mathbb{R}^D$ et calculer :

$$\mathbb{E} [\cos(\angle(X - Y, Z - W))] = \mathbb{E} \left[\frac{\langle X - Y, Z - W \rangle}{\|X - Y\| \cdot \|Z - W\|} \right]$$

Puisque W, X, Y, Z sont i.i.d., $X - Y$ et $Z - W$ sont aussi i.i.d. et centrées :

$$\mathbb{E}(X - Y) = \mathbb{E}(Z - W) = 0$$

Le numérateur est $\text{cov}(X - Y, Z - W) = 0$, le dénominateur est un normaliseur.

Résultat : $\mathbb{E}[\cos(\theta)] = 0 \implies \theta \sim \frac{\pi}{2}$

Alternative :

$$\langle X - Y, Z - W \rangle = \langle X, Z \rangle - \langle X, W \rangle - \langle Y, Z \rangle + \langle Y, W \rangle$$

En espérance, tous les termes s'annulent car W, X, Y, Z sont i.i.d.

Conclusion :

- Chaque triangle aléatoire est un **triangle rectangle**
- Deux vecteurs aléatoires sont **quasi-orthogonaux**

Concentration des angles dans un triangle

Question : Quel est l'angle attendu dans un triangle aléatoire ?

Méthode : Déclarer 3 v.a. i.i.d. X, Y, Z et calculer pour un angle :

$$\mathbb{E}[\cos(\angle(X - Y, Z - Y))] = \mathbb{E}\left[\frac{\langle X - Y, Z - Y \rangle}{\|X - Y\| \cdot \|Z - Y\|}\right]$$

Note : $X - Y$ et $Z - Y$ ne sont **plus indépendants** !

Calcul (simplifié) :

$$\frac{\langle X - Y, Z - Y \rangle}{\langle X - Y, X - Y \rangle} = \frac{\langle X, Z \rangle - \langle X, Y \rangle - \langle Y, Z \rangle + \langle Y, Y \rangle}{\langle X, X \rangle + \langle Y, Y \rangle - 2\langle X, Y \rangle}$$

En espérance :

$$= \frac{\langle Y, Y \rangle - \langle X, Y \rangle}{2\langle Y, Y \rangle - 2\langle X, Y \rangle} = \frac{1}{2}$$

Résultat : $\mathbb{E}[\cos(\theta)] = \frac{1}{2} \implies \theta \sim \frac{\pi}{3}$

Conclusion : Chaque triangle aléatoire est un **triangle équilatéral**

Impact pour la sphère

Étant donné la boule unitaire B_D , si X est un point aléatoire sur sa surface et Y un autre point, soit $\theta = \angle(X, Y)$:

- Si Y échantillonné depuis Ω : $\mathbb{E}[\cos(\theta)] = \frac{1}{2} \implies \theta \sim \frac{\pi}{3}$
- Si Y échantillonné depuis B_D : $\mathbb{E}[\cos(\theta)] = 0 \implies \theta \sim \frac{\pi}{2}$

Le volume de la sphère est contenu à son **équateur** (pour toute direction nord X)

→ **Preuve alternative** pour la concentration du volume à la surface de la sphère

Note : Pour échantillonner sur l'hypersphère unitaire, échantillonner une distribution centralement symétrique (e.g. Gaussienne) et normaliser.

Révision Rapide : Quasi-Orthogonalité

2 vecteurs aléatoires : $\mathbb{E}[\cos(\theta)] = 0 \rightarrow \theta \sim \pi/2$ (quasi-orthogonaux).

Triangle aléatoire : $\mathbb{E}[\cos(\theta)] = 1/2 \rightarrow \theta \sim \pi/3$ (équilatéral).

Sphère : volume à l'équateur.

7. Hubness (Présence de *Hubs*)

Définition

Question : Combien de fois un échantillon apparaît-il comme k -plus proche voisin d'une autre donnée ?

Étant donné X , définir :

$$r_{ik}(x_j) = \begin{cases} 1 & \text{si } x_j \in V_X^k(x_i) \\ 0 & \text{sinon} \end{cases}$$

Puis :

$$n_k(x_j) = \sum_i r_{ik}(x_j)$$

Résultat : La distribution des valeurs de n_k est **asymétrique vers la gauche**.

Conséquence : Un petit nombre d'échantillons apparaissent dans le voisinage de **beaucoup d'autres** échantillons.

Ces **hubs** sont proches de tous les autres échantillons

Visualisation empirique : Pour 20-NN avec $D = 100$ et 1000 échantillons uniformes sur 50 bins, on observe une forte asymétrie de la distribution de n_k .

Révision Rapide : Hubness

$n_k(x_j)$ = nombre de fois où x_j est k -NN d'un autre point.

Distribution **asymétrique** : quelques **hubs** apparaissent dans beaucoup de voisinages.

Ces hubs sont "proches" de tous.

8. Inégalités de Concentration

Inégalités fondamentales

Inégalité de Markov : Pour une v.a. non-négative X :

$$P(X > \varepsilon) \leq \frac{\mathbb{E}[X]}{\varepsilon}$$

Inégalité de Chebyshev : Pour une v.a. de moyenne μ et variance σ^2 finie :

$$P(|X - \mu| > \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}$$

Inégalité de Hoeffding

Énoncé : Si $\{X_i\}_{i \in [D]}$ sont des v.a. indépendantes avec $P(a \leq X_i \leq b) = 1$ et $\mathbb{E}[X_i] = \mu$, alors pour tout $t > 0$:

$$P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-2D\varepsilon^2/(b-a)^2}$$

où $\bar{X} = \frac{1}{D} \sum_{i=1}^D X_i$

Note : Exemple d'analyse PAC (*Probably Approximately Correct*) : probabilité qu'un événement se produise approximativement.

Explication de la concentration des distances

L'inégalité de Hoeffding explique :

- Quand on agrège des variables indépendantes, l'agrégat **converge vers leur espérance commune**
- La structure $\sum_{i=1}^D (\cdot)$ correspond au calcul des distances de Minkowski :

$$d_p(x, y) = \left(\sum_{i=1}^D |x[i] - y[i]|^p \right)^{1/p}$$

- L'inégalité de Hoeffding explique formellement pourquoi les valeurs de distance **se concentrent**
- Bien que contre-intuitif que tous les voisins soient équidistants, il est intuitif que pour D grand, les valeurs extrêmes (petites ou grandes) de $d_p(x, y)$ deviennent improbables : pour que $d_p(x, y)$ soit petit (grand), **toutes** les D coordonnées $x[i]$ et $y[i]$ doivent être (dis)similaires. Quand D augmente, cela devient improbable.

Révision Rapide : Inégalités de Concentration

Hoeffding : $P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-2D\varepsilon^2/(b-a)^2}$.

Agrégation de variables indépendantes $\rightarrow$ convergence vers μ .

Structure $\sum_{i=1}^D (\cdot)$ dans distances $\rightarrow$ **concentration des distances**.

Bénédiction de la Dimensionnalité (*Blessing of Dimensionality*)

1. Loix des Grands Nombres

Loi Faible des Grands Nombres (WLLN)

Énoncé : Étant donné un ensemble de D v.a. i.i.d. $\{X_i\}_{i \in [D]}$ avec $\mathbb{E}[X_i] = \mu$, alors pour tout $\varepsilon > 0$:

$$\lim_{D \rightarrow \infty} P(|\bar{X} - \mu| < \varepsilon) = 1$$

où $\bar{X} = \frac{1}{D} \sum_{i=1}^D X_i$

(Peut être prouvée à partir de l'inégalité de Chebyshev)

Interprétation :

- La WLLN dit que la **moyenne empirique** $\bar{X}$ converge (en probabilité) vers la **vraie espérance** μ quand le nombre d'échantillons augmente
- Fondamentalement cohérente avec l'approche fréquentiste des probabilités
- C'est la **base fondamentale** de la théorie de l'estimation (et de l'estimation de densité)

Théorème Central Limite (CLT)

La forme et le taux de convergence sont donnés par le TCL :

$$Z_D = \frac{\sqrt{D}}{\sigma}(\bar{X} - \mu) \sim \mathcal{N}(0, 1)$$

si $\text{Var}(X_i) = \sigma^2$

Révision Rapide : Loix des Grands Nombres

WLLN : $\bar{X} \xrightarrow{P} \mu$ quand $D \rightarrow \infty$.

Base de l'estimation de densité.

CLT : $Z_D = \frac{\sqrt{D}}{\sigma}(\bar{X} - \mu) \sim \mathcal{N}(0, 1)$ (taux de convergence).

2. Projections Aléatoires (*Random Projections*)

Principe

Rappel : Deux vecteurs aléatoires u et v sont probablement orthogonaux.

Quasi-orthogonalité : $\langle u, v \rangle = \varepsilon$ (petit).

Propriété clé : **Exponentiellement nombreuses** directions quasi-orthogonales dans les espaces de haute dimension.

Application : Créer des bases aléatoires (quasi-orthonormales) pour la décomposition et le codage de signaux.

Lemme de Johnson-Lindenstrauss

Énoncé : Étant donné $X \subset \Omega$, il existe une application linéaire $p : \mathbb{R}^D \rightarrow \mathbb{R}^d$ telle que, avec $0 < \varepsilon < 1$ et pour tous $i, j \in \llbracket N \rrbracket$:

$$(1 - \varepsilon)\|x_i - x_j\| \leq \|p(x_i) - p(x_j)\| \leq (1 + \varepsilon)\|x_i - x_j\|$$

et

$$d = O\left(\frac{\log N}{\varepsilon^2}\right) \leftarrow \text{Ne dépend PAS de } D!$$

Applications :

- *Locally Sensitive Hashing* (LSH) pour la recherche approximative du plus proche voisin (ANN)
- **Caveat** : Taux de convergence plus lent que la plupart des concentrations

Révision Rapide : Projections Aléatoires

Principe : Exponentiellement nombreuses directions quasi-orthogonales en haute dimension.

Johnson-Lindenstrauss : projection $\mathbb{R}^D \rightarrow \mathbb{R}^d$ préservant distances (à ε près) avec $d = O(\log N / \varepsilon^2)$ (indépendant de D !).

Application : LSH pour ANN.

Importance en Data Science

1. Échantillonnage (*Sampling*)

Conséquences de la parcimonie :

- On a besoin d'un **nombre exponentiel d'échantillons** pour atteindre chaque position d'un espace de haute dimension
- Les inégalités de concentration (incluant WLLN et CLT) sont des **indicateurs de précision** pour l'estimation de densité
- Dans les processus pratiques comme l'échantillonnage par rejet, le **taux de rejet** devient exponentiellement proche de 100% (cf. sphère vide)

2. Indexation (*Indexing*)

Exploitation de la structure :

- L'indexation exploite la structure des données pour anticiper les parties de l'espace Ω à visiter au moment de la requête
- Si tous les voisins sont apparemment à **distance égale** du centre, la structure **disparaît**

Techniques de partitionnement spatial (e.g. *kd-trees*) :

- Tentent d'obtenir une partition de l'espace où chaque donnée est uniquement identifiée dans une intersection de cellules (chemins dans l'arbre de recherche)
- Avec la concentration des distances, la taille de la cellule atteint le **rayon de la sphère** pour couvrir l'espace complet

La recherche équivaut à une **recherche exhaustive** complexité $O(N)$

- Le *hubness* rend certaines données une réponse à **presque toutes les requêtes**

3. Apprentissage (*Learning*)

Fonction d'approximation

Machine Learning = découverte d'**approximateurs de fonctions**.

Problème : Étant donné $\phi : X \rightarrow Y$ la fonction (vraie) qui mappe données X vers labels Y , le ML cherche une approximation $\phi_\theta \in \mathcal{F}$ de ϕ minimisant une erreur (risque) sur des échantillons (train/test).

Borne théorique

Si $\mathcal{F}$ est une classe de fonctions c -uniformément Lipschitz sur Ω :

$$\sup_{\phi_\theta \in \mathcal{F}} \|\phi_\theta - \phi\|_\infty \geq \frac{c\sqrt{D}N^{-1/D}}{2} \sqrt{\frac{2}{\pi e}} \left(1 + O\left(\frac{\log D}{D}\right)\right)$$

Si on autorise une erreur $c\varepsilon$ pour $\varepsilon > 0$, le nombre d'exemples d'entraînement N requis est :

$$N \geq \frac{\varepsilon^{-D} D^{D/2}}{(2\pi e)^{D/2}}$$

Exemples concrets :

- $c = 1, \varepsilon = 0.1, D = 3 \rightarrow N \geq 74$
- $c = 1, \varepsilon = 0.1, D = 10 \rightarrow N \geq 687 \times 10^6$
- $c = 1, \varepsilon = 0.1, D = 15 \rightarrow N \geq 377 \times 10^{12}$
- $c = 1, \varepsilon = 0.01, D = 10 \rightarrow N \geq 6.9 \times 10^{18}$

Cas réaliste en ML :

- Données ML : généralement des centaines de features ($D \sim O(10^2)$)
- Erreur typique recherchée : $\varepsilon \approx 10^{-4}$

$$N \geq \frac{10^{4 \cdot 100} \cdot 100^{50}}{17.07^{50}} \approx 10^{400}$$

Conclusion : C'est **impossible** en pratique !

Révision Rapide : Importance en Data Science

Échantillonnage : besoin exponentiel de samples, taux de rejet $\rightarrow 100\%$.

Indexation : structure disparaît, kd-trees $\rightarrow$ complexité $O(N)$, hubness.

Learning : $N \geq \varepsilon^{-D} D^{D/2} / (2\pi e)^{D/2} \rightarrow$ impossible pour D grand et ε petit.

4. Pourquoi la Data Science fonctionne-t-elle quand même ?

Question : Pourquoi les processus de data science fonctionnent-ils malgré tout ?

Hypothèses dans l'analyse ci-dessus :

- La plupart des analyses supposent une distribution **uniforme** (ou isotrope – Normale, ...)
des données
- La plupart des analyses supposent des **features indépendantes**

Réalité :

- Les **données réelles ne peuplent PAS l'espace de features uniformément** (si les features sont informatives)
- Les **features montrent des corrélations**

En pratique, les données peuplent des **sous-espaces** de Ω de **dimensionnalité intrinsèque locale plus faible**

Solutions :

- **Décorrélérer les features** (e.g. via espace latent linéaire)
- **Découvrir des sous-espaces** de données (clustering, réduction de dimension non-linéaire)

Révision Rapide : Pourquoi ça marche ?

Analyses supposent distribution **uniforme** et features **indépendantes**.

Réalité : données sur **sous-espaces** de dimensionnalité intrinsèque plus faible.

Solutions : décorrélation, clustering, réduction de dimension.

Résumé Global

Géométrie en haute dimension ($D \gtrsim 10$) est **différente** de la géométrie 3D habituelle.

+ Aspects positifs

- Les **inégalités de concentration** sont à la base de l'estimation statistique
- **Lois des Grands Nombres** permettent l'estimation de densité
- **Projections aléatoires** exploitent la quasi-orthogonalité

- Aspects négatifs (Curse)

- Les données deviennent très **parcimonieuses** sauf à utiliser exponentiellement plus de données
- Même avec des données denses, les valeurs de **distance et angle se concentrent**
 - Depuis une requête, tous les voisins sont **équidistants**
 - Depuis une direction, tout le reste semble **orthogonal**
- La densité se concentre sur des **rayons étroits** → échantillonnage biaisé
- Les **hubs** font partie de toutes les classes/réponses de requête

Solution

Puisque c'est par construction, la seule solution est d'opérer d'une manière ou d'une autre dans des **espaces de basse dimension** :

- Réduction de dimensionnalité
- Découverte de sous-espaces
- Décorrélacion des features

Révision Rapide : Résumé

Haute dimension ($D \gtrsim 10$) géométrie 3D.

: inégalités de concentration pour estimation, projections aléatoires.

: data sparsity, concentration distances/angles, hubs.

Solution : opérer en **basse dimension**.