

# Table of contents

|                                                                                   |          |
|-----------------------------------------------------------------------------------|----------|
| <b>Cours détaillé</b>                                                             | <b>1</b> |
| Motivation et Contexte . . . . .                                                  | 2        |
| Qu'est-ce que la Data Science ? . . . . .                                         | 2        |
| Pipeline typique de données . . . . .                                             | 2        |
| Espaces de Représentation ( <i>Representation Spaces</i> ) . . . . .              | 2        |
| Définition formale . . . . .                                                      | 2        |
| Propriétés de l'espace . . . . .                                                  | 3        |
| Questions fondamentales . . . . .                                                 | 3        |
| Malédiction de la Dimensionnalité ( <i>Curse of Dimensionality</i> ) . . . . .    | 4        |
| 1. Parcimonie des Données ( <i>Data Sparsity</i> ) . . . . .                      | 4        |
| 2. Sphère Vide et Cube Épineux ( <i>Empty Sphere &amp; Spiky Cube</i> ) . . . . . | 5        |
| 3. Distribution du Volume . . . . .                                               | 7        |
| 4. L'œuf gaussien ( <i>Gaussian Egg</i> ) . . . . .                               | 8        |
| 5. Concentration des Distances . . . . .                                          | 9        |
| 6. Quasi-Orthogonalité . . . . .                                                  | 10       |
| 7. Hubness (Présence de <i>Hubs</i> ) . . . . .                                   | 12       |
| 8. Inégalités de Concentration . . . . .                                          | 13       |
| Bénédiction de la Dimensionnalité ( <i>Blessing of Dimensionality</i> ) . . . . . | 14       |
| 1. Lois des Grands Nombres . . . . .                                              | 14       |
| 2. Projections Aléatoires ( <i>Random Projections</i> ) . . . . .                 | 15       |
| Importance en Data Science . . . . .                                              | 16       |
| 1. Échantillonnage ( <i>Sampling</i> ) . . . . .                                  | 16       |
| 2. Indexation ( <i>Indexing</i> ) . . . . .                                       | 16       |
| 3. Apprentissage ( <i>Learning</i> ) . . . . .                                    | 16       |
| 4. Pourquoi la Data Science fonctionne-t-elle quand même ? . . . . .              | 18       |
| Résumé Global . . . . .                                                           | 18       |
| + Aspects positifs . . . . .                                                      | 18       |
| - Aspects négatifs (Curse) . . . . .                                              | 19       |
| Solution . . . . .                                                                | 19       |

## Cours détaillé

---

## Motivation et Contexte

### Qu'est-ce que la Data Science ?

La **Data Science** étudie :

- La modélisation de phénomènes en données numériques (quantitatives)
- Les propriétés géométriques et statistiques de ces données
- Les propriétés des espaces dans lesquels vivent ces données
- L'analyse des données et le développement d'outils pour cette analyse
- Les hypothèses sous-jacentes dans la conception de ces outils

**Relation avec le Machine Learning** : La Data Science étudie les espaces de représentation dans lesquels le Machine Learning opère.

#### Révision Rapide : Motivation

**Data Science = ML** : Étude des espaces de représentation où agit le ML.

**Pipeline** : Processus  $\rightarrow$  Capteur  $\rightarrow$  Données brutes  $\rightarrow$  Représentation (matrice dans  $\mathbb{R}^D$ ).

Focus sur propriétés géométriques ET statistiques.

### Pipeline typique de données

**Flux général** : Processus  $\rightarrow$  Capteur  $\rightarrow$  Données brutes  $\rightarrow$  Représentation

**Exemples concrets** :

- Caméra  $\rightarrow$  pixels d'image  $\rightarrow$  matrice
- Population  $\rightarrow$  résultats de sondage  $\rightarrow$  matrice
- Documents texte  $\rightarrow$  occurrences de mots  $\rightarrow$  matrice
- Réseau social  $\rightarrow$  relations  $\rightarrow$  matrice
- Environnement  $\rightarrow$  mesures  $\rightarrow$  matrice

---

## Espaces de Représentation (*Representation Spaces*)

### Définition formale

On obtient des données  $X = \{x_1, \dots, x_N\}$  où  $x_i \in \Omega \subseteq \mathbb{R}^D$  pour tout  $i \in \llbracket N \rrbracket$ .

**Vision statistique** :

- $X$  est un échantillon de taille  $N$  de la fonction de densité sous-jacente  $f_X : \Omega \rightarrow \mathbb{R}^+$  à  $D$  variables
- On déclare  $N$  variables aléatoires i.i.d.  $\{X_i\}_{i \in \llbracket N \rrbracket}$  où  $X_i \sim f_X$
- Chaque donnée  $x_i$  est une réalisation (échantillon) de  $X_i$

**Vision algébrique :**

- On forme la matrice  $X = \begin{bmatrix} | & & | \\ x_1 & \cdots & x_N \\ | & & | \end{bmatrix} \in \mathbb{R}^{D \times N}$
- Les colonnes  $X_{:,j} = x_j$  sont les vecteurs de données

**Propriétés de l'espace**

L'espace de représentation  $\Omega$  est généralement un sous-ensemble de  $\mathbb{R}^D$  :

- C'est un **espace vectoriel** qui peut être muni d'un produit scalaire  $\langle \cdot, \cdot \rangle$
- Le produit scalaire induit une **norme**  $\| \cdot \|$
- La norme induit une **fonction de distance**  $d(\cdot, \cdot)$
- Cas favorable :  $(\Omega, d)$  est un **espace métrique** où l'apprentissage peut être effectué

**Note :**  $\Omega$  est aussi la base d'un espace mesurable sur lequel les variables aléatoires peuvent être définies.

#### Révision Rapide : Espaces de Représentation

$X = \{x_1, \dots, x_N\}$  avec  $x_i \in \Omega \subseteq \mathbb{R}^D$ .

**Deux visions :**

- Statistique : échantillon de  $f_X$ , variables i.i.d.
- Algébrique : matrice  $X \in \mathbb{R}^{D \times N}$ .

**Structure :** espace vectoriel  $\rightarrow$  produit scalaire  $\rightarrow$  norme  $\rightarrow$  distance  $\rightarrow$  espace métrique.

**Questions fondamentales**

**Que se passe-t-il quand :**

- $D$  augmente ? (dimensionnalité)
- $N$  augmente ? (nombre d'échantillons)

**Impact sur :**

- La modélisation des données

- L'apprentissage automatique

## Curse of Dimensionality et Blessing of Dimensionality

---

### Malédiction de la Dimensionnalité (*Curse of Dimensionality*)

#### 1. Parcimonie des Données (*Data Sparsity*)

##### Problème de l'estimation de densité

Contexte :

- Population sur hypercube  $\Omega = [a, b]^D$
- Échantillon  $X$  de cette population
- Objectif : estimer la pdf empiriquement via histogramme

Méthode :

- Quantification uniforme :  $b$  bins par dimension
- Qualité souhaitée :  $n$  échantillons par bin en moyenne

**Question** : Combien d'échantillons  $N$  sont nécessaires ?

Réponse :

- $D = 1 \rightarrow N \approx n \cdot b$
- $D = 2 \rightarrow N \approx n \cdot b^2$
- $D$  quelconque  $\rightarrow N \approx n \cdot b^D$

**Exemple catastrophique** :  $b = 10, n = 10, D = 6 \rightarrow N \approx 10^7$  échantillons !

##### Qualité d'estimation avec $N$ fixé

Si on fixe le nombre d'échantillons à  $N$  :

**Question** : Quelle qualité d'estimation peut-on espérer ?

- $D = 1 \rightarrow n = \frac{N}{b} \rightarrow \mathbb{E}[P(x_i \in \text{bin}_j)] \approx \frac{1}{b}$
- $D$  quelconque  $\rightarrow n = \frac{N}{b^D} \rightarrow \mathbb{E}[P(x_i \in \text{bin}_j)] \approx \frac{1}{b^D}$

**Conséquence** : La plupart des bins sont probablement vides

### Révision Rapide : Data Sparsity

Pour estimer une densité avec qualité, besoin de  $N \approx n \cdot b^D$  échantillons (croissance exponentielle).

Si  $N$  fixé :  $n = N/b^D \rightarrow$  la plupart des bins **vides**.

Exemple :  $D = 6, b = 10, n = 10 \rightarrow N \approx 10^7$ .

---

## 2. Sphère Vide et Cube Épineux (*Empty Sphere & Spiky Cube*)

### Volume de l'hypersphère

Formule pour une hypersphère  $B_D(r)$  de rayon  $r$  centrée à l'origine :

$$\text{vol}(B_D(r)) = \frac{2r^D \pi^{D/2}}{D\Gamma(D/2)}$$

Relation de récurrence (pour  $D > 1$ ) :

$$\text{vol}(B_D(r)) = \frac{2\pi r^2}{D} \text{vol}(B_{D-2}(r))$$

Propriété importante :

$$\frac{\text{area}(B_D(r))}{\text{vol}(B_D(r))} = \frac{\pi^{1/2} D\Gamma(D/2)}{\Gamma(\frac{D+1}{2})}$$

**Question** : Comment évolue le volume de la sphère quand  $D$  augmente ?

### Phénomène de la sphère vide

**Configuration** : Hypersphère  $B_D(r)$  inscrite dans hypercube  $C_D(r) = [-r, r]^D$ .

**Tirer  $N$  échantillons uniformes** du cube (i.e. de  $\mathcal{U}(C_D(r))$ ).

**Question** : Quelle proportion d'échantillons tombe dans  $B_D(r)$  ?

**Calcul** :

- $\text{vol}(B_D(r)) = \frac{2r^D \pi^{D/2}}{D\Gamma(D/2)}$
- $\text{vol}(C_D(r)) = (2r)^D$

**Ratio :**

$$\frac{\text{vol}(B_D(r))}{\text{vol}(C_D(r))} = \frac{\pi^{D/2}}{D \cdot 2^{D-1} \Gamma(D/2)}$$

**Limite asymptotique :**


$$\lim_{D \rightarrow \infty} \frac{\text{vol}(B_D(r))}{\text{vol}(C_D(r))} = 0$$

**Note :**  $\Gamma(n)$  se comporte comme  $n! \sim n^n$

**Conséquences :**

- Tous les échantillons vont dans la partie du cube **hors de la sphère** (les coins)
- Le volume du cube est **concentré dans ses coins**
- Tous les échantillons **s'échappent du centre**
- Le volume relatif de l'hypersphère tend vers zéro

**La sphère est probablement vide**



**Coins de l'hypercube**

**Configuration :** Hypercube unitaire centré  $C_D(1) = [-\frac{1}{2}, \frac{1}{2}]^D$  avec  $\text{vol}(C_D(1)) = 1$ .

**Propriétés des coins :**

- Nombre de coins :  $n = 2^D$
- Chaque coin  $x_i$  a  $D$  coordonnées :  $|x_i(j)| = \frac{1}{2}$  pour tout  $j$
- Distance à l'origine :  $\|x_i\|_2 = \frac{\sqrt{D}}{2}$

**Table des distances :**

| $D$                  | 1             | 2                    | 4 | 5                    | 100 |
|----------------------|---------------|----------------------|---|----------------------|-----|
| $\frac{\sqrt{D}}{2}$ | $\frac{1}{2}$ | $\frac{\sqrt{2}}{2}$ | 1 | $\frac{\sqrt{5}}{2}$ | 5   |

**Observation :** La distance aux coins **croît avec**  $\sqrt{D} \rightarrow$  les coins s'éloignent du centre !

### Révision Rapide : Sphère Vide & Cube Épineux

**Ratio sphère/cube :**  $\frac{\text{vol}(B_D(r))}{\text{vol}(C_D(r))} = \frac{\pi^{D/2}}{D \cdot 2^{D-1} \Gamma(D/2)} \rightarrow 0$ .

Volume concentré aux **coins** du cube (distance centre-coin =  $\sqrt{D}/2$ ).

Échantillonnage uniforme  $\rightarrow$  sphère **vide**.

### 3. Distribution du Volume

#### Pour l'hypercube

**Question :** Comment le volume se distribue-t-il dans une forme de mesure  $r$  ?

**Ratio de volumes** entre hypercubes de côté  $r$  et  $(1 - \varepsilon)r$  pour  $\varepsilon \in ]0, 1[$  :

$$\frac{\text{vol}(C_D((1 - \varepsilon)r))}{\text{vol}(C_D(r))} = \frac{((1 - \varepsilon)r)^D}{r^D} = (1 - \varepsilon)^D$$

**Limite :**

$$\lim_{D \rightarrow \infty} \frac{\text{vol}(C_D((1 - \varepsilon)r))}{\text{vol}(C_D(r))} = 0$$

#### Pour l'hypersphère

**Ratio de volumes** entre hypersphères de rayon  $r$  et  $(1 - \varepsilon)r$  :

$$\frac{\text{vol}(B_D((1 - \varepsilon)r))}{\text{vol}(B_D(r))} = \frac{2((1 - \varepsilon)r)^D \pi^{D/2}}{D \Gamma(D/2)} \cdot \frac{D \Gamma(D/2)}{2r^D \pi^{D/2}} = (1 - \varepsilon)^D$$

**Limite :**

$$\lim_{D \rightarrow \infty} \frac{\text{vol}(B_D((1 - \varepsilon)r))}{\text{vol}(B_D(r))} = 0$$

**Note technique :**  $1 - \varepsilon \leq e^{-\varepsilon}$  donc  $(1 - \varepsilon)^D \leq e^{-D\varepsilon} \rightarrow 0$  si  $D \rightarrow \infty$

### Généralisation à tout volume

**Principe** : Décomposer le volume en voxels (hyper-)cubiques arbitrairement petits.

**Réduction** : Si on réduit la longueur d'un côté de voxel par facteur  $(1 - \varepsilon)$  :

- Volume du voxel réduit par  $(1 - \varepsilon)^D$
- Volume complet réduit par  $(1 - \varepsilon)^D$

**Ratio de volumes** :

$$\lim_{D \rightarrow \infty} \frac{\text{vol}(V_D(r)) - \text{vol}(V_D((1 - \varepsilon)r))}{\text{vol}(V_D(r))} = \lim_{D \rightarrow \infty} 1 - (1 - \varepsilon)^D = 1$$

**Conclusion fondamentale** : Le volume est concentré près de la surface de la forme

#### Révision Rapide : Distribution du Volume

Pour **toute forme** : ratio de volumes  $(1 - \varepsilon)^D \rightarrow 0$  quand  $D \rightarrow \infty$ .

**Méthode** : décomposition en voxels hypercubiques.

**Résultat** : le volume est **concentré à la surface** (différence  $\rightarrow 1$ ).

---

## 4. L'œuf gaussien (*Gaussian Egg*)

### Densité le long du rayon

**Question** : Étant donnée une distribution Normale  $\mathcal{N}(\mu, \Sigma)$ , quelle est sa densité le long du rayon  $r$  ?

**Contexte** : Les coordonnées sont  $D$  v.a. i.i.d.  $X_i \sim \mathcal{N}(0, 1)$ .

**Intégration le long de  $r$**  = prendre la norme.  $R$  est la v.a. attachée au rayon :

$$R^2 = \|X\|_2^2 = \sum_{i=1}^D X_i^2 \sim \chi^2(D)$$

**Espérance** :

$$\mathbb{E}[R^2] = D \implies \mathbb{E}[R] \approx \sqrt{D}$$

On peut considérer la distribution centrée et réduite (i.e.  $\mathcal{N}(0, \text{Id}_D)$ ) avec  $\sigma = 1$ .

**La densité est concentrée au rayon  $\sigma\sqrt{D}$**





### Théorème de l'anneau gaussien (*Gaussian Annulus Theorem*)

Étant donné  $X \sim \mathcal{N}(0, \text{Id}_D)$ , pour tout  $\beta \leq \sqrt{D}$  :

$$P\left[\left|\|X\|_2 - \sqrt{D}\right| > \beta\right] \leq 3e^{-c\beta^2}$$

où  $c > 0$  est une constante.

**Interprétation** : La norme est **concentrée exponentiellement** autour de  $\sqrt{D}$ .

**Formulation alternative** :

$$P\left[\left|\frac{\|X\|}{\sqrt{D}} - 1\right| \leq \varepsilon\right] \approx 1$$

La quasi-totalité de la densité est dans un **anneau fin** autour du rayon  $\sqrt{D}$

#### Révision Rapide : Œuf Gaussien

Pour  $X \sim \mathcal{N}(0, \text{Id}_D)$  :  $R^2 = \|X\|_2^2 \sim \chi^2(D)$  donc  $\mathbb{E}[R^2] = D$ .

**Gaussian Annulus Theorem** :  $P[|\|X\|_2 - \sqrt{D}| > \beta] \leq 3e^{-c\beta^2}$ .

Densité concentrée au rayon  $\sigma\sqrt{D}$  (anneau fin).

## 5. Concentration des Distances

**Contexte** : Données  $X \subset \Omega$ , sélectionner une donnée  $x$  et ses  $k$  plus proches voisins  $V_X^k(x)$ .

Soit  $D_{\min}$  et  $D_{\max}$  les v.a. associées aux distances du voisin le plus proche et le plus éloigné parmi les  $k$  voisins.

### Théorème de concentration

**Théorème :** Si  $\lim_{D \rightarrow \infty} \text{Var} \left[ \frac{d(x,y)^p}{\mathbb{E}[d(x,y)^p]} \right] = 0$  pour  $0 < p < \infty$ , alors pour tout  $\varepsilon > 0$  :

$$\lim_{D \rightarrow \infty} P \left[ \frac{D_{\max} - D_{\min}}{D_{\min}} \leq \varepsilon \right] = 1$$

**Conséquences :**

- Tous les voisins sont vus à distance  $D_{\min}$  de  $x$
- Le pouvoir de discrimination **décroît exponentiellement**
- Les structures KNN (*k-nearest neighbors*) et  $\varepsilon$ NN deviennent **non significatives**

#### Révision Rapide : Concentration des Distances

Si variance de distance normalisée  $\rightarrow 0$ , alors  $\frac{D_{\max} - D_{\min}}{D_{\min}} \rightarrow 0$ .

Tous les voisins sont **équidistants**.

KNN et  $\varepsilon$ NN **perdent leur sens**.

---

## 6. Quasi-Orthogonalité

### Concentration des angles entre vecteurs aléatoires

**Question :** En tirant des vecteurs d'un espace  $D$ -dimensionnel, quel est leur angle attendu ?

**Méthode :** Déclarer 4 v.a. i.i.d.  $W, X, Y, Z$  sur  $\Omega \subset \mathbb{R}^D$  et calculer :

$$\mathbb{E} [\cos(\angle(X - Y, Z - W))] = \mathbb{E} \left[ \frac{\langle X - Y, Z - W \rangle}{\|X - Y\| \cdot \|Z - W\|} \right]$$

**Puisque**  $W, X, Y, Z$  sont i.i.d.,  $X - Y$  et  $Z - W$  sont aussi i.i.d. et centrées :

$$\mathbb{E}(X - Y) = \mathbb{E}(Z - W) = 0$$

Le numérateur est  $\text{cov}(X - Y, Z - W) = 0$ , le dénominateur est un normaliseur.

**Résultat :**  $\mathbb{E}[\cos(\theta)] = 0 \implies \theta \sim \frac{\pi}{2}$

**Alternative :**

$$\langle X - Y, Z - W \rangle = \langle X, Z \rangle - \langle X, W \rangle - \langle Y, Z \rangle + \langle Y, W \rangle$$

En espérance, tous les termes s'annulent car  $W, X, Y, Z$  sont i.i.d.

**Conclusion :**

- Chaque triangle aléatoire est un **triangle rectangle**
- Deux vecteurs aléatoires sont **quasi-orthogonaux**

### Concentration des angles dans un triangle

**Question :** Quel est l'angle attendu dans un triangle aléatoire ?

**Méthode :** Déclarer 3 v.a. i.i.d.  $X, Y, Z$  et calculer pour un angle :

$$\mathbb{E}[\cos(\angle(X - Y, Z - Y))] = \mathbb{E}\left[\frac{\langle X - Y, Z - Y \rangle}{\|X - Y\| \cdot \|Z - Y\|}\right]$$

**Note :**  $X - Y$  et  $Z - Y$  ne sont **plus indépendants** !

**Calcul** (simplifié) :

$$\frac{\langle X - Y, Z - Y \rangle}{\langle X - Y, X - Y \rangle} = \frac{\langle X, Z \rangle - \langle X, Y \rangle - \langle Y, Z \rangle + \langle Y, Y \rangle}{\langle X, X \rangle + \langle Y, Y \rangle - 2\langle X, Y \rangle}$$

En espérance :

$$= \frac{\langle Y, Y \rangle - \langle X, Y \rangle}{2\langle Y, Y \rangle - 2\langle X, Y \rangle} = \frac{1}{2}$$

**Résultat :**  $\mathbb{E}[\cos(\theta)] = \frac{1}{2} \implies \theta \sim \frac{\pi}{3}$

**Conclusion :** Chaque triangle aléatoire est un **triangle équilatéral**

### Impact pour la sphère

Étant donné la boule unitaire  $B_D$ , si  $X$  est un point aléatoire sur sa surface et  $Y$  un autre point, soit  $\theta = \angle(X, Y)$  :

- Si  $Y$  échantillonné depuis  $\Omega$  :  $\mathbb{E}[\cos(\theta)] = \frac{1}{2} \implies \theta \sim \frac{\pi}{3}$
- Si  $Y$  échantillonné depuis  $B_D$  :  $\mathbb{E}[\cos(\theta)] = 0 \implies \theta \sim \frac{\pi}{2}$

Le volume de la sphère est contenu à son **équateur** (pour toute direction nord  $X$ )

→ **Preuve alternative** pour la concentration du volume à la surface de la sphère

**Note :** Pour échantillonner sur l'hypersphère unitaire, échantillonner une distribution centralement symétrique (e.g. Gaussienne) et normaliser.

### Révision Rapide : Quasi-Orthogonalité

**2 vecteurs aléatoires** :  $\mathbb{E}[\cos(\theta)] = 0 \rightarrow \theta \sim \pi/2$  (quasi-orthogonaux).

**Triangle aléatoire** :  $\mathbb{E}[\cos(\theta)] = 1/2 \rightarrow \theta \sim \pi/3$  (équilatéral).

**Sphère** : volume à l'équateur.

---

## 7. Hubness (Présence de *Hubs*)

### Définition

**Question** : Combien de fois un échantillon apparaît-il comme  $k$ -plus proche voisin d'une autre donnée ?

Étant donné  $X$ , définir :

$$r_{ik}(x_j) = \begin{cases} 1 & \text{si } x_j \in V_X^k(x_i) \\ 0 & \text{sinon} \end{cases}$$

Puis :

$$n_k(x_j) = \sum_i r_{ik}(x_j)$$

**Résultat** : La distribution des valeurs de  $n_k$  est **asymétrique vers la gauche**.

**Conséquence** : Un petit nombre d'échantillons apparaissent dans le voisinage de **beaucoup d'autres** échantillons.

Ces **hubs** sont proches de tous les autres échantillons

**Visualisation empirique** : Pour 20-NN avec  $D = 100$  et 1000 échantillons uniformes sur 50 bins, on observe une forte asymétrie de la distribution de  $n_k$ .

### Révision Rapide : Hubness

$n_k(x_j)$  = nombre de fois où  $x_j$  est  $k$ -NN d'un autre point.

Distribution **asymétrique** : quelques **hubs** apparaissent dans beaucoup de voisinages.

Ces hubs sont "proches" de tous.

## 8. Inégalités de Concentration

### Inégalités fondamentales

**Inégalité de Markov** : Pour une v.a. non-négative  $X$  :

$$P(X > \varepsilon) \leq \frac{\mathbb{E}[X]}{\varepsilon}$$

**Inégalité de Chebyshev** : Pour une v.a. de moyenne  $\mu$  et variance  $\sigma^2$  finie :

$$P(|X - \mu| > \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}$$

### Inégalité de Hoeffding

**Énoncé** : Si  $\{X_i\}_{i \in [D]}$  sont des v.a. indépendantes avec  $P(a \leq X_i \leq b) = 1$  et  $\mathbb{E}[X_i] = \mu$ , alors pour tout  $t > 0$  :

$$P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-2D\varepsilon^2/(b-a)^2}$$

où  $\bar{X} = \frac{1}{D} \sum_{i=1}^D X_i$

**Note** : Exemple d'analyse PAC (*Probably Approximately Correct*) : probabilité qu'un événement se produise approximativement.

### Explication de la concentration des distances

L'inégalité de Hoeffding explique :

- Quand on agrège des variables indépendantes, l'agrégat **converge vers leur espérance commune**
- La structure  $\sum_{i=1}^D (\cdot)$  correspond au calcul des distances de Minkowski :

$$d_p(x, y) = \left( \sum_{i=1}^D |x[i] - y[i]|^p \right)^{1/p}$$

- L'inégalité de Hoeffding explique formellement pourquoi les valeurs de distance **se concentrent**
- Bien que contre-intuitif que tous les voisins soient équidistants, il est intuitif que pour  $D$  grand, les valeurs extrêmes (petites ou grandes) de  $d_p(x, y)$  deviennent improbables : pour que  $d_p(x, y)$  soit petit (grand), **toutes** les  $D$  coordonnées  $x[i]$  et  $y[i]$  doivent être (dis)similaires. Quand  $D$  augmente, cela devient improbable.

### Révision Rapide : Inégalités de Concentration

**Hoeffding** :  $P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-2D\varepsilon^2/(b-a)^2}$ .

Agrégation de variables indépendantes  $\rightarrow$  convergence vers  $\mu$ .

Structure  $\sum_{i=1}^D (\cdot)$  dans distances  $\rightarrow$  **concentration des distances**.

## Bénédiction de la Dimensionnalité (*Blessing of Dimensionality*)

### 1. Loix des Grands Nombres

#### Loi Faible des Grands Nombres (WLLN)

**Énoncé** : Étant donné un ensemble de  $D$  v.a. i.i.d.  $\{X_i\}_{i \in [D]}$  avec  $\mathbb{E}[X_i] = \mu$ , alors pour tout  $\varepsilon > 0$  :

$$\lim_{D \rightarrow \infty} P(|\bar{X} - \mu| < \varepsilon) = 1$$

où  $\bar{X} = \frac{1}{D} \sum_{i=1}^D X_i$

(Peut être prouvée à partir de l'inégalité de Chebyshev)

**Interprétation** :

- La WLLN dit que la **moyenne empirique**  $\bar{X}$  converge (en probabilité) vers la **vraie espérance**  $\mu$  quand le nombre d'échantillons augmente
- Fondamentalement cohérente avec l'approche fréquentiste des probabilités
- C'est la **base fondamentale** de la théorie de l'estimation (et de l'estimation de densité)

#### Théorème Central Limite (CLT)

La forme et le taux de convergence sont donnés par le TCL :

$$Z_D = \frac{\sqrt{D}}{\sigma}(\bar{X} - \mu) \sim \mathcal{N}(0, 1)$$

si  $\text{Var}(X_i) = \sigma^2$

### Révision Rapide : Loix des Grands Nombres

**WLLN** :  $\bar{X} \xrightarrow{P} \mu$  quand  $D \rightarrow \infty$ .

Base de l'estimation de densité.

**CLT** :  $Z_D = \frac{\sqrt{D}}{\sigma}(\bar{X} - \mu) \sim \mathcal{N}(0, 1)$  (taux de convergence).

## 2. Projections Aléatoires (*Random Projections*)

### Principe

**Rappel** : Deux vecteurs aléatoires  $u$  et  $v$  sont probablement orthogonaux.

**Quasi-orthogonalité** :  $\langle u, v \rangle = \varepsilon$  (petit).

**Propriété clé** : **Exponentiellement nombreuses** directions quasi-orthogonales dans les espaces de haute dimension.

**Application** : Créer des bases aléatoires (quasi-orthonormales) pour la décomposition et le codage de signaux.

### Lemme de Johnson-Lindenstrauss

**Énoncé** : Étant donné  $X \subset \Omega$ , il existe une application linéaire  $p : \mathbb{R}^D \rightarrow \mathbb{R}^d$  telle que, avec  $0 < \varepsilon < 1$  et pour tous  $i, j \in \llbracket N \rrbracket$  :

$$(1 - \varepsilon)\|x_i - x_j\| \leq \|p(x_i) - p(x_j)\| \leq (1 + \varepsilon)\|x_i - x_j\|$$

et

$$d = O\left(\frac{\log N}{\varepsilon^2}\right) \leftarrow \text{Ne dépend PAS de } D!$$

### Applications :

- *Locally Sensitive Hashing* (LSH) pour la recherche approximative du plus proche voisin (ANN)
- **Caveat** : Taux de convergence plus lent que la plupart des concentrations

### Révision Rapide : Projections Aléatoires

**Principe** : Exponentiellement nombreuses directions quasi-orthogonales en haute dimension.

**Johnson-Lindenstrauss** : projection  $\mathbb{R}^D \rightarrow \mathbb{R}^d$  préservant distances (à  $\varepsilon$  près) avec  $d = O(\log N / \varepsilon^2)$  (indépendant de  $D$  !).

Application : LSH pour ANN.

---

## Importance en Data Science

### 1. Échantillonnage (*Sampling*)

Conséquences de la parcimonie :

- On a besoin d'un **nombre exponentiel d'échantillons** pour atteindre chaque position d'un espace de haute dimension
- Les inégalités de concentration (incluant WLLN et CLT) sont des **indicateurs de précision** pour l'estimation de densité
- Dans les processus pratiques comme l'échantillonnage par rejet, le **taux de rejet** devient exponentiellement proche de 100% (cf. sphère vide)

### 2. Indexation (*Indexing*)

Exploitation de la structure :

- L'indexation exploite la structure des données pour anticiper les parties de l'espace  $\Omega$  à visiter au moment de la requête
- Si tous les voisins sont apparemment à **distance égale** du centre, la structure **disparaît**

Techniques de partitionnement spatial (e.g. *kd-trees*) :

- Tentent d'obtenir une partition de l'espace où chaque donnée est uniquement identifiée dans une intersection de cellules (chemins dans l'arbre de recherche)
- Avec la concentration des distances, la taille de la cellule atteint le **rayon de la sphère** pour couvrir l'espace complet

La recherche équivaut à une **recherche exhaustive** complexité  $O(N)$

- Le *hubness* rend certaines données une réponse à **presque toutes les requêtes**

### 3. Apprentissage (*Learning*)

Fonction d'approximation

Machine Learning = découverte d'**approximateurs de fonctions**.

**Problème** : Étant donné  $\phi : X \rightarrow Y$  la fonction (vraie) qui mappe données  $X$  vers labels  $Y$ , le ML cherche une approximation  $\phi_\theta \in \mathcal{F}$  de  $\phi$  minimisant une erreur (risque) sur des échantillons (train/test).



## Borne théorique

Si  $\mathcal{F}$  est une classe de fonctions  $c$ -uniformément Lipschitz sur  $\Omega$  :

$$\sup_{\phi_\theta \in \mathcal{F}} \|\phi_\theta - \phi\|_\infty \geq \frac{c\sqrt{D}N^{-1/D}}{2} \sqrt{\frac{2}{\pi e}} \left(1 + O\left(\frac{\log D}{D}\right)\right)$$

Si on autorise une erreur  $c\varepsilon$  pour  $\varepsilon > 0$ , le nombre d'exemples d'entraînement  $N$  requis est :

$$N \geq \frac{\varepsilon^{-D} D^{D/2}}{(2\pi e)^{D/2}}$$

## Exemples concrets :

- $c = 1, \varepsilon = 0.1, D = 3 \rightarrow N \geq 74$
- $c = 1, \varepsilon = 0.1, D = 10 \rightarrow N \geq 687 \times 10^6$
- $c = 1, \varepsilon = 0.1, D = 15 \rightarrow N \geq 377 \times 10^{12}$
- $c = 1, \varepsilon = 0.01, D = 10 \rightarrow N \geq 6.9 \times 10^{18}$

## Cas réaliste en ML :

- Données ML : généralement des centaines de features ( $D \sim O(10^2)$ )
- Erreur typique recherchée :  $\varepsilon \approx 10^{-4}$

$$N \geq \frac{10^{4 \cdot 100} \cdot 100^{50}}{17.07^{50}} \approx 10^{400}$$

**Conclusion :** C'est **impossible** en pratique !

### Révision Rapide : Importance en Data Science

**Échantillonnage :** besoin exponentiel de samples, taux de rejet  $\rightarrow 100\%$ .

**Indexation :** structure disparaît, kd-trees  $\rightarrow$  complexité  $O(N)$ , hubness.

**Learning :**  $N \geq \varepsilon^{-D} D^{D/2} / (2\pi e)^{D/2} \rightarrow$  impossible pour  $D$  grand et  $\varepsilon$  petit.

#### 4. Pourquoi la Data Science fonctionne-t-elle quand même ?

**Question** : Pourquoi les processus de data science fonctionnent-ils malgré tout ?

**Hypothèses dans l'analyse ci-dessus** :

- La plupart des analyses supposent une distribution **uniforme** (ou isotrope – Normale, ...)  
des données
- La plupart des analyses supposent des **features indépendantes**

**Réalité** :

- Les **données réelles ne peuplent PAS l'espace de features uniformément** (si les features sont informatives)
- Les **features montrent des corrélations**

En pratique, les données peuplent des **sous-espaces** de  $\Omega$  de **dimensionnalité intrinsèque locale plus faible**

**Solutions** :

- **Décorrélérer les features** (e.g. via espace latent linéaire)
- **Découvrir des sous-espaces** de données (clustering, réduction de dimension non-linéaire)

##### Révision Rapide : Pourquoi ça marche ?

Analyses supposent distribution **uniforme** et features **indépendantes**.

**Réalité** : données sur **sous-espaces** de dimensionnalité intrinsèque plus faible.

**Solutions** : décorrélation, clustering, réduction de dimension.

---

#### Résumé Global

Géométrie en haute dimension ( $D \gtrsim 10$ ) est **différente** de la géométrie 3D habituelle.

#### + Aspects positifs

- Les **inégalités de concentration** sont à la base de l'estimation statistique
- **Lois des Grands Nombres** permettent l'estimation de densité
- **Projections aléatoires** exploitent la quasi-orthogonalité

### - Aspects négatifs (Curse)

- Les données deviennent très **parcimonieuses** sauf à utiliser exponentiellement plus de données
- Même avec des données denses, les valeurs de **distance et angle se concentrent**
  - Depuis une requête, tous les voisins sont **équidistants**
  - Depuis une direction, tout le reste semble **orthogonal**
- La densité se concentre sur des **rayons étroits** → échantillonnage biaisé
- Les **hubs** font partie de toutes les classes/réponses de requête

### Solution

Puisque c'est par construction, la seule solution est d'opérer d'une manière ou d'une autre dans des **espaces de basse dimension** :

- Réduction de dimensionnalité
- Découverte de sous-espaces
- Décorrélation des features

#### Révision Rapide : Résumé

**Haute dimension** ( $D \gtrsim 10$ ) géométrie 3D.

: inégalités de concentration pour estimation, projections aléatoires.

: data sparsity, concentration distances/angles, hubs.

**Solution** : opérer en **basse dimension**.