

Table of contents

Questions d'Examen	2
Question 1 : Qu'est-ce que la dimension ?	2
Question 2 : Citez une instance concrète de la Malédiction de la Dimensionnalité	3
Question 3 : Citez une instance concrète de la Bénédiction de la Dimensionnalité	4
Question 4 : Pourquoi la dimension augmente-t-elle la parcimonie des données ?	5
Question 5 : Pourquoi le volume se concentre-t-il sur la surface des volumes ?	6
Question 6 : Qu'est-ce qu'un phénomène de concentration ? Comment peut-il être bénéfique ?	8
1. Estimation statistique (Loi Faible des Grands Nombres)	9
2. Inégalité de Hoeffding (analyse PAC)	9
3. Projections aléatoires (Johnson-Lindenstrauss)	9
4. Stabilité numérique	9
Question 7 : Pourquoi les angles se concentrent-ils ? Comment peut-on exploiter cela ?	10
Cas 1 : Deux vecteurs aléatoires indépendants	10
Cas 2 : Triangle aléatoire (vecteurs partageant origine)	11
1. Projections aléatoires (Random Projections)	12
2. Locally Sensitive Hashing (LSH)	12
3. Codage de signaux (Signal Coding)	13
4. Dimension Reduction	13
5. Tests de randomness	13
Question 8 : Quel est le taux typique de concentration ?	14
1. Inégalité de Hoeffding	14
2. Gaussian Annulus Theorem	15
3. Concentration des distances (Beyer et al.)	15
4. Distribution du volume	15
Question 9 : Citez une inégalité de concentration. Pouvez-vous la prouver ?	17
Énoncé	17
Preuve	17
Question 10 : Détaillez une situation concrète où la concentration est bénéfique	20
Contexte	20
Approche naïve (sans concentration)	20
Approche avec concentration (échantillonnage)	20
Bénéfices de la concentration	21
Généralisation : Théorème Central Limite	22
Autres situations bénéfiques	23
Question 11 : Détaillez une situation concrète où la concentration est adverse	23
Contexte	23
Le problème : Concentration des distances	24
Conséquences adverses	24

Coût business	26
Solutions (atténuation)	27
Tableau récapitulatif	28
Généralisation	28
Question 12 : Qu'est-ce qu'une analyse PAC ?	29
Définition formelle	29
Les deux composantes	29
Relation avec inégalités de concentration	30
Exemple concret : Classification binaire	30
Composantes d'une borne PAC	31
Applications en Data Science	31
Limites de l'analyse PAC	32
Extensions	33
Résumé visuel	34

Questions d'Examen

Question 1 : Qu'est-ce que la dimension ?

Réponse :

La **dimension** D d'un espace de représentation $\Omega \subseteq \mathbb{R}^D$ représente le nombre de coordonnées nécessaires pour décrire un point dans cet espace.

Formellement :

- Dimension mathématique : nombre de vecteurs de base linéairement indépendants nécessaires pour engendrer l'espace
- En data science : nombre de **features** ou **attributs** d'un vecteur de données $x \in \mathbb{R}^D$

Types de dimension :

- **Dimension ambiante** (*ambient dimension*) : dimension de l'espace $\mathbb{R}^D$ dans lequel les données sont représentées
- **Dimension intrinsèque** (*intrinsic dimension*) : dimension réelle du sous-espace (manifold) que les données peuplent effectivement (souvent $\ll D$)

Exemple : - Image 100×100 pixels : $D = 10000$ (dimension ambiante) - Si les images représentent des visages, la dimension intrinsèque pourrait être $\sim 50 - 100$

Révision Rapide : Dimension

D = nombre de coordonnées/features. **Dimension ambiante** : $\mathbb{R}^D$ où vivent les données.
Dimension intrinsèque : dimension réelle du manifold peuplé (souvent $\ll D$).

Question 2 : Citez une instance concrète de la Malédiction de la Dimensionnalité

Réponse :

Instance concrète : Concentration des distances et échec du k-NN

Dans un problème de classification avec k -plus proches voisins (k -NN) :

Contexte :

- Dataset X avec $N = 1000$ points en dimension $D = 100$
- Algorithme k-NN cherche les $k = 10$ plus proches voisins d'un point requête q

Problème :

- En haute dimension, le théorème de concentration des distances stipule que :

$$\lim_{D \rightarrow \infty} P \left[\frac{D_{\max} - D_{\min}}{D_{\min}} \leq \varepsilon \right] = 1$$

- Concrètement : **tous les voisins sont approximativement équidistants** du point requête
- La différence entre le plus proche et le plus éloigné voisin devient **négligeable**

Conséquence pratique :

- Le choix des k voisins devient **arbitraire** (tous sont “égaleement bons”)
- Le **pouvoir discriminant** de l'algorithme disparaît
- La précision de classification **chute drastiquement**
- L'algorithme k-NN perd son utilité

Mesure empirique : Pour $D = 100$, le ratio $\frac{D_{\max} - D_{\min}}{D_{\min}}$ peut être < 0.01 , rendant la distinction entre voisins impossible.

Autre exemple : Sphère vide

Dans un échantillonnage par rejet pour générer des points dans une sphère :

- Ratio $\frac{\text{vol}(B_D(r))}{\text{vol}(C_D(r))} \rightarrow 0$ quand $D \rightarrow \infty$
- Pour $D = 10$ et rayon unitaire : ratio $\approx 0.0025 \rightarrow$ **99.75% de rejet**
- Processus devient **impraticable**

Révision Rapide : Instance Concrète de la Curse

k-NN en haute dimension : distances se concentrent $\rightarrow \frac{D_{\max} - D_{\min}}{D_{\min}} \rightarrow 0 \rightarrow$

tous voisins équidistants $\rightarrow$ discrimination impossible. **Échantillonnage par rejet**
: $\text{vol}(B_D)/\text{vol}(C_D) \rightarrow 0 \rightarrow \text{taux rejet} \rightarrow 100\%$.

Question 3 : Citez une instance concrète de la Bénédiction de la Dimensionnalité

Réponse :

Instance concrète : **Projections aléatoires et lemme de Johnson-Lindenstrauss**

En apprentissage automatique et traitement de données massives :

Contexte :

- Dataset X avec $N = 10000$ points en très haute dimension $D = 10000$ (e.g., représentation TF-IDF de documents)
- Calculs coûteux : distances, produits scalaires, clustering

Solution via projections aléatoires :

Le lemme de Johnson-Lindenstrauss garantit qu'il existe une projection linéaire aléatoire $p : \mathbb{R}^D \rightarrow \mathbb{R}^d$:

$$(1 - \varepsilon)\|x_i - x_j\| \leq \|p(x_i) - p(x_j)\| \leq (1 + \varepsilon)\|x_i - x_j\|$$

avec $d = O\left(\frac{\log N}{\varepsilon^2}\right)$ **indépendant de D !**

Exemple numérique :

- $N = 10000$, $\varepsilon = 0.1$
- $d \approx \frac{\log(10000)}{0.01} \approx \frac{9.2}{0.01} \approx 920$
- Réduction : $D = 10000 \rightarrow d = 920$ (facteur ~ 11)
- **Préservation des distances à 10% près**

Applications pratiques :

1. **Réduction de dimension** : compression de données sans perte significative d'information géométrique
2. **Accélération d'algorithmes** :
 - Calculs en $O(d)$ au lieu de $O(D)$
 - Clustering, k-NN approximatif

3. **Locally Sensitive Hashing (LSH)** : recherche approximative de plus proches voisins en temps sous-linéaire

Principe exploité :

- **Quasi-orthogonalité** en haute dimension : exponentiellement nombreuses directions quasi-orthogonales
- Directions aléatoires forment une base quasi-orthonormale
- Préservation de la structure géométrique avec bien moins de dimensions

Révision Rapide : Instance Concrète de la Blessing

Projections aléatoires (Johnson-Lindenstrauss) : réduction $\mathbb{R}^D \rightarrow \mathbb{R}^d$ avec $d = O(\log N / \varepsilon^2)$ (indépendant de D) préservant distances. **Application** : LSH, accélération algos, réduction dimension. **Principe** : quasi-orthogonalité $\rightarrow$ exponentiellement nombreuses directions.

Question 4 : Pourquoi la dimension augmente-t-elle la parcimonie des données ?

Réponse :

La dimension augmente la parcimonie (*data sparsity*) par **croissance exponentielle du volume** de l'espace.

Explication mathématique :

Considérons l'estimation de densité par histogramme sur $\Omega = [a, b]^D$:

- Quantification : b bins par dimension
- **Nombre total de bins** : b^D (croissance exponentielle)
- Pour qualité n échantillons/bin : besoin de $N = n \cdot b^D$ échantillons

Table d'illustration ($b = 10, n = 10$) :

Dimension D	Nombre de bins b^D	Échantillons nécessaires N
1	10	100
2	100	1,000
3	1,000	10,000
6	1,000,000	10,000,000
10	10,000,000,000	100,000,000,000

Si N est fixé :

- Moyenne d'échantillons par bin : $n = \frac{N}{b^D}$
- **Probabilité qu'un bin soit occupé** : $\mathbb{E}[P(x_i \in \text{bin}_j)] \approx \frac{1}{b^D}$

Conséquence : Pour D croissant :

$$\frac{1}{b^D} \rightarrow 0 \Rightarrow \text{La plupart des bins sont vides}$$

Principe fondamental :

- Volume de l'espace croît comme $V \sim L^D$ (où L est longueur caractéristique)
- Nombre d'échantillons pour "remplir" l'espace : $N \sim L^D$
- **Échelle exponentielle** : chaque dimension supplémentaire multiplie le volume par L

Exemple concret :

- $D = 2$: grille $10 \times 10 = 100$ cellules $\rightarrow$ 100 échantillons pour 1/cellule
- $D = 3$: grille $10 \times 10 \times 10 = 1000$ cellules $\rightarrow$ 1000 échantillons
- $D = 10$: 10^{10} cellules $\rightarrow$ **10 milliards d'échantillons !**

Implications :

- **Régions vides** : La plupart de l'espace n'est jamais "visitée" par les données
- **Estimation de densité** : histogrammes deviennent inutiles
- **Apprentissage supervisé** : manque de données dans la plupart des régions

Révision Rapide : Parcimonie et Dimension

Volume croît comme L^D (exponentiel). Nombre de bins : b^D . Besoin : $N = n \cdot b^D$ échantillons. Si N fixé : $n = N/b^D \rightarrow 0 \rightarrow$ **bins vides**. Chaque dimension multiplie volume par facteur.

Question 5 : Pourquoi le volume se concentre-t-il sur la surface des volumes ?

Réponse :

Le volume se concentre à la surface en haute dimension par **décroissance exponentielle** du ratio de volumes.

Démonstration générale :

Considérons une forme de "mesure" r (rayon pour sphère, côté pour cube) et réduisons par facteur $(1 - \varepsilon)$ avec $\varepsilon \in]0, 1[$.

Pour tout volume :

$$\frac{\text{vol}(\text{forme de mesure } (1 - \varepsilon)r)}{\text{vol}(\text{forme de mesure } r)} = (1 - \varepsilon)^D$$

Limite asymptotique :

$$\lim_{D \rightarrow \infty} (1 - \varepsilon)^D = 0$$

Car $1 - \varepsilon \leq e^{-\varepsilon}$ donc $(1 - \varepsilon)^D \leq e^{-D\varepsilon} \xrightarrow{D \rightarrow \infty} 0$

Proportion du volume près de la surface :

$$\frac{\text{vol}(\text{extérieur})}{\text{vol}(\text{total})} = \frac{\text{vol}(r) - \text{vol}((1 - \varepsilon)r)}{\text{vol}(r)} = 1 - (1 - \varepsilon)^D \xrightarrow{D \rightarrow \infty} 1$$

Exemples numériques :

Pour $\varepsilon = 0.1$ (couche externe = 10% du rayon) :

D	$(1 - \varepsilon)^D = 0.9^D$	% volume externe
2	0.81	19%
5	0.59	41%
10	0.35	65%
20	0.12	88%
50	0.005	99.5%
100	0.000026	100%

Interprétation géométrique :

- En 2D : cercle $\rightarrow$ anneau fin contient peu de volume
- En 3D : sphère $\rightarrow$ coquille fine contient plus de volume
- En haute D : **presque tout le volume** est dans une coquille infiniment fine à la surface

Principe sous-jacent :

- **Décomposition en voxels** : tout volume peut être décomposé en voxels (hyper-)cubiques
- Réduire mesure par $(1 - \varepsilon) \rightarrow$ volume voxel réduit par $(1 - \varepsilon)^D$
- **Effet exponentiel** : même petit ε donne ratio $\rightarrow 0$ quand D grand

Cas de la Gaussienne :

Pour $X \sim \mathcal{N}(0, \text{Id}_D)$:

- $R^2 = \|X\|_2^2 \sim \chi^2(D)$ avec $\mathbb{E}[R^2] = D$
- **Gaussian Annulus Theorem** : $P[|\|X\|_2 - \sqrt{D}| > \beta] \leq 3e^{-c\beta^2}$
- Densité concentrée dans anneau à rayon $\sqrt{D}$ avec épaisseur $O(\sqrt{\log D})$

Conséquence pratique :

- Échantillonnage : difficile de générer points “au centre”
- Taux de rejet pour méthodes Monte Carlo $\rightarrow 100\%$
- Points générés uniformément dans volume $\rightarrow$ concentrés à surface

Révision Rapide : Concentration à la Surface

Ratio $(1 - \varepsilon)^D \xrightarrow{D \rightarrow \infty} 0$. Volume externe : $1 - (1 - \varepsilon)^D \rightarrow 1$. **Décomposition en voxels** : réduction mesure par $(1 - \varepsilon) \rightarrow$ volume par $(1 - \varepsilon)^D$. **Tout le volume** à la surface.

Question 6 : Qu'est-ce qu'un phénomène de concentration ? Comment peut-il être bénéfique ?

Réponse :

Définition :

Un **phénomène de concentration** se produit quand une variable aléatoire (ou une collection de v.a.) prend des valeurs très **proches de son espérance** avec haute probabilité quand la dimension augmente.

Formulation mathématique :

Pour une v.a. Z dépendant de la dimension D :

$$P(|Z - \mathbb{E}[Z]| > \varepsilon) \rightarrow 0 \text{ quand } D \rightarrow \infty$$

Plus précisément, cette probabilité décroît **exponentiellement** avec D .

Exemples de concentration :

1. **Distances** : $\frac{D_{\max} - D_{\min}}{D_{\min}} \rightarrow 0$
2. **Angles** : $\mathbb{E}[\cos(\theta)] \rightarrow 0$ ou $\frac{1}{2}$ (valeurs concentrées)
3. **Norme gaussienne** : $\|X\|_2 \approx \sqrt{D}$ pour $X \sim \mathcal{N}(0, \text{Id}_D)$
4. **Moyenne empirique** : $\bar{X} \rightarrow \mu$ (WLLN)

Comment c'est bénéfique :

1. Estimation statistique (Loi Faible des Grands Nombres)

Principe : Pour $\{X_i\}_{i=1}^D$ i.i.d. avec $\mathbb{E}[X_i] = \mu$:

$$P(|\bar{X} - \mu| < \varepsilon) \xrightarrow{D \rightarrow \infty} 1$$

Bénéfice :

- **Estimation de densité** : histogrammes convergent vers vraie densité
- **Estimateurs statistiques** : convergence garantie
- **Base du Machine Learning** : approximation de fonctions par moyennes empiriques

2. Inégalité de Hoeffding (analyse PAC)

$$P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-2D\varepsilon^2/(b-a)^2}$$

Bénéfice :

- **Borne exponentielle** : très forte garantie de convergence
- **Analyse PAC** (*Probably Approximately Correct*) : fondement théorique du ML
- **Garanties de généralisation** : erreur sur données test proche de l'erreur train

3. Projections aléatoires (Johnson-Lindenstrauss)

Principe : Distances préservées après projection aléatoire en dimension $d = O(\log N / \varepsilon^2)$

Bénéfice :

- **Réduction de dimension** sans perte d'information géométrique
- **Accélération d'algorithmes** : complexité réduite de $O(D)$ à $O(d)$
- **Compression** : stockage et calculs plus efficaces

4. Stabilité numérique

Bénéfice :

- **Prédictibilité** : comportement asymptotique bien défini
- **Théorie de l'approximation** : bornes d'erreur quantifiables
- **Convergence d'algorithmes** : garanties théoriques

Tableau récapitulatif :

Phénomène	Type	Bénéfice
WLLN	Concentration de $\bar{X}$ vers μ	Estimation de densité
Hoeffding	Borne exponentielle	Analyse PAC, généralisation
JL Lemma	Distances préservées en basse dim	Réduction dimension, LSH
Gaussienne	Norme concentrée à $\sqrt{D}$	Propriétés prédictibles

Principe général :

“**La concentration donne de la certitude**” : En haute dimension, les quantités aléatoires deviennent **déterministes** autour de leur espérance.

Révision Rapide : Phénomène de Concentration

$P(|Z - \mathbb{E}[Z]| > \varepsilon) \rightarrow 0$ (exponentielle). **Bénéfices** : (1) WLLN $\rightarrow$ estimation densité, (2) Hoeffding $\rightarrow$ analyse PAC/généralisation, (3) JL Lemma $\rightarrow$ réduction dimension, (4) prédictibilité. **Principe** : aléatoire $\rightarrow$ déterministe.

Question 7 : Pourquoi les angles se concentrent-ils ? Comment peut-on exploiter cela ?

Réponse :

Pourquoi les angles se concentrent :

Cas 1 : Deux vecteurs aléatoires indépendants

Déclarer 4 v.a. i.i.d. W, X, Y, Z sur $\Omega \subset \mathbb{R}^D$ et former deux vecteurs $(X - Y)$ et $(Z - W)$:

$$\mathbb{E}[\cos(\theta)] = \mathbb{E} \left[\frac{\langle X - Y, Z - W \rangle}{\|X - Y\| \cdot \|Z - W\|} \right]$$

Calcul :

$$\langle X - Y, Z - W \rangle = \langle X, Z \rangle - \langle X, W \rangle - \langle Y, Z \rangle + \langle Y, W \rangle$$

Puisque W, X, Y, Z sont i.i.d., en espérance :

$$\mathbb{E}[\langle X, Z \rangle] = \mathbb{E}[\langle X, W \rangle] = \mathbb{E}[\langle Y, Z \rangle] = \mathbb{E}[\langle Y, W \rangle]$$

Donc : $\mathbb{E}[\langle X - Y, Z - W \rangle] = 0$

Résultat :

$$\mathbb{E}[\cos(\theta)] = 0 \implies \theta \sim \frac{\pi}{2}$$

Deux vecteurs aléatoires sont quasi-orthogonaux

Cas 2 : Triangle aléatoire (vecteurs partageant origine)

Déclarer 3 v.a. i.i.d. X, Y, Z et former angle au sommet Y :

$$\mathbb{E}[\cos(\angle(X - Y, Z - Y))] = \mathbb{E} \left[\frac{\langle X - Y, Z - Y \rangle}{\|X - Y\| \cdot \|Z - Y\|} \right]$$

Note : $X - Y$ et $Z - Y$ ne sont plus indépendants (partagent Y) !

Calcul (simplifié) :

$$\frac{\langle X - Y, Z - Y \rangle}{\|X - Y\|^2} = \frac{\langle Y, Y \rangle - \langle X, Y \rangle}{2\langle Y, Y \rangle - 2\langle X, Y \rangle} \xrightarrow{\mathbb{E}} \frac{1}{2}$$

Résultat :

$$\mathbb{E}[\cos(\theta)] = \frac{1}{2} \implies \theta \sim \frac{\pi}{3}$$

Triangle aléatoire est équilatéral

Principe général :

En haute dimension D :

- Produits scalaires de vecteurs indépendants : $\langle u, v \rangle \approx 0$
- Par définition : $\cos(\theta) = \frac{\langle u, v \rangle}{\|u\| \cdot \|v\|}$
- Donc : $\cos(\theta) \approx 0 \rightarrow \theta \approx \pi/2$

Comment exploiter la quasi-orthogonalité :

1. Projections aléatoires (Random Projections)

Principe :

- Générer **directions aléatoires** en haute dimension
- Ces directions forment une **base quasi-orthonormale**
- Utiliser pour projection avec préservation de distances

Application : Johnson-Lindenstrauss Lemma

Projection $p : \mathbb{R}^D \rightarrow \mathbb{R}^d$ avec $d = O(\log N / \varepsilon^2)$ préserve distances

Avantages :

- Pas besoin de calculer SVD/PCA (coûteux)
- Très rapide : simple multiplication matricielle aléatoire
- Garanties théoriques fortes

2. Locally Sensitive Hashing (LSH)

Principe :

- Projeter données sur directions aléatoires
- Points proches $\rightarrow$ mêmes projections (avec haute probabilité)
- Construire table de hachage pour recherche rapide

Algorithme :

1. Générer k vecteurs aléatoires $\{r_1, \dots, r_k\}$
2. Pour chaque point x :
 - Calculer $h(x) = \text{sign}(x \cdot r_1, \dots, x \cdot r_k)$
 - Stocker x dans bucket $h(x)$
3. Recherche : calculer $h(q)$, chercher dans bucket

Complexité :

- Construction : $O(NkD)$
- Recherche : $O(kD + L)$ où L = taille bucket (typiquement $\ll N$)

3. Codage de signaux (Signal Coding)

Compressed Sensing :

- Signal $s \in \mathbb{R}^D$ sparse (peu de coefficients non-nuls)
- Mesures : $y = \Phi s$ où $\Phi \in \mathbb{R}^{m \times D}$ matrice aléatoire ($m \ll D$)
- Reconstruction : résoudre $\min_s \|s\|_1$ sujet à $y = \Phi s$

Garantie : Si Φ a lignes quasi-orthogonales, reconstruction exacte possible avec $m = O(k \log(D/k))$ mesures pour signal k -sparse.

4. Dimension Reduction

Avantages sur PCA :

- Pas de calcul de covariance ($O(D^2 N)$)
- Pas de SVD ($O(D^3)$)
- Données streaming : peut traiter données au vol
- Garanti théoriquement : JL Lemma

5. Tests de randomness

Principe : Tester si vecteurs sont “vraiment aléatoires”

- Calculer angles entre paires
- Si distribution $\cos(\theta) \approx \mathcal{U}([-1, 1])$ en basse dim
- En haute dim : devrait être ≈ 0 (distribution concentrée)

Tableau récapitulatif :

Application	Exploitation	Bénéfice
Random Projections	Base quasi-orthonormale	Réduction dimension rapide
LSH	Hachage par projections	Recherche ANN sous-linéaire
Compressed Sensing	Mesures aléatoires	Acquisition compressée
Streaming	Pas de SVD	Traitement en ligne

Révision Rapide : Concentration des Angles

2 vecteurs indép. : $\mathbb{E}[\cos(\theta)] = 0 \rightarrow \theta \sim \pi/2$. **Triangle** : $\mathbb{E}[\cos(\theta)] = 1/2 \rightarrow \theta \sim \pi/3$.
Exploitation : (1) Projections aléatoires (JL), (2) LSH pour ANN, (3) Compressed

sensing, (4) Codage signaux, (5) Pas de SVD coûteux.

Question 8 : Quel est le taux typique de concentration ?

Réponse :

Le taux typique de concentration en haute dimension est **exponentiel** en la dimension D .

Formes générales :

$$P(|Z - \mathbb{E}[Z]| > \varepsilon) \leq C \cdot e^{-c \cdot D \cdot f(\varepsilon)}$$

où $C, c > 0$ sont des constantes et $f(\varepsilon)$ dépend de ε (souvent $f(\varepsilon) = \varepsilon^2$).

1. Inégalité de Hoeffding

Pour $\{X_i\}_{i=1}^D$ indépendantes avec $P(a \leq X_i \leq b) = 1$ et $\mathbb{E}[X_i] = \mu$:

$$P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-\frac{2D\varepsilon^2}{(b-a)^2}}$$

Taux de concentration : $e^{-2D\varepsilon^2/(b-a)^2}$

Interprétation :

- Décroissance **doublement exponentielle** : exponentielle en D , qui est lui-même dans l'exposant
- Pour D grand, la probabilité devient **astronomiquement petite**

2. Gaussian Annulus Theorem

Pour $X \sim \mathcal{N}(0, \text{Id}_D)$:

$$P\left[\left|\|X\|_2 - \sqrt{D}\right| > \beta\right] \leq 3e^{-c\beta^2}$$

Taux de concentration : $e^{-c\beta^2}$ (exponentiel en β^2)

Remarque : Pour $\beta = \varepsilon\sqrt{D}$:

$$P\left[\left|\frac{\|X\|_2}{\sqrt{D}} - 1\right| > \varepsilon\right] \leq 3e^{-cD\varepsilon^2}$$

Taux : $e^{-cD\varepsilon^2}$ (exponentiel en D)

3. Concentration des distances (Beyer et al.)

Pour la variance de distances normalisées qui tend vers 0 :

$$\text{Var}\left[\frac{d(x, y)^p}{\mathbb{E}[d(x, y)^p]}\right] = O\left(\frac{1}{D}\right)$$

Taux : $\frac{1}{D}$ (polynomial, plus lent)

4. Distribution du volume

Proportion de volume dans couche externe :

$$1 - (1 - \varepsilon)^D$$

Pour ε petit : $(1 - \varepsilon)^D \approx e^{-D\varepsilon}$

Taux : $e^{-D\varepsilon}$ (exponentiel en D)

Table comparative :

Phénomène	Borne de concentration	Taux	Type
Hoeffding	$2e^{-2D\varepsilon^2/(b-a)^2}$	$e^{-O(D\varepsilon^2)}$	Exponentiel

Phénomène	Borne de concentration	Taux	Type
Gaussian Annulus	$3e^{-c\beta^2}$ (avec $\beta = \varepsilon\sqrt{D}$)	$e^{-O(D\varepsilon^2)}$	Exponentiel
Volume	$e^{-D\varepsilon}$	$e^{-O(D\varepsilon)}$	Exponentiel
Variance distances	$O(1/D)$	Polynomial	Plus lent

Ordre de grandeur :

Pour $D = 100$ et $\varepsilon = 0.1$:

- Hoeffding (avec $b - a = 2$) : $\approx 2e^{-2 \cdot 100 \cdot 0.01/4} = 2e^{-0.5} \approx 1.2...$ (borne lâche)
- Calcul précis : $2e^{-5} \approx 0.0135$
- Gaussian : $3e^{-c \cdot 100 \cdot 0.01} = 3e^{-c}$ (avec $c \sim 1$) ≈ 1.1
- Volume : $e^{-100 \cdot 0.1} = e^{-10} \approx 4.5 \times 10^{-5}$

Pour $D = 1000$:

- Volume : $e^{-1000 \cdot 0.1} = e^{-100} \approx 3.7 \times 10^{-44}$ (astronomiquement petit !)

Caractéristiques importantes :

1. **Convergence rapide** : quelques dizaines de dimensions suffisent pour concentration forte
2. **Universalité** : même forme e^{-cD} pour beaucoup de phénomènes
3. **Indépendance du nombre d'échantillons** N : dépend surtout de D
4. **Seuil critique** : $D \gtrsim 10$ où effets deviennent prononcés

Taux relatifs :

- **Concentration positive** (WLLN, Hoeffding) : $O(e^{-cD\varepsilon^2}) \rightarrow$ très rapide
- **Concentration négative** (volume à surface) : $O(e^{-cD\varepsilon}) \rightarrow$ très rapide
- **Concentration des distances** : $O(1/D) \rightarrow$ plus lent (caveat dans Random Projections)

Révision Rapide : Taux de Concentration

Taux typique : **exponentiel** en D . **Hoeffding** : $2e^{-2D\varepsilon^2/(b-a)^2}$. **Gaussian Annulus** : $3e^{-c\beta^2}$ (avec $\beta \sim \varepsilon\sqrt{D}$). **Volume** : $e^{-D\varepsilon}$. **Forme générale** : $e^{-O(D)}$. Convergence **très rapide**, seuil $D \gtrsim 10$.

Question 9 : Citez une inégalité de concentration. Pouvez-vous la prouver ?

Réponse :

Inégalité de Hoeffding

Énoncé

Soit $\{X_i\}_{i=1}^D$ des variables aléatoires **indépendantes** telles que $P(a \leq X_i \leq b) = 1$ et $\mathbb{E}[X_i] = \mu$.
Alors pour tout $\varepsilon > 0$:

$$P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-\frac{2D\varepsilon^2}{(b-a)^2}}$$

où $\bar{X} = \frac{1}{D} \sum_{i=1}^D X_i$.

Preuve

Étape 1 : Symétrie et décomposition

Par symétrie :

$$P(|\bar{X} - \mu| > \varepsilon) = P(\bar{X} - \mu > \varepsilon) + P(\bar{X} - \mu < -\varepsilon)$$

Par symétrie, les deux termes sont égaux. On se concentre sur :

$$P(\bar{X} - \mu > \varepsilon)$$

Étape 2 : Inégalité de Markov

Pour tout $t > 0$:

$$P(\bar{X} - \mu > \varepsilon) = P(e^{t(\bar{X}-\mu)} > e^{t\varepsilon}) \leq \frac{\mathbb{E}[e^{t(\bar{X}-\mu)}]}{e^{t\varepsilon}}$$

(par inégalité de Markov pour $e^{t(\bar{X}-\mu)}$ qui est non-négatif)

Étape 3 : Indépendance et factorisation

$$\mathbb{E}[e^{t(\bar{X}-\mu)}] = \mathbb{E}\left[e^{t\left(\frac{1}{D} \sum_{i=1}^D X_i - \mu\right)}\right] = \mathbb{E}\left[e^{\frac{t}{D} \sum_{i=1}^D (X_i - \mu)}\right]$$

Par **indépendance** des X_i :

$$= \prod_{i=1}^D \mathbb{E} \left[e^{\frac{t}{D}(X_i - \mu)} \right]$$

Étape 4 : Lemme de Hoeffding

Lemme : Si $\mathbb{E}[Y] = 0$ et $a \leq Y \leq b$, alors :

$$\mathbb{E}[e^{tY}] \leq e^{\frac{t^2(b-a)^2}{8}}$$

Application : Pour $Y_i = \frac{1}{D}(X_i - \mu)$, on a $\mathbb{E}[Y_i] = 0$ et $\frac{a-\mu}{D} \leq Y_i \leq \frac{b-\mu}{D}$.

Range : $\frac{b-a}{D}$

Donc :

$$\mathbb{E}[e^{tY_i}] \leq e^{\frac{t^2(b-a)^2}{8D^2}}$$

Étape 5 : Produit et optimisation

$$\mathbb{E}[e^{t(\bar{X} - \mu)}] \leq \prod_{i=1}^D e^{\frac{t^2(b-a)^2}{8D^2}} = e^{\frac{t^2(b-a)^2}{8D}}$$

Donc :

$$P(\bar{X} - \mu > \varepsilon) \leq \frac{e^{\frac{t^2(b-a)^2}{8D}}}{e^{t\varepsilon}} = e^{\frac{t^2(b-a)^2}{8D} - t\varepsilon}$$

Optimisation en t : dériver par rapport à t et annuler :

$$\frac{d}{dt} \left(\frac{t^2(b-a)^2}{8D} - t\varepsilon \right) = \frac{t(b-a)^2}{4D} - \varepsilon = 0$$

$$\Rightarrow t^* = \frac{4D\varepsilon}{(b-a)^2}$$

Substitution :

$$\frac{(t^*)^2(b-a)^2}{8D} - t^*\varepsilon = \frac{16D^2\varepsilon^2}{(b-a)^4} \cdot \frac{(b-a)^2}{8D} - \frac{4D\varepsilon^2}{(b-a)^2}$$

$$= \frac{2D\varepsilon^2}{(b-a)^2} - \frac{4D\varepsilon^2}{(b-a)^2} = -\frac{2D\varepsilon^2}{(b-a)^2}$$

Donc :

$$P(\bar{X} - \mu > \varepsilon) \leq e^{-\frac{2D\varepsilon^2}{(b-a)^2}}$$

Étape 6 : Par symétrie

$$P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-\frac{2D\varepsilon^2}{(b-a)^2}}$$

□

Preuve du Lemme de Hoeffding (esquisse) :

Pour $\mathbb{E}[Y] = 0$ et $a \leq Y \leq b$:

- Par convexité de e^{tY} , on a :

$$e^{tY} \leq \frac{b-Y}{b-a}e^{ta} + \frac{Y-a}{b-a}e^{tb}$$

- Prendre l'espérance (et utiliser $\mathbb{E}[Y] = 0$) :

$$\mathbb{E}[e^{tY}] \leq \frac{be^{ta} - ae^{tb}}{b-a}$$

- Poser $u = t(b-a)$, $\alpha = -\frac{a}{b-a}$ et utiliser :

$$\log(\alpha e^{-u} + (1-\alpha)e^{u(1-\alpha)/\alpha}) \leq \frac{u^2}{8}$$

- On obtient :

$$\mathbb{E}[e^{tY}] \leq e^{\frac{t^2(b-a)^2}{8}}$$

Révision Rapide : Inégalité de Hoeffding

Énoncé : $P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-2D\varepsilon^2/(b-a)^2}$ pour X_i indép., bornées $[a, b]$. **Preuve** : (1) Markov : $P(\bar{X} > \mu + \varepsilon) \leq \mathbb{E}[e^{t(\bar{X}-\mu)}]/e^{t\varepsilon}$, (2) Indépendance : factorisation, (3) Lemme Hoeffding : $\mathbb{E}[e^{tY}] \leq e^{t^2(b-a)^2/8}$, (4) Optimiser t .

Question 10 : Détaillez une situation concrète où la concentration est bénéfique

Réponse :

Situation concrète : Estimation de moyenne pour sondage d'opinion

Contexte

Entreprise : Une plateforme de streaming vidéo veut estimer la **satisfaction moyenne** de ses utilisateurs.

Population :

- $N_{\text{total}} = 100$ millions d'utilisateurs
- Chaque utilisateur a un niveau de satisfaction $X_i \in [1, 5]$ (échelle Likert)
- Vraie moyenne : μ (inconnue)

Objectif : Estimer μ avec précision $\varepsilon = 0.1$ (erreur de ± 0.1) avec confiance 95%.

Approche naïve (sans concentration)

Sondage exhaustif :

- Interroger TOUS les 100 millions d'utilisateurs
- Coût : prohibitif (temps, argent)
- Délai : plusieurs mois

Approche avec concentration (échantillonnage)

Échantillonnage aléatoire :

- Tirer D utilisateurs **uniformément au hasard**
- Calculer moyenne empirique $\bar{X} = \frac{1}{D} \sum_{i=1}^D X_i$

Application de Hoeffding :

Pour variables X_i indépendantes avec $a = 1$, $b = 5$:

$$P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-\frac{2D\varepsilon^2}{(b-a)^2}} = 2e^{-\frac{2D \cdot 0.01}{16}} = 2e^{-\frac{D}{800}}$$

Calcul de taille d'échantillon :

Pour confiance 95%, on veut :

$$P(|\bar{X} - \mu| \leq 0.1) \geq 0.95$$

Donc :

$$P(|\bar{X} - \mu| > 0.1) \leq 0.05$$

Par Hoeffding :

$$2e^{-\frac{D}{800}} \leq 0.05$$

$$e^{-\frac{D}{800}} \leq 0.025$$

$$-\frac{D}{800} \leq \log(0.025) \approx -3.69$$

$$D \geq 800 \times 3.69 \approx 2952$$

Arrondi : $D = 3000$ échantillons suffisent !

Bénéfices de la concentration

1. Réduction drastique de coût

- **Sans concentration** : 100 millions d'interrogations
- **Avec concentration** : 3000 interrogations
- **Facteur** : $\frac{100,000,000}{3000} \approx 33,000$ fois moins !

2. Garanties mathématiques

- **Certitude** : 95% de confiance que $|\bar{X} - \mu| \leq 0.1$
- **Indépendance de N_{total}** : taille échantillon ne dépend QUE de précision et confiance souhaitées
- **Formule explicite** : on peut calculer exactement combien d'échantillons nécessaires

3. Temps et praticité

- Sondage réalisable en **quelques jours** au lieu de mois
- Mise à jour régulière possible (tracking mensuel)

4. Scalabilité

Pour différentes précisions :

Précision ε	Confiance	Taille échantillon D	Coût relatif
0.2	95%	~750	$0.25\times$
0.1	95%	~3,000	$1\times$
0.05	95%	~12,000	$4\times$
0.1	99%	~4,600	$1.5\times$

Observation : Pour diviser l'erreur par 2, il faut multiplier échantillon par 4 (relation $D \propto \frac{1}{\varepsilon^2}$)

Généralisation : Théorème Central Limite

Amélioration avec CLT :

Si $\text{Var}(X_i) = \sigma^2$ connue, on peut utiliser :

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{D}} \sim \mathcal{N}(0, 1)$$

Pour confiance 95% (intervalle ± 1.96 écart-types) :

$$P\left(|\bar{X} - \mu| \leq 1.96 \frac{\sigma}{\sqrt{D}}\right) \approx 0.95$$

Pour $\varepsilon = 0.1$:

$$1.96 \frac{\sigma}{\sqrt{D}} = 0.1 \implies D = \left(\frac{1.96\sigma}{0.1}\right)^2$$

Si $\sigma \approx 1$ (estimation) : $D \approx 385$

Comparaison :

- **Hoeffding** : $D \approx 3000$ (borne conservatrice, pire cas)
- **CLT** : $D \approx 385$ (utilise connaissance de variance)

En pratique : on utilise CLT quand variance estimable, sinon Hoeffding

Autres situations bénéfiques

1. A/B Testing (web) :

- Tester deux versions d'un site
- Besoin petit échantillon pour détecter différence significative
- Concentration garantit validité statistique

2. Contrôle qualité (industrie) :

- Vérifier qualité production sans tout tester
- Échantillon de $n \approx 100 - 1000$ suffit pour population millions
- Économie massive en temps et destruction d'échantillons

3. Machine Learning (validation) :

- Estimer erreur de généralisation sur échantillon test
- Concentration garantit que erreur test $\approx$ erreur population
- Base théorique pour *train/validation/test split*

Révision Rapide : Concentration Bénéfique

Sondage d'opinion : estimer moyenne population 100M avec $D = 3000$ échantillons (facteur 33,000 $\times$). **Hoeffding** : $D \geq 800 \times \log(2/\delta)/\varepsilon^2$. **Bénéfices** : (1) coût réduit, (2) garanties mathématiques 95%, (3) rapide, (4) scalable. **Applications** : A/B testing, contrôle qualité, validation ML.

Question 11 : Détaillez une situation concrète où la concentration est adverse

Réponse :

Situation concrète : Recherche de plus proches voisins pour système de recommandation

Contexte

Entreprise : Plateforme de streaming musical (type Spotify).

Données :

- Base de $N = 10$ millions de chansons
- Chaque chanson représentée par vecteur de features audio : $x \in \mathbb{R}^D$ avec $D = 200$

- Features : tempo, timbre, harmonies, MFCC (*Mel-Frequency Cepstral Coefficients*), etc.

Objectif : Pour une chanson requête q , trouver les $k = 10$ chansons les plus similaires pour recommandation.

Algorithme : *k-Nearest Neighbors* (k-NN) basé sur distance Euclidienne.

Le problème : Concentration des distances

Phénomène : En dimension $D = 200$, toutes les distances se **concentrent**.

Théorème (Beyer et al.) :

Si $\lim_{D \rightarrow \infty} \text{Var} \left[\frac{d(x,y)^p}{\mathbb{E}[d(x,y)^p]} \right] = 0$, alors :

$$\lim_{D \rightarrow \infty} P \left[\frac{D_{\max} - D_{\min}}{D_{\min}} \leq \varepsilon \right] = 1$$

où $D_{\max}$, $D_{\min}$ sont distances au voisin le plus éloigné et le plus proche.

Concrètement : Pour $D = 200$, on observe empiriquement :

$$\frac{D_{\max} - D_{\min}}{D_{\min}} \approx 0.01 \text{ à } 0.05$$

Interprétation : Les 10 plus proches voisins et les 10,000ème voisins sont quasiment à la même distance !

Conséquences adverses

1. Perte de pouvoir discriminant

Expérience empirique :

Chanson requête: "Bohemian Rhapsody" (Queen)

k-NN traditionnel avec D=200:

Voisin 1: distance = 14.23

Voisin 2: distance = 14.25

Voisin 3: distance = 14.26

...

Voisin 10: distance = 14.31

...

Voisin 1000: distance = 14.89

Problème : Différence entre voisin 1 et 1000 : $(14.89 - 14.23)/14.23 \approx 4.6\%$ seulement !

Conséquence : Difficile de distinguer les “vraiment proches” des “moyennement proches”.

2. Recommandations de mauvaise qualité

Résultat utilisateur :

Recommandations pour "Bohemian Rhapsody":

1. "We Will Rock You" (Queen) pertinent
2. "Stairway to Heaven" (Led Zeppelin) pertinent
3. "Random Jazz Track" non pertinent
4. "Classical Piano" non pertinent
5. "Electronic Dance" non pertinent
- ...

Raison : Les chansons 3-5 sont presque à la même distance que 1-2, donc sélectionnées “aléatoirement”.

Impact métrique :

- **Précision@10** : chute de 80% (basse dimension) à 30% (haute dimension)
- **User satisfaction** : baisse significative

3. Complexité computationnelle

Index spatial (kd-tree) :

En basse dimension ($D \leq 10$) :

- Partition de l'espace efficace
- Recherche en $O(\log N)$

En haute dimension ($D = 200$) :

- Concentration des distances $\rightarrow$ partition inefficace
- Chaque cellule doit couvrir rayon $\approx$ rayon total
- **Dégénération** : recherche devient $O(N)$ (exhaustive)

Mesure empirique :

Dimension D	Temps recherche (ms)	Amélioration vs linéaire
3	0.5	200×
10	2	50×
50	45	2×
100	85	1.2×

Dimension D	Temps recherche (ms)	Amélioration vs linéaire
200	98	1.02×

Conclusion : Pour $D = 200$, kd-tree est **inutile** (presque aussi lent que recherche linéaire).

4. Hubness

Phénomène : Certaines chansons deviennent **hubs**, apparaissant dans les k-NN de presque toutes les requêtes.

Distribution empirique de n_k (nombre de fois où chanson est k-NN) :

Chanson A: $n_k = 0$ (jamais voisin)

Chanson B: $n_k = 2$ (rare)

...

Chanson C: $n_k = 4500$ (hub!) ← apparaît pour 45% des requêtes

Chanson D: $n_k = 3200$ (hub!)

Conséquence :

- Même recommandations pour beaucoup d'utilisateurs différents
- Perte de **personnalisation**
- Expérience utilisateur dégradée

Coût business

Mesures d'impact :

- **Taux d'écoute des recommandations** : chute de 25%
- **Temps d'écoute moyen** : baisse de 18%
- **Satisfaction utilisateur (NPS)** : baisse de 15 points
- **Coût computationnel** : $O(N)$ pour chaque requête
 - 10^7 chansons $\times$ 200 features $\times$ distance calcul
 - Pour 1000 requêtes/seconde : infrastructure serveur très coûteuse

Estimation financière :

- Infrastructure : +\$500k/an pour supporter recherche exhaustive
- Perte engagement utilisateur : -\$2M/an en revenus publicitaires

Solutions (atténuation)

1. Réduction de dimensionnalité

PCA (Principal Component Analysis) :

- Projeter $\mathbb{R}^{200} \rightarrow \mathbb{R}^{20}$
- Garder 90% de variance
- k-NN en dimension 20 beaucoup plus efficace

Résultat :

- Précision@10 : remonte à 65%
- Temps recherche : réduit de 80%

2. Approximate Nearest Neighbors (ANN)

Algorithmes : LSH (*Locality-Sensitive Hashing*), HNSW (*Hierarchical Navigable Small World*)

Principe : Trade-off précision vs vitesse

- Garantie : trouver ϵ -ANN avec prob. $1 - \delta$
- Complexité : $O(\log N)$ au lieu de $O(N)$

3. Apprentissage de métriques

Metric Learning :

- Apprendre transformation $\Phi : \mathbb{R}^D \rightarrow \mathbb{R}^d$ ($d \ll D$)
- Supervisé : paires similaires/dissimilaires
- Objectif : maximiser séparabilité

Résultat :

- Précision@10 : remonte à 78%
- Distance entre voisins pertinents non-pertinents

4. Features spécialisées

Ingénierie de features :

- Au lieu de 200 features génériques
- Construire 20-30 features **hautement informatives**
- Exemple : genre musical, époque, instrumentalisation

Trade-off : Expertise domaine nécessaire, mais efficacité +++

Tableau récapitulatif

Aspect	Problème (haute dim)	Solution
Discrimination	Distances concentrées	Réduction dimension
Qualité recommandations	Précision@10 = 30%	Metric learning
Temps calcul	$O(N)$ exhaustif	ANN (LSH, HNSW)
Hubness	Même résultats partout	Features spécialisées
Coût	+\$500k infra/an	PCA, compression

Généralisation

Autres domaines affectés :

1. Computer Vision

- Images haute résolution : $D = 1024 \times 1024 \times 3 \approx 3M$
- Recherche d'images similaires inefficace
- Solution : CNN embeddings en basse dimension ($D \sim 128 - 512$)

2. NLP (Natural Language Processing)

- Word embeddings : $D = 300$ (Word2Vec)
- BERT : $D = 768$
- Recherche sémantique souffre de concentration
- Solution : embeddings compressés, quantization

3. Bioinformatique

- Séquences génétiques : $D \sim 10^4 - 10^6$
- Clustering de gènes/protéines
- Solution : sélection de features, dimensionality reduction

Révision Rapide : Concentration Adverse

k-NN haute dimension : distances concentrées $\rightarrow (D_{\max} - D_{\min})/D_{\min} \approx 0.01 \rightarrow$ discrimination impossible. **Conséquences** : précision↓, temps $O(N)$, hubness. **Impact** : recommandations mauvaises, coût+++ . **Solutions** : PCA, ANN (LSH), metric learning, features spécialisées.

Question 12 : Qu'est-ce qu'une analyse PAC ?

Réponse :

PAC = *Probably Approximately Correct*

Une **analyse PAC** est un cadre théorique en apprentissage automatique qui fournit des **garanties probabilistes** sur la qualité de l'apprentissage.

Définition formelle

Un algorithme d'apprentissage est dit **PAC-learnable** si :

Pour tout :

- Précision souhaitée $\varepsilon > 0$ (erreur tolérée)
- Confiance souhaitée $\delta > 0$ (probabilité d'échec tolérée)

Il existe :

- Taille d'échantillon d'entraînement $N = N(\varepsilon, \delta)$
- Complexité computationnelle $T = T(\varepsilon, \delta)$ polynomial

Tel que :

Avec probabilité au moins $(1 - \delta)$, l'erreur de généralisation est au plus ε :

$$P[\text{erreur}(h) \leq \varepsilon] \geq 1 - \delta$$

où h est l'hypothèse (modèle) apprise.

Les deux composantes

1. Probably (Probabiliste)

- La garantie est **probabiliste**, pas déterministe
- On tolère une probabilité δ d'échec
- Exemple : $\delta = 0.05 \rightarrow$ confiance 95%

2. Approximately Correct (Approximativement correct)

- On n'exige pas erreur nulle (souvent impossible)
- On tolère erreur ε
- Exemple : $\varepsilon = 0.1 \rightarrow$ erreur 10%

Relation avec inégalités de concentration

Les **inégalités de concentration** (comme Hoeffding) sont les outils mathématiques fondamentaux pour l'analyse PAC.

Exemple avec Hoeffding :

Pour estimateur $\bar{X}$ de moyenne μ :

$$P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-\frac{2N\varepsilon^2}{(b-a)^2}}$$

Interprétation PAC :

- Choisir $\delta = 2e^{-\frac{2N\varepsilon^2}{(b-a)^2}}$
- Résoudre pour N :

$$N \geq \frac{(b-a)^2}{2\varepsilon^2} \log\left(\frac{2}{\delta}\right)$$

Garantie : Avec N échantillons, l'erreur $|\bar{X} - \mu|$ est ε avec probabilité $(1 - \delta)$.

Exemple concret : Classification binaire

Problème :

- Espace d'entrée X , labels $Y \in \{0, 1\}$
- Distribution inconnue $\mathcal{D}$ sur $X \times Y$
- Classe d'hypothèses $\mathcal{H}$ (e.g., classifieurs linéaires)

Objectif : Trouver $h \in \mathcal{H}$ avec faible erreur de généralisation :

$$\text{err}(h) = P_{(x,y) \sim \mathcal{D}}[h(x) \neq y]$$

Analyse PAC :

Soit $\hat{\text{err}}(h)$ l'erreur empirique sur échantillon d'entraînement de taille N .

Théorème : Pour toute classe $\mathcal{H}$ de dimension VC d , avec probabilité au moins $(1 - \delta)$:

$$\text{err}(h) \leq \hat{\text{err}}(h) + \sqrt{\frac{d \log(2N/d) + \log(2/\delta)}{N}}$$

Taille d'échantillon nécessaire :

Pour garantir $\text{err}(h) \leq \varepsilon$ avec confiance $(1 - \delta)$:

$$N = O\left(\frac{d + \log(1/\delta)}{\varepsilon^2}\right)$$

Composantes d'une borne PAC

Forme générale :

$$N \geq \frac{C}{\varepsilon^p} \cdot f(d, \delta)$$

où :

- C : constante
- ε : précision (erreur tolérée)
- p : typiquement 1 ou 2
- $f(d, \delta)$: dépend de complexité modèle (d) et confiance (δ)

Facteurs clés :

Facteur	Impact	Intuition
ε	$N \propto 1/\varepsilon^2$	Diviser erreur par 2 $\rightarrow$ 4 $\times$ plus d'échantillons
δ	$N \propto \log(1/\delta)$	Doubler confiance $\rightarrow$ logarithmique en N
d (complexité)	$N \propto d$	Modèle plus complexe $\rightarrow$ plus d'échantillons

Applications en Data Science

1. Validation croisée

Question : Combien de données dans ensemble test ?

Analyse PAC : Pour estimer erreur vraie à ε près avec confiance $1 - \delta$:

$$N_{\text{test}} \geq \frac{1}{2\varepsilon^2} \log\left(\frac{2}{\delta}\right)$$

Exemple : $\varepsilon = 0.05$, $\delta = 0.05$:

$$N_{\text{test}} \geq \frac{1}{2 \cdot 0.0025} \log(40) \approx \frac{3.69}{0.005} \approx 738$$

2. Sélection de modèle

Trade-off biais-variance :

- Modèle simple (d petit) : $\hat{\text{err}}$ grand mais borne PAC petite
- Modèle complexe (d grand) : $\hat{\text{err}}$ petit mais borne PAC grande

Principe : Minimiser borne PAC (pas seulement erreur empirique).

3. Regularisation

Objectif régularisé :

$$\min_{h \in \mathcal{H}} \hat{\text{err}}(h) + \lambda \cdot \text{complexité}(h)$$

Le terme de complexité correspond à la borne PAC.

4. Early stopping

Principe : Arrêter entraînement quand borne PAC commence à augmenter (sur-apprentissage).

Limites de l'analyse PAC

1. Bornes pessimistes

- Souvent très larges en pratique
- Modèles réels performant mieux que garanti

2. Dépendance distributionnelle

- Suppose distribution $\mathcal{D}$ fixe
- En pratique : distribution shift, non-stationnarité

3. Complexité computationnelle

- PAC-learnability : efficacité pratique
- Algorithme peut être polynomial mais impraticable

4. Hypothèses indépendance

- Suppose échantillons i.i.d.
- Données temporelles, spatiales : corrélées

Extensions

1. Agnostic PAC learning

- Sans hypothèse sur réalisabilité (meilleur $h \in \mathcal{H}$ peut avoir erreur > 0)


2. PAC-Bayes

- Distributions sur hypothèses
- Bornes plus fines pour ensembles de modèles

3. Online learning

- Garanties PAC pour apprentissage séquentiel
- Regret bounds

Résumé visuel



Révision Rapide : Analyse PAC

PAC = *Probably Approximately Correct*. **Garantie** : avec prob. $(1 - \delta)$, erreur $\leq \epsilon$.

Échantillons : $N = O\left(\frac{d + \log(1/\delta)}{\epsilon^2}\right)$. **Outil** : inégalités de concentration (Hoeffding).

Applications : validation croisée, sélection modèle, régularisation. **Principe** : quantifier combien d'échantillons pour apprendre avec garanties.