

## Table of contents

|                                                                                                      |    |
|------------------------------------------------------------------------------------------------------|----|
| Questions d'Examen . . . . .                                                                         | 2  |
| Question 1 : Qu'est-ce que la dimension ? . . . . .                                                  | 2  |
| Question 2 : Citez une instance concrète de la Malédiction de la Dimensionnalité . . . . .           | 3  |
| Question 3 : Citez une instance concrète de la Bénédiction de la Dimensionnalité . . . . .           | 4  |
| Question 4 : Pourquoi la dimension augmente-t-elle la parcimonie des données ? . . . . .             | 5  |
| Question 5 : Pourquoi le volume se concentre-t-il sur la surface des volumes ? . . . . .             | 6  |
| Question 6 : Qu'est-ce qu'un phénomène de concentration ? Comment peut-il être bénéfique ? . . . . . | 8  |
| 1. <b>Estimation statistique (Loi Faible des Grands Nombres)</b> . . . . .                           | 9  |
| 2. <b>Inégalité de Hoeffding (analyse PAC)</b> . . . . .                                             | 9  |
| 3. <b>Projections aléatoires (Johnson-Lindenstrauss)</b> . . . . .                                   | 9  |
| 4. <b>Stabilité numérique</b> . . . . .                                                              | 9  |
| Question 7 : Pourquoi les angles se concentrent-ils ? Comment peut-on exploiter cela ? . . . . .     | 10 |
| Cas 1 : Deux vecteurs aléatoires indépendants . . . . .                                              | 10 |
| Cas 2 : Triangle aléatoire (vecteurs partageant origine) . . . . .                                   | 11 |
| 1. <b>Projections aléatoires (Random Projections)</b> . . . . .                                      | 12 |
| 2. <b>Locally Sensitive Hashing (LSH)</b> . . . . .                                                  | 12 |
| 3. <b>Codage de signaux (Signal Coding)</b> . . . . .                                                | 13 |
| 4. <b>Dimension Reduction</b> . . . . .                                                              | 13 |
| 5. <b>Tests de randomness</b> . . . . .                                                              | 13 |
| Question 8 : Quel est le taux typique de concentration ? . . . . .                                   | 14 |
| 1. <b>Inégalité de Hoeffding</b> . . . . .                                                           | 14 |
| 2. <b>Gaussian Annulus Theorem</b> . . . . .                                                         | 15 |
| 3. <b>Concentration des distances (Beyer et al.)</b> . . . . .                                       | 15 |
| 4. <b>Distribution du volume</b> . . . . .                                                           | 15 |
| Question 9 : Citez une inégalité de concentration. Pouvez-vous la prouver ? . . . . .                | 17 |
| Énoncé . . . . .                                                                                     | 17 |
| Preuve . . . . .                                                                                     | 17 |
| Question 10 : Détaillez une situation concrète où la concentration est bénéfique . . . . .           | 20 |
| Contexte . . . . .                                                                                   | 20 |
| Approche naïve (sans concentration) . . . . .                                                        | 20 |
| Approche avec concentration (échantillonnage) . . . . .                                              | 20 |
| Bénéfices de la concentration . . . . .                                                              | 21 |
| Généralisation : Théorème Central Limite . . . . .                                                   | 22 |
| Autres situations bénéfiques . . . . .                                                               | 23 |
| Question 11 : Détaillez une situation concrète où la concentration est adverse . . . . .             | 23 |
| Contexte . . . . .                                                                                   | 23 |
| Le problème : Concentration des distances . . . . .                                                  | 24 |
| Conséquences adverses . . . . .                                                                      | 24 |

|                                                        |    |
|--------------------------------------------------------|----|
| Coût business . . . . .                                | 26 |
| Solutions (atténuation) . . . . .                      | 27 |
| Tableau récapitulatif . . . . .                        | 28 |
| Généralisation . . . . .                               | 28 |
| Question 12 : Qu'est-ce qu'une analyse PAC ? . . . . . | 29 |
| Définition formelle . . . . .                          | 29 |
| Les deux composantes . . . . .                         | 29 |
| Relation avec inégalités de concentration . . . . .    | 30 |
| Exemple concret : Classification binaire . . . . .     | 30 |
| Composantes d'une borne PAC . . . . .                  | 31 |
| Applications en Data Science . . . . .                 | 31 |
| Limites de l'analyse PAC . . . . .                     | 32 |
| Extensions . . . . .                                   | 33 |
| Résumé visuel . . . . .                                | 34 |

## Questions d'Examen

### Question 1 : Qu'est-ce que la dimension ?

Réponse :

La **dimension**  $D$  d'un espace de représentation  $\Omega \subseteq \mathbb{R}^D$  représente le nombre de coordonnées nécessaires pour décrire un point dans cet espace.

Formellement :

- Dimension mathématique : nombre de vecteurs de base linéairement indépendants nécessaires pour engendrer l'espace
- En data science : nombre de **features** ou **attributs** d'un vecteur de données  $x \in \mathbb{R}^D$

Types de dimension :

- **Dimension ambiante** (*ambient dimension*) : dimension de l'espace  $\mathbb{R}^D$  dans lequel les données sont représentées
- **Dimension intrinsèque** (*intrinsic dimension*) : dimension réelle du sous-espace (manifold) que les données peuplent effectivement (souvent  $\ll D$ )

**Exemple** : - Image  $100 \times 100$  pixels :  $D = 10000$  (dimension ambiante) - Si les images représentent des visages, la dimension intrinsèque pourrait être  $\sim 50 - 100$

#### Révision Rapide : Dimension

$D$  = nombre de coordonnées/features. **Dimension ambiante** :  $\mathbb{R}^D$  où vivent les données.  
**Dimension intrinsèque** : dimension réelle du manifold peuplé (souvent  $\ll D$ ).

---

## Question 2 : Citez une instance concrète de la Malédiction de la Dimensionnalité

Réponse :

**Instance concrète : Concentration des distances et échec du k-NN**

Dans un problème de classification avec  $k$ -plus proches voisins ( $k$ -NN) :

**Contexte :**

- Dataset  $X$  avec  $N = 1000$  points en dimension  $D = 100$
- Algorithme k-NN cherche les  $k = 10$  plus proches voisins d'un point requête  $q$

**Problème :**

- En haute dimension, le théorème de concentration des distances stipule que :

$$\lim_{D \rightarrow \infty} P \left[ \frac{D_{\max} - D_{\min}}{D_{\min}} \leq \varepsilon \right] = 1$$

- Concrètement : **tous les voisins sont approximativement équidistants** du point requête
- La différence entre le plus proche et le plus éloigné voisin devient **négligeable**

**Conséquence pratique :**

- Le choix des  $k$  voisins devient **arbitraire** (tous sont “également bons”)
- Le **pouvoir discriminant** de l'algorithme disparaît
- La précision de classification **chute drastiquement**
- L'algorithme k-NN perd son utilité

**Mesure empirique :** Pour  $D = 100$ , le ratio  $\frac{D_{\max} - D_{\min}}{D_{\min}}$  peut être  $< 0.01$ , rendant la distinction entre voisins impossible.

**Autre exemple : Sphère vide**

Dans un échantillonnage par rejet pour générer des points dans une sphère :

- Ratio  $\frac{\text{vol}(B_D(r))}{\text{vol}(C_D(r))} \rightarrow 0$  quand  $D \rightarrow \infty$
- Pour  $D = 10$  et rayon unitaire : ratio  $\approx 0.0025 \rightarrow$  **99.75% de rejet**
- Processus devient **impraticable**

**Révision Rapide : Instance Concrète de la Curse**

**k-NN en haute dimension :** distances se concentrent  $\rightarrow \frac{D_{\max} - D_{\min}}{D_{\min}} \rightarrow 0 \rightarrow$

tous voisins équidistants  $\rightarrow$  discrimination impossible. **Échantillonnage par rejet**  
:  $\text{vol}(B_D)/\text{vol}(C_D) \rightarrow 0 \rightarrow \text{taux rejet} \rightarrow 100\%$ .

---

### Question 3 : Citez une instance concrète de la Bénédiction de la Dimensionnalité

Réponse :

Instance concrète : **Projections aléatoires et lemme de Johnson-Lindenstrauss**

En apprentissage automatique et traitement de données massives :

Contexte :

- Dataset  $X$  avec  $N = 10000$  points en très haute dimension  $D = 10000$  (e.g., représentation TF-IDF de documents)
- Calculs coûteux : distances, produits scalaires, clustering

**Solution via projections aléatoires :**

Le lemme de Johnson-Lindenstrauss garantit qu'il existe une projection linéaire aléatoire  $p : \mathbb{R}^D \rightarrow \mathbb{R}^d$  :

$$(1 - \varepsilon)\|x_i - x_j\| \leq \|p(x_i) - p(x_j)\| \leq (1 + \varepsilon)\|x_i - x_j\|$$

avec  $d = O\left(\frac{\log N}{\varepsilon^2}\right)$  **indépendant de  $D$  !**

**Exemple numérique :**

- $N = 10000$ ,  $\varepsilon = 0.1$
- $d \approx \frac{\log(10000)}{0.01} \approx \frac{9.2}{0.01} \approx 920$
- Réduction :  $D = 10000 \rightarrow d = 920$  (facteur  $\sim 11$ )
- **Préservation des distances à 10% près**

**Applications pratiques :**

1. **Réduction de dimension** : compression de données sans perte significative d'information géométrique
2. **Accélération d'algorithmes** :
  - Calculs en  $O(d)$  au lieu de  $O(D)$
  - Clustering, k-NN approximatif

3. **Locally Sensitive Hashing (LSH)** : recherche approximative de plus proches voisins en temps sous-linéaire

**Principe exploité :**

- **Quasi-orthogonalité** en haute dimension : exponentiellement nombreuses directions quasi-orthogonales
- Directions aléatoires forment une base quasi-orthonormale
- Préservation de la structure géométrique avec bien moins de dimensions

**Révision Rapide : Instance Concrète de la Blessing**

**Projections aléatoires (Johnson-Lindenstrauss)** : réduction  $\mathbb{R}^D \rightarrow \mathbb{R}^d$  avec  $d = O(\log N / \varepsilon^2)$  (indépendant de  $D$ ) préservant distances. **Application** : LSH, accélération algos, réduction dimension. **Principe** : quasi-orthogonalité  $\rightarrow$  exponentiellement nombreuses directions.

**Question 4 : Pourquoi la dimension augmente-t-elle la parcimonie des données ?**

**Réponse :**

La dimension augmente la parcimonie (*data sparsity*) par **croissance exponentielle du volume** de l'espace.

**Explication mathématique :**

Considérons l'estimation de densité par histogramme sur  $\Omega = [a, b]^D$  :

- Quantification :  $b$  bins par dimension
- **Nombre total de bins** :  $b^D$  (croissance exponentielle)
- Pour qualité  $n$  échantillons/bin : besoin de  $N = n \cdot b^D$  échantillons

**Table d'illustration** ( $b = 10, n = 10$ ) :

| Dimension $D$ | Nombre de bins $b^D$ | Échantillons nécessaires $N$ |
|---------------|----------------------|------------------------------|
| 1             | 10                   | 100                          |
| 2             | 100                  | 1,000                        |
| 3             | 1,000                | 10,000                       |
| 6             | 1,000,000            | 10,000,000                   |
| 10            | 10,000,000,000       | 100,000,000,000              |

**Si  $N$  est fixé :**

- Moyenne d'échantillons par bin :  $n = \frac{N}{b^D}$
- **Probabilité qu'un bin soit occupé** :  $\mathbb{E}[P(x_i \in \text{bin}_j)] \approx \frac{1}{b^D}$

**Conséquence** : Pour  $D$  croissant :

$$\frac{1}{b^D} \rightarrow 0 \Rightarrow \text{La plupart des bins sont vides}$$

**Principe fondamental** :

- Volume de l'espace croît comme  $V \sim L^D$  (où  $L$  est longueur caractéristique)
- Nombre d'échantillons pour "remplir" l'espace :  $N \sim L^D$
- **Échelle exponentielle** : chaque dimension supplémentaire multiplie le volume par  $L$

**Exemple concret** :

- $D = 2$  : grille  $10 \times 10 = 100$  cellules  $\rightarrow$  100 échantillons pour 1/cellule
- $D = 3$  : grille  $10 \times 10 \times 10 = 1000$  cellules  $\rightarrow$  1000 échantillons
- $D = 10$  :  $10^{10}$  cellules  $\rightarrow$  **10 milliards d'échantillons !**

**Implications** :

- **Régions vides** : La plupart de l'espace n'est jamais "visitée" par les données
- **Estimation de densité** : histogrammes deviennent inutiles
- **Apprentissage supervisé** : manque de données dans la plupart des régions

#### Révision Rapide : Parcimonie et Dimension

Volume croît comme  $L^D$  (exponentiel). Nombre de bins :  $b^D$ . Besoin :  $N = n \cdot b^D$  échantillons. Si  $N$  fixé :  $n = N/b^D \rightarrow 0 \rightarrow$  **bins vides**. Chaque dimension multiplie volume par facteur.

---

**Question 5 : Pourquoi le volume se concentre-t-il sur la surface des volumes ?**

**Réponse** :

Le volume se concentre à la surface en haute dimension par **décroissance exponentielle** du ratio de volumes.

**Démonstration générale** :

Considérons une forme de "mesure"  $r$  (rayon pour sphère, côté pour cube) et réduisons par facteur  $(1 - \varepsilon)$  avec  $\varepsilon \in ]0, 1[$ .

Pour tout volume :

$$\frac{\text{vol}(\text{forme de mesure } (1-\varepsilon)r)}{\text{vol}(\text{forme de mesure } r)} = (1-\varepsilon)^D$$

Limite asymptotique :

$$\lim_{D \rightarrow \infty} (1-\varepsilon)^D = 0$$

Car  $1-\varepsilon \leq e^{-\varepsilon}$  donc  $(1-\varepsilon)^D \leq e^{-D\varepsilon} \xrightarrow{D \rightarrow \infty} 0$

Proportion du volume près de la surface :

$$\frac{\text{vol}(\text{extérieur})}{\text{vol}(\text{total})} = \frac{\text{vol}(r) - \text{vol}((1-\varepsilon)r)}{\text{vol}(r)} = 1 - (1-\varepsilon)^D \xrightarrow{D \rightarrow \infty} 1$$

Exemples numériques :

Pour  $\varepsilon = 0.1$  (couche externe = 10% du rayon) :

| $D$ | $(1-\varepsilon)^D = 0.9^D$ | % volume externe |
|-----|-----------------------------|------------------|
| 2   | 0.81                        | 19%              |
| 5   | 0.59                        | 41%              |
| 10  | 0.35                        | 65%              |
| 20  | 0.12                        | 88%              |
| 50  | 0.005                       | 99.5%            |
| 100 | 0.000026                    | 100%             |

Interprétation géométrique :

- En 2D : cercle  $\rightarrow$  anneau fin contient peu de volume
- En 3D : sphère  $\rightarrow$  coquille fine contient plus de volume
- En haute D : **presque tout le volume** est dans une coquille infiniment fine à la surface

Principe sous-jacent :

- **Décomposition en voxels** : tout volume peut être décomposé en voxels (hyper-)cubiques
- Réduire mesure par  $(1-\varepsilon) \rightarrow$  volume voxel réduit par  $(1-\varepsilon)^D$
- **Effet exponentiel** : même petit  $\varepsilon$  donne ratio  $\rightarrow 0$  quand  $D$  grand

Cas de la Gaussienne :

Pour  $X \sim \mathcal{N}(0, \text{Id}_D)$  :

- $R^2 = \|X\|_2^2 \sim \chi^2(D)$  avec  $\mathbb{E}[R^2] = D$
- **Gaussian Annulus Theorem** :  $P[|\|X\|_2 - \sqrt{D}| > \beta] \leq 3e^{-c\beta^2}$
- Densité concentrée dans anneau à rayon  $\sqrt{D}$  avec épaisseur  $O(\sqrt{\log D})$

**Conséquence pratique :**

- Échantillonnage : difficile de générer points “au centre”
- Taux de rejet pour méthodes Monte Carlo  $\rightarrow 100\%$
- Points générés uniformément dans volume  $\rightarrow$  concentrés à surface

#### Révision Rapide : Concentration à la Surface

Ratio  $(1 - \varepsilon)^D \xrightarrow{D \rightarrow \infty} 0$ . Volume externe :  $1 - (1 - \varepsilon)^D \rightarrow 1$ . **Décomposition en voxels** : réduction mesure par  $(1 - \varepsilon) \rightarrow$  volume par  $(1 - \varepsilon)^D$ . **Tout le volume** à la surface.

---

**Question 6 : Qu'est-ce qu'un phénomène de concentration ? Comment peut-il être bénéfique ?**

**Réponse :**

**Définition :**

Un **phénomène de concentration** se produit quand une variable aléatoire (ou une collection de v.a.) prend des valeurs très **proches de son espérance** avec haute probabilité quand la dimension augmente.

**Formulation mathématique :**

Pour une v.a.  $Z$  dépendant de la dimension  $D$  :

$$P(|Z - \mathbb{E}[Z]| > \varepsilon) \rightarrow 0 \text{ quand } D \rightarrow \infty$$

Plus précisément, cette probabilité décroît **exponentiellement** avec  $D$ .

**Exemples de concentration :**

1. **Distances** :  $\frac{D_{\max} - D_{\min}}{D_{\min}} \rightarrow 0$
2. **Angles** :  $\mathbb{E}[\cos(\theta)] \rightarrow 0$  ou  $\frac{1}{2}$  (valeurs concentrées)
3. **Norme gaussienne** :  $\|X\|_2 \approx \sqrt{D}$  pour  $X \sim \mathcal{N}(0, \text{Id}_D)$
4. **Moyenne empirique** :  $\bar{X} \rightarrow \mu$  (WLLN)

**Comment c'est bénéfique :**



## 1. Estimation statistique (Loi Faible des Grands Nombres)

**Principe** : Pour  $\{X_i\}_{i=1}^D$  i.i.d. avec  $\mathbb{E}[X_i] = \mu$  :

$$P(|\bar{X} - \mu| < \varepsilon) \xrightarrow{D \rightarrow \infty} 1$$

**Bénéfice** :

- **Estimation de densité** : histogrammes convergent vers vraie densité
- **Estimateurs statistiques** : convergence garantie
- **Base du Machine Learning** : approximation de fonctions par moyennes empiriques

## 2. Inégalité de Hoeffding (analyse PAC)

$$P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-2D\varepsilon^2/(b-a)^2}$$

**Bénéfice** :

- **Borne exponentielle** : très forte garantie de convergence
- **Analyse PAC** (*Probably Approximately Correct*) : fondement théorique du ML
- **Garanties de généralisation** : erreur sur données test proche de l'erreur train

## 3. Projections aléatoires (Johnson-Lindenstrauss)

**Principe** : Distances préservées après projection aléatoire en dimension  $d = O(\log N / \varepsilon^2)$

**Bénéfice** :

- **Réduction de dimension** sans perte d'information géométrique
- **Accélération d'algorithmes** : complexité réduite de  $O(D)$  à  $O(d)$
- **Compression** : stockage et calculs plus efficaces

## 4. Stabilité numérique

**Bénéfice** :

- **Prédictibilité** : comportement asymptotique bien défini
- **Théorie de l'approximation** : bornes d'erreur quantifiables
- **Convergence d'algorithmes** : garanties théoriques

**Tableau récapitulatif** :

| Phénomène  | Type                                  | Bénéfice                    |
|------------|---------------------------------------|-----------------------------|
| WLLN       | Concentration de $\bar{X}$ vers $\mu$ | Estimation de densité       |
| Hoeffding  | Borne exponentielle                   | Analyse PAC, généralisation |
| JL Lemma   | Distances préservées en basse dim     | Réduction dimension, LSH    |
| Gaussienne | Norme concentrée à $\sqrt{D}$         | Propriétés prédictibles     |

### Principe général :

“**La concentration donne de la certitude**” : En haute dimension, les quantités aléatoires deviennent **déterministes** autour de leur espérance.

#### Révision Rapide : Phénomène de Concentration

$P(|Z - \mathbb{E}[Z]| > \varepsilon) \rightarrow 0$  (exponentielle). **Bénéfices** : (1) WLLN  $\rightarrow$  estimation densité, (2) Hoeffding  $\rightarrow$  analyse PAC/généralisation, (3) JL Lemma  $\rightarrow$  réduction dimension, (4) prédictibilité. **Principe** : aléatoire  $\rightarrow$  déterministe.

### Question 7 : Pourquoi les angles se concentrent-ils ? Comment peut-on exploiter cela ?

Réponse :

Pourquoi les angles se concentrent :

#### Cas 1 : Deux vecteurs aléatoires indépendants

Déclarer 4 v.a. i.i.d.  $W, X, Y, Z$  sur  $\Omega \subset \mathbb{R}^D$  et former deux vecteurs  $(X - Y)$  et  $(Z - W)$  :

$$\mathbb{E}[\cos(\theta)] = \mathbb{E} \left[ \frac{\langle X - Y, Z - W \rangle}{\|X - Y\| \cdot \|Z - W\|} \right]$$

Calcul :

$$\langle X - Y, Z - W \rangle = \langle X, Z \rangle - \langle X, W \rangle - \langle Y, Z \rangle + \langle Y, W \rangle$$

Puisque  $W, X, Y, Z$  sont i.i.d., en espérance :

$$\mathbb{E}[\langle X, Z \rangle] = \mathbb{E}[\langle X, W \rangle] = \mathbb{E}[\langle Y, Z \rangle] = \mathbb{E}[\langle Y, W \rangle]$$

Donc :  $\mathbb{E}[\langle X - Y, Z - W \rangle] = 0$

**Résultat :**

$$\mathbb{E}[\cos(\theta)] = 0 \implies \theta \sim \frac{\pi}{2}$$

**Deux vecteurs aléatoires sont quasi-orthogonaux**

**Cas 2 : Triangle aléatoire (vecteurs partageant origine)**

Déclarer 3 v.a. i.i.d.  $X, Y, Z$  et former angle au sommet  $Y$  :

$$\mathbb{E}[\cos(\angle(X - Y, Z - Y))] = \mathbb{E} \left[ \frac{\langle X - Y, Z - Y \rangle}{\|X - Y\| \cdot \|Z - Y\|} \right]$$

**Note :**  $X - Y$  et  $Z - Y$  ne sont plus indépendants (partagent  $Y$ ) !

**Calcul (simplifié) :**

$$\frac{\langle X - Y, Z - Y \rangle}{\|X - Y\|^2} = \frac{\langle Y, Y \rangle - \langle X, Y \rangle}{2\langle Y, Y \rangle - 2\langle X, Y \rangle} \xrightarrow{\mathbb{E}} \frac{1}{2}$$

**Résultat :**

$$\mathbb{E}[\cos(\theta)] = \frac{1}{2} \implies \theta \sim \frac{\pi}{3}$$

**Triangle aléatoire est équilatéral**

**Principe général :**

En haute dimension  $D$  :

- Produits scalaires de vecteurs indépendants :  $\langle u, v \rangle \approx 0$
- Par définition :  $\cos(\theta) = \frac{\langle u, v \rangle}{\|u\| \cdot \|v\|}$
- Donc :  $\cos(\theta) \approx 0 \rightarrow \theta \approx \pi/2$

**Comment exploiter la quasi-orthogonalité :**

## 1. Projections aléatoires (Random Projections)

**Principe :**

- Générer **directions aléatoires** en haute dimension
- Ces directions forment une **base quasi-orthonormale**
- Utiliser pour projection avec préservation de distances

**Application : Johnson-Lindenstrauss Lemma**

Projection  $p : \mathbb{R}^D \rightarrow \mathbb{R}^d$  avec  $d = O(\log N / \varepsilon^2)$  préserve distances

**Avantages :**

- Pas besoin de calculer SVD/PCA (coûteux)
- Très rapide : simple multiplication matricielle aléatoire
- Garanties théoriques fortes

## 2. Locally Sensitive Hashing (LSH)

**Principe :**

- Projeter données sur directions aléatoires
- Points proches  $\rightarrow$  mêmes projections (avec haute probabilité)
- Construire table de hachage pour recherche rapide

**Algorithme :**

1. Générer  $k$  vecteurs aléatoires  $\{r_1, \dots, r_k\}$
2. Pour chaque point  $x$  :
  - Calculer  $h(x) = \text{sign}(x \cdot r_1, \dots, x \cdot r_k)$
  - Stocker  $x$  dans bucket  $h(x)$
3. Recherche : calculer  $h(q)$ , chercher dans bucket

**Complexité :**

- Construction :  $O(NkD)$
- Recherche :  $O(kD + L)$  où  $L$  = taille bucket (typiquement  $\ll N$ )

### 3. Codage de signaux (Signal Coding)

Compressed Sensing :

- Signal  $s \in \mathbb{R}^D$  sparse (peu de coefficients non-nuls)
- Mesures :  $y = \Phi s$  où  $\Phi \in \mathbb{R}^{m \times D}$  matrice aléatoire ( $m \ll D$ )
- Reconstruction : résoudre  $\min_s \|s\|_1$  sujet à  $y = \Phi s$

**Garantie** : Si  $\Phi$  a lignes quasi-orthogonales, reconstruction exacte possible avec  $m = O(k \log(D/k))$  mesures pour signal  $k$ -sparse.

### 4. Dimension Reduction

Avantages sur PCA :

- Pas de calcul de covariance ( $O(D^2N)$ )
- Pas de SVD ( $O(D^3)$ )
- Données streaming : peut traiter données au vol
- Garanti théoriquement : JL Lemma

### 5. Tests de randomness

**Principe** : Tester si vecteurs sont “vraiment aléatoires”

- Calculer angles entre paires
- Si distribution  $\cos(\theta) \approx \mathcal{U}([-1, 1])$  en basse dim
- En haute dim : devrait être  $\approx 0$  (distribution concentrée)

**Tableau récapitulatif** :

| Application        | Exploitation            | Bénéfice                    |
|--------------------|-------------------------|-----------------------------|
| Random Projections | Base quasi-orthonormale | Réduction dimension rapide  |
| LSH                | Hachage par projections | Recherche ANN sous-linéaire |
| Compressed Sensing | Mesures aléatoires      | Acquisition compressée      |
| Streaming          | Pas de SVD              | Traitement en ligne         |

#### Révision Rapide : Concentration des Angles

**2 vecteurs indép.** :  $\mathbb{E}[\cos(\theta)] = 0 \rightarrow \theta \sim \pi/2$ . **Triangle** :  $\mathbb{E}[\cos(\theta)] = 1/2 \rightarrow \theta \sim \pi/3$ .  
**Exploitation** : (1) Projections aléatoires (JL), (2) LSH pour ANN, (3) Compressed

sensing, (4) Codage signaux, (5) Pas de SVD coûteux.

**Question 8 : Quel est le taux typique de concentration ?**

**Réponse :**

Le taux typique de concentration en haute dimension est **exponentiel** en la dimension  $D$ .

**Formes générales :**

$$P(|Z - \mathbb{E}[Z]| > \varepsilon) \leq C \cdot e^{-c \cdot D \cdot f(\varepsilon)}$$

où  $C, c > 0$  sont des constantes et  $f(\varepsilon)$  dépend de  $\varepsilon$  (souvent  $f(\varepsilon) = \varepsilon^2$ ).

### 1. Inégalité de Hoeffding

Pour  $\{X_i\}_{i=1}^D$  indépendantes avec  $P(a \leq X_i \leq b) = 1$  et  $\mathbb{E}[X_i] = \mu$  :

$$P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-\frac{2D\varepsilon^2}{(b-a)^2}}$$

**Taux de concentration :**  $e^{-2D\varepsilon^2/(b-a)^2}$

**Interprétation :**

- Décroissance **doublement exponentielle** : exponentielle en  $D$ , qui est lui-même dans l'exposant
- Pour  $D$  grand, la probabilité devient **astronomiquement petite**

## 2. Gaussian Annulus Theorem

Pour  $X \sim \mathcal{N}(0, \text{Id}_D)$  :

$$P\left[\left|\|X\|_2 - \sqrt{D}\right| > \beta\right] \leq 3e^{-c\beta^2}$$

**Taux de concentration** :  $e^{-c\beta^2}$  (exponentiel en  $\beta^2$ )

**Remarque** : Pour  $\beta = \varepsilon\sqrt{D}$  :

$$P\left[\left|\frac{\|X\|_2}{\sqrt{D}} - 1\right| > \varepsilon\right] \leq 3e^{-cD\varepsilon^2}$$

**Taux** :  $e^{-cD\varepsilon^2}$  (exponentiel en  $D$ )

## 3. Concentration des distances (Beyer et al.)

Pour la variance de distances normalisées qui tend vers 0 :

$$\text{Var}\left[\frac{d(x, y)^p}{\mathbb{E}[d(x, y)^p]}\right] = O\left(\frac{1}{D}\right)$$

**Taux** :  $\frac{1}{D}$  (polynomial, plus lent)

## 4. Distribution du volume

Proportion de volume dans couche externe :

$$1 - (1 - \varepsilon)^D$$

Pour  $\varepsilon$  petit :  $(1 - \varepsilon)^D \approx e^{-D\varepsilon}$

**Taux** :  $e^{-D\varepsilon}$  (exponentiel en  $D$ )

**Table comparative** :

| Phénomène | Borne de concentration          | Taux                     | Type        |
|-----------|---------------------------------|--------------------------|-------------|
| Hoeffding | $2e^{-2D\varepsilon^2/(b-a)^2}$ | $e^{-O(D\varepsilon^2)}$ | Exponentiel |

| Phénomène          | Borne de concentration                                 | Taux                     | Type        |
|--------------------|--------------------------------------------------------|--------------------------|-------------|
| Gaussian Annulus   | $3e^{-c\beta^2}$ (avec $\beta = \varepsilon\sqrt{D}$ ) | $e^{-O(D\varepsilon^2)}$ | Exponentiel |
| Volume             | $e^{-D\varepsilon}$                                    | $e^{-O(D\varepsilon)}$   | Exponentiel |
| Variance distances | $O(1/D)$                                               | Polynomial               | Plus lent   |

### Ordre de grandeur :

Pour  $D = 100$  et  $\varepsilon = 0.1$  :

- Hoeffding (avec  $b - a = 2$ ) :  $\approx 2e^{-2 \cdot 100 \cdot 0.01/4} = 2e^{-0.5} \approx 1.2...$  (borne lâche)
- Calcul précis :  $2e^{-5} \approx 0.0135$
- Gaussian :  $3e^{-c \cdot 100 \cdot 0.01} = 3e^{-c}$  (avec  $c \sim 1$ )  $\approx 1.1$
- Volume :  $e^{-100 \cdot 0.1} = e^{-10} \approx 4.5 \times 10^{-5}$

Pour  $D = 1000$  :

- Volume :  $e^{-1000 \cdot 0.1} = e^{-100} \approx 3.7 \times 10^{-44}$  (astronomiquement petit !)

### Caractéristiques importantes :

1. **Convergence rapide** : quelques dizaines de dimensions suffisent pour concentration forte
2. **Universalité** : même forme  $e^{-cD}$  pour beaucoup de phénomènes
3. **Indépendance du nombre d'échantillons**  $N$  : dépend surtout de  $D$
4. **Seuil critique** :  $D \gtrsim 10$  où effets deviennent prononcés

### Taux relatifs :

- **Concentration positive** (WLLN, Hoeffding) :  $O(e^{-cD\varepsilon^2}) \rightarrow$  très rapide
- **Concentration négative** (volume à surface) :  $O(e^{-cD\varepsilon}) \rightarrow$  très rapide
- **Concentration des distances** :  $O(1/D) \rightarrow$  plus lent (caveat dans Random Projections)

#### Révision Rapide : Taux de Concentration

Taux typique : **exponentiel** en  $D$ . **Hoeffding** :  $2e^{-2D\varepsilon^2/(b-a)^2}$ . **Gaussian Annulus** :  $3e^{-c\beta^2}$  (avec  $\beta \sim \varepsilon\sqrt{D}$ ). **Volume** :  $e^{-D\varepsilon}$ . **Forme générale** :  $e^{-O(D)}$ . Convergence **très rapide**, seuil  $D \gtrsim 10$ .



**Question 9 : Citez une inégalité de concentration. Pouvez-vous la prouver ?**

Réponse :

Inégalité de Hoeffding

**Énoncé**

Soit  $\{X_i\}_{i=1}^D$  des variables aléatoires **indépendantes** telles que  $P(a \leq X_i \leq b) = 1$  et  $\mathbb{E}[X_i] = \mu$ .  
Alors pour tout  $\varepsilon > 0$  :

$$P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-\frac{2D\varepsilon^2}{(b-a)^2}}$$

où  $\bar{X} = \frac{1}{D} \sum_{i=1}^D X_i$ .

**Preuve**

**Étape 1 : Symétrie et décomposition**

Par symétrie :

$$P(|\bar{X} - \mu| > \varepsilon) = P(\bar{X} - \mu > \varepsilon) + P(\bar{X} - \mu < -\varepsilon)$$

Par symétrie, les deux termes sont égaux. On se concentre sur :

$$P(\bar{X} - \mu > \varepsilon)$$

**Étape 2 : Inégalité de Markov**

Pour tout  $t > 0$  :

$$P(\bar{X} - \mu > \varepsilon) = P(e^{t(\bar{X}-\mu)} > e^{t\varepsilon}) \leq \frac{\mathbb{E}[e^{t(\bar{X}-\mu)}]}{e^{t\varepsilon}}$$

(par inégalité de Markov pour  $e^{t(\bar{X}-\mu)}$  qui est non-négatif)

**Étape 3 : Indépendance et factorisation**

$$\mathbb{E}[e^{t(\bar{X}-\mu)}] = \mathbb{E}\left[e^{t\left(\frac{1}{D} \sum_{i=1}^D X_i - \mu\right)}\right] = \mathbb{E}\left[e^{\frac{t}{D} \sum_{i=1}^D (X_i - \mu)}\right]$$

Par **indépendance** des  $X_i$  :

$$= \prod_{i=1}^D \mathbb{E} \left[ e^{\frac{t}{D}(X_i - \mu)} \right]$$

#### Étape 4 : Lemme de Hoeffding

**Lemme :** Si  $\mathbb{E}[Y] = 0$  et  $a \leq Y \leq b$ , alors :

$$\mathbb{E}[e^{tY}] \leq e^{\frac{t^2(b-a)^2}{8}}$$

**Application :** Pour  $Y_i = \frac{1}{D}(X_i - \mu)$ , on a  $\mathbb{E}[Y_i] = 0$  et  $\frac{a-\mu}{D} \leq Y_i \leq \frac{b-\mu}{D}$ .

Range :  $\frac{b-a}{D}$

Donc :

$$\mathbb{E}[e^{tY_i}] \leq e^{\frac{t^2(b-a)^2}{8D^2}}$$

#### Étape 5 : Produit et optimisation

$$\mathbb{E}[e^{t(\bar{X} - \mu)}] \leq \prod_{i=1}^D e^{\frac{t^2(b-a)^2}{8D^2}} = e^{\frac{t^2(b-a)^2}{8D}}$$

Donc :

$$P(\bar{X} - \mu > \varepsilon) \leq \frac{e^{\frac{t^2(b-a)^2}{8D}}}{e^{t\varepsilon}} = e^{\frac{t^2(b-a)^2}{8D} - t\varepsilon}$$

**Optimisation en  $t$  :** dériver par rapport à  $t$  et annuler :

$$\frac{d}{dt} \left( \frac{t^2(b-a)^2}{8D} - t\varepsilon \right) = \frac{t(b-a)^2}{4D} - \varepsilon = 0$$

$$\Rightarrow t^* = \frac{4D\varepsilon}{(b-a)^2}$$

**Substitution :**

$$\frac{(t^*)^2(b-a)^2}{8D} - t^*\varepsilon = \frac{16D^2\varepsilon^2}{(b-a)^4} \cdot \frac{(b-a)^2}{8D} - \frac{4D\varepsilon^2}{(b-a)^2}$$

$$= \frac{2D\varepsilon^2}{(b-a)^2} - \frac{4D\varepsilon^2}{(b-a)^2} = -\frac{2D\varepsilon^2}{(b-a)^2}$$

Donc :

$$P(\bar{X} - \mu > \varepsilon) \leq e^{-\frac{2D\varepsilon^2}{(b-a)^2}}$$

**Étape 6 : Par symétrie**

$$P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-\frac{2D\varepsilon^2}{(b-a)^2}}$$

□

**Preuve du Lemme de Hoeffding** (esquisse) :

Pour  $\mathbb{E}[Y] = 0$  et  $a \leq Y \leq b$  :

- Par convexité de  $e^{tY}$ , on a :

$$e^{tY} \leq \frac{b-Y}{b-a}e^{ta} + \frac{Y-a}{b-a}e^{tb}$$

- Prendre l'espérance (et utiliser  $\mathbb{E}[Y] = 0$ ) :

$$\mathbb{E}[e^{tY}] \leq \frac{be^{ta} - ae^{tb}}{b-a}$$

- Poser  $u = t(b-a)$ ,  $\alpha = -\frac{a}{b-a}$  et utiliser :

$$\log(\alpha e^{-u} + (1-\alpha)e^{u(1-\alpha)/\alpha}) \leq \frac{u^2}{8}$$

- On obtient :

$$\mathbb{E}[e^{tY}] \leq e^{\frac{t^2(b-a)^2}{8}}$$

#### Révision Rapide : Inégalité de Hoeffding

**Énoncé** :  $P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-2D\varepsilon^2/(b-a)^2}$  pour  $X_i$  indép., bornées  $[a, b]$ . **Preuve** : (1) Markov :  $P(\bar{X} > \mu + \varepsilon) \leq \mathbb{E}[e^{t(\bar{X}-\mu)}]/e^{t\varepsilon}$ , (2) Indépendance : factorisation, (3) Lemme Hoeffding :  $\mathbb{E}[e^{tY}] \leq e^{t^2(b-a)^2/8}$ , (4) Optimiser  $t$ .

## Question 10 : Détaillez une situation concrète où la concentration est bénéfique

Réponse :

Situation concrète : Estimation de moyenne pour sondage d'opinion

### Contexte

**Entreprise** : Une plateforme de streaming vidéo veut estimer la **satisfaction moyenne** de ses utilisateurs.

**Population** :

- $N_{\text{total}} = 100$  millions d'utilisateurs
- Chaque utilisateur a un niveau de satisfaction  $X_i \in [1, 5]$  (échelle Likert)
- Vraie moyenne :  $\mu$  (inconnue)

**Objectif** : Estimer  $\mu$  avec précision  $\varepsilon = 0.1$  (erreur de  $\pm 0.1$ ) avec confiance 95%.

### Approche naïve (sans concentration)

Sondage exhaustif :

- Interroger TOUS les 100 millions d'utilisateurs
- Coût : prohibitif (temps, argent)
- Délai : plusieurs mois

### Approche avec concentration (échantillonnage)

Échantillonnage aléatoire :

- Tirer  $D$  utilisateurs **uniformément au hasard**
- Calculer moyenne empirique  $\bar{X} = \frac{1}{D} \sum_{i=1}^D X_i$

Application de Hoeffding :

Pour variables  $X_i$  indépendantes avec  $a = 1$ ,  $b = 5$  :

$$P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-\frac{2D\varepsilon^2}{(b-a)^2}} = 2e^{-\frac{2D \cdot 0.01}{16}} = 2e^{-\frac{D}{800}}$$

Calcul de taille d'échantillon :

Pour confiance 95%, on veut :

$$P(|\bar{X} - \mu| \leq 0.1) \geq 0.95$$

Donc :

$$P(|\bar{X} - \mu| > 0.1) \leq 0.05$$

Par Hoeffding :

$$2e^{-\frac{D}{800}} \leq 0.05$$

$$e^{-\frac{D}{800}} \leq 0.025$$

$$-\frac{D}{800} \leq \log(0.025) \approx -3.69$$

$$D \geq 800 \times 3.69 \approx 2952$$

**Arrondi :**  $D = 3000$  échantillons suffisent !

## Bénéfices de la concentration

### 1. Réduction drastique de coût

- **Sans concentration** : 100 millions d'interrogations
- **Avec concentration** : 3000 interrogations
- **Facteur** :  $\frac{100,000,000}{3000} \approx 33,000$  fois moins !

### 2. Garanties mathématiques

- **Certitude** : 95% de confiance que  $|\bar{X} - \mu| \leq 0.1$
- **Indépendance de  $N_{\text{total}}$**  : taille échantillon ne dépend QUE de précision et confiance souhaitées
- **Formule explicite** : on peut calculer exactement combien d'échantillons nécessaires

### 3. Temps et praticité

- Sondage réalisable en **quelques jours** au lieu de mois
- Mise à jour régulière possible (tracking mensuel)

#### 4. Scalabilité

Pour différentes précisions :

| Précision $\varepsilon$ | Confiance | Taille échantillon $D$ | Coût relatif |
|-------------------------|-----------|------------------------|--------------|
| 0.2                     | 95%       | ~750                   | $0.25\times$ |
| 0.1                     | 95%       | ~3,000                 | $1\times$    |
| 0.05                    | 95%       | ~12,000                | $4\times$    |
| 0.1                     | 99%       | ~4,600                 | $1.5\times$  |

**Observation** : Pour diviser l'erreur par 2, il faut multiplier échantillon par 4 (relation  $D \propto \frac{1}{\varepsilon^2}$ )

#### Généralisation : Théorème Central Limite

**Amélioration avec CLT** :

Si  $\text{Var}(X_i) = \sigma^2$  connue, on peut utiliser :

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{D}} \sim \mathcal{N}(0, 1)$$

Pour confiance 95% (intervalle  $\pm 1.96$  écart-types) :

$$P\left(|\bar{X} - \mu| \leq 1.96 \frac{\sigma}{\sqrt{D}}\right) \approx 0.95$$

Pour  $\varepsilon = 0.1$  :

$$1.96 \frac{\sigma}{\sqrt{D}} = 0.1 \implies D = \left(\frac{1.96\sigma}{0.1}\right)^2$$

Si  $\sigma \approx 1$  (estimation) :  $D \approx 385$

**Comparaison** :

- **Hoeffding** :  $D \approx 3000$  (borne conservatrice, pire cas)
- **CLT** :  $D \approx 385$  (utilise connaissance de variance)

**En pratique** : on utilise CLT quand variance estimable, sinon Hoeffding

## Autres situations bénéfiques

### 1. A/B Testing (web) :

- Tester deux versions d'un site
- Besoin petit échantillon pour détecter différence significative
- Concentration garantit validité statistique

### 2. Contrôle qualité (industrie) :

- Vérifier qualité production sans tout tester
- Échantillon de  $n \approx 100 - 1000$  suffit pour population millions
- Économie massive en temps et destruction d'échantillons

### 3. Machine Learning (validation) :

- Estimer erreur de généralisation sur échantillon test
- Concentration garantit que erreur test  $\approx$  erreur population
- Base théorique pour *train/validation/test split*

#### Révision Rapide : Concentration Bénéfique

**Sondage d'opinion** : estimer moyenne population 100M avec  $D = 3000$  échantillons (facteur 33,000 $\times$ ). **Hoeffding** :  $D \geq 800 \times \log(2/\delta)/\varepsilon^2$ . **Bénéfices** : (1) coût réduit, (2) garanties mathématiques 95%, (3) rapide, (4) scalable. **Applications** : A/B testing, contrôle qualité, validation ML.

---

## Question 11 : Détaillez une situation concrète où la concentration est adverse

Réponse :

**Situation concrète** : Recherche de plus proches voisins pour système de recommandation

### Contexte

**Entreprise** : Plateforme de streaming musical (type Spotify).

**Données** :

- Base de  $N = 10$  millions de chansons
- Chaque chanson représentée par vecteur de features audio :  $x \in \mathbb{R}^D$  avec  $D = 200$

- Features : tempo, timbre, harmonies, MFCC (*Mel-Frequency Cepstral Coefficients*), etc.

**Objectif** : Pour une chanson requête  $q$ , trouver les  $k = 10$  chansons les plus similaires pour recommandation.

**Algorithme** : *k-Nearest Neighbors* (k-NN) basé sur distance Euclidienne.

### Le problème : Concentration des distances

**Phénomène** : En dimension  $D = 200$ , toutes les distances se **concentrent**.

**Théorème (Beyer et al.)** :

Si  $\lim_{D \rightarrow \infty} \text{Var} \left[ \frac{d(x,y)^p}{\mathbb{E}[d(x,y)^p]} \right] = 0$ , alors :

$$\lim_{D \rightarrow \infty} P \left[ \frac{D_{\max} - D_{\min}}{D_{\min}} \leq \varepsilon \right] = 1$$

où  $D_{\max}$ ,  $D_{\min}$  sont distances au voisin le plus éloigné et le plus proche.

**Concrètement** : Pour  $D = 200$ , on observe empiriquement :

$$\frac{D_{\max} - D_{\min}}{D_{\min}} \approx 0.01 \text{ à } 0.05$$

**Interprétation** : Les 10 plus proches voisins et les 10,000ème voisins sont quasiment à la même distance !

### Conséquences adverses

#### 1. Perte de pouvoir discriminant

**Expérience empirique** :

Chanson requête: "Bohemian Rhapsody" (Queen)

k-NN traditionnel avec D=200:

Voisin 1: distance = 14.23

Voisin 2: distance = 14.25

Voisin 3: distance = 14.26

...

Voisin 10: distance = 14.31

...

Voisin 1000: distance = 14.89



**Problème :** Différence entre voisin 1 et 1000 :  $(14.89 - 14.23)/14.23 \approx 4.6\%$  seulement !

**Conséquence :** Difficile de distinguer les “vraiment proches” des “moyennement proches”.

## 2. Recommandations de mauvaise qualité

**Résultat utilisateur :**

Recommandations pour "Bohemian Rhapsody":

1. "We Will Rock You" (Queen) pertinent
2. "Stairway to Heaven" (Led Zeppelin) pertinent
3. "Random Jazz Track" non pertinent
4. "Classical Piano" non pertinent
5. "Electronic Dance" non pertinent
- ...

**Raison :** Les chansons 3-5 sont presque à la même distance que 1-2, donc sélectionnées “aléatoirement”.

**Impact métrique :**

- **Précision@10 :** chute de 80% (basse dimension) à 30% (haute dimension)
- **User satisfaction :** baisse significative

## 3. Complexité computationnelle

**Index spatial (kd-tree) :**

En basse dimension ( $D \leq 10$ ) :

- Partition de l'espace efficace
- Recherche en  $O(\log N)$

En haute dimension ( $D = 200$ ) :

- Concentration des distances  $\rightarrow$  partition inefficace
- Chaque cellule doit couvrir rayon  $\approx$  rayon total
- **Dégénération :** recherche devient  $O(N)$  (exhaustive)

**Mesure empirique :**

| Dimension $D$ | Temps recherche (ms) | Amélioration vs linéaire |
|---------------|----------------------|--------------------------|
| 3             | 0.5                  | 200×                     |
| 10            | 2                    | 50×                      |
| 50            | 45                   | 2×                       |
| 100           | 85                   | 1.2×                     |

| Dimension $D$ | Temps recherche (ms) | Amélioration vs linéaire |
|---------------|----------------------|--------------------------|
| 200           | 98                   | <b>1.02×</b>             |

**Conclusion** : Pour  $D = 200$ , kd-tree est **inutile** (presque aussi lent que recherche linéaire).

#### 4. Hubness

**Phénomène** : Certaines chansons deviennent **hubs**, apparaissant dans les k-NN de presque toutes les requêtes.

**Distribution empirique de  $n_k$  (nombre de fois où chanson est k-NN) :**

Chanson A:  $n_k = 0$  (jamais voisin)

Chanson B:  $n_k = 2$  (rare)

...

Chanson C:  $n_k = 4500$  (hub!) ← apparaît pour 45% des requêtes

Chanson D:  $n_k = 3200$  (hub!)

**Conséquence** :

- Même recommandations pour beaucoup d'utilisateurs différents
- Perte de **personnalisation**
- Expérience utilisateur dégradée

#### Coût business

**Mesures d'impact** :

- **Taux d'écoute des recommandations** : chute de 25%
- **Temps d'écoute moyen** : baisse de 18%
- **Satisfaction utilisateur (NPS)** : baisse de 15 points
- **Coût computationnel** :  $O(N)$  pour chaque requête
  - $10^7$  chansons  $\times$  200 features  $\times$  distance calcul
  - Pour 1000 requêtes/seconde : infrastructure serveur très coûteuse

**Estimation financière** :

- Infrastructure : +\$500k/an pour supporter recherche exhaustive
- Perte engagement utilisateur : -\$2M/an en revenus publicitaires

## Solutions (atténuation)

### 1. Réduction de dimensionnalité

#### PCA (Principal Component Analysis) :

- Projeter  $\mathbb{R}^{200} \rightarrow \mathbb{R}^{20}$
- Garder 90% de variance
- k-NN en dimension 20 beaucoup plus efficace

#### Résultat :

- Précision@10 : remonte à 65%
- Temps recherche : réduit de 80%

### 2. Approximate Nearest Neighbors (ANN)

**Algorithmes** : LSH (*Locality-Sensitive Hashing*), HNSW (*Hierarchical Navigable Small World*)

**Principe** : Trade-off précision vs vitesse

- Garantie : trouver  $\epsilon$ -ANN avec prob.  $1 - \delta$
- Complexité :  $O(\log N)$  au lieu de  $O(N)$

### 3. Apprentissage de métriques

#### Metric Learning :

- Apprendre transformation  $\Phi : \mathbb{R}^D \rightarrow \mathbb{R}^d$  ( $d \ll D$ )
- Supervisé : paires similaires/dissimilaires
- Objectif : maximiser séparabilité

#### Résultat :

- Précision@10 : remonte à 78%
- Distance entre voisins pertinents non-pertinents

### 4. Features spécialisées

#### Ingénierie de features :

- Au lieu de 200 features génériques
- Construire 20-30 features **hautement informatives**
- Exemple : genre musical, époque, instrumentalisation

**Trade-off** : Expertise domaine nécessaire, mais efficacité +++

## Tableau récapitulatif

| Aspect                  | Problème (haute dim)   | Solution              |
|-------------------------|------------------------|-----------------------|
| Discrimination          | Distances concentrées  | Réduction dimension   |
| Qualité recommandations | Précision@10 = 30%     | Metric learning       |
| Temps calcul            | $O(N)$ exhaustif       | ANN (LSH, HNSW)       |
| Hubness                 | Même résultats partout | Features spécialisées |
| Coût                    | +\$500k infra/an       | PCA, compression      |

## Généralisation

Autres domaines affectés :

### 1. Computer Vision

- Images haute résolution :  $D = 1024 \times 1024 \times 3 \approx 3M$
- Recherche d'images similaires inefficace
- Solution : CNN embeddings en basse dimension ( $D \sim 128 - 512$ )

### 2. NLP (Natural Language Processing)

- Word embeddings :  $D = 300$  (Word2Vec)
- BERT :  $D = 768$
- Recherche sémantique souffre de concentration
- Solution : embeddings compressés, quantization

### 3. Bioinformatique

- Séquences génétiques :  $D \sim 10^4 - 10^6$
- Clustering de gènes/protéines
- Solution : sélection de features, dimensionality reduction

#### Révision Rapide : Concentration Adverse

**k-NN haute dimension** : distances concentrées  $\rightarrow (D_{\max} - D_{\min})/D_{\min} \approx 0.01 \rightarrow$  discrimination impossible. **Conséquences** : précision↓, temps  $O(N)$ , hubness. **Impact** : recommandations mauvaises, coût+++ . **Solutions** : PCA, ANN (LSH), metric learning, features spécialisées.

## Question 12 : Qu'est-ce qu'une analyse PAC ?

Réponse :

**PAC** = *Probably Approximately Correct*

Une **analyse PAC** est un cadre théorique en apprentissage automatique qui fournit des **garanties probabilistes** sur la qualité de l'apprentissage.

### Définition formelle

Un algorithme d'apprentissage est dit **PAC-learnable** si :

**Pour tout :**

- Précision souhaitée  $\varepsilon > 0$  (erreur tolérée)
- Confiance souhaitée  $\delta > 0$  (probabilité d'échec tolérée)

**Il existe :**

- Taille d'échantillon d'entraînement  $N = N(\varepsilon, \delta)$
- Complexité computationnelle  $T = T(\varepsilon, \delta)$  polynomial

**Tel que :**

Avec probabilité au moins  $(1 - \delta)$ , l'erreur de généralisation est au plus  $\varepsilon$  :

$$P[\text{erreur}(h) \leq \varepsilon] \geq 1 - \delta$$

où  $h$  est l'hypothèse (modèle) apprise.

### Les deux composantes

#### 1. Probably (Probabiliste)

- La garantie est **probabiliste**, pas déterministe
- On tolère une probabilité  $\delta$  d'échec
- Exemple :  $\delta = 0.05 \rightarrow$  confiance 95%

#### 2. Approximately Correct (Approximativement correct)

- On n'exige pas erreur nulle (souvent impossible)
- On tolère erreur  $\varepsilon$
- Exemple :  $\varepsilon = 0.1 \rightarrow$  erreur 10%

## Relation avec inégalités de concentration

Les **inégalités de concentration** (comme Hoeffding) sont les outils mathématiques fondamentaux pour l'analyse PAC.

### Exemple avec Hoeffding :

Pour estimateur  $\bar{X}$  de moyenne  $\mu$  :

$$P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-\frac{2N\varepsilon^2}{(b-a)^2}}$$

### Interprétation PAC :

- Choisir  $\delta = 2e^{-\frac{2N\varepsilon^2}{(b-a)^2}}$
- Résoudre pour  $N$  :

$$N \geq \frac{(b-a)^2}{2\varepsilon^2} \log\left(\frac{2}{\delta}\right)$$

**Garantie** : Avec  $N$  échantillons, l'erreur  $|\bar{X} - \mu|$  est  $\leq \varepsilon$  avec probabilité  $(1 - \delta)$ .

## Exemple concret : Classification binaire

### Problème :

- Espace d'entrée  $X$ , labels  $Y \in \{0, 1\}$
- Distribution inconnue  $\mathcal{D}$  sur  $X \times Y$
- Classe d'hypothèses  $\mathcal{H}$  (e.g., classifieurs linéaires)

**Objectif** : Trouver  $h \in \mathcal{H}$  avec faible erreur de généralisation :

$$\text{err}(h) = P_{(x,y) \sim \mathcal{D}}[h(x) \neq y]$$

### Analyse PAC :

Soit  $\hat{\text{err}}(h)$  l'erreur empirique sur échantillon d'entraînement de taille  $N$ .

**Théorème** : Pour toute classe  $\mathcal{H}$  de dimension VC  $d$ , avec probabilité au moins  $(1 - \delta)$  :

$$\text{err}(h) \leq \hat{\text{err}}(h) + \sqrt{\frac{d \log(2N/d) + \log(2/\delta)}{N}}$$

**Taille d'échantillon nécessaire** :

Pour garantir  $\text{err}(h) \leq \varepsilon$  avec confiance  $(1 - \delta)$  :

$$N = O\left(\frac{d + \log(1/\delta)}{\varepsilon^2}\right)$$

## Composantes d'une borne PAC

Forme générale :

$$N \geq \frac{C}{\varepsilon^p} \cdot f(d, \delta)$$

où :

- $C$  : constante
- $\varepsilon$  : précision (erreur tolérée)
- $p$  : typiquement 1 ou 2
- $f(d, \delta)$  : dépend de complexité modèle ( $d$ ) et confiance ( $\delta$ )

Facteurs clés :

| Facteur          | Impact                      | Intuition                                                         |
|------------------|-----------------------------|-------------------------------------------------------------------|
| $\varepsilon$    | $N \propto 1/\varepsilon^2$ | Diviser erreur par 2 $\rightarrow$ 4 $\times$ plus d'échantillons |
| $\delta$         | $N \propto \log(1/\delta)$  | Doubler confiance $\rightarrow$ logarithmique en $N$              |
| $d$ (complexité) | $N \propto d$               | Modèle plus complexe $\rightarrow$ plus d'échantillons            |

## Applications en Data Science

### 1. Validation croisée

**Question** : Combien de données dans ensemble test ?

**Analyse PAC** : Pour estimer erreur vraie à  $\varepsilon$  près avec confiance  $1 - \delta$  :

$$N_{\text{test}} \geq \frac{1}{2\varepsilon^2} \log\left(\frac{2}{\delta}\right)$$

**Exemple** :  $\varepsilon = 0.05$ ,  $\delta = 0.05$  :

$$N_{\text{test}} \geq \frac{1}{2 \cdot 0.0025} \log(40) \approx \frac{3.69}{0.005} \approx 738$$

## 2. Sélection de modèle

**Trade-off biais-variance :**

- Modèle simple ( $d$  petit) :  $\hat{\text{err}}$  grand mais borne PAC petite
- Modèle complexe ( $d$  grand) :  $\hat{\text{err}}$  petit mais borne PAC grande

**Principe :** Minimiser borne PAC (pas seulement erreur empirique).

## 3. Regularisation

**Objectif régularisé :**

$$\min_{h \in \mathcal{H}} \hat{\text{err}}(h) + \lambda \cdot \text{complexité}(h)$$

Le terme de complexité correspond à la borne PAC.

## 4. Early stopping

**Principe :** Arrêter entraînement quand borne PAC commence à augmenter (sur-apprentissage).

## Limites de l'analyse PAC

### 1. Bornes pessimistes

- Souvent très larges en pratique
- Modèles réels performant mieux que garanti

### 2. Dépendance distributionnelle

- Suppose distribution  $\mathcal{D}$  fixe
- En pratique : distribution shift, non-stationnarité

### 3. Complexité computationnelle

- PAC-learnability : efficacité pratique
- Algorithme peut être polynomial mais impraticable

### 4. Hypothèses indépendance

- Suppose échantillons i.i.d.
- Données temporelles, spatiales : corrélées



## **Extensions**

### **1. Agnostic PAC learning**

- Sans hypothèse sur réalisabilité (meilleur  $h \in \mathcal{H}$  peut avoir erreur  $> 0$ )


### **2. PAC-Bayes**

- Distributions sur hypothèses
- Bornes plus fines pour ensembles de modèles

### **3. Online learning**

- Garanties PAC pour apprentissage séquentiel
- Regret bounds

## Résumé visuel



### Révision Rapide : Analyse PAC

**PAC** = *Probably Approximately Correct*. **Garantie** : avec prob.  $(1 - \delta)$ , erreur  $\leq \epsilon$ .

**Échantillons** :  $N = O\left(\frac{d + \log(1/\delta)}{\epsilon^2}\right)$ . **Outil** : inégalités de concentration (Hoeffding).

**Applications** : validation croisée, sélection modèle, régularisation. **Principe** : quantifier combien d'échantillons pour apprendre avec garanties.