

Table of contents

L'essentiel	1
Pourquoi étudier les espaces de haute dimension ?	1
L'Espace de Représentation	2
La malédiction de la dimensionnalité	2
1. Parcimonie des Données (Data Sparsity)	2
2. Sphère Vide et Cube Épineux	3
3. Distribution du Volume	4
4. L'Œuf Gaussien	5
5. Concentration des Distances	5
6. Quasi-Orthogonalité	6
7. Hubness (Présence de Hubs)	7
8. Inégalités de Concentration	8
La bénédiction de la dimensionnalité	9
1. Lois des Grands Nombres	9
2. Projections Aléatoires	10
Impact en data science	11
1. Échantillonnage	11
2. Indexation	11
3. Apprentissage	12
4. Pourquoi la Data Science fonctionne-t-elle quand même ?	13
Résumé global	13
Aspects positifs (Bénédiction)	13
Aspects négatifs (Malédiction)	14
Solution unique	14

L'essentiel

Pourquoi étudier les espaces de haute dimension ?

La **Data Science** étudie comment représenter le monde réel sous forme de données numériques dans des espaces mathématiques. Elle se concentre sur les propriétés **géométriques** et **statistiques** de ces espaces.

Pipeline universel :

- Monde réel $\rightarrow$ Capteurs $\rightarrow$ Données brutes $\rightarrow$ Représentation numérique
- Tout devient une **matrice** : N échantillons, D caractéristiques

Deux visions complémentaires :

- **Statistique** : échantillon d'une distribution sous-jacente
- **Algébrique** : matrice $X \in \mathbb{R}^{D \times N}$

L'Espace de Représentation

Un espace de dimension D a une structure complète :

- Produit scalaire $\rightarrow$ Norme $\rightarrow$ Distance $\rightarrow$ Espace métrique

Question centrale : Que se passe-t-il quand D devient grand ?

- Effets négatifs : **Malédiction** de la dimensionnalité
 - Effets positifs : **Bénédiction** de la dimensionnalité
-

La malédiction de la dimensionnalité

1. Parcimonie des Données (Data Sparsity)

Pour estimer précisément une distribution en dimension D , il faut un nombre **exponentiel** d'échantillons :

$$N \approx n \cdot b^D$$

où n = échantillons par bin, b = nombre de bins par dimension.

Exemple :

- $D = 6, b = 10, n = 10 \rightarrow N \approx 10^7$ échantillons nécessaires
- Avec N fixé : la plupart des bins restent **vides**

Détails : Estimation de qualité

Si on fixe N , la qualité d'estimation devient :

$$n = \frac{N}{b^D} \implies \mathbb{E}[P(x_i \in \text{bin}_j)] \approx \frac{1}{b^D}$$

La probabilité qu'un bin soit occupé décroît exponentiellement avec D .

Révision Rapide : Data Sparsity

Besoin de $N \approx n \cdot b^D$ échantillons (croissance **exponentielle**).
Si N fixé : $n = N/b^D \rightarrow$ la plupart des bins **vides**.

2. Sphère Vide et Cube Épineux

Dans un cube en haute dimension, le volume de la sphère inscrite devient **négligeable** :

$$\frac{\text{vol}(B_D(r))}{\text{vol}(C_D(r))} = \frac{\pi^{D/2}}{D \cdot 2^{D-1} \Gamma(D/2)} \xrightarrow{D \rightarrow \infty} 0$$

Conséquences :

- Le volume se concentre dans les **coins** du cube
- Distance centre-coin = $\frac{\sqrt{D}}{2}$ (croît avec $\sqrt{D}$)
- Échantillonnage uniforme $\rightarrow$ sphère **vide**

Détails : Volume de l'hypersphère

Formule générale :

$$\text{vol}(B_D(r)) = \frac{2r^D \pi^{D/2}}{D \Gamma(D/2)}$$

Relation de récurrence (pour $D > 1$) :

$$\text{vol}(B_D(r)) = \frac{2\pi r^2}{D} \text{vol}(B_{D-2}(r))$$

Coins du cube unitaire :

- Nombre de coins : 2^D
- Distance à l'origine : $\|x_i\|_2 = \frac{\sqrt{D}}{2}$

D	1	2	4	5	100
$\frac{\sqrt{D}}{2}$	$\frac{1}{2}$	$\frac{\sqrt{2}}{2}$	1	$\frac{\sqrt{5}}{2}$	5

Révision Rapide : Sphère Vide & Cube Épineux

Ratio sphère/cube $\rightarrow 0$. Volume concentré aux **coins** (distance $\sqrt{D}/2$).
Échantillonnage uniforme $\rightarrow$ sphère **vide**.

3. Distribution du Volume

Pour **toute forme** (cube, sphère, ou autre), le volume se concentre près de la surface :

$$\lim_{D \rightarrow \infty} \frac{\text{vol}(V_D(r)) - \text{vol}(V_D((1-\varepsilon)r))}{\text{vol}(V_D(r))} = 1$$

Principe :

- Réduire la taille par facteur $(1-\varepsilon) \rightarrow$ volume réduit par $(1-\varepsilon)^D \rightarrow 0$
- Presque tout le volume est dans une mince **coquille** à la surface

Détails : Calcul pour hypercube et hypersphère

Pour l'hypercube :

$$\frac{\text{vol}(C_D((1-\varepsilon)r))}{\text{vol}(C_D(r))} = (1-\varepsilon)^D \xrightarrow{D \rightarrow \infty} 0$$

Pour l'hypersphère :

$$\frac{\text{vol}(B_D((1-\varepsilon)r))}{\text{vol}(B_D(r))} = (1-\varepsilon)^D \xrightarrow{D \rightarrow \infty} 0$$

Note technique : $(1-\varepsilon)^D \leq e^{-D\varepsilon} \rightarrow 0$ si $D \rightarrow \infty$

Méthode de décomposition : Découper le volume en voxels hypercubiques arbitrairement petits, puis appliquer le même raisonnement.

Révision Rapide : Distribution du Volume

Pour **toute forme** : ratio $(1-\varepsilon)^D \rightarrow 0$.
Volume **concentré à la surface**.

4. L'Œuf Gaussien

Pour une distribution $X \sim \mathcal{N}(0, \text{Id}_D)$, le rayon $R = \|X\|_2$ suit :

$$R^2 = \sum_{i=1}^D X_i^2 \sim \chi^2(D) \implies \mathbb{E}[R^2] = D \implies \mathbb{E}[R] \approx \sqrt{D}$$

La densité est **concentrée** autour du rayon $\sqrt{D}$.

Théorème de l'Anneau Gaussien :

$$P\left[\left|\|X\|_2 - \sqrt{D}\right| > \beta\right] \leq 3e^{-c\beta^2}$$

La quasi-totalité de la densité est dans un **anneau fin** autour de $\sqrt{D}$.

Détails : Densité le long du rayon

Contexte : Coordonnées $X_i \sim \mathcal{N}(0, 1)$ i.i.d.

Intégration le long de r = prendre la norme. R est la v.a. du rayon.

Formulation alternative :

$$P\left[\left|\frac{\|X\|}{\sqrt{D}} - 1\right| \leq \varepsilon\right] \approx 1$$

Pour une Gaussienne $\mathcal{N}(0, \sigma^2 \text{Id}_D)$, la densité est concentrée au rayon $\sigma\sqrt{D}$.

Révision Rapide : Œuf Gaussien

Pour $X \sim \mathcal{N}(0, \text{Id}_D)$: $R^2 \sim \chi^2(D)$ donc $\mathbb{E}[R^2] = D$.

Densité concentrée au rayon $\sqrt{D}$ (anneau fin).

5. Concentration des Distances

Tous les voisins deviennent **équidistants** quand D augmente.

Théorème : Si la variance de distance normalisée tend vers 0, alors :

$$\lim_{D \rightarrow \infty} P\left[\frac{D_{\max} - D_{\min}}{D_{\min}} \leq \varepsilon\right] = 1$$

où $D_{\min}$ et $D_{\max}$ sont les distances aux voisins les plus proche et plus éloigné.

Conséquences :

- Tous les voisins sont vus à distance $D_{\min}$
- Le pouvoir de discrimination décroît exponentiellement
- KNN et ε -NN deviennent **non significatifs**

Détails : Condition de concentration

Théorème complet : Si $\lim_{D \rightarrow \infty} \text{Var} \left[\frac{d(x,y)^p}{\mathbb{E}[d(x,y)^p]} \right] = 0$ pour $0 < p < \infty$, alors la concentration se produit.

Cette condition signifie que les fluctuations relatives de la distance deviennent négligeables.

Révision Rapide : Concentration des Distances

Si variance de distance normalisée $\rightarrow 0$, alors $\frac{D_{\max} - D_{\min}}{D_{\min}} \rightarrow 0$.
Tous les voisins **équidistants**. KNN perd son sens.

6. Quasi-Orthogonalité

En haute dimension, les vecteurs aléatoires présentent des propriétés géométriques surprenantes :

Deux vecteurs aléatoires sont quasi-orthogonaux :

$$\mathbb{E}[\cos(\theta)] = 0 \implies \theta \approx \frac{\pi}{2}$$

Triangle aléatoire est quasi-équilatéral :

$$\mathbb{E}[\cos(\theta)] = \frac{1}{2} \implies \theta \approx \frac{\pi}{3}$$

Conséquence : Sur une sphère, le volume est concentré à l'**équateur** (quelle que soit la direction).

Détails : Calcul des angles entre vecteurs

Pour deux vecteurs aléatoires :

Déclarer 4 v.a. i.i.d. W, X, Y, Z sur $\Omega \subset \mathbb{R}^D$:

$$\mathbb{E}[\cos(\angle(X - Y, Z - W))] = \mathbb{E} \left[\frac{\langle X - Y, Z - W \rangle}{\|X - Y\| \cdot \|Z - W\|} \right]$$

Puisque W, X, Y, Z sont i.i.d., $X - Y$ et $Z - W$ sont aussi i.i.d. et centrées : $\mathbb{E}(X - Y) =$

$$\mathbb{E}(Z - W) = 0.$$

Le numérateur est $\text{cov}(X - Y, Z - W) = 0$.

Pour un triangle :

Avec 3 v.a. i.i.d. X, Y, Z , calculer :

$$\frac{\langle X - Y, Z - Y \rangle}{\langle X - Y, X - Y \rangle} = \frac{\langle X, Z \rangle - \langle X, Y \rangle - \langle Y, Z \rangle + \langle Y, Y \rangle}{\langle X, X \rangle + \langle Y, Y \rangle - 2\langle X, Y \rangle}$$

En espérance : $= \frac{1}{2}$

Note : Pour échantillonner sur l'hypersphère unitaire, échantillonner une distribution centralement symétrique (e.g. Gaussienne) et normaliser.

Révision Rapide : Quasi-Orthogonalité

2 vecteurs aléatoires : $\theta \approx \pi/2$ (quasi-orthogonaux).

Triangle aléatoire : $\theta \approx \pi/3$ (équilatéral).

Sphère : volume à l'équateur.

7. Hubness (Présence de Hubs)

Certains échantillons apparaissent dans le voisinage de **beaucoup** d'autres.

Définition : $n_k(x_j)$ = nombre de fois où x_j est k-NN d'un autre point.

Observation : La distribution de n_k est **asymétrique** :

- Quelques points (**hubs**) ont des valeurs très élevées
- La plupart des points ont des valeurs faibles
- Ces hubs sont "proches" de tous les autres échantillons

Détails : Définition formale du hubness

Étant donné X , définir :

$$r_{ik}(x_j) = \begin{cases} 1 & \text{si } x_j \in V_X^k(x_i) \\ 0 & \text{sinon} \end{cases}$$

Puis :

$$n_k(x_j) = \sum_i r_{ik}(x_j)$$

Visualisation empirique : Pour 20-NN avec $D = 100$ et 1000 échantillons uniformes sur 50 bins, on observe une forte asymétrie de la distribution de n_k .

Révision Rapide : Hubness

$n_k(x_j)$ = nombre de fois où x_j est k-NN d'un autre point.

Distribution **asymétrique** : quelques **hubs** dans beaucoup de voisinages.

8. Inégalités de Concentration

Les inégalités de concentration expliquent mathématiquement ces phénomènes.

Inégalités fondamentales :

- **Markov** : $P(X > \varepsilon) \leq \frac{\mathbb{E}[X]}{\varepsilon}$
- **Chebyshev** : $P(|X - \mu| > \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}$

Inégalité de Hoeffding : Pour $\{X_i\}_{i \in [D]}$ indépendantes avec $P(a \leq X_i \leq b) = 1$ et $\mathbb{E}[X_i] = \mu$:

$$P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-2D\varepsilon^2/(b-a)^2}$$

où $\bar{X} = \frac{1}{D} \sum_{i=1}^D X_i$

Explication :

- Agrégation de variables indépendantes $\rightarrow$ convergence vers μ
- Les distances de Minkowski ont structure $\sum_{i=1}^D (\cdot)$
- Pour que $d_p(x, y)$ soit petit (grand), **toutes** les D coordonnées doivent être similaires (dissimilaires)
- Quand D augmente, cela devient improbable

Détails : Application aux distances

Les distances de Minkowski :

$$d_p(x, y) = \left(\sum_{i=1}^D |x[i] - y[i]|^p \right)^{1/p}$$

L'inégalité de Hoeffding explique formellement pourquoi les valeurs de distance se **concentrent**.

Intuition : Pour D grand, les valeurs extrêmes de $d_p(x, y)$ deviennent improbables car nécessitent une coordination sur **toutes** les dimensions.

Note : Exemple d'analyse PAC (Probably Approximately Correct).

Révision Rapide : Inégalités de Concentration

Hoeffding : $P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-2D\varepsilon^2/(b-a)^2}$.

Structure $\sum_{i=1}^D (\cdot)$ dans distances $\rightarrow$ **concentration**.

La bénédiction de la dimensionnalité

1. Lois des Grands Nombres

Loi Faible des Grands Nombres (WLLN) :

Pour $\{X_i\}_{i \in [D]}$ i.i.d. avec $\mathbb{E}[X_i] = \mu$:

$$\lim_{D \rightarrow \infty} P(|\bar{X} - \mu| < \varepsilon) = 1$$

où $\bar{X} = \frac{1}{D} \sum_{i=1}^D X_i$

Interprétation :

- La moyenne empirique $\bar{X}$ converge vers la vraie espérance μ
- Base fondamentale de la théorie de l'estimation
- Cohérente avec l'approche fréquentiste des probabilités

Théorème Central Limite (CLT) :

$$Z_D = \frac{\sqrt{D}}{\sigma}(\bar{X} - \mu) \sim \mathcal{N}(0, 1)$$

si $\text{Var}(X_i) = \sigma^2$

Détails : Preuve via Chebyshev

La WLLN peut être prouvée à partir de l'inégalité de Chebyshev :

$$P(|\bar{X} - \mu| \geq \varepsilon) \leq \frac{\text{Var}(\bar{X})}{\varepsilon^2} = \frac{\sigma^2}{D\varepsilon^2} \xrightarrow{D \rightarrow \infty} 0$$

Le TCL donne la forme (Gaussienne) et le taux $(1/\sqrt{D})$ de convergence.

Révision Rapide : Lois des Grands Nombres

WLLN : $\bar{X} \xrightarrow{P} \mu$ quand $D \rightarrow \infty$.

Base de l'estimation de densité.
CLT : taux de convergence $1/\sqrt{D}$.

2. Projections Aléatoires

Principe : Exponentiellement nombreuses directions quasi-orthogonales en haute dimension.

Lemme de Johnson-Lindenstrauss :

Étant donné $X \subset \Omega$, il existe une projection linéaire $p : \mathbb{R}^D \rightarrow \mathbb{R}^d$ telle que :

$$(1 - \varepsilon)\|x_i - x_j\| \leq \|p(x_i) - p(x_j)\| \leq (1 + \varepsilon)\|x_i - x_j\|$$

avec

$$d = O\left(\frac{\log N}{\varepsilon^2}\right)$$

Remarque importante : d ne dépend **PAS** de D !

Applications :

- Locally Sensitive Hashing (LSH) pour recherche approximative du plus proche voisin (ANN)
- Bases aléatoires pour décomposition et codage de signaux

Caveat : Taux de convergence plus lent que la plupart des concentrations

Détails : Pourquoi ça marche ?

Rappel : Deux vecteurs aléatoires u et v sont probablement orthogonaux : $\langle u, v \rangle = \varepsilon$ (petit).

Propriété clé : Il existe exponentiellement nombreuses directions quasi-orthogonales dans les espaces de haute dimension.

Cela permet de créer des bases aléatoires (quasi-orthonormales) qui préservent les propriétés métriques essentielles tout en réduisant drastiquement la dimension.

Révision Rapide : Projections Aléatoires

Johnson-Lindenstrauss : projection $\mathbb{R}^D \rightarrow \mathbb{R}^d$ préservant distances avec $d = O(\log N / \varepsilon^2)$ (indépendant de D).

Application : LSH pour ANN.

Impact en data science

1. Échantillonnage

Conséquences de la parcimonie :

- Besoin d'un nombre **exponentiel** d'échantillons pour couvrir l'espace
- Les inégalités de concentration sont des **indicateurs de précision** pour l'estimation
- Taux de rejet dans l'échantillonnage par rejet → proche de 100%

Détails : Échantillonnage par rejet

Dans les processus pratiques comme l'échantillonnage par rejet, le taux de rejet devient exponentiellement proche de 100% en raison du phénomène de sphère vide.

Si on veut échantillonner dans une région particulière (comme une sphère inscrite dans un cube), la probabilité d'acceptation décroît exponentiellement avec D .

2. Indexation

Exploitation de la structure :

- L'indexation exploite la structure des données pour anticiper les parties de l'espace à visiter
- Si tous les voisins sont à distance égale, la structure **disparaît**

Techniques de **partitionnement spatial** (e.g. kd-trees) :

- Tentent d'identifier uniquement chaque donnée dans une cellule
- Avec concentration des distances : taille de cellule → rayon complet
- La recherche devient **exhaustive** → complexité $O(N)$
- Le hubness rend certaines données réponses à presque toutes les requêtes

Détails : Arbres de recherche

Les arbres k-d tentent d'obtenir une partition de l'espace où chaque donnée est uniquement identifiée dans une intersection de cellules (chemins dans l'arbre).

Avec la concentration des distances :

- La cellule doit avoir une taille égale au rayon de la sphère pour couvrir l'espace complet

- Les conditions de pruning (élagage) de branches deviennent inefficaces
- L'arbre dégénère en liste linéaire

3. Apprentissage

Machine Learning = découverte d'approximateurs de fonctions.

Problème : Trouver $\phi_\theta \in \mathcal{F}$ approximant $\phi : X \rightarrow Y$ en minimisant une erreur.

Borne théorique catastrophique :

Si $\mathcal{F}$ est une classe de fonctions c -uniformément Lipschitz sur Ω :

$$\sup_{\phi_\theta \in \mathcal{F}} \|\phi_\theta - \phi\|_\infty \geq \frac{c\sqrt{D}N^{-1/D}}{2} \sqrt{\frac{2}{\pi e}} \left(1 + O\left(\frac{\log D}{D}\right)\right)$$

Pour une erreur $c\varepsilon$ avec $\varepsilon > 0$, le nombre d'exemples requis est :

$$N \geq \frac{\varepsilon^{-D} D^{D/2}}{(2\pi e)^{D/2}}$$

Exemples concrets :

- $D = 3, \varepsilon = 0.1 \rightarrow N \geq 74$
- $D = 10, \varepsilon = 0.1 \rightarrow N \geq 687 \times 10^6$
- $D = 15, \varepsilon = 0.1 \rightarrow N \geq 377 \times 10^{12}$
- $D = 10, \varepsilon = 0.01 \rightarrow N \geq 6.9 \times 10^{18}$

Cas réaliste : $D \sim 100, \varepsilon \sim 10^{-4} \rightarrow N \sim 10^{400}$ **IMPOSSIBLE**

Révision Rapide : Importance en Data Science

Échantillonnage : besoin exponentiel, taux de rejet $\rightarrow 100\%$.

Indexation : structure disparaît, kd-trees $\rightarrow O(N)$, hubness.

Learning : $N \geq \varepsilon^{-D} D^{D/2} / (2\pi e)^{D/2} \rightarrow$ impossible pour D grand.

4. Pourquoi la Data Science fonctionne-t-elle quand même ?

Hypothèses dans les analyses ci-dessus :

- Distribution **uniforme** (ou isotrope) des données
- Features **indépendantes**

Ces hypothèses sont **FAUSSES** en pratique !

Réalité :

- Les données réelles **ne peuplent PAS** l'espace uniformément
- Les features montrent des **corrélations**
- Les données occupent des **sous-espaces** de dimensionnalité intrinsèque plus faible

Solutions pratiques :

- Décorrélérer les features (espace latent linéaire)
- Découvrir des sous-espaces (clustering, réduction de dimension non-linéaire)
- PCA, autoencodeurs, réseaux de neurones
- Exploiter la structure géométrique sous-jacente

Intuition clé : Si les features sont informatives, elles ne sont pas indépendantes et les données se concentrent sur des variétés de dimension bien plus faible que D .

Révision Rapide : Pourquoi ça marche ?

Analyses supposent distribution **uniforme** et features **indépendantes**.

Réalité : données sur **sous-espaces** de dimensionnalité intrinsèque faible.

Solutions : décorrélation, clustering, réduction de dimension.

Résumé global

La **géométrie en haute dimension** ($D \gtrsim 10$) est **différente** de la géométrie 3D habituelle.

Aspects positifs (Bénédiction)

- **Inégalités de concentration** : base de l'estimation statistique
- **Lois des Grands Nombres** : permettent l'estimation de densité
- **Projections aléatoires** : exploitent la quasi-orthogonalité

Aspects négatifs (Malédiction)

- Données très **parcimonieuses** (besoin exponentiel d'échantillons)
- **Concentration des distances et angles** :
 - Tous les voisins équidistants
 - Tout semble orthogonal
- Densité concentrée sur **rayons étroits** → échantillonnage biaisé
- **Hubs** : partie de toutes les classes/réponses

Solution unique

Puisque c'est par construction, la seule solution est d'opérer dans des **espaces de basse dimension** :

- Réduction de dimensionnalité
- Découverte de sous-espaces
- Décorrélacion des features

Message clé : La Data Science fonctionne parce que les données réelles **ne sont pas uniformes** et vivent sur des **sous-variétés de faible dimension**.

Révision Rapide : Résumé

Haute dimension ($D \gtrsim 10$) géométrie 3D.

: inégalités de concentration, WLLN, projections aléatoires.

: data sparsity, concentration distances/angles, hubs.

Solution : opérer en **basse dimension** (PCA, autoencodeurs, exploitation de structure).