

## Table of contents

|                                                            |          |
|------------------------------------------------------------|----------|
| <b>L'essentiel</b>                                         | <b>1</b> |
| Pourquoi étudier les espaces de haute dimension ?          | 1        |
| L'Espace de Représentation                                 | 2        |
| La malédiction de la dimensionnalité                       | 2        |
| 1. Parcimonie des Données (Data Sparsity)                  | 2        |
| 2. Sphère Vide et Cube Épineux                             | 3        |
| 3. Distribution du Volume                                  | 4        |
| 4. L'Œuf Gaussien                                          | 5        |
| 5. Concentration des Distances                             | 5        |
| 6. Quasi-Orthogonalité                                     | 6        |
| 7. Hubness (Présence de Hubs)                              | 7        |
| 8. Inégalités de Concentration                             | 8        |
| La bénédiction de la dimensionnalité                       | 9        |
| 1. Lois des Grands Nombres                                 | 9        |
| 2. Projections Aléatoires                                  | 10       |
| Impact en data science                                     | 11       |
| 1. Échantillonnage                                         | 11       |
| 2. Indexation                                              | 11       |
| 3. Apprentissage                                           | 12       |
| 4. Pourquoi la Data Science fonctionne-t-elle quand même ? | 13       |
| Résumé global                                              | 13       |
| Aspects positifs (Bénédiction)                             | 13       |
| Aspects négatifs (Malédiction)                             | 14       |
| Solution unique                                            | 14       |

## L'essentiel

### Pourquoi étudier les espaces de haute dimension ?

La **Data Science** étudie comment représenter le monde réel sous forme de données numériques dans des espaces mathématiques. Elle se concentre sur les propriétés **géométriques** et **statistiques** de ces espaces.

#### Pipeline universel :

- Monde réel  $\rightarrow$  Capteurs  $\rightarrow$  Données brutes  $\rightarrow$  Représentation numérique
- Tout devient une **matrice** :  $N$  échantillons,  $D$  caractéristiques

#### Deux visions complémentaires :

- **Statistique** : échantillon d'une distribution sous-jacente
- **Algébrique** : matrice  $X \in \mathbb{R}^{D \times N}$

---

## L'Espace de Représentation

Un espace de dimension  $D$  a une structure complète :

- Produit scalaire  $\rightarrow$  Norme  $\rightarrow$  Distance  $\rightarrow$  Espace métrique

**Question centrale** : Que se passe-t-il quand  $D$  devient grand ?

- Effets négatifs : **Malédiction** de la dimensionnalité
  - Effets positifs : **Bénédiction** de la dimensionnalité
- 

## La malédiction de la dimensionnalité

### 1. Parcimonie des Données (Data Sparsity)

Pour estimer précisément une distribution en dimension  $D$ , il faut un nombre **exponentiel** d'échantillons :

$$N \approx n \cdot b^D$$

où  $n$  = échantillons par bin,  $b$  = nombre de bins par dimension.

**Exemple** :

- $D = 6, b = 10, n = 10 \rightarrow N \approx 10^7$  échantillons nécessaires
- Avec  $N$  fixé : la plupart des bins restent **vides**

#### Détails : Estimation de qualité

Si on fixe  $N$ , la qualité d'estimation devient :

$$n = \frac{N}{b^D} \implies \mathbb{E}[P(x_i \in \text{bin}_j)] \approx \frac{1}{b^D}$$

La probabilité qu'un bin soit occupé décroît exponentiellement avec  $D$ .

### Révision Rapide : Data Sparsity

Besoin de  $N \approx n \cdot b^D$  échantillons (croissance **exponentielle**).  
Si  $N$  fixé :  $n = N/b^D \rightarrow$  la plupart des bins **vides**.

## 2. Sphère Vide et Cube Épineux

Dans un cube en haute dimension, le volume de la sphère inscrite devient **négligeable** :

$$\frac{\text{vol}(B_D(r))}{\text{vol}(C_D(r))} = \frac{\pi^{D/2}}{D \cdot 2^{D-1} \Gamma(D/2)} \xrightarrow{D \rightarrow \infty} 0$$

Conséquences :

- Le volume se concentre dans les **coins** du cube
- Distance centre-coin =  $\frac{\sqrt{D}}{2}$  (croît avec  $\sqrt{D}$ )
- Échantillonnage uniforme  $\rightarrow$  sphère **vide**

### Détails : Volume de l'hypersphère

Formule générale :

$$\text{vol}(B_D(r)) = \frac{2r^D \pi^{D/2}}{D \Gamma(D/2)}$$

Relation de récurrence (pour  $D > 1$ ) :

$$\text{vol}(B_D(r)) = \frac{2\pi r^2}{D} \text{vol}(B_{D-2}(r))$$

Coins du cube unitaire :

- Nombre de coins :  $2^D$
- Distance à l'origine :  $\|x_i\|_2 = \frac{\sqrt{D}}{2}$

| $D$                  | 1             | 2                    | 4 | 5                    | 100 |
|----------------------|---------------|----------------------|---|----------------------|-----|
| $\frac{\sqrt{D}}{2}$ | $\frac{1}{2}$ | $\frac{\sqrt{2}}{2}$ | 1 | $\frac{\sqrt{5}}{2}$ | 5   |

### Révision Rapide : Sphère Vide & Cube Épineux

Ratio sphère/cube  $\rightarrow 0$ . Volume concentré aux **coins** (distance  $\sqrt{D}/2$ ).  
Échantillonnage uniforme  $\rightarrow$  sphère **vide**.

---

### 3. Distribution du Volume

Pour **toute forme** (cube, sphère, ou autre), le volume se concentre près de la surface :

$$\lim_{D \rightarrow \infty} \frac{\text{vol}(V_D(r)) - \text{vol}(V_D((1-\varepsilon)r))}{\text{vol}(V_D(r))} = 1$$

**Principe :**

- Réduire la taille par facteur  $(1-\varepsilon) \rightarrow$  volume réduit par  $(1-\varepsilon)^D \rightarrow 0$
- Presque tout le volume est dans une mince **coquille** à la surface

#### Détails : Calcul pour hypercube et hypersphère

**Pour l'hypercube :**

$$\frac{\text{vol}(C_D((1-\varepsilon)r))}{\text{vol}(C_D(r))} = (1-\varepsilon)^D \xrightarrow{D \rightarrow \infty} 0$$

**Pour l'hypersphère :**

$$\frac{\text{vol}(B_D((1-\varepsilon)r))}{\text{vol}(B_D(r))} = (1-\varepsilon)^D \xrightarrow{D \rightarrow \infty} 0$$

**Note technique :**  $(1-\varepsilon)^D \leq e^{-D\varepsilon} \rightarrow 0$  si  $D \rightarrow \infty$

**Méthode de décomposition :** Découper le volume en voxels hypercubiques arbitrairement petits, puis appliquer le même raisonnement.

### Révision Rapide : Distribution du Volume

Pour **toute forme** : ratio  $(1-\varepsilon)^D \rightarrow 0$ .  
Volume **concentré à la surface**.

---

#### 4. L'Œuf Gaussien

Pour une distribution  $X \sim \mathcal{N}(0, \text{Id}_D)$ , le rayon  $R = \|X\|_2$  suit :

$$R^2 = \sum_{i=1}^D X_i^2 \sim \chi^2(D) \implies \mathbb{E}[R^2] = D \implies \mathbb{E}[R] \approx \sqrt{D}$$

La densité est **concentrée** autour du rayon  $\sqrt{D}$ .

**Théorème de l'Anneau Gaussien :**

$$P\left[\left|\|X\|_2 - \sqrt{D}\right| > \beta\right] \leq 3e^{-c\beta^2}$$

La quasi-totalité de la densité est dans un **anneau fin** autour de  $\sqrt{D}$ .

##### Détails : Densité le long du rayon

**Contexte :** Coordonnées  $X_i \sim \mathcal{N}(0, 1)$  i.i.d.

**Intégration le long de  $r$**  = prendre la norme.  $R$  est la v.a. du rayon.

**Formulation alternative :**

$$P\left[\left|\frac{\|X\|}{\sqrt{D}} - 1\right| \leq \varepsilon\right] \approx 1$$

Pour une Gaussienne  $\mathcal{N}(0, \sigma^2 \text{Id}_D)$ , la densité est concentrée au rayon  $\sigma\sqrt{D}$ .

##### Révision Rapide : Œuf Gaussien

Pour  $X \sim \mathcal{N}(0, \text{Id}_D)$  :  $R^2 \sim \chi^2(D)$  donc  $\mathbb{E}[R^2] = D$ .

Densité concentrée au rayon  $\sqrt{D}$  (anneau fin).

---

#### 5. Concentration des Distances

Tous les voisins deviennent **équidistants** quand  $D$  augmente.

**Théorème :** Si la variance de distance normalisée tend vers 0, alors :

$$\lim_{D \rightarrow \infty} P\left[\frac{D_{\max} - D_{\min}}{D_{\min}} \leq \varepsilon\right] = 1$$

où  $D_{\min}$  et  $D_{\max}$  sont les distances aux voisins les plus proche et plus éloigné.

**Conséquences :**

- Tous les voisins sont vus à distance  $D_{\min}$
- Le pouvoir de discrimination décroît exponentiellement
- KNN et  $\varepsilon$ -NN deviennent **non significatifs**

**Détails : Condition de concentration**

**Théorème complet :** Si  $\lim_{D \rightarrow \infty} \text{Var} \left[ \frac{d(x,y)^p}{\mathbb{E}[d(x,y)^p]} \right] = 0$  pour  $0 < p < \infty$ , alors la concentration se produit.

Cette condition signifie que les fluctuations relatives de la distance deviennent négligeables.

**Révision Rapide : Concentration des Distances**

Si variance de distance normalisée  $\rightarrow 0$ , alors  $\frac{D_{\max} - D_{\min}}{D_{\min}} \rightarrow 0$ .

Tous les voisins **équidistants**. KNN perd son sens.

---

## 6. Quasi-Orthogonalité

En haute dimension, les vecteurs aléatoires présentent des propriétés géométriques surprenantes :

**Deux vecteurs aléatoires** sont quasi-orthogonaux :

$$\mathbb{E}[\cos(\theta)] = 0 \implies \theta \approx \frac{\pi}{2}$$

**Triangle aléatoire** est quasi-équilatéral :

$$\mathbb{E}[\cos(\theta)] = \frac{1}{2} \implies \theta \approx \frac{\pi}{3}$$

**Conséquence :** Sur une sphère, le volume est concentré à l'**équateur** (quelle que soit la direction).

**Détails : Calcul des angles entre vecteurs**

**Pour deux vecteurs aléatoires :**

Déclarer 4 v.a. i.i.d.  $W, X, Y, Z$  sur  $\Omega \subset \mathbb{R}^D$  :

$$\mathbb{E}[\cos(\angle(X - Y, Z - W))] = \mathbb{E} \left[ \frac{\langle X - Y, Z - W \rangle}{\|X - Y\| \cdot \|Z - W\|} \right]$$

Puisque  $W, X, Y, Z$  sont i.i.d.,  $X - Y$  et  $Z - W$  sont aussi i.i.d. et centrées :  $\mathbb{E}(X - Y) =$

$$\mathbb{E}(Z - W) = 0.$$

Le numérateur est  $\text{cov}(X - Y, Z - W) = 0$ .

**Pour un triangle :**

Avec 3 v.a. i.i.d.  $X, Y, Z$ , calculer :

$$\frac{\langle X - Y, Z - Y \rangle}{\langle X - Y, X - Y \rangle} = \frac{\langle X, Z \rangle - \langle X, Y \rangle - \langle Y, Z \rangle + \langle Y, Y \rangle}{\langle X, X \rangle + \langle Y, Y \rangle - 2\langle X, Y \rangle}$$

En espérance :  $= \frac{1}{2}$

**Note :** Pour échantillonner sur l'hypersphère unitaire, échantillonner une distribution centralement symétrique (e.g. Gaussienne) et normaliser.

### Révision Rapide : Quasi-Orthogonalité

**2 vecteurs aléatoires :**  $\theta \approx \pi/2$  (quasi-orthogonaux).

**Triangle aléatoire :**  $\theta \approx \pi/3$  (équilatéral).

**Sphère :** volume à l'équateur.

## 7. Hubness (Présence de Hubs)

Certains échantillons apparaissent dans le voisinage de **beaucoup** d'autres.

**Définition :**  $n_k(x_j)$  = nombre de fois où  $x_j$  est k-NN d'un autre point.

**Observation :** La distribution de  $n_k$  est **asymétrique** :

- Quelques points (**hubs**) ont des valeurs très élevées
- La plupart des points ont des valeurs faibles
- Ces hubs sont "proches" de tous les autres échantillons

### Détails : Définition formale du hubness

Étant donné  $X$ , définir :

$$r_{ik}(x_j) = \begin{cases} 1 & \text{si } x_j \in V_X^k(x_i) \\ 0 & \text{sinon} \end{cases}$$

Puis :

$$n_k(x_j) = \sum_i r_{ik}(x_j)$$

**Visualisation empirique :** Pour 20-NN avec  $D = 100$  et 1000 échantillons uniformes sur 50 bins, on observe une forte asymétrie de la distribution de  $n_k$ .

### Révision Rapide : Hubness

$n_k(x_j)$  = nombre de fois où  $x_j$  est k-NN d'un autre point.

Distribution **asymétrique** : quelques **hubs** dans beaucoup de voisinages.

## 8. Inégalités de Concentration

Les inégalités de concentration expliquent mathématiquement ces phénomènes.

**Inégalités fondamentales :**

- **Markov** :  $P(X > \varepsilon) \leq \frac{\mathbb{E}[X]}{\varepsilon}$
- **Chebyshev** :  $P(|X - \mu| > \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}$

**Inégalité de Hoeffding** : Pour  $\{X_i\}_{i \in [D]}$  indépendantes avec  $P(a \leq X_i \leq b) = 1$  et  $\mathbb{E}[X_i] = \mu$  :

$$P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-2D\varepsilon^2/(b-a)^2}$$

où  $\bar{X} = \frac{1}{D} \sum_{i=1}^D X_i$

**Explication :**

- Agrégation de variables indépendantes  $\rightarrow$  convergence vers  $\mu$
- Les distances de Minkowski ont structure  $\sum_{i=1}^D (\cdot)$
- Pour que  $d_p(x, y)$  soit petit (grand), **toutes** les  $D$  coordonnées doivent être similaires (dissimilaires)
- Quand  $D$  augmente, cela devient improbable

### Détails : Application aux distances

Les distances de Minkowski :

$$d_p(x, y) = \left( \sum_{i=1}^D |x[i] - y[i]|^p \right)^{1/p}$$

L'inégalité de Hoeffding explique formellement pourquoi les valeurs de distance se **concentrent**.

**Intuition** : Pour  $D$  grand, les valeurs extrêmes de  $d_p(x, y)$  deviennent improbables car nécessitent une coordination sur **toutes** les dimensions.

**Note** : Exemple d'analyse PAC (Probably Approximately Correct).



### Révision Rapide : Inégalités de Concentration

**Hoeffding** :  $P(|\bar{X} - \mu| > \varepsilon) \leq 2e^{-2D\varepsilon^2/(b-a)^2}$ .

Structure  $\sum_{i=1}^D (\cdot)$  dans distances  $\rightarrow$  **concentration**.

## La bénédiction de la dimensionnalité

### 1. Lois des Grands Nombres

**Loi Faible des Grands Nombres (WLLN)** :

Pour  $\{X_i\}_{i \in [D]}$  i.i.d. avec  $\mathbb{E}[X_i] = \mu$  :

$$\lim_{D \rightarrow \infty} P(|\bar{X} - \mu| < \varepsilon) = 1$$

où  $\bar{X} = \frac{1}{D} \sum_{i=1}^D X_i$

**Interprétation** :

- La moyenne empirique  $\bar{X}$  converge vers la vraie espérance  $\mu$
- Base fondamentale de la théorie de l'estimation
- Cohérente avec l'approche fréquentiste des probabilités

**Théorème Central Limite (CLT)** :

$$Z_D = \frac{\sqrt{D}}{\sigma}(\bar{X} - \mu) \sim \mathcal{N}(0, 1)$$

si  $\text{Var}(X_i) = \sigma^2$

### Détails : Preuve via Chebyshev

La WLLN peut être prouvée à partir de l'inégalité de Chebyshev :

$$P(|\bar{X} - \mu| \geq \varepsilon) \leq \frac{\text{Var}(\bar{X})}{\varepsilon^2} = \frac{\sigma^2}{D\varepsilon^2} \xrightarrow{D \rightarrow \infty} 0$$

Le TCL donne la forme (Gaussienne) et le taux  $(1/\sqrt{D})$  de convergence.

### Révision Rapide : Lois des Grands Nombres

**WLLN** :  $\bar{X} \xrightarrow{P} \mu$  quand  $D \rightarrow \infty$ .

Base de l'estimation de densité.  
**CLT** : taux de convergence  $1/\sqrt{D}$ .

## 2. Projections Aléatoires

**Principe** : Exponentiellement nombreuses directions quasi-orthogonales en haute dimension.

**Lemme de Johnson-Lindenstrauss** :

Étant donné  $X \subset \Omega$ , il existe une projection linéaire  $p : \mathbb{R}^D \rightarrow \mathbb{R}^d$  telle que :

$$(1 - \varepsilon)\|x_i - x_j\| \leq \|p(x_i) - p(x_j)\| \leq (1 + \varepsilon)\|x_i - x_j\|$$

avec

$$d = O\left(\frac{\log N}{\varepsilon^2}\right)$$

**Remarque importante** :  $d$  ne dépend **PAS** de  $D$  !

**Applications** :

- Locally Sensitive Hashing (LSH) pour recherche approximative du plus proche voisin (ANN)
- Bases aléatoires pour décomposition et codage de signaux

**Caveat** : Taux de convergence plus lent que la plupart des concentrations

**Détails : Pourquoi ça marche ?**

**Rappel** : Deux vecteurs aléatoires  $u$  et  $v$  sont probablement orthogonaux :  $\langle u, v \rangle = \varepsilon$  (petit).

**Propriété clé** : Il existe exponentiellement nombreuses directions quasi-orthogonales dans les espaces de haute dimension.

Cela permet de créer des bases aléatoires (quasi-orthonormales) qui préservent les propriétés métriques essentielles tout en réduisant drastiquement la dimension.

**Révision Rapide : Projections Aléatoires**

**Johnson-Lindenstrauss** : projection  $\mathbb{R}^D \rightarrow \mathbb{R}^d$  préservant distances avec  $d = O(\log N / \varepsilon^2)$  (indépendant de  $D$ ).

Application : LSH pour ANN.

---

## Impact en data science

### 1. Échantillonnage

Conséquences de la parcimonie :

- Besoin d'un nombre **exponentiel** d'échantillons pour couvrir l'espace
- Les inégalités de concentration sont des **indicateurs de précision** pour l'estimation
- Taux de rejet dans l'échantillonnage par rejet → proche de 100%

#### Détails : Échantillonnage par rejet

Dans les processus pratiques comme l'échantillonnage par rejet, le taux de rejet devient exponentiellement proche de 100% en raison du phénomène de sphère vide.

Si on veut échantillonner dans une région particulière (comme une sphère inscrite dans un cube), la probabilité d'acceptation décroît exponentiellement avec  $D$ .

---

### 2. Indexation

Exploitation de la structure :

- L'indexation exploite la structure des données pour anticiper les parties de l'espace à visiter
- Si tous les voisins sont à distance égale, la structure **disparaît**

Techniques de **partitionnement spatial** (e.g. kd-trees) :

- Tentent d'identifier uniquement chaque donnée dans une cellule
- Avec concentration des distances : taille de cellule → rayon complet
- La recherche devient **exhaustive** → complexité  $O(N)$
- Le hubness rend certaines données réponses à presque toutes les requêtes

#### Détails : Arbres de recherche

Les arbres k-d tentent d'obtenir une partition de l'espace où chaque donnée est uniquement identifiée dans une intersection de cellules (chemins dans l'arbre).

Avec la concentration des distances :

- La cellule doit avoir une taille égale au rayon de la sphère pour couvrir l'espace complet

- Les conditions de pruning (élagage) de branches deviennent inefficaces
- L'arbre dégénère en liste linéaire

### 3. Apprentissage

**Machine Learning** = découverte d'approximateurs de fonctions.

**Problème** : Trouver  $\phi_\theta \in \mathcal{F}$  approximant  $\phi : X \rightarrow Y$  en minimisant une erreur.

**Borne théorique catastrophique** :

Si  $\mathcal{F}$  est une classe de fonctions  $c$ -uniformément Lipschitz sur  $\Omega$  :

$$\sup_{\phi_\theta \in \mathcal{F}} \|\phi_\theta - \phi\|_\infty \geq \frac{c\sqrt{D}N^{-1/D}}{2} \sqrt{\frac{2}{\pi e}} \left(1 + O\left(\frac{\log D}{D}\right)\right)$$

Pour une erreur  $c\varepsilon$  avec  $\varepsilon > 0$ , le nombre d'exemples requis est :

$$N \geq \frac{\varepsilon^{-D} D^{D/2}}{(2\pi e)^{D/2}}$$

**Exemples concrets** :

- $D = 3, \varepsilon = 0.1 \rightarrow N \geq 74$
- $D = 10, \varepsilon = 0.1 \rightarrow N \geq 687 \times 10^6$
- $D = 15, \varepsilon = 0.1 \rightarrow N \geq 377 \times 10^{12}$
- $D = 10, \varepsilon = 0.01 \rightarrow N \geq 6.9 \times 10^{18}$

**Cas réaliste** :  $D \sim 100, \varepsilon \sim 10^{-4} \rightarrow N \sim 10^{400}$  **IMPOSSIBLE**

**Révision Rapide : Importance en Data Science**

**Échantillonnage** : besoin exponentiel, taux de rejet  $\rightarrow 100\%$ .

**Indexation** : structure disparaît, kd-trees  $\rightarrow O(N)$ , hubness.

**Learning** :  $N \geq \varepsilon^{-D} D^{D/2} / (2\pi e)^{D/2} \rightarrow$  impossible pour  $D$  grand.

#### 4. Pourquoi la Data Science fonctionne-t-elle quand même ?

Hypothèses dans les analyses ci-dessus :

- Distribution **uniforme** (ou isotrope) des données
- Features **indépendantes**

Ces hypothèses sont **FAUSSES** en pratique !

Réalité :

- Les données réelles **ne peuplent PAS** l'espace uniformément
- Les features montrent des **corrélations**
- Les données occupent des **sous-espaces** de dimensionnalité intrinsèque plus faible

Solutions pratiques :

- Décorrélérer les features (espace latent linéaire)
- Découvrir des sous-espaces (clustering, réduction de dimension non-linéaire)
- PCA, autoencodeurs, réseaux de neurones
- Exploiter la structure géométrique sous-jacente

**Intuition clé** : Si les features sont informatives, elles ne sont pas indépendantes et les données se concentrent sur des variétés de dimension bien plus faible que  $D$ .

##### Révision Rapide : Pourquoi ça marche ?

Analyses supposent distribution **uniforme** et features **indépendantes**.

**Réalité** : données sur **sous-espaces** de dimensionnalité intrinsèque faible.

**Solutions** : décorrélation, clustering, réduction de dimension.

---

#### Résumé global

La **géométrie en haute dimension** ( $D \gtrsim 10$ ) est **différente** de la géométrie 3D habituelle.

#### Aspects positifs (Bénédiction)

- **Inégalités de concentration** : base de l'estimation statistique
- **Lois des Grands Nombres** : permettent l'estimation de densité
- **Projections aléatoires** : exploitent la quasi-orthogonalité

## Aspects négatifs (Malédiction)

- Données très **parcimonieuses** (besoin exponentiel d'échantillons)
- **Concentration des distances et angles** :
  - Tous les voisins équidistants
  - Tout semble orthogonal
- Densité concentrée sur **rayons étroits** → échantillonnage biaisé
- **Hubs** : partie de toutes les classes/réponses

## Solution unique

Puisque c'est par construction, la seule solution est d'opérer dans des **espaces de basse dimension** :

- Réduction de dimensionnalité
- Découverte de sous-espaces
- Décorrélacion des features

**Message clé** : La Data Science fonctionne parce que les données réelles **ne sont pas uniformes** et vivent sur des **sous-variétés de faible dimension**.

### Révision Rapide : Résumé

**Haute dimension** ( $D \gtrsim 10$ ) géométrie 3D.

: inégalités de concentration, WLLN, projections aléatoires.

: data sparsity, concentration distances/angles, hubs.

**Solution** : opérer en **basse dimension** (PCA, autoencodeurs, exploitation de structure).