

Table of contents

Cours détaillé	1
Introduction et Motivation	1
Contexte général	1
Caractéristiques fondamentales	2
Formalisation	2
Maximisation de la variance	2
Minimisation de l'erreur	4
Réduction de Dimension	5
Structure de l'espace latent	5
Approximation de rang faible et réduction de dimension	7
Géométrie et qualité de reconstruction	8
Application pratique de la PCA	9
Algorithme PCA complet	9
Choix du nombre de composantes K	10
Alternatives et extensions	10
AutoEncodeurs linéaires (Linear AE)	10
Relation entre PCA et AutoEncodeur linéaire	11
Extensions des AutoEncodeurs	12
Formulations alternatives de la PCA	12
Synthèse et points clés	13
Caractéristiques essentielles de la PCA	13
Quand utiliser la PCA ?	14
Concepts mathématiques à maîtriser	14
Questions d'examen types	14
Questions conceptuelles	14
Questions techniques	15
Démonstrations mathématiques	15

Cours détaillé

Introduction et Motivation

Contexte général

La **PCA** (Analyse en Composantes Principales) est une méthode de **décomposition latente linéaire** qui permet d'identifier les **facteurs latents sous-jacents** structurant les données.

Problématique principale :

Les représentations de base des données ne sont pas toujours optimales. La PCA cherche à trouver une nouvelle représentation qui :

- Révèle les **facteurs latents** (cachés) qui gouvernent le processus
- Utilise la **corrélation statistique** pour identifier ces facteurs
- Permet une **simplification** des données par décimation justifiée

Caractéristiques fondamentales

La PCA exhibe des **facteurs latents linéaires** et permet plusieurs interprétations complémentaires que nous étudierons.

Point clé : La PCA fait partie de la famille des **modèles latents linéaires**

Formalisation

Maximisation de la variance

Intuition géométrique

Question fondamentale : Quelle information devons-nous préserver lors d'une projection ?

Exemple illustratif :

Supposons que les données $X \subset \Omega$ sont presque contenues dans un plan 2D au sein d'un espace 3D. Le choix pertinent consiste à sélectionner une base $\{u_1, u_2\}$ pour ce plan.

Caractérisation de la base optimale $\{u_1, u_2, u_3\}$:

- Les données **varient le plus** le long des directions u_1 et u_2
- Les données **varient le moins** orthogonalement à ces directions (le long de u_3)

Formalisation mathématique

Définitions :

Soit X l'ensemble de données, $\{u_i\}_{i \in [[D]]}$ une nouvelle **base orthonormale** de $\mathbb{R}^D$.

La **première composante principale** u_1 est choisie telle que la **variance des données projetées** sur u_1 soit maximale.

La composante u_2 est ensuite choisie en utilisant la projection sur $\text{Proj}_{u_1^\perp}(X)$ (orthogonal à u_1).

Modèle mathématique :

La moyenne empirique et la variance projetée sont :

$$x = \frac{1}{N} \sum_{i=1}^N x_i$$

$$v_{u_1} = \frac{1}{N} \sum_{i=1}^N (u_1^T x_i - u_1^T x)^2 = u_1^T \Sigma u_1$$

où $\Sigma = \frac{1}{N} \sum_{i=1}^N (x_i - x)(x_i - x)^T$ est la **matrice de covariance** des données.

Problème d'optimisation :

$$u_1 = \arg \max_{u^T u = 1} u^T \Sigma u$$

Résolution par les multiplicateurs de Lagrange

Fonction de Lagrange :

$$J(u) = u^T \Sigma u + \lambda(1 - u^T u)$$

Conditions d'optimalité :

$$\left. \frac{\partial J(u)}{\partial u} \right|_{u=u_1} = 0 \quad \text{et} \quad \left. \frac{\partial J(u)}{\partial \lambda} \right|_{\lambda=\lambda_1} = 0$$

Résultat fondamental :

$$\Sigma u_1 = \lambda_1 u_1 \quad \Rightarrow \quad v_{u_1} = u_1^T \Sigma u_1 = \lambda_1$$

Conclusion : (u_1, λ_1) est une **paire propre** (eigenpair) de la matrice de covariance Σ

Décomposition complète

En continuant ce processus de décimation, on obtient l'ensemble des **composantes principales** comme les paires propres $\{(u_i, \lambda_i)\}_{i \in [[D]]}$ de Σ .

Décomposition matricielle :

$$\Lambda = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_D \end{pmatrix} = \begin{pmatrix} | & | & \cdots & | \\ u_1 & u_2 & \cdots & u_D \\ | & | & \cdots & | \end{pmatrix}^T \Sigma \begin{pmatrix} | & | & \cdots & | \\ u_1 & u_2 & \cdots & u_D \\ | & | & \cdots & | \end{pmatrix} = U^T \Sigma U$$

Minimisation de l'erreur

Équivalence variance-erreur

La variance v_{u_1} s'exprime comme une somme de carrés :

$$v_{u_1} = \frac{1}{N} \sum_{i=1}^N (u_1^T (x_i - x))^2$$

Raisonnement par le théorème de Pythagore :

- Pour maximiser v_{u_1} , les termes $u_1^T (x_i - x)$ doivent être collectivement maximisés
- Puisque $(x_i - x)$ est fixé, cela équivaut à **minimiser la distance à l'axe de projection** (erreur d'approximation)

Formulation alternative :

$$u_1 = \arg \min_{u^T u = 1} \sum_{i=1}^N \|(x_i - x) - [u^T (x_i - x)]u\|_2^2 \quad \Rightarrow \quad \Sigma u_1 = \lambda_1 u_1$$

Équivalence fondamentale :

Maximiser la variance de projection Minimiser l'erreur d'approximation

Interprétation : Régression quadratique

Une composante principale est une **régression quadratique** sur les données

Interprétation physique

Considérons un système physique X avec des masses $m_i = 1$ aux positions x_i .

Inertie du système :

L'inertie par rapport à un point $a \in \Omega$ est :

$$I_a(X) = \sum_{i=1}^N d^2(a, x_i)$$

Théorème de Huygens :

Si $g = \frac{1}{N} \sum_{i=1}^N x_i$ (centre de gravité), alors :

$$I_a(X) = d^2(a, g) + I_g(X)$$

Cette relation est l'analogie physique de $\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$.

Pour un sous-espace F passant par g :

$$I_F(X) = \sum_{i=1}^N d^2(F, x_i) \quad \text{où} \quad d(F, x_i) = \|x_i - \text{Proj}_F(x_i)\|$$

Conclusion physique : Une composante principale est un **sous-espace d'inertie minimale** par rapport à X

Réduction de Dimension

Structure de l'espace latent

Propriétés de l'espace latent

L'espace latent avec base $\{u_1, \dots, u_D\}$ possède les propriétés suivantes :

Ordre des valeurs propres :

Par construction : $\lambda_1 > \lambda_2 > \dots > \lambda_D$

Variance totale :

$$\lambda \stackrel{\text{def}}{=} \sum_{d=1}^D \lambda_d = \text{Tr}(\Sigma)$$

λ représente la **variance totale** des données.

Décorrélation des features latentes :

$$v_{u_d} = \lambda_d \quad \text{et} \quad u_d^T u_{d'} = 0 \text{ pour } d \neq d'$$

Λ est la **matrice de covariance diagonale** dans l'espace latent.

Coordonnées latentes

La base $\{u_1, \dots, u_D\}$ induit des **coordonnées latentes** y_i pour les données :

$$y_i(d) = \langle u_d, x_i - x \rangle = u_d^T (x_i - x)$$


En forme vectorielle :

$$y_i = U^T (x_i - x)$$

Transformation linéaire PCA

La transformation PCA est **linéaire** et composée de trois étapes :

1. **Centrage** sur x
2. **Rotation** utilisant la matrice U
3. **Mise à l'échelle** (whitening) utilisant $\Lambda^{1/2}$



Modèle sous-jacent

Préservation de la variance :

L'espace latent préserve la variance des données centrées.

Hypothèse de distribution :

$$X_i \sim f_X = \mathcal{N}(x, \Sigma)$$

Limitation importante : La PCA ne sera **pas pertinente** pour des données **non-gaussiennes** (par exemple, des données clusterisées)

Transformation exacte

Point crucial : Jusqu'à présent, la PCA est une **transformation exacte**

$$y_i = U^T(x_i - x) \quad \text{donc} \quad Uy_i = UU^T(x_i - x) = x_i - x$$

Car U est orthogonale : $UU^T = I_D$

À ce stade, un objectif est d'étudier le **spectre** $\{\lambda_1 > \lambda_2 > \dots > \lambda_D\}$ des données pour comprendre comment la variance est distribuée.

Approximation de rang faible et réduction de dimension

Théorème d'Eckart et Young

Théorème fondamental :

Si $\Sigma = U\Lambda U^T$ et pour $K < D$, on définit :

$$\Sigma_K \stackrel{\text{def}}{=} \sum_{d=1}^K \lambda_d u_d u_d^T$$

Alors :

$$\arg \min_{\text{rang}(S)=K} \|\Sigma - S\|_F^2 = \Sigma_K$$

où $\|\cdot\|_F$ est la **norme de Frobenius**.

Erreur d'approximation :

$$\|\Sigma - \Sigma_K\|_F^2 = \sum_{d=K+1}^D \lambda_d$$

Σ_K est la **matrice de rang K la plus proche** de Σ

Troncation pratique

Troncation de U et Λ :

$$\Sigma_K = \begin{pmatrix} | & & | \\ u_1 & \cdots & u_K \\ | & & | \end{pmatrix} \begin{pmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_K \end{pmatrix} \begin{pmatrix} | & & | \\ u_1 & \cdots & u_K \\ | & & | \end{pmatrix}^T = U_K \Lambda_K U_K^T$$

Projection et reconstruction :

- **Projection** (encodage) : $\tilde{y}_i = U_K^T x_i \in \mathbb{R}^K$
- **Reconstruction** (décodage) : $\tilde{x}_i = U_K U_K^T x_i + x$

Important : On passe de D dimensions à K dimensions avec $K < D$

Géométrie et qualité de reconstruction

Contribution relative à la variance

Contribution de chaque dimension :

$$c_d = \frac{\lambda_d}{\sum_k \lambda_k}$$

Cette métrique dépend de la **distribution du spectre** des valeurs propres.

Ratio de projection

Ratio de projection d'une donnée x_i sur un facteur latent :

$$\rho_d(x_i) = \frac{\langle u_d, x_i \rangle^2}{\|x_i\|^2} = \cos^2(\angle(u_d, x_i))$$

Interprétation :

- Plus $\rho_d(x_i)$ est proche de 1, plus x_i se situe sur l'axe u_d
- Ces métriques peuvent être **groupées** (sommées) pour évaluer la qualité par rapport à un sous-espace $\{u_1, u_2, \dots\}$

Normalisation et mise à l'échelle

Problème des échelles différentes :

Chaque dimension originale possède sa propre unité (échelle), estimée par σ_d^2 (variance empirique le long de la dimension d).

La PCA est plus efficace si **toutes les échelles sont similaires**

Solution : Normalisation

On crée la **matrice de mise à l'échelle** :

$$S = \text{diag}[\sigma_1^2, \dots, \sigma_D^2]$$

On définit la **métrique de Mahalanobis** :

$$d_S^2(x, y) = (x - y)^T S^{-1} (x - y)$$

Dans cet espace métrique, la matrice de covariance Σ_S est aussi normalisée (elle devient la **matrice de corrélation**) et utilisée comme base pour la PCA.

Astuce pratique : Normaliser les données avant PCA améliore souvent les résultats

Application pratique de la PCA

Algorithme PCA complet

Étapes d'application :

Soit $X \in \Omega$ l'ensemble de données :

1. **Calculer** la moyenne empirique $x = \frac{1}{N} \sum_{i=1}^N x_i$
2. **Centrer** les données : $x_i \leftarrow (x_i - x)$ et former la matrice centrée X
3. **Calculer** la matrice de covariance : $\Sigma = \frac{1}{N} X X^T$
4. **Décomposer** en valeurs propres : $\Sigma = U \Lambda U^T$

Jusqu'ici : transformation **exacte**

5. **Sélectionner** le nombre de composantes K
6. **Définir** U_K , Λ_K et calculer $\{\tilde{y}_i\}_{i \in [[N]]}$ et/ou $\{\tilde{x}_i\}_{i \in [[N]]}$

Choix du nombre de composantes K

Trois stratégies principales :

Stratégie 1 : Dimension cible

$$K = d$$

où d est la dimension souhaitée, ce qui donne $\tilde{y}_i \in \mathbb{R}^d$

Stratégie 2 : Seuil de variance

Exiger que l'espace latent conserve une proportion τ de la variance totale :

$$\text{Var}(Y) = \tau \cdot \text{Var}(X) \quad \Rightarrow \quad K \text{ tel que } \frac{\sum_{d=1}^K \lambda_d}{\sum_{d=1}^D \lambda_d} \geq \tau$$

Exemple : $\tau = 0.95$ signifie conserver 95% de la variance

Stratégie 3 : Erreur de reconstruction

Entraîner K tel que $L(X) \leq \epsilon$, où par exemple :


$$L(X) = \sum_i \|x_i - \tilde{x}_i\|^2$$

Conseil pratique : Visualiser le spectre des valeurs propres (scree plot) aide à identifier un “coude” naturel

Alternatives et extensions

AutoEncodeurs linéaires (Linear AE)

Structure d'un AutoEncodeur linéaire :



- W_{enc} et W_{dec} : matrices de poids (encoder et decoder)
- $z(x_i) = W_{\text{enc}} x_i$: encodage

- $\tilde{x}_i = W_{\text{dec}} z(x_i)$: décodage

Problème d'optimisation :

$$\theta^* = \arg \min_{W_1, W_2} \sum_{i=1}^N \frac{1}{2} \sum_{d=1}^D (x_i[d] - \tilde{x}_i[d])^2 = \arg \min_{\text{rang}(W)=K} \|X - WZ\|_F^2$$

Relation entre PCA et AutoEncodeur linéaire

Décomposition SVD :

En utilisant le théorème d'Eckart et Young avec $X = U\Psi V^T$, la solution est :

$$W_{\text{dec}} Z = U_K \Psi_K V_K^T$$

Solution optimale :

En posant $W_{\text{dec}} = U_K \Psi_K$, alors :

$$W_{\text{enc}} = \Psi_K^{-1} U_K^T$$

Reconstruction :

$$\tilde{x}_i = U_K U_K^T x_i$$

Relation mathématique :

Pour des données **centrées** :

- **PCA** : $\Sigma = \frac{1}{N} X X^T = U \Lambda U^T$ donc $\tilde{x}_i = U_K U_K^T x_i$
- **AE** : $X = U \Psi V^T$ donc $\Sigma = \frac{1}{N} U \Psi^2 U^T$ et $\tilde{x}_i = U_K U_K^T x_i$

Relation entre valeurs propres :

$$\Lambda = \frac{1}{N} \Psi^2 \quad \Rightarrow \quad \text{PCA}(X) \leftrightarrow \text{AE} \left(\sqrt{\frac{1}{N}} X \right)$$

Conclusion fondamentale : Un AutoEncodeur linéaire effectue une PCA si les données sont **centrées et normalisées**

Note : W_{enc} n'est **pas l'inverse** de W_{dec} si $K < D$

Extensions des AutoEncodeurs

AutoEncodeurs non-linéaires :

En ajoutant des couches cachées avec fonctions d'activation non-linéaires, l'espace latent devient **non-linéaire**.

Variational AutoEncoders (VAE) :

En changeant la fonction de perte (utilisation de l'ELBO - Evidence Lower BOund), on peut imposer de la **parcimonie** (sparsity) dans l'espace latent.

Formulations alternatives de la PCA

PCA Probabiliste

Reformulation avec distribution latente explicite :

- Distribution latente : $\mathbb{P}(z) = \mathcal{N}(0, I_{dK})$
- Modèle conditionnel : $\mathbb{P}(x|z) = \mathcal{N}(Wz + \mu, \sigma^2 I_{dD})$

Avantages :

- Accommodation du **bruit de mesure** (variance σ^2)
- Mode **génératif** : possibilité de générer de nouvelles données
- Estimation des paramètres par **Maximum de Vraisemblance**
- Algorithme **EM** (Expectation-Maximization) pour économiser les calculs
- **Bayesian PCA** : inversion du conditionnel pour trouver K par entraînement

Kernel PCA

Principe :

Utilisation d'un **mapping non-linéaire** $\phi(x_i)$ via une fonction noyau :

$$k(x_i, x_j) = \phi(x_i)^T \phi(x_j)$$

Permet d'effectuer la PCA dans un **espace plus favorable** (possiblement de dimension infinie) sans calculer explicitement ϕ .

Local PCA

Effectue la PCA sur des **voisinages locaux** des données pour considérer uniquement la **dimensionnalité intrinsèque locale**.

Utile pour des données avec structure locale complexe (variétés non-linéaires).

Limitation computationnelle

Complexité : La limitation principale de la PCA classique est la **décomposition en valeurs propres** de Σ en $O(D^3)$

Pour de très grandes dimensions, des méthodes alternatives ou approximatives peuvent être nécessaires.

Synthèse et points clés

Caractéristiques essentielles de la PCA

Nature du modèle :

- La PCA fait partie des **modèles latents linéaires**
- S'applique sur **données centrées**
- Utilise la **variance** comme critère de décomposition

Propriétés mathématiques :

- Décomposition **exacte et complète** en composantes **décorrélées**
- Suppose une **distribution normale** des données
- Peut être formulée comme une **régression**

Applications :

- Stratégie de **décimation justifiée** basée sur l'approximation de rang faible
- Utile pour le **débruitage** via un modèle de bruit gaussien

Équivalences :

- Équivalent à un **AutoEncodeur linéaire**
- Peut recevoir une **formulation stochastique**
- Généralisable au cas **non-linéaire via des noyaux**

Quand utiliser la PCA ?

Adapté pour :

- Données suivant approximativement une distribution gaussienne
- Réduction de dimension avec préservation de variance
- Visualisation de données haute dimension
- Débruitage de données corrompues par bruit gaussien
- Compression de données

Non adapté pour :

- Données fortement clusterisées (non-gaussiennes)
- Données où les relations sont fortement non-linéaires
- Cas où la variance n'est pas un bon critère d'information

Concepts mathématiques à maîtriser

Pour bien comprendre la PCA, il faut maîtriser :

- **Transformation linéaire** et **matrice orthogonale**
 - **Coordonnées** et **rang** matriciel
 - **Moyenne** et **variance**
 - **Projection** orthogonale
 - **Décomposition en valeurs propres** (eigendecomposition)
 - **Trace** d'une matrice
 - **Norme de Frobenius**
 - **Multiplicateurs de Lagrange**
-

Questions d'examen types

Questions conceptuelles

1. Expliquer comment la PCA utilise la variance comme critère
2. Montrer que maximisation de variance minimisation d'erreur
3. Montrer comment la PCA utilise le théorème d'Eckart-Young
4. Peut-on appliquer la PCA sur n'importe quelles données ?
5. Est-il pertinent d'appliquer la PCA sur n'importe quelles données ?

6. Comment appliquer la PCA sur des données clusterisées ?

Questions techniques

Étant donné des données :

- Comment appliquez-vous la PCA ?
- Quelle information la PCA vous fournit-elle ?
- Comment reconstruire les données avec $K < D$ composantes ?
- Comment sélectionner les composantes à conserver ?

Démonstrations mathématiques

- Montrer que la PCA est équivalente à un AutoEncodeur linéaire
- Démontrer l'équivalence variance maximale / erreur minimale
- Prouver que les composantes principales sont les vecteurs propres de Σ