

Table of contents

1. Expliquez comment la PCA utilise la variance comme critère	1
2. Montrez que la maximisation de la variance est équivalente à la minimisation de l'erreur	2
3. Montrez comment la PCA utilise le théorème d'Eckart-Young	3
4. Étant donné certaines données, comment appliquez-vous la PCA ?	3
5. Quelles informations cela vous fournit-il ?	4
6. Comment reconstruire les données avec $K < D$ composantes ?	5
7. Comment sélectionner les composantes à conserver ?	6
8. Pouvez-vous appliquer la PCA sur n'importe quelle donnée ?	7
9. Est-il pertinent d'appliquer la PCA sur n'importe quelle donnée ?	8
10. Comment puis-je appliquer la PCA sur des données clusterisées ?	8
11. Montrez que la PCA est équivalente à un autoencodeur linéaire	9

Voici la traduction en français du texte fourni, en conservant la forme et le formatage d'origine (y compris les équations LaTeX).

1. Expliquez comment la PCA utilise la variance comme critère

Intuition :

La PCA recherche les directions (composantes) dans les données le long desquelles les données varient le plus. En maximisant la variance des données projetées, la PCA trouve les axes les plus informatifs, en supposant que les directions avec une variance plus élevée portent plus d'informations sur la structure des données.

Réponse détaillée :

Formellement, étant donné un jeu de données centré $X = \{x_1, \dots, x_N\}$ (avec une moyenne $\bar{x} = 0$ pour simplifier), la PCA définit la première composante principale u_1 comme le vecteur unitaire qui maximise la variance des projections des données sur celle-ci. La variance des projections est donnée par :

$$v_{u_1} = \frac{1}{N} \sum_{i=1}^N (u_1^T x_i)^2 = u_1^T \Sigma u_1,$$

où $\Sigma = \frac{1}{N} \sum_{i=1}^N x_i x_i^T$ est la matrice de covariance des données. Le problème d'optimisation est :

$$u_1 = \arg \max_{u: \|u\|=1} u^T \Sigma u.$$

En utilisant les multiplicateurs de Lagrange, nous définissons le lagrangien $J(u) = u^T \Sigma u + \lambda(1 - u^T u)$. En prenant la dérivée par rapport à u et en la fixant à zéro, on obtient :

$$\Sigma u = \lambda u.$$

Ainsi, u_1 est le vecteur propre de Σ correspondant à la plus grande valeur propre λ_1 . Les composantes suivantes $u_2, u_3, \dots, u_D$ sont choisies de manière similaire, mais chacune est contrainte à être orthogonale aux précédentes. Elles correspondent aux vecteurs propres de Σ dans l'ordre décroissant des valeurs propres. Les valeurs propres λ_d représentent la variance capturée par chaque composante. Par conséquent, la PCA utilise la variance comme critère en sélectionnant les directions orthogonales qui maximisent la variance projetée, qui sont exactement les vecteurs propres de la matrice de covariance.

2. Montrez que la maximisation de la variance est équivalente à la minimisation de l'erreur

Intuition :

Maximiser la variance des données projetées est équivalent à minimiser l'erreur de reconstruction lors de l'approximation des données originales par leur projection sur un sous-espace de dimension inférieure. En d'autres termes, la meilleure représentation en faible dimension est celle qui retient le plus de variance, ce qui minimise simultanément l'erreur d'approximation.

Réponse détaillée :

Considérons la projection d'un point de données centré x_i sur un vecteur unitaire u . La projection est $(u^T x_i)u$, et l'erreur de reconstruction (distance au carré) est $\|x_i - (u^T x_i)u\|^2$. L'erreur de reconstruction totale sur tous les points de données lors de l'utilisation d'un ensemble de vecteurs orthonormaux $\{u_1, \dots, u_K\}$ est :

$$\sum_{i=1}^N \left\| x_i - \sum_{d=1}^K (u_d^T x_i) u_d \right\|^2.$$

Nous pouvons montrer que minimiser cette erreur est équivalent à maximiser la variance capturée par les projections. Notez que la variance totale dans les données est $\sum_{i=1}^N \|x_i\|^2$, qui est constante. Pour une seule composante u , nous avons :

$$\sum_i \|x_i\|^2 = \sum_i \|x_i - (u^T x_i)u\|^2 + \sum_i (u^T x_i)^2.$$

Ainsi, minimiser l'erreur de reconstruction $\sum_i \|x_i - (u^T x_i)u\|^2$ est équivalent à maximiser la variance projetée $\sum_i (u^T x_i)^2$. Cette équivalence s'étend à plusieurs composantes car les composantes sont orthogonales. Par conséquent, les composantes principales qui maximisent la variance minimisent également l'erreur de reconstruction.

3. Montrez comment la PCA utilise le théorème d'Eckart-Young

Intuition :

Le théorème d'Eckart-Young stipule que la meilleure approximation de rang faible d'une matrice (en termes de norme de Frobenius) est donnée par sa décomposition en valeurs singulières (SVD) tronquée. La PCA effectue essentiellement une approximation de rang faible de la matrice de données, et le théorème garantit que les composantes principales donnent l'approximation optimale.

Réponse détaillée :

Soit X la matrice de données centrée de taille $D \times N$. La matrice de covariance est $\Sigma = \frac{1}{N}XX^T$. La PCA calcule la décomposition en valeurs propres $\Sigma = U\Lambda U^T$, où U est orthogonale et Λ est diagonale avec les valeurs propres $\lambda_1 \geq \dots \geq \lambda_D$. Le théorème d'Eckart-Young s'applique à la SVD de X . Écrivons la SVD comme $X = U\Psi V^T$, où U et V sont orthogonales et Ψ est diagonale avec les valeurs singulières $\psi_1 \geq \dots \geq \psi_D$. Alors $\Sigma = \frac{1}{N}U\Psi^2U^T$, donc les valeurs propres sont $\lambda_d = \psi_d^2/N$. Pour un $K < D$ donné, la meilleure approximation de rang K de X (en norme de Frobenius) est :

$$X_K = U_K\Psi_K V_K^T,$$

où U_K et V_K contiennent les K premières colonnes de U et V , et Ψ_K est la sous-matrice $K \times K$ en haut à gauche de Ψ . Les données projetées dans la PCA sont $Y = U_K^T X$, ce qui correspond aux coordonnées latentes. La reconstruction est $\tilde{X} = U_K Y = U_K U_K^T X$. Notez que $U_K U_K^T X$ est exactement la projection de X sur le sous-espace engendré par les K premières composantes principales. Le théorème d'Eckart-Young garantit que cette reconstruction minimise l'erreur de Frobenius $\|X - \tilde{X}\|_F^2$ parmi toutes les approximations de rang K . Ainsi, la PCA utilise le théorème d'Eckart-Young pour fournir une approximation de rang faible optimale des données.

4. Étant donné certaines données, comment appliquez-vous la PCA ?

Intuition :

L'application de la PCA implique une séquence d'étapes : centrer les données, calculer la matrice de covariance, trouver ses vecteurs propres et valeurs propres, puis utiliser ceux-ci pour transformer les données en un nouveau système de coordonnées défini par les composantes principales.

Réponse détaillée :

Étant donné un jeu de données $X = \{x_1, \dots, x_N\}$ avec $x_i \in \mathbb{R}^D$, les étapes pour appliquer la PCA sont :

1. **Centrer les données :** Calculer la moyenne empirique $\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$, et la soustraire de chaque point de données : $x_i^{(c)} = x_i - \bar{x}$.
2. **Former la matrice de données centrée :** Soit X_c la matrice $D \times N$ dont les colonnes sont les vecteurs centrés $x_i^{(c)}$.
3. **Calculer la matrice de covariance :** Calculer la matrice de covariance $D \times D$ $\Sigma = \frac{1}{N} X_c X_c^T$.
4. **Décomposition en valeurs propres :** Calculer les vecteurs propres et valeurs propres de Σ . C'est-à-dire, résoudre $\Sigma u = \lambda u$. Les vecteurs propres $u_1, \dots, u_D$ sont les composantes principales, ordonnées par valeurs propres décroissantes $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_D$.
5. **Sélectionner le nombre de composantes :** Choisir K (avec $1 \leq K \leq D$) basé sur un critère (par exemple, variance retenue, graphique des éboulis, etc.). Soit U_K la matrice dont les colonnes sont les K premiers vecteurs propres.
6. **Projeter les données :** Les données transformées dans l'espace de dimension inférieure sont $y_i = U_K^T x_i^{(c)}$ pour chaque i , donnant une représentation de dimension K .

Optionnellement, on peut blanchir les données en mettant à l'échelle chaque composante par $1/\sqrt{\lambda_d}$ pour avoir une variance unitaire.

5. Quelles informations cela vous fournit-il ?

Intuition :

La PCA fournit des informations sur les directions de plus grande variance dans les données, la quantité de variance capturée par chaque direction, et une représentation en faible dimension qui préserve autant de variance que possible. Elle révèle également les corrélations entre les caractéristiques originales et permet la réduction de dimension, la réduction du bruit et la visualisation des données.

Réponse détaillée :

La PCA fournit plusieurs informations :

- **Composantes principales :** Les vecteurs propres $u_1, \dots, u_D$ de la matrice de covariance. Ce sont les directions orthogonales dans l'espace original le long desquelles les données varient le plus.
- **Variances expliquées :** Les valeurs propres $\lambda_1, \dots, \lambda_D$ indiquent la quantité de variance capturée par chaque composante principale. La variance totale est $\sum_{d=1}^D \lambda_d$.

- **Proportions de variance :** La proportion de variance totale expliquée par la d -ième composante est $\lambda_d / \sum_{j=1}^D \lambda_j$. Cela aide à évaluer l'importance de chaque composante.
 - **Représentation en faible dimension :** Les données projetées y_i dans l'espace latent de dimension K (avec $K < D$) fournissent une version compressée des données qui retient la majeure partie de la variance.
 - **Erreur de reconstruction :** Lors de l'utilisation de K composantes, l'erreur de reconstruction (erreur quadratique moyenne) est donnée par la somme des valeurs propres des composantes omises : $\sum_{d=K+1}^D \lambda_d$.
 - **Informations sur la structure des données :** En examinant les composantes principales, on peut identifier quelles caractéristiques originales contribuent le plus à chaque composante (via les loadings). Cela peut révéler des patterns cachés ou des corrélations entre les caractéristiques.
 - **Caractéristiques décorréélées :** Les caractéristiques transformées (composantes principales) sont non corrélées, ce qui peut être utile pour l'analyse en aval.
-

6. Comment reconstruire les données avec $K < D$ composantes ?

Intuition :

La reconstruction est effectuée en projetant la représentation de dimension K réduite vers l'espace de dimension D original en utilisant les K composantes principales. Cela donne une approximation des données originales qui perd l'information correspondant aux composantes supprimées.

Réponse détaillée :

Après avoir effectué la PCA et obtenu les K premières composantes principales (colonnes de U_K), nous avons la représentation latente $y_i = U_K^T(x_i - \bar{x})$ pour chaque point de données. Pour reconstruire une approximation $\tilde{x}_i$ des données (centrées) originales, nous calculons :

$$\tilde{x}_i^{(c)} = U_K y_i = U_K U_K^T (x_i - \bar{x}).$$

Ensuite, nous rajoutons la moyenne pour obtenir la reconstruction dans le système de coordonnées original :

$$\tilde{x}_i = \tilde{x}_i^{(c)} + \bar{x} = \bar{x} + U_K U_K^T (x_i - \bar{x}).$$

Notez que $U_K U_K^T$ est une matrice de projection sur le sous-espace engendré par les K premières composantes principales. L'erreur de reconstruction est la différence entre x_i et $\tilde{x}_i$, et sa norme quadratique moyenne sur tous les points est égale à la somme des valeurs propres des composantes omises : $\sum_{d=K+1}^D \lambda_d$.

7. Comment sélectionner les composantes à conserver ?

Intuition :

Le but est de choisir un nombre de composantes K qui équilibre la réduction de dimension et la rétention d'informations importantes. Les méthodes courantes incluent fixer un seuil sur la variance expliquée cumulative, chercher un “coude” dans le graphique des éboulis, ou utiliser des critères basés sur l'erreur de reconstruction.

Réponse détaillée :

Plusieurs stratégies existent :

- **Seuil de variance** : Choisir K tel que la proportion de variance totale expliquée par les K premières composantes dépasse un seuil prédéfini τ (par exemple, 0.95 ou 95%). C'est-à-dire, trouver le plus petit K satisfaisant :

$$\frac{\sum_{d=1}^K \lambda_d}{\sum_{d=1}^D \lambda_d} \geq \tau.$$

- **Graphique des éboulis (scree plot)** : Tracer les valeurs propres dans l'ordre décroissant et chercher un point de “coude” où les valeurs propres commencent à se stabiliser. Les composantes avant le coude sont conservées.
- **Critère de Kaiser** : Dans certains domaines (comme l'analyse factorielle), conserver les composantes avec des valeurs propres supérieures à 1 (si les données sont standardisées). Cependant, cela est moins courant pour la PCA.
- **Seuil d'erreur de reconstruction** : Choisir K tel que l'erreur de reconstruction (ou sa moyenne) soit inférieure à une tolérance ϵ . C'est-à-dire, s'assurer que $\sum_{d=K+1}^D \lambda_d \leq \epsilon$.
- **Validation croisée** : Utiliser la PCA dans un cadre de validation croisée pour choisir K qui optimise une tâche en aval (par exemple, la précision de classification) ou minimise l'erreur de reconstruction sur un ensemble de validation.
- **Critères informationnels** : Tels que la longueur de description minimale (MDL) ou le critère d'information bayésien (BIC).

En pratique, le seuil de variance et le graphique des éboulis sont les plus courants.

8. Pouvez-vous appliquer la PCA sur n'importe quelle donnée ?

Intuition :

La PCA est une procédure mathématique qui peut être appliquée à n'importe quel jeu de données numériques, tant que nous pouvons calculer la matrice de covariance et sa décomposition en valeurs propres. Cependant, la pertinence et l'interprétabilité de la PCA dépendent des caractéristiques des données.

Réponse détaillée :

Techniquement, la PCA peut être appliquée à tout jeu de données représenté comme une matrice de valeurs réelles. Les étapes (centrage, calcul de covariance, décomposition en valeurs propres) sont bien définies pour de telles données. Cependant, il y a des considérations pratiques :

- **Type de données :** La PCA est conçue pour les données numériques continues. Elle peut ne pas être adaptée aux données catégorielles ou aux données avec des valeurs manquantes sans prétraitement approprié.
- **Sensibilité à l'échelle :** La PCA est sensible aux échelles des variables. Si les variables sont sur des échelles différentes, celles avec des variances plus grandes domineront les premières composantes. Par conséquent, il est courant de standardiser les données (soustraire la moyenne et diviser par l'écart-type) pour donner un poids égal à chaque variable.
- **Hypothèse de linéarité :** La PCA suppose que les composantes principales sont des combinaisons linéaires des caractéristiques originales. Si les données ont une structure non linéaire, la PCA peut ne pas la capturer efficacement.
- **Hypothèses distributionnelles :** Bien que non strictement requises, la PCA est la plus interprétable lorsque les données suivent une distribution gaussienne multivariée. Pour des données non gaussiennes, les composantes peuvent ne pas représenter les directions d'information maximale.
- **Corrélations :** La PCA fonctionne mieux lorsqu'il existe des corrélations entre les variables qui peuvent être exploitées pour la réduction de dimension. Si les variables sont non corrélées, la PCA ne sera pas efficace.

Ainsi, bien que la PCA puisse être calculée sur n'importe quel jeu de données numériques, son utilité dépend de la satisfaction de certaines conditions par les données.

9. Est-il pertinent d'appliquer la PCA sur n'importe quelle donnée ?

Intuition :

Non, la PCA n'est pas toujours pertinente. Sa pertinence dépend des objectifs et de la nature des données. Par exemple, si les données ont une structure non linéaire ou si les hypothèses de la PCA sont violées, d'autres méthodes peuvent être plus appropriées.

Réponse détaillée :

La PCA est pertinente lorsque :

- Le but est la réduction de dimension, la réduction du bruit ou la visualisation.
- Les données ont des corrélations linéaires qui peuvent être capturées par des transformations orthogonales.
- Les données sont approximativement gaussiennes, ou au moins symétriques et unimodales.
- La variance dans les données est une mesure significative d'information.

La PCA n'est pas pertinente lorsque :

- Les données ont une structure non linéaire (envisager la PCA à noyau ou l'apprentissage de variétés).
- Les données sont clusterisées ou multi-modales ; la PCA peut aplatir les clusters car elle se concentre sur la variance globale.
- Les données ont des valeurs aberrantes, car la PCA y est sensible (des variantes robustes de la PCA existent).
- Le but est de préserver les voisinages locaux (comme dans t-SNE).
- Les données sont discrètes ou catégorielles (envisager l'analyse des correspondances ou d'autres techniques).
- Les variables sont non corrélées ; la PCA ne réduirait pas efficacement la dimension.

Par conséquent, on devrait évaluer la structure des données et les objectifs d'analyse avant de décider d'utiliser la PCA.

10. Comment puis-je appliquer la PCA sur des données clusterisées ?

Intuition :

L'application de la PCA à des données clusterisées est techniquement possible, mais elle peut ne pas préserver la structure de cluster car la PCA recherche les directions de variance globale, qui pourraient ne pas s'aligner avec la séparation entre les clusters. Une interprétation prudente et possiblement des méthodes alternatives sont nécessaires.

Réponse détaillée :

Lorsque les données sont clusterisées, la PCA peut toujours être appliquée de la même manière que décrite ci-dessus. Cependant, notez les points suivants :

- **Structure globale vs locale :** La PCA capture la structure de variance globale. Si les clusters sont bien séparés, les premières composantes principales pourraient s'aligner avec la direction de séparation entre les clusters, mais ce n'est pas garanti. Souvent, la première composante s'aligne avec l'étalement global de tous les clusters combinés, ce qui peut ne pas être utile pour distinguer les clusters.
- **Problème de centrage :** La PCA centre les données globalement. Si les clusters ont des moyennes différentes, la moyenne globale peut se situer entre les clusters, et le centrage peut obscurcir la structure de cluster.
- **Recommandations :**
 - **Visualisation :** La PCA peut être utilisée pour visualiser les données clusterisées en 2D ou 3D, mais soyez conscient que les clusters peuvent se chevaucher dans l'espace des composantes principales.
 - **Standardisation :** Si les caractéristiques ont des échelles différentes, standardisez-les pour éviter la domination par une caractéristique.
 - **Envisager des méthodes prenant en compte les clusters :** Des méthodes comme l'Analyse Discriminante Linéaire (LDA) utilisent l'information des labels pour trouver les directions qui séparent les clusters. Pour le clustering non supervisé, on pourrait d'abord clusteriser les données puis effectuer la PCA dans chaque cluster pour comprendre la structure locale.
 - **PCA à noyau :** Si les clusters sont séparables non linéairement, la PCA à noyau pourrait capturer la structure mieux.

En résumé, la PCA peut être appliquée à des données clusterisées, mais elle peut ne pas préserver ou mettre en évidence les frontières de clusters. Elle est souvent utilisée comme étape de prétraitement pour le clustering (pour réduire le bruit) plutôt que pour visualiser les clusters.

11. Montrez que la PCA est équivalente à un autoencodeur linéaire

Intuition :

Un autoencodeur (AE) linéaire avec une couche goulot d'étranglement de taille K et des fonctions d'activation linéaires apprend à reconstruire son entrée en minimisant l'erreur quadratique moyenne. Les poids optimaux d'un tel autoencodeur produisent la même transformation que

la PCA : l'encodeur projette sur le sous-espace de dimension K engendré par les K premières composantes principales, et le décodeur reconstruit à partir de cette projection.

Réponse détaillée :

Considérons un autoencodeur linéaire avec une couche cachée de K unités, pas de biais, et des fonctions d'activation linéaires. Soit la matrice de poids de l'encodeur $W_{\text{enc}} \in \mathbb{R}^{K \times D}$ et la matrice de poids du décodeur $W_{\text{dec}} \in \mathbb{R}^{D \times K}$. L'autoencodeur map une entrée $x \in \mathbb{R}^D$ vers un code latent $z = W_{\text{enc}}x$ puis reconstruit $\tilde{x} = W_{\text{dec}}z = W_{\text{dec}}W_{\text{enc}}x$. Le but est de minimiser l'erreur de reconstruction sur un jeu de données centré X (moyenne soustraite) :

$$\min_{W_{\text{enc}}, W_{\text{dec}}} \sum_{i=1}^N \|x_i - W_{\text{dec}}W_{\text{enc}}x_i\|^2.$$

Ceci est équivalent à trouver une matrice de rang K $A = W_{\text{dec}}W_{\text{enc}}$ qui approche le mieux l'identité sur les données, c'est-à-dire minimisant $\|X - AX\|_F^2$. Par le théorème d'Eckart-Young, la matrice A optimale est la projection sur le sous-espace engendré par les K premières composantes principales. Spécifiquement, si U_K contient les K premiers vecteurs propres de la matrice de covariance $\Sigma = \frac{1}{N}XX^T$, alors la solution optimale est $A = U_KU_K^T$. De plus, un choix possible pour les poids est $W_{\text{enc}} = U_K^T$ et $W_{\text{dec}} = U_K$. Alors l'autoencodeur effectue exactement la projection et la reconstruction de la PCA :

- Encodage : $z_i = U_K^T x_i$ (identique à la projection PCA).
- Décodage : $\tilde{x}_i = U_K z_i = U_K U_K^T x_i$ (identique à la reconstruction PCA).

Notez que les poids ne sont pas uniques (par exemple, toute transformation linéaire inversible de l'espace latent peut être compensée par son inverse dans le décodeur). Cependant, le sous-espace engendré par les colonnes de W_{dec} est unique et égal au sous-espace engendré par les K premières composantes principales. Ainsi, un autoencodeur linéaire entraîné à minimiser l'erreur quadratique moyenne sur des données centrées apprend la même représentation que la PCA.