

Table of contents

Cours détaillé	2
Introduction et Motivation	2
Contexte général	2
Apprentissage supervisé : Fondements	2
Définition générale	2
Exemples de learners	3
Principe de la LDA : Direction discriminante	3
Problématique	3
Direction discriminante avec 2 classes	3
Critère inter-classes (Between-class)	4
Principe de séparation maximale	4
Formulation mathématique	4
Critère intra-classe (Within-class)	5
Principe de variance minimale	5
Variance intra-classe	5
Critère de Fisher	5
Généralisation à M classes	6
Critère inter-classes généralisé	6
Critère intra-classe généralisé	6
Critère de Fisher combiné	7
Combinaison des deux critères	7
Résolution par dérivation	7
Sous-espaces discriminants	7
Dimensions discriminantes multiples	7
Limitation dimensionnelle	8
Cas particulier : $M = 2$	8
Exemple pratique : Reconnaissance de caractères	8
Description du dataset	8
Résultat de la projection LDA	9
Inférence et prise de décision	9
Modélisation conditionnelle	9
Approche probabiliste	9
Approximation gaussienne	10
Modèle gaussien par classe	10
Maximum de vraisemblance	10
Règle de décision	10
Optimalité de la LDA	11
Conditions d'optimalité	11
Limitations	11

Synthèse des concepts clés	11
Caractéristiques essentielles de la LDA	11
Comparaison LDA vs PCA	12
Différences fondamentales	12
Complémentarité	12
Questions d'examen types	13
Questions conceptuelles	13
Questions techniques	13
Démonstrations mathématiques	14
Concepts mathématiques à maîtriser	14

Cours détaillé

Introduction et Motivation

Contexte général

La **LDA** (Analyse Discriminante Linéaire) est une méthode d'**analyse latente supervisée** qui permet de trouver les facteurs latents optimaux pour la discrimination entre classes.

Objectifs de la LDA :

- Introduire une définition **supervisée** des facteurs latents
- Proposer une **modélisation conditionnelle** des données
- Effectuer la **classification** d'items non étiquetés

Attention : Cette LDA ne doit pas être confondue avec **Latent Dirichlet Allocation** (utilisée en NLP)

Apprentissage supervisé : Fondements

Définition générale

Soit des données $X \subset \Omega \subseteq \mathbb{R}^D$ associées à des catégories (étiquettes de classe) $Y = [[M]] \subset \mathbb{N}$.

L'apprentissage supervisé consiste à trouver (apprendre) les paramètres θ d'un apprenant (fonction) ϕ_θ de manière à minimiser la perte $L_{X \times Y}(\theta)$ encourue lors de la prédiction des étiquettes de classe.

Fonction de prédiction :

$$\begin{aligned}\phi_\theta : \Omega &\rightarrow Y \\ x_i &\mapsto \phi_\theta(x_i) = \tilde{y}_i\end{aligned}$$

Exemples de learners

Régression logistique :

ϕ_θ est une régression logistique avec paramètres θ

Réseau de neurones :

ϕ_θ est un réseau de neurones avec poids θ

Fonction de perte exemple :

$$L_{X \times Y}(\theta) = \sum_X \|\phi_\theta(x_i) - y_i\|^2$$

Principe de la LDA : Direction discriminante


Problématique

Question fondamentale : Étant donné des données multivariées X associées à des étiquettes Y , on cherche un modèle pour ces données.

Direction discriminante avec 2 classes

On cherche une **direction** $a \in \mathbb{R}^D$ telle que la projection des données sur cette direction $\hat{X} = \text{Proj}_a(X)$ montre des **propriétés optimales pour la discrimination** entre classes.

Visualisation géométrique :



Principe clé : Trouver la direction a qui sépare au mieux les classes après projection

Critère inter-classes (Between-class)

Principe de séparation maximale

Si les projections des classes sont **bien séparées**, alors elles peuvent être facilement discriminées.

Objectif : Chercher la direction a où la discrimination inter-classes est **maximale**

Formulation mathématique

Intuition géométrique :

La direction a doit être **colinéaire** à la ligne $\mu_1 - \mu_2$ qui relie les centres de masse des classes, car :

$$\|\hat{\mu}_1 - \hat{\mu}_2\|^2 = \left\| \frac{a^T \mu_1}{\|a\|^2} a - \frac{a^T \mu_2}{\|a\|^2} a \right\|^2 = \frac{1}{\|a\|^2} (a^T (\mu_1 - \mu_2))^2$$

Cette expression est **maximale** quand $a = \lambda(\mu_1 - \mu_2)$

Point important : Les données originales ($x_i \in X$) ne changent pas. Seules les **données projetées** ($\hat{x}_i \in \hat{X}$) et les calculs subséquents changent lorsqu'on fait évoluer a .

Propriété : Le centre de masse des données projetées est la projection du centre de masse des données originales

Critère intra-classe (Within-class)

Principe de variance minimale

On cherche également à **minimiser la variance** de chaque classe projetée individuellement.

Objectif : Réduire la dispersion au sein de chaque classe après projection

Variance intra-classe

Pour chaque classe k , la variance normalisée de la projection est :

$$\hat{\sigma}_k^2 = \frac{1}{N_k} \sum_{y_i=k} (\hat{x}_i - \hat{\mu}_k)^T (\hat{x}_i - \hat{\mu}_k)$$

Critère de Fisher

Le **critère de Fisher** maximise le ratio :

$$\arg \max_a \frac{\|\hat{\mu}_1 - \hat{\mu}_2\|^2}{\hat{\sigma}_1^2 + \hat{\sigma}_2^2}$$

Interprétation :

- **Numérateur :** Distance entre les moyennes projetées (inter-classe) $\rightarrow$ à **maximiser**
 - **Dénominateur :** Somme des variances intra-classes $\rightarrow$ à **minimiser**
-

Généralisation à M classes

Critère inter-classes généralisé

Définitions :

Soit $B = [\mu_1 - \mu, \dots, \mu_M - \mu]$ la matrice des centres de classes centrés, où :

- $\mu = \frac{1}{N} \sum_i x_i$ est la moyenne globale
- $N = \sum_k N_k$ est le nombre total de points

Matrice de covariance inter-classes :

$$\Sigma_b = \frac{1}{M} B B^T$$

Critère à maximiser :

$$\frac{1}{M} \sum_k (\hat{\mu}_k - \hat{\mu})^T (\hat{\mu}_k - \hat{\mu}) = \frac{1}{\|a\|^2} a^T \Sigma_b a$$

Critère intra-classe généralisé

Définitions :

Soit $A_k = [x_1 - \mu_k, \dots, x_{N_k} - \mu_k]$ avec $y_i = k$, la matrice des données centrées pour la classe k .

Matrice de covariance intra-classe :

- Pour la classe k : $\frac{1}{N_k} A_k A_k^T$
- **Somme des matrices intra-classes :** $\Sigma_w = \sum_k \frac{1}{N_k} A_k A_k^T$

Critère à minimiser :

$$\sum_k \frac{1}{N_k} \sum_{y_i=k} (\hat{x}_i - \hat{\mu}_k)^T (\hat{x}_i - \hat{\mu}_k) = \frac{1}{a^T a} a^T \Sigma_w a$$

Développement :

$$\sum_k \frac{1}{N_k} \sum_{y_i=k} \left[\frac{a^T (x_i - \mu_k)}{\|a\|^2} a \right]^T \left[\frac{a^T (x_i - \mu_k)}{\|a\|^2} a \right] = \frac{1}{a^T a} a^T \Sigma_w a$$

Critère de Fisher combiné

Combinaison des deux critères

Le **critère de Fisher généralisé** combine les critères inter-classe et intra-classe :

$$\arg \max_a L(a) = \arg \max_a \frac{a^T \Sigma_b a}{a^T \Sigma_w a}$$

Résolution par dérivation

Pour trouver le maximum, on calcule la dérivée :

$$\frac{\partial L(a)}{\partial a} = \frac{\Sigma_b a (a^T \Sigma_w a) - \Sigma_w a (a^T \Sigma_b a)}{(a^T \Sigma_w a)^2} = 0$$

Équation résultante :

$$\Sigma_b a = L(a) \Sigma_w a$$

Solution : a est solution du **système aux valeurs propres généralisé**

La direction optimale a est le **premier vecteur propre** de $\Sigma_w^{-1} \Sigma_b$ (avec valeur propre $\lambda_1 = L(a)$)

Sous-espaces discriminants

Dimensions discriminantes multiples

Vecteurs propres ordonnés :

Les vecteurs propres correspondant aux **plus grandes valeurs propres** λ_i sont les dimensions les plus discriminatives :

$$a_1, a_2, \dots, a_p \quad \text{avec} \quad \lambda_1 > \lambda_2 > \dots > \lambda_p$$

Limitation dimensionnelle

Propriété fondamentale : M classes peuvent être discriminées dans un sous-espace de dimension **au plus** $(M - 1)$.

Conséquence : Il y a seulement $M - 1$ valeurs propres **non nulles**

Explication : Avec M classes, on a M centres de classe. Une fois centrés globalement, ces centres sont contraints à vivre dans un espace de dimension $M - 1$.

Cas particulier : $M = 2$

Pour deux classes, on peut montrer que :

$$BB^T = (\mu_1 - \mu)(\mu_1 - \mu)^T + (\mu_2 - \mu)(\mu_2 - \mu)^T \propto (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T$$

Implications :

- $BB^T a$ est un vecteur selon la direction $(\mu_1 - \mu_2)$
 - La solution est $a = \lambda \Sigma_w^{-1}(\mu_1 - \mu_2)$
-

Exemple pratique : Reconnaissance de caractères

Description du dataset

Dataset MNIST partiel :

- 7291 images de taille 16×16 (8 bits)
- Chiffres de 0 à 9
- Représentation : $\{x_i, y_i\}$ avec $x_i \in \mathbb{R}^{256}$ et $y_i \in [[10]]$, $i \in [[7291]]$

Résultat de la projection LDA

La LDA trouve le **sous-espace optimal** pour séparer **linéairement** les données selon leurs étiquettes y_i .

Avantages de la projection LDA :

- Réduction de dimension (de 256 à quelques dimensions)
 - Visualisation en 2D ou 3D possible
 - Séparation des classes maximisée
-

Inférence et prise de décision

Modélisation conditionnelle

Problème de classification :

Pour une nouvelle donnée j :

- x_j est **connu**
- y_j est **inconnu**

Question : À quelle classe k le point j appartient-il ?

Approche probabiliste

Déclaration d'une variable aléatoire catégorielle :

On déclare la variable aléatoire de classe C

Prédiction par la règle de Bayes :

$$\mathbb{P}(C = k|x_j) = \frac{\mathbb{P}(x_j|C = k)\mathbb{P}(C = k)}{\mathbb{P}(x_j)}$$

Composantes :

- $\mathbb{P}(x_j|C = k)$: **vraisemblance** (likelihood)
 - $\mathbb{P}(C = k)$: **prior** (probabilité a priori)
 - $\mathbb{P}(x_j)$: **évidence** (normalisation)
-

Approximation gaussienne

Modèle gaussien par classe

Hypothèse de distribution :

Chaque classe est modélisée par une distribution normale :

$$\mathbb{P}(x|C = k) \sim \mathcal{N}(\mu_k, \Sigma_k)$$

Choix du prior :

Prior uniforme : $\mathbb{P}(C = k) = \frac{1}{M}$ (toutes les classes équiprobables)

Simplification :

L'évidence $\mathbb{P}(x_j)$ est **ignorée** car constante pour toutes les classes (normalisation)

Maximum de vraisemblance

Approximation :

$$\mathbb{P}(x|C = k) \propto \exp(-(x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k))$$

Règle de décision

Classification par maximum a posteriori :

$$\delta(x) = \arg \max_k \mathbb{P}(x|C = k)$$

Interprétation : On assigne x à la classe k qui maximise la vraisemblance (ou la probabilité a posteriori)

Optimalité de la LDA

Conditions d'optimalité

La LDA est **optimale** lorsque les M classes suivent chacune une **distribution gaussienne**

Justification :

Les critères de discrimination sont basés sur les matrices de covariance Σ_w et Σ_b , qui caractérisent pleinement les distributions gaussiennes.

Limitations

Linear Discriminant Analysis : ne prend **pas en compte** les relations **non-linéaires** entre variables

Discrimination linéaire uniquement

Alternative : Pour des relations non-linéaires, utiliser des méthodes de **classification non-linéaire** :

- Kernel LDA
 - Quadratic Discriminant Analysis (QDA)
 - Support Vector Machines (SVM)
 - Réseaux de neurones
-

Synthèse des concepts clés

Caractéristiques essentielles de la LDA

Nature de la méthode :

- La LDA est une technique **supervisée**
- Utilise les **étiquettes de classe** pour guider la réduction de dimension

Objectif :

- Trouver les **facteurs latents linéaires optimaux** qui expliquent la discrimination linéaire entre classes

Critère de Fisher :

- Combine la dispersion **intra-classe** (within-scatter) et **inter-classe** (between-scatter)

- Maximise le ratio $\frac{a^T \Sigma_b a}{a^T \Sigma_w a}$

Résolution :

- Résolu en trouvant les valeurs propres de la matrice $\Sigma_w^{-1} \Sigma_b$
- Les vecteurs propres forment les axes discriminants

Applications :

- **Visualisation** des données en tenant compte des étiquettes
- **Réduction de dimension** supervisée
- **Classification** via modélisation conditionnelle (chaque classe suit une distribution normale)

Comparaison LDA vs PCA

Différences fondamentales

PCA (non supervisée) :

- Maximise la **variance** globale
- Ignore les étiquettes de classe
- Trouve les directions de variance maximale
- Basée sur Σ (covariance totale)

LDA (supervisée) :

- Maximise la **séparation entre classes**
- Utilise les étiquettes de classe
- Trouve les directions discriminantes
- Basée sur $\Sigma_w^{-1} \Sigma_b$ (ratio de covariances)

Complémentarité

En pratique : On peut combiner PCA et LDA

1. PCA pour réduction initiale de dimension (éliminer le bruit)
 2. LDA pour maximiser la discrimination
-

Questions d'examen types

Questions conceptuelles

Setup de l'apprentissage supervisé :

- Expliquer le contexte de l'apprentissage supervisé
- Différence entre supervisé et non-supervisé

Nature linéaire de la LDA :

- Pourquoi la LDA est-elle une méthode linéaire ?
- Quelles sont ses limitations ?

Direction discriminante :

- Qu'est-ce qui caractérise une direction discriminante ?
- Que représente le vecteur a ?

Questions techniques

Critères de Fisher :

- Qu'est-ce que le critère de Fisher ?
- Comment combine-t-il les critères inter et intra-classes ?

Critère inter-classes (between) :

- Principe du critère inter-classes
- Comment calculer la matrice de covariance inter-classes Σ_b ?

Critère intra-classe (within) :

- Principe du critère intra-classe
- Comment calculer la matrice de covariance intra-classes Σ_w ?

Démonstrations mathématiques

Dérivation du maximum :

- Justifier et expliquer la dérivation du maximum pour a
- Montrer que a satisfait $\Sigma_b a = \lambda \Sigma_w a$

Situation multidimensionnelle :

- Décrire la situation multidimensionnelle ($D > 2$)
- Expliquer pourquoi on a au plus $M - 1$ dimensions discriminantes

Inférence :

- Comment faire de l'inférence avec la LDA ?
 - Fournir un exemple de modèle conditionnel utilisant la LDA
-

Concepts mathématiques à maîtriser

Pour bien comprendre la LDA, il faut maîtriser :

Algèbre linéaire :

- Vecteurs propres et valeurs propres
- Système aux valeurs propres généralisé
- Matrices de covariance
- Projection orthogonale

Statistiques :

- Moyenne et variance
- Covariance et corrélation
- Distribution normale multivariée
- Règle de Bayes

Optimisation :

- Dérivation de fonctions matricielles
- Optimisation sous contrainte
- Méthode du ratio de Rayleigh