

Table of contents

L'essentiel	1
Introduction et Motivation	1
Le problème fondamental	2
Apprentissage supervisé	2
Intuition géométrique : Séparer des nuages de points colorés	2
Les deux objectifs en tension	3
Objectif 1 : Éloigner les centres (Between-class)	3
Objectif 2 : Regrouper chaque classe (Within-class)	3
Critère de Fisher : Le compromis mathématique	4
Formulation pour 2 classes	4
Généralisation à M classes	4
Solution : Problème aux valeurs propres	5
Résolution par dérivation	5
Limitation dimensionnelle	6
Pourquoi seulement M-1 dimensions ?	6
Application pratique de la LDA	6
Algorithme LDA complet	6
LDA comme classifieur : L'hypothèse gaussienne	7
Modélisation probabiliste	7
Approximation gaussienne	8
Pourquoi la frontière est-elle linéaire ?	8
Optimalité de la LDA	9
Conditions d'optimalité	9
Quand la LDA fonctionne bien (et moins bien)	9
LDA vs QDA : Le dilemme linéaire vs quadratique	9
La différence cruciale	9
Comparaison LDA vs PCA	10
Différences fondamentales	10
Complémentarité	10

L'essentiel

Introduction et Motivation

La **LDA** (Analyse Discriminante Linéaire) est une méthode d'**analyse latente supervisée** qui permet de trouver les facteurs latents optimaux pour la discrimination entre classes.

Le problème fondamental

Imaginez que vous travaillez dans un centre de tri postal. Vous avez des lettres avec 100 mesures différentes (poids, taille, couleur, texture...). Vous devez les trier automatiquement par type (lettre, colis, magazine). Comment trouver **la ou les dimensions qui séparent le mieux les catégories** ?

C'est exactement ce que résout la LDA : trouver **les axes qui maximisent la séparation entre classes** tout en minimisant la dispersion à l'intérieur de chaque classe.

Différence fondamentale avec la PCA :

La PCA regarde **toutes** les données et cherche les directions de variation maximale. La LDA regarde d'abord **les étiquettes** (les classes) et cherche les directions qui séparent le mieux ces classes.

Attention : Cette LDA ne doit pas être confondue avec **Latent Dirichlet Allocation** (utilisée en NLP).

Apprentissage supervisé

Soit des données $X \subset \Omega \subseteq \mathbb{R}^D$ associées à des catégories (étiquettes de classe) $Y = [[M]] \subset \mathbb{N}$.

L'apprentissage supervisé consiste à trouver (apprendre) les paramètres θ d'un apprenant (fonction) ϕ_θ de manière à minimiser la perte $L_{X \times Y}(\theta)$ encourue lors de la prédiction des étiquettes de classe.

$$\begin{aligned}\phi_\theta : \Omega &\rightarrow Y \\ x_i &\mapsto \phi_\theta(x_i) = \tilde{y}_i\end{aligned}$$

Intuition géométrique : Séparer des nuages de points colorés

Imaginez des points de deux couleurs (rouge et bleu) dispersés sur un plan. Vous ne pouvez regarder que selon une seule direction (comme une lampe torche qui éclaire une ligne).

Question : Comment orienter la lampe pour que, sur cette ligne, les points rouges et bleus soient **le plus séparés possible** ?

Idée essentielle : La LDA cherche la **ligne de démarcation**, comme un arbitre qui trace une ligne entre deux équipes. Elle trouve la direction qui sépare le mieux les groupes, tout en s'assurant que chaque équipe est regroupée.

On cherche une **direction** $a \in \mathbb{R}^D$ telle que la projection des données sur cette direction $\hat{X} = \text{Proj}_a(X)$ montre des **propriétés optimales pour la discrimination** entre classes.

Les deux objectifs en tension

Objectif 1 : Éloigner les centres (Between-class)

“Mettre les moyennes le plus loin possible”

Si les projections des classes sont **bien séparées**, alors elles peuvent être facilement discriminées.

Objectif : Chercher la direction a où la discrimination inter-classes est **maximale**.

i Détails mathématiques : Formulation inter-classes

La direction a doit être **colinéaire** à la ligne $\mu_1 - \mu_2$ qui relie les centres de masse des classes, car :

$$\|\hat{\mu}_1 - \hat{\mu}_2\|^2 = \left\| \frac{a^T \mu_1}{\|a\|^2} a - \frac{a^T \mu_2}{\|a\|^2} a \right\|^2 = \frac{1}{\|a\|^2} (a^T (\mu_1 - \mu_2))^2$$

Cette expression est **maximale** quand $a = \lambda(\mu_1 - \mu_2)$.

Propriété : Le centre de masse des données projetées est la projection du centre de masse des données originales.

Objectif 2 : Regrouper chaque classe (Within-class)

“Garder chaque classe compacte”

On cherche également à **minimiser la variance** de chaque classe projetée individuellement.

Pour chaque classe k , la variance normalisée de la projection est :

$$\hat{\sigma}_k^2 = \frac{1}{N_k} \sum_{y_i=k} (\hat{x}_i - \hat{\mu}_k)^T (\hat{x}_i - \hat{\mu}_k)$$

Le dilemme : Parfois, étirer les centres les éloigne, mais cela peut aussi étirer les classes. Il faut trouver le bon compromis.

Critère de Fisher : Le compromis mathématique

Formulation pour 2 classes

Le critère de Fisher maximise le ratio :

$$\arg \max_a \frac{\|\hat{\mu}_1 - \hat{\mu}_2\|^2}{\hat{\sigma}_1^2 + \hat{\sigma}_2^2}$$

Interprétation :

- **Numérateur** : Distance entre les moyennes projetées (inter-classe) → à **maximiser**
- **Dénominateur** : Somme des variances intra-classes → à **minimiser**

Astuce mnémotechnique :

- **B** comme **Between** = **B** pour “Bien séparer” (les centres)
- **W** comme **Within** = “Regrouper” (chaque classe)

Généralisation à M classes

i Détails mathématiques : Matrices de covariance

Matrice de covariance inter-classes :

Soit $B = [\mu_1 - \mu, \dots, \mu_M - \mu]$ la matrice des centres de classes centrés, où :

- $\mu = \frac{1}{N} \sum_i x_i$ est la moyenne globale
- $N = \sum_k N_k$ est le nombre total de points

$$\Sigma_b = \frac{1}{M} B B^T$$

Critère à maximiser :

$$\frac{1}{M} \sum_k (\hat{\mu}_k - \hat{\mu})^T (\hat{\mu}_k - \hat{\mu}) = \frac{1}{\|a\|^2} a^T \Sigma_b a$$

Matrice de covariance intra-classe :

Soit $A_k = [x_1 - \mu_k, \dots, x_{N_k} - \mu_k]$ avec $y_i = k$, la matrice des données centrées pour la classe k .

$$\Sigma_w = \sum_k \frac{1}{N_k} A_k A_k^T$$

Critère à minimiser :

$$\sum_k \frac{1}{N_k} \sum_{y_i=k} (\hat{x}_i - \hat{\mu}_k)^T (\hat{x}_i - \hat{\mu}_k) = \frac{1}{a^T a} a^T \Sigma_w a$$

Le **critère de Fisher généralisé** combine les critères inter-classe et intra-classe :

$$\arg \max_a J(a) = \arg \max_a \frac{a^T \Sigma_b a}{a^T \Sigma_w a}$$

où :

- Σ_b = matrice de covariance “entre classes” (between) → mesure l'éloignement des centres
- Σ_w = matrice de covariance “dans les classes” (within) → mesure la dispersion interne

Solution : Problème aux valeurs propres

Résolution par dérivation

Détails mathématiques : Dérivation

Pour trouver le maximum, on calcule la dérivée :

$$\frac{\partial J(a)}{\partial a} = \frac{\Sigma_b a (a^T \Sigma_w a) - \Sigma_w a (a^T \Sigma_b a)}{(a^T \Sigma_w a)^2} = 0$$

Équation résultante :

$$\Sigma_b a = J(a) \Sigma_w a$$

Ce qui peut se réécrire :

$$\Sigma_w^{-1} \Sigma_b a = J(a) a$$

Solution : a est solution du **système aux valeurs propres généralisé**.

La direction optimale a est le **premier vecteur propre** de $\Sigma_w^{-1} \Sigma_b$ (avec valeur propre $\lambda_1 = J(a)$).

Limitation dimensionnelle

Pourquoi seulement M-1 dimensions ?

Les vecteurs propres correspondant aux **plus grandes valeurs propres** λ_i sont les dimensions les plus discriminatives :

$$a_1, a_2, \dots, a_p \quad \text{avec} \quad \lambda_1 > \lambda_2 > \dots > \lambda_p$$

Propriété fondamentale : M classes peuvent être discriminées dans un sous-espace de dimension **au plus** $(M - 1)$.

Conséquence : Il y a seulement $M - 1$ valeurs propres **non nulles**.

Analogie : Avec 3 points (3 classes), vous pouvez au plus les placer dans un plan (2D). Avec 2 points (2 classes), vous pouvez au plus les placer sur une ligne (1D).

i Détails mathématiques : Cas $M = 2$

Pour deux classes, on peut montrer que :

$$BB^T = (\mu_1 - \mu)(\mu_1 - \mu)^T + (\mu_2 - \mu)(\mu_2 - \mu)^T \propto (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T$$

Implications :

- $BB^T a$ est un vecteur selon la direction $(\mu_1 - \mu_2)$
- La solution est $a = \lambda \Sigma_w^{-1} (\mu_1 - \mu_2)$

Piège à éviter : Si vous avez plus de dimensions que M-1, les directions supplémentaires auront une valeur propre nulle $\rightarrow$ pas discriminantes.

Application pratique de la LDA

Algorithme LDA complet

Étape 1 : Préparer les données

- Vérifier que chaque classe a assez d'exemples (au moins D+1 pour éviter Σ_w singulière)
- Optionnel : standardiser si les échelles sont très différentes

Étape 2 : Calculer les matrices clés

- Σ_w (within) : moyenne des covariances de chaque classe
- Σ_b (between) : covariance des centres de classes

Étape 3 : Résoudre le problème aux valeurs propres

Calculer les vecteurs propres de $\Sigma_w^{-1}\Sigma_b$

Étape 4 : Garder les M-1 premières directions

Trier par valeurs propres décroissantes, garder les plus importantes

Étape 5 : Projeter et classifier

- Projeter les données sur le sous-espace discriminant
- Classifier (par exemple avec une règle du plus proche voisin)

LDA comme classifieur : L'hypothèse gaussienne

Modélisation probabiliste

Pour une nouvelle donnée j :

- x_j est **connu**
- y_j est **inconnu**

Question : À quelle classe k le point j appartient-il ?

On déclare la variable aléatoire de classe C et on utilise la **règle de Bayes** :

$$\mathbb{P}(C = k|x_j) = \frac{\mathbb{P}(x_j|C = k)\mathbb{P}(C = k)}{\mathbb{P}(x_j)}$$

Composantes :

- $\mathbb{P}(x_j|C = k)$: **vraisemblance** (likelihood)
- $\mathbb{P}(C = k)$: **prior** (probabilité a priori)
- $\mathbb{P}(x_j)$: **évidence** (normalisation)

Approximation gaussienne

La LDA suppose que **chaque classe suit une distribution gaussienne** :

$$\mathbb{P}(x|C = k) \sim \mathcal{N}(\mu_k, \Sigma_k)$$

avec :

- Moyennes différentes pour chaque classe
- **Même matrice de covariance** pour toutes les classes (crucial !)

i Détails mathématiques : Maximum de vraisemblance

Approximation :

$$\mathbb{P}(x|C = k) \propto \exp(-(x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k))$$

Prior uniforme : $\mathbb{P}(C = k) = \frac{1}{M}$ (toutes les classes équiprobables)

Simplification : L'évidence $\mathbb{P}(x_j)$ est **ignorée** car constante pour toutes les classes (normalisation).

Règle de décision :

$$\delta(x) = \arg \max_k \mathbb{P}(x|C = k)$$

Interprétation : On assigne x à la classe k qui maximise la vraisemblance.

Pourquoi la frontière est-elle linéaire ?

Avec cette hypothèse, la frontière entre deux classes est **linéaire** (d'où le “L” de LDA).

Pourquoi ? Les contours d'égal densité de deux gaussiennes avec même covariance sont des hyperplans.

Optimalité de la LDA

Conditions d'optimalité

La LDA est optimale lorsque les M classes suivent chacune une **distribution gaussienne** avec la même matrice de covariance.

Justification :

Les critères de discrimination sont basés sur les matrices de covariance Σ_w et Σ_b , qui caractérisent pleinement les distributions gaussiennes.

Quand la LDA fonctionne bien (et moins bien)

Conditions idéales

- Les classes sont **approximativement gaussiennes**
- Les covariances des classes sont **similaires**
- Assez d'exemples par classe (au moins $10 \times$ le nombre de dimensions)
- Relations **linéaires** entre variables

Situations problématiques

- **Covariances très différentes** → utiliser QDA (Quadratic Discriminant Analysis)
- **Relations non-linéaires** → Kernel LDA ou méthodes non-linéaires
- **Peu d'exemples** par rapport aux dimensions → régulariser ou réduire dimension d'abord
- **Classes non-gaussiennes** → autres classifieurs (forêts aléatoires, SVM...)

LDA vs QDA : Le dilemme linéaire vs quadratique

La différence cruciale

- **LDA** : Suppose **même covariance** pour toutes classes → frontières linéaires
- **QDA** : Suppose **covariances différentes** → frontières quadratiques

Règle pratique : Si vous avez peu de données, LDA est plus robuste (moins de paramètres à estimer).

Comparaison LDA vs PCA

Différences fondamentales

PCA (non supervisée) :

- Maximise la **variance** globale
- Ignore les étiquettes de classe
- Trouve les directions de variance maximale
- Basée sur Σ (covariance totale)

LDA (supervisée) :

- Maximise la **séparation entre classes**
- Utilise les étiquettes de classe
- Trouve les directions discriminantes
- Basée sur $\Sigma_w^{-1}\Sigma_b$ (ratio de covariances)

Complémentarité

En pratique : On peut combiner PCA et LDA :

- PCA pour réduction initiale de dimension (éliminer le bruit)
- LDA pour maximiser la discrimination

Exemple concret : Reconnaissance faciale avec Fisherfaces (LDA) contrairement aux Eigenfaces (PCA).

Fiche de révision condensée

En 30 secondes :

- LDA = réduction supervisée (utilise les étiquettes)
- Maximise (distance entre centres) / (dispersion dans classes)
- Solution = vecteurs propres de $\Sigma_w^{-1}\Sigma_b$
- Au plus M-1 dimensions discriminantes
- Suppose : classes gaussiennes, mêmes covariances
- Utile pour : classification, visualisation supervisée
- Alternative : QDA si covariances différentes

! Concepts mathématiques à maîtriser

Pour bien comprendre la LDA :

Algèbre linéaire :

- Vecteurs propres et valeurs propres
- Système aux valeurs propres généralisé
- Matrices de covariance
- Projection orthogonale

Statistiques :

- Moyenne et variance
- Covariance et corrélation
- Distribution normale multivariée
- Règle de Bayes

Optimisation :

- Dérivation de fonctions matricielles
- Optimisation sous contrainte
- Méthode du ratio de Rayleigh