

Table of contents

Cours détaillé	2
Introduction et Motivation	2
Contexte général	2
Rappel : Modèles utilisés jusqu'à présent	2
Nouvelle approche : Modélisation de densité	3
Méthodes d'estimation de densité	3
Modèles de mélange	3
Définition	3
Interprétation probabiliste	4
Estimation par maximum de vraisemblance (MLE)	4
Mélange gaussien (Gaussian Mixture Model - GMM)	5
Choix de la famille gaussienne	5
Avantages du GMM	6
Cas simple : 1 composante	6
Cas complexe : 2 composantes	7
Variables latentes et stratégie EM	7
Étape E (Expectation)	8
Assignation dure vs douce	9
Étape M (Maximization)	9
Convergence de l'algorithme EM	10
Limitations de l'algorithme EM	11
Généralisation à c composantes	12
Algorithme EM complet pour c composantes	12
Étape 1 : Initialisation	12
Étape 2 : E-step	13
Étape 3 : M-step	13
Étape 4 : Itération	13
Modélisation pratique	14
Forme de la matrice de covariance	14
Prétraitement : Réduction de dimension par PCA	15
Sélection du nombre de composantes	16
Synthèse des concepts clés	17
Mélanges gaussiens (GMM)	17
Algorithme EM	17
Relation entre GMM et K-means	18
Comparaison conceptuelle	18
GMM comme généralisation de K-means	18
Questions d'examen types	18
Questions conceptuelles	18
Questions techniques	19

Développements mathématiques	19
Concepts mathématiques à maîtriser	20
Probabilités et statistiques	20
Optimisation	20

Cours détaillé

Introduction et Motivation

Contexte général

L'algorithme **Expectation-Maximization (EM)** est une méthode d'**estimation de facteurs latents** dans un contexte **non supervisé** de modélisation conditionnelle.

Objectifs du cours :

- Comprendre la **modélisation conditionnelle non supervisée** comme estimation de facteurs latents
- Développer l'exemple de l'**estimation de densité par modèles de mélange gaussien** (GMM - Gaussian Mixture Models)
- Pratiquer l'**estimation par maximum de vraisemblance** (MLE - Maximum Likelihood Estimation)
- Comprendre le principe **alternatif** de l'Expectation-Maximization pour la découverte de facteurs latents

Rappel : Modèles utilisés jusqu'à présent

Modèles à composantes (PCA) :

- Critère basé sur la **variance** de données centrées
- Distribution implicite : **normale**

Modèles discriminants (LDA) :

- Variance des données projetées pour les modèles intra-classe (within) et inter-classe (between)

Point commun : La distribution est **fixée** (essentiellement normale) et on cherche ses paramètres θ (par exemple $\theta = [\mu, \Sigma]$)

Nouvelle approche : Modélisation de densité

Alternative : Chercher un modèle pour la **densité des données**

Soit $f_\theta(x) : \Omega \rightarrow \mathbb{R}$ la **densité des données**

Méthodes d'estimation de densité

Vue d'ensemble des méthodes

Méthodes non-paramétriques :

- **k-Nearest Neighbors (kNN)** : estimation basée sur les k plus proches voisins
- **Fenêtres de Parzen** : estimation par noyaux
- **Réseaux RBF** : fonctions à base radiale
- **Histogrammes** : discrétisation de l'espace

Méthodes paramétriques :

- **Modèles de mélange** (Mixture models) : le focus de ce cours
-

Modèles de mélange

Définition

Formulation générale

Définition :

La densité $f(x)$ est générée par c fonctions de “base” ϕ (composantes), issues d’une famille $\mathcal{F}$:

$$f(x) = \sum_{j=1}^c \pi_j \phi(x, \theta_j)$$

Composantes du modèle :

- $\pi_j \in \mathbb{R}$: **paramètres du mélange** (mixture parameters)
- $\phi(x, \theta_j) \in \mathcal{F}$: **fonctions de base** contrôlées par les paramètres θ_j

Hypothèses du modèle

Trois hypothèses fondamentales :

1. Le **nombre de composantes** $c \in \mathbb{N}^*$ est **connu**
 2. La **famille de fonctions** $\mathcal{F}$ est **connue**
 3. Les **étiquettes** (class labels) sont **inconnues** (contexte non supervisé)
-

Interprétation probabiliste

Lecture probabiliste du mélange

La densité $f(x)$ représente un **processus aléatoire** où x est tiré d'un ensemble d'états ω_j avec probabilité a priori $\mathbb{P}(\omega_j)$.

Formulation probabiliste :

$$f(x) = \sum_{j=1}^c \pi_j \phi(x, \theta_j) = \mathbb{P}(x|\theta) = \sum_{j=1}^c \mathbb{P}(\omega_j) \mathbb{P}(x|\omega_j, \theta_j)$$

Par identification :

- $\pi_j = \mathbb{P}(\omega_j)$ avec la contrainte $\sum_j \pi_j = 1$
 - $\phi(x, \theta_j) = \mathbb{P}(x|\omega_j, \theta_j)$ est la **probabilité conditionnelle** que x soit généré par l'état ω_j
-

Estimation par maximum de vraisemblance (MLE)

Rappel sur la vraisemblance

Données :

Soit $X = \{x_1, \dots, x_N\}$ des échantillons **non étiquetés** générés par le mélange $f(x) = \mathbb{P}(x|\theta)$

Paramètres à inférer :

$$\theta = [\pi_j, \theta_j]_{j \in [c]}$$

Fonction de vraisemblance

Vraisemblance :

En supposant les données **indépendantes et identiquement distribuées** (i.i.d.) :

$$\mathbb{P}(X|\theta) \stackrel{\text{i.i.d.}}{=} \prod_{i=1}^N \mathbb{P}(x_i|\theta)$$

Estimateur de vraisemblance :

$$\hat{\theta} = \arg \max_{\theta} \mathbb{P}(X|\theta)$$

Log-vraisemblance

Transformation logarithmique :

$$LL(\theta, X) = \sum_{i=1}^N \log \mathbb{P}(x_i|\theta) = \sum_{i=1}^N \log \left[\sum_{j=1}^c \pi_j \phi(x_i, \theta_j) \right]$$

Estimateur du maximum de log-vraisemblance (MLE) :

$$\hat{\theta} = \arg \max_{\theta} LL(\theta, X)$$

Avantage : Transformation du produit en somme, numériquement plus stable

Mélange gaussien (Gaussian Mixture Model - GMM)

Choix de la famille gaussienne

Puisque ϕ doit être une **fonction de densité de probabilité**, choisir la famille de densités **normales** comme base semble raisonnable (choix **agnostique**) :

$$\phi \in \mathcal{F} = \{\mathcal{N}(\mu, \Sigma)\}$$

Modèle de mélange gaussien :

$$f(x) = \sum_{j=1}^c \pi_j \mathcal{N}(x|\mu_j, \Sigma_j)$$

où $\phi_j(x) := \phi(x, \theta_j) = \mathcal{N}(x|\mu_j, \Sigma_j)$

Avantages du GMM

Universalité : Peut approximer **n'importe quelle densité** (théorème d'approximation universelle)

Linéarité : Permet un système **linéaire** des paramètres lors de la maximisation de la log-vraisemblance

Cas simple : 1 composante

Estimation directe

Paramètres : $\theta = [\mu, \Sigma]$

Problème d'optimisation :

$$\hat{\theta} = \arg \max_{\theta} \sum_i \log e^{-(x_i - \mu)^T \Sigma^{-1} (x_i - \mu)} \Leftrightarrow \hat{\theta} = \arg \min_{\theta} \sum_i (x_i - \mu)^T \Sigma^{-1} (x_i - \mu)$$

Solutions analytiques :

$$\hat{\mu} = \frac{1}{N} \sum_i x_i$$

$$\hat{\Sigma} = \frac{1}{N} \sum_i (x_i - \hat{\mu})(x_i - \hat{\mu})^T$$

Remarque : Solutions identiques à l'estimation empirique standard de moyenne et covariance

Cas complexe : 2 composantes

Problématique

Paramètres :

$$\theta = [\pi_1, \theta_1, \pi_2, \theta_2] = [\pi_1, [\mu_1, \Sigma_1], \pi_2, [\mu_2, \Sigma_2]]$$

avec la contrainte $\pi_1 + \pi_2 = 1$

Log-vraisemblance :

$$LL(\theta, X) = \sum_{i=1}^N \log[\pi_1 \phi(x_i, \theta_1) + \pi_2 \phi(x_i, \theta_2)]$$

Difficulté : Maximisation difficile à cause de la **somme à l'intérieur du logarithme !**

Solution : Algorithme EM

Solution : Algorithme itératif en **2 étapes** (E-M) pour maximiser LL

→ **Expectation-Maximization (EM) algorithm**

Variables latentes et stratégie EM

Introduction des variables latentes

Problème fondamental :

Ce qui manque ici est l'**assignation** de x_i à l'une des 2 composantes ϕ_j

Observation clé :

Si on **connaissait** cette assignation, on traiterai le problème comme **deux fois le cas à 1 composante**

Variables d'assignation binaire

On introduit des **variables latentes (non observées)** : l'assignation binaire $\delta_{ij} \in \{\text{true}, \text{false}\}$ de chaque x_i à la composante ϕ_j :

- $x_i \sim \phi_1 \Rightarrow \delta_{i1} = \text{true}, \delta_{i2} = \text{false}$
- $x_i \sim \phi_2 \Rightarrow \delta_{i1} = \text{false}, \delta_{i2} = \text{true}$

Mais on peut seulement **estimer** $\delta_{ij} \rightarrow$ **stratégie EM**

Étape E (Expectation)

Principe de l'étape E

Paramètres :

$$\theta = [\pi_1, \theta_1, \pi_2, \theta_2] = [\pi_1, [\mu_1, \Sigma_1], \pi_2, [\mu_2, \Sigma_2]]$$

Initialisation :

On suppose connaître une valeur initiale :

$$\theta^0 = [\pi_1^0, \theta_1^0, \pi_2^0, \theta_2^0]$$

Calcul de la responsabilité (Responsibility)

On peut inférer la **contribution statistique** γ_{ij} de chaque donnée x_i à chaque composante ϕ_j (paramétrisée par θ_j^0) :

$$\gamma_{ij}(\theta^0) = \mathbb{P}[\delta_{ij} = \text{true} | \theta^0, X]$$

Formule de Bayes :

$$\gamma_{i1}(\theta^0) = \frac{\pi_1^0 \phi(x_i, \theta_1^0)}{\pi_1^0 \phi(x_i, \theta_1^0) + \pi_2^0 \phi(x_i, \theta_2^0)}$$

Interprétation de la responsabilité

Définition formelle :

γ_{ij} est la **responsabilité** (responsibility) de la composante j pour la donnée i

Signification :

- C'est la **vraisemblance** que x_i soit (purement) modélisée par la composante ϕ_j
 - γ_{ij} représente la **part de** x_i qui est modélisée (générée) par la composante ϕ_j
-

Assignment dure vs douce

Assignment dure (Hard assignment)

On peut utiliser γ_{ij} pour déterminer $\delta_{ij} \rightarrow x_i$ peut être assigné soit à ϕ_1 soit à ϕ_2 (**vote maximum** $\rightarrow$ binarisation)

$\rightarrow$ Assignment de type **K-means** : chaque donnée est assignée à **une et une seule** composante (cluster)

Assignment douce (Soft assignment)

EM est “plus douce” :

Une donnée **contribue** (via γ_{ij}) à **plusieurs composantes** (modes de densité)

EM calcule une **assignment douce** avec :

$$\sum_j \gamma_{ij} = 1 \quad \forall i$$

Avantage : Plus robuste et reflète mieux l'incertitude dans l'assignment

Étape M (Maximization)

Principe de l'étape M

Note : Pour 2 composantes, $\gamma_{i1} + \gamma_{i2} = 1$

Étant donné la **responsabilité** de chaque donnée (γ_{ij}), on peut estimer les paramètres de chaque composante par **maximum de vraisemblance pondéré** :

Estimation des paramètres

Moyennes :

$$\hat{\mu}_1 = \sum_{i=1}^N \frac{\gamma_{i1}}{\sum_{k=1}^N \gamma_{k1}} x_i$$

$$\hat{\mu}_2 = \sum_{i=1}^N \frac{\gamma_{i2}}{\sum_{k=1}^N \gamma_{k2}} x_i$$

Covariances :

$$\hat{\Sigma}_1 = \sum_{i=1}^N \frac{\gamma_{i1}}{\sum_{k=1}^N \gamma_{k1}} (x_i - \hat{\mu}_1)(x_i - \hat{\mu}_1)^T$$

$$\hat{\Sigma}_2 = \sum_{i=1}^N \frac{\gamma_{i2}}{\sum_{k=1}^N \gamma_{k2}} (x_i - \hat{\mu}_2)(x_i - \hat{\mu}_2)^T$$

Poids du mélange :

$$\pi_j = \frac{1}{N} \sum_{i=1}^N \gamma_{ij}$$

Cette formule garantit que $\sum_j \pi_j = 1$

Convergence de l'algorithme EM

Principe itératif

Le cycle alterné **Expectation-Maximization** augmente la vraisemblance des données par rapport au modèle de mélange.

Critère de convergence :

Le processus est itéré jusqu'à **convergence**, c'est-à-dire quand la vraisemblance des données ne change (presque) plus :

$$|LL(\theta^{t+1}, X) - LL(\theta^t, X)| < \epsilon$$

où ϵ est un seuil de tolérance (par exemple $\epsilon = 10^{-6}$)

Propriété de monotonie

Propriété garantie : À chaque itération, $LL(\theta^{t+1}, X) \geq LL(\theta^t, X)$

La log-vraisemblance **ne diminue jamais** (propriété hill-climbing)

Limitations de l'algorithme EM

Sensibilité à l'initialisation

Hill-climbing : L'algorithme dépend des **paramètres initiaux**

Conséquences :

- **Sensible aux maxima locaux :** peut converger vers un optimum local plutôt que global
- Différentes initialisations peuvent donner différents résultats

Stratégies d'initialisation

Méthodes recommandées :

- **K-means :** utiliser le clustering K-means pour initialiser les centres μ_j
- **K-means++ :** version améliorée de K-means avec initialisation intelligente
- **Exécutions multiples :** lancer l'algorithme plusieurs fois avec différentes initialisations et garder la meilleure

Convergence lente

Convergence potentiellement lente, selon :

- La séparation entre les composantes
 - La forme des distributions
 - Le nombre de composantes
-

Généralisation à c composantes

Variables latentes générales

Généralisation :

$$\delta_{i1}, \delta_{i2}, \dots, \delta_{ij}, \dots, \delta_{ic}$$

où $\delta_{ij} = \text{true}$ si la donnée x_i est générée par la composante ϕ_j ($\delta_{ij} = \text{false}$ sinon)

Responsabilité :

γ_{ij} : espérance de δ_{ij} sur toutes les composantes

Paramètres à estimer :

$$\theta = [\pi_j, \theta_j]_{j \in [[c]]} = [\pi_j, [\mu_j, \Sigma_j]]_j$$

Algorithme EM complet pour c composantes

Étape 1 : Initialisation

Initialisation des paramètres :

$$\theta^0 = \{\pi_j^0, \mu_j^0, \Sigma_j^0\}_{j \in [[c]]}$$

Stratégies courantes :

- **Générale :**
 - $\pi_j = 1/c$
 - μ_j choisi aléatoirement
 - $\Sigma_j = I_D$
- **Alternative :** utiliser K-means comme initialisation

Étape 2 : E-step

Calcul des responsabilités :

Pour chaque donnée $i \in [[N]]$ et chaque composante $j \in [[c]]$:

$$\gamma_{ij} = \frac{\pi_j \phi(x_i, \theta_j)}{\sum_{k=1}^c \pi_k \phi(x_i, \theta_k)}$$

Étape 3 : M-step

Estimation des paramètres du mélange :

Moyennes :

$$\mu_j = \frac{\sum_{i=1}^N \gamma_{ij} x_i}{\sum_i \gamma_{ij}}$$

Covariances :

$$\Sigma_j = \frac{X_j \Gamma_j X_j^T}{\text{Tr}(\Gamma_j)}$$

où $\Gamma_j = \text{diag}(\gamma_{1j}, \dots, \gamma_{Nj})$ et X_j est centré sur μ_j

Poids :

$$\pi_j = \frac{\sum_i \gamma_{ij}}{N}$$

Étape 4 : Itération

Itérer les étapes 2 et 3 jusqu'à convergence

Modélisation pratique

Paramètres influençant la convergence

La **paramétrisation a priori** du mélange change la convergence :

Paramètres critiques :

1. c : nombre de composantes
2. Σ_j : forme des matrices de covariance (diagonale, complète, paramétrée)

Risques :

- Modèles **trop flexibles** ou **trop rigides** $\rightarrow$ mauvaise convergence ou absence de convergence
 - **Sur-paramétrisation** : $D \times D \times c + 2 \times c$ variables
Si N est faible, D grand et c grand $\rightarrow$ **sur-paramétrisation** problématique
-

Forme de la matrice de covariance

Problème de sur-paramétrisation

Dimension de Σ :

$$\Sigma \in \mathbb{R}^{D \times D}$$

Exemple critique :

Reconnaissance de caractères avec $x_i \in \mathbb{R}^{256}$

$\rightarrow$ Besoin d'estimer $256^2 \times c$ paramètres pour la covariance (avec environ 7000 points de données) !

Stratégies de paramétrisation

Modèles sphériques :

- $\Sigma = \sigma I_D$
- **1 paramètre** par composante

Modèles diagonaux :

- $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_D)$
- **D paramètres** par composante

Modèles complets :

- $\Sigma \in \mathbb{R}^{D \times D}$
- **$O(D^2)$ paramètres** par composante

Conseil pratique : Commencer avec des modèles simples (sphériques) puis augmenter la complexité si nécessaire

Prétraitement : Réduction de dimension par PCA

Problématique en haute dimension

Pour des données de haute dimension (par exemple $D = 256$), les modèles complexes ne convergent pas car le nombre de paramètres p est trop grand.

Solution : PCA préalable

Stratégie recommandée :

1. Appliquer **PCA** pour réduire la dimension de D à K dimensions
2. Appliquer **EM** dans l'espace des K premières composantes principales

Exemple pratique :

- 50 composantes principales reconstruisent 90% du signal
- EM dans l'espace des 50, 10 ou 2 premières composantes principales

Avantages :

- Réduction drastique du nombre de paramètres

- Élimination du bruit
- Convergence plus rapide et stable

Sélection du nombre de composantes

Principe de parcimonie

Problème :

Plus c est grand, moins de points peuvent être assignés à chaque composante (en moyenne)

Objectif :

Chercher des modèles **parcimonieux**, c'est-à-dire avec un **petit nombre de paramètres** à estimer

Critère d'Information Bayésien (BIC)

Trade-off vraisemblance-complexité :

- Plus c est grand, meilleure est l'estimation de la vraisemblance LL
- Mais plus le modèle est complexe (nombreux paramètres)

Formule du BIC :

$$BIC(\theta, X) = -2 \cdot LL(\theta, X) + |\theta| \log(N)$$

où $|\theta|$ est le **nombre de paramètres** du modèle

Critère de sélection :

$$\hat{\theta} = \arg \min_{\theta} BIC(\theta, X)$$

Composantes du BIC :

- $-2 \cdot LL(\theta, X)$: pénalise les modèles avec mauvaise vraisemblance
- $|\theta| \log(N)$: pénalise la complexité du modèle

Interprétation : Le BIC favorise les modèles qui expliquent bien les données **sans sur-ajustement**

Limitations de la sélection de modèle

Défis pratiques :

- Besoin de **tester tous les modèles** (différentes valeurs de c)
 - Dépend de la **convergence** de chaque modèle
 - Nécessite souvent un **ajustement manuel** fin
-

Synthèse des concepts clés

Mélanges gaussiens (GMM)

Généralisation :

Le modèle de mélange gaussien **généralise** les hypothèses sous-jacentes à la PCA et à la LDA

Modélisation et estimation explicites :

- **Modélisation explicite** de la densité
- **Estimation** par maximum de vraisemblance

Classification non supervisée :

Si les composantes sont des classes, la donnée x_i est associée à la classe j pour laquelle :

$$\mathbb{P}(C = j|x_i) \approx \pi_j \phi_j(x_i)$$

est maximisée parmi toutes les classes

Algorithme EM

Caractéristiques :

- Algorithme **itératif** pour maximiser la (log-)vraisemblance
- Principe utilisé dans **de nombreux autres scénarios**
- Basé sur la définition de **variables non observées (latentes)** δ_{ij}

Applications :

- **Probabilistic Latent Semantic Analysis (pLSA)** : EM où les variables cachées sont les concepts latents
- **Modèles de Markov cachés (HMM)**

- Factorisation matricielle
-

Relation entre GMM et K-means

Comparaison conceptuelle

K-means :

- **Assignment dure** (hard assignment)
- Chaque point appartient à **un seul cluster**
- Minimise la distance euclidienne aux centres

GMM avec EM :

- **Assignment douce** (soft assignment)
- Chaque point a une **probabilité d'appartenance** à chaque composante
- Maximise la vraisemblance selon un modèle probabiliste

GMM comme généralisation de K-means

K-means est un cas particulier de GMM quand :

- Matrices de covariance $\Sigma_j = \sigma^2 I$ (sphériques et identiques)
 - $\sigma \rightarrow 0$: les responsabilités γ_{ij} deviennent binaires
 - Assignment douce $\rightarrow$ assignment dure
-

Questions d'examen types

Questions conceptuelles

Modèle de mélange gaussien :

- Qu'est-ce qu'un modèle de mélange gaussien (GMM) ?
- Pourquoi peut-il être vu comme une modélisation conditionnelle ?
- Comment peut-on l'utiliser pour générer des données ?

Responsabilité :

- Qu'est-ce que la responsabilité (responsibility) ?
- Comment l'interpréter ?

Algorithme EM :

- Pourquoi l'EM pour GMM est-il une MLE ?
- Comment interpréter l'étape E ?
- Comment interpréter l'étape M ?

Questions techniques

Relation avec K-means :

- Discuter la relation entre GMM et K-means
- Qu'est-ce que les assignations dure et douce (hard- et soft-assignments) ?

Convergence et optimisation :

- Comment choisir le nombre de composantes ?
- Quelles sont les stratégies d'initialisation ?
- Comment gérer la sur-paramétrisation ?

Développements mathématiques

Conseil important : Il est **fortement recommandé** de développer l'algèbre contenue dans ce chapitre

Points à maîtriser :

- Dérivation de la log-vraisemblance
- Calcul des responsabilités par la règle de Bayes
- Dérivation des équations de mise à jour du M-step
- Preuve de la monotonie de LL dans l'algorithme EM

Concepts mathématiques à maîtriser

Probabilités et statistiques

Fondamentaux :

- Distribution normale multivariée
- Maximum de vraisemblance (MLE)
- Log-vraisemblance
- Règle de Bayes

Modélisation :

- Variables aléatoires latentes
- Probabilités conditionnelles
- Espérance conditionnelle

Optimisation

Techniques :

- Optimisation itérative
- Algorithmes hill-climbing
- Critères de convergence
- Maxima locaux vs globaux

Critères de sélection :

- BIC (Bayesian Information Criterion)
- Trade-off biais-variance
- Parcimonie de modèle