

Table of contents

Document de Révision : Expectation-Maximization pour la modélisation de densité	3
Introduction et Motivation	3
Contexte général	3
Rappel : Modèles utilisés jusqu'à présent	3
Nouvelle approche : Modélisation de densité	3
Méthodes d'estimation de densité	4
Vue d'ensemble des méthodes	4
Modèles de mélange : Définition	4
Formulation générale	4
Hypothèses du modèle	4
Interprétation probabiliste	5
Lecture probabiliste du mélange	5
Estimation par maximum de vraisemblance (MLE)	5
Rappel sur la vraisemblance	5
Fonction de vraisemblance	5
Log-vraisemblance	6
Mélange gaussien (Gaussian Mixture Model - GMM)	6
Choix de la famille gaussienne	6
Avantages du GMM	7
Cas simple : 1 composante	7
Estimation directe	7
Cas complexe : 2 composantes	8
Problématique	8
Solution : Algorithme EM	8
Variables latentes et stratégie EM	8
Introduction des variables latentes	8
Variables d'assignation binaire	9
Étape E (Expectation)	9
Principe de l'étape E	9
Calcul de la responsabilité (Responsibility)	9
Interprétation de la responsabilité	10
Assignation dure vs douce	10
Assignation dure (Hard assignment)	10
Assignation douce (Soft assignment)	10
Étape M (Maximization)	11
Principe de l'étape M	11
Estimation des paramètres	11
Convergence de l'algorithme EM	12
Principe itératif	12
Propriété de monotonie	12

Limitations de l'algorithme EM	12
Sensibilité à l'initialisation	12
Stratégies d'initialisation	12
Convergence lente	13
Généralisation à c composantes	13
Variables latentes générales	13
Algorithme EM complet pour c composantes	13
Étape 1 : Initialisation	13
Étape 2 : E-step	14
Étape 3 : M-step	14
Étape 4 : Itération	14
Modélisation pratique	15
Paramètres influençant la convergence	15
Forme de la matrice de covariance	15
Problème de sur-paramétrisation	15
Stratégies de paramétrisation	16
Prétraitement : Réduction de dimension par PCA	16
Problématique en haute dimension	16
Solution : PCA préalable	17
Sélection du nombre de composantes	17
Principe de parcimonie	17
Critère d'Information Bayésien (BIC)	17
Limitations de la sélection de modèle	18
Synthèse des concepts clés	18
Mélanges gaussiens (GMM)	18
Algorithme EM	19
Relation entre GMM et K-means	19
Comparaison conceptuelle	19
GMM comme généralisation de K-means	20
Questions d'examen types	20
Questions conceptuelles	20
Questions techniques	20
Développements mathématiques	21
Concepts mathématiques à maîtriser	21
Probabilités et statistiques	21
Optimisation	21

Document de Révision : Expectation-Maximization pour la modélisation de densité

Introduction et Motivation

Contexte général

L'algorithme **Expectation-Maximization (EM)** est une méthode d'**estimation de facteurs latents** dans un contexte **non supervisé** de modélisation conditionnelle.

Objectifs du cours :

- Comprendre la **modélisation conditionnelle non supervisée** comme estimation de facteurs latents
- Développer l'exemple de l'**estimation de densité par modèles de mélange gaussien** (GMM - Gaussian Mixture Models)
- Pratiquer l'**estimation par maximum de vraisemblance** (MLE - Maximum Likelihood Estimation)
- Comprendre le principe **alternatif** de l'Expectation-Maximization pour la découverte de facteurs latents

Rappel : Modèles utilisés jusqu'à présent

Modèles à composantes (PCA) :

- Critère basé sur la **variance** de données centrées
- Distribution implicite : **normale**

Modèles discriminants (LDA) :

- Variance des données projetées pour les modèles intra-classe (within) et inter-classe (between)

Point commun : La distribution est **fixée** (essentiellement normale) et on cherche ses paramètres θ (par exemple $\theta = [\mu, \Sigma]$)

Nouvelle approche : Modélisation de densité

Alternative : Chercher un modèle pour la **densité des données**

Soit $f_{\theta}(x) : \Omega \rightarrow \mathbb{R}$ la **densité des données**

Méthodes d'estimation de densité

Vue d'ensemble des méthodes

Méthodes non-paramétriques :

- **k-Nearest Neighbors (kNN)** : estimation basée sur les k plus proches voisins
- **Fenêtres de Parzen** : estimation par noyaux
- **Réseaux RBF** : fonctions à base radiale
- **Histogrammes** : discrétisation de l'espace

Méthodes paramétriques :

- **Modèles de mélange** (Mixture models) : le focus de ce cours
-

Modèles de mélange : Définition

Formulation générale

Définition :

La densité $f(x)$ est générée par c fonctions de “base” ϕ (composantes), issues d'une famille $\mathcal{F}$:

$$f(x) = \sum_{j=1}^c \pi_j \phi(x, \theta_j)$$

Composantes du modèle :

- $\pi_j \in \mathbb{R}$: **paramètres du mélange** (mixture parameters)
- $\phi(x, \theta_j) \in \mathcal{F}$: **fonctions de base** contrôlées par les paramètres θ_j

Hypothèses du modèle

Trois hypothèses fondamentales :

1. Le **nombre de composantes** $c \in \mathbb{N}^*$ est **connu**
 2. La **famille de fonctions** $\mathcal{F}$ est **connue**
 3. Les **étiquettes** (class labels) sont **inconnues** (contexte non supervisé)
-

Interprétation probabiliste

Lecture probabiliste du mélange

La densité $f(x)$ représente un **processus aléatoire** où x est tiré d'un ensemble d'états ω_j avec probabilité a priori $\mathbb{P}(\omega_j)$.

Formulation probabiliste :

$$f(x) = \sum_{j=1}^c \pi_j \phi(x, \theta_j) = \mathbb{P}(x|\theta) = \sum_{j=1}^c \mathbb{P}(\omega_j) \mathbb{P}(x|\omega_j, \theta_j)$$

Par identification :

- $\pi_j = \mathbb{P}(\omega_j)$ avec la contrainte $\sum_j \pi_j = 1$
 - $\phi(x, \theta_j) = \mathbb{P}(x|\omega_j, \theta_j)$ est la **probabilité conditionnelle** que x soit généré par l'état ω_j
-

Estimation par maximum de vraisemblance (MLE)

Rappel sur la vraisemblance

Données :

Soit $X = \{x_1, \dots, x_N\}$ des échantillons **non étiquetés** générés par le mélange $f(x) = \mathbb{P}(x|\theta)$

Paramètres à inférer :

$$\theta = [\pi_j, \theta_j]_{j \in [c]}$$

Fonction de vraisemblance

Vraisemblance :

En supposant les données **indépendantes et identiquement distribuées** (i.i.d.) :

$$\mathbb{P}(X|\theta) \stackrel{\text{i.i.d.}}{=} \prod_{i=1}^N \mathbb{P}(x_i|\theta)$$

Estimateur de vraisemblance :

$$\hat{\theta} = \arg \max_{\theta} \mathbb{P}(X|\theta)$$

Log-vraisemblance

Transformation logarithmique :

$$LL(\theta, X) = \sum_{i=1}^N \log \mathbb{P}(x_i|\theta) = \sum_{i=1}^N \log \left[\sum_{j=1}^c \pi_j \phi(x_i, \theta_j) \right]$$

Estimateur du maximum de log-vraisemblance (MLE) :

$$\hat{\theta} = \arg \max_{\theta} LL(\theta, X)$$

Avantage : Transformation du produit en somme, numériquement plus stable

Mélange gaussien (Gaussian Mixture Model - GMM)

Choix de la famille gaussienne

Puisque ϕ doit être une **fonction de densité de probabilité**, choisir la famille de densités **normales** comme base semble raisonnable (choix **agnostique**) :

$$\phi \in \mathcal{F} = \{\mathcal{N}(\mu, \Sigma)\}$$

Modèle de mélange gaussien :

$$f(x) = \sum_{j=1}^c \pi_j \mathcal{N}(x|\mu_j, \Sigma_j)$$

où $\phi_j(x) := \phi(x, \theta_j) = \mathcal{N}(x|\mu_j, \Sigma_j)$

Avantages du GMM

Universalité : Peut approximer **n'importe quelle densité** (théorème d'approximation universelle)

Linéarité : Permet un système **linéaire** des paramètres lors de la maximisation de la log-vraisemblance

Cas simple : 1 composante

Estimation directe

Paramètres : $\theta = [\mu, \Sigma]$

Problème d'optimisation :

$$\hat{\theta} = \arg \max_{\theta} \sum_i \log e^{-(x_i - \mu)^T \Sigma^{-1} (x_i - \mu)} \Leftrightarrow \hat{\theta} = \arg \min_{\theta} \sum_i (x_i - \mu)^T \Sigma^{-1} (x_i - \mu)$$

Solutions analytiques :

$$\hat{\mu} = \frac{1}{N} \sum_i x_i$$

$$\hat{\Sigma} = \frac{1}{N} \sum_i (x_i - \hat{\mu})(x_i - \hat{\mu})^T$$

Remarque : Solutions identiques à l'estimation empirique standard de moyenne et covariance

Cas complexe : 2 composantes

Problématique

Paramètres :

$$\theta = [\pi_1, \theta_1, \pi_2, \theta_2] = [\pi_1, [\mu_1, \Sigma_1], \pi_2, [\mu_2, \Sigma_2]]$$

avec la contrainte $\pi_1 + \pi_2 = 1$

Log-vraisemblance :

$$LL(\theta, X) = \sum_{i=1}^N \log[\pi_1 \phi(x_i, \theta_1) + \pi_2 \phi(x_i, \theta_2)]$$

Difficulté : Maximisation difficile à cause de la **somme à l'intérieur du logarithme** !

Solution : Algorithme EM

Solution : Algorithme itératif en **2 étapes** (E-M) pour maximiser LL

→ **Expectation-Maximization (EM) algorithm**

Variables latentes et stratégie EM

Introduction des variables latentes

Problème fondamental :

Ce qui manque ici est l'**assignation** de x_i à l'une des 2 composantes ϕ_j

Observation clé :

Si on **connaissait** cette assignation, on traiterai le problème comme **deux fois le cas à 1 composante**

Variables d'assignation binaire

On introduit des **variables latentes (non observées)** : l'assignation binaire $\delta_{ij} \in \{\text{true}, \text{false}\}$ de chaque x_i à la composante ϕ_j :

- $x_i \sim \phi_1 \Rightarrow \delta_{i1} = \text{true}, \delta_{i2} = \text{false}$
- $x_i \sim \phi_2 \Rightarrow \delta_{i1} = \text{false}, \delta_{i2} = \text{true}$

Mais on peut seulement **estimer** $\delta_{ij} \rightarrow$ **stratégie EM**

Étape E (Expectation)

Principe de l'étape E

Paramètres :

$$\theta = [\pi_1, \theta_1, \pi_2, \theta_2] = [\pi_1, [\mu_1, \Sigma_1], \pi_2, [\mu_2, \Sigma_2]]$$

Initialisation :

On suppose connaître une valeur initiale :

$$\theta^0 = [\pi_1^0, \theta_1^0, \pi_2^0, \theta_2^0]$$

Calcul de la responsabilité (Responsibility)

On peut inférer la **contribution statistique** γ_{ij} de chaque donnée x_i à chaque composante ϕ_j (paramétrisée par θ_j^0) :

$$\gamma_{ij}(\theta^0) = \mathbb{P}[\delta_{ij} = \text{true} | \theta^0, X]$$

Formule de Bayes :

$$\gamma_{i1}(\theta^0) = \frac{\pi_1^0 \phi(x_i, \theta_1^0)}{\pi_1^0 \phi(x_i, \theta_1^0) + \pi_2^0 \phi(x_i, \theta_2^0)}$$

Interprétation de la responsabilité

Définition formelle :

γ_{ij} est la **responsabilité** (responsibility) de la composante j pour la donnée i

Signification :

- C'est la **vraisemblance** que x_i soit (purement) modélisée par la composante ϕ_j
 - γ_{ij} représente la **part de** x_i qui est modélisée (générée) par la composante ϕ_j
-

Assignment dure vs douce

Assignment dure (Hard assignment)

On peut utiliser γ_{ij} pour déterminer $\delta_{ij} \rightarrow x_i$ peut être assigné soit à ϕ_1 soit à ϕ_2 (**vote maximum** $\rightarrow$ binarisation)

$\rightarrow$ Assignment de type **K-means** : chaque donnée est assignée à **une et une seule** composante (cluster)

Assignment douce (Soft assignment)

EM est “plus douce” :

Une donnée **contribue** (via γ_{ij}) à **plusieurs composantes** (modes de densité)

EM calcule une **assignment douce** avec :

$$\sum_j \gamma_{ij} = 1 \quad \forall i$$

Avantage : Plus robuste et reflète mieux l'incertitude dans l'assignment

Étape M (Maximization)

Principe de l'étape M

Note : Pour 2 composantes, $\gamma_{i1} + \gamma_{i2} = 1$

Étant donné la **responsabilité** de chaque donnée (γ_{ij}), on peut estimer les paramètres de chaque composante par **maximum de vraisemblance pondéré** :

Estimation des paramètres

Moyennes :

$$\hat{\mu}_1 = \sum_{i=1}^N \frac{\gamma_{i1}}{\sum_{k=1}^N \gamma_{k1}} x_i$$

$$\hat{\mu}_2 = \sum_{i=1}^N \frac{\gamma_{i2}}{\sum_{k=1}^N \gamma_{k2}} x_i$$

Covariances :

$$\hat{\Sigma}_1 = \sum_{i=1}^N \frac{\gamma_{i1}}{\sum_{k=1}^N \gamma_{k1}} (x_i - \hat{\mu}_1)(x_i - \hat{\mu}_1)^T$$

$$\hat{\Sigma}_2 = \sum_{i=1}^N \frac{\gamma_{i2}}{\sum_{k=1}^N \gamma_{k2}} (x_i - \hat{\mu}_2)(x_i - \hat{\mu}_2)^T$$

Poids du mélange :

$$\pi_j = \frac{1}{N} \sum_{i=1}^N \gamma_{ij}$$

Cette formule garantit que $\sum_j \pi_j = 1$

Convergence de l'algorithme EM

Principe itératif

Le cycle alterné **Expectation-Maximization** augmente la vraisemblance des données par rapport au modèle de mélange.

Critère de convergence :

Le processus est itéré jusqu'à **convergence**, c'est-à-dire quand la vraisemblance des données ne change (presque) plus :

$$|LL(\theta^{t+1}, X) - LL(\theta^t, X)| < \epsilon$$

où ϵ est un seuil de tolérance (par exemple $\epsilon = 10^{-6}$)

Propriété de monotonie

Propriété garantie : À chaque itération, $LL(\theta^{t+1}, X) \geq LL(\theta^t, X)$

La log-vraisemblance **ne diminue jamais** (propriété hill-climbing)

Limitations de l'algorithme EM

Sensibilité à l'initialisation

Hill-climbing : L'algorithme dépend des **paramètres initiaux**

Conséquences :

- **Sensible aux maxima locaux :** peut converger vers un optimum local plutôt que global
- Différentes initialisations peuvent donner différents résultats

Stratégies d'initialisation

Méthodes recommandées :

- **K-means :** utiliser le clustering K-means pour initialiser les centres μ_j
- **K-means++ :** version améliorée de K-means avec initialisation intelligente
- **Exécutions multiples :** lancer l'algorithme plusieurs fois avec différentes initialisations et garder la meilleure

Convergence lente

Convergence potentiellement lente, selon :

- La séparation entre les composantes
 - La forme des distributions
 - Le nombre de composantes
-

Généralisation à c composantes

Variables latentes générales

Généralisation :

$$\delta_{i1}, \delta_{i2}, \dots, \delta_{ij}, \dots, \delta_{ic}$$

où $\delta_{ij} = \text{true}$ si la donnée x_i est générée par la composante ϕ_j ($\delta_{ij} = \text{false}$ sinon)

Responsabilité :

γ_{ij} : espérance de δ_{ij} sur toutes les composantes

Paramètres à estimer :

$$\theta = [\pi_j, \theta_j]_{j \in [[c]]} = [\pi_j, [\mu_j, \Sigma_j]]_j$$

Algorithme EM complet pour c composantes

Étape 1 : Initialisation

Initialisation des paramètres :

$$\theta^0 = \{\pi_j^0, \mu_j^0, \Sigma_j^0\}_{j \in [[c]]}$$

Stratégies courantes :

- **Générale** : $\pi_j = 1/c$, μ_j choisi aléatoirement, $\Sigma_j = I_D$
- **Alternative** : utiliser K-means comme initialisation

Étape 2 : E-step

Calcul des responsabilités :

Pour chaque donnée $i \in [[N]]$ et chaque composante $j \in [[c]]$:

$$\gamma_{ij} = \frac{\pi_j \phi(x_i, \theta_j)}{\sum_{k=1}^c \pi_k \phi(x_i, \theta_k)}$$

Étape 3 : M-step

Estimation des paramètres du mélange :

Moyennes :

$$\mu_j = \frac{\sum_{i=1}^N \gamma_{ij} x_i}{\sum_i \gamma_{ij}}$$

Covariances :

$$\Sigma_j = \frac{X_j \Gamma_j X_j^T}{\text{Tr}(\Gamma_j)}$$

où $\Gamma_j = \text{diag}(\gamma_{1j}, \dots, \gamma_{Nj})$ et X_j est centré sur μ_j

Poids :

$$\pi_j = \frac{\sum_i \gamma_{ij}}{N}$$

Étape 4 : Itération

Itérer les étapes 2 et 3 jusqu'à convergence

Modélisation pratique

Paramètres influençant la convergence

La **paramétrisation a priori** du mélange change la convergence :

Paramètres critiques :

1. c : nombre de composantes
2. Σ_j : forme des matrices de covariance (diagonale, complète, paramétrée)

Risques :

- Modèles **trop flexibles** ou **trop rigides** $\rightarrow$ mauvaise convergence ou absence de convergence
- **Sur-paramétrisation** : $D \times D \times c + 2 \times c$ variables

Si N est faible, D grand et c grand $\rightarrow$ **sur-paramétrisation** problématique

Forme de la matrice de covariance

Problème de sur-paramétrisation

Dimension de Σ :

$$\Sigma \in \mathbb{R}^{D \times D}$$

Exemple critique :

Reconnaissance de caractères avec $x_i \in \mathbb{R}^{256}$

$\rightarrow$ Besoin d'estimer $256^2 \times c$ paramètres pour la covariance (avec environ 7000 points de données) !

Stratégies de paramétrisation

Modèles sphériques :

$$\Sigma = \sigma I_D$$

→ **1 paramètre** par composante

Modèles diagonaux :

$$\Sigma = \text{diag}(\sigma_1, \dots, \sigma_D)$$

→ **D paramètres** par composante

Modèles complets :

$$\Sigma \in \mathbb{R}^{D \times D}$$

→ **$O(D^2)$ paramètres** par composante

Conseil pratique : Commencer avec des modèles simples (sphériques) puis augmenter la complexité si nécessaire

Prétraitement : Réduction de dimension par PCA

Problématique en haute dimension

Pour des données de haute dimension (par exemple $D = 256$), les modèles complexes ne convergent pas car le nombre de paramètres p est trop grand.

Solution : PCA préalable

Stratégie recommandée :

1. Appliquer **PCA** pour réduire la dimension de D à K dimensions
2. Appliquer **EM** dans l'espace des K premières composantes principales

Exemple pratique :

- 50 composantes principales reconstruisent 90% du signal
- EM dans l'espace des 50, 10 ou 2 premières composantes principales

Avantages :

- Réduction drastique du nombre de paramètres
 - Élimination du bruit
 - Convergence plus rapide et stable
-

Sélection du nombre de composantes

Principe de parcimonie

Problème :

Plus c est grand, moins de points peuvent être assignés à chaque composante (en moyenne)

Objectif :

Chercher des modèles **parcimonieux**, c'est-à-dire avec un **petit nombre de paramètres** à estimer

Critère d'Information Bayésien (BIC)

Trade-off vraisemblance-complexité :

- Plus c est grand, meilleure est l'estimation de la vraisemblance LL
- Mais plus le modèle est complexe (nombreux paramètres)

Formule du BIC :

$$BIC(\theta, X) = -2 \cdot LL(\theta, X) + |\theta| \log(N)$$

où $|\theta|$ est le **nombre de paramètres** du modèle

Critère de sélection :

$$\hat{\theta} = \arg \min_{\theta} BIC(\theta, X)$$

Composantes du BIC :

- $-2 \cdot LL(\theta, X)$: pénalise les modèles avec mauvaise vraisemblance
- $|\theta| \log(N)$: pénalise la complexité du modèle

Interprétation : Le BIC favorise les modèles qui expliquent bien les données **sans sur-ajustement**

Limitations de la sélection de modèle

Défis pratiques :

- Besoin de **tester tous les modèles** (différentes valeurs de c)
- Dépend de la **convergence** de chaque modèle
- Nécessite souvent un **ajustement manuel** fin

Synthèse des concepts clés

Mélanges gaussiens (GMM)

Généralisation :

Le modèle de mélange gaussien **généralise** les hypothèses sous-jacentes à la PCA et à la LDA

Modélisation et estimation explicites :

- **Modélisation explicite** de la densité
- **Estimation** par maximum de vraisemblance

Classification non supervisée :

Si les composantes sont des classes, la donnée x_i est associée à la classe j pour laquelle :

$$\mathbb{P}(C = j|x_i) \approx \pi_j \phi_j(x_i)$$

est maximisée parmi toutes les classes

Algorithme EM

Caractéristiques :

- Algorithme **itératif** pour maximiser la (log-)vraisemblance
- Principe utilisé dans **de nombreux autres scénarios**
- Basé sur la définition de **variables non observées (latentes)** δ_{ij}

Applications :

- **Probabilistic Latent Semantic Analysis (pLSA)** : EM où les variables cachées sont les concepts latents
 - **Modèles de Markov cachés** (HMM)
 - **Factorisation matricielle**
-

Relation entre GMM et K-means

Comparaison conceptuelle

K-means :

- **Assignation dure** (hard assignment)
- Chaque point appartient à **un seul cluster**
- Minimise la distance euclidienne aux centres

GMM avec EM :

- **Assignation douce** (soft assignment)
- Chaque point a une **probabilité d'appartenance** à chaque composante
- Maximise la vraisemblance selon un modèle probabiliste

GMM comme généralisation de K-means

K-means est un cas particulier de GMM quand :

- Matrices de covariance $\Sigma_j = \sigma^2 I$ (sphériques et identiques)
 - $\sigma \rightarrow 0$: les responsabilités γ_{ij} deviennent binaires
 - Assignment douce $\rightarrow$ assignment dure
-

Questions d'examen types

Questions conceptuelles

Modèle de mélange gaussien :

- Qu'est-ce qu'un modèle de mélange gaussien (GMM) ?
- Pourquoi peut-il être vu comme une modélisation conditionnelle ?
- Comment peut-on l'utiliser pour générer des données ?

Responsabilité :

- Qu'est-ce que la responsabilité (responsibility) ?
- Comment l'interpréter ?

Algorithme EM :

- Pourquoi l'EM pour GMM est-il une MLE ?
- Comment interpréter l'étape E ?
- Comment interpréter l'étape M ?

Questions techniques

Relation avec K-means :

- Discuter la relation entre GMM et K-means
- Qu'est-ce que les assignments dure et douce (hard- et soft-assignments) ?

Convergence et optimisation :

- Comment choisir le nombre de composantes ?
- Quelles sont les stratégies d'initialisation ?
- Comment gérer la sur-paramétrisation ?

Développements mathématiques

Conseil important : Il est **fortement recommandé** de développer l'algèbre contenue dans ce chapitre

Points à maîtriser :

- Dérivation de la log-vraisemblance
 - Calcul des responsabilités par la règle de Bayes
 - Dérivation des équations de mise à jour du M-step
 - Preuve de la monotonie de LL dans l'algorithme EM
-

Concepts mathématiques à maîtriser

Probabilités et statistiques

Fondamentaux :

- Distribution normale multivariée
- Maximum de vraisemblance (MLE)
- Log-vraisemblance
- Règle de Bayes

Modélisation :

- Variables aléatoires latentes
- Probabilités conditionnelles
- Espérance conditionnelle

Optimisation

Techniques :

- Optimisation itérative
- Algorithmes hill-climbing
- Critères de convergence
- Maxima locaux vs globaux

Critères de sélection :

- BIC (Bayesian Information Criterion)

- Trade-off biais-variance
- Parcimonie de modèle