

Table of contents

L'essentiel	2
Introduction et Motivation	2
Le problème fondamental	2
Rappel : Modèles utilisés jusqu'à présent	3
Nouvelle approche : Modélisation de densité	3
Méthodes d'estimation de densité	3
Vue d'ensemble des méthodes	3
Modèles de mélange : Définition	4
Formulation générale	4
Hypothèses du modèle	4
Interprétation probabiliste	4
Les modèles de mélange comme "bosses" dans le paysage	4
Estimation par maximum de vraisemblance (MLE)	5
Rappel sur la vraisemblance	5
Log-vraisemblance	5
Mélange gaussien (GMM)	6
Choix de la famille gaussienne	6
Avantages du GMM	6
Cas simple : 1 composante	6
Estimation directe	6
Le dilemme du poulet et de l'œuf	7
Problématique pour 2 composantes	7
Le cercle vicieux	7
Variables latentes et stratégie EM	8
Introduction des variables latentes	8
Variables d'assignation binaire	8
Les deux étapes magiques de l'EM	8
Étape E (Expectation) : Attribution probabiliste	8
Étape M (Maximization) : Mise à jour des paramètres	9
Assignation dure vs douce	10
Assignation dure (Hard assignment)	10
Assignation douce (Soft assignment)	10
Convergence de l'algorithme EM	11
Principe itératif	11
Propriété de monotonie	11
Limitations de l'algorithme EM	11
Sensibilité à l'initialisation	11
Stratégies d'initialisation	12
Convergence lente	12

Généralisation à c composantes	12
Algorithme EM complet	12
Modélisation pratique	13
Forme de la matrice de covariance	13
Stratégies de paramétrisation	14
Prétraitement : Réduction de dimension par PCA	14
Problématique en haute dimension	14
Solution : PCA préalable	15
Sélection du nombre de composantes	15
Le dilemme de la complexité	15
Critère d'Information Bayésien (BIC)	16
Relation entre GMM et K-means	16
Comparaison conceptuelle	16
GMM comme généralisation de K-means	17
Synthèse des concepts clés	17
Mélanges gaussiens (GMM)	17
Algorithme EM	17

L'essentiel

Introduction et Motivation

L'algorithme **Expectation-Maximization (EM)** est une méthode d'**estimation de facteurs latents** dans un contexte **non supervisé** de modélisation conditionnelle.

Le problème fondamental

Imaginez que vous êtes dans une salle avec plusieurs instruments de musique qui jouent en même temps. Vous enregistrez le son global (le mélange). Comment retrouver **les caractéristiques de chaque instrument** (hauteur, volume) sans savoir qui joue quoi à quel moment ?

C'est exactement le problème que résout l'algorithme EM pour les modèles de mélange : **séparer un mélange en ses composantes sous-jacentes** quand on ne connaît pas l'origine de chaque observation.

Concept clé : L'EM est utilisé quand certaines informations sont **manquantes** (ici, l'étiquette de quelle composante a généré chaque donnée). On appelle ces informations manquantes des **variables latentes**.

Rappel : Modèles utilisés jusqu'à présent

Modèles à composantes (PCA) :

- Critère basé sur la **variance** de données centrées
- Distribution implicite : **normale**

Modèles discriminants (LDA) :

- Variance des données projetées pour les modèles intra-classe (within) et inter-classe (between)

Point commun : La distribution est **fixée** (essentiellement normale) et on cherche ses paramètres θ (par exemple $\theta = [\mu, \Sigma]$).

Nouvelle approche : Modélisation de densité

Alternative : Chercher un modèle pour la **densité des données**.

Soit $f_{\theta}(x) : \Omega \rightarrow \mathbb{R}$ la **densité des données**.

Méthodes d'estimation de densité

Vue d'ensemble des méthodes

Méthodes non-paramétriques :

- **k-Nearest Neighbors (kNN)** : estimation basée sur les k plus proches voisins
- **Fenêtres de Parzen** : estimation par noyaux
- **Réseaux RBF** : fonctions à base radiale
- **Histogrammes** : discrétisation de l'espace

Méthodes paramétriques :

- **Modèles de mélange** (Mixture models) : le focus de ce cours
-

Modèles de mélange : Définition

Formulation générale

La densité $f(x)$ est générée par c fonctions de “base” ϕ (composantes), issues d’une famille $\mathcal{F}$:

$$f(x) = \sum_{j=1}^c \pi_j \phi(x, \theta_j)$$

Composantes du modèle :

- $\pi_j \in \mathbb{R}$: **paramètres du mélange** (mixture parameters)
- $\phi(x, \theta_j) \in \mathcal{F}$: **fonctions de base** contrôlées par les paramètres θ_j

Hypothèses du modèle

Trois hypothèses fondamentales :

- Le **nombre de composantes** $c \in \mathbb{N}^*$ est **connu**
 - La **famille de fonctions** $\mathcal{F}$ est **connue**
 - Les **étiquettes** (class labels) sont **inconnues** (contexte non supervisé)
-

Interprétation probabiliste

Les modèles de mélange comme “bosses” dans le paysage

Imaginez un paysage de montagnes avec plusieurs sommets. Chaque sommet représente un groupe dans vos données. Un modèle de mélange gaussien modélise ce paysage comme une **superposition de collines gaussiennes**.

La densité $f(x)$ représente un **processus aléatoire** où x est tiré d’un ensemble d’états ω_j avec probabilité a priori $\mathbb{P}(\omega_j)$.

$$f(x) = \sum_{j=1}^c \pi_j \phi(x, \theta_j) = \mathbb{P}(x|\theta) = \sum_{j=1}^c \mathbb{P}(\omega_j) \mathbb{P}(x|\omega_j, \theta_j)$$

Par identification :

- $\pi_j = \mathbb{P}(\omega_j)$ avec la contrainte $\sum_j \pi_j = 1$
- $\phi(x, \theta_j) = \mathbb{P}(x|\omega_j, \theta_j)$ est la **probabilité conditionnelle** que x soit généré par l'état ω_j

Estimation par maximum de vraisemblance (MLE)

Rappel sur la vraisemblance

Soit $X = \{x_1, \dots, x_N\}$ des échantillons **non étiquetés** générés par le mélange $f(x) = \mathbb{P}(x|\theta)$.

Paramètres à inférer :

$$\theta = [\pi_j, \theta_j]_{j \in [c]}$$

En supposant les données **indépendantes et identiquement distribuées** (i.i.d.) :

$$\mathbb{P}(X|\theta) \stackrel{\text{i.i.d.}}{=} \prod_{i=1}^N \mathbb{P}(x_i|\theta)$$

Estimateur de vraisemblance :

$$\hat{\theta} = \arg \max_{\theta} \mathbb{P}(X|\theta)$$

Log-vraisemblance

Transformation logarithmique :

$$LL(\theta, X) = \sum_{i=1}^N \log \mathbb{P}(x_i|\theta) = \sum_{i=1}^N \log \left[\sum_{j=1}^c \pi_j \phi(x_i, \theta_j) \right]$$

Estimateur du maximum de log-vraisemblance (MLE) :

$$\hat{\theta} = \arg \max_{\theta} LL(\theta, X)$$

Avantage : Transformation du produit en somme, numériquement plus stable.

Mélange gaussien (GMM)

Choix de la famille gaussienne

Puisque ϕ doit être une **fonction de densité de probabilité**, choisir la famille de densités **normales** comme base semble raisonnable (choix **agnostique**) :

$$\phi \in \mathcal{F} = \{\mathcal{N}(\mu, \Sigma)\}$$

Modèle de mélange gaussien :

$$f(x) = \sum_{j=1}^c \pi_j \mathcal{N}(x | \mu_j, \Sigma_j)$$

où $\phi_j(x) := \phi(x, \theta_j) = \mathcal{N}(x | \mu_j, \Sigma_j)$.

Avantages du GMM

Universalité : Peut approximer **n'importe quelle densité** (théorème d'approximation universelle).

Linéarité : Permet un système **linéaire** des paramètres lors de la maximisation de la log-vraisemblance.

Cas simple : 1 composante

Estimation directe

Paramètres : $\theta = [\mu, \Sigma]$

i Détails mathématiques : Optimisation directe

Problème d'optimisation :

$$\hat{\theta} = \arg \max_{\theta} \sum_i \log e^{-(x_i - \mu)^T \Sigma^{-1} (x_i - \mu)} \Leftrightarrow \hat{\theta} = \arg \min_{\theta} \sum_i (x_i - \mu)^T \Sigma^{-1} (x_i - \mu)$$

Solutions analytiques :

$$\hat{\mu} = \frac{1}{N} \sum_i x_i$$

$$\hat{\Sigma} = \frac{1}{N} \sum_i (x_i - \hat{\mu})(x_i - \hat{\mu})^T$$

Remarque : Solutions identiques à l'estimation empirique standard de moyenne et covariance.

Le dilemme du poulet et de l'œuf

Problématique pour 2 composantes

Paramètres :

$$\theta = [\pi_1, \theta_1, \pi_2, \theta_2] = [\pi_1, [\mu_1, \Sigma_1], \pi_2, [\mu_2, \Sigma_2]]$$

avec la contrainte $\pi_1 + \pi_2 = 1$.

Log-vraisemblance :

$$LL(\theta, X) = \sum_{i=1}^N \log[\pi_1 \phi(x_i, \theta_1) + \pi_2 \phi(x_i, \theta_2)]$$

Difficulté : Maximisation difficile à cause de la **somme à l'intérieur du logarithme !**

Le cercle vicieux

Pour estimer les paramètres (μ_j, Σ_j) , il faudrait connaître l'origine de chaque point. Pour connaître l'origine de chaque point, il faudrait connaître les paramètres.

C'est le problème classique du "poulet et de l'œuf" !

La solution EM : Au lieu de chercher une solution parfaite d'un coup, l'EM procède par approximations successives.

Variables latentes et stratégie EM

Introduction des variables latentes

Problème fondamental :

Ce qui manque ici est l'**assignation** de x_i à l'une des 2 composantes ϕ_j .

Observation clé :

Si on **connaissait** cette assignation, on traiterai le problème comme **deux fois le cas à 1 composante**.

Variables d'assignation binaire

On introduit des **variables latentes (non observées)** : l'assignation binaire $\delta_{ij} \in \{\text{true}, \text{false}\}$ de chaque x_i à la composante ϕ_j :

- $x_i \sim \phi_1 \Rightarrow \delta_{i1} = \text{true}, \delta_{i2} = \text{false}$
- $x_i \sim \phi_2 \Rightarrow \delta_{i1} = \text{false}, \delta_{i2} = \text{true}$

Mais on peut seulement **estimer** $\delta_{ij} \rightarrow$ **stratégie EM**.

Les deux étapes magiques de l'EM

Étape E (Expectation) : Attribution probabiliste

Paramètres :

$$\theta = [\pi_1, \theta_1, \pi_2, \theta_2]$$

Initialisation :

On suppose connaître une valeur initiale $\theta^0 = [\pi_1^0, \theta_1^0, \pi_2^0, \theta_2^0]$.

Calcul de la responsabilité (Responsibility) :

On peut inférer la **contribution statistique** γ_{ij} de chaque donnée x_i à chaque composante ϕ_j :

$$\gamma_{ij}(\theta^0) = \mathbb{P}[\delta_{ij} = \text{true} | \theta^0, X]$$

i Détails mathématiques : Formule de Bayes

Formule de Bayes :

$$\gamma_{i1}(\theta^0) = \frac{\pi_1^0 \phi(x_i, \theta_1^0)}{\pi_1^0 \phi(x_i, \theta_1^0) + \pi_2^0 \phi(x_i, \theta_2^0)}$$

Définition formelle :

γ_{ij} est la **responsabilité** (responsibility) de la composante j pour la donnée i .

Signification :

- C'est la **vraisemblance** que x_i soit (purement) modélisée par la composante ϕ_j
- γ_{ij} représente la **part de** x_i qui est modélisée (générée) par la composante ϕ_j

Question : Sachant les paramètres actuels, quelle est la probabilité que chaque point vienne de chaque composante ?

C'est une **attribution douce** (soft assignment) : chaque point appartient partiellement à toutes les composantes.

Étape M (Maximization) : Mise à jour des paramètres

Note : Pour 2 composantes, $\gamma_{i1} + \gamma_{i2} = 1$.

Étant donné la **responsabilité** de chaque donnée (γ_{ij}), on peut estimer les paramètres de chaque composante par **maximum de vraisemblance pondéré**.

i Détails mathématiques : Estimation des paramètres

Moyennes :

$$\hat{\mu}_1 = \sum_{i=1}^N \frac{\gamma_{i1}}{\sum_{k=1}^N \gamma_{k1}} x_i$$
$$\hat{\mu}_2 = \sum_{i=1}^N \frac{\gamma_{i2}}{\sum_{k=1}^N \gamma_{k2}} x_i$$

Covariances :

$$\hat{\Sigma}_1 = \sum_{i=1}^N \frac{\gamma_{i1}}{\sum_{k=1}^N \gamma_{k1}} (x_i - \hat{\mu}_1)(x_i - \hat{\mu}_1)^T$$
$$\hat{\Sigma}_2 = \sum_{i=1}^N \frac{\gamma_{i2}}{\sum_{k=1}^N \gamma_{k2}} (x_i - \hat{\mu}_2)(x_i - \hat{\mu}_2)^T$$

Poids du mélange :

$$\pi_j = \frac{1}{N} \sum_{i=1}^N \gamma_{ij}$$

Cette formule garantit que $\sum_j \pi_j = 1$.

Question : Sachant les responsabilités, quelles sont les meilleures estimations des paramètres ?

Recalcul des paramètres :

- μ_j = moyenne pondérée des points (pondérée par γ_{ij})
 - Σ_j = variance pondérée des points
 - π_j = proportion moyenne de la composante
-

Assignment dure vs douce

Assignment dure (Hard assignment)

On peut utiliser γ_{ij} pour déterminer $\delta_{ij} \rightarrow x_i$ peut être assigné soit à ϕ_1 soit à ϕ_2 (**vote maximum** $\rightarrow$ binarisation).

$\rightarrow$ Assignment de type **K-means** : chaque donnée est assignée à **une et une seule** composante (cluster).

Assignment douce (Soft assignment)

EM est “plus douce” :

Une donnée **contribue** (via γ_{ij}) à **plusieurs composantes** (modes de densité).

EM calcule une **assignment douce** avec :

$$\sum_j \gamma_{ij} = 1 \quad \forall i$$

Avantage : Plus robuste et reflète mieux l’incertitude dans l’assignation.

Convergence de l'algorithme EM

Principe itératif

Le cycle alterné **Expectation-Maximization** augmente la vraisemblance des données par rapport au modèle de mélange.

Critère de convergence :

Le processus est itéré jusqu'à **convergence**, c'est-à-dire quand la vraisemblance des données ne change (presque) plus :

$$|LL(\theta^{t+1}, X) - LL(\theta^t, X)| < \epsilon$$

où ϵ est un seuil de tolérance (par exemple $\epsilon = 10^{-6}$).

Propriété de monotonie

Propriété garantie : À chaque itération, $LL(\theta^{t+1}, X) \geq LL(\theta^t, X)$.

La log-vraisemblance **ne diminue jamais** (propriété hill-climbing).

Limitations de l'algorithme EM

Sensibilité à l'initialisation

Hill-climbing : L'algorithme dépend des **paramètres initiaux**.

Conséquences :

- **Sensible aux maxima locaux :** peut converger vers un optimum local plutôt que global
- Différentes initialisations peuvent donner différents résultats

L'initialisation est cruciale : L'EM est un algorithme "hill-climbing" : il gravit la colline de vraisemblance à partir de son point de départ. S'il part d'un mauvais endroit, il peut rester coincé dans un **maximum local** (petit sommet) au lieu d'atteindre le **maximum global** (plus haut sommet).

Stratégies d'initialisation

Méthodes recommandées :

- **K-means** : utiliser le clustering K-means pour initialiser les centres μ_j
- **K-means++** : version améliorée de K-means avec initialisation intelligente
- **Exécutions multiples** : lancer l'algorithme plusieurs fois avec différentes initialisations et garder la meilleure

Convergence lente

Convergence potentiellement lente, selon :

- La séparation entre les composantes
 - La forme des distributions
 - Le nombre de composantes
-

Généralisation à c composantes

Algorithme EM complet

Étape 1 : Initialisation

Initialisation des paramètres :

$$\theta^0 = \{\pi_j^0, \mu_j^0, \Sigma_j^0\}_{j \in [[c]]}$$

Stratégies courantes :

- **Générale** : $\pi_j = 1/c$, μ_j choisi aléatoirement, $\Sigma_j = I_D$
- **Alternative** : utiliser K-means comme initialisation

Étape 2 : E-step

Calcul des responsabilités pour chaque donnée $i \in [[N]]$ et chaque composante $j \in [[c]]$:

$$\gamma_{ij} = \frac{\pi_j \phi(x_i, \theta_j)}{\sum_{k=1}^c \pi_k \phi(x_i, \theta_k)}$$

Étape 3 : M-step

Estimation des paramètres du mélange :

$$\mu_j = \frac{\sum_{i=1}^N \gamma_{ij} x_i}{\sum_i \gamma_{ij}}$$

$$\Sigma_j = \frac{X_j \Gamma_j X_j^T}{\text{Tr}(\Gamma_j)}$$

où $\Gamma_j = \text{diag}(\gamma_{1j}, \dots, \gamma_{Nj})$ et X_j est centré sur μ_j .

$$\pi_j = \frac{\sum_i \gamma_{ij}}{N}$$

Étape 4 : Itération

Itérer les étapes 2 et 3 jusqu'à convergence.

Modélisation pratique

Forme de la matrice de covariance

Problème de sur-paramétrisation :

$$\Sigma \in \mathbb{R}^{D \times D}$$

Exemple critique :

Reconnaissance de caractères avec $x_i \in \mathbb{R}^{256} \rightarrow$ Besoin d'estimer $256^2 \times c$ paramètres pour la covariance !

Stratégies de paramétrisation

Modèles sphériques :

$$\Sigma = \sigma I_D$$

→ **1 paramètre** par composante

Modèles diagonaux :

$$\Sigma = \text{diag}(\sigma_1, \dots, \sigma_D)$$

→ **D paramètres** par composante

Modèles complets :

$$\Sigma \in \mathbb{R}^{D \times D}$$

→ **$O(D^2)$ paramètres** par composante

Conseil pratique : Commencer avec des modèles simples (sphériques) puis augmenter la complexité si nécessaire.

Prétraitement : Réduction de dimension par PCA

Problématique en haute dimension

Pour des données de haute dimension (par exemple $D = 256$), les modèles complexes ne convergent pas car le nombre de paramètres p est trop grand.

Solution : PCA préalable

Stratégie recommandée :

- Appliquer **PCA** pour réduire la dimension de D à K dimensions
- Appliquer **EM** dans l'espace des K premières composantes principales

Exemple pratique :

- 50 composantes principales reconstruisent 90% du signal
- EM dans l'espace des 50, 10 ou 2 premières composantes principales

Avantages :

- Réduction drastique du nombre de paramètres
 - Élimination du bruit
 - Convergence plus rapide et stable
-

Sélection du nombre de composantes

Le dilemme de la complexité

Problème :

Plus c est grand, moins de points peuvent être assignés à chaque composante (en moyenne).

Objectif :

Chercher des modèles **parcimonieux**, c'est-à-dire avec un **petit nombre de paramètres** à estimer.

- **K trop petit** : Sous-ajustement (underfitting) → modèle trop simple, ne capture pas la structure
- **K trop grand** : Sur-ajustement (overfitting) → modèle trop complexe, capture le bruit

Critère d'Information Bayésien (BIC)

Trade-off vraisemblance-complexité :

- Plus c est grand, meilleure est l'estimation de la vraisemblance LL
- Mais plus le modèle est complexe (nombreux paramètres)

Formule du BIC :

$$BIC(\theta, X) = -2 \cdot LL(\theta, X) + |\theta| \log(N)$$

où $|\theta|$ est le **nombre de paramètres** du modèle.

Critère de sélection :

$$\hat{\theta} = \arg \min_{\theta} BIC(\theta, X)$$

Composantes du BIC :

- $-2 \cdot LL(\theta, X)$: pénalise les modèles avec mauvaise vraisemblance
- $|\theta| \log(N)$: pénalise la complexité du modèle

Interprétation : Le BIC favorise les modèles qui expliquent bien les données **sans sur-ajustement**.

Relation entre GMM et K-means

Comparaison conceptuelle

K-means :

- **Assignment dure** (hard assignment)
- Chaque point appartient à **un seul cluster**
- Minimise la distance euclidienne aux centres

GMM avec EM :

- **Assignment douce** (soft assignment)
- Chaque point a une **probabilité d'appartenance** à chaque composante
- Maximise la vraisemblance selon un modèle probabiliste

GMM comme généralisation de K-means

K-means est un cas particulier de GMM quand :

- Matrices de covariance $\Sigma_j = \sigma^2 I$ (sphériques et identiques)
 - $\sigma \rightarrow 0$: les responsabilités γ_{ij} deviennent binaires
 - Assignment douce $\rightarrow$ assignment dure
-

Synthèse des concepts clés

Mélanges gaussiens (GMM)

Généralisation :

Le modèle de mélange gaussien **généralise** les hypothèses sous-jacentes à la PCA et à la LDA.

Modélisation et estimation explicites :

- **Modélisation explicite** de la densité
- **Estimation** par maximum de vraisemblance

Classification non supervisée :

Si les composantes sont des classes, la donnée x_i est associée à la classe j pour laquelle :

$$\mathbb{P}(C = j | x_i) \approx \pi_j \phi_j(x_i)$$

est maximisée parmi toutes les classes.

Algorithme EM

Caractéristiques :

- Algorithme **itératif** pour maximiser la (log-)vraisemblance
- Principe utilisé dans **de nombreux autres scénarios**
- Basé sur la définition de **variables non observées (latentes)** δ_{ij}

Applications :

- **Probabilistic Latent Semantic Analysis (pLSA)** : EM où les variables cachées sont les concepts latents

- **Modèles de Markov cachés (HMM)**
 - **Factorisation matricielle**
-

 Fiche de révision condensée

En 30 secondes :

- EM = algorithme pour estimer modèles avec variables cachées
- Deux étapes : E (calcul responsabilités), M (mise à jour paramètres)
- Pour GMM : modélise données comme mélange de gaussiennes
- Avantage : attribution douce, modèle probabiliste
- Défis : initialisation, choix de K, maxima locaux
- Utilisations : clustering, séparation sources, segmentation
- Parenté : généralise K-means, lié à d'autres modèles latents

 Concepts mathématiques à maîtriser

Probabilités et statistiques :

- Distribution normale multivariée
- Maximum de vraisemblance (MLE)
- Log-vraisemblance
- Règle de Bayes
- Variables aléatoires latentes
- Probabilités conditionnelles
- Espérance conditionnelle

Optimisation :

- Optimisation itérative
- Algorithmes hill-climbing
- Critères de convergence
- Maxima locaux vs globaux
- BIC (Bayesian Information Criterion)
- Trade-off biais-variance
- Parcimonie de modèle