

Table of contents

L'essentiel	2
Introduction et Motivation	2
Le problème fondamental	2
Rappel : Modèles utilisés jusqu'à présent	3
Nouvelle approche : Modélisation de densité	3
Méthodes d'estimation de densité	3
Vue d'ensemble des méthodes	3
Modèles de mélange : Définition	4
Formulation générale	4
Hypothèses du modèle	4
Interprétation probabiliste	5
Les modèles de mélange comme "bosses" dans le paysage	5
Estimation par maximum de vraisemblance (MLE)	5
Rappel sur la vraisemblance	5
Log-vraisemblance	6
Mélange gaussien (GMM)	6
Choix de la famille gaussienne	6
Avantages du GMM	7
Cas simple : 1 composante	7
Estimation directe	7
Le dilemme du poulet et de l'œuf	7
Problématique pour 2 composantes	7
Le cercle vicieux	8
Variables latentes et stratégie EM	8
Introduction des variables latentes	8
Variables d'assignation binaire	9
Les deux étapes magiques de l'EM	9
Étape E (Expectation) : Attribution probabiliste	9
Étape M (Maximization) : Mise à jour des paramètres	10
Assignation dure vs douce	11
Assignation dure (Hard assignment)	11
Assignation douce (Soft assignment)	11
Convergence de l'algorithme EM	12
Principe itératif	12
Propriété de monotonie	12
Limitations de l'algorithme EM	13
Sensibilité à l'initialisation	13
Stratégies d'initialisation	13
Convergence lente	13

Algorithme EM complet pour c composantes	13
Étape 1 : Initialisation	13
Étape 2 : E-step	14
Étape 3 : M-step	14
Étape 4 : Itération	14
Modélisation pratique	15
Forme de la matrice de covariance	15
Stratégies de paramétrisation	15
Prétraitement : Réduction de dimension par PCA	16
Problématique en haute dimension	16
Solution : PCA préalable	16
Sélection du nombre de composantes	16
Le dilemme de la complexité	16
Critère d'Information Bayésien (BIC)	17
Relation entre GMM et K-means	17
Comparaison conceptuelle	17
GMM comme généralisation de K-means	18
Pièges à éviter et bonnes pratiques	18
Piège 1 : Les “Composantes Fantômes”	18
Piège 2 : La Convergence Prématurée	18
Piège 3 : L'Interprétation Abusive	18
Synthèse des concepts clés	19
Mélanges gaussiens (GMM)	19
Algorithme EM	19

L'essentiel

Introduction et Motivation

L'algorithme **Expectation-Maximization (EM)** est une méthode d'**estimation de facteurs latents** dans un contexte **non supervisé** de modélisation conditionnelle.

Le problème fondamental

Imaginez que vous êtes dans une salle avec plusieurs instruments de musique qui jouent en même temps. Vous enregistrez le son global (le mélange). Comment retrouver **les caractéristiques de chaque instrument** (hauteur, volume) sans savoir qui joue quoi à quel moment ?

C'est exactement le problème que résout l'algorithme EM pour les modèles de mélange : **séparer un mélange en ses composantes sous-jacentes** quand on ne connaît pas l'origine de chaque observation.

Le cœur du problème :

Avec les modèles de mélange, nous avons **deux types d'inconnues** qui dépendent l'une de l'autre :

- **Les paramètres** de chaque composante (moyenne, variance)
- **L'origine** de chaque point (quelle composante l'a générée)

C'est un **cercle vicieux** : pour connaître l'un, il faut connaître l'autre.

Rappel : Modèles utilisés jusqu'à présent

Modèles à composantes (PCA) :

- Critère basé sur la **variance** de données centrées
- Distribution implicite : **normale**

Modèles discriminants (LDA) :

- Variance des données projetées pour les modèles intra-classe (within) et inter-classe (between)

Point commun : La distribution est **fixée** (essentiellement normale) et on cherche ses paramètres θ (par exemple $\theta = [\mu, \Sigma]$).

Nouvelle approche : Modélisation de densité

Alternative : Chercher un modèle pour la **densité des données**.

Soit $f_\theta(x) : \Omega \rightarrow \mathbb{R}$ la **densité des données**.

Méthodes d'estimation de densité

Vue d'ensemble des méthodes

Méthodes non-paramétriques :

- **k-Nearest Neighbors (kNN)** : estimation basée sur les k plus proches voisins
- **Fenêtres de Parzen** : estimation par noyaux
- **Réseaux RBF** : fonctions à base radiale
- **Histogrammes** : discrétisation de l'espace

Méthodes paramétriques :

- **Modèles de mélange** (Mixture models) : le focus de ce cours
-

Modèles de mélange : Définition

Formulation générale

La densité $f(x)$ est générée par c fonctions de “base” ϕ (composantes), issues d’une famille $\mathcal{F}$:

$$f(x) = \sum_{j=1}^c \pi_j \phi(x, \theta_j)$$

Composantes du modèle :

- $\pi_j \in \mathbb{R}$: **paramètres du mélange** (mixture parameters)
- $\phi(x, \theta_j) \in \mathcal{F}$: **fonctions de base** contrôlées par les paramètres θ_j

Hypothèses du modèle

Trois hypothèses fondamentales :

- Le **nombre de composantes** $c \in \mathbb{N}^*$ est **connu**
 - La **famille de fonctions** $\mathcal{F}$ est **connue**
 - Les **étiquettes** (class labels) sont **inconnues** (contexte non supervisé)
-

Interprétation probabiliste

Les modèles de mélange comme “bosses” dans le paysage

Imaginez que vos données forment un **paysage de montagnes**. Chaque montagne représente un groupe naturel dans vos données. Un modèle de mélange gaussien (GMM) représente ce paysage comme une **superposition de collines gaussiennes**.

La densité $f(x)$ représente un **processus aléatoire** où x est tiré d'un ensemble d'états ω_j avec probabilité a priori $\mathbb{P}(\omega_j)$.

$$f(x) = \sum_{j=1}^c \pi_j \phi(x, \theta_j) = \mathbb{P}(x|\theta) = \sum_{j=1}^c \mathbb{P}(\omega_j) \mathbb{P}(x|\omega_j, \theta_j)$$

Par identification :

- $\pi_j = \mathbb{P}(\omega_j)$ avec la contrainte $\sum_j \pi_j = 1$
- $\phi(x, \theta_j) = \mathbb{P}(x|\omega_j, \theta_j)$ est la **probabilité conditionnelle** que x soit généré par l'état ω_j

Pourquoi des gaussiennes ?

- **Théorème central limite** : beaucoup de phénomènes naturels sont gaussiens
- **Universalité** : un mélange de gaussiennes peut approximer n'importe quelle densité
- **Calculabilité** : les formules sont mathématiquement maniables

Estimation par maximum de vraisemblance (MLE)

Rappel sur la vraisemblance

Soit $X = \{x_1, \dots, x_N\}$ des échantillons **non étiquetés** générés par le mélange $f(x) = \mathbb{P}(x|\theta)$.

Paramètres à inférer :

$$\theta = [\pi_j, \theta_j]_{j \in [c]}$$

En supposant les données **indépendantes et identiquement distribuées** (i.i.d.) :

$$\mathbb{P}(X|\theta) \stackrel{\text{i.i.d.}}{=} \prod_{i=1}^N \mathbb{P}(x_i|\theta)$$

Estimateur de vraisemblance :

$$\hat{\theta} = \arg \max_{\theta} \mathbb{P}(X|\theta)$$

Log-vraisemblance

Transformation logarithmique :

$$LL(\theta, X) = \sum_{i=1}^N \log \mathbb{P}(x_i|\theta) = \sum_{i=1}^N \log \left[\sum_{j=1}^c \pi_j \phi(x_i, \theta_j) \right]$$

Estimateur du maximum de log-vraisemblance (MLE) :

$$\hat{\theta} = \arg \max_{\theta} LL(\theta, X)$$

Avantage : Transformation du produit en somme, numériquement plus stable.

Mélange gaussien (GMM)

Choix de la famille gaussienne

Puisque ϕ doit être une **fonction de densité de probabilité**, choisir la famille de densités **normales** comme base semble raisonnable (choix **agnostique**) :

$$\phi \in \mathcal{F} = \{\mathcal{N}(\mu, \Sigma)\}$$

Modèle de mélange gaussien :

$$f(x) = \sum_{j=1}^c \pi_j \mathcal{N}(x|\mu_j, \Sigma_j)$$

où $\phi_j(x) := \phi(x, \theta_j) = \mathcal{N}(x|\mu_j, \Sigma_j)$.

Avantages du GMM

Universalité : Peut approximer **n'importe quelle densité** (théorème d'approximation universelle).

Linéarité : Permet un système **linéaire** des paramètres lors de la maximisation de la log-vraisemblance.

Cas simple : 1 composante

Estimation directe

Paramètres : $\theta = [\mu, \Sigma]$

i Détails mathématiques : Optimisation directe

Problème d'optimisation :

$$\hat{\theta} = \arg \max_{\theta} \sum_i \log e^{-(x_i - \mu)^T \Sigma^{-1} (x_i - \mu)} \Leftrightarrow \hat{\theta} = \arg \min_{\theta} \sum_i (x_i - \mu)^T \Sigma^{-1} (x_i - \mu)$$

Solutions analytiques :

$$\hat{\mu} = \frac{1}{N} \sum_i x_i$$

$$\hat{\Sigma} = \frac{1}{N} \sum_i (x_i - \hat{\mu})(x_i - \hat{\mu})^T$$

Remarque : Solutions identiques à l'estimation empirique standard de moyenne et covariance.

Le dilemme du poulet et de l'œuf

Problématique pour 2 composantes

Paramètres :

$$\theta = [\pi_1, \theta_1, \pi_2, \theta_2] = [\pi_1, [\mu_1, \Sigma_1], \pi_2, [\mu_2, \Sigma_2]]$$

avec la contrainte $\pi_1 + \pi_2 = 1$.

Log-vraisemblance :

$$LL(\theta, X) = \sum_{i=1}^N \log[\pi_1 \phi(x_i, \theta_1) + \pi_2 \phi(x_i, \theta_2)]$$

Difficulté : Maximisation difficile à cause de la **somme à l'intérieur du logarithme !**

Le cercle vicieux

Pour estimer les paramètres (μ_j, Σ_j) , il faudrait connaître l'origine de chaque point. Pour connaître l'origine de chaque point, il faudrait connaître les paramètres.

C'est le problème classique du "poulet et de l'œuf" !

La solution EM : Au lieu de chercher une solution parfaite d'un coup, l'EM procède par **approximations successives** en alternant deux questions.

Variables latentes et stratégie EM

Introduction des variables latentes

Problème fondamental :

Ce qui manque ici est l'**assignation** de x_i à l'une des 2 composantes ϕ_j .

Observation clé :

Si on **connaissait** cette assignation, on traiterai le problème comme **deux fois le cas à 1 composante**.

Variables d'assignation binaire

On introduit des **variables latentes (non observées)** : l'assignation binaire $\delta_{ij} \in \{\text{true}, \text{false}\}$ de chaque x_i à la composante ϕ_j :

- $x_i \sim \phi_1 \Rightarrow \delta_{i1} = \text{true}, \delta_{i2} = \text{false}$
- $x_i \sim \phi_2 \Rightarrow \delta_{i1} = \text{false}, \delta_{i2} = \text{true}$

Mais on peut seulement **estimer** $\delta_{ij} \rightarrow$ **stratégie EM**.

Les deux étapes magiques de l'EM

Étape E (Expectation) : Attribution probabiliste

Paramètres :

$$\theta = [\pi_1, \theta_1, \pi_2, \theta_2]$$

Initialisation :

On suppose connaître une valeur initiale $\theta^0 = [\pi_1^0, \theta_1^0, \pi_2^0, \theta_2^0]$.

Calcul de la responsabilité (Responsibility) :

On peut inférer la **contribution statistique** γ_{ij} de chaque donnée x_i à chaque composante ϕ_j :

$$\gamma_{ij}(\theta^0) = \mathbb{P}[\delta_{ij} = \text{true} | \theta^0, X]$$

i Détails mathématiques : Formule de Bayes

Formule de Bayes :

$$\gamma_{i1}(\theta^0) = \frac{\pi_1^0 \phi(x_i, \theta_1^0)}{\pi_1^0 \phi(x_i, \theta_1^0) + \pi_2^0 \phi(x_i, \theta_2^0)}$$

Définition formelle :

γ_{ij} est la **responsabilité** (responsibility) de la composante j pour la donnée i .

Signification :

- C'est la **vraisemblance** que x_i soit (purement) modélisée par la composante ϕ_j
- γ_{ij} représente la **part de** x_i qui est modélisée (générée) par la composante ϕ_j

Interprétation générale :

Pour c composantes :

$$\gamma_{ij} = \frac{\pi_j \phi(x_i, \theta_j)}{\sum_{k=1}^c \pi_k \phi(x_i, \theta_k)}$$

Question : Sachant les paramètres actuels, quelle est la probabilité que chaque point vienne de chaque composante ?

C'est une **attribution douce** (soft assignment). Contrairement au K-means qui dit "ce point est à 100% dans ce cluster", l'EM dit "ce point est à 60% dans le cluster A, 30% dans B, 10% dans C".

Étape M (Maximization) : Mise à jour des paramètres

Note : Pour 2 composantes, $\gamma_{i1} + \gamma_{i2} = 1$.

Étant donné la **responsabilité** de chaque donnée (γ_{ij}), on peut estimer les paramètres de chaque composante par **maximum de vraisemblance pondéré**.

i Détails mathématiques : Estimation des paramètres

Moyennes :

$$\hat{\mu}_1 = \sum_{i=1}^N \frac{\gamma_{i1}}{\sum_{k=1}^N \gamma_{k1}} x_i = \frac{\sum_{i=1}^N \gamma_{i1} x_i}{\sum_{i=1}^N \gamma_{i1}}$$
$$\hat{\mu}_2 = \sum_{i=1}^N \frac{\gamma_{i2}}{\sum_{k=1}^N \gamma_{k2}} x_i = \frac{\sum_{i=1}^N \gamma_{i2} x_i}{\sum_{i=1}^N \gamma_{i2}}$$

Covariances :

$$\hat{\Sigma}_1 = \sum_{i=1}^N \frac{\gamma_{i1}}{\sum_{k=1}^N \gamma_{k1}} (x_i - \hat{\mu}_1)(x_i - \hat{\mu}_1)^T$$
$$\hat{\Sigma}_2 = \sum_{i=1}^N \frac{\gamma_{i2}}{\sum_{k=1}^N \gamma_{k2}} (x_i - \hat{\mu}_2)(x_i - \hat{\mu}_2)^T$$

Poids du mélange :

$$\pi_j = \frac{1}{N} \sum_{i=1}^N \gamma_{ij}$$

Cette formule garantit que $\sum_j \pi_j = 1$.

Forme générale pour c composantes :

$$\mu_j = \frac{\sum_{i=1}^N \gamma_{ij} x_i}{\sum_i \gamma_{ij}}$$

$$\Sigma_j = \frac{X_j \Gamma_j X_j^T}{\text{Tr}(\Gamma_j)}$$

où $\Gamma_j = \text{diag}(\gamma_{1j}, \dots, \gamma_{Nj})$ et X_j est centré sur μ_j .

Question : Sachant les responsabilités, quelles sont les meilleures estimations des paramètres ?

Recalcul des paramètres :

- μ_j = moyenne pondérée des points (pondérée par γ_{ij})
- Σ_j = variance pondérée des points
- π_j = proportion moyenne de la composante

Assignment dure vs douce

Assignment dure (Hard assignment)

On peut utiliser γ_{ij} pour déterminer $\delta_{ij} \rightarrow x_i$ peut être assigné soit à ϕ_1 soit à ϕ_2 (**vote maximum** $\rightarrow$ binarisation).

$\rightarrow$ Assignment de type **K-means** : chaque donnée est assignée à **une et une seule** composante (cluster).

Assignment douce (Soft assignment)

EM est “plus douce” :

Une donnée **contribue** (via γ_{ij}) à **plusieurs composantes** (modes de densité).

EM calcule une **assignment douce** avec :

$$\sum_j \gamma_{ij} = 1 \quad \forall i$$

Avantage : Plus robuste et reflète mieux l'incertitude dans l'assignation.

Convergence de l'algorithme EM

Principe itératif

Le cycle alterné **Expectation-Maximization** augmente la vraisemblance des données par rapport au modèle de mélange.

Critère de convergence :

Le processus est itéré jusqu'à **convergence**, c'est-à-dire quand la vraisemblance des données ne change (presque) plus :

$$|LL(\theta^{t+1}, X) - LL(\theta^t, X)| < \epsilon$$

où ϵ est un seuil de tolérance (par exemple $\epsilon = 10^{-6}$).

Propriété de monotonie

Propriété garantie : À chaque itération, $LL(\theta^{t+1}, X) \geq LL(\theta^t, X)$.

La log-vraisemblance **ne diminue jamais** (propriété hill-climbing).

Pourquoi ça marche ? Chaque étape améliore la **vraisemblance** des données (probabilité d'observer ces données avec le modèle courant). C'est un algorithme "**hill-climbing**" : à chaque itération, on monte la colline de vraisemblance.

Limitations de l'algorithme EM

Sensibilité à l'initialisation

Hill-climbing : L'algorithme dépend des **paramètres initiaux**.

Conséquences :

- **Sensible aux maxima locaux** : peut converger vers un optimum local plutôt que global
- Différentes initialisations peuvent donner différents résultats

L'initialisation est cruciale : L'EM peut converger vers des **maxima locaux** (petits sommets) au lieu du maximum global (plus haut sommet).

Stratégies d'initialisation

Méthodes recommandées :

- **K-means** : utiliser le clustering K-means pour initialiser les centres μ_j
- **K-means++** : version améliorée de K-means avec initialisation intelligente
- **Exécutions multiples** : lancer l'algorithme plusieurs fois avec différentes initialisations et garder la meilleure

Convergence lente

Convergence potentiellement lente, selon :

- La séparation entre les composantes
- La forme des distributions
- Le nombre de composantes

Algorithme EM complet pour c composantes

Étape 1 : Initialisation

Initialisation des paramètres :

$$\theta^0 = \{\pi_j^0, \mu_j^0, \Sigma_j^0\}_{j \in [c]}$$

Stratégies courantes :

- **Générale** : $\pi_j = 1/c$, μ_j choisi aléatoirement, $\Sigma_j = I_D$
- **Alternative** : utiliser K-means comme initialisation

Étape 2 : E-step

Calcul des responsabilités :

Pour chaque donnée $i \in [[N]]$ et chaque composante $j \in [[c]]$:

$$\gamma_{ij} = \frac{\pi_j \phi(x_i, \theta_j)}{\sum_{k=1}^c \pi_k \phi(x_i, \theta_k)}$$

Étape 3 : M-step

Estimation des paramètres du mélange :

$$\mu_j = \frac{\sum_{i=1}^N \gamma_{ij} x_i}{\sum_i \gamma_{ij}}$$

$$\Sigma_j = \frac{X_j \Gamma_j X_j^T}{\text{Tr}(\Gamma_j)}$$

où $\Gamma_j = \text{diag}(\gamma_{1j}, \dots, \gamma_{Nj})$ et X_j est centré sur μ_j .

$$\pi_j = \frac{\sum_i \gamma_{ij}}{N}$$

Étape 4 : Itération

Itérer les étapes 2 et 3 jusqu'à convergence.

Modélisation pratique

Forme de la matrice de covariance

Problème de sur-paramétrisation :

$$\Sigma \in \mathbb{R}^{D \times D}$$

Exemple critique :

Reconnaissance de caractères avec $x_i \in \mathbb{R}^{256} \rightarrow$ Besoin d'estimer $256^2 \times c$ paramètres pour la covariance !

Stratégies de paramétrisation

Modèles sphériques :

$$\Sigma = \sigma I_D$$

$\rightarrow$ 1 paramètre par composante

Modèles diagonaux :

$$\Sigma = \text{diag}(\sigma_1, \dots, \sigma_D)$$

$\rightarrow D$ paramètres par composante

Modèles complets :

$$\Sigma \in \mathbb{R}^{D \times D}$$

$\rightarrow O(D^2)$ paramètres par composante

Conseil pratique : Commencer avec des modèles simples (sphériques) puis augmenter la complexité si nécessaire.

Attention à la sur-paramétrisation ! Avec $D=256$ dimensions et $K=10$ composantes, une covariance complète nécessite 330,000 paramètres ! Souvent, on réduit d'abord la dimension avec PCA.

Prétraitement : Réduction de dimension par PCA

Problématique en haute dimension

Pour des données de haute dimension (par exemple $D = 256$), les modèles complexes ne convergent pas car le nombre de paramètres p est trop grand.

Solution : PCA préalable

Stratégie recommandée :

- Appliquer **PCA** pour réduire la dimension de D à K dimensions
- Appliquer **EM** dans l'espace des K premières composantes principales

Exemple pratique :

- 50 composantes principales reconstruisent 90% du signal
- EM dans l'espace des 50, 10 ou 2 premières composantes principales

Avantages :

- Réduction drastique du nombre de paramètres
 - Élimination du bruit
 - Convergence plus rapide et stable
-

Sélection du nombre de composantes

Le dilemme de la complexité

Problème :

Plus c est grand, moins de points peuvent être assignés à chaque composante (en moyenne).

Objectif :

Chercher des modèles **parcimonieux**, c'est-à-dire avec un **petit nombre de paramètres** à estimer.

- **K trop petit** : Sous-ajustement (underfitting) $\rightarrow$ modèle trop simple, ne capture pas la structure
- **K trop grand** : Sur-ajustement (overfitting) $\rightarrow$ modèle trop complexe, capture le bruit

Critère d'Information Bayésien (BIC)

Trade-off vraisemblance-complexité :

- Plus c est grand, meilleure est l'estimation de la vraisemblance LL
- Mais plus le modèle est complexe (nombreux paramètres)

Formule du BIC :

$$BIC(\theta, X) = -2 \cdot LL(\theta, X) + |\theta| \log(N)$$

où $|\theta|$ est le **nombre de paramètres** du modèle.

Critère de sélection :

$$\hat{\theta} = \arg \min_{\theta} BIC(\theta, X)$$

Composantes du BIC :

- $-2 \cdot LL(\theta, X)$: pénalise les modèles avec mauvaise vraisemblance
- $|\theta| \log(N)$: pénalise la complexité du modèle

Interprétation : Le BIC favorise les modèles qui expliquent bien les données **sans sur-ajustement** (équilibre entre qualité d'ajustement et complexité).

Relation entre GMM et K-means

Comparaison conceptuelle

K-means :

- **Assignment dure** (hard assignment)
- Chaque point appartient à **un seul cluster**
- Minimise la distance euclidienne aux centres
- Modèle géométrique basé sur les distances

GMM avec EM :

- **Assignment douce** (soft assignment)
- Chaque point a une **probabilité d'appartenance** à chaque composante
- Maximise la vraisemblance selon un modèle probabiliste
- Modèle probabiliste basé sur les densités

GMM comme généralisation de K-means

K-means est un cas particulier de GMM quand :

- Matrices de covariance $\Sigma_j = \sigma^2 I$ (sphériques et identiques)
- $\sigma \rightarrow 0$: les responsabilités γ_{ij} deviennent binaires
- Assignment douce $\rightarrow$ assignment dure

Point clé : K-means si on veut un clustering simple et rapide avec des clusters sphériques.
EM si on veut un modèle probabiliste, des formes flexibles, ou gérer l'incertitude.

Pièges à éviter et bonnes pratiques

Piège 1 : Les “Composantes Fantômes”

Problème : L'EM peut créer des composantes avec très peu de points ($\pi_j \approx 0$) qui capturent du bruit.

Solution : Regarder les poids π_j après convergence, fusionner ou éliminer les composantes trop petites.

Piège 2 : La Convergence Prématinée

Problème : L'algorithme semble converger mais reste dans un maximum local médiocre.

Solution : Multiples essais avec initialisations différentes, monitoring de la vraisemblance.

Piège 3 : L'Interprétation Abusive

Problème : Penser que les composantes trouvées correspondent forcément à des “classes réelles”.

Solution : L'EM trouve des **groupes statistiques**, pas nécessairement des catégories sémantiques. Valider avec des connaissances du domaine.

Synthèse des concepts clés

Mélanges gaussiens (GMM)

Généralisation :

Le modèle de mélange gaussien **généralise** les hypothèses sous-jacentes à la PCA et à la LDA.

Modélisation et estimation explicites :

- **Modélisation explicite** de la densité
- **Estimation** par maximum de vraisemblance

Classification non supervisée :

Si les composantes sont des classes, la donnée x_i est associée à la classe j pour laquelle :

$$\mathbb{P}(C = j|x_i) \approx \pi_j \phi_j(x_i)$$

est maximisée parmi toutes les classes.

Algorithme EM

Caractéristiques :

- Algorithme **itératif** pour maximiser la (log-)vraisemblance
- Principe utilisé dans **de nombreux autres scénarios**
- Basé sur la définition de **variables non observées (latentes)** δ_{ij}

Applications :

- **Probabilistic Latent Semantic Analysis (pLSA)** : EM où les variables cachées sont les concepts latents
- **Modèles de Markov cachés (HMM)**
- **Factorisation matricielle**
- Segmentation d'images, séparation de sources audio



Fiche de révision condensée

À retenir absolument :

- EM = algorithme pour modèles avec variables latentes
- Deux étapes alternées : E (responsabilités) $\rightarrow$ M (paramètres)
- GMM = mélange de gaussiennes, modélise densité des données
- Initialisation cruciale $\rightarrow$ utiliser K-means ou K-means++
- Choix de K avec BIC ou validation croisée
- Forme covariance : commencer simple (sphérique), complexifier si besoin
- Avantage principal : modèle probabiliste avec assignations douces
- Parenté : généralise K-means (cas particulier)
- Applications : segmentation, séparation de sources, clustering avancé
- Vérification : toujours visualiser et valider les résultats

! Concepts mathématiques à maîtriser

Probabilités et statistiques :

- Distribution normale multivariée
- Maximum de vraisemblance (MLE)
- Log-vraisemblance
- Règle de Bayes
- Variables aléatoires latentes
- Probabilités conditionnelles
- Espérance conditionnelle

Optimisation :

- Optimisation itérative
- Algorithmes hill-climbing
- Critères de convergence
- Maxima locaux vs globaux
- BIC (Bayesian Information Criterion)
- Trade-off biais-variance
- Parcimonie de modèle

Points à développer :

- Dérivation de la log-vraisemblance
- Calcul des responsabilités par la règle de Bayes
- Dérivation des équations de mise à jour du M-step
- Preuve de la monotonie de LL dans l'algorithme EM