

## Table of contents

|                                                                                         |          |
|-----------------------------------------------------------------------------------------|----------|
| <b>Expectation-Maximization (EM) pour modèles de mélange - Support de révision oral</b> | <b>2</b> |
| 1. Le problème fondamental : Démêler les sources mélangées . . . . .                    | 2        |
| 2. L'analogie du professeur et des élèves . . . . .                                     | 3        |
| Le scénario pédagogique . . . . .                                                       | 3        |
| 3. Les modèles de mélange gaussien : Des “bosses” dans le paysage des données . . .     | 4        |
| Visualisation géométrique . . . . .                                                     | 4        |
| 4. Le dilemme du poulet et de l'œuf . . . . .                                           | 4        |
| Pourquoi c'est difficile à estimer . . . . .                                            | 4        |
| 5. Les deux étapes magiques de l'EM . . . . .                                           | 5        |
| Étape E (Expectation) : L'attribution probabiliste . . . . .                            | 5        |
| Étape M (Maximization) : La mise à jour des paramètres . . . . .                        | 5        |
| 6. L'initialisation : Le point de départ crucial . . . . .                              | 7        |
| Pourquoi l'initialisation est importante . . . . .                                      | 7        |
| Stratégies d'initialisation intelligentes . . . . .                                     | 7        |
| 7. Le choix de K : Combien de composantes ? . . . . .                                   | 7        |
| Le dilemme de la complexité . . . . .                                                   | 7        |
| Méthodes pour choisir K . . . . .                                                       | 7        |
| 8. EM vs K-means : Le duel des algorithmes . . . . .                                    | 8        |
| Les similitudes . . . . .                                                               | 8        |
| Les différences fondamentales . . . . .                                                 | 8        |
| 9. Les pièges courants et comment les éviter . . . . .                                  | 9        |
| Piège 1 : Les matrices de covariance singulières . . . . .                              | 9        |
| Piège 2 : La convergence lente . . . . .                                                | 9        |
| Piège 3 : L'interprétation des résultats . . . . .                                      | 9        |
| 10. L'EM dans le monde réel : Exemple des séparations de sources . . . . .              | 9        |
| Séparation audio (Cocktail Party Problem) . . . . .                                     | 9        |
| Segmentation d'images . . . . .                                                         | 9        |
| 11. Fiche de révision ultra-condensée . . . . .                                         | 10       |
| 12. Pour l'oral : Les 3 histoires à raconter . . . . .                                  | 10       |
| Histoire 1 : Le professeur et les copies anonymes . . . . .                             | 10       |
| Histoire 2 : La séparation des voix au cocktail . . . . .                               | 10       |
| Histoire 3 : Le paysage de montagnes . . . . .                                          | 10       |
| 13. Questions pièges et comment y répondre . . . . .                                    | 10       |
| 14. L'astuce mnémotechnique finale . . . . .                                            | 11       |
| 15. En résumé : L'EM, c'est... . . . . .                                                | 11       |

# Expectation-Maximization (EM) pour modèles de mélange - Support de révision oral


## 1. Le problème fondamental : Démêler les sources mélangées

Imaginez que vous êtes dans une salle avec plusieurs instruments de musique qui jouent en même temps. Vous enregistrez le son global (le mélange). Comment retrouver **les caractéristiques de chaque instrument** (hauteur, volume) sans savoir qui joue quoi à quel moment ?

C'est exactement le problème que résout l'algorithme EM pour les modèles de mélange : **séparer un mélange en ses composantes sous-jacentes** quand on ne connaît pas l'origine de chaque observation.

### ! Important

**Concept Clé : Apprentissage non supervisé avec variables cachées** L'EM est utilisé quand certaines informations sont **manquantes** (ici, l'étiquette de quelle composante a généré chaque donnée). On appelle ces informations manquantes des **variables latentes**.



## 2. L'analogie du professeur et des élèves

### Le scénario pédagogique

Imaginez un professeur qui reçoit des copies anonymes de deux élèves (A et B). Il sait que : - Il y a deux élèves - Chaque élève a son niveau moyen ( $\mu$ ) et sa régularité ( ) - Mais il ne sait pas quelle copie vient de quel élève

### Comment estimer le niveau de chaque élève ?

La stratégie EM : 1. **Étape E (Expectation)** : Deviner l'auteur de chaque copie basé sur des niveaux estimés 2. **Étape M (Maximization)** : Recalculer les niveaux moyens basés sur ces attributions 3. **Répéter** jusqu'à convergence



Tip

**Idée Essentielle : Le cercle vertueux de l'EM** Plus on estime bien les paramètres, mieux on peut deviner les origines. Plus on devine bien les origines, mieux on peut estimer les paramètres. L'EM exploite cette synergie.

### 3. Les modèles de mélange gaussien : Des “bosses” dans le paysage des données


#### Visualisation géométrique

Imaginez un paysage de montagnes avec plusieurs sommets. Chaque sommet représente un groupe dans vos données. Un modèle de mélange gaussien modélise ce paysage comme une **superposition de collines gaussiennes**.

Formule du mélange :

$$f(x) = \pi_1 \cdot N(x|\mu_1, \sigma_1^2) + \pi_2 \cdot N(x|\mu_2, \sigma_2^2) + \dots + \pi_K \cdot N(x|\mu_K, \sigma_K^2)$$

Où :  $\pi_j$  = proportion de la composante  $j$  (hauteur relative de la colline) -  $N(x|\mu, \sigma^2)$  = colline gaussienne centrée en  $\mu$  avec écart  $\sigma^2$



### 4. Le dilemme du poulet et de l'œuf

#### Pourquoi c'est difficile à estimer

Pour estimer les paramètres  $(\mu, \sigma^2)$ , il faudrait connaître l'origine de chaque point. Pour connaître l'origine de chaque point, il faudrait connaître les paramètres.

**C'est le problème classique du “poulet et de l'œuf” !**

**i** Note

**La solution EM : Briser le cercle vicieux** Au lieu de chercher une solution parfaite d'un coup, l'EM procède par **approximations successives** : 1. Partir d'une estimation initiale des paramètres 2. Utiliser ces paramètres pour estimer les origines 3. Utiliser ces origines estimées pour mettre à jour les paramètres 4. Répéter jusqu'à ce que les estimations se stabilisent

## 5. Les deux étapes magiques de l'EM

### Étape E (Expectation) : L'attribution probabiliste

**Question** : Sachant les paramètres actuels, quelle est la probabilité que chaque point vienne de chaque composante ?

**Calcul des “responsabilités”** :


$$= P(\text{point } i \text{ vient de la composante } j \mid \text{paramètres actuels})$$

C'est une **attribution douce** (soft assignment) : chaque point appartient partiellement à toutes les composantes.

### Étape M (Maximization) : La mise à jour des paramètres

**Question** : Sachant les responsabilités, quelles sont les meilleures estimations des paramètres ?

**Recalcul des paramètres** : -  $\mu$  = moyenne pondérée des points (pondérée par  $r_{ij}$ ) -  $\sigma^2$  = variance pondérée des points -  $\pi_j$  = proportion moyenne de la composante



## 6. L'initialisation : Le point de départ crucial

### Pourquoi l'initialisation est importante

L'EM est un algorithme “**hill-climbing**” : il gravit la colline de vraisemblance à partir de son point de départ. S'il part d'un mauvais endroit, il peut rester coincé dans un **maximum local** (petit sommet) au lieu d'atteindre le **maximum global** (plus haut sommet).

#### Warning

**Piège à éviter : L'aléatoire pur** Initialiser complètement au hasard peut conduire à :  
- Des convergences lentes - Des solutions sous-optimales - Des résultats non reproductibles

### Stratégies d'initialisation intelligentes

1. **K-means d'abord** : Utiliser K-means pour une première attribution, puis convertir en probabilités
2. **K-means++** : Version améliorée qui éloigne les centres initiaux
3. **Multiple essais** : Lancer l'EM plusieurs fois avec différentes initialisations, garder la meilleure

## 7. Le choix de K : Combien de composantes ?

### Le dilemme de la complexité

- **K trop petit** : Sous-ajustement (underfitting) → modèle trop simple, ne capture pas la structure
- **K trop grand** : Sur-ajustement (overfitting) → modèle trop complexe, capture le bruit


### Méthodes pour choisir K

1. **Critère d'information (BIC/AIC)** : Pénalise la complexité

$$\text{BIC} = -2 \cdot \log(\text{vraisemblance}) + n_{\text{param}} \cdot \log(n_{\text{points}})$$

On choisit le K qui minimise le BIC.

2. **Validation croisée** : Séparer les données, entraîner sur une partie, évaluer sur l'autre.
3. **Analyse de la vraisemblance** : Observer quand l'augmentation de vraisemblance ralentit (méthode du “coude”).



## 8. EM vs K-means : Le duel des algorithmes

### Les similitudes

- Deux algorithmes itératifs
- Deux algorithmes de clustering
- Deux algorithmes sensibles à l'initialisation

### Les différences fondamentales

| Aspect                 | K-means                 | EM pour GMM             |
|------------------------|-------------------------|-------------------------|
| <b>Modèle</b>          | Géométrique (distances) | Probabiliste (densités) |
| <b>Appartenance</b>    | Dure (un seul cluster)  | Douce (probabiliste)    |
| <b>Forme clusters</b>  | Sphères uniquement      | Ellipses orientées      |
| <b>Bruit/tolérance</b> | Sensible aux outliers   | Plus robuste            |

#### 💡 Tip

**K-means est un cas particulier de l'EM** Quand les covariances sont sphériques et identiques, et qu'on force les appartenances à être dures, l'EM se réduit à K-means.



## 9. Les pièges courants et comment les éviter

### Piège 1 : Les matrices de covariance singulières

**Problème :** Quand une composante a très peu de points, sa matrice de covariance peut devenir singulière (non-inversible).

**Solution :** Contraintes sur les covariances (diagonale, sphérique) ou ajout d'un terme de régularisation.

### Piège 2 : La convergence lente

**Problème :** L'EM peut prendre beaucoup d'itérations pour converger, surtout si les composantes sont mal séparées.

**Solution :** Utiliser des critères d'arrêt adaptatifs, monitoring de la vraisemblance.

### Piège 3 : L'interprétation des résultats

**Problème :** Les composantes trouvées ne correspondent pas toujours à des "classes" réelles.

**Solution :** Toujours valider avec des connaissances du domaine, visualiser les résultats.

## 10. L'EM dans le monde réel : Exemple des séparations de sources

### Séparation audio (Cocktail Party Problem)

**Problème :** Plusieurs personnes parlent en même temps, plusieurs microphones enregistrent.

**Solution EM :** 1. Modéliser chaque source comme une gaussienne dans l'espace des caractéristiques audio 2. Utiliser l'EM pour estimer les paramètres de chaque source 3. Séparer les signaux en fonction des responsabilités

### Segmentation d'images

**Problème :** Une image contient plusieurs régions (ciel, terre, objets).

**Solution EM :** 1. Modéliser chaque région par une gaussienne dans l'espace des couleurs 2. Utiliser l'EM pour trouver les paramètres de chaque région 3. Attribuer chaque pixel à la région la plus probable

## 11. Fiche de révision ultra-condensée

! Important

En 30 secondes :

1. **EM** = algorithme pour estimer modèles avec variables cachées
2. **Deux étapes** : E (calcul responsabilités), M (mise à jour paramètres)
3. **Pour GMM** : modélise données comme mélange de gaussiennes
4. **Avantage** : attribution douce, modèle probabiliste
5. **Défis** : initialisation, choix de K, maxima locaux
6. **Utilisations** : clustering, séparation sources, segmentation
7. **Parenté** : généralise K-means, lié à d'autres modèles latents

## 12. Pour l'oral : Les 3 histoires à raconter

### Histoire 1 : Le professeur et les copies anonymes

“Imaginez un professeur qui reçoit des copies anonymes de deux élèves. Comment estimer leur niveau moyen sans savoir qui a écrit quoi ? L'EM propose une solution...”

### Histoire 2 : La séparation des voix au cocktail

“À une fête bruyante, comment isoler la voix d'une personne ? L'EM modélise chaque voix comme une source et les sépare...”

### Histoire 3 : Le paysage de montagnes

“Vos données sont comme un paysage avec plusieurs sommets. L'EM identifie chaque sommet (composante) et mesure à quel sommet appartient chaque point...”

## 13. Questions pièges et comment y répondre

**Q : “Pourquoi l'EM converge-t-il ?”** R : “Parce qu'à chaque itération, la vraisemblance des données ne peut qu'augmenter (ou rester stable). C'est un algorithme ‘hill-climbing’.”

**Q : “EM ou K-means ?”** R : “K-means si vous voulez une attribution claire et rapide. EM si vous voulez un modèle probabiliste et des formes de clusters flexibles.”

**Q : “Comment choisir  $K$  ?”** R : “Utilisez des critères comme le BIC qui pénalisent la complexité, ou validez sur des données de test. Parfois, le domaine d’application donne une indication.”

#### **14. L’astuce mnémotechnique finale**

**EM = Estimation Maximisation** - **E** comme **Espérer** les appartenances (responsabilités) - **M** comme **Maximiser** la vraisemblance (paramètres)

**GMM = Gaussiennes Multiples en Mélange** - Plusieurs cloches gaussiennes - Superposées avec des poids - Modélisent des groupes dans les données

#### **15. En résumé : L’EM, c’est...**

**L’art d’apprendre à partir de l’incomplétude.** Une méthode puissante qui transforme l’incertitude sur les origines des données en une estimation probabiliste raffinée.

**Pour finir :** L’EM ne vous donne pas la vérité absolue, mais la **meilleure explication probabiliste** étant donné les observations et le modèle choisi.