

Table of contents


Intuition	1
1. Le Problème Fondamental : Séparer les Sources Mélangées	1
2. Les Modèles de Mélange Gaussien : La Mathématique du “Paysage”	3
L’idée géométrique	3
3. L’Algorithme EM : La Danse en Deux Temps	3
Le Principe Général	3
Étape E (Expectation) : “Attribuer les points”	4
Étape M (Maximization) : “Mettre à jour les paramètres”	4
4. Les Détails Pratiques Cruciaux	5
L’Initialisation : Le Point de Départ est Capital	5
Le Choix de K : Combien de Composantes ?	5
La Forme des Matrices de Covariance	6
5. L’EM en Action : Exemple Complet	6
Scénario : Segmentation d’Image	6
Visualisation de la Convergence	7
6. EM vs K-means : La Différence Profonde	7
7. Pièges à Éviter et Bonnes Pratiques	8
Piège 1 : Les “Composantes Fantômes”	8
Piège 2 : La Convergence Prématurée	8
Piège 3 : L’Interprétation Abusive	8
8. Fiche de Révision Synthétique	8
9. Pour Répondre aux Questions de l’Examineur	9
10. En Résumé : La Philosophie de l’EM	9

Intuition

1. Le Problème Fondamental : Séparer les Sources Mélangées

Imaginez cette situation : Vous enregistrez le son d’une salle où plusieurs instruments jouent ensemble. Vous avez le mélange final, mais vous voulez isoler chaque instrument. Comment faire sans savoir quelle note appartient à quel instrument ?

C’est **exactement** le problème que résout l’algorithme EM pour les modèles de mélange gaussien.



! Important

Le cœur du problème : Avec les modèles de mélange, nous avons **deux types d'inconnues** qui dépendent l'une de l'autre : 1. **Les paramètres** de chaque composante (moyenne, variance) 2. **L'origine** de chaque point (quelle composante l'a généré)
C'est un **cercle vicieux** : pour connaître l'un, il faut connaître l'autre.

2. Les Modèles de Mélange Gaussien : La Mathématique du “Paysage”

L'idée géométrique

Imaginez que vos données forment un **paysage de montagnes**. Chaque montagne représente un groupe naturel dans vos données. Un modèle de mélange gaussien (GMM) représente ce paysage comme une **superposition de collines gaussiennes**.

Formule du GMM :

$$f(x) = \pi_1 \cdot N(x|\mu_1, \Sigma_1) + \pi_2 \cdot N(x|\mu_2, \Sigma_2) + \dots + \pi_K \cdot N(x|\mu_K, \Sigma_K)$$

Où : - π_j = “hauteur relative” de la colline j (poids du mélange) - $N(x|\mu, \Sigma)$ = forme de la colline (gaussienne centrée en μ , forme Σ)

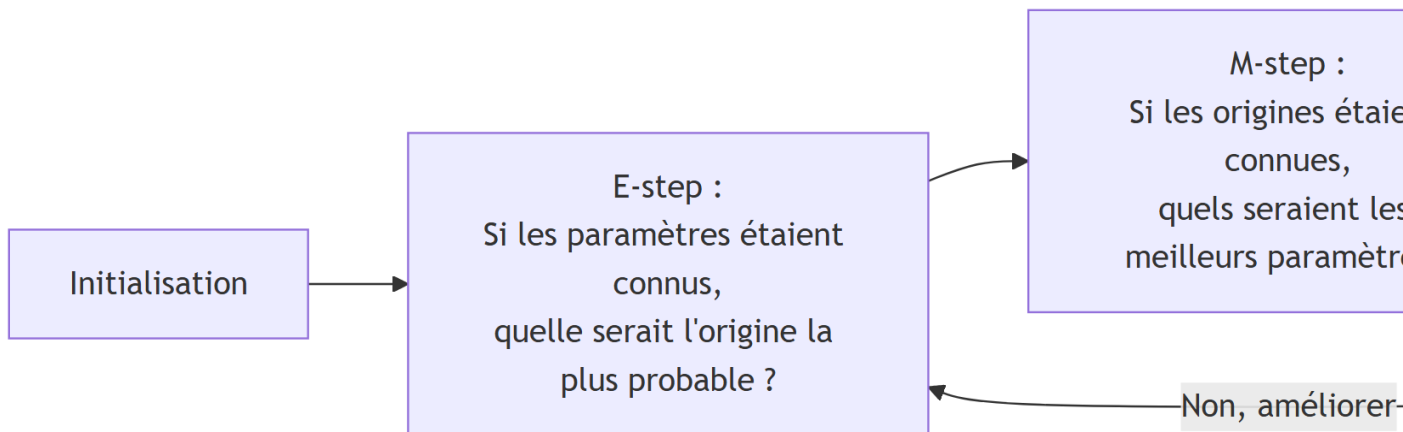
💡 Tip

Pourquoi des gaussiennes ? 1. **Théorème central limite** : beaucoup de phénomènes naturels sont gaussiens 2. **Universalité** : un mélange de gaussiennes peut approximer n'importe quelle densité 3. **Calculabilité** : les formules sont mathématiquement maniables

3. L'Algorithme EM : La Danse en Deux Temps

Le Principe Général

Plutôt que de chercher une solution parfaite d'un coup (impossible), l'EM procède par **approximations successives** en alternant deux questions :



Étape E (Expectation) : “Attribuer les points”

Question : Étant donné les paramètres actuels, quelle est la probabilité que chaque point vienne de chaque composante ?

Calcul des “responsabilités” :

$$\begin{aligned} &= P(\text{point } i \text{ vient de la composante } j \mid \text{paramètres actuels}) \\ &= \frac{p_{ij} \cdot N(x_i \mid \mu_j, \Sigma_j)}{\sum_{k=1}^K p_{ik} \cdot N(x_i \mid \mu_k, \Sigma_k)} \end{aligned}$$

Interprétation : C’est une **attribution douce** (soft assignment). Contrairement au K-means qui dit “ce point est à 100% dans ce cluster”, l’EM dit “ce point est à 60% dans le cluster A, 30% dans B, 10% dans C”.

Étape M (Maximization) : “Mettre à jour les paramètres”

Question : Étant donné ces probabilités d’appartenance, quelles sont les meilleures estimations des paramètres ?

Formules de mise à jour :


$$\begin{aligned} \mu_j &= \frac{\sum_i p_{ij} x_i}{\sum_i p_{ij}} && \text{(moyenne pondérée)} \\ \Sigma_j &= \frac{\sum_i p_{ij} (x_i - \mu_j)(x_i - \mu_j)^T}{\sum_i p_{ij}} && \text{(covariance pondérée)} \\ &= \frac{1}{N_j} \sum_i p_{ij} (x_i - \mu_j)(x_i - \mu_j)^T && \text{(proportion de la composante)} \end{aligned}$$

Note

Pourquoi ça marche ? Chaque étape améliore la **vraisemblance** des données (probabilité d’observer ces données avec le modèle courant). C’est un algorithme “**hill-climbing**” : à chaque itération, on monte la colline de vraisemblance.

4. Les Détails Pratiques Cruciaux

L'Initialisation : Le Point de Départ est Capital



Pourquoi c'est important ? L'EM peut converger vers des **maxima locaux** (petits sommets) au lieu du maximum global (plus haut sommet).

Le Choix de K : Combien de Composantes ?

Le dilemme classique : - **K trop petit** = sous-ajustement = modèle trop simple - **K trop grand** = sur-ajustement = modèle trop complexe

Solution : Le critère BIC (Bayesian Information Criterion)

$$\text{BIC} = -2 \cdot \log(\text{vraisemblance}) + n_{\text{paramètres}} \cdot \log(n_{\text{points}})$$

On choisit le **K** qui minimise le **BIC** (équilibre entre qualité d'ajustement et complexité).

La Forme des Matrices de Covariance

Trois options principales :

Type	Forme	Nombre paramètres	Utilisation
Sphérique	$\Sigma = \sigma^2 \mathbf{I}$	1 par composante	Données isotropes, clusters sphériques
Diagonale	$\Sigma = \text{diag}(\sigma_1^2, \dots, \sigma_D^2)$	D par composante	Axes alignés avec les axes principaux
Complète	Σ complète	$D(D+1)/2$ par composante	Clusters de forme ellipsoïdale libre

Warning

Attention à la sur-paramétrisation ! Avec $D=256$ dimensions et $K=10$ composantes, une covariance complète nécessite 330,000 paramètres ! Souvent, on réduit d'abord la dimension avec PCA.

5. L'EM en Action : Exemple Complet


Scénario : Segmentation d'Image

1. **Données** : Pixels d'une image (3 dimensions : R, V, B)
2. **Objectif** : Séparer l'image en régions homogènes (ciel, terre, végétation...)
3. **Procédure EM** :
 - Initialisation : $K=3$ (hypothèse de 3 régions principales)
 - Étape E : Pour chaque pixel, calculer sa probabilité d'appartenir à chaque région
 - Étape M : Recalculer les couleurs moyennes et variances de chaque région
 - Répéter jusqu'à convergence (10-20 itérations)
4. **Résultat** : Carte de segmentation probabiliste

Visualisation de la Convergence

Itération 0 : vraisemblance = -15230.4
Itération 1 : vraisemblance = -12456.2 (+ amélioration)
Itération 2 : vraisemblance = -11234.5 (+ amélioration)
...
Itération 15 : vraisemblance = -9823.1 (convergence)
Itération 16 : vraisemblance = -9823.0 (très faible amélioration → stop)

6. EM vs K-means : La Différence Profonde



Point clé : K-means est **un cas particulier** de l'EM ! Quand les covariances sont sphériques et qu'on force les probabilités à 0 ou 1, on retrouve K-means.

7. Pièges à Éviter et Bonnes Pratiques

Piège 1 : Les “Composantes Fantômes”

Problème : L’EM peut créer des composantes avec très peu de points (< 10) qui capturent du bruit. **Solution :** Regarder les poids après convergence, fusionner ou éliminer les composantes trop petites.

Piège 2 : La Convergence Précoce

Problème : L’algorithme semble converger mais reste dans un maximum local médiocre. **Solution :** Multiples essais avec initialisations différentes, monitoring de la vraisemblance.

Piège 3 : L’Interprétation Abusive

Problème : Penser que les composantes trouvées correspondent forcément à des “classes réelles”. **Solution :** L’EM trouve des **groupes statistiques**, pas nécessairement des catégories sémantiques. Valider avec des connaissances du domaine.

8. Fiche de Révision Synthétique

! Important

À retenir absolument pour l’oral :

1. **EM** = algorithme pour modèles avec variables latentes
2. **Deux étapes alternées** : E (responsabilités) $\rightarrow$ M (paramètres)
3. **GMM** = mélange de gaussiennes, modélise densité des données
4. **Initialisation cruciale** $\rightarrow$ utiliser K-means ou K-means++
5. **Choix de K** avec BIC ou validation croisée
6. **Forme covariance** : commencer simple (sphérique), complexifier si besoin
7. **Avantage principal** : modèle probabiliste avec assignations douces
8. **Parenté** : généralise K-means (cas particulier)
9. **Applications** : segmentation, séparation de sources, clustering avancé
10. **Vérification** : toujours visualiser et valider les résultats

9. Pour Répondre aux Questions de l'Examinateur

Q : “Pourquoi l’EM converge-t-il toujours ?” R : “L’EM garantit que la vraisemblance ne diminue jamais (monotonie). Il converge vers un maximum local, mais pas nécessairement global.”

Q : “Comment choisir entre EM et K-means ?” R : “K-means si on veut un clustering simple et rapide avec des clusters sphériques. EM si on veut un modèle probabiliste, des formes flexibles, ou gérer l’incertitude.”

Q : “Que faire si l’EM donne des résultats différents à chaque lancement ?” R : “C’est normal ! L’EM dépend de l’initialisation. Il faut le lancer plusieurs fois et garder la solution avec la plus haute vraisemblance, ou utiliser une initialisation intelligente (K-means++).”

10. En Résumé : La Philosophie de l’EM

L’algorithme EM nous enseigne une leçon profonde : **face à l’incomplétude, l’itération et l’alternance sont puissantes**. Au lieu de chercher la solution parfaite d’un coup (mission impossible), on fait des allers-retours entre estimation des causes et estimation des effets, chaque étape s’appuyant sur la précédente.

Pour finir : L’EM ne prétend pas trouver la Vérité, mais la **meilleure explication probabiliste** étant donné les observations et le modèle choisi. C’est un outil d’humilité mathématique qui reconnaît et gère l’incertitude.