

Table of contents

Expectation-Maximization (EM) pour modèles de mélange - Support de révision oral	2
1. Le problème fondamental : Démêler les sources mélangées	2
2. L'analogie du professeur et des élèves	3
Le scénario pédagogique	3
3. Les modèles de mélange gaussien : Des “bosses” dans le paysage des données . . .	4
Visualisation géométrique	4
4. Le dilemme du poulet et de l'œuf	4
Pourquoi c'est difficile à estimer	4
5. Les deux étapes magiques de l'EM	5
Étape E (Expectation) : L'attribution probabiliste	5
Étape M (Maximization) : La mise à jour des paramètres	5
6. L'initialisation : Le point de départ crucial	7
Pourquoi l'initialisation est importante	7
Stratégies d'initialisation intelligentes	7
7. Le choix de K : Combien de composantes ?	7
Le dilemme de la complexité	7
Méthodes pour choisir K	7
8. EM vs K-means : Le duel des algorithmes	8
Les similitudes	8
Les différences fondamentales	8
9. Les pièges courants et comment les éviter	9
Piège 1 : Les matrices de covariance singulières	9
Piège 2 : La convergence lente	9
Piège 3 : L'interprétation des résultats	9
10. L'EM dans le monde réel : Exemple des séparations de sources	9
Séparation audio (Cocktail Party Problem)	9
Segmentation d'images	9
11. Fiche de révision ultra-condensée	10
12. Pour l'oral : Les 3 histoires à raconter	10
Histoire 1 : Le professeur et les copies anonymes	10
Histoire 2 : La séparation des voix au cocktail	10
Histoire 3 : Le paysage de montagnes	10
13. Questions pièges et comment y répondre	10
14. L'astuce mnémotechnique finale	11
15. En résumé : L'EM, c'est...	11

Expectation-Maximization (EM) pour modèles de mélange - Support de révision oral


1. Le problème fondamental : Démêler les sources mélangées

Imaginez que vous êtes dans une salle avec plusieurs instruments de musique qui jouent en même temps. Vous enregistrez le son global (le mélange). Comment retrouver **les caractéristiques de chaque instrument** (hauteur, volume) sans savoir qui joue quoi à quel moment ?

C'est exactement le problème que résout l'algorithme EM pour les modèles de mélange : **séparer un mélange en ses composantes sous-jacentes** quand on ne connaît pas l'origine de chaque observation.

! Important

Concept Clé : Apprentissage non supervisé avec variables cachées L'EM est utilisé quand certaines informations sont **manquantes** (ici, l'étiquette de quelle composante a généré chaque donnée). On appelle ces informations manquantes des **variables latentes**.



2. L'analogie du professeur et des élèves

Le scénario pédagogique

Imaginez un professeur qui reçoit des copies anonymes de deux élèves (A et B). Il sait que : - Il y a deux élèves - Chaque élève a son niveau moyen (μ) et sa régularité () - Mais il ne sait pas quelle copie vient de quel élève

Comment estimer le niveau de chaque élève ?

La stratégie EM : 1. **Étape E (Expectation)** : Deviner l'auteur de chaque copie basé sur des niveaux estimés 2. **Étape M (Maximization)** : Recalculer les niveaux moyens basés sur ces attributions 3. **Répéter** jusqu'à convergence



Tip

Idée Essentielle : Le cercle vertueux de l'EM Plus on estime bien les paramètres, mieux on peut deviner les origines. Plus on devine bien les origines, mieux on peut estimer les paramètres. L'EM exploite cette synergie.

3. Les modèles de mélange gaussien : Des “bosses” dans le paysage des données


Visualisation géométrique

Imaginez un paysage de montagnes avec plusieurs sommets. Chaque sommet représente un groupe dans vos données. Un modèle de mélange gaussien modélise ce paysage comme une **superposition de collines gaussiennes**.

Formule du mélange :

$$f(x) = \pi_1 \cdot N(x|\mu_1, \sigma_1^2) + \pi_2 \cdot N(x|\mu_2, \sigma_2^2) + \dots + \pi_K \cdot N(x|\mu_K, \sigma_K^2)$$

Où : π_j = proportion de la composante j (hauteur relative de la colline) - $N(x|\mu, \sigma^2)$ = colline gaussienne centrée en μ avec écart σ



4. Le dilemme du poulet et de l'œuf

Pourquoi c'est difficile à estimer

Pour estimer les paramètres (μ, σ) , il faudrait connaître l'origine de chaque point. Pour connaître l'origine de chaque point, il faudrait connaître les paramètres.

C'est le problème classique du “poulet et de l'œuf” !

i Note

La solution EM : Briser le cercle vicieux Au lieu de chercher une solution parfaite d'un coup, l'EM procède par **approximations successives** : 1. Partir d'une estimation initiale des paramètres 2. Utiliser ces paramètres pour estimer les origines 3. Utiliser ces origines estimées pour mettre à jour les paramètres 4. Répéter jusqu'à ce que les estimations se stabilisent

5. Les deux étapes magiques de l'EM

Étape E (Expectation) : L'attribution probabiliste

Question : Sachant les paramètres actuels, quelle est la probabilité que chaque point vienne de chaque composante ?

Calcul des “responsabilités” :


$$= P(\text{point } i \text{ vient de la composante } j \mid \text{paramètres actuels})$$

C'est une **attribution douce** (soft assignment) : chaque point appartient partiellement à toutes les composantes.

Étape M (Maximization) : La mise à jour des paramètres

Question : Sachant les responsabilités, quelles sont les meilleures estimations des paramètres ?

Recalcul des paramètres : - μ = moyenne pondérée des points (pondérée par r_{ij}) - σ^2 = variance pondérée des points - π_j = proportion moyenne de la composante



6. L'initialisation : Le point de départ crucial

Pourquoi l'initialisation est importante

L'EM est un algorithme “**hill-climbing**” : il gravit la colline de vraisemblance à partir de son point de départ. S'il part d'un mauvais endroit, il peut rester coincé dans un **maximum local** (petit sommet) au lieu d'atteindre le **maximum global** (plus haut sommet).

Warning

Piège à éviter : L'aléatoire pur Initialiser complètement au hasard peut conduire à :
- Des convergences lentes - Des solutions sous-optimales - Des résultats non reproductibles

Stratégies d'initialisation intelligentes

1. **K-means d'abord** : Utiliser K-means pour une première attribution, puis convertir en probabilités
2. **K-means++** : Version améliorée qui éloigne les centres initiaux
3. **Multiple essais** : Lancer l'EM plusieurs fois avec différentes initialisations, garder la meilleure

7. Le choix de K : Combien de composantes ?

Le dilemme de la complexité

- **K trop petit** : Sous-ajustement (underfitting) → modèle trop simple, ne capture pas la structure
- **K trop grand** : Sur-ajustement (overfitting) → modèle trop complexe, capture le bruit


Méthodes pour choisir K

1. **Critère d'information (BIC/AIC)** : Pénalise la complexité

$$\text{BIC} = -2 \cdot \log(\text{vraisemblance}) + n_{\text{param}} \cdot \log(n_{\text{points}})$$

On choisit le K qui minimise le BIC.

2. **Validation croisée** : Séparer les données, entraîner sur une partie, évaluer sur l'autre.
3. **Analyse de la vraisemblance** : Observer quand l'augmentation de vraisemblance ralentit (méthode du “coude”).



8. EM vs K-means : Le duel des algorithmes

Les similitudes

- Deux algorithmes itératifs
- Deux algorithmes de clustering
- Deux algorithmes sensibles à l'initialisation

Les différences fondamentales

Aspect	K-means	EM pour GMM
Modèle	Géométrique (distances)	Probabiliste (densités)
Appartenance	Dure (un seul cluster)	Douce (probabiliste)
Forme clusters	Sphères uniquement	Ellipses orientées
Bruit/tolérance	Sensible aux outliers	Plus robuste

💡 Tip

K-means est un cas particulier de l'EM Quand les covariances sont sphériques et identiques, et qu'on force les appartenances à être dures, l'EM se réduit à K-means.

9. Les pièges courants et comment les éviter

Piège 1 : Les matrices de covariance singulières

Problème : Quand une composante a très peu de points, sa matrice de covariance peut devenir singulière (non-inversible).

Solution : Contraintes sur les covariances (diagonale, sphérique) ou ajout d'un terme de régularisation.

Piège 2 : La convergence lente

Problème : L'EM peut prendre beaucoup d'itérations pour converger, surtout si les composantes sont mal séparées.

Solution : Utiliser des critères d'arrêt adaptatifs, monitoring de la vraisemblance.

Piège 3 : L'interprétation des résultats

Problème : Les composantes trouvées ne correspondent pas toujours à des "classes" réelles.

Solution : Toujours valider avec des connaissances du domaine, visualiser les résultats.

10. L'EM dans le monde réel : Exemple des séparations de sources

Séparation audio (Cocktail Party Problem)

Problème : Plusieurs personnes parlent en même temps, plusieurs microphones enregistrent.

Solution EM : 1. Modéliser chaque source comme une gaussienne dans l'espace des caractéristiques audio 2. Utiliser l'EM pour estimer les paramètres de chaque source 3. Séparer les signaux en fonction des responsabilités

Segmentation d'images

Problème : Une image contient plusieurs régions (ciel, terre, objets).

Solution EM : 1. Modéliser chaque région par une gaussienne dans l'espace des couleurs 2. Utiliser l'EM pour trouver les paramètres de chaque région 3. Attribuer chaque pixel à la région la plus probable

11. Fiche de révision ultra-condensée

! Important

En 30 secondes :

1. **EM** = algorithme pour estimer modèles avec variables cachées
2. **Deux étapes** : E (calcul responsabilités), M (mise à jour paramètres)
3. **Pour GMM** : modélise données comme mélange de gaussiennes
4. **Avantage** : attribution douce, modèle probabiliste
5. **Défis** : initialisation, choix de K, maxima locaux
6. **Utilisations** : clustering, séparation sources, segmentation
7. **Parenté** : généralise K-means, lié à d'autres modèles latents

12. Pour l'oral : Les 3 histoires à raconter

Histoire 1 : Le professeur et les copies anonymes

“Imaginez un professeur qui reçoit des copies anonymes de deux élèves. Comment estimer leur niveau moyen sans savoir qui a écrit quoi ? L'EM propose une solution...”

Histoire 2 : La séparation des voix au cocktail

“À une fête bruyante, comment isoler la voix d'une personne ? L'EM modélise chaque voix comme une source et les sépare...”

Histoire 3 : Le paysage de montagnes

“Vos données sont comme un paysage avec plusieurs sommets. L'EM identifie chaque sommet (composante) et mesure à quel sommet appartient chaque point...”

13. Questions pièges et comment y répondre

Q : “Pourquoi l'EM converge-t-il ?” R : “Parce qu'à chaque itération, la vraisemblance des données ne peut qu'augmenter (ou rester stable). C'est un algorithme ‘hill-climbing’.”

Q : “EM ou K-means ?” R : “K-means si vous voulez une attribution claire et rapide. EM si vous voulez un modèle probabiliste et des formes de clusters flexibles.”

Q : “Comment choisir K ?” **R :** “Utilisez des critères comme le BIC qui pénalisent la complexité, ou validez sur des données de test. Parfois, le domaine d’application donne une indication.”

14. L’astuce mnémotechnique finale

EM = Estimation Maximisation - **E** comme **Espérer** les appartenances (responsabilités) - **M** comme **Maximiser** la vraisemblance (paramètres)

GMM = Gaussiennes Multiples en Mélange - Plusieurs cloches gaussiennes - Superposées avec des poids - Modélisent des groupes dans les données

15. En résumé : L’EM, c’est...

L’art d’apprendre à partir de l’incomplétude. Une méthode puissante qui transforme l’incertitude sur les origines des données en une estimation probabiliste raffinée.

Pour finir : L’EM ne vous donne pas la vérité absolue, mais la **meilleure explication probabiliste** étant donné les observations et le modèle choisi.