

# Table of contents

|                                                          |          |
|----------------------------------------------------------|----------|
| <b>Document de Révision : Algorithme k-means</b>         | <b>2</b> |
| Introduction et Motivation . . . . .                     | 2        |
| Contexte général . . . . .                               | 2        |
| Problématique des données réelles . . . . .              | 3        |
| Terminologie alternative . . . . .                       | 3        |
| Panorama des méthodes de clustering . . . . .            | 4        |
| Principales méthodes . . . . .                           | 4        |
| Clustering hiérarchique agglomératif . . . . .           | 4        |
| Principe de l'algorithme . . . . .                       | 4        |
| Distances entre ensembles (clusters) . . . . .           | 5        |
| Stratégie k-means . . . . .                              | 5        |
| Hypothèses fondamentales . . . . .                       | 5        |
| Modèle formel . . . . .                                  | 5        |
| Fonction de perte k-means . . . . .                      | 6        |
| Problème d'optimisation . . . . .                        | 6        |
| Fonction de perte . . . . .                              | 6        |
| Complexité du problème . . . . .                         | 6        |
| Rappel : Algorithme de descente de coordonnées . . . . . | 7        |
| Principe général . . . . .                               | 7        |
| Stratégie de résolution . . . . .                        | 7        |
| Application au k-means . . . . .                         | 8        |
| Optimisation alternée de Z et M . . . . .                | 8        |
| Optimisation par rapport à M (représentants) . . . . .   | 8        |
| Mise à jour de l'assignation . . . . .                   | 9        |
| Optimisation par rapport à Z . . . . .                   | 9        |
| Règle d'assignation . . . . .                            | 9        |
| Algorithme k-means complet . . . . .                     | 9        |
| Description détaillée . . . . .                          | 9        |
| Étapes de l'algorithme . . . . .                         | 10       |
| Critères de convergence . . . . .                        | 10       |
| Visualisation du processus . . . . .                     | 11       |
| Propriétés de l'algorithme k-means . . . . .             | 12       |
| Garanties théoriques . . . . .                           | 12       |
| Interprétation géométrique . . . . .                     | 12       |
| Lien avec l'algorithme EM . . . . .                      | 12       |
| Sensibilité à l'initialisation . . . . .                 | 13       |
| Problème des optima locaux . . . . .                     | 13       |
| Stratégies pratiques . . . . .                           | 13       |
| k-means++ : Initialisation intelligente . . . . .        | 13       |
| Principe fondamental . . . . .                           | 13       |

|                                                                 |    |
|-----------------------------------------------------------------|----|
| Algorithme k-means++ détaillé . . . . .                         | 14 |
| Intuition de l'algorithme . . . . .                             | 14 |
| Adoption pratique . . . . .                                     | 15 |
| Relation entre k-means et modèles gaussiens . . . . .           | 15 |
| k-means comme cas particulier du GMM . . . . .                  | 15 |
| Formulation probabiliste . . . . .                              | 15 |
| Lien intrinsèque avec la métrique euclidienne . . . . .         | 16 |
| Pourquoi k-means dépend de la métrique euclidienne ? . . . . .  | 16 |
| Conséquences pratiques . . . . .                                | 16 |
| Clustering contraint . . . . .                                  | 16 |
| Extension de k-means . . . . .                                  | 16 |
| Application pratique . . . . .                                  | 17 |
| Synthèse des concepts clés . . . . .                            | 17 |
| Caractéristiques essentielles de k-means . . . . .              | 17 |
| Comparaison k-means vs GMM vs Clustering hiérarchique . . . . . | 18 |
| Tableau comparatif . . . . .                                    | 18 |
| Choix du nombre de clusters K . . . . .                         | 18 |
| Problématique . . . . .                                         | 18 |
| Méthodes de sélection . . . . .                                 | 19 |
| Questions d'examen types . . . . .                              | 19 |
| Questions conceptuelles . . . . .                               | 19 |
| Questions techniques . . . . .                                  | 20 |
| Développements mathématiques . . . . .                          | 20 |
| Concepts mathématiques à maîtriser . . . . .                    | 20 |
| Algèbre et géométrie . . . . .                                  | 20 |
| Optimisation . . . . .                                          | 21 |
| Probabilités et statistiques . . . . .                          | 21 |
| Conseils pratiques pour l'implémentation . . . . .              | 21 |
| Prétraitement des données . . . . .                             | 21 |
| Paramètres algorithmiques . . . . .                             | 22 |

## Document de Révision : Algorithme k-means

---

### Introduction et Motivation

#### Contexte général

L'algorithme **k-means** est une méthode d'**estimation de facteurs latents discrets** dans un contexte **non supervisé** de clustering (regroupement).

## Objectifs du cours :

- Comprendre les propriétés **géométriques et statistiques** des données
- Analyser les données et développer des outils pour cette analyse
- Aborder spécifiquement l'approche (**non supervisée**) du clustering de données
- Comprendre les **hypothèses** faites dans la conception de ces outils
- Travailler la **théorie en profondeur**

**Note importante :** Le clustering est similaire à la classification (non supervisée), l'estimation de densité, et dual à la détection d'outliers

## Problématique des données réelles

### Observation fondamentale :

Les données ne proviennent généralement **pas d'un simple processus gaussien** (variations autour d'un prototype moyen)

### Caractéristiques des données réelles :

- La distribution des données montre généralement une **non-uniformité**
- Présence de **régions de densité plus élevée**

### Définition du clustering :

Le clustering est une méthode **non supervisée** qui vise à découvrir des **groupes cohérents** de données, correspondant à des **pics de densité** des données

## Terminologie alternative

### Vector Quantization (VQ) :

Synonyme souvent utilisé (en traitement du signal) pour le clustering, signifiant “quantification multi-dimensionnelle”

## **Panorama des méthodes de clustering**

### **Principales méthodes**

Il existe un grand nombre de méthodes de clustering, incluant :

#### **Méthodes hiérarchiques :**

- Hierarchical Agglomerative Clustering (HAC)

#### **Méthodes de partitionnement :**

- **k-means** (algorithme de Lloyd)
- k-medoids

#### **Méthodes spectrales :**

- Spectral clustering

#### **Autres approches :**

- Community detection
- High-dimensional clustering
- Self-Organizing Maps (SOM)
- Neural Gas

**Note historique :** La recherche sur le clustering est active depuis au moins 50 ans

---

## **Clustering hiérarchique agglomératif**

### **Principe de l'algorithme**

#### **Processus itératif :**

##### **Étape 1 : Initialisation**

Chaque donnée est un cluster

##### **Étape 2 : Recherche**

Trouver la paire de clusters la plus proche

##### **Étape 3 : Fusion**

Fusionner ces deux clusters

#### Étape 4 : Itération

Répéter depuis l'étape 2 jusqu'à la fin

**Résultat** : Production d'un **dendrogramme** des données

#### Distances entre ensembles (clusters)

Métriques possibles :

- **Distance entre centres** (centroid linkage)
- **Distance maximale** (complete linkage) :  $\max_{x \in C_1, y \in C_2} d(x, y)$
- **Distance minimale** (single linkage) :  $\min_{x \in C_1, y \in C_2} d(x, y)$

**Limitation** : Le nombre de clusters est **inconnu a priori**

---

#### Stratégie k-means

##### Hypothèses fondamentales

L'algorithme de clustering **k-means** postule :

- Un espace métrique (**euclidien**) normé sur les données
- Une assignation **non supervisée** des données aux clusters
- Un algorithme d'**assignation dure** (hard-assignment) : l'assignation est **binaire**, chaque donnée est assignée à **un et un seul** cluster

##### Modèle formel

**Données** :

Soit  $X = \{x_i\}_{i \in [[N]]} \subset \Omega \subseteq \mathbb{R}^D$ , et  $K \in \mathbb{N}^*$  donné

**Variables du modèle** :

**Variables d'assignation binaire (latentes)** :

$$Z = \{z_{ik}\} \quad \text{avec} \quad z_{ik} \in \{\text{false}, \text{true}\} \equiv \{0, 1\} \quad \forall i, k$$

**Représentants des clusters** :

$$M = \{\mu_k\}_{k \in [K]} \quad \text{avec} \quad \mu_k \in \mathbb{R}^D \quad \forall k$$

**Paramètres complets :**

$$\theta = [M, Z]$$


---

## Fonction de perte k-means

### Problème d'optimisation

k-means cherche l'assignation suivante :

$$\hat{\theta} = [\hat{M}, \hat{Z}] = \arg \min_{\theta=[M,Z]} L(\theta, X)$$

### Fonction de perte

**Définition :**

$$L(\theta, X) = \sum_{i=1}^N \sum_{k=1}^K z_{ik} \|x_i - \mu_k\|_2^2$$

**Interprétation :**

- Somme des **distances au carré** entre chaque point et son représentant de cluster
- Plus cette somme est petite, meilleure est la partition

### Complexité du problème

**Difficulté majeure :** Puisque l'assignation est binaire, l'optimisation exacte est **NP-Hard**

**Solution pratique :** Chercher une **approximation par descente de coordonnées** (coordinate descent)

---

## Rappel : Algorithme de descente de coordonnées

### Principe général

La descente de coordonnées est un **algorithme de minimisation alternée** :

#### Problème :

Soit  $f : \mathbb{R}^D \rightarrow \mathbb{R}$ , on cherche :

$$x^* = \arg \min_{x \in \mathbb{R}^D} f(x)$$

### Stratégie de résolution

#### Définition des fonctions partielles :

Pour  $d \in [[D]]$ , on définit  $f^d : \mathbb{R}^D \times \mathbb{R} \rightarrow \mathbb{R}$  :

$$f^d(x, y) = f([x(1), \dots, x(d-1), y, x(d+1), \dots, x(D)]^T)$$

#### Optimisation alternée :

On cherche alternativement le minimum selon chaque coordonnée :

$$x^{(t+1)}(d) = \arg \min_y f^d(x^{(t)}, y)$$

**Principe :** Fixer toutes les variables sauf une, optimiser cette variable, puis passer à la suivante

---

## Application au k-means

### Optimisation alternée de Z et M

On alterne l'optimisation de Z et M

Définitions des pertes partielles :

$$L_M(Z) = L(\theta, X)|_{M=\bar{M}}$$

$$L_Z(M) = L(\theta, X)|_{Z=\bar{Z}}$$

### Optimisation par rapport à M (représentants)

Calcul de la dérivée :

$$\frac{\partial L_Z}{\partial \mu_k} = -2 \sum_{i=1}^N z_{ik}(x_i - \mu_k)$$

Condition d'optimalité :

Le représentant optimal M pour une assignation donnée Z est atteint quand :

$$\frac{\partial L_Z}{\partial \mu_k} = 0 \quad \Rightarrow \quad \mu_k = \frac{\sum_{i=1}^N z_{ik} x_i}{\sum_{i=1}^N z_{ik}}$$

**Conclusion fondamentale :** Les représentants des clusters sont leurs **centres de masse** (barycentres)

---



## Mise à jour de l'assignation

### Optimisation par rapport à Z

Étant donné un ensemble de représentants de clusters  $M$ , pour minimiser  $L_M(Z)$  :

Rappel de la perte :

$$L_M(Z) = \left[ \sum_{i=1}^N \sum_{k=1}^K z_{ik} \|x_i - \mu_k\|_2^2 \right]_{M=\bar{M}}$$

### Règle d'assignation

C'est une **somme de termes positifs**  $\rightarrow$  on assigne :

$$z_{ik} = 1 \quad \text{seulement quand} \quad k = \arg \min_m \|x_i - \mu_m\|_2^2$$

(et  $z_{ik} = 0$  sinon)

**Conclusion :**  $L_M(Z)$  est minimale quand **chaque donnée est assignée à son représentant de cluster le plus proche**

---

## Algorithme k-means complet

### Description détaillée

Données d'entrée :

- $X = \{x_i\}_{i \in [N]}$  avec  $x_i \in \mathbb{R}^D$
- $K \in \mathbb{N}^*$  (nombre de clusters)

## Étapes de l'algorithme

### Étape 1 : Initialisation

Initialiser les représentants de clusters  $M^{(0)}$

### Étape 2 : Assignment (E-step like)

Étant donné les représentants de clusters  $M^{(t)}$ , l'assignation  $Z^{(t)}$  associe chaque donnée à son représentant de cluster le plus proche :

$$z_{ik}^{(t)} = \begin{cases} 1 & \text{si } k = \arg \min_m \|x_i - \mu_m^{(t)}\|_2^2 \\ 0 & \text{sinon} \end{cases}$$

### Étape 3 : Mise à jour (M-step like)

Étant donné l'assignation  $Z^{(t)}$ , les nouveaux représentants de clusters  $M^{(t+1)}$  sont les centres de masse des données assignées aux clusters :

$$\mu_k^{(t+1)} = \frac{\sum_{i=1}^N z_{ik}^{(t)} x_i}{\sum_{i=1}^N z_{ik}^{(t)}}$$

### Étape 4 : Convergence


Répéter depuis l'étape 2 jusqu'à convergence

### Critères de convergence

La convergence est atteinte quand :

- Les centres de masse **ne bougent plus beaucoup** :  $\|\mu_k^{(t+1)} - \mu_k^{(t)}\| < \epsilon$
- Ou l'assignation est **stable** :  $Z^{(t+1)} = Z^{(t)}$

## Visualisation du processus



**Note importante :** L'étape 2 est similaire à une étape d'**Expectation**, et l'étape 3 est similaire à une étape de **Maximization**, en considérant une assignation dure (référence à l'algorithme EM)

---

## Propriétés de l'algorithme k-means

### Garanties théoriques

#### Décroissance de la perte :

Puisqu'il effectue une **minimisation alternée de fonctions convexes**, il garantit de **diminuer la perte à chaque itération** :

$$L(M^{(t+1)}, Z^{(t+1)}) \leq L(M^{(t)}, Z^{(t)})$$

#### Finitude :

Il existe un nombre **combinatoire mais fini** d'assignations possibles  $\rightarrow$  le nombre d'itérations est **(grand mais) fini**

### Interprétation géométrique

#### Diagramme de Voronoï :

L'étape 2 est équivalente à construire le **diagramme de Voronoï discret** de  $X$  avec les centres  $M$  comme graines (seeds)

**Définition** : Le diagramme de Voronoï partitionne l'espace en régions, où chaque région contient tous les points plus proches d'un centre donné que de tout autre centre

### Lien avec l'algorithme EM

#### Comparaison conceptuelle :

- **Étape 2 (Assignment)** : similaire à une étape **Expectation** (mais dure)
- **Étape 3 (Mise à jour)** : similaire à une étape **Maximization**

**Différence clé** : k-means utilise une **assignation dure** (hard-assignment) tandis que EM utilise une **assignation douce** (soft-assignment)

## Sensibilité à l'initialisation

### Problème des optima locaux

**Limitation majeure :** Puisque l'optimisation exacte (assignation optimale) est **NP-Hard**, l'algorithme k-means atteint un **optimum local**

#### Conséquences :

- La qualité du résultat **varie selon l'initialisation**
- Différentes initialisations peuvent donner des résultats très différents

### Stratégies pratiques

#### Randomisation :

La randomisation peut être utile si le calcul est rapide → lancer plusieurs fois avec différentes initialisations

#### Heuristiques :

Sinon, utiliser des **heuristiques pour une meilleure initialisation** (comme k-means++)

---

## k-means++ : Initialisation intelligente

### Principe fondamental

Le principe de **k-means++** est de **maximalement disperser** les représentants de clusters initiaux  $M^{(0)}$  sur les données

#### Avantages démontrés :

1. Produit des clusters de **meilleure qualité**
2. **Accélère la convergence** de k-means

## Algorithme k-means++ détaillé

### Étape 1 : Premier centre

Sélectionner le premier représentant de cluster  $\mu_1^0$  **aléatoirement** parmi les données  $X$

### Étape 2 : Calcul des distances

Pour toutes les données non sélectionnées  $x_i$ , calculer :

$$\Delta_i = \|x_i - \mu_m^0\|_2^2$$

la distance entre  $x_i$  et son représentant le plus proche  $\mu_m^0$  parmi les  $k$  représentants déjà sélectionnés

### Étape 3 : Échantillonnage pondéré

Échantillonner le prochain représentant  $\mu_{k+1}^0$  depuis  $X$  avec une **probabilité proportionnelle** à la distribution  $\Delta$

$$\mathbb{P}(\text{choisir } x_i) = \frac{\Delta_i}{\sum_j \Delta_j}$$

### Étape 4 : Itération

Répéter depuis l'étape 2 jusqu'à ce que  $K$  représentants soient choisis

## Intuition de l'algorithme

**Idée clé :** Les points **loin des centres déjà sélectionnés** ont plus de chances d'être choisis comme nouveaux centres

**Conséquence :** Les centres initiaux sont bien **répartis dans l'espace des données**, couvrant les différentes régions de densité

## Adoption pratique

**Utilisation répandue :** Cette stratégie d'initialisation est utilisée par plusieurs packages de Data Science :

- MATLAB™
  - Python SciKit Learn
  - R
  - Et autres bibliothèques standards
- 

## Relation entre k-means et modèles gaussiens

### k-means comme cas particulier du GMM

**Question :** Pourquoi dit-on que k-means considère un **modèle gaussien** pour les clusters ?

**Réponse :**

k-means peut être vu comme un cas limite de GMM (Gaussian Mixture Model) où :

**Hypothèses du modèle :**

- Chaque cluster suit une distribution **normale**
- Matrices de covariance **sphériques et identiques** :  $\Sigma_k = \sigma^2 I_D$  pour tous les clusters
- Variance  $\sigma^2 \rightarrow 0$  : les distributions deviennent des pics

**Conséquence :**

Dans cette limite, l'**assignation douce** (soft-assignment) du GMM devient une **assignation dure** (hard-assignment), et on retrouve k-means

### Formulation probabiliste

Si on considère le modèle probabiliste :

$$\mathbb{P}(x|\mu_k, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{D/2}} \exp\left(-\frac{\|x - \mu_k\|^2}{2\sigma^2}\right)$$

Quand  $\sigma \rightarrow 0$ , maximiser cette probabilité est équivalent à minimiser  $\|x - \mu_k\|^2$ , ce qui est exactement le critère de k-means

---

## Lien intrinsèque avec la métrique euclidienne

### Pourquoi k-means dépend de la métrique euclidienne ?

Analyse de la fonction de perte :

$$L(\theta, X) = \sum_{i=1}^N \sum_{k=1}^K z_{ik} \|x_i - \mu_k\|_2^2$$

La norme  $\|\cdot\|_2$  est la **norme euclidienne** :  $\|x\|_2^2 = \sum_d x(d)^2$

### Conséquences pratiques

Sensibilité à l'échelle :

k-means est **sensible à l'échelle** des variables. Des variables avec de grandes valeurs dominent la distance

**Solution : Normalisation** des données avant d'appliquer k-means :

- Centrer : soustraire la moyenne
- Réduire : diviser par l'écart-type

**Limitation aux espaces euclidiens :**

k-means ne peut pas être directement appliqué à des données **non-euclidiennes** (graphes, textes, etc.)

**Alternatives :** Pour d'autres métriques, utiliser des variantes comme k-medoids qui fonctionnent avec des distances arbitraires

---

## Clustering contraint

### Extension de k-means

Le clustering peut être **contraint** avec :

**Contraintes MUST-LINK :**

Deux points doivent être dans le **même cluster**

**Contraintes CANNOT-LINK :**

Deux points doivent être dans des **clusters différents**



## Application pratique

Ces contraintes permettent d'incorporer des **connaissances a priori** ou des **contraintes du domaine** dans le processus de clustering

---

## Synthèse des concepts clés

### Caractéristiques essentielles de k-means

#### Nature de la méthode :

- k-means fait partie de la famille **non supervisée** de techniques de modélisation de données
- Une des techniques de clustering les **plus populaires**

#### Assignment :

- k-means effectue une **assignment dure** (hard-assignment)
- Chaque point appartient à **un seul cluster**

#### Optimisation :

- Critère d'optimisation (perte) **solide** mais **NP-Hard**
- L'algorithme k-means cherche une **solution approximative** par descente de coordonnées (minimisation alternée)

#### Convergence :

- La perte **n'est pas convexe** → technique **sensible à l'initialisation**
- k-means++ est une **heuristique a priori** pour l'initialisation, efficace en pratique

#### Extensions :

- Clustering peut être **contraint** (contraintes MUST-LINK et CANNOT-LINK)
-

## Comparaison k-means vs GMM vs Clustering hiérarchique

### Tableau comparatif

#### k-means :

- **Type d'assignation** : Dure (hard)
- **Forme des clusters** : Sphériques (même variance)
- **Nombre de clusters** : Doit être spécifié
- **Complexité** :  $O(N \cdot K \cdot D \cdot T)$  où  $T$  est le nombre d'itérations
- **Avantages** : Rapide, simple
- **Inconvénients** : Sensible à l'initialisation, suppose clusters sphériques

#### GMM (avec EM) :

- **Type d'assignation** : Douce (soft)
- **Forme des clusters** : Elliptiques (covariances différentes)
- **Nombre de clusters** : Doit être spécifié
- **Complexité** :  $O(N \cdot K \cdot D^2 \cdot T)$
- **Avantages** : Modèle probabiliste, clusters de formes variées
- **Inconvénients** : Plus lent, plus de paramètres à estimer

#### Clustering hiérarchique :

- **Type d'assignation** : Hiérarchique
- **Forme des clusters** : Flexible
- **Nombre de clusters** : Déterminé a posteriori (dendrogramme)
- **Complexité** :  $O(N^2 \log N)$  ou  $O(N^3)$
- **Avantages** : Pas besoin de spécifier  $K$ , visualisation par dendrogramme
- **Inconvénients** : Coûteux pour grandes données, pas de réassignation

---

## Choix du nombre de clusters $K$

### Problématique

**Difficulté** : Le nombre de clusters  $K$  doit être **spécifié a priori** dans k-means

## Méthodes de sélection

### Méthode du coude (Elbow method) :

Tracer la perte  $L$  en fonction de  $K$  et chercher un “coude” dans la courbe

### Silhouette score :

Mesure la qualité du clustering en comparant la distance intra-cluster à la distance inter-cluster

### Gap statistic :

Compare la perte observée à la perte attendue sous une distribution de référence

### Critères d’information :

- BIC (Bayesian Information Criterion)
- AIC (Akaike Information Criterion)

**Conseil pratique :** Tester plusieurs valeurs de  $K$  et utiliser des critères multiples

---

## Questions d’examen types

### Questions conceptuelles

#### Description formelle :

- Décrire formellement le clustering
- En quel sens est-ce une technique non supervisée ?

#### Relation avec la métrique :

- Expliquer pourquoi k-means est intrinsèquement lié à la métrique euclidienne
- Pourquoi dit-on que k-means considère un modèle gaussien pour les clusters ?

#### Exactitude :

- L’algorithme k-means est-il exact ?
- Quelles sont les garanties théoriques ?

## Questions techniques

### Initialisation :

- Quels sont les principes pour initialiser k-means ?
- Décrire l'algorithme k-means++

### Optimisation :

- Qu'est-ce que l'algorithme de descente de coordonnées ?
- Comment s'applique-t-il à k-means ?

### Relation avec d'autres méthodes :

- Quelle est la relation entre k-means et GMM ?
- Quelle est la différence entre assignation dure et douce ?

## Développements mathématiques

**Conseil important :** Il est **fortement recommandé** de développer l'algèbre contenue dans ce chapitre

### Points à maîtriser :

- Dérivation de la fonction de perte
- Calcul de  $\frac{\partial L_Z}{\partial \mu_k}$  et condition d'optimalité
- Preuve que les centres sont les barycentres
- Preuve de la décroissance monotone de la perte
- Relation entre k-means et modèle gaussien limite

---

## Concepts mathématiques à maîtriser

### Algèbre et géométrie

#### Fondamentaux :

- Norme euclidienne et distance
- Centre de masse (barycentre)
- Diagramme de Voronoï
- Espaces métriques

## **Optimisation**

### **Techniques :**

- Descente de coordonnées
- Minimisation alternée
- Optimisation combinatoire
- Complexité NP-Hard

### **Propriétés :**

- Convergence d'algorithmes itératifs
- Optima locaux vs globaux
- Fonctions convexes

## **Probabilités et statistiques**

### **Concepts :**

- Distribution gaussienne multivariée
- Maximum de vraisemblance
- Modèles de mélange

---

## **Conseils pratiques pour l'implémentation**

### **Prétraitement des données**

#### **Étapes recommandées :**

1. **Normalisation** : centrer et réduire les variables
2. **Gestion des outliers** : détecter et traiter les valeurs aberrantes
3. **Réduction de dimension** : PCA si  $D$  très grand

## Paramètres algorithmiques

### Initialisation :

- Utiliser **k-means++** par défaut
- Ou lancer **plusieurs fois** avec initialisations aléatoires

### Convergence :

- Seuil de tolérance :  $\epsilon = 10^{-4}$  typiquement
- Nombre maximum d'itérations : éviter les boucles infinies

### Choix de **K** :

- Tester plusieurs valeurs
- Utiliser des critères de validation