

Table of contents

Cours détaillé	2
Introduction et Motivation	2
Contexte général	2
Problématique des données réelles	2
Terminologie alternative	3
Panorama des méthodes de clustering	3
Clustering hiérarchique agglomératif	4
Principe de l'algorithme	4
Distances entre ensembles (clusters)	4
Stratégie k-means	4
Hypothèses fondamentales	4
Modèle formel	5
Fonction de perte k-means	5
Rappel : Algorithme de descente de coordonnées	6
Application au k-means	7
Mise à jour de l'assignation	7
Algorithme k-means complet	8
Description détaillée	8
Étapes de l'algorithme	8
Critères de convergence	9
Visualisation du processus	10
Propriétés de l'algorithme k-means	11
Garanties théoriques	11
Interprétation géométrique	11
Lien avec l'algorithme EM	11
Sensibilité à l'initialisation	12
Variantes, liens et relations	12
k-means++ : Initialisation intelligente	12
Relation entre k-means et modèles gaussiens	14
Lien intrinsèque avec la métrique euclidienne	14
Clustering contraint	15
Synthèse des concepts clés	16
Caractéristiques essentielles de k-means	16
Comparaison k-means vs GMM vs Clustering hiérarchique	16
Choix du nombre de clusters K	17
Questions d'examen types	18
Questions conceptuelles	18
Questions techniques	18
Développements mathématiques	19

Concepts mathématiques à maîtriser	19
Algèbre et géométrie	19
Optimisation	19
Probabilités et statistiques	20
Conseils pratiques pour l'implémentation	20
Prétraitement des données	20
Paramètres algorithmiques	20

Cours détaillé

Introduction et Motivation

Contexte général

L'algorithme **k-means** est une méthode d'**estimation de facteurs latents discrets** dans un contexte **non supervisé** de clustering (regroupement).

Objectifs du cours :

- Comprendre les propriétés **géométriques et statistiques** des données
- Analyser les données et développer des outils pour cette analyse
- Aborder spécifiquement l'approche (**non supervisée**) du clustering de données
- Comprendre les **hypothèses** faites dans la conception de ces outils
- Travailler la **théorie en profondeur**

Note importante : Le clustering est similaire à la classification (non supervisée), l'estimation de densité, et dual à la détection d'outliers

Problématique des données réelles

Observation fondamentale :

Les données ne proviennent généralement **pas d'un simple processus gaussien** (variations autour d'un prototype moyen)

Caractéristiques des données réelles :

- La distribution des données montre généralement une **non-uniformité**
- Présence de **régions de densité plus élevée**

Définition du clustering :

Le clustering est une méthode **non supervisée** qui vise à découvrir des **groupes cohérents** de données, correspondant à des **pics de densité** des données

Terminologie alternative

Vector Quantization (VQ) :

Synonyme souvent utilisé (en traitement du signal) pour le clustering, signifiant “quantification multi-dimensionnelle”

Panorama des méthodes de clustering

Principales méthodes

Il existe un grand nombre de méthodes de clustering, incluant :

Méthodes hiérarchiques :

- Hierarchical Agglomerative Clustering (HAC)

Méthodes de partitionnement :

- **k-means** (algorithme de Lloyd)
- k-medoids

Méthodes spectrales :

- Spectral clustering

Autres approches :

- Community detection
- High-dimensional clustering
- Self-Organizing Maps (SOM)
- Neural Gas

Note historique : La recherche sur le clustering est active depuis au moins 50 ans

Clustering hiérarchique agglomératif

Principe de l'algorithme

Processus itératif :

Étape 1 : Initialisation

- Chaque donnée est un cluster

Étape 2 : Recherche

- Trouver la paire de clusters la plus proche

Étape 3 : Fusion

- Fusionner ces deux clusters

Étape 4 : Itération

- Répéter depuis l'étape 2 jusqu'à la fin

Résultat : Production d'un **dendrogramme** des données

Distances entre ensembles (clusters)

Métriques possibles :

- **Distance entre centres** (centroid linkage)
- **Distance maximale** (complete linkage) : $\max_{x \in C_1, y \in C_2} d(x, y)$
- **Distance minimale** (single linkage) : $\min_{x \in C_1, y \in C_2} d(x, y)$

Limitation : Le nombre de clusters est **inconnu a priori**

Stratégie k-means

Hypothèses fondamentales

L'algorithme de clustering **k-means** postule :

- Un espace métrique (**euclidien**) normé sur les données
- Une assignation **non supervisée** des données aux clusters
- Un algorithme d'**assignation dure** (hard-assignment) : l'assignation est **binaire**, chaque donnée est assignée à **un et un seul** cluster

Modèle formel

Données :

Soit $X = \{x_i\}_{i \in [[N]]} \subset \Omega \subseteq \mathbb{R}^D$, et $K \in \mathbb{N}^*$ donné

Variables du modèle :

- Variables d'assignation binaire (latentes) :

$$Z = \{z_{ik}\} \quad \text{avec} \quad z_{ik} \in \{\text{false}, \text{true}\} \equiv \{0, 1\} \quad \forall i, k$$

- Représentants des clusters :

$$M = \{\mu_k\}_{k \in [[K]]} \quad \text{avec} \quad \mu_k \in \mathbb{R}^D \quad \forall k$$

Paramètres complets :

$$\theta = [M, Z]$$

Fonction de perte k-means

Problème d'optimisation

k-means cherche l'assignation suivante :

$$\hat{\theta} = [\hat{M}, \hat{Z}] = \arg \min_{\theta = [M, Z]} L(\theta, X)$$

Fonction de perte

Définition :

$$L(\theta, X) = \sum_{i=1}^N \sum_{k=1}^K z_{ik} \|x_i - \mu_k\|_2^2$$

Interprétation :

- Somme des **distances au carré** entre chaque point et son représentant de cluster
- Plus cette somme est petite, meilleure est la partition

Complexité du problème

Difficulté majeure : Puisque l'assignation est binaire, l'optimisation exacte est **NP-Hard**

Solution pratique : Chercher une **approximation par descente de coordonnées** (coordinate descent)

Rappel : Algorithme de descente de coordonnées

Principe général

La descente de coordonnées est un **algorithme de minimisation alternée** :

Problème :

Soit $f : \mathbb{R}^D \rightarrow \mathbb{R}$, on cherche :

$$x^* = \arg \min_{x \in \mathbb{R}^D} f(x)$$

Stratégie de résolution

Définition des fonctions partielles :

Pour $d \in [[D]]$, on définit $f^d : \mathbb{R}^D \times \mathbb{R} \rightarrow \mathbb{R}$:

$$f^d(x, y) = f([x(1), \dots, x(d-1), y, x(d+1), \dots, x(D)]^T)$$

Optimisation alternée :

On cherche alternativement le minimum selon chaque coordonnée :

$$x^{(t+1)}(d) = \arg \min_y f^d(x^{(t)}, y)$$

Principe : Fixer toutes les variables sauf une, optimiser cette variable, puis passer à la suivante

Application au k-means

Optimisation alternée de Z et M

On alterne l'optimisation de Z et M

Définitions des pertes partielles :

$$L_M(Z) = L(\theta, X)|_{M=M}$$

$$L_Z(M) = L(\theta, X)|_{Z=Z}$$

Optimisation par rapport à M (représentants)

Calcul de la dérivée :

$$\frac{\partial L_Z}{\partial \mu_k} = -2 \sum_{i=1}^N z_{ik} (x_i - \mu_k)$$

Condition d'optimalité :

Le représentant optimal M pour une assignation donnée Z est atteint quand :

$$\frac{\partial L_Z}{\partial \mu_k} = 0 \quad \Rightarrow \quad \mu_k = \frac{\sum_{i=1}^N z_{ik} x_i}{\sum_{i=1}^N z_{ik}}$$

Conclusion fondamentale : Les représentants des clusters sont leurs **centres de masse** (barycentres)

Mise à jour de l'assignation

Optimisation par rapport à Z

Étant donné un ensemble de représentants de clusters M , pour minimiser $L_M(Z)$:

Rappel de la perte :

$$L_M(Z) = \left[\sum_{i=1}^N \sum_{k=1}^K z_{ik} \|x_i - \mu_k\|_2^2 \right]_{M=M}$$

Règle d'assignation

C'est une **somme de termes positifs** $\rightarrow$ on assigne :

$$z_{ik} = 1 \quad \text{seulement quand} \quad k = \arg \min_m \|x_i - \mu_m\|_2^2$$

(et $z_{ik} = 0$ sinon)

Conclusion : $L_M(Z)$ est minimale quand **chaque donnée est assignée à son représentant de cluster le plus proche**

Algorithme k-means complet

Description détaillée

Données d'entrée :

- $X = \{x_i\}_{i \in [[N]]}$ avec $x_i \in \mathbb{R}^D$
- $K \in \mathbb{N}^*$ (nombre de clusters)

Étapes de l'algorithme

Étape 1 : Initialisation

Initialiser les représentants de clusters $M^{(0)}$

Étape 2 : Assignation (E-step like)

Étant donné les représentants de clusters $M^{(t)}$, l'assignation $Z^{(t)}$ associe chaque donnée à son représentant de cluster le plus proche :

$$z_{ik}^{(t)} = \begin{cases} 1 & \text{si } k = \arg \min_m \|x_i - \mu_m^{(t)}\|_2^2 \\ 0 & \text{sinon} \end{cases}$$

Étape 3 : Mise à jour (M-step like)

Étant donné l'assignation $Z^{(t)}$, les nouveaux représentants de clusters $M^{(t+1)}$ sont les centres de masse des données assignées aux clusters :

$$\mu_k^{(t+1)} = \frac{\sum_{i=1}^N z_{ik}^{(t)} x_i}{\sum_{i=1}^N z_{ik}^{(t)}}$$

Étape 4 : Convergence


Répéter depuis l'étape 2 jusqu'à convergence

Critères de convergence

La convergence est atteinte quand :

- Les centres de masse **ne bougent plus beaucoup** : $\|\mu_k^{(t+1)} - \mu_k^{(t)}\| < \epsilon$
- Ou l'assignation est **stable** : $Z^{(t+1)} = Z^{(t)}$

Visualisation du processus



Note importante : L'étape 2 est similaire à une étape d'**Expectation**, et l'étape 3 est similaire à une étape de **Maximization**, en considérant une assignation dure (référence à l'algorithme EM)

Propriétés de l'algorithme k-means

Garanties théoriques

Décroissance de la perte :

Puisqu'il effectue une **minimisation alternée de fonctions convexes**, il garantit de **diminuer la perte à chaque itération** :

$$L(M^{(t+1)}, Z^{(t+1)}) \leq L(M^{(t)}, Z^{(t)})$$

Finitude :

Il existe un nombre **combinatoire mais fini** d'assignations possibles $\rightarrow$ le nombre d'itérations est **(grand mais) fini**

Interprétation géométrique

Diagramme de Voronoï :

L'étape 2 est équivalente à construire le **diagramme de Voronoï discret** de X avec les centres M comme graines (seeds)

Définition : Le diagramme de Voronoï partitionne l'espace en régions, où chaque région contient tous les points plus proches d'un centre donné que de tout autre centre

Lien avec l'algorithme EM

Comparaison conceptuelle :

- **Étape 2 (Assignment)** : similaire à une étape **Expectation** (mais dure)
- **Étape 3 (Mise à jour)** : similaire à une étape **Maximization**

Différence clé : k-means utilise une **assignation dure** (hard-assignment) tandis que EM utilise une **assignation douce** (soft-assignment)

Sensibilité à l'initialisation

Problème des optima locaux

Limitation majeure : Puisque l'optimisation exacte (assignation optimale) est **NP-Hard**, l'algorithme k-means atteint un **optimum local**

Conséquences :

- La qualité du résultat **varie selon l'initialisation**
- Différentes initialisations peuvent donner des résultats très différents

Stratégies pratiques

Randomisation :

La randomisation peut être utile si le calcul est rapide → lancer plusieurs fois avec différentes initialisations

Heuristiques :

Sinon, utiliser des **heuristiques pour une meilleure initialisation** (comme k-means++)

Variantes, liens et relations

k-means++ : Initialisation intelligente

Principe fondamental

Le principe de **k-means++** est de **maximalement disperser** les représentants de clusters initiaux $M^{(0)}$ sur les données

Avantages démontrés :

1. Produit des clusters de **meilleure qualité**
2. **Accélère la convergence** de k-means

Algorithme k-means++ détaillé

Étape 1 : Premier centre

Sélectionner le premier représentant de cluster μ_1^0 **aléatoirement** parmi les données X

Étape 2 : Calcul des distances

Pour toutes les données non sélectionnées x_i , calculer :

$$\Delta_i = \|x_i - \mu_m^0\|_2^2$$

la distance entre x_i et son représentant le plus proche μ_m^0 parmi les k représentants déjà sélectionnés

Étape 3 : Échantillonnage pondéré

Échantillonner le prochain représentant μ_{k+1}^0 depuis X avec une **probabilité proportionnelle** à la distribution Δ

$$\mathbb{P}(\text{choisir } x_i) = \frac{\Delta_i}{\sum_j \Delta_j}$$

Étape 4 : Itération

Répéter depuis l'étape 2 jusqu'à ce que K représentants soient choisis

Intuition de l'algorithme

Idee clé : Les points **loin des centres déjà sélectionnés** ont plus de chances d'être choisis comme nouveaux centres

Conséquence : Les centres initiaux sont bien **répartis dans l'espace des données**, couvrant les différentes régions de densité

Adoption pratique

Utilisation répandue : Cette stratégie d'initialisation est utilisée par plusieurs packages de Data Science :

- MATLAB™
- Python SciKit Learn
- R
- Et autres bibliothèques standards

Relation entre k-means et modèles gaussiens

k-means comme cas particulier du GMM

Question : Pourquoi dit-on que k-means considère un **modèle gaussien** pour les clusters ?

Réponse :

k-means peut être vu comme un cas limite de GMM (Gaussian Mixture Model) où :

Hypothèses du modèle :

- Chaque cluster suit une distribution **normale**
- Matrices de covariance **sphériques et identiques** : $\Sigma_k = \sigma^2 I_D$ pour tous les clusters
- Variance $\sigma^2 \rightarrow 0$: les distributions deviennent des pics

Conséquence :

Dans cette limite, l'**assignation douce** (soft-assignment) du GMM devient une **assignation dure** (hard-assignment), et on retrouve k-means

Formulation probabiliste

Si on considère le modèle probabiliste :

$$\mathbb{P}(x|\mu_k, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{D/2}} \exp\left(-\frac{\|x - \mu_k\|^2}{2\sigma^2}\right)$$

Quand $\sigma \rightarrow 0$, maximiser cette probabilité est équivalent à minimiser $\|x - \mu_k\|^2$, ce qui est exactement le critère de k-means

Lien intrinsèque avec la métrique euclidienne

Pourquoi k-means dépend de la métrique euclidienne ?

Analyse de la fonction de perte :

$$L(\theta, X) = \sum_{i=1}^N \sum_{k=1}^K z_{ik} \|x_i - \mu_k\|_2^2$$

La norme $\|\cdot\|_2$ est la **norme euclidienne** : $\|x\|_2^2 = \sum_d x(d)^2$

Conséquences pratiques

Sensibilité à l'échelle :

k-means est **sensible à l'échelle** des variables. Des variables avec de grandes valeurs dominent la distance

Solution : Normalisation des données avant d'appliquer k-means :

- Centrer : soustraire la moyenne
- Réduire : diviser par l'écart-type

Limitation aux espaces euclidiens :

k-means ne peut pas être directement appliqué à des données **non-euclidiennes** (graphes, textes, etc.)

Alternatives : Pour d'autres métriques, utiliser des variantes comme k-medoids qui fonctionnent avec des distances arbitraires

Clustering contraint

Extension de k-means

Le clustering peut être **contraint** avec :

Contraintes MUST-LINK :

Deux points doivent être dans le **même cluster**

Contraintes CANNOT-LINK :

Deux points doivent être dans des **clusters différents**

Application pratique

Ces contraintes permettent d'incorporer des **connaissances a priori** ou des **contraintes du domaine** dans le processus de clustering

Synthèse des concepts clés

Caractéristiques essentielles de k-means

Nature de la méthode :

- k-means fait partie de la famille **non supervisée** de techniques de modélisation de données
- Une des techniques de clustering les **plus populaires**

Assignment :

- k-means effectue une **assignment dure** (hard-assignment)
- Chaque point appartient à **un seul cluster**

Optimisation :

- Critère d'optimisation (perte) **solide** mais **NP-Hard**
- L'algorithme k-means cherche une **solution approximative** par descente de coordonnées (minimisation alternée)

Convergence :

- La perte **n'est pas convexe** → technique **sensible à l'initialisation**
- k-means++ est une **heuristique a priori** pour l'initialisation, efficace en pratique

Extensions :

- Clustering peut être **contraint** (contraintes MUST-LINK et CANNOT-LINK)

Comparaison k-means vs GMM vs Clustering hiérarchique

Critère	k-means	GMM (avec EM)	Clustering hiérarchique
Type d'assignment	Dure (hard)	Douce (soft)	Hiérarchique
Forme des clusters	Sphériques(même variance)	Elliptiques(covariances différentes)	Flexible

Critère	k-means	GMM (avec EM)	Clustering hiérarchique
Nom- bre de clus- ters	Doit être spécifié	Doit être spécifié	Déterminé a posteriori(dendrogramme)
Com- plexité	$O(N \cdot K \cdot D \cdot T)$ où T est le nombre d'itérations	$O(N \cdot K \cdot D^2 \cdot T)$	$O(N^2 \log N)$ ou $O(N^3)$
Avan- tages	Rapide simple	Modèle probabiliste clusters de formes variées	Pas besoin de spécifier K visualisation par dendrogramme
Incon- vénients	Sensible à l'initialisation suppose clusters sphériques	Plus lent plus de paramètres à estimer	Coûteux pour grandes données pas de réassignation

Choix du nombre de clusters K

Problématique

Difficulté : Le nombre de clusters K doit être **spécifié a priori** dans k-means

Méthodes de sélection

Méthode du coude (Elbow method) :

Tracer la perte L en fonction de K et chercher un “coude” dans la courbe

Silhouette score :

Mesure la qualité du clustering en comparant la distance intra-cluster à la distance inter-cluster

Gap statistic :

Compare la perte observée à la perte attendue sous une distribution de référence

Critères d'information :

- BIC (Bayesian Information Criterion)
- AIC (Akaike Information Criterion)

Conseil pratique : Tester plusieurs valeurs de K et utiliser des critères multiples

Questions d'examen types

Questions conceptuelles

Description formelle :

- Décrire formellement le clustering
- En quel sens est-ce une technique non supervisée ?

Relation avec la métrique :

- Expliquer pourquoi k-means est intrinsèquement lié à la métrique euclidienne
- Pourquoi dit-on que k-means considère un modèle gaussien pour les clusters ?

Exactitude :

- L'algorithme k-means est-il exact ?
- Quelles sont les garanties théoriques ?

Questions techniques

Initialisation :

- Quels sont les principes pour initialiser k-means ?
- Décrire l'algorithme k-means++

Optimisation :

- Qu'est-ce que l'algorithme de descente de coordonnées ?
- Comment s'applique-t-il à k-means ?

Relation avec d'autres méthodes :

- Quelle est la relation entre k-means et GMM ?
- Quelle est la différence entre assignation dure et douce ?

Développements mathématiques

Conseil important : Il est **fortement recommandé** de développer l'algèbre contenue dans ce chapitre

Points à maîtriser :

- Dérivation de la fonction de perte
 - Calcul de $\frac{\partial L_Z}{\partial \mu_k}$ et condition d'optimalité
 - Preuve que les centres sont les barycentres
 - Preuve de la décroissance monotone de la perte
 - Relation entre k-means et modèle gaussien limite
-

Concepts mathématiques à maîtriser

Algèbre et géométrie

Fondamentaux :

- Norme euclidienne et distance
- Centre de masse (barycentre)
- Diagramme de Voronoï
- Espaces métriques

Optimisation

Techniques :

- Descente de coordonnées
- Minimisation alternée
- Optimisation combinatoire
- Complexité NP-Hard

Propriétés :

- Convergence d'algorithmes itératifs
- Optima locaux vs globaux
- Fonctions convexes

Probabilités et statistiques

Concepts :

- Distribution gaussienne multivariée
 - Maximum de vraisemblance
 - Modèles de mélange
-

Conseils pratiques pour l'implémentation

Prétraitement des données

Étapes recommandées :

1. **Normalisation** : centrer et réduire les variables
2. **Gestion des outliers** : détecter et traiter les valeurs aberrantes
3. **Réduction de dimension** : PCA si D très grand

Paramètres algorithmiques

Initialisation :

- Utiliser **k-means++** par défaut
- Ou lancer **plusieurs fois** avec initialisations aléatoires

Convergence :

- Seuil de tolérance : $\epsilon = 10^{-4}$ typiquement
- Nombre maximum d'itérations : éviter les boucles infinies

Choix de **K** :

- Tester plusieurs valeurs
- Utiliser des critères de validation