

# Table of contents

|                                                                 |          |
|-----------------------------------------------------------------|----------|
| <b>Cours détaillé</b>                                           | <b>2</b> |
| Introduction et Motivation . . . . .                            | 2        |
| Contexte général . . . . .                                      | 2        |
| Problématique des données réelles . . . . .                     | 2        |
| Terminologie alternative . . . . .                              | 3        |
| Panorama des méthodes de clustering . . . . .                   | 3        |
| Clustering hiérarchique agglomératif . . . . .                  | 4        |
| Principe de l'algorithme . . . . .                              | 4        |
| Distances entre ensembles (clusters) . . . . .                  | 4        |
| Stratégie k-means . . . . .                                     | 4        |
| Hypothèses fondamentales . . . . .                              | 4        |
| Modèle formel . . . . .                                         | 5        |
| Fonction de perte k-means . . . . .                             | 5        |
| Rappel : Algorithme de descente de coordonnées . . . . .        | 6        |
| Application au k-means . . . . .                                | 7        |
| Mise à jour de l'assignation . . . . .                          | 7        |
| Algorithme k-means complet . . . . .                            | 8        |
| Description détaillée . . . . .                                 | 8        |
| Étapes de l'algorithme . . . . .                                | 8        |
| Critères de convergence . . . . .                               | 9        |
| Visualisation du processus . . . . .                            | 10       |
| Propriétés de l'algorithme k-means . . . . .                    | 11       |
| Garanties théoriques . . . . .                                  | 11       |
| Interprétation géométrique . . . . .                            | 11       |
| Lien avec l'algorithme EM . . . . .                             | 11       |
| Sensibilité à l'initialisation . . . . .                        | 12       |
| Variantes, liens et relations . . . . .                         | 12       |
| k-means++ : Initialisation intelligente . . . . .               | 12       |
| Relation entre k-means et modèles gaussiens . . . . .           | 14       |
| Lien intrinsèque avec la métrique euclidienne . . . . .         | 14       |
| Clustering contraint . . . . .                                  | 15       |
| Synthèse des concepts clés . . . . .                            | 16       |
| Caractéristiques essentielles de k-means . . . . .              | 16       |
| Comparaison k-means vs GMM vs Clustering hiérarchique . . . . . | 16       |
| Choix du nombre de clusters K . . . . .                         | 17       |
| Questions d'examen types . . . . .                              | 18       |
| Questions conceptuelles . . . . .                               | 18       |
| Questions techniques . . . . .                                  | 18       |
| Développements mathématiques . . . . .                          | 19       |

|                                                    |    |
|----------------------------------------------------|----|
| Concepts mathématiques à maîtriser . . . . .       | 19 |
| Algèbre et géométrie . . . . .                     | 19 |
| Optimisation . . . . .                             | 19 |
| Probabilités et statistiques . . . . .             | 20 |
| Conseils pratiques pour l'implémentation . . . . . | 20 |
| Prétraitement des données . . . . .                | 20 |
| Paramètres algorithmiques . . . . .                | 20 |

## Cours détaillé

---

### Introduction et Motivation

#### Contexte général

L'algorithme **k-means** est une méthode d'**estimation de facteurs latents discrets** dans un contexte **non supervisé** de clustering (regroupement).

#### Objectifs du cours :

- Comprendre les propriétés **géométriques et statistiques** des données
- Analyser les données et développer des outils pour cette analyse
- Aborder spécifiquement l'approche (**non supervisée**) du clustering de données
- Comprendre les **hypothèses** faites dans la conception de ces outils
- Travailler la **théorie en profondeur**

**Note importante :** Le clustering est similaire à la classification (non supervisée), l'estimation de densité, et dual à la détection d'outliers

#### Problématique des données réelles

##### Observation fondamentale :

Les données ne proviennent généralement **pas d'un simple processus gaussien** (variations autour d'un prototype moyen)

##### Caractéristiques des données réelles :

- La distribution des données montre généralement une **non-uniformité**
- Présence de **régions de densité plus élevée**

### Définition du clustering :

Le clustering est une méthode **non supervisée** qui vise à découvrir des **groupes cohérents** de données, correspondant à des **pics de densité** des données

### Terminologie alternative

#### Vector Quantization (VQ) :

Synonyme souvent utilisé (en traitement du signal) pour le clustering, signifiant “quantification multi-dimensionnelle”

---

## Panorama des méthodes de clustering

### Principales méthodes

Il existe un grand nombre de méthodes de clustering, incluant :

#### Méthodes hiérarchiques :

- Hierarchical Agglomerative Clustering (HAC)

#### Méthodes de partitionnement :

- **k-means** (algorithme de Lloyd)
- k-medoids

#### Méthodes spectrales :

- Spectral clustering

#### Autres approches :

- Community detection
- High-dimensional clustering
- Self-Organizing Maps (SOM)
- Neural Gas

**Note historique :** La recherche sur le clustering est active depuis au moins 50 ans

## Clustering hiérarchique agglomératif

### Principe de l'algorithme

Processus itératif :

#### Étape 1 : Initialisation

- Chaque donnée est un cluster

#### Étape 2 : Recherche

- Trouver la paire de clusters la plus proche

#### Étape 3 : Fusion

- Fusionner ces deux clusters

#### Étape 4 : Itération

- Répéter depuis l'étape 2 jusqu'à la fin

Résultat : Production d'un **dendrogramme** des données

### Distances entre ensembles (clusters)

Métriques possibles :

- **Distance entre centres** (centroid linkage)
- **Distance maximale** (complete linkage) :  $\max_{x \in C_1, y \in C_2} d(x, y)$
- **Distance minimale** (single linkage) :  $\min_{x \in C_1, y \in C_2} d(x, y)$

**Limitation** : Le nombre de clusters est **inconnu a priori**

---

## Stratégie k-means

### Hypothèses fondamentales

L'algorithme de clustering **k-means** postule :

- Un espace métrique (**euclidien**) normé sur les données
- Une assignation **non supervisée** des données aux clusters
- Un algorithme d'**assignation dure** (hard-assignment) : l'assignation est **binaire**, chaque donnée est assignée à **un et un seul** cluster

## Modèle formel

Données :

Soit  $X = \{x_i\}_{i \in [[N]]} \subset \Omega \subseteq \mathbb{R}^D$ , et  $K \in \mathbb{N}^*$  donné

Variables du modèle :

- Variables d'assignation binaire (latentes) :

$$Z = \{z_{ik}\} \quad \text{avec} \quad z_{ik} \in \{\text{false}, \text{true}\} \equiv \{0, 1\} \quad \forall i, k$$

- Représentants des clusters :

$$M = \{\mu_k\}_{k \in [[K]]} \quad \text{avec} \quad \mu_k \in \mathbb{R}^D \quad \forall k$$

Paramètres complets :

$$\theta = [M, Z]$$

---

## Fonction de perte k-means

### Problème d'optimisation

k-means cherche l'assignation suivante :

$$\hat{\theta} = [\hat{M}, \hat{Z}] = \arg \min_{\theta = [M, Z]} L(\theta, X)$$

### Fonction de perte

Définition :

$$L(\theta, X) = \sum_{i=1}^N \sum_{k=1}^K z_{ik} \|x_i - \mu_k\|_2^2$$

Interprétation :

- Somme des **distances au carré** entre chaque point et son représentant de cluster
- Plus cette somme est petite, meilleure est la partition

## Complexité du problème

**Difficulté majeure :** Puisque l'assignation est binaire, l'optimisation exacte est **NP-Hard**

**Solution pratique :** Chercher une **approximation par descente de coordonnées** (coordinate descent)

---

## Rappel : Algorithme de descente de coordonnées

### Principe général

La descente de coordonnées est un **algorithme de minimisation alternée** :

### Problème :

Soit  $f : \mathbb{R}^D \rightarrow \mathbb{R}$ , on cherche :

$$x^* = \arg \min_{x \in \mathbb{R}^D} f(x)$$

### Stratégie de résolution

#### Définition des fonctions partielles :

Pour  $d \in [[D]]$ , on définit  $f^d : \mathbb{R}^D \times \mathbb{R} \rightarrow \mathbb{R}$  :

$$f^d(x, y) = f([x(1), \dots, x(d-1), y, x(d+1), \dots, x(D)]^T)$$

#### Optimisation alternée :

On cherche alternativement le minimum selon chaque coordonnée :

$$x^{(t+1)}(d) = \arg \min_y f^d(x^{(t)}, y)$$

**Principe :** Fixer toutes les variables sauf une, optimiser cette variable, puis passer à la suivante

---

## Application au k-means

### Optimisation alternée de $Z$ et $M$

On alterne l'optimisation de  $Z$  et  $M$

Définitions des pertes partielles :

$$L_M(Z) = L(\theta, X)|_{M=M}$$

$$L_Z(M) = L(\theta, X)|_{Z=Z}$$

### Optimisation par rapport à $M$ (représentants)

Calcul de la dérivée :

$$\frac{\partial L_Z}{\partial \mu_k} = -2 \sum_{i=1}^N z_{ik} (x_i - \mu_k)$$

Condition d'optimalité :

Le représentant optimal  $M$  pour une assignation donnée  $Z$  est atteint quand :

$$\frac{\partial L_Z}{\partial \mu_k} = 0 \quad \Rightarrow \quad \mu_k = \frac{\sum_{i=1}^N z_{ik} x_i}{\sum_{i=1}^N z_{ik}}$$

**Conclusion fondamentale :** Les représentants des clusters sont leurs **centres de masse** (barycentres)

---

## Mise à jour de l'assignation

### Optimisation par rapport à $Z$

Étant donné un ensemble de représentants de clusters  $M$ , pour minimiser  $L_M(Z)$  :

Rappel de la perte :

$$L_M(Z) = \left[ \sum_{i=1}^N \sum_{k=1}^K z_{ik} \|x_i - \mu_k\|_2^2 \right]_{M=M}$$

## Règle d'assignation

C'est une **somme de termes positifs**  $\rightarrow$  on assigne :

$$z_{ik} = 1 \quad \text{seulement quand} \quad k = \arg \min_m \|x_i - \mu_m\|_2^2$$

(et  $z_{ik} = 0$  sinon)

**Conclusion :**  $L_M(Z)$  est minimale quand **chaque donnée est assignée à son représentant de cluster le plus proche**

---

## Algorithme k-means complet

### Description détaillée

Données d'entrée :

- $X = \{x_i\}_{i \in [[N]]}$  avec  $x_i \in \mathbb{R}^D$
- $K \in \mathbb{N}^*$  (nombre de clusters)

### Étapes de l'algorithme

#### Étape 1 : Initialisation

Initialiser les représentants de clusters  $M^{(0)}$

#### Étape 2 : Assignment (E-step like)

Étant donné les représentants de clusters  $M^{(t)}$ , l'assignation  $Z^{(t)}$  associe chaque donnée à son représentant de cluster le plus proche :

$$z_{ik}^{(t)} = \begin{cases} 1 & \text{si } k = \arg \min_m \|x_i - \mu_m^{(t)}\|_2^2 \\ 0 & \text{sinon} \end{cases}$$

#### Étape 3 : Mise à jour (M-step like)

Étant donné l'assignation  $Z^{(t)}$ , les nouveaux représentants de clusters  $M^{(t+1)}$  sont les centres de masse des données assignées aux clusters :



$$\mu_k^{(t+1)} = \frac{\sum_{i=1}^N z_{ik}^{(t)} x_i}{\sum_{i=1}^N z_{ik}^{(t)}}$$

#### Étape 4 : Convergence


Répéter depuis l'étape 2 jusqu'à convergence

#### Critères de convergence

La convergence est atteinte quand :

- Les centres de masse **ne bougent plus beaucoup** :  $\|\mu_k^{(t+1)} - \mu_k^{(t)}\| < \epsilon$
- Ou l'assignation est **stable** :  $Z^{(t+1)} = Z^{(t)}$

## Visualisation du processus



**Note importante :** L'étape 2 est similaire à une étape d'**Expectation**, et l'étape 3 est similaire à une étape de **Maximization**, en considérant une assignation dure (référence à l'algorithme EM)

---

## Propriétés de l'algorithme k-means

### Garanties théoriques

#### Décroissance de la perte :

Puisqu'il effectue une **minimisation alternée de fonctions convexes**, il garantit de **diminuer la perte à chaque itération** :

$$L(M^{(t+1)}, Z^{(t+1)}) \leq L(M^{(t)}, Z^{(t)})$$

#### Finitude :

Il existe un nombre **combinatoire mais fini** d'assignations possibles  $\rightarrow$  le nombre d'itérations est **(grand mais) fini**

### Interprétation géométrique

#### Diagramme de Voronoï :

L'étape 2 est équivalente à construire le **diagramme de Voronoï discret** de  $X$  avec les centres  $M$  comme graines (seeds)

**Définition** : Le diagramme de Voronoï partitionne l'espace en régions, où chaque région contient tous les points plus proches d'un centre donné que de tout autre centre

### Lien avec l'algorithme EM

#### Comparaison conceptuelle :

- **Étape 2 (Assignment)** : similaire à une étape **Expectation** (mais dure)
- **Étape 3 (Mise à jour)** : similaire à une étape **Maximization**

**Différence clé** : k-means utilise une **assignation dure** (hard-assignment) tandis que EM utilise une **assignation douce** (soft-assignment)

## Sensibilité à l'initialisation

### Problème des optima locaux

**Limitation majeure :** Puisque l'optimisation exacte (assignation optimale) est **NP-Hard**, l'algorithme k-means atteint un **optimum local**

### Conséquences :

- La qualité du résultat **varie selon l'initialisation**
- Différentes initialisations peuvent donner des résultats très différents

## Stratégies pratiques

### Randomisation :

La randomisation peut être utile si le calcul est rapide → lancer plusieurs fois avec différentes initialisations

### Heuristiques :

Sinon, utiliser des **heuristiques pour une meilleure initialisation** (comme k-means++)

---

## Variantes, liens et relations

### k-means++ : Initialisation intelligente

#### Principe fondamental

Le principe de **k-means++** est de **maximalement disperser** les représentants de clusters initiaux  $M^{(0)}$  sur les données

#### Avantages démontrés :

1. Produit des clusters de **meilleure qualité**
2. **Accélère la convergence** de k-means

## Algorithme k-means++ détaillé

### Étape 1 : Premier centre

Sélectionner le premier représentant de cluster  $\mu_1^0$  **aléatoirement** parmi les données  $X$

### Étape 2 : Calcul des distances

Pour toutes les données non sélectionnées  $x_i$ , calculer :

$$\Delta_i = \|x_i - \mu_m^0\|_2^2$$

la distance entre  $x_i$  et son représentant le plus proche  $\mu_m^0$  parmi les  $k$  représentants déjà sélectionnés

### Étape 3 : Échantillonnage pondéré

Échantillonner le prochain représentant  $\mu_{k+1}^0$  depuis  $X$  avec une **probabilité proportionnelle** à la distribution  $\Delta$

$$\mathbb{P}(\text{choisir } x_i) = \frac{\Delta_i}{\sum_j \Delta_j}$$

### Étape 4 : Itération

Répéter depuis l'étape 2 jusqu'à ce que  $K$  représentants soient choisis

## Intuition de l'algorithme

**Idee clé :** Les points **loin des centres déjà sélectionnés** ont plus de chances d'être choisis comme nouveaux centres

**Conséquence :** Les centres initiaux sont bien **répartis dans l'espace des données**, couvrant les différentes régions de densité

## Adoption pratique

**Utilisation répandue :** Cette stratégie d'initialisation est utilisée par plusieurs packages de Data Science :

- MATLAB™
- Python SciKit Learn
- R
- Et autres bibliothèques standards

## Relation entre k-means et modèles gaussiens

### k-means comme cas particulier du GMM

**Question :** Pourquoi dit-on que k-means considère un **modèle gaussien** pour les clusters ?

**Réponse :**

k-means peut être vu comme un cas limite de GMM (Gaussian Mixture Model) où :

**Hypothèses du modèle :**

- Chaque cluster suit une distribution **normale**
- Matrices de covariance **sphériques et identiques** :  $\Sigma_k = \sigma^2 I_D$  pour tous les clusters
- Variance  $\sigma^2 \rightarrow 0$  : les distributions deviennent des pics

**Conséquence :**

Dans cette limite, l'**assignation douce** (soft-assignment) du GMM devient une **assignation dure** (hard-assignment), et on retrouve k-means

### Formulation probabiliste

Si on considère le modèle probabiliste :

$$\mathbb{P}(x|\mu_k, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{D/2}} \exp\left(-\frac{\|x - \mu_k\|^2}{2\sigma^2}\right)$$

Quand  $\sigma \rightarrow 0$ , maximiser cette probabilité est équivalent à minimiser  $\|x - \mu_k\|^2$ , ce qui est exactement le critère de k-means

---

## Lien intrinsèque avec la métrique euclidienne

### Pourquoi k-means dépend de la métrique euclidienne ?

**Analyse de la fonction de perte :**

$$L(\theta, X) = \sum_{i=1}^N \sum_{k=1}^K z_{ik} \|x_i - \mu_k\|_2^2$$

La norme  $\|\cdot\|_2$  est la **norme euclidienne** :  $\|x\|_2^2 = \sum_d x(d)^2$

## Conséquences pratiques

### Sensibilité à l'échelle :

k-means est **sensible à l'échelle** des variables. Des variables avec de grandes valeurs dominent la distance

**Solution : Normalisation** des données avant d'appliquer k-means :

- Centrer : soustraire la moyenne
- Réduire : diviser par l'écart-type

### Limitation aux espaces euclidiens :

k-means ne peut pas être directement appliqué à des données **non-euclidiennes** (graphes, textes, etc.)

**Alternatives :** Pour d'autres métriques, utiliser des variantes comme k-medoids qui fonctionnent avec des distances arbitraires

---

## Clustering contraint

### Extension de k-means

Le clustering peut être **contraint** avec :

#### Contraintes MUST-LINK :

Deux points doivent être dans le **même cluster**

#### Contraintes CANNOT-LINK :

Deux points doivent être dans des **clusters différents**

### Application pratique

Ces contraintes permettent d'incorporer des **connaissances a priori** ou des **contraintes du domaine** dans le processus de clustering

---

## Synthèse des concepts clés

### Caractéristiques essentielles de k-means

#### Nature de la méthode :

- k-means fait partie de la famille **non supervisée** de techniques de modélisation de données
- Une des techniques de clustering les **plus populaires**

#### Assignment :

- k-means effectue une **assignment dure** (hard-assignment)
- Chaque point appartient à **un seul cluster**

#### Optimisation :

- Critère d'optimisation (perte) **solide** mais **NP-Hard**
- L'algorithme k-means cherche une **solution approximative** par descente de coordonnées (minimisation alternée)

#### Convergence :

- La perte **n'est pas convexe** → technique **sensible à l'initialisation**
- k-means++ est une **heuristique a priori** pour l'initialisation, efficace en pratique

#### Extensions :

- Clustering peut être **contraint** (contraintes MUST-LINK et CANNOT-LINK)

---

### Comparaison k-means vs GMM vs Clustering hiérarchique

| Critère                   | k-means                   | GMM (avec EM)                        | Clustering hiérarchique |
|---------------------------|---------------------------|--------------------------------------|-------------------------|
| <b>Type d'assignment</b>  | Dure (hard)               | Douce (soft)                         | Hiérarchique            |
| <b>Forme des clusters</b> | Sphériques(même variance) | Elliptiques(covariances différentes) | Flexible                |



| Critère                                   | k-means                                                          | GMM (avec EM)                                  | Clustering hiérarchique                                    |
|-------------------------------------------|------------------------------------------------------------------|------------------------------------------------|------------------------------------------------------------|
| <b>Nom-<br/>bre de<br/>clus-<br/>ters</b> | Doit être spécifié                                               | Doit être spécifié                             | Déterminé a posteriori(dendrogramme)                       |
| <b>Com-<br/>plexité</b>                   | $O(N \cdot K \cdot D \cdot T)$ où $T$ est le nombre d'itérations | $O(N \cdot K \cdot D^2 \cdot T)$               | $O(N^2 \log N)$ ou $O(N^3)$                                |
| <b>Avan-<br/>tages</b>                    | Rapide simple                                                    | Modèle probabiliste clusters de formes variées | Pas besoin de spécifier $K$ visualisation par dendrogramme |
| <b>Incon-<br/>vénients</b>                | Sensible à l'initialisation suppose clusters sphériques          | Plus lent plus de paramètres à estimer         | Coûteux pour grandes données pas de réassignation          |

## Choix du nombre de clusters $K$

### Problématique

**Difficulté :** Le nombre de clusters  $K$  doit être **spécifié a priori** dans k-means

### Méthodes de sélection

#### Méthode du coude (Elbow method) :

Tracer la perte  $L$  en fonction de  $K$  et chercher un “coude” dans la courbe

#### Silhouette score :

Mesure la qualité du clustering en comparant la distance intra-cluster à la distance inter-cluster

#### Gap statistic :

Compare la perte observée à la perte attendue sous une distribution de référence

#### Critères d'information :

- BIC (Bayesian Information Criterion)
- AIC (Akaike Information Criterion)

**Conseil pratique :** Tester plusieurs valeurs de  $K$  et utiliser des critères multiples

## Questions d'examen types

### Questions conceptuelles

#### Description formelle :

- Décrire formellement le clustering
- En quel sens est-ce une technique non supervisée ?

#### Relation avec la métrique :

- Expliquer pourquoi k-means est intrinsèquement lié à la métrique euclidienne
- Pourquoi dit-on que k-means considère un modèle gaussien pour les clusters ?

#### Exactitude :

- L'algorithme k-means est-il exact ?
- Quelles sont les garanties théoriques ?

### Questions techniques

#### Initialisation :

- Quels sont les principes pour initialiser k-means ?
- Décrire l'algorithme k-means++

#### Optimisation :

- Qu'est-ce que l'algorithme de descente de coordonnées ?
- Comment s'applique-t-il à k-means ?

#### Relation avec d'autres méthodes :

- Quelle est la relation entre k-means et GMM ?
- Quelle est la différence entre assignation dure et douce ?

## Développements mathématiques

**Conseil important :** Il est **fortement recommandé** de développer l'algèbre contenue dans ce chapitre

### Points à maîtriser :

- Dérivation de la fonction de perte
  - Calcul de  $\frac{\partial L_Z}{\partial \mu_k}$  et condition d'optimalité
  - Preuve que les centres sont les barycentres
  - Preuve de la décroissance monotone de la perte
  - Relation entre k-means et modèle gaussien limite
- 

## Concepts mathématiques à maîtriser

### Algèbre et géométrie

#### Fondamentaux :

- Norme euclidienne et distance
- Centre de masse (barycentre)
- Diagramme de Voronoï
- Espaces métriques

### Optimisation

#### Techniques :

- Descente de coordonnées
- Minimisation alternée
- Optimisation combinatoire
- Complexité NP-Hard

#### Propriétés :

- Convergence d'algorithmes itératifs
- Optima locaux vs globaux
- Fonctions convexes

## Probabilités et statistiques

### Concepts :

- Distribution gaussienne multivariée
  - Maximum de vraisemblance
  - Modèles de mélange
- 

## Conseils pratiques pour l'implémentation

### Prétraitement des données

#### Étapes recommandées :

1. **Normalisation** : centrer et réduire les variables
2. **Gestion des outliers** : détecter et traiter les valeurs aberrantes
3. **Réduction de dimension** : PCA si  $D$  très grand

### Paramètres algorithmiques

#### Initialisation :

- Utiliser **k-means++** par défaut
- Ou lancer **plusieurs fois** avec initialisations aléatoires

#### Convergence :

- Seuil de tolérance :  $\epsilon = 10^{-4}$  typiquement
- Nombre maximum d'itérations : éviter les boucles infinies

#### Choix de **K** :

- Tester plusieurs valeurs
- Utiliser des critères de validation