

Table of contents

L'essentiel	2
Introduction et Motivation	2
Le problème fondamental	2
Problématique des données réelles	2
L'intuition géométrique : Le jeu des chaises musicales	3
Panorama des méthodes de clustering	3
Clustering hiérarchique agglomératif	4
Principe de l'algorithme	4
Distances entre ensembles (clusters)	4
Stratégie k-means	5
Hypothèses fondamentales	5
Modèle formel	5
Fonction de perte k-means	6
Algorithme de descente de coordonnées	6
Application au k-means	7
Algorithme k-means complet	8
Description détaillée	8
Étapes de l'algorithme	8
Critères de convergence	9
Propriétés de l'algorithme k-means	9
Garanties théoriques	9
Interprétation géométrique	10
Lien avec l'algorithme EM	10
Sensibilité à l'initialisation	10
Initialisation, liens et relations	11
K-means++ : Initialisation intelligente	11
Relation entre k-means et modèles gaussiens	12
Lien intrinsèque avec la métrique euclidienne	13
Choix du nombre de clusters K	14
Les pièges de k-means et comment les éviter	15
Piège 1 : Les Clusters Non Sphériques	15
Piège 2 : Les Clusters de Tailles Très Différentes	15
Piège 3 : La Sensibilité aux Outliers	15
Piège 4 : L'Interprétation des Résultats	15
Variantes de k-means	16
K-medoids	16
Mini-batch K-means	16
Fuzzy C-means	16
Clustering contraint	16

En pratique : La recette complète	16
Étape 1 : Préparation des Données	16
Étape 2 : Choix de K	17
Étape 3 : Exécution	17
Étape 4 : Validation	17
Comparaison k-means vs GMM vs Clustering hiérarchique	17
Synthèse des concepts clés	18
Caractéristiques essentielles de k-means	18

L'essentiel

Introduction et Motivation

L'algorithme **k-means** est une méthode d'**estimation de facteurs latents discrets** dans un contexte **non supervisé** de clustering (regroupement).

Le problème fondamental

Imaginez : On vous donne 1000 photos d'animaux non étiquetées et on vous demande : "Combien y a-t-il de types d'animaux différents, et quelles photos vont ensemble ?" C'est exactement le problème du clustering !

K-means répond à cette question en faisant **une hypothèse simplificatrice** : chaque type d'animal peut être représenté par une **image moyenne** (prototype), et chaque photo est proche de l'un de ces prototypes.

Concept clé : Le clustering est **non supervisé** : pas d'étiquettes, pas de professeur pour dire "ceci est un chat". L'algorithme doit découvrir la structure par lui-même.

Problématique des données réelles

Observation fondamentale :

Les données ne proviennent généralement **pas d'un simple processus gaussien** (variations autour d'un prototype moyen).

Caractéristiques des données réelles :

- La distribution des données montre généralement une **non-uniformité**
- Présence de **régions de densité plus élevée**

Définition du clustering :

Le clustering est une méthode **non supervisée** qui vise à découvrir des **groupes cohérents** de données, correspondant à des **pics de densité** des données.

L'intuition géométrique : Le jeu des chaises musicales

Analogie pratique

Imaginez un jeu de chaises musicales avec K chaises (clusters) et N joueurs (points de données). Quand la musique s'arrête :

- Chaque joueur court vers la chaise la plus proche (**assignation**)
- On déplace chaque chaise au centre des joueurs qui l'entourent (**mise à jour**)
- On recommence jusqu'à ce que les chaises ne bougent plus

C'est exactement k-means !

Idée essentielle : K-means alterne entre deux questions simples : “où va chaque point ?” et “où sont les centres ?”. Cette alternance garantit une amélioration à chaque étape.

Panorama des méthodes de clustering

Principales méthodes

Il existe un grand nombre de méthodes de clustering, incluant :

Méthodes hiérarchiques :

- Hierarchical Agglomerative Clustering (HAC)

Méthodes de partitionnement :

- **k-means** (algorithme de Lloyd)
- k-medoids

Méthodes spectrales :

- Spectral clustering

Autres approches :

- Community detection
- High-dimensional clustering
- Self-Organizing Maps (SOM)
- Neural Gas

Note historique : La recherche sur le clustering est active depuis au moins 50 ans.

Clustering hiérarchique agglomératif

Principe de l'algorithme

Processus itératif :

- **Initialisation** : Chaque donnée est un cluster
- **Recherche** : Trouver la paire de clusters la plus proche
- **Fusion** : Fusionner ces deux clusters
- **Itération** : Répéter jusqu'à la fin

Résultat : Production d'un **dendrogramme** des données.

Distances entre ensembles (clusters)

Métriques possibles :

- **Distance entre centres** (centroid linkage)
- **Distance maximale** (complete linkage) : $\max_{x \in C_1, y \in C_2} d(x, y)$
- **Distance minimale** (single linkage) : $\min_{x \in C_1, y \in C_2} d(x, y)$

Limitation : Le nombre de clusters est **inconnu a priori**.

Stratégie k-means

Hypothèses fondamentales

L'algorithme de clustering **k-means** postule :

- Un espace métrique (**euclidien**) normé sur les données
- Une assignation **non supervisée** des données aux clusters
- Un algorithme d'**assignation dure** (hard-assignment) : l'assignation est **binaire**, chaque donnée est assignée à **un et un seul** cluster

Modèle formel

Données :

Soit $X = \{x_i\}_{i \in [[N]]} \subset \Omega \subseteq \mathbb{R}^D$, et $K \in \mathbb{N}^*$ donné.

Variables du modèle :

- Variables d'assignation binaire (latentes) :

$$Z = \{z_{ik}\} \quad \text{avec} \quad z_{ik} \in \{\text{false}, \text{true}\} \equiv \{0, 1\} \quad \forall i, k$$

- Représentants des clusters :

$$M = \{\mu_k\}_{k \in [[K]]} \quad \text{avec} \quad \mu_k \in \mathbb{R}^D \quad \forall k$$

Paramètres complets :

$$\theta = [M, Z]$$

Fonction de perte k-means

Problème d'optimisation

k-means cherche l'assignation suivante :

$$\hat{\theta} = [\hat{M}, \hat{Z}] = \arg \min_{\theta=[M,Z]} L(\theta, X)$$

Fonction de perte :

$$L(\theta, X) = \sum_{i=1}^N \sum_{k=1}^K z_{ik} \|x_i - \mu_k\|_2^2$$

Interprétation :

- Somme des **distances au carré** entre chaque point et son représentant de cluster
- Plus cette somme est petite, meilleure est la partition

Pourquoi au carré ? Deux raisons :

- **Mathématique** : rend le problème plus facile à résoudre
- **Géométrie** : pénalise plus les points très éloignés

Complexité du problème

Difficulté majeure : Puisque l'assignation est binaire, l'optimisation exacte est **NP-Hard**.

Solution pratique : Chercher une **approximation par descente de coordonnées** (coordinate descent).

Algorithme de descente de coordonnées

Principe général

La descente de coordonnées est un **algorithme de minimisation alternée**.

Problème :

Soit $f : \mathbb{R}^D \rightarrow \mathbb{R}$, on cherche :

$$x^* = \arg \min_{x \in \mathbb{R}^D} f(x)$$

i Détails mathématiques : Stratégie de résolution

Définition des fonctions partielles :

Pour $d \in [[D]]$, on définit $f^d : \mathbb{R}^D \times \mathbb{R} \rightarrow \mathbb{R}$:

$$f^d(x, y) = f([x(1), \dots, x(d-1), y, x(d+1), \dots, x(D)]^T)$$

Optimisation alternée :

On cherche alternativement le minimum selon chaque coordonnée :

$$x^{(t+1)}(d) = \arg \min_y f^d(x^{(t)}, y)$$

Principe : Fixer toutes les variables sauf une, optimiser cette variable, puis passer à la suivante.

Application au k-means

Optimisation alternée de Z et M

On alterne l'optimisation de Z et M.

Définitions des pertes partielles :

$$L_M(Z) = L(\theta, X)|_{M=M}$$

$$L_Z(M) = L(\theta, X)|_{Z=Z}$$

Les deux équations magiques

Optimisation par rapport à M (représentants) :

i Détails mathématiques : Calcul des centres

Calcul de la dérivée :

$$\frac{\partial L_Z}{\partial \mu_k} = -2 \sum_{i=1}^N z_{ik} (x_i - \mu_k)$$

Condition d'optimalité :

Le représentant optimal M pour une assignation donnée Z est atteint quand :

$$\frac{\partial L_Z}{\partial \mu_k} = 0 \quad \Rightarrow \quad \mu_k = \frac{\sum_{i=1}^N z_{ik} x_i}{\sum_{i=1}^N z_{ik}}$$

Conclusion fondamentale : Les représentants des clusters sont leurs **centres de masse** (barycentres).

Optimisation par rapport à Z (assignment) :

Étant donné un ensemble de représentants de clusters M , pour minimiser $L_M(Z)$:

$$z_{ik} = 1 \quad \text{seulement quand} \quad k = \arg \min_m \|x_i - \mu_m\|_2^2$$

(et $z_{ik} = 0$ sinon)

Conclusion : $L_M(Z)$ est minimale quand **chaque donnée est assignée à son représentant de cluster le plus proche**.

Algorithme k-means complet

Description détaillée

Données d'entrée :

- $X = \{x_i\}_{i \in [N]}$ avec $x_i \in \mathbb{R}^D$
- $K \in \mathbb{N}^*$ (nombre de clusters)

Étapes de l'algorithme

Étape 1 : Initialisation

Initialiser les représentants de clusters $M^{(0)}$.

Étape 2 : Assignment (E-step like)

Étant donné les représentants de clusters $M^{(t)}$, l'assignation $Z^{(t)}$ associe chaque donnée à son représentant de cluster le plus proche :

$$z_{ik}^{(t)} = \begin{cases} 1 & \text{si } k = \arg \min_m \|x_i - \mu_m^{(t)}\|_2^2 \\ 0 & \text{sinon} \end{cases}$$

Étape 3 : Mise à jour (M-step like)

Étant donné l'assignation $Z^{(t)}$, les nouveaux représentants de clusters $M^{(t+1)}$ sont les centres de masse des données assignées aux clusters :

$$\mu_k^{(t+1)} = \frac{\sum_{i=1}^N z_{ik}^{(t)} x_i}{\sum_{i=1}^N z_{ik}^{(t)}}$$

Étape 4 : Convergence

Répéter depuis l'étape 2 jusqu'à convergence.

Critères de convergence

La convergence est atteinte quand :

- Les centres de masse **ne bougent plus beaucoup** : $\|\mu_k^{(t+1)} - \mu_k^{(t)}\| < \epsilon$
- Ou l'assignation est **stable** : $Z^{(t+1)} = Z^{(t)}$

Note importante : L'étape 2 est similaire à une étape d'**Expectation**, et l'étape 3 est similaire à une étape de **Maximization**, en considérant une assignation dure (référence à l'algorithme EM).

Propriétés de l'algorithme k-means

Garanties théoriques

Décroissance de la perte :

Puisqu'il effectue une **minimisation alternée de fonctions convexes**, il garantit de **diminuer la perte à chaque itération** :

$$L(M^{(t+1)}, Z^{(t+1)}) \leq L(M^{(t)}, Z^{(t)})$$

Finitude :

Il existe un nombre **combinatoire mais fini** d'assignations possibles $\rightarrow$ le nombre d'itérations est **(grand mais) fini**.

Pourquoi ça converge ? Chaque étape ne peut qu'améliorer (ou laisser inchangé) le critère. Comme il y a un nombre fini d'assignations possibles, l'algorithme doit terminer.

Interprétation géométrique

Diagramme de Voronoï :

L'étape 2 est équivalente à construire le **diagramme de Voronoï discret** de X avec les centres M comme graines (seeds).

Définition : Le diagramme de Voronoï partitionne l'espace en régions, où chaque région contient tous les points plus proches d'un centre donné que de tout autre centre.

Lien avec l'algorithme EM

Comparaison conceptuelle :

- **Étape 2 (Assignment)** : similaire à une étape **Expectation** (mais dure)
- **Étape 3 (Mise à jour)** : similaire à une étape **Maximization**

Différence clé : k-means utilise une **assignment dure** (hard-assignment) tandis que EM utilise une **assignment douce** (soft-assignment).

Sensibilité à l'initialisation

Problème des optima locaux

Limitation majeure : Puisque l'optimisation exacte (assignment optimale) est **NP-Hard**, l'algorithme k-means atteint un **optimum local**.

Conséquences :

- La qualité du résultat **varie selon l'initialisation**
- Différentes initialisations peuvent donner des résultats très différents

Le dilemme de l'initialisation

Si toutes les chaises commencent dans le même coin, le jeu sera très long et donnera un mauvais résultat. **K-means est très sensible à l'initialisation !**

Stratégies pratiques

Randomisation :

La randomisation peut être utile si le calcul est rapide → lancer plusieurs fois avec différentes initialisations.

Heuristiques :

Sinon, utiliser des **heuristiques pour une meilleure initialisation** (comme k-means++).

Initialisation, liens et relations

K-means++ : Initialisation intelligente

Principe fondamental

Le principe de **k-means++** est de **maximalement disperser** les représentants de clusters initiaux $M^{(0)}$ sur les données.

Avantages démontrés :

- Produit des clusters de **meilleure qualité**
- **Accélère la convergence** de k-means

Algorithme k-means++ détaillé

Étape 1 : Premier centre

Sélectionner le premier représentant de cluster μ_1^0 **aléatoirement** parmi les données X .

Étape 2 : Calcul des distances

Pour toutes les données non sélectionnées x_i , calculer :

$$\Delta_i = \|x_i - \mu_m^0\|_2^2$$

la distance entre x_i et son représentant le plus proche μ_m^0 parmi les k représentants déjà sélectionnés.

Étape 3 : Échantillonnage pondéré

Échantillonner le prochain représentant μ_{k+1}^0 depuis X avec une **probabilité proportionnelle** à la distribution Δ :

$$\mathbb{P}(\text{choisir } x_i) = \frac{\Delta_i}{\sum_j \Delta_j}$$

Étape 4 : Itération

Répéter depuis l'étape 2 jusqu'à ce que K représentants soient choisis.

Intuition de l'algorithme

Idée clé : Les points **loin des centres déjà sélectionnés** ont plus de chances d'être choisis comme nouveaux centres.

Conséquence : Les centres initiaux sont bien **répartis dans l'espace des données**, couvrant les différentes régions de densité.

Adoption pratique

Utilisation répandue : Cette stratégie d'initialisation est utilisée par plusieurs packages de Data Science : MATLABTM, Python SciKit Learn, R, et autres bibliothèques standards.

Astuce pratique : Toujours utiliser k-means++ ou lancer k-means plusieurs fois avec différentes initialisations aléatoires et garder le meilleur résultat.

Relation entre k-means et modèles gaussiens

k-means comme cas particulier du GMM

Question : Pourquoi dit-on que k-means considère un **modèle gaussien** pour les clusters ?

Réponse :

k-means peut être vu comme un cas limite de GMM (Gaussian Mixture Model) où :

Hypothèses du modèle :

- Chaque cluster suit une distribution **normale**
- Matrices de covariance **sphériques et identiques** : $\Sigma_k = \sigma^2 I_D$ pour tous les clusters
- Variance $\sigma^2 \rightarrow 0$: les distributions deviennent des pics

Conséquence :

Dans cette limite, l'**assignation douce** (soft-assignment) du GMM devient une **assignation dure** (hard-assignment), et on retrouve k-means.

i Détails mathématiques : Formulation probabiliste

Si on considère le modèle probabiliste :

$$\mathbb{P}(x|\mu_k, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{D/2}} \exp\left(-\frac{\|x - \mu_k\|^2}{2\sigma^2}\right)$$

Quand $\sigma \rightarrow 0$, maximiser cette probabilité est équivalent à minimiser $\|x - \mu_k\|^2$, ce qui est exactement le critère de k-means.

K-means est un cas particulier de GMM ! Quand on prend un mélange de gaussiennes avec covariances sphériques et identiques $\Sigma_k = \sigma^2 I$, et qu'on fait tendre $\sigma \rightarrow 0$, alors l'assignation douce devient dure, et on retrouve k-means.

Lien intrinsèque avec la métrique euclidienne

Pourquoi k-means dépend de la métrique euclidienne ?

Analyse de la fonction de perte :

$$L(\theta, X) = \sum_{i=1}^N \sum_{k=1}^K z_{ik} \|x_i - \mu_k\|_2^2$$

La norme $\|\cdot\|_2$ est la **norme euclidienne** : $\|x\|_2^2 = \sum_d x(d)^2$.

Conséquences pratiques

Sensibilité à l'échelle :

k-means est **sensible à l'échelle** des variables. Des variables avec de grandes valeurs dominent la distance.

Solution : Normalisation des données avant d'appliquer k-means :

- Centrer : soustraire la moyenne
- Réduire : diviser par l'écart-type

Limitation aux espaces euclidiens :

k-means ne peut pas être directement appliqué à des données **non-euclidiennes** (graphes, textes, etc.).

Alternatives : Pour d'autres métriques, utiliser des variantes comme k-medoids qui fonctionnent avec des distances arbitraires.

Choix du nombre de clusters K

Problématique

Difficulté : Le nombre de clusters K doit être **spécifié a priori** dans k-means.

Méthodes de sélection

Méthode du coude (Elbow method) :

Tracer la perte L en fonction de K et chercher un “coude” dans la courbe.

Silhouette score :

Mesure la qualité du clustering en comparant la distance intra-cluster à la distance inter-cluster.

Pour un point i :

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

où $a(i)$ = distance moyenne aux autres points du même cluster, $b(i)$ = distance moyenne aux points du cluster le plus proche.

Interprétation : $s(i) \approx 1$ = bien classé, ≈ 0 = à la frontière, ≈ -1 = mal classé.

Gap statistic :

Compare la perte observée à la perte attendue sous une distribution de référence.

Critères d'information :

- BIC (Bayesian Information Criterion)
- AIC (Akaike Information Criterion)

Conseil pratique : Tester plusieurs valeurs de K et utiliser des critères multiples.

Les pièges de k-means et comment les éviter

Piège 1 : Les Clusters Non Sphériques

Problème : K-means suppose des clusters sphériques. S'ils sont allongés ou de formes bizarres, ça échoue.

Solution :

- Standardiser les données (centrer-réduire)
- Utiliser une autre méthode (GMM, spectral clustering)
- Transformer les données (PCA d'abord)

Piège 2 : Les Clusters de Tailles Très Différentes

Problème : K-means tend à créer des clusters de taille similaire, même si la réalité est différente.

Solution : Ajuster K, ou utiliser une méthode qui gère ça (GMM).

Piège 3 : La Sensibilité aux Outliers

Problème : Un point très éloigné tire le centre de son cluster vers lui.

Solution :

- Détecter et enlever les outliers avant
- Utiliser k-medoids (plus robuste)
- Standardiser pour réduire l'influence

Piège 4 : L'Interprétation des Résultats

Problème : K-means trouve toujours K clusters, même si les données n'ont pas de structure.

Solution : Toujours valider avec des méthodes objectives (silhouette, gap statistic).

Variantes de k-means

K-medoids

Différence : Les centres sont des points réels des données (pas des moyennes).

Avantage : Plus robuste aux outliers, fonctionne avec n'importe quelle distance.

Mini-batch K-means

Différence : Utilise des sous-échantillons des données à chaque itération.

Avantage : Beaucoup plus rapide pour les grandes données.

Fuzzy C-means

Différence : Assignment douce (comme GMM) mais avec un critère géométrique.

Avantage : Points frontières appartiennent partiellement à plusieurs clusters.

Clustering contraint

Le clustering peut être **contraint** avec :

Contraintes MUST-LINK :

Deux points doivent être dans le **même cluster**.

Contraintes CANNOT-LINK :

Deux points doivent être dans des **clusters différents**.

Application pratique : Ces contraintes permettent d'incorporer des **connaissances a priori** ou des **contraintes du domaine** dans le processus de clustering.

En pratique : La recette complète

Étape 1 : Préparation des Données

- **Nettoyer** : gérer les valeurs manquantes
- **Standardiser** : centrer et réduire chaque variable
- **Visualiser** (si possible en 2D/3D) pour avoir une idée

Étape 2 : Choix de K

- **Méthode du coude** : tracer inertie vs K
- **Score de silhouette** : moyenne sur tous les points
- **Connaissance du domaine** : parfois on sait combien de clusters on cherche

Étape 3 : Exécution

- Initialiser K centres avec k-means++
- Répéter :
 - Assigner chaque point au centre le plus proche
 - Recalculer les centres comme moyennes
 - Si les centres bougent peu, arrêter
- Évaluer avec score de silhouette
- Si doute, relancer avec différentes initialisations

Étape 4 : Validation

- **Interne** : scores (silhouette, Davies-Bouldin)
- **Externe** : si on a quelques étiquettes, comparer
- **Manuelle** : visualisation, bon sens

Comparaison k-means vs GMM vs Clustering hiérarchique

Critère	k-means	GMM (avec EM)	Clustering hiérarchique
Type d'assignation	Dure (hard)	Douce (soft)	Hiérarchique
Forme des clusters	Sphériques (même variance)	Elliptiques (covariances différentes)	Flexible
Nombre de clusters	Doit être spécifié	Doit être spécifié	Déterminé a posteriori (dendrogramme)
Complexité	$O(N \cdot K \cdot D \cdot T)$	$O(N \cdot K \cdot D^2 \cdot T)$	$O(N^2 \log N)$ ou $O(N^3)$

Critère	k-means	GMM (avec EM)	Clustering hiérarchique
Avantages	Rapide, simple	Modèle probabiliste, clusters de formes variées	Pas besoin de spécifier K, visualisation
Inconvénients	Sensible à l'initialisation, suppose clusters sphériques	Plus lent, plus de paramètres	Coûteux pour grandes données, pas de réassignation

Synthèse des concepts clés

Caractéristiques essentielles de k-means

Nature de la méthode :

- k-means fait partie de la famille **non supervisée** de techniques de modélisation de données
- Une des techniques de clustering les **plus populaires**

Assignation :

- k-means effectue une **assignation dure** (hard-assignment)
- Chaque point appartient à **un seul cluster**

Optimisation :

- Critère d'optimisation (perte) **solide** mais **NP-Hard**
- L'algorithme k-means cherche une **solution approximative** par descente de coordonnées (minimisation alternée)

Convergence :

- La perte **n'est pas convexe** → technique **sensible à l'initialisation**
- k-means++ est une **heuristique a priori** pour l'initialisation, efficace en pratique

Extensions :

- Clustering peut être **contraint** (contraintes MUST-LINK et CANNOT-LINK)

💡 Fiche de révision condensée

En 30 secondes pour l'oral :

- K-means = clustering par minimisation de distance
- Deux étapes : assignation (points $\rightarrow$ centre plus proche) et mise à jour (recalcul des centres)
- Problèmes : choix de K, initialisation, clusters sphériques
- Solutions : k-means++, méthode du coude, standardisation
- Parenté : cas particulier des GMM avec $\sigma \rightarrow 0$
- Applications : segmentation, regroupement, réduction de dimension

! Concepts mathématiques à maîtriser

Algèbre et géométrie :

- Norme euclidienne et distance
- Centre de masse (barycentre)
- Diagramme de Voronoï
- Espaces métriques

Optimisation :

- Descente de coordonnées
- Minimisation alternée
- Optimisation combinatoire
- Complexité NP-Hard
- Convergence d'algorithmes itératifs
- Optima locaux vs globaux
- Fonctions convexes

Probabilités et statistiques :

- Distribution gaussienne multivariée
- Maximum de vraisemblance
- Modèles de mélange

Points à développer :

- Dérivation de la fonction de perte
- Calcul de $\frac{\partial L_Z}{\partial \mu_k}$ et condition d'optimalité
- Preuve que les centres sont les barycentres
- Preuve de la décroissance monotone de la perte
- Relation entre k-means et modèle gaussien limite