

# Table of contents

|                                                                  |          |
|------------------------------------------------------------------|----------|
| <b>L'essentiel</b>                                               | <b>2</b> |
| Introduction et Motivation . . . . .                             | 2        |
| Le problème fondamental . . . . .                                | 2        |
| Problématique des données réelles . . . . .                      | 2        |
| L'intuition géométrique : Le jeu des chaises musicales . . . . . | 3        |
| Panorama des méthodes de clustering . . . . .                    | 3        |
| Clustering hiérarchique agglomératif . . . . .                   | 4        |
| Principe de l'algorithme . . . . .                               | 4        |
| Distances entre ensembles (clusters) . . . . .                   | 4        |
| Stratégie k-means . . . . .                                      | 5        |
| Hypothèses fondamentales . . . . .                               | 5        |
| Modèle formel . . . . .                                          | 5        |
| Fonction de perte k-means . . . . .                              | 6        |
| Algorithme de descente de coordonnées . . . . .                  | 6        |
| Application au k-means . . . . .                                 | 7        |
| Algorithme k-means complet . . . . .                             | 8        |
| Description détaillée . . . . .                                  | 8        |
| Étapes de l'algorithme . . . . .                                 | 8        |
| Critères de convergence . . . . .                                | 9        |
| Propriétés de l'algorithme k-means . . . . .                     | 9        |
| Garanties théoriques . . . . .                                   | 9        |
| Interprétation géométrique . . . . .                             | 10       |
| Lien avec l'algorithme EM . . . . .                              | 10       |
| Sensibilité à l'initialisation . . . . .                         | 10       |
| Initialisation, liens et relations . . . . .                     | 11       |
| K-means++ : Initialisation intelligente . . . . .                | 11       |
| Relation entre k-means et modèles gaussiens . . . . .            | 12       |
| Lien intrinsèque avec la métrique euclidienne . . . . .          | 13       |
| Choix du nombre de clusters K . . . . .                          | 14       |
| Les pièges de k-means et comment les éviter . . . . .            | 15       |
| Piège 1 : Les Clusters Non Sphériques . . . . .                  | 15       |
| Piège 2 : Les Clusters de Tailles Très Différentes . . . . .     | 15       |
| Piège 3 : La Sensibilité aux Outliers . . . . .                  | 15       |
| Piège 4 : L'Interprétation des Résultats . . . . .               | 15       |
| Variantes de k-means . . . . .                                   | 16       |
| K-medoids . . . . .                                              | 16       |
| Mini-batch K-means . . . . .                                     | 16       |
| Fuzzy C-means . . . . .                                          | 16       |
| Clustering contraint . . . . .                                   | 16       |

|                                                                 |    |
|-----------------------------------------------------------------|----|
| En pratique : La recette complète . . . . .                     | 16 |
| Étape 1 : Préparation des Données . . . . .                     | 16 |
| Étape 2 : Choix de K . . . . .                                  | 17 |
| Étape 3 : Exécution . . . . .                                   | 17 |
| Étape 4 : Validation . . . . .                                  | 17 |
| Comparaison k-means vs GMM vs Clustering hiérarchique . . . . . | 17 |
| Synthèse des concepts clés . . . . .                            | 18 |
| Caractéristiques essentielles de k-means . . . . .              | 18 |

## L'essentiel

### Introduction et Motivation

L'algorithme **k-means** est une méthode d'**estimation de facteurs latents discrets** dans un contexte **non supervisé** de clustering (regroupement).

### Le problème fondamental

Imaginez : On vous donne 1000 photos d'animaux non étiquetées et on vous demande : "Combien y a-t-il de types d'animaux différents, et quelles photos vont ensemble ?" C'est exactement le problème du clustering !

**K-means** répond à cette question en faisant **une hypothèse simplificatrice** : chaque type d'animal peut être représenté par une **image moyenne** (prototype), et chaque photo est proche de l'un de ces prototypes.

**Concept clé** : Le clustering est **non supervisé** : pas d'étiquettes, pas de professeur pour dire "ceci est un chat". L'algorithme doit découvrir la structure par lui-même.

### Problématique des données réelles

#### Observation fondamentale :

Les données ne proviennent généralement **pas d'un simple processus gaussien** (variations autour d'un prototype moyen).

#### Caractéristiques des données réelles :

- La distribution des données montre généralement une **non-uniformité**
- Présence de **régions de densité plus élevée**

### Définition du clustering :

Le clustering est une méthode **non supervisée** qui vise à découvrir des **groupes cohérents** de données, correspondant à des **pics de densité** des données.

---

### L'intuition géométrique : Le jeu des chaises musicales

#### Analogie pratique

Imaginez un jeu de chaises musicales avec K chaises (clusters) et N joueurs (points de données). Quand la musique s'arrête :

- Chaque joueur court vers la chaise la plus proche (**assignation**)
- On déplace chaque chaise au centre des joueurs qui l'entourent (**mise à jour**)
- On recommence jusqu'à ce que les chaises ne bougent plus

**C'est exactement k-means !**

**Idée essentielle :** K-means alterne entre deux questions simples : “où va chaque point ?” et “où sont les centres ?”. Cette alternance garantit une amélioration à chaque étape.

---

### Panorama des méthodes de clustering

#### Principales méthodes

Il existe un grand nombre de méthodes de clustering, incluant :

#### Méthodes hiérarchiques :

- Hierarchical Agglomerative Clustering (HAC)

#### Méthodes de partitionnement :

- **k-means** (algorithme de Lloyd)
- k-medoids

#### Méthodes spectrales :

- Spectral clustering

#### Autres approches :

- Community detection
- High-dimensional clustering
- Self-Organizing Maps (SOM)
- Neural Gas

**Note historique :** La recherche sur le clustering est active depuis au moins 50 ans.

---

## Clustering hiérarchique agglomératif

### Principe de l'algorithme

Processus itératif :

- **Initialisation** : Chaque donnée est un cluster
- **Recherche** : Trouver la paire de clusters la plus proche
- **Fusion** : Fusionner ces deux clusters
- **Itération** : Répéter jusqu'à la fin

**Résultat** : Production d'un **dendrogramme** des données.

### Distances entre ensembles (clusters)

Métriques possibles :

- **Distance entre centres** (centroid linkage)
- **Distance maximale** (complete linkage) :  $\max_{x \in C_1, y \in C_2} d(x, y)$
- **Distance minimale** (single linkage) :  $\min_{x \in C_1, y \in C_2} d(x, y)$

**Limitation** : Le nombre de clusters est **inconnu a priori**.

---

## Stratégie k-means

### Hypothèses fondamentales

L'algorithme de clustering **k-means** postule :

- Un espace métrique (**euclidien**) normé sur les données
- Une assignation **non supervisée** des données aux clusters
- Un algorithme d'**assignation dure** (hard-assignment) : l'assignation est **binaire**, chaque donnée est assignée à **un et un seul** cluster

### Modèle formel

Données :

Soit  $X = \{x_i\}_{i \in [[N]]} \subset \Omega \subseteq \mathbb{R}^D$ , et  $K \in \mathbb{N}^*$  donné.

Variables du modèle :

- Variables d'assignation binaire (latentes) :

$$Z = \{z_{ik}\} \quad \text{avec} \quad z_{ik} \in \{\text{false}, \text{true}\} \equiv \{0, 1\} \quad \forall i, k$$

- Représentants des clusters :

$$M = \{\mu_k\}_{k \in [[K]]} \quad \text{avec} \quad \mu_k \in \mathbb{R}^D \quad \forall k$$

Paramètres complets :

$$\theta = [M, Z]$$

---

## Fonction de perte k-means

### Problème d'optimisation

k-means cherche l'assignation suivante :

$$\hat{\theta} = [\hat{M}, \hat{Z}] = \arg \min_{\theta=[M,Z]} L(\theta, X)$$

### Fonction de perte :

$$L(\theta, X) = \sum_{i=1}^N \sum_{k=1}^K z_{ik} \|x_i - \mu_k\|_2^2$$

### Interprétation :

- Somme des **distances au carré** entre chaque point et son représentant de cluster
- Plus cette somme est petite, meilleure est la partition

**Pourquoi au carré ?** Deux raisons :

- **Mathématique** : rend le problème plus facile à résoudre
- **Géométrique** : pénalise plus les points très éloignés

### Complexité du problème

**Difficulté majeure** : Puisque l'assignation est binaire, l'optimisation exacte est **NP-Hard**.

**Solution pratique** : Chercher une **approximation par descente de coordonnées** (coordinate descent).

---

## Algorithme de descente de coordonnées

### Principe général

La descente de coordonnées est un **algorithme de minimisation alternée**.

### Problème :

Soit  $f : \mathbb{R}^D \rightarrow \mathbb{R}$ , on cherche :

$$x^* = \arg \min_{x \in \mathbb{R}^D} f(x)$$

**i** Détails mathématiques : Stratégie de résolution

**Définition des fonctions partielles :**

Pour  $d \in [[D]]$ , on définit  $f^d : \mathbb{R}^D \times \mathbb{R} \rightarrow \mathbb{R}$  :

$$f^d(x, y) = f([x(1), \dots, x(d-1), y, x(d+1), \dots, x(D)]^T)$$

**Optimisation alternée :**

On cherche alternativement le minimum selon chaque coordonnée :

$$x^{(t+1)}(d) = \arg \min_y f^d(x^{(t)}, y)$$

**Principe :** Fixer toutes les variables sauf une, optimiser cette variable, puis passer à la suivante.

---

**Application au k-means**

**Optimisation alternée de Z et M**

On alterne l'optimisation de Z et M.

**Définitions des pertes partielles :**

$$L_M(Z) = L(\theta, X)|_{M=M}$$

$$L_Z(M) = L(\theta, X)|_{Z=Z}$$

**Les deux équations magiques**

**Optimisation par rapport à M (représentants) :**

**i** Détails mathématiques : Calcul des centres

**Calcul de la dérivée :**

$$\frac{\partial L_Z}{\partial \mu_k} = -2 \sum_{i=1}^N z_{ik} (x_i - \mu_k)$$

**Condition d'optimalité :**

Le représentant optimal M pour une assignation donnée Z est atteint quand :

$$\frac{\partial L_Z}{\partial \mu_k} = 0 \quad \Rightarrow \quad \mu_k = \frac{\sum_{i=1}^N z_{ik} x_i}{\sum_{i=1}^N z_{ik}}$$

**Conclusion fondamentale :** Les représentants des clusters sont leurs **centres de masse** (barycentres).

**Optimisation par rapport à  $Z$  (assignment) :**

Étant donné un ensemble de représentants de clusters  $M$ , pour minimiser  $L_M(Z)$  :

$$z_{ik} = 1 \quad \text{seulement quand} \quad k = \arg \min_m \|x_i - \mu_m\|_2^2$$

(et  $z_{ik} = 0$  sinon)

**Conclusion :**  $L_M(Z)$  est minimale quand **chaque donnée est assignée à son représentant de cluster le plus proche**.

## Algorithme k-means complet

### Description détaillée

**Données d'entrée :**

- $X = \{x_i\}_{i \in [N]}$  avec  $x_i \in \mathbb{R}^D$
- $K \in \mathbb{N}^*$  (nombre de clusters)

### Étapes de l'algorithme

#### Étape 1 : Initialisation

Initialiser les représentants de clusters  $M^{(0)}$ .

#### Étape 2 : Assignment (E-step like)

Étant donné les représentants de clusters  $M^{(t)}$ , l'assignation  $Z^{(t)}$  associe chaque donnée à son représentant de cluster le plus proche :

$$z_{ik}^{(t)} = \begin{cases} 1 & \text{si } k = \arg \min_m \|x_i - \mu_m^{(t)}\|_2^2 \\ 0 & \text{sinon} \end{cases}$$



### Étape 3 : Mise à jour (M-step like)

Étant donné l'assignation  $Z^{(t)}$ , les nouveaux représentants de clusters  $M^{(t+1)}$  sont les centres de masse des données assignées aux clusters :

$$\mu_k^{(t+1)} = \frac{\sum_{i=1}^N z_{ik}^{(t)} x_i}{\sum_{i=1}^N z_{ik}^{(t)}}$$

### Étape 4 : Convergence

Répéter depuis l'étape 2 jusqu'à convergence.

### Critères de convergence

La convergence est atteinte quand :

- Les centres de masse **ne bougent plus beaucoup** :  $\|\mu_k^{(t+1)} - \mu_k^{(t)}\| < \epsilon$
- Ou l'assignation est **stable** :  $Z^{(t+1)} = Z^{(t)}$

**Note importante** : L'étape 2 est similaire à une étape d'**Expectation**, et l'étape 3 est similaire à une étape de **Maximization**, en considérant une assignation dure (référence à l'algorithme EM).

---

## Propriétés de l'algorithme k-means

### Garanties théoriques

#### Décroissance de la perte :

Puisqu'il effectue une **minimisation alternée de fonctions convexes**, il garantit de **diminuer la perte à chaque itération** :

$$L(M^{(t+1)}, Z^{(t+1)}) \leq L(M^{(t)}, Z^{(t)})$$

#### Finitude :

Il existe un nombre **combinatoire mais fini** d'assignations possibles  $\rightarrow$  le nombre d'itérations est **(grand mais) fini**.

**Pourquoi ça converge ?** Chaque étape ne peut qu'améliorer (ou laisser inchangé) le critère. Comme il y a un nombre fini d'assignations possibles, l'algorithme doit terminer.

## Interprétation géométrique

### Diagramme de Voronoï :

L'étape 2 est équivalente à construire le **diagramme de Voronoï discret** de  $X$  avec les centres  $M$  comme graines (seeds).

**Définition :** Le diagramme de Voronoï partitionne l'espace en régions, où chaque région contient tous les points plus proches d'un centre donné que de tout autre centre.

### Lien avec l'algorithme EM

#### Comparaison conceptuelle :

- **Étape 2 (Assignment)** : similaire à une étape **Expectation** (mais dure)
- **Étape 3 (Mise à jour)** : similaire à une étape **Maximization**

**Différence clé :** k-means utilise une **assignment dure** (hard-assignment) tandis que EM utilise une **assignment douce** (soft-assignment).

---

### Sensibilité à l'initialisation

#### Problème des optima locaux

**Limitation majeure :** Puisque l'optimisation exacte (assignment optimale) est **NP-Hard**, l'algorithme k-means atteint un **optimum local**.

#### Conséquences :

- La qualité du résultat **varie selon l'initialisation**
- Différentes initialisations peuvent donner des résultats très différents

### Le dilemme de l'initialisation

Si toutes les chaises commencent dans le même coin, le jeu sera très long et donnera un mauvais résultat. **K-means est très sensible à l'initialisation !**

## Stratégies pratiques

### Randomisation :

La randomisation peut être utile si le calcul est rapide → lancer plusieurs fois avec différentes initialisations.

### Heuristiques :

Sinon, utiliser des **heuristiques pour une meilleure initialisation** (comme k-means++).

---

## Initialisation, liens et relations

### K-means++ : Initialisation intelligente

#### Principe fondamental

Le principe de **k-means++** est de **maximalement disperser** les représentants de clusters initiaux  $M^{(0)}$  sur les données.

#### Avantages démontrés :

- Produit des clusters de **meilleure qualité**
- **Accélère la convergence** de k-means

### Algorithme k-means++ détaillé

#### Étape 1 : Premier centre

Sélectionner le premier représentant de cluster  $\mu_1^0$  **aléatoirement** parmi les données  $X$ .

#### Étape 2 : Calcul des distances

Pour toutes les données non sélectionnées  $x_i$ , calculer :

$$\Delta_i = \|x_i - \mu_m^0\|_2^2$$

la distance entre  $x_i$  et son représentant le plus proche  $\mu_m^0$  parmi les  $k$  représentants déjà sélectionnés.

#### Étape 3 : Échantillonnage pondéré

Échantillonner le prochain représentant  $\mu_{k+1}^0$  depuis  $X$  avec une **probabilité proportionnelle** à la distribution  $\Delta$  :

$$\mathbb{P}(\text{choisir } x_i) = \frac{\Delta_i}{\sum_j \Delta_j}$$

#### Étape 4 : Itération

Répéter depuis l'étape 2 jusqu'à ce que  $K$  représentants soient choisis.

#### Intuition de l'algorithme

**Idée clé :** Les points **loin des centres déjà sélectionnés** ont plus de chances d'être choisis comme nouveaux centres.

**Conséquence :** Les centres initiaux sont bien **répartis dans l'espace des données**, couvrant les différentes régions de densité.

#### Adoption pratique

**Utilisation répandue :** Cette stratégie d'initialisation est utilisée par plusieurs packages de Data Science : MATLAB™, Python SciKit Learn, R, et autres bibliothèques standards.

**Astuce pratique :** Toujours utiliser k-means++ ou lancer k-means plusieurs fois avec différentes initialisations aléatoires et garder le meilleur résultat.

#### Relation entre k-means et modèles gaussiens

##### k-means comme cas particulier du GMM

**Question :** Pourquoi dit-on que k-means considère un **modèle gaussien** pour les clusters ?

**Réponse :**

k-means peut être vu comme un cas limite de GMM (Gaussian Mixture Model) où :

**Hypothèses du modèle :**

- Chaque cluster suit une distribution **normale**
- Matrices de covariance **sphériques et identiques** :  $\Sigma_k = \sigma^2 I_D$  pour tous les clusters
- Variance  $\sigma^2 \rightarrow 0$  : les distributions deviennent des pics

**Conséquence :**

Dans cette limite, l'**assignation douce** (soft-assignment) du GMM devient une **assignation dure** (hard-assignment), et on retrouve k-means.

### **i** Détails mathématiques : Formulation probabiliste

Si on considère le modèle probabiliste :

$$\mathbb{P}(x|\mu_k, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{D/2}} \exp\left(-\frac{\|x - \mu_k\|^2}{2\sigma^2}\right)$$

Quand  $\sigma \rightarrow 0$ , maximiser cette probabilité est équivalent à minimiser  $\|x - \mu_k\|^2$ , ce qui est exactement le critère de k-means.

**K-means est un cas particulier de GMM !** Quand on prend un mélange de gaussiennes avec covariances sphériques et identiques  $\Sigma_k = \sigma^2 I$ , et qu'on fait tendre  $\sigma \rightarrow 0$ , alors l'assignation douce devient dure, et on retrouve k-means.

---

### Lien intrinsèque avec la métrique euclidienne

#### Pourquoi k-means dépend de la métrique euclidienne ?

Analyse de la fonction de perte :

$$L(\theta, X) = \sum_{i=1}^N \sum_{k=1}^K z_{ik} \|x_i - \mu_k\|_2^2$$

La norme  $\|\cdot\|_2$  est la **norme euclidienne** :  $\|x\|_2^2 = \sum_d x(d)^2$ .

### Conséquences pratiques

#### Sensibilité à l'échelle :

k-means est **sensible à l'échelle** des variables. Des variables avec de grandes valeurs dominent la distance.

**Solution : Normalisation** des données avant d'appliquer k-means :

- Centrer : soustraire la moyenne
- Réduire : diviser par l'écart-type

#### Limitation aux espaces euclidiens :

k-means ne peut pas être directement appliqué à des données **non-euclidiennes** (graphes, textes, etc.).

**Alternatives :** Pour d'autres métriques, utiliser des variantes comme k-medoids qui fonctionnent avec des distances arbitraires.

---

## Choix du nombre de clusters $K$

### Problématique

**Difficulté :** Le nombre de clusters  $K$  doit être **spécifié a priori** dans k-means.

### Méthodes de sélection

#### Méthode du coude (Elbow method) :

Tracer la perte  $L$  en fonction de  $K$  et chercher un “coude” dans la courbe.

#### Silhouette score :

Mesure la qualité du clustering en comparant la distance intra-cluster à la distance inter-cluster.

Pour un point  $i$  :

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

où  $a(i)$  = distance moyenne aux autres points du même cluster,  $b(i)$  = distance moyenne aux points du cluster le plus proche.

**Interprétation :**  $s(i) \approx 1$  = bien classé,  $\approx 0$  = à la frontière,  $\approx -1$  = mal classé.

#### Gap statistic :

Compare la perte observée à la perte attendue sous une distribution de référence.

#### Critères d'information :

- BIC (Bayesian Information Criterion)
- AIC (Akaike Information Criterion)

**Conseil pratique :** Tester plusieurs valeurs de  $K$  et utiliser des critères multiples.

---

## Les pièges de k-means et comment les éviter

### Piège 1 : Les Clusters Non Sphériques

**Problème :** K-means suppose des clusters sphériques. S'ils sont allongés ou de formes bizarres, ça échoue.

**Solution :**

- Standardiser les données (centrer-réduire)
- Utiliser une autre méthode (GMM, spectral clustering)
- Transformer les données (PCA d'abord)

### Piège 2 : Les Clusters de Tailles Très Différentes

**Problème :** K-means tend à créer des clusters de taille similaire, même si la réalité est différente.

**Solution :** Ajuster K, ou utiliser une méthode qui gère ça (GMM).

### Piège 3 : La Sensibilité aux Outliers

**Problème :** Un point très éloigné tire le centre de son cluster vers lui.

**Solution :**

- Détecter et enlever les outliers avant
- Utiliser k-medoids (plus robuste)
- Standardiser pour réduire l'influence

### Piège 4 : L'Interprétation des Résultats

**Problème :** K-means trouve toujours K clusters, même si les données n'ont pas de structure.

**Solution :** Toujours valider avec des méthodes objectives (silhouette, gap statistic).

## Variantes de k-means

### K-medoids

**Différence :** Les centres sont des points réels des données (pas des moyennes).

**Avantage :** Plus robuste aux outliers, fonctionne avec n'importe quelle distance.

### Mini-batch K-means

**Différence :** Utilise des sous-échantillons des données à chaque itération.

**Avantage :** Beaucoup plus rapide pour les grandes données.

### Fuzzy C-means

**Différence :** Assignment douce (comme GMM) mais avec un critère géométrique.

**Avantage :** Points frontières appartiennent partiellement à plusieurs clusters.

### Clustering contraint

Le clustering peut être **contraint** avec :

**Contraintes MUST-LINK :**

Deux points doivent être dans le **même cluster**.

**Contraintes CANNOT-LINK :**

Deux points doivent être dans des **clusters différents**.

**Application pratique :** Ces contraintes permettent d'incorporer des **connaissances a priori** ou des **contraintes du domaine** dans le processus de clustering.

---

## En pratique : La recette complète

### Étape 1 : Préparation des Données

- **Nettoyer** : gérer les valeurs manquantes
- **Standardiser** : centrer et réduire chaque variable
- **Visualiser** (si possible en 2D/3D) pour avoir une idée



## Étape 2 : Choix de K

- **Méthode du coude** : tracer inertie vs K
- **Score de silhouette** : moyenne sur tous les points
- **Connaissance du domaine** : parfois on sait combien de clusters on cherche

## Étape 3 : Exécution

- Initialiser K centres avec k-means++
- Répéter :
  - Assigner chaque point au centre le plus proche
  - Recalculer les centres comme moyennes
  - Si les centres bougent peu, arrêter
- Évaluer avec score de silhouette
- Si doute, relancer avec différentes initialisations

## Étape 4 : Validation

- **Interne** : scores (silhouette, Davies-Bouldin)
- **Externe** : si on a quelques étiquettes, comparer
- **Manuelle** : visualisation, bon sens

---

## Comparaison k-means vs GMM vs Clustering hiérarchique

| Critère                   | k-means                        | GMM (avec EM)                         | Clustering hiérarchique               |
|---------------------------|--------------------------------|---------------------------------------|---------------------------------------|
| <b>Type d'assignation</b> | Dure (hard)                    | Douce (soft)                          | Hiérarchique                          |
| <b>Forme des clusters</b> | Sphériques (même variance)     | Elliptiques (covariances différentes) | Flexible                              |
| <b>Nombre de clusters</b> | Doit être spécifié             | Doit être spécifié                    | Déterminé a posteriori (dendrogramme) |
| <b>Complexité</b>         | $O(N \cdot K \cdot D \cdot T)$ | $O(N \cdot K \cdot D^2 \cdot T)$      | $O(N^2 \log N)$ ou $O(N^3)$           |

| Critère              | k-means                                                  | GMM (avec EM)                                   | Clustering hiérarchique                            |
|----------------------|----------------------------------------------------------|-------------------------------------------------|----------------------------------------------------|
| <b>Avantages</b>     | Rapide, simple                                           | Modèle probabiliste, clusters de formes variées | Pas besoin de spécifier K, visualisation           |
| <b>Inconvénients</b> | Sensible à l'initialisation, suppose clusters sphériques | Plus lent, plus de paramètres                   | Coûteux pour grandes données, pas de réassignation |

## Synthèse des concepts clés

### Caractéristiques essentielles de k-means

#### Nature de la méthode :

- k-means fait partie de la famille **non supervisée** de techniques de modélisation de données
- Une des techniques de clustering les **plus populaires**

#### Assignation :

- k-means effectue une **assignation dure** (hard-assignment)
- Chaque point appartient à **un seul cluster**

#### Optimisation :

- Critère d'optimisation (perte) **solide** mais **NP-Hard**
- L'algorithme k-means cherche une **solution approximative** par descente de coordonnées (minimisation alternée)

#### Convergence :

- La perte **n'est pas convexe** → technique **sensible à l'initialisation**
- k-means++ est une **heuristique a priori** pour l'initialisation, efficace en pratique

#### Extensions :

- Clustering peut être **contraint** (contraintes MUST-LINK et CANNOT-LINK)

💡 Fiche de révision condensée

**En 30 secondes pour l'oral :**

- K-means = clustering par minimisation de distance
- Deux étapes : assignation (points  $\rightarrow$  centre plus proche) et mise à jour (recalcul des centres)
- Problèmes : choix de K, initialisation, clusters sphériques
- Solutions : k-means++, méthode du coude, standardisation
- Parenté : cas particulier des GMM avec  $\sigma \rightarrow 0$
- Applications : segmentation, regroupement, réduction de dimension

! Concepts mathématiques à maîtriser

**Algèbre et géométrie :**

- Norme euclidienne et distance
- Centre de masse (barycentre)
- Diagramme de Voronoï
- Espaces métriques

**Optimisation :**

- Descente de coordonnées
- Minimisation alternée
- Optimisation combinatoire
- Complexité NP-Hard
- Convergence d'algorithmes itératifs
- Optima locaux vs globaux
- Fonctions convexes

**Probabilités et statistiques :**

- Distribution gaussienne multivariée
- Maximum de vraisemblance
- Modèles de mélange

**Points à développer :**

- Dérivation de la fonction de perte
- Calcul de  $\frac{\partial L_Z}{\partial \mu_k}$  et condition d'optimalité
- Preuve que les centres sont les barycentres
- Preuve de la décroissance monotone de la perte
- Relation entre k-means et modèle gaussien limite