

Table of contents

Intuition	1
1. Le Problème Fondamental : Regrouper sans Guide	1
2. L'Intuition Géométrique : Le Jeu des Chaises Musicales	3
3. La Formulation Mathématique : Minimiser l'Énergie	6
Le Critère à Minimiser	6
Les Deux Équations Magiques	6
4. Le Problème de l'Initialisation : Où Placer les Premières Chaises ?	6
Le Dilemme	6
K-means++ : La Solution Intelligente	7
5. Le Choix de K : Combien de Chaises ?	8
Le Problème Principal	8
Méthodes pour Choisir K	8
6. K-means vs GMM : Le Duel des Clusters	8
7. Les Pièges de K-means et Comment les Éviter	9
Piège 1 : Les Clusters Non Sphériques	9
Piège 2 : Les Clusters de Tailles Très Différentes	9
Piège 3 : La Sensibilité aux Outliers	9
Piège 4 : L'Interprétation des Résultats	10
8. En Pratique : La Recette Complète	10
Étape 1 : Préparation des Données	10
Étape 2 : Choix de K	10
Étape 3 : Exécution	10
Étape 4 : Validation	10
9. Les Variantes de K-means	11
K-medoids	11
Mini-batch K-means	11
Fuzzy C-means	11
10. Fiche de Révision Express	11
11. Pour l'Oral : L'Histoire à Raconter	11
12. Questions Fréquentes à l'Examen	12
13. Le Mot de la Fin	12

Intuition


1. Le Problème Fondamental : Regrouper sans Guide

Imaginez : On vous donne 1000 photos d'animaux non étiquetées et on vous demande : "Combien y a-t-il de types d'animaux différents, et quelles photos vont ensemble ?" C'est exactement le problème du clustering !

K-means répond à cette question en faisant **une hypothèse simplificatrice** : chaque type d'animal peut être représenté par une **image moyenne** (prototype), et chaque photo est proche de l'un de ces prototypes.

! Important

Concept Clé : Apprentissage non supervisé Le clustering est **non supervisé** : pas d'étiquettes, pas de professeur pour dire “ceci est un chat”. L'algorithme doit découvrir la structure par lui-même.




2. L'Intuition Géométrique : Le Jeu des Chaises Musicales

Analogie : Imaginez un jeu de chaises musicales avec K chaises (clusters) et N joueurs (points de données). Quand la musique s'arrête : 1. Chaque joueur court vers la chaise la plus proche

(**assignation**) 2. On déplace chaque chaise au centre des joueurs qui l'entourent (**mise à jour**) 3. On recommence jusqu'à ce que les chaises ne bougent plus

C'est exactement k-means !



3. La Formulation Mathématique : Minimiser l'Énergie

Le Critère à Minimiser

K-means cherche à minimiser :

$L = \text{somme sur tous les points de (distance au centre de son cluster)}^2$

Pourquoi au carré ? Deux raisons : 1. **Mathématique** : rend le problème plus facile à résoudre 2. **Géométrique** : pénalise plus les points très éloignés

Les Deux Équations Magiques

Étape d'assignation (E-like) : Pour chaque point x_i , trouver le centre μ_k le plus proche :

Assigner x_i au cluster k qui minimise $\|x_i - \mu_k\|^2$

Étape de mise à jour (M-like) : Pour chaque cluster k , recalculer son centre :

$\mu_k = \text{moyenne de tous les points assignés au cluster } k$

Note

Pourquoi ça converge ? Chaque étape ne peut qu'améliorer (ou laisser inchangé) le critère. Comme il y a un nombre fini d'assignations possibles, l'algorithme doit terminer.

4. Le Problème de l'Initialisation : Où Placer les Premières Chaises ?

Le Dilemme

Si toutes les chaises commencent dans le même coin, le jeu sera très long et donnera un mauvais résultat. **K-means est très sensible à l'initialisation !**



K-means++ : La Solution Intelligente

Principe : Éloigner les centres initiaux les uns des autres.

Algorithme : 1. Choisir un premier centre au hasard 2. Pour chaque point, calculer sa distance $D(x)$ au centre le plus proche 3. Choisir le prochain centre avec une probabilité proportionnelle à $D(x)^2$ 4. Répéter jusqu'à avoir K centres

Pourquoi ça marche ? En favorisant les points éloignés, on couvre mieux l'espace des données.



Tip

Astuce pratique : Toujours utiliser k-means++ ou lancer k-means plusieurs fois avec différentes initialisations aléatoires et garder le meilleur résultat.

5. Le Choix de K : Combien de Clusters ?

Le Problème Principal

K-means a besoin qu'on lui dise combien de clusters chercher. Mais dans la vraie vie, **on ne sait pas à l'avance !**

Méthodes pour Choisir K

1. Méthode du Coude (Elbow Method)

Principe : Tracer l'erreur (inertie) en fonction de K.

$\text{Erreur}(K) = \text{somme des distances}^2 \text{ des points à leur centre}$

Quand K augmente, l'erreur diminue. On cherche le “coude” où l'amélioration ralentit.

2. Score de Silhouette

Principe : Mesure combien un point est bien dans son cluster vs hors de son cluster.

$$s(i) = (b(i) - a(i)) / \max(a(i), b(i))$$

où $a(i)$ = distance moyenne aux autres points du même cluster,

$b(i)$ = distance moyenne aux points du cluster le plus proche.

Interprétation : $s(i) \approx 1$ = bien classé, $s(i) \approx 0$ = à la frontière, $s(i) \approx -1$ = mal classé.

3. Règle Pratique

Pour N points : $K \approx \sqrt{N/2}$ (très grossier, à utiliser avec prudence).

6. K-means vs GMM : Le Duel des Clusters

Aspect	K-means	GMM avec EM
Philosophie	Géométrique (distance)	Probabiliste (densité)
Appartenance	Dure (0 ou 1)	Douce (probabilité)
Forme clusters	Sphères (toutes mêmes tailles)	Ellipses (tailles/orientations variables)
Modèle	Minimise distance	Maximise vraisemblance
Vitesse	Rapide ($O(NKT)$)	Plus lent (plus de calculs)
Cas limite	-	K-means = GMM avec $\sigma^2 \rightarrow 0$ et covariances sphériques

! Important

K-means est un cas particulier de GMM ! Quand on prend un mélange de gaussiennes avec : - Covariances sphériques et identiques : $\Sigma_k = \sigma^2 I$ - Et qu'on fait tendre $\sigma^2 \rightarrow 0$ Alors l'assignation douce devient dure, et on retrouve k-means.

7. Les Pièges de K-means et Comment les Éviter

Piège 1 : Les Clusters Non Sphériques

Problème : K-means suppose des clusters sphériques. S'ils sont allongés ou de formes bizarres, ça échoue.

Solution : - Standardiser les données (centrer-réduire) - Utiliser une autre méthode (GMM, spectral clustering) - Transformer les données (PCA d'abord)

Piège 2 : Les Clusters de Tailles Très Différentes

Problème : K-means tend à créer des clusters de taille similaire, même si la réalité est différente.

Solution : Ajuster K, ou utiliser une méthode qui gère ça (GMM).

Piège 3 : La Sensibilité aux Outliers

Problème : Un point très éloigné tire le centre de son cluster vers lui.

Solution : - Détecter et enlever les outliers avant - Utiliser k-medoids (plus robuste) - Standardiser pour réduire l'influence

Piège 4 : L'Interprétation des Résultats

Problème : K-means trouve toujours K clusters, même si les données n'ont pas de structure.

Solution : Toujours valider avec des méthodes objectives (silhouette, gap statistic).

8. En Pratique : La Recette Complète

Étape 1 : Préparation des Données

1. **Nettoyer** : gérer les valeurs manquantes
2. **Standardiser** : centrer et réduire chaque variable
3. **Visualiser** (si possible en 2D/3D) pour avoir une idée

Étape 2 : Choix de K

1. **Méthode du coude** : tracer inertie vs K
2. **Score de silhouette** : moyenne sur tous les points
3. **Connaissance du domaine** : parfois on sait combien de clusters on cherche

Étape 3 : Exécution

```
# Pseudocode
1. Initialiser K centres avec k-means++
2. Répéter:
  a. Assigner chaque point au centre le plus proche
  b. Recalculer les centres comme moyennes
  c. Si les centres bougent peu, arrêter
3. Évaluer avec score de silhouette
4. Si doute, relancer avec différentes initialisations
```

Étape 4 : Validation

1. **Interne** : scores (silhouette, Davies-Bouldin)
2. **Externe** : si on a quelques étiquettes, comparer
3. **Manuelle** : visualisation, bon sens

9. Les Variantes de K-means

K-medoids

Différence : Les centres sont des points réels des données (pas des moyennes).

Avantage : Plus robuste aux outliers, fonctionne avec n'importe quelle distance.

Mini-batch K-means

Différence : Utilise des sous-échantillons des données à chaque itération.

Avantage : Beaucoup plus rapide pour les grandes données.

Fuzzy C-means

Différence : Attribution douce (comme GMM) mais avec un critère géométrique.

Avantage : Points frontières appartiennent partiellement à plusieurs clusters.

10. Fiche de Révision Express

! Important

En 30 secondes pour l'oral :

1. **K-means** = clustering par minimisation de distance
2. **Deux étapes** : attribution (points $\rightarrow$ centre plus proche) et mise à jour (recalcul des centres)
3. **Problèmes** : choix de K, initialisation, clusters sphériques
4. **Solutions** : k-means++, méthode du coude, standardisation
5. **Parenté** : cas particulier des GMM avec $\rightarrow 0$
6. **Applications** : segmentation, regroupement, réduction de dimension

11. Pour l'Oral : L'Histoire à Raconter

“Imaginez organiser une fête avec des invités dispersés dans un parc. Vous voulez créer K groupes de discussion. Vous placez K animateurs au hasard (initialisation), chaque invité rejoint l'animateur le plus proche (attribution), puis les animateurs se déplacent au centre de leur groupe (mise à jour). On recommence jusqu'à ce que les animateurs ne bougent plus. C'est exactement k-means !”

12. Questions Fréquentes à l'Examen

Q : “Pourquoi k-means est-il sensible à l’initialisation ?” R : “Parce que le critère à minimiser a plusieurs minima locaux. Selon où on commence, on peut rester coincé dans un mauvais minimum.”

Q : “Comment choisir K si on n’a aucune idée ?” R : “Utilisez la méthode du coude pour voir où l’amélioration ralentit, et validez avec le score de silhouette. Testez plusieurs K et regardez ce qui a du sens pour vos données.”

Q : “Quand ne pas utiliser k-means ?” R : “Quand vos clusters ne sont pas sphériques, ou ont des tailles très différentes, ou quand vous avez beaucoup de bruit/outliers.”

13. Le Mot de la Fin

K-means est comme un couteau suisse du clustering : **simple, rapide, utile dans beaucoup de situations**. Mais comme tout outil simple, il faut connaître ses limites. L’essentiel est de toujours : 1. **Préparer** ses données (nettoyer, standardiser) 2. **Choisir K intelligemment** (méthode du coude, silhouette) 3. **Initialiser proprement** (k-means++) 4. **Valider** les résultats (visualisation, scores)

En résumé : K-means est votre premier outil pour explorer la structure de données non étiquetées. Pas le plus sophistiqué, mais souvent le plus pratique pour commencer.