

Table of contents

Document de Révision : Concepts fondamentaux et applications en Data Science	3
Introduction générale	3
Principaux problèmes d'intérêt en Data Science	3
Notations fondamentales	4
Variables aléatoires scalaires	4
Vecteurs aléatoires	5
Distributions de probabilité	5
Variables discrètes	5
Variables continues	6
Moments des distributions	6
Définitions des moments	6
Moments d'ordre supérieur	7
Interprétation intuitive	7
Fonction caractéristique	8
Définition	8
Récupération de la pdf	8
Développement en série de Taylor	8
Estimation empirique des moments	9
Moments de la pdf	9
Moments de la CDF (Cumulative Distribution Function)	9
Estimation empirique des moments de CDF	10
Applications des moments : Analyse d'images	10
Pipeline de traitement	10
Propriétés de la variance et covariance	11
Propriétés fondamentales	11
Covariance	12
Vecteurs aléatoires	12
Notations	12
Exemple : Image comme vecteur	13
Représentations alternatives	13
Règle de chaîne et décomposition	14
Règle de chaîne pour probabilités jointes	14
Cas particulier : 2 variables	14
Indépendance	14
Variables indépendantes	14
Généralisation à N variables	15
Application pratique de l'indépendance	15
Modèles de Markov	15
Modèle de Markov de 1er ordre	15
Modèle de Markov de 2ème ordre	16

Application pratique : Traitement d'images	16
Indépendance conditionnelle	16
Définition	16
Décomposition avec règle de chaîne	17
Représentation graphique	17
Normes vectorielles	17
Norme L_p ou norme p	17
Normes particulières	18
Distances et mesures de similarité	18
Distance euclidienne (L_2)	18
Distance L_1	19
Distance de Hamming	19
Distance attendue pour vecteurs aléatoires	19
Interprétation géométrique des distances	20
Cas d'une image	20
Proximité perceptuelle	20
Lien entre distance et produit scalaire	21
Décomposition de la distance au carré	21
Relation inverse	21
Similarité cosinus	22
Définition géométrique	22
Projection sur un vecteur unitaire	22
Vecteurs orthogonaux et colinéaires	23
Vecteurs orthogonaux	23
Vecteurs colinéaires	23
Extraction de caractéristiques (Feature Extraction)	24
Principe général	24
Techniques clés	24
Information Mining (Fouille de données)	25
Problématique	25
Applications	25
Techniques de base	25
Architectures typiques pour Mining	26
Architecture 1 : Features de classification	26
Architecture 2 : Features d'auto-encodage	26
Architecture 3 : Apprentissage auto-supervisé	26
Reconnaissance et Classification	27
Problèmes de base	27
Domaines d'application	27
Base commune : Test d'hypothèses	27
Test d'hypothèses : Classification binaire	28
Formulation du problème	28
Espaces de représentation	28

Classifieurs pratiques	28
Test d'hypothèses : Détection d'anomalies	29
Formulation asymétrique	29
Classification M-aire	29
Formulation du problème	29
Lien avec le Machine Learning	30
Configurations d'apprentissage	30
Configuration théorique vs pratique	30
Recherche et Identification	30
Problème d'identification	30
Architectures pour Recherche	31
Architecture 1 : Auto-encodage	31
Architecture 2 : Apprentissage auto-supervisé	31
Transmission et Compression	32
Communication numérique	32
Compression sans perte (Lossless)	32
Compression avec perte (Lossy)	33
Concepts mathématiques à maîtriser	33
Probabilités et statistiques	33
Algèbre linéaire	34
Théorie de l'information	34
Questions d'examen types	34
Questions conceptuelles	34
Questions d'applications	35
Développements mathématiques	35

Document de Révision : Concepts fondamentaux et applications en Data Science

Introduction générale

Principaux problèmes d'intérêt en Data Science

Les applications principales de la Data Science couvrent plusieurs domaines :

Extraction de caractéristiques (Feature Extraction)

Extraire des descripteurs pertinents des données brutes

Fouille de données (Information Mining)

Découvrir des patterns cachés dans les données

Reconnaissance et Classification

Identifier et catégoriser des objets ou patterns

Recherche et Identification (Search & Identification)

Retrouver et authentifier des éléments dans des bases de données

Transmission et Compression

Encoder et transmettre l'information efficacement

Sécurité Multimédia

Protéger et authentifier les contenus numériques

Notations fondamentales

Variables aléatoires scalaires

Variable aléatoire scalaire :

- X : variable aléatoire scalaire
- x : réalisation de la variable aléatoire
- X prend des valeurs dans $\mathcal{X}$

Ensembles de valeurs possibles :

Variables discrètes :

- $\mathcal{X} = \{0, 1, 2, \dots\}$ (entiers)
- $\mathcal{X} = \{0, 1\}$ (binaire)
- $\mathcal{X} = \{a, b, \dots, z\}$ (alphabet)
- $\mathcal{X} = \{\text{Janvier, Février, } \dots, \text{Décembre}\}$

Variables continues :

- $\mathcal{X} = \mathbb{R}$ (réels)
- $x_i \in \mathbb{S}$ ou $\mathcal{X}$ (espace général)

Vecteurs aléatoires

Notation vectorielle :

$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_N \end{pmatrix} \quad \text{ou} \quad X = (X_1, X_2, \dots, X_N)$$

Réalisation du vecteur :

$$x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{pmatrix}$$

avec $x_i \in \mathcal{X}$ pour tout i

Convention : Les vecteurs sont notés en gras ou avec une flèche selon le contexte

Distributions de probabilité

Variables discrètes

Fonction de masse de probabilité (pmf) :

$$p_X(x) = \mathbb{P}[X = x]$$

Exemple : Loi binomiale

$$X \sim p_X(x) = B(M, p)$$

$$p_X(k) = \mathbb{P}[X = k] = \binom{M}{k} p^k (1-p)^{M-k}, \quad k = 0, 1, \dots, M$$

Variables continues

Fonction de densité de probabilité (pdf) :

$$f_X(x)$$

avec la propriété $\int_{-\infty}^{+\infty} f_X(x)dx = 1$

Exemple : Loi normale (gaussienne)

$$X \sim f_X(x) = \mathcal{N}(\mu_X, \sigma_X^2)$$

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma_X^2}} \exp\left(-\frac{(x - \mu_X)^2}{2\sigma_X^2}\right)$$

Moments des distributions

Définitions des moments

Pour les variables discrètes :

1er moment (moyenne) :

$$\mu_X = \mathbb{E}_{p_X(x)}[X] = \sum_{i=1}^M x_i p(x_i)$$

2ème moment (variance) :

$$\sigma_X^2 = \text{Var}[X] = \mathbb{E}_{p_X(x)}[(X - \mu_X)^2] = \sum_{i=1}^M (x_i - \mu_X)^2 p(x_i)$$

Pour les variables continues :

1er moment (moyenne) :

$$\mu_X = \mathbb{E}_{f_X(x)}[X] = \int_{x \in \mathcal{X}} x f_X(x) dx$$

2ème moment (variance) :

$$\sigma_X^2 = \text{Var}[X] = \mathbb{E}_{f_X(x)}[(X - \mu_X)^2] = \int_{x \in \mathcal{X}} (x - \mu_X)^2 f_X(x) dx$$

Moments d'ordre supérieur

3ème moment (skewness - asymétrie) :

$$\frac{\mathbb{E}_{p_X(x)}[(X - \mu_X)^3]}{\sigma_X^3} \quad \text{ou} \quad \frac{\mathbb{E}_{f_X(x)}[(X - \mu_X)^3]}{\sigma_X^3}$$

4ème moment (kurtosis - aplatissement) :

$$\frac{\mathbb{E}_{p_X(x)}[(X - \mu_X)^4]}{\sigma_X^4} \quad \text{ou} \quad \frac{\mathbb{E}_{f_X(x)}[(X - \mu_X)^4]}{\sigma_X^4}$$

Interprétation intuitive

Moyenne (μ_X) :

Centre de la distribution

Variance (σ_X^2) :

Dispersion autour de la moyenne

Skewness :

Asymétrie de la distribution (positive $\rightarrow$ queue à droite, négative $\rightarrow$ queue à gauche)

Kurtosis :

“Épaisseur” des queues de distribution (> 3 : queues épaisses, < 3 : queues fines)

Principe général : Étant donné une pmf/pdf, on peut calculer les moments (pas pour toutes les distributions)

Fonction caractéristique

Définition

Fonction caractéristique d'une pdf :

$$\Phi(t) = \int_{-\infty}^{+\infty} f(x)e^{jtx} dx = \mathbb{E}_{f(x)}[e^{jtX}]$$

où $j = \sqrt{-1}$

Fonction génératrice des moments :

$$M(t) = \mathbb{E}_{f(x)}[e^{tX}]$$

Récupération de la pdf

La pdf peut être récupérée par transformée inverse :

$$f(x) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} \Phi(t)e^{-jtx} dt$$

Développement en série de Taylor

Pour la fonction caractéristique :

$$\Phi(t) = \mathbb{E}_{f(x)}[\exp(jtX)] = 1 + jt\mathbb{E}_{f(x)}[X] - \frac{t^2}{2!}\mathbb{E}_{f(x)}[X^2] + \dots + \frac{(jt)^n}{n!}\mathbb{E}_{f(x)}[X^n]$$

Pour la fonction génératrice :

$$M(t) = \mathbb{E}_{f(x)}[\exp(tX)] = 1 + t\mathbb{E}_{f(x)}[X] + \frac{t^2}{2!}\mathbb{E}_{f(x)}[X^2] + \dots + \frac{t^n}{n!}\mathbb{E}_{f(x)}[X^n]$$

Rappel : $\exp(tX) = \sum_{n=0}^{\infty} \frac{(t)^n \cdot X^n}{n!}$

Point clé : Les quatre premiers moments définissent respectivement la moyenne, variance, skewness et kurtosis de la pdf $f(x)$

Estimation empirique des moments

Moments de la pdf

Données :

Séquence i.i.d. $x = (x_1, \dots, x_N)$ tirée de $f(x)$

Estimation du n-ième moment empirique :

$$\hat{m}_n = \frac{1}{N} \sum_{i=1}^N x_i^n, \quad n \geq 1$$

Moments théoriques :

$$m_n = \mathbb{E}[X^n] = \int_{-\infty}^{+\infty} f(x) x^n dx$$

$\hat{m}_n$ est une **estimation non biaisée** des vrais moments de la pdf

Moments de la CDF (Cumulative Distribution Function)

Définition des moments de la CDF :

$$M_n = \int_{-\infty}^{+\infty} \Phi(t) t^n dt$$

Lien avec la pdf :

$$M_n = j^n 2\pi \frac{d^n}{dx^n} f(x) \Big|_{x=0}$$

Estimation empirique des moments de CDF

Étape 1 : Estimer l'histogramme empirique à M bins : $\{h(m)\}_{m=0}^{M-1}$

Étape 2 : Estimer la CDF à K points avec $K = 2^{\lceil \log_2 M \rceil}$:

$$\Phi(k) = \sum_{m=0}^{M-1} h(m) \exp \left\{ -j \frac{2\pi mk}{K} \right\}$$

Étape 3 : Calcul inverse par transformée de Fourier :

$$h(m) = \frac{1}{K} \sum_{k=0}^{K-1} \Phi(k) \exp \left\{ j \frac{2\pi mk}{K} \right\}, \quad 0 \leq m \leq M-1$$

Étape 4 : Calculer les moments empiriques de la CDF :

$$\hat{M}'_n = \sum_{k=0}^{K/2-1} |\Phi(k)| k^n$$

Forme alternative (borne supérieure) :

$$\hat{M}_n = \sum_{k=0}^{K-1} \Phi(k) \sin^n \left(\frac{\pi k}{K} \right)$$

Note : La transformée de Fourier fonctionne dans les deux sens (pdf → CDF)

Applications des moments : Analyse d'images

Pipeline de traitement

Transformation par ondelettes (DWT) :

Image → DWT → Coefficients d'ondelettes → Calcul des moments (pdf/CDF)

Applications pratiques :

Détection d'outliers :

Identifier des images anormales par analyse des moments

Détection de fausses images (Fake detection) :

Distinguer images authentiques vs manipulées

Stéganalyse :

Détecter des messages secrets cachés dans les images

Principe : Les moments statistiques capturent des propriétés fines de la distribution qui changent en cas de manipulation

Propriétés de la variance et covariance**Propriétés fondamentales**

Soit X et Y des variables aléatoires, a, b, c des constantes.

Décomposition de la variance :

$$\text{Var}[X] = \mathbb{E}[X - \mathbb{E}[X]]^2 = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

Bornes :

$$0 \leq \text{Var}[X] \leq \mathbb{E}[X^2]$$

Variance d'un multiple :

$$\text{Var}[cX] = c^2 \text{Var}[X]$$

Variance d'une combinaison linéaire :

$$\text{Var}[aX + bY] = a^2 \text{Var}[X] + 2ab \text{Cov}[X, Y] + b^2 \text{Var}[Y]$$

Covariance

Définition :

$$\text{Cov}[X, Y] = \mathbb{E}_{p(x,y)}[(X - \mu_X)(Y - \mu_Y)]$$

Forme développée (variables discrètes) :

$$\text{Cov}[X, Y] = \sum_{(x,y) \in \mathcal{S}_{X,Y}} p(x,y)(x - \mu_X)(y - \mu_Y)$$

Forme alternative :

$$\text{Cov}[X, Y] = \mathbb{E}_{p(x,y)}[XY] - \mu_X \mu_Y = \sigma_{XY}$$

Vecteurs aléatoires

Notations

Vecteur aléatoire :

$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_N \end{pmatrix}$$

où chaque X_i est une variable aléatoire avec sa distribution $p_{X_i}(x_i)$ ou $f_{X_i}(x_i)$

Distribution jointe :

- **pmf jointe** : $p_X(x) = p_X(x_1, x_2, \dots, x_N)$
- **pdf jointe** : $f_X(x) = f_X(x_1, x_2, \dots, x_N)$

Exemple : Image comme vecteur

Lecture en zig-zag :

Une image $n \times m$ est lue en zig-zag pour former un vecteur de dimension $N = n \times m$

$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_N \end{pmatrix}$$

Complexité : Pour une image moderne de taille 1000×1000 , on a $N = 1,000,000$ pixels. La distribution jointe décrit toutes les relations par paires, triplets, etc.

Représentations alternatives

Lecture par lignes (matrice) :

$$X = \begin{pmatrix} | & | & & | \\ x_1 & x_2 & \cdots & x_m \\ | & | & & | \end{pmatrix}$$

de dimension $n \times m$

Image comme colonne dans une base de données :

$$X = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{pmatrix}$$

où chaque x_i représente une image entière

Règle de chaîne et décomposition

Règle de chaîne pour probabilités jointes

Distribution jointe complète :

$$p_X(x) = p(x_1, x_2, \dots, x_N)$$

Décomposition par règle de chaîne :

$$p(x_1, x_2, \dots, x_N) = p(x_1) \cdot p(x_2|x_1) \cdot p(x_3|x_2, x_1) \cdots p(x_N|x_{N-1}, \dots, x_2, x_1)$$

Forme générale :

$$p(x_1, x_2, \dots, x_N) = \prod_{i=1}^N p(x_i|x_{i-1}, \dots, x_2, x_1)$$

Cas particulier : 2 variables

$$p(x_1, x_2) = p(x_1)p(x_2|x_1) = p(x_2)p(x_1|x_2)$$

Conséquence (règle de Bayes) :

$$p(x_2|x_1) = \frac{p(x_2)p(x_1|x_2)}{p(x_1)}$$

Indépendance

Variables indépendantes

Définition :

X_1 et X_2 sont **indépendantes** (noté $X_1 \perp X_2$) si :

$$p(x_1, x_2) = p(x_1) \cdot p(x_2)$$

Généralisation à N variables

Variables indépendantes et identiquement distribuées (i.i.d.) :

$$p_X(x_1, x_2, \dots, x_N) = p_X(x_1) \cdot p_X(x_2) \cdots p_X(x_N) = \prod_{i=1}^N p_X(x_i)$$

Application pratique de l'indépendance

Simplification majeure :

$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_N \end{pmatrix} \quad \text{avec} \quad \begin{cases} X_1 \sim p(x_1) \\ X_2 \sim p(x_2) \\ \vdots \\ X_N \sim p(x_N) \end{cases}$$

Au lieu de modéliser $p_X(x_1, x_2, \dots, x_N)$ (complexité exponentielle), on modélise N distributions univariées indépendantes.

Avantage : Réduction drastique de la complexité

Modèles de Markov

Modèle de Markov de 1er ordre

Hypothèse markovienne :

La dépendance est limitée à **un élément du passé** :

$$p(x_i | x_{i-1}, x_{i-2}, \dots, x_1) \stackrel{\text{Markov 1}}{\Rightarrow} p(x_i | x_{i-1})$$

Distribution jointe sous Markov 1 :

$$p(x_1, x_2, \dots, x_N) \stackrel{\text{Markov 1}}{\Rightarrow} p(x_1) \prod_{i=2}^N p(x_i | x_{i-1})$$

Simplification : La modélisation d'une pmf/pdf complexe est réduite à la définition de distributions conditionnelles par paires

Modèle de Markov de 2ème ordre

Hypothèse markovienne d'ordre 2 :

La dépendance est limitée à **deux éléments du passé** :

$$p(x_i | x_{i-1}, x_{i-2}, \dots, x_1) \stackrel{\text{Markov 2}}{\Rightarrow} p(x_i | x_{i-1}, x_{i-2})$$

Distribution jointe sous Markov 2 :

$$p(x_1, x_2, \dots, x_N) \stackrel{\text{Markov 2}}{\Rightarrow} p(x_1) \cdot p(x_2 | x_1) \prod_{i=3}^N p(x_i | x_{i-1}, x_{i-2})$$

Application pratique : Traitement d'images

Modèle Markovien pour images :

$$X = \begin{pmatrix} \vdots \\ X_{i-2} \\ X_{i-1} \\ X_i \\ \vdots \end{pmatrix} \Rightarrow p(x_i | x_{i-1}, x_{i-2})$$

Chaque pixel X_i dépend conditionnellement des deux pixels précédents X_{i-1} et X_{i-2}

Application : Modélisation de textures, compression d'images, génération d'images

Indépendance conditionnelle

Définition

Les variables aléatoires X_1 et X_3 sont **conditionnellement indépendantes** étant donné X_2 si :

$$p(x_1, x_3 | x_2) = p(x_1 | x_2) \cdot p(x_3 | x_2)$$


Décomposition avec règle de chaîne

$$p(x_1, x_2, x_3) = p(x_2) \cdot p(x_1, x_3 | x_2)$$

Si $X_1 \perp X_3 | X_2$:

$$p(x_1, x_2, x_3) = p(x_2) \cdot p(x_1 | x_2) \cdot p(x_3 | x_2)$$

Représentation graphique



X_2 est un “parent” commun de X_1 et X_3 , qui deviennent indépendants conditionnellement à X_2

Normes vectorielles

Norme L_p ou norme p

Définition générale :

$$\|x\|_p = \left(\sum_{i=1}^N |x_i|^p \right)^{1/p}$$

Normes particulières

Norme L_1 (norme Manhattan) :

$$\|x\|_1 = \sum_{i=1}^N |x_i| = |x_1| + |x_2| + \dots + |x_N|$$

Norme L_2 (norme euclidienne) :

$$\|x\|_2 = \sqrt{\sum_{i=1}^N x_i^2} = \sqrt{x_1^2 + x_2^2 + \dots + x_N^2}$$

Norme L_∞ (norme maximum) :

$$\|x\|_\infty = \max\{|x_1|, |x_2|, \dots, |x_N|\}$$

Norme unitaire :

$$\|x\| = \frac{x}{\|x\|_2}$$

Donne un vecteur de longueur 1 dans la même direction

Distances et mesures de similarité

Distance euclidienne (L_2)

Définition :

$$d_2(x, y) = \|x - y\|_2 = \sqrt{\sum_{i=1}^N (x_i - y_i)^2}$$

Distance L_1

Définition :

$$d_1(x, y) = \|x - y\|_1 = \sum_{i=1}^N |x_i - y_i|$$

Distance de Hamming

Définition :

$$d_H(x, y) = \|x \oplus y\| = \sum_{i=1}^N \mathbb{1}\{x_i \neq y_i\}$$

où la fonction indicatrice est :

$$\mathbb{1}\{x_i \neq y_i\} = \begin{cases} 0 & \text{si } x_i = y_i \\ 1 & \text{si } x_i \neq y_i \end{cases}$$

Distance attendue pour vecteurs aléatoires

Définition :

Pour deux vecteurs aléatoires avec pdf $f(x)$:

$$D = \mathbb{E}_{f(x)}[d(X, Y)]$$

où

$$d(X, Y) = \frac{1}{N} \sum_{i=1}^N d(X_i, Y_i)$$

Interprétation géométrique des distances

Cas d'une image

Pour $n = 2$ dimensions, une image $n \times m$ peut être représentée comme :

$$x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

Distance euclidienne entre deux images :

$$d_2(x_1, x_2) = \|x_1 - x_2\|_2 = \sqrt{\sum_{i=1}^N (x_{1i} - x_{2i})^2}$$

représente la longueur du vecteur différence $x_1 - x_2$

Proximité perceptuelle

Images perceptuellement proches :

$$\|x_1 - x_2\|_2 \text{ petit} \Rightarrow \text{Images visuellement similaires}$$

Images perceptuellement différentes :

$$\|x_1 - x_2\|_2 \text{ grand} \Rightarrow \text{Images visuellement différentes}$$

Limitation : La distance euclidienne ne capture pas toujours la similarité perceptuelle humaine

Lien entre distance et produit scalaire

Décomposition de la distance au carré

$$\|x_1 - x_2\|_2^2 = \|x_1\|_2^2 - 2x_1^T x_2 + \|x_2\|_2^2$$

Produit scalaire (inner product) :

$$x^T y = y^T x \in \mathbb{R}$$

$$x^T y = \begin{pmatrix} x_1 & x_2 & \cdots & x_n \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \sum_{i=1}^n x_i y_i$$

Relation inverse

Distance petite Produit scalaire grand :

$$\|x_1 - x_2\|_2 \text{ petit} \quad \Rightarrow \quad x_1^T x_2 \text{ grand}$$

Distance grande Produit scalaire petit :

$$\|x_1 - x_2\|_2 \text{ grand} \quad \Rightarrow \quad x_1^T x_2 \text{ petit}$$

Interprétation géométrique : Plus deux vecteurs pointent dans la même direction, plus leur produit scalaire est grand et leur distance est petite

Similarité cosinus

Définition géométrique

Angle entre deux vecteurs :

$$x_1^T x_2 = \|x_1\|_2 \|x_2\|_2 \cos \theta$$

Similarité cosinus :

$$\cos \theta = \frac{x_1^T x_2}{\|x_1\|_2 \|x_2\|_2}$$

Projection sur un vecteur unitaire

Vecteur unitaire (direction) :

$$\hat{x}_2 = \frac{x_2}{\|x_2\|_2}$$

Projection de x_1 sur $\hat{x}_2$:

$$x_1^T \hat{x}_2 = x_1^T \frac{x_2}{\|x_2\|_2} = \frac{x_1^T x_2}{\|x_2\|_2}$$

Longueur de la projection :

$$\|x_1\|_2 \cos \theta = x_1^T \hat{x}_2 = \frac{x_1^T x_2}{\|x_2\|_2}$$

Vecteurs orthogonaux et colinéaires

Vecteurs orthogonaux

Condition d'orthogonalité ($\theta = 90^\circ$) :

$$x_1^T x_2 = 0 \quad \Leftrightarrow \quad \|x_1\|_2 \|x_2\|_2 \cos(90^\circ) = 0$$

Distance entre vecteurs orthogonaux :

$$\|x_1 - x_2\|_2^2 = \|x_1\|_2^2 + \|x_2\|_2^2 - 2x_1^T x_2 = \|x_1\|_2^2 + \|x_2\|_2^2$$

(Théorème de Pythagore)

Vecteurs colinéaires

Condition de colinéarité ($\theta = 0^\circ$) :

$$x_1^T x_2 = \max \quad \Leftrightarrow \quad \|x_1\|_2 \|x_2\|_2 \cos(0^\circ) = \|x_1\|_2 \|x_2\|_2$$

Si de plus $\|x_1\|_2 = \|x_2\|_2$:

$$\|x_1 - x_2\|_2^2 = \|x_1\|_2^2 + \|x_2\|_2^2 - 2\|x_1\|_2 \|x_2\|_2 = 0$$

$$\Rightarrow x_1 = x_2$$

Extraction de caractéristiques (Feature Extraction)

Principe général

Objectif :

Extraire des descripteurs/empreintes caractéristiques à partir d'une image originale avec distribution $p_X(x)$

Types d'approches :

Hand-crafted (faites à la main) :

Conçues sous des contraintes strictes de complexité/mémoire

- Descripteurs SIFT, SURF, HOG
- Moments statistiques
- Filtres de Gabor

Learned (appries) :

Appries directement à partir des données

- Features de réseaux de neurones profonds
- Embeddings appris

Techniques clés

PCA/ICA :

Analyse en composantes principales/indépendantes

Réduction de dimensionnalité :

Projeter dans un espace de dimension réduite

Transformées de décorrélation :

DCT, DWT (ondelettes), etc.

Quantification vectorielle (k-means) :

Clustering et représentation par centres

Information Mining (Fouille de données)

Problématique

Objectif :

L'élément (ou caractéristique) commun est **inconnu** et doit être **découvert** dans la collection ou base de données

Applications

Images/Multimédia :

Découvrir des patterns visuels récurrents

Biomarqueurs :

Identifier des marqueurs biologiques dans des données médicales

Analyse de marché :

Détecter des tendances et segments de clientèle

Techniques de base

Classification :

Assigner des catégories aux données

Clustering :


Regrouper des données similaires

Prédiction :

Prédire des valeurs futures ou manquantes

Architectures typiques pour Mining

Architecture 1 : Features de classification



Principe :

Les features sont extraites puis utilisées pour la classification

Architecture 2 : Features d'auto-encodage



Principe :

Les features sont prises du goulot d'étranglement (bottleneck) d'un auto-encodeur

Architecture 3 : Apprentissage auto-supervisé



Principe :

Les features sont apprises par apprentissage contrastif (contrastive learning)

Reconnaissance et Classification

Problèmes de base

Classification binaire (2 classes) :

Distinguer entre deux hypothèses H_0 et H_1

Classification M-aire (M classes) :

Distinguer entre M hypothèses $H_0, H_1, \dots, H_{M-1}$

Domaines d'application

Reconnaissance de patterns :

Reconnaître des objets, visages, gestes

Récupération d'information (Information Retrieval) :

Rechercher des documents pertinents

Classification :

Catégoriser automatiquement des données

Machine Learning :

Apprendre à partir d'exemples

Identification/Authentification :

Vérifier l'identité (biométrie, etc.)

Base commune : Test d'hypothèses

Tous ces problèmes se ramènent au **test d'hypothèses** probabiliste

Test d'hypothèses : Classification binaire

Formulation du problème

Deux hypothèses :

$$\begin{cases} H_0 : Y \sim f_Y(y|H_0) \\ H_1 : Y \sim f_Y(y|H_1) \end{cases}$$

Données :

Les pdfs des classes sont données

Décision :

Quelle classe est observée ?

Espaces de représentation

Espace des distributions :

Mesurer la **proximité des pdfs** (sous hypothèses spécifiques)

Espace des réalisations :

Mesurer la **proximité des vecteurs** observés

Classifieurs pratiques

k-NN (k-Nearest Neighbors) :

Classification basée sur les k plus proches voisins

Classifieur profond (Deep classifier) :

Réseau de neurones pour apprendre la frontière de décision

Test d'hypothèses : Détection d'anomalies

Formulation asymétrique

Hypothèse nulle (classe normale) :

$$H_0 : Y \sim \text{any pdf (inconnue)}$$

Hypothèse alternative (classe cible) :

$$H_1 : Y \sim f_Y(y|H_1)$$

Objectif :

Déterminer dans quelle **région** se situe l'observation

Application :

Détection d'outliers, détection de fraude, détection d'intrusion

Classification M-aire

Formulation du problème

M hypothèses :

$$\begin{cases} H_0 : Y \sim f_Y(y|H_0) \\ H_1 : Y \sim f_Y(y|H_1) \\ \vdots \\ H_{M-1} : Y \sim f_Y(y|H_{M-1}) \end{cases}$$

Données :

Les pdfs de toutes les classes sont données

Décision :

Quelle classe parmi les M est observée ?

Problème principal :

Séparation efficace des classes dans l'espace des features

Lien avec le Machine Learning

Configurations d'apprentissage

Apprentissage supervisé (Supervised learning) :

- Données d'entraînement **étiquetées** fournies
- **Objectif** : Faire des prédictions (estimer les pdfs) basées sur des exemples

Apprentissage non supervisé (Unsupervised learning) :

- Données d'entraînement **non étiquetées**
- **Objectif** : Révéler la structure dans les données observées (data mining)

Apprentissage semi-supervisé (Semi-supervised learning) :

- Nombre **limité** de données étiquetées + beaucoup de données non étiquetées
- **Objectif** : Améliorer les prédictions en exploitant les exemples non étiquetés

Configuration théorique vs pratique

Configuration théorique (IT - Information Theory) :

Toutes les pdfs des classes sont **connues**

Configuration pratique (Machine Learning) :

Les pdfs ne sont **pas connues** mais peuvent être **estimées** à partir des données

Recherche et Identification

Problème d'identification

Configuration :

- **Codebook de features** : Base de données de M éléments de référence
- **Probe features** : Requête à identifier

Question fondamentale :

Combien d'images peuvent être identifiées de manière **non ambiguë** ?

$$M(P_e \rightarrow 0)$$

où P_e est la probabilité d'erreur

Réponse :

M doit être tel que les distorsions ne causent **aucune ambiguïté**

Conséquence :

- Probabilité de fausse acceptation (false acceptance)
 - Probabilité de décodage incorrect
-

Architectures pour Recherche

Architecture 1 : Auto-encodage

Phase d'entraînement :



Phase d'extraction de features :

Les features du bottleneck sont utilisées comme représentation compacte

Architecture 2 : Apprentissage auto-supervisé

Phase d'entraînement :



Phase d'extraction :

Les features apprises sont utilisées pour la recherche par similarité

Principe : Apprendre des représentations telles que les éléments similaires sont proches dans l'espace des features

Transmission et Compression

Communication numérique

Canaux de transmission :

- Câble optique
- WiFi/3G/4G/5G
- Systèmes fixes/mobiles
- Systèmes de diffusion/accès multiple

Compression sans perte (Lossless)

Configuration :

$$X \xrightarrow{\text{Encoder}} R \xrightarrow{\text{Decoder}} \hat{X}$$

Propriété :

$$\hat{X} = X \quad \Rightarrow \quad D = \mathbb{E}[\|X - \hat{X}\|^2] = 0$$

Taille compressée :

Par exemple : 500 Kbytes (image compressée vs originale)

Usages :

Documents texte, images médicales, données scientifiques

Compression avec perte (Lossy)

Configuration :

$$X \xrightarrow{\text{Encoder}} R \xrightarrow{\text{Decoder}} \hat{X}$$

Propriété :

$$\hat{X} \neq X \Rightarrow D = \mathbb{E}[\|X - \hat{X}\|^2] \neq 0$$

Distorsion :

Perte d'information contrôlée et acceptable

Taille compressée :

Par exemple : 64 Kbytes (forte compression)

Usages :

Images, vidéos, audio pour consommation humaine

Concepts mathématiques à maîtriser

Probabilités et statistiques

Fondamentaux :

- Variables aléatoires (discrètes, continues)
- Distributions (pmf, pdf, CDF)
- Moments (moyenne, variance, skewness, kurtosis)
- Fonction caractéristique et fonction génératrice

Concepts avancés :

- Indépendance et indépendance conditionnelle
- Modèles de Markov
- Règle de chaîne
- Covariance et corrélation

Algèbre linéaire

Vecteurs et matrices :

- Normes vectorielles (L_1 , L_2 , L_∞)
- Produit scalaire
- Projection
- Orthogonalité

Mesures de distance :

- Distance euclidienne
- Distance de Hamming
- Similarité cosinus

Théorie de l'information

Concepts de base :

- Entropie
 - Information mutuelle
 - Divergence KL
-

Questions d'examen types

Questions conceptuelles

Notations et définitions :

- Différence entre variable aléatoire et réalisation
- Différence entre pmf et pdf
- Qu'est-ce qu'un moment d'une distribution ?

Indépendance et dépendance :

- Définir l'indépendance de variables aléatoires
- Qu'est-ce qu'un modèle de Markov ?
- Différence entre indépendance et indépendance conditionnelle

Distances et similarités :

- Relation entre distance euclidienne et produit scalaire
- Qu'est-ce que la similarité cosinus ?
- Interprétation géométrique de l'orthogonalité

Questions d'applications

Extraction de features :

- Différence entre features hand-crafted et learned
- Rôle de la PCA dans l'extraction de features
- Applications des moments statistiques

Classification :

- Différence entre classification binaire et M-aire
- Lien entre test d'hypothèses et classification
- Différence entre apprentissage supervisé et non supervisé

Compression :

- Différence entre compression avec et sans perte
- Notion de distorsion
- Trade-off rate-distorsion

Développements mathématiques

Moments :

- Calculer les moments empiriques d'une distribution
- Développement en série de Taylor de la fonction caractéristique
- Relation entre moments de pdf et CDF

Probabilités :

- Appliquer la règle de chaîne pour décomposer une distribution jointe
- Démontrer des propriétés de la variance et covariance
- Simplification sous hypothèse d'indépendance