

Table of contents

Document de Révision : Fondamentaux de la Théorie de l'Information pour la Data

Science	4
Introduction générale	4
Contexte de la théorie de l'information	4
Rappel : Règle de chaîne pour probabilités	4
Règle de chaîne générale	4
Cas particulier : 2 variables	4
Variables indépendantes	5
Exemples de décomposition par règle de chaîne	5
Trois variables : Différentes décompositions	5
Entropie (Entropy)	6
Définition formelle	6
Interprétation	7
Espérance et entropie	7
Entropie d'une variable binaire	7
Cas binaire : Variable de Bernoulli	7
Formule de l'entropie binaire	8
Propriétés de $H(\theta)$	8
Application : Compression sans perte	9
Schéma de compression	9
Complexité de compression pour images	9
Complexité computationnelle	10
Taux de compression	10
Définition pratique	10
Taux de compression réels	10
Lien avec la théorie de l'information : Assignment optimale de codes	11
Principe de base	11
Lien entre probabilité et longueur de code	11
Principe du codage à longueur variable	12
Exemple : Image à 8 niveaux	12
Table de codage	12
Calculs	12
Observations	13
Codes sources pratiques : Codage de Huffman	13
Principe du codage de Huffman	13
Hypothèses	13
Algorithme de Huffman	14
Exemple de construction	14
Code préfixe	16
Définition	16

Importance du code préfixe	16
Exemple comparatif	16
Entropie jointe (Joint Entropy)	17
Définition	17
Propriété de symétrie	17
Entropie conditionnelle (Conditional Entropy)	17
Définition	17
Entropie conditionnelle pour une valeur fixée	18
Développement complet	18
Asymétrie	18
Propriétés de l'entropie	18
Propriété 1 : Non-négativité	18
Propriété 2 : Règle de chaîne pour l'entropie	19
Application à un vecteur d'image	20
Propriété 3 : Augmentation de l'entropie par ajout de variables	21
Propriété 4 : Conditionnement réduit l'entropie	21
Propriété 5 : Entropie maximale pour distribution uniforme	22
Divergence de Kullback-Leibler (KLD)	23
Définition	23
Conventions	23
Propriétés fondamentales	23
Interprétation pratique de la KLD	24
Problème de codage avec mauvaise distribution	24
Décomposition de la longueur moyenne	24
Interprétation	25
Exemple numérique de KLD	25
Configuration	25
Formules	25
Calcul avec valeurs spécifiques	26
Cross-Entropy (Entropie croisée)	26
Définition	26
Lien avec la KLD	26
Propriété d'optimisation	27
Information mutuelle (Mutual Information)	27
Définition	27
Forme alternative	27
Propriétés fondamentales	28
Information mutuelle via KL-divergence	28
Formulation en termes de KLD	28
Interprétation	28
Formes conditionnelles	29
Relations entre information mutuelle et entropie	29
Relations fondamentales	29

Diagramme de Venn des entropies	30
Information mutuelle conditionnelle	30
Définition	30
Démonstration	31
Propriétés de l'information mutuelle	31
Information mutuelle conditionnelle	31
Règle de chaîne pour l'information mutuelle	31
Application : Pixels d'image et label	32
Décomposition complexe	33
Inégalité de traitement des données	33
Chaîne de Markov	33
Inégalité fondamentale	34
Interprétation	34
Démonstration de l'inégalité	34
Variables continues : Entropie différentielle	35
Motivation	35
Décomposition	36
Problème avec la limite	36
Définition de l'entropie différentielle	36
Définition formelle	36
Entropie différentielle d'une gaussienne	37
Variable gaussienne	37
Démonstration	37
Propriétés de l'entropie différentielle	38
Propriété 1 : Invariance par translation	38
Propriété 2 : Effet de la mise à l'échelle	38
Concepts mathématiques à maîtriser	39
Théorie de l'information	39
Probabilités	39
Codage et compression	40
Questions d'examen types	40
Questions conceptuelles	40
Questions techniques	40
Démonstrations mathématiques	41
Applications en Machine Learning	41
Fonctions de perte	41
Sélection de features	42
Régularisation	42
Résumé des formules clés	42
Entropie	42
Relations	43
Information mutuelle	43
KLD et Cross-entropy	43

Document de Révision : Fondamentaux de la Théorie de l'Information pour la Data Science

Introduction générale

Contexte de la théorie de l'information

La **théorie de l'information** fournit un cadre mathématique rigoureux pour quantifier l'information, l'incertitude et la dépendance entre variables aléatoires.

Applications en Data Science :

- Compression de données
 - Apprentissage automatique
 - Sélection de features
 - Mesure de similarité entre distributions
 - Optimisation de réseaux de neurones
-

Rappel : Règle de chaîne pour probabilités

Règle de chaîne générale

Pour N variables aléatoires :

$$p(x_1, x_2, \dots, x_n) = p(x_1) \cdot p(x_2|x_1) \cdot p(x_3|x_2, x_1) \cdots p(x_n|x_{n-1}, \dots, x_2, x_1)$$

Forme compacte :

$$p(x_1, x_2, \dots, x_n) = \prod_{i=1}^n p(x_i|x_{i-1}, \dots, x_2, x_1)$$

Cas particulier : 2 variables

$$p(x_1, x_2) = p(x_1)p(x_2|x_1) = p(x_2)p(x_1|x_2)$$

Variables indépendantes

Définition :

Si les variables sont **indépendantes** : $X_1 \perp X_2$

$$p(x_1, x_2) = p(x_1) \cdot p(x_2)$$

Généralisation à N variables i.i.d. :

$$p(x_1, x_2, \dots, x_n) = \prod_{i=1}^n p(x_i) = [p(x)]^n$$

Exemples de décomposition par règle de chaîne

Trois variables : Différentes décompositions

Chaîne linéaire :




$$p(x, y, z) = p(x) \cdot p(y|x) \cdot p(z|x, y)$$

Indépendance complète :

$$p(x, y, z) = p(x) \cdot p(y) \cdot p(z)$$

Indépendance conditionnelle (Y comme parent commun) :



$$p(x, y, z) = p(y) \cdot p(x|y) \cdot p(z|y)$$

Structure alternative :

$$p(x, y, z) = p(z) \cdot p(y|z) \cdot p(x|y, z)$$

$$p(x, y, z) = p(z|x, y) \cdot p(x) \cdot p(y)$$

$$p(x, y, z) = p(z) \cdot p(x|z) \cdot p(y|z)$$

Entropie (Entropy)

Définition formelle

Entropie d'une variable aléatoire discrète :

Soit X une variable aléatoire discrète prenant ses valeurs dans $\mathcal{X} = \{x_1, x_2, \dots, x_n\}$

$$H(X) = - \sum_{x \in \mathcal{X}} p_X(x) \log_2 p_X(x) = -\mathbb{E}_{p_X}[\log p_X(x)]$$

Unités :

- **Base 2** ($\alpha = 2$) : mesure en **bits**
- **Base e** ($\alpha = e$) : mesure en **nats**

On note parfois $H_\alpha(X)$ pour spécifier la base

Interprétation

L'entropie mesure :

- L'**incertitude** d'une variable aléatoire discrète
- Le **caractère aléatoire** (randomness)
- Le nombre **moyen de bits** nécessaires pour encoder la variable

Point important : $H(X)$ dépend uniquement de la **distribution** de X , pas des valeurs particulières prises

Notations équivalentes :

- $H(X)$
- $H(p)$
- $H(p(x))$

Espérance et entropie

Rappel de l'espérance :

$$\mathbb{E}_{p_X}[g(X)] = \sum_{x \in \mathcal{X}} p_X(x)g(x)$$

Entropie comme espérance :

$$H(X) = \mathbb{E}_{p_X}[-\log p_X(x)]$$

Entropie d'une variable binaire

Cas binaire : Variable de Bernoulli

Variable binaire :

$$X \in \mathcal{X} = \{0, 1\}$$

$$\mathbb{P}[X = 0] = 1 - \theta$$

$$\mathbb{P}[X = 1] = \theta$$

Forme compacte :

$$\mathbb{P}[X = x] = \theta^x (1 - \theta)^{1-x}$$

Formule de l'entropie binaire

$$H(X) = -\theta \log_2 \theta - (1 - \theta) \log_2 (1 - \theta) := H(\theta) \text{ ou } H_2(\theta)$$

Propriétés de $H(\theta)$

Symétrie :

La fonction est **symétrique** par rapport à $\theta = 0.5$

$$H(\theta) = H(1 - \theta)$$

Maximum :

Le maximum est atteint en $\theta = 0.5$:

$$\max_{\theta} H(\theta) = H(0.5) = 1 \text{ bit}$$

Principe fondamental : L'entropie est **maximale** si les symboles sont **équiprobables**

Exemples numériques :

- $\theta = 0.11$: $H(0.11) \approx 0.5$ bit
 - $\theta = 0.5$: $H(0.5) = 1$ bit
 - $\theta = 0.89$: $H(0.89) \approx 0.5$ bit
-

Application : Compression sans perte

Schéma de compression

Compression sans perte (Lossless) :

$$X \xrightarrow{\text{Encodeur}} R \xrightarrow{\text{Décodeur}} \hat{X}$$

Propriété :

$$\hat{X} = X \Rightarrow D = \mathbb{E}[\|X - \hat{X}\|^2] = 0$$

Compression avec perte (Lossy) :

$$\hat{X} \neq X \Rightarrow D = \mathbb{E}[\|X - \hat{X}\|^2] \neq 0$$

Complexité de compression pour images

Problématique :

Soit une image représentée comme vecteur $x \sim p_x(x) = p_x(x_1, x_2, \dots, x_n)$

Connaissance de la distribution source :

La **pdf/pmf jointe** est nécessaire pour la compression optimale

Défis :

1. Modélisation : la pdf multidimensionnelle est **très complexe**
2. La vraie pdf est **inconnue**
3. Simplification courante : considérer les pixels **indépendamment** (mais cela **augmente l'entropie**)
4. Le codage indépendant des symboles n'est **pas optimal** selon la théorie rate-distorsion de Shannon qui suggère un **codage par blocs**

Solution intermédiaire :

Utiliser un **codage par sous-blocs** (comme dans JPEG)

Complexité computationnelle

Codage par blocs de Shannon :

Complexité **exponentielle** en fonction de la longueur du bloc

Méthodes pratiques :

Réduire la taille des blocs jusqu'à un symbole/pixel (sous-optimal mais **complexité réduite**)

Taux de compression

Définition pratique

Ratio de compression (Compression Ratio) :

$$CR = \frac{\text{Nombre de bits avant}}{\text{Nombre de bits après}}$$

Taux de compression réels

Pour images réelles :

Compression sans perte :

$$CR \approx 2$$

Compression avec perte :

- **JPEG** : $CR = 10$ à 50
 - **JPEG 2000** : CR jusqu'à 150
-

Lien avec la théorie de l'information : Assignment optimale de codes

Principe de base

Histogramme et indépendance :

L'histogramme est **trompeur** mais supposons que les pixels de l'image sont **discrets** et **indépendants**

Entropie pour variables discrètes :

$$H(X) = - \sum_{i=0}^{L-1} p_i \log p_i = \ell_{av}$$

où ℓ_{av} est la **longueur moyenne** nécessaire

Probabilité d'observer une intensité particulière :

$$p_i = \mathbb{P}\{X(i, j) = k\} = \frac{\text{Nombre de } x(i, j) = k}{\text{Nombre total de pixels } (M \times N)}$$

Interprétation : Cela correspond au **nombre moyen de bits** nécessaires pour décrire chaque pixel

Lien entre probabilité et longueur de code

Longueur de code pour chaque niveau :

Définir une longueur de code ℓ_i pour chaque niveau de gris avec probabilité p_i :

$$\ell_i \approx -\log p_i = \log \frac{1}{p_i}$$

Exemples numériques :

$$p_i = 0.5 = 2^{-1} \quad : \quad \ell_i = \log \frac{1}{2^{-1}} = \log 2 = 1 \text{ bit}$$

$$p_i = 0.25 = 2^{-2} \quad : \quad \ell_i = \log \frac{1}{2^{-2}} = \log 2^2 = 2 \text{ bits}$$

Principe du codage à longueur variable

Conclusion fondamentale :

- Les symboles **plus fréquents** se voient assigner des codes **plus courts**
- Les symboles **moins fréquents** se voient assigner des codes **plus longs**

→ **Codage à longueur variable** (Variable Length Coding)

Longueur moyenne :

$$\ell_{av} = H(X) = \sum_{i=0}^{L-1} p_i \log p_i = \sum_{i=0}^{L-1} p_i \ell_i$$

Exemple : Image à 8 niveaux

Table de codage

Données :

Niveau	Probabilité	Code longueur fixe	Code longueur variable
0	0.19	000	00
1	0.25	001	11
2	0.21	010	01
3	0.16	011	101
4	0.08	100	1001
5	0.06	101	10001
6	0.03	110	100001
7	0.02	111	100000

Calculs

Somme des probabilités :

$$\sum p_i = 1$$

Entropie de la source :

$$H = 2.6508 \text{ bits}$$

Longueur moyenne (code fixe) :

$$\ell_{av}^{\text{fixe}} = 3 \text{ bits}$$

Longueur moyenne (code variable) :

$$\ell_{av}^{\text{var}} = 2.7000 \text{ bits}$$

Observations

1. Le code à longueur variable est **très proche** de l'entropie de la source
2. Le code à longueur fixe est **loin** de l'entropie
3. La différence peut être **significative** pour de gros fichiers :

Calcul pratique :

- Différence : $3 - 2.65 = 0.35$ bits par symbole/pixel
- Pour une image $1000 \times 1000 = 1$ Mio de symboles
- Différence totale : $1 \text{ Mio} \times 0.35 = 3.5 \times 10^5 \text{ bits} = 42.7 \text{ Kbytes}$

Codes sources pratiques : Codage de Huffman

Principe du codage de Huffman

Objectif :

Concevoir un code qui **approche l'entropie** de la source

Codage de Huffman :

Code **optimal** (longueur de code minimale) pour le codage indépendant de N symboles

Hypothèses

1. Tous les symboles sont **indépendants** (pas très réaliste)
2. Encodage **symbole par symbole**
3. La pmf de la source est **connue** (peut être estimée par histogramme)

Algorithme de Huffman

Étapes :

Étape 1 : Arranger les symboles par **probabilité décroissante**. Les considérer comme des nœuds

Étape 2 : Fusionner les nœuds avec les **plus faibles probabilités**

Étape 3 : Assigner **0 et 1** aux branches supérieure et inférieure, respectivement


Étape 4 : Lire le code de la **racine à la feuille**

Exemple de construction

Probabilités ordonnées :

0.25, 0.21, 0.19, 0.16, 0.08, 0.06, 0.03, 0.02

Arbre de Huffman :



Codes résultants :

Niveau	Probabilité	Code Huffman
0	0.19	00
1	0.25	11
2	0.21	01
3	0.16	101
4	0.08	1001
5	0.06	10001
6	0.03	100001
7	0.02	100000

Propriété : Les symboles avec la **plus haute probabilité** ont la **longueur la plus courte**

Code préfixe

Définition

Code préfixe (Prefix code) :

Aucun code n'est le **préfixe** d'un autre code

Importance du code préfixe

Pourquoi est-ce important ?

1. Pour le **décodage unique** à partir d'une chaîne sans besoin de voir le symbole suivant
2. Le code préfixe peut être décodé **instantanément**

Exemple comparatif

Code A (NON préfixe) :

Symbole	Code
1	1
2	00
3	11
4	110

Code B (préfixe) :

Symbole	Code
1	0
2	10
3	110
4	111

Exemple d'encodage : 1234321

- **Code A** : 100011110110010 → Pas de décodage unique
- **Code B** : 010110111110100 → Décodage unique

Entropie jointe (Joint Entropy)

Définition

Entropie jointe de deux variables discrètes :

Soit $X \in \mathcal{X} = \{x_1, x_2, \dots, x_n\}$ et $Y \in \mathcal{Y} = \{y_1, y_2, \dots, y_m\}$

$$H(X, Y) = - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p_{X,Y}(x, y) \log_2 p_{X,Y}(x, y)$$

Forme espérance :

$$H(X, Y) = -\mathbb{E}_{p_{X,Y}}[\log p_{X,Y}(x, y)]$$

Propriété de symétrie

$$H(X, Y) = H(Y, X)$$

Entropie conditionnelle (Conditional Entropy)

Définition

Entropie conditionnelle de X sachant Y :

$$H(X|Y) = \sum_{y \in \mathcal{Y}} p_Y(y) H(X|Y = y)$$

Forme développée :

$$H(X|Y) = - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p_{X,Y}(x, y) \log p_{X|Y}(x|y)$$

Entropie conditionnelle pour une valeur fixée

Pour $Y = y$ fixé :

$$H(X|Y = y) = - \sum_{i=1}^n p_{X|Y}(x_i|y) \log p_{X|Y}(x_i|y)$$

Développement complet

$$\begin{aligned} H(X|Y) &= - \sum_{j=1}^m p_Y(y_j) \left[\sum_{i=1}^n p_{X|Y}(x_i|y_j) \log p_{X|Y}(x_i|y_j) \right] \\ &= - \sum_{i=1}^n \sum_{j=1}^m p_{X,Y}(x_i, y_j) \log p_{X|Y}(x_i|y_j) \end{aligned}$$

Asymétrie

Attention :

$$H(X|Y) \neq H(Y|X)$$

L'entropie conditionnelle n'est **pas symétrique**

Propriétés de l'entropie

Propriété 1 : Non-négativité

Entropie strictement positive :

$$H(X) \geq 0$$

$$H(X, Y) \geq 0$$

$$H(X|Y) \geq 0$$

Justification :

$$0 \leq p_X(x) \leq 1 \quad \Rightarrow \quad \log p_X(x) \leq 0$$

$$\Rightarrow \quad 0 \leq - \sum p_X(x) \log p_X(x)$$

De même pour $p_{X,Y}(x,y)$ et $p_{X|Y}(x|y)$

Propriété 2 : Règle de chaîne pour l'entropie

Cas de 2 variables :

$$p(x,y) = p(x|y)p(y) = p(y|x)p(x)$$

Entropie jointe :

$$H(X,Y) = H(X|Y) + H(Y) = H(Y|X) + H(X)$$

Démonstration :

$$-\log p_{X,Y}(x,y) = -\log[p_{Y|X}(y|x)p_X(x)] = -\log p_{Y|X}(y|x) - \log p_X(x)$$

$$H(X,Y) = \mathbb{E}_{p_{X,Y}}[-\log p_{X,Y}(x,y)] = \mathbb{E}_{p_{X,Y}}[-\log p_X(x)] + \mathbb{E}_{p_{X,Y}}[-\log p_{Y|X}(y|x)]$$

$$= H(X) + H(Y|X)$$

Cas général de N variables :

$$p(x_1, \dots, x_N) = p(x_1) \prod_{i=2}^N p(x_i | x_{i-1}, \dots, x_1)$$

$$H(X_1, X_2, \dots, X_N) = \sum_{i=1}^N H(X_i | X_{i-1}, \dots, X_1)$$

Conséquence pour variables indépendantes :

$$H(X_1, X_2) \leq H(X_1) + H(X_2)$$

Égalité si et seulement si les variables sont **indépendantes**

Application à un vecteur d'image

Représentation vectorielle :

$$X = p_x(x) = p_x(x_1, x_2, \dots, x_N)$$

$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_N \end{pmatrix}$$

Modèle de Markov d'ordre 2 :

$$p(x_i | x_{i-1}, x_{i-2})$$

Entropie totale :

$$H(X_1, X_2, \dots, X_N) = \sum_{i=1}^N H(X_i | X_{i-1}, \dots, X_1)$$

Pour variables indépendantes :

$$H(X_1, X_2, \dots, X_N) = \sum_{i=1}^N H(X_i)$$

Propriété 3 : Augmentation de l'entropie par ajout de variables

Principe :

Ajouter une nouvelle variable aléatoire **augmente** l'entropie

$$H(X) \leq H(X, Y) \leq H(X, Y, Z) \leq \dots$$

Conditions d'égalité :

$$H(X) = H(X, Y) \Leftrightarrow Y = f(X)$$

(Y est une fonction déterministe de X)

$$H(X, Y) = H(X, Y, Z) \Leftrightarrow Z = f(X, Y)$$

Décomposition :

$$H(X, Y) = H(X) + H(Y|X)$$

où $H(Y|X) \geq 0$

Propriété 4 : Conditionnement réduit l'entropie

Principe fondamental :

Le conditionnement **réduit** (ou laisse inchangée) l'entropie

$$H(X) \geq H(X|Y) \geq H(X|Y, Z) \geq \dots$$

Conditions d'égalité :

$$H(X) = H(X|Y) \Leftrightarrow X \perp Y$$

(X et Y sont indépendants)

$$H(X|Y) = H(X|Y, Z) \Leftrightarrow X \perp Z|Y$$

(X et Z sont conditionnellement indépendants sachant Y)

Intuition : Connaître Y ne peut que **réduire l'incertitude** sur X

Propriété 5 : Entropie maximale pour distribution uniforme

Théorème :

$$H(X) \leq \log_2 |\mathcal{X}|$$

Condition d'égalité :

Égalité si et seulement si X suit une **distribution uniforme** :

$$\mathbb{P}[X = x_i] = \frac{1}{N} = \frac{1}{|\mathcal{X}|}$$

Démonstration :

Soit $\mathcal{X} = \{x_1, x_2, \dots, x_N\}$ et $\mathbb{P}[X = x_i] = p_i$

$$\begin{aligned} H(X) &= - \sum_{x \in \mathcal{X}} \mathbb{P}[X = x] \log_2 \mathbb{P}[X = x] \\ &= -(p_1 \log_2 p_1 + p_2 \log_2 p_2 + \dots + p_N \log_2 p_N) \end{aligned}$$

Objectif :

Trouver la distribution $\{p_i\}_{i=1}^N$ qui maximise $H(X)$ sous la contrainte $\sum p_i = 1$

Résultat :

La distribution uniforme $p_i = 1/N$ maximise l'entropie

Divergence de Kullback-Leibler (KLD)

Définition

Entropie relative ou divergence KL :

Entre deux pmfs $p(x)$ et $q(x)$:

$$D_{KL}(p\|q) = D(p\|q) = \sum_{x \in \mathcal{X}} p(x) \log_2 \frac{p(x)}{q(x)} = \mathbb{E}_{p(x)} \left[\log_2 \frac{p(x)}{q(x)} \right]$$

Conventions

Valeurs limites :

$$0 \log_2 \frac{0}{q(x)} = 0, \quad \forall q(x)$$

$$p(x) \log_2 \frac{p(x)}{0} = +\infty, \quad \forall p(x) > 0$$

Propriétés fondamentales

Asymétrie :

$$D(p\|q) \neq D(q\|p)$$

La KLD n'est **pas une distance** (pas symétrique, ne vérifie pas l'inégalité triangulaire)

Non-négativité :

$$D(p\|q) \geq 0$$

avec égalité si et seulement si $p(x) = q(x)$ pour tout x

Interprétation pratique de la KLD

Problème de codage avec mauvaise distribution

Situation :

- Distribution réelle des données : $p(x)$ (inconnue)
- Distribution supposée pour le codage : $q(x)$

Longueur de code :

Pour $q(x)$: $\ell_q(x) = -\log q(x)$

Pour $p(x)$: $\ell_p(x) = -\log p(x)$

Longueur moyenne attendue :

Si on utilise le code conçu pour $q(x)$ pour coder des données de $p(x)$:

$$\ell_{av}^q = \mathbb{E}_{X \sim p(x)}[\ell_q(X)] = \sum_x p(x) \cdot (-\log q(x))$$

Décomposition de la longueur moyenne

$$\begin{aligned}\ell_{av}^q &= \sum_x p(x) \cdot (-\log q(x)) \\ &= \sum_x p(x) \left(-\log \frac{p(x)}{q(x)} \cdot \frac{1}{p(x)} \right) \\ &= \sum_x p(x) \log \frac{p(x)}{q(x)} + \sum_x p(x) \log \frac{1}{p(x)} \\ &= D(p(x) \| q(x)) + H(p(x))\end{aligned}$$

Formule fondamentale :

$$\mathbb{E}_{X \sim p(x)}[\ell_q(X)] = H(p(x)) + D(p(x) \| q(x))$$

Interprétation

En Machine Learning :

La KLD mesure le niveau de **similarité** entre deux distributions

En théorie du codage :

La KLD mesure l'**inefficacité** du codage conçu pour la pmf $q(x)$ alors que les données proviennent de la pmf $p(x)$

Bits supplémentaires :

$$D(p(x)\|q(x))$$

représente les **bits extra** nécessaires en moyenne

Condition optimale :

$$D(p(x)\|q(x)) = 0 \quad \Leftrightarrow \quad p(x) = q(x)$$

Exemple numérique de KLD

Configuration

Variables binaires :

$$x \in \mathcal{X} = \{0, 1\}$$

- $p(0) = a, p(1) = 1 - a$
- $q(0) = b, q(1) = 1 - b$

Formules

$$D(p\|q) = \sum_{x \in \mathcal{X}} p(x) \log_2 \frac{p(x)}{q(x)} = a \log_2 \frac{a}{b} + (1 - a) \log_2 \frac{1 - a}{1 - b}$$

$$D(q\|p) = \sum_{x \in \mathcal{X}} q(x) \log_2 \frac{q(x)}{p(x)} = b \log_2 \frac{b}{a} + (1 - b) \log_2 \frac{1 - b}{1 - a}$$

Calcul avec valeurs spécifiques

Paramètres :

$$a = 1/4, b = 1/8$$

$$D(p\|q) = \frac{1}{4} \log_2 \frac{8}{4} + \left(1 - \frac{1}{4}\right) \log_2 \frac{1 - 1/4}{1 - 1/8} = 0.0832 \text{ bit}$$

$$D(q\|p) = \frac{1}{8} \log_2 \frac{4}{8} + \left(1 - \frac{1}{8}\right) \log_2 \frac{1 - 1/8}{1 - 1/4} = 0.0696 \text{ bit}$$

Vérification :

$$D(p\|q) \neq D(q\|p)$$

Cross-Entropy (Entropie croisée)

Définition

Entropie croisée entre pmfs $p(x)$ et $q(x)$:

$$H(p, q) = - \sum_{x \in \mathcal{X}} p(x) \log q(x) = -\mathbb{E}_{p(x)}[\log q(x)]$$

Lien avec la KLD

Relation fondamentale :

$$H(p, q) = H(p) + D_{KL}(p\|q)$$

Démonstration :

$$\begin{aligned} D_{KL}(p\|q) &= \mathbb{E}_{p(x)} \left[\log \frac{p(x)}{q(x)} \right] = \mathbb{E}_{p(x)}[\log p(x)] - \mathbb{E}_{p(x)}[\log q(x)] \\ &= -H(p) + H(p, q) \end{aligned}$$

Propriété d'optimisation

Remarque importante :

Puisque $H(p)$ est **constant** (ne dépend pas de q), optimiser $H(p, q)$ par rapport à $q(x)$ est **équivalent** à optimiser $D_{KL}(p\|q)$

$$\min_q H(p, q) \Leftrightarrow \min_q D_{KL}(p\|q)$$

Application en Machine Learning :

La cross-entropy est largement utilisée comme **fonction de perte** dans les réseaux de neurones pour la classification

Information mutuelle (Mutual Information)

Définition

Information mutuelle entre deux variables aléatoires X et Y :

$$I(X; Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p_{X,Y}(x, y) \log \frac{p_{X,Y}(x, y)}{p_X(x)p_Y(y)}$$

Forme espérance :

$$I(X; Y) = \mathbb{E}_{p_{X,Y}(x,y)} \left[\log \frac{p_{X,Y}(x,y)}{p_X(x)p_Y(y)} \right]$$

Forme alternative

$$I(X; Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p_{X,Y}(x, y) \log \frac{p_{X|Y}(x|y)}{p_X(x)} \cdot p_Y(y)$$

Propriétés fondamentales

Symétrie :

$$I(X; Y) = I(Y; X)$$

Non-négativité :

$$I(X; Y) \geq 0$$

Condition d'annulation :

$$I(X; Y) = 0 \quad \Leftrightarrow \quad X \perp Y$$

(si et seulement si X et Y sont indépendants)

Information mutuelle via KL-divergence

Formulation en termes de KLD

Information mutuelle comme divergence KL :

$$I(X; Y) = D_{KL}(p_{X,Y}(x, y) \| p_X(x)p_Y(y))$$

$$= \mathbb{E}_{p_{X,Y}(x,y)} \left[\log \frac{p_{X,Y}(x,y)}{p_X(x)p_Y(y)} \right]$$

Interprétation

L'information mutuelle mesure :

À quel point la distribution jointe $p_{X,Y}(x, y)$ diffère du produit des marginales $p_X(x)p_Y(y)$

Autrement dit :

Mesure la **dépendance** entre X et Y par rapport à l'hypothèse d'**indépendance**

Attention aux notations :

Équivalence : $p_{X,Y}(x, y) = p(x, y)$

Formes conditionnelles

$$I(X; Y) = \mathbb{E}_{p(y)}[D_{KL}(p(x|y) \| p(x))]$$

$$I(X; Y) = \mathbb{E}_{p(x)}[D_{KL}(p(y|x) \| p(y))]$$

Relations entre information mutuelle et entropie

Relations fondamentales

Relation 1 :

$$I(X; Y) = H(X) - H(X|Y)$$

Relation 2 :

$$I(X; Y) = H(Y) - H(Y|X)$$

Relation 3 :


$$I(X; Y) = H(X) + H(Y) - H(X, Y)$$

Cas particulier :

$$I(X; X) = H(X)$$

car $H(X|X) = 0$

Diagramme de Venn des entropies



Lecture du diagramme :

- $H(X, Y)$: entropie jointe (tout le rectangle)
 - $I(X; Y)$: information mutuelle (intersection)
 - $H(X|Y)$: entropie de X sachant Y (partie gauche uniquement)
 - $H(Y|X)$: entropie de Y sachant X (partie droite uniquement)
-

Information mutuelle conditionnelle

Définition

Information mutuelle entre X et Y sachant Z :

$$I(X; Y|Z) = H(X|Z) - H(X|Y, Z)$$

Forme avec KL-divergence :

$$\begin{aligned} I(X; Y|Z) &= \mathbb{E}_{p(x, y, z)} \left[\log \frac{p_{X, Y|Z}(x, y|z)}{p_{X|Z}(x|z)p_{Y|Z}(y|z)} \right] \\ &= \mathbb{E}_{p(x, y, z)} \left[\log \frac{p_{X|Y, Z}(x|y, z)}{p_{X|Z}(x|z)} \right] \end{aligned}$$

Démonstration

$$p_{X,Y|Z}(x, y|z) = p_{Y|Z}(y|z) \cdot p_{X|Y,Z}(x|y, z)$$

$$\begin{aligned} I(X; Y|Z) &= \mathbb{E}_{p(x,y,z)}[\log p_{X|Y,Z}(x|y, z)] - \mathbb{E}_{p(x,y,z)}[\log p_{X|Z}(x|z)] \\ &= -H(X|Y, Z) + H(X|Z) \end{aligned}$$

Propriétés de l'information mutuelle

Information mutuelle conditionnelle

Diagramme :

$$\begin{array}{ccc} H(X|Z) & & H(Y|Z) \\ & \searrow & \swarrow \\ & I(X; Y|Z) & \end{array}$$

$$I(X; Y|Z) = H(X|Z) - H(X|Y, Z)$$

Règle de chaîne pour l'information mutuelle

Pour N variables :

$$I(X_1, X_2, \dots, X_N; Y) = \sum_{i=1}^N I(X_i; Y|X_{i-1}, \dots, X_1)$$

Démonstration :

$$I(X_1, X_2, \dots, X_N; Y) = H(X_1, X_2, \dots, X_N) - H(X_1, X_2, \dots, X_N | Y)$$

$$\begin{aligned} &= \sum_{i=1}^N H(X_i | X_{i-1}, \dots, X_1) - \sum_{i=1}^N H(X_i | X_{i-1}, \dots, X_1, Y) \\ &= \sum_{i=1}^N I(X_i; Y | X_{i-1}, \dots, X_1) \end{aligned}$$

Application : Pixels d'image et label

Configuration :

$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_N \end{pmatrix} \in \mathcal{X}^N$$

représente une image de $N = n \times m$ pixels

$$Y \in \mathcal{Y}$$

représente un label

Information mutuelle totale :

$$I(X_1, X_2, \dots, X_N; Y) = \sum_{i=1}^N I(X_i; Y | X_{i-1}, \dots, X_1)$$

Décomposition complexe

Exemple avec 2 variables et 2 labels :

$$I(X_1, X_2; Y_1, Y_2) = I(X_1; Y_1, Y_2) + I(X_2; Y_1, Y_2 | X_1)$$

Décomposition de $I(X_1; Y_1, Y_2)$:

$$I(X_1; Y_1, Y_2) = I(X_1; Y_1) + I(X_1; Y_2 | Y_1) = I(X_1; Y_2) + I(X_1; Y_1 | Y_2)$$

Décomposition de $I(X_2; Y_1, Y_2 | X_1)$:

$$I(X_2; Y_1, Y_2 | X_1) = I(X_2; Y_1 | X_1) + I(X_2; Y_2 | X_1, Y_1)$$

$$= I(X_2; Y_2 | X_1) + I(X_2; Y_1 | X_1, Y_2)$$

Inégalité de traitement des données

Chaîne de Markov

Configuration :



$$p_{X,Y,Z}(x, y, z) = p_X(x) \cdot p_{Y|X}(y|x) \cdot p_{Z|Y}(z|y)$$

Notation : $X \rightarrow Y \rightarrow Z$

Inégalité fondamentale

Deux inégalités valides :

$$I(X; Y) \geq I(X; Z)$$

$$I(Y; Z) \geq I(X; Z)$$

Cas particulier important :

Si $Z = g(Y)$ (fonction déterministe de Y) :

$$I(X; Y) \geq I(X; Z)$$

Interprétation

Principe de non-créativité de l'information :

La quantité d'information **ne peut pas être augmentée** par un traitement quelconque

Ceci inclut les réseaux de neurones profonds !

L'information mutuelle entre l'entrée et la sortie d'un réseau ne peut qu'être **inférieure ou égale** à l'information mutuelle entre l'entrée et les couches intermédiaires

Démonstration de l'inégalité

En utilisant la règle de chaîne :

$$I(X; Y, Z) = I(X; Z) + I(X; Y|Z) \quad (\text{a})$$

$$I(X; Y, Z) = I(X; Y) + I(X; Z|Y) \quad (\text{b})$$

Propriété clé :

Pour la chaîne de Markov $X \rightarrow Y \rightarrow Z$:

$$X \perp Z|Y \Rightarrow I(X; Z|Y) = 0$$

Donc de (b) :

$$I(X; Y, Z) = I(X; Y)$$

En combinant avec (a) :

$$I(X; Y) = I(X; Z) + I(X; Y|Z)$$

Conclusion :

$$I(X; Y) \geq I(X; Z)$$

car $I(X; Y|Z) \geq 0$

Variables continues : Entropie différentielle

Motivation

Pour variables discrètes :

$$P[x_k; \Delta x] = \int f_X(x) dx \approx f_X(x_k) \Delta x$$

Entropie avec quantification :

$$\begin{aligned} H(X; \Delta x) &= - \sum_{i=1}^N P[x_k; \Delta x] \log_2 P[x_k; \Delta x] \\ &= - \sum_{i=1}^N f_X(x_k) \Delta x \log_2 [f_X(x_k) \Delta x] \end{aligned}$$

Décomposition

$$\begin{aligned} H(X; \Delta x) &= - \sum_{i=1}^N f_X(x_k) \Delta x \log_2 f_X(x_k) - \sum_{i=1}^N f_X(x_k) \Delta x \log_2 \Delta x \\ &= - \sum_{i=1}^N f_X(x_k) \Delta x \log_2 f_X(x_k) - \log_2 \Delta x \underbrace{\sum_{i=1}^N f_X(x_k) \Delta x}_{=1} \end{aligned}$$

Passage à la limite :

$$H(X; \Delta x) = - \int f_X(x) \log_2 f_X(x) dx - \log_2 \Delta x$$

Problème avec la limite

Dans la limite $\Delta x \rightarrow 0$:

Δx tend vers zéro pour un grand N

Conséquence :

$$\log_2 \Delta x \rightarrow -\infty$$

$$\text{Donc } H(X; \Delta x) \rightarrow +\infty$$

Définition de l'entropie différentielle

Définition formelle

Entropie différentielle d'une v.a. continue X avec pdf $f_X(x)$:

$$h(X) = - \int_x f_X(x) \log_2 f_X(x) dx = -\mathbb{E}_{f_X}[\log_2 f_X(x)]$$

Attention :

- Notation différente : $h(X)$ au lieu de $H(X)$
- Peut être **négative** (contrairement à l'entropie discrète)
- N'a pas d'interprétation directe en termes de bits

Entropie différentielle d'une gaussienne

Variable gaussienne

Distribution :

$$X \sim \mathcal{N}(0, \sigma_X^2)$$

Entropie différentielle :

$$h(X) = -\mathbb{E}_{f_X}[\log_2 f_X(x)] = \frac{1}{2} \log_2(2\pi e \sigma_X^2)$$

Démonstration

PDF gaussienne :

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma_X^2}} \exp\left(-\frac{x^2}{2\sigma_X^2}\right)$$

Calcul de l'entropie :

$$\begin{aligned} h(X) &= - \int f_X(x) \ln f_X(x) dx \quad [\text{nats}] \\ &= - \int f_X(x) \left[-\frac{x^2}{2\sigma_X^2} - \ln(\sqrt{2\pi\sigma_X^2}) \right] dx \\ &= \int_{-\infty}^{\infty} f_X(x) \frac{x^2}{2\sigma_X^2} dx + \ln(\sqrt{2\pi\sigma_X^2}) \underbrace{\int_{-\infty}^{\infty} f_X(x) dx}_{=1} \end{aligned}$$

Calcul de la première intégrale :

$$\int_{-\infty}^{\infty} f_X(x) \frac{x^2}{2\sigma_X^2} dx = \frac{1}{2\sigma_X^2} \underbrace{\int_{-\infty}^{\infty} x^2 f_X(x) dx}_{=\text{Var}[X]=\sigma_X^2} = \frac{\sigma_X^2}{2\sigma_X^2} = \frac{1}{2}$$

Résultat en nats :

$$h(X) = \frac{1}{2} + \ln(\sqrt{2\pi\sigma_X^2}) = \frac{1}{2} \ln e + \frac{1}{2} \ln(2\pi\sigma_X^2)$$

$$= \frac{1}{2} [\ln e + \ln(2\pi\sigma_X^2)] = \frac{1}{2} \ln(2\pi e\sigma_X^2) \quad [\text{nats}]$$

Conversion en bits :

$$h(X) = \frac{1}{2} \log_2(2\pi e\sigma_X^2) \quad [\text{bits}]$$

Propriétés de l'entropie différentielle

Propriété 1 : Invariance par translation

Translation :

$$h(X + a) = h(X)$$

où a est une constante scalaire

Interprétation : Décaler une distribution ne change pas son entropie différentielle

Propriété 2 : Effet de la mise à l'échelle

Pour variable scalaire :

Si X est une variable aléatoire scalaire :

$$h(aX) = h(X) + \log |a|$$

Pour variable vectorielle :

Si X est un vecteur aléatoire et A est une matrice :

$$h(AX) = h(X) + \log |\det(A)|$$

où $\det(A)$ est le **déterminant** de la matrice A

Interprétation :

- Étirer la distribution (facteur $|a| > 1$) **augmente** l'entropie
 - Compresser la distribution (facteur $|a| < 1$) **diminue** l'entropie
-

Concepts mathématiques à maîtriser

Théorie de l'information

Concepts fondamentaux :

- Entropie (discrète et différentielle)
- Entropie jointe et conditionnelle
- Information mutuelle
- Divergence KL
- Cross-entropy

Relations :

- Règle de chaîne pour entropie
- Relations entre $H(X)$, $H(Y)$, $H(X, Y)$, $I(X; Y)$
- Inégalité de traitement des données

Probabilités

Distributions :

- Distribution discrète vs continue
- Distribution uniforme
- Distribution gaussienne

Concepts :

- Indépendance
- Conditionnement
- Marginalisation

Codage et compression

Théorie du codage :

- Longueur de code optimale
 - Code préfixe
 - Codage de Huffman
 - Taux de compression
-

Questions d'examen types

Questions conceptuelles

Entropie :

- Définir l'entropie et expliquer son interprétation
- Quelle distribution maximise l'entropie ?
- Différence entre entropie et entropie différentielle

Relations :

- Relation entre $H(X, Y)$, $H(X)$, et $H(Y|X)$
- Qu'est-ce que l'information mutuelle ?
- Pourquoi $H(X|Y) \leq H(X)$?

KLD et cross-entropy :

- Définir la divergence KL
- Interprétation en termes de codage
- Lien entre KLD et cross-entropy

Questions techniques

Calculs :

- Calculer l'entropie d'une distribution binaire
- Calculer la KLD entre deux distributions
- Calculer l'information mutuelle entre deux variables

Codage :

- Appliquer l'algorithme de Huffman
- Calculer la longueur moyenne d'un code
- Qu'est-ce qu'un code préfixe et pourquoi est-il important ?

Propriétés :

- Démontrer la règle de chaîne pour l'entropie
- Démontrer l'inégalité de traitement des données
- Prouver que $I(X; Y) \geq 0$

Démonstrations mathématiques

Propriétés de l'entropie :

- Montrer que le conditionnement réduit l'entropie
- Prouver que la distribution uniforme maximise l'entropie
- Démontrer la règle de chaîne pour l'information mutuelle

Variables continues :

- Calculer l'entropie différentielle d'une gaussienne
- Effet de la mise à l'échelle sur l'entropie différentielle

Applications en Machine Learning

Fonctions de perte

Cross-entropy comme loss :

Utilisée en classification pour minimiser la divergence entre :

- Distribution prédite par le modèle : $q(y|x)$
- Distribution vraie (one-hot) : $p(y|x)$

$$\mathcal{L} = - \sum_i p(y_i) \log q(y_i)$$

Sélection de features

Information mutuelle :

Mesurer $I(X_i; Y)$ pour sélectionner les features les plus informatives

Critère :

Garder les features avec $I(X_i; Y)$ élevée

Régularisation

Variational AutoEncoders (VAE) :

Minimiser la KLD entre :

- Distribution encodée $q(z|x)$
- Prior $p(z)$ (souvent gaussien)

$$\mathcal{L}_{KL} = D_{KL}(q(z|x) \| p(z))$$

Résumé des formules clés

Entropie

$$H(X) = - \sum_x p(x) \log p(x)$$

$$H(X, Y) = - \sum_x \sum_y p(x, y) \log p(x, y)$$

$$H(X|Y) = - \sum_x \sum_y p(x, y) \log p(x|y)$$

Relations

$$H(X, Y) = H(X) + H(Y|X) = H(Y) + H(X|Y)$$

$$H(X|Y) \leq H(X)$$

$$H(X, Y) \leq H(X) + H(Y)$$

Information mutuelle

$$I(X; Y) = H(X) - H(X|Y) = H(Y) - H(Y|X)$$

$$I(X; Y) = H(X) + H(Y) - H(X, Y)$$

$$I(X; Y) = D_{KL}(p(x, y) \| p(x)p(y))$$

KLD et Cross-entropy

$$D_{KL}(p \| q) = \sum_x p(x) \log \frac{p(x)}{q(x)}$$

$$H(p, q) = - \sum_x p(x) \log q(x)$$

$$H(p, q) = H(p) + D_{KL}(p \| q)$$