

# Table of contents

## Document de Révision : Fondamentaux de la Théorie de l'Information pour la Data

|                                                                                |          |
|--------------------------------------------------------------------------------|----------|
| <b>Science</b>                                                                 | <b>4</b> |
| Introduction générale . . . . .                                                | 4        |
| Contexte de la théorie de l'information . . . . .                              | 4        |
| Rappel : Règle de chaîne pour probabilités . . . . .                           | 4        |
| Règle de chaîne générale . . . . .                                             | 4        |
| Cas particulier : 2 variables . . . . .                                        | 4        |
| Variables indépendantes . . . . .                                              | 5        |
| Exemples de décomposition par règle de chaîne . . . . .                        | 5        |
| Trois variables : Différentes décompositions . . . . .                         | 5        |
| Entropie (Entropy) . . . . .                                                   | 6        |
| Définition formelle . . . . .                                                  | 6        |
| Interprétation . . . . .                                                       | 7        |
| Espérance et entropie . . . . .                                                | 7        |
| Entropie d'une variable binaire . . . . .                                      | 7        |
| Cas binaire : Variable de Bernoulli . . . . .                                  | 7        |
| Formule de l'entropie binaire . . . . .                                        | 8        |
| Propriétés de $H(\theta)$ . . . . .                                            | 8        |
| Application : Compression sans perte . . . . .                                 | 9        |
| Schéma de compression . . . . .                                                | 9        |
| Complexité de compression pour images . . . . .                                | 9        |
| Complexité computationnelle . . . . .                                          | 10       |
| Taux de compression . . . . .                                                  | 10       |
| Définition pratique . . . . .                                                  | 10       |
| Taux de compression réels . . . . .                                            | 10       |
| Lien avec la théorie de l'information : Assignment optimale de codes . . . . . | 11       |
| Principe de base . . . . .                                                     | 11       |
| Lien entre probabilité et longueur de code . . . . .                           | 11       |
| Principe du codage à longueur variable . . . . .                               | 12       |
| Exemple : Image à 8 niveaux . . . . .                                          | 12       |
| Table de codage . . . . .                                                      | 12       |
| Calculs . . . . .                                                              | 12       |
| Observations . . . . .                                                         | 13       |
| Codes sources pratiques : Codage de Huffman . . . . .                          | 13       |
| Principe du codage de Huffman . . . . .                                        | 13       |
| Hypothèses . . . . .                                                           | 13       |
| Algorithme de Huffman . . . . .                                                | 14       |
| Exemple de construction . . . . .                                              | 14       |
| Code préfixe . . . . .                                                         | 16       |
| Définition . . . . .                                                           | 16       |

|                                                                           |    |
|---------------------------------------------------------------------------|----|
| Importance du code préfixe . . . . .                                      | 16 |
| Exemple comparatif . . . . .                                              | 16 |
| Entropie jointe (Joint Entropy) . . . . .                                 | 17 |
| Définition . . . . .                                                      | 17 |
| Propriété de symétrie . . . . .                                           | 17 |
| Entropie conditionnelle (Conditional Entropy) . . . . .                   | 17 |
| Définition . . . . .                                                      | 17 |
| Entropie conditionnelle pour une valeur fixée . . . . .                   | 18 |
| Développement complet . . . . .                                           | 18 |
| Asymétrie . . . . .                                                       | 18 |
| Propriétés de l'entropie . . . . .                                        | 18 |
| Propriété 1 : Non-négativité . . . . .                                    | 18 |
| Propriété 2 : Règle de chaîne pour l'entropie . . . . .                   | 19 |
| Application à un vecteur d'image . . . . .                                | 20 |
| Propriété 3 : Augmentation de l'entropie par ajout de variables . . . . . | 21 |
| Propriété 4 : Conditionnement réduit l'entropie . . . . .                 | 21 |
| Propriété 5 : Entropie maximale pour distribution uniforme . . . . .      | 22 |
| Divergence de Kullback-Leibler (KLD) . . . . .                            | 23 |
| Définition . . . . .                                                      | 23 |
| Conventions . . . . .                                                     | 23 |
| Propriétés fondamentales . . . . .                                        | 23 |
| Interprétation pratique de la KLD . . . . .                               | 24 |
| Problème de codage avec mauvaise distribution . . . . .                   | 24 |
| Décomposition de la longueur moyenne . . . . .                            | 24 |
| Interprétation . . . . .                                                  | 25 |
| Exemple numérique de KLD . . . . .                                        | 25 |
| Configuration . . . . .                                                   | 25 |
| Formules . . . . .                                                        | 25 |
| Calcul avec valeurs spécifiques . . . . .                                 | 26 |
| Cross-Entropy (Entropie croisée) . . . . .                                | 26 |
| Définition . . . . .                                                      | 26 |
| Lien avec la KLD . . . . .                                                | 26 |
| Propriété d'optimisation . . . . .                                        | 27 |
| Information mutuelle (Mutual Information) . . . . .                       | 27 |
| Définition . . . . .                                                      | 27 |
| Forme alternative . . . . .                                               | 27 |
| Propriétés fondamentales . . . . .                                        | 28 |
| Information mutuelle via KL-divergence . . . . .                          | 28 |
| Formulation en termes de KLD . . . . .                                    | 28 |
| Interprétation . . . . .                                                  | 28 |
| Formes conditionnelles . . . . .                                          | 29 |
| Relations entre information mutuelle et entropie . . . . .                | 29 |
| Relations fondamentales . . . . .                                         | 29 |

|                                                         |    |
|---------------------------------------------------------|----|
| Diagramme de Venn des entropies . . . . .               | 30 |
| Information mutuelle conditionnelle . . . . .           | 30 |
| Définition . . . . .                                    | 30 |
| Démonstration . . . . .                                 | 31 |
| Propriétés de l'information mutuelle . . . . .          | 31 |
| Information mutuelle conditionnelle . . . . .           | 31 |
| Règle de chaîne pour l'information mutuelle . . . . .   | 31 |
| Application : Pixels d'image et label . . . . .         | 32 |
| Décomposition complexe . . . . .                        | 33 |
| Inégalité de traitement des données . . . . .           | 33 |
| Chaîne de Markov . . . . .                              | 33 |
| Inégalité fondamentale . . . . .                        | 34 |
| Interprétation . . . . .                                | 34 |
| Démonstration de l'inégalité . . . . .                  | 34 |
| Variables continues : Entropie différentielle . . . . . | 35 |
| Motivation . . . . .                                    | 35 |
| Décomposition . . . . .                                 | 36 |
| Problème avec la limite . . . . .                       | 36 |
| Définition de l'entropie différentielle . . . . .       | 36 |
| Définition formelle . . . . .                           | 36 |
| Entropie différentielle d'une gaussienne . . . . .      | 37 |
| Variable gaussienne . . . . .                           | 37 |
| Démonstration . . . . .                                 | 37 |
| Propriétés de l'entropie différentielle . . . . .       | 38 |
| Propriété 1 : Invariance par translation . . . . .      | 38 |
| Propriété 2 : Effet de la mise à l'échelle . . . . .    | 38 |
| Concepts mathématiques à maîtriser . . . . .            | 39 |
| Théorie de l'information . . . . .                      | 39 |
| Probabilités . . . . .                                  | 39 |
| Codage et compression . . . . .                         | 40 |
| Questions d'examen types . . . . .                      | 40 |
| Questions conceptuelles . . . . .                       | 40 |
| Questions techniques . . . . .                          | 40 |
| Démonstrations mathématiques . . . . .                  | 41 |
| Applications en Machine Learning . . . . .              | 41 |
| Fonctions de perte . . . . .                            | 41 |
| Sélection de features . . . . .                         | 42 |
| Régularisation . . . . .                                | 42 |
| Résumé des formules clés . . . . .                      | 42 |
| Entropie . . . . .                                      | 42 |
| Relations . . . . .                                     | 43 |
| Information mutuelle . . . . .                          | 43 |
| KLD et Cross-entropy . . . . .                          | 43 |

# Document de Révision : Fondamentaux de la Théorie de l'Information pour la Data Science

---

## Introduction générale

### Contexte de la théorie de l'information

La **théorie de l'information** fournit un cadre mathématique rigoureux pour quantifier l'information, l'incertitude et la dépendance entre variables aléatoires.

### Applications en Data Science :

- Compression de données
  - Apprentissage automatique
  - Sélection de features
  - Mesure de similarité entre distributions
  - Optimisation de réseaux de neurones
- 

## Rappel : Règle de chaîne pour probabilités

### Règle de chaîne générale

Pour  $N$  variables aléatoires :

$$p(x_1, x_2, \dots, x_n) = p(x_1) \cdot p(x_2|x_1) \cdot p(x_3|x_2, x_1) \cdots p(x_n|x_{n-1}, \dots, x_2, x_1)$$

Forme compacte :

$$p(x_1, x_2, \dots, x_n) = \prod_{i=1}^n p(x_i|x_{i-1}, \dots, x_2, x_1)$$

### Cas particulier : 2 variables

$$p(x_1, x_2) = p(x_1)p(x_2|x_1) = p(x_2)p(x_1|x_2)$$

## Variables indépendantes

### Définition :

Si les variables sont **indépendantes** :  $X_1 \perp X_2$

$$p(x_1, x_2) = p(x_1) \cdot p(x_2)$$

Généralisation à N variables i.i.d. :

$$p(x_1, x_2, \dots, x_n) = \prod_{i=1}^n p(x_i) = [p(x)]^n$$

---

## Exemples de décomposition par règle de chaîne

### Trois variables : Différentes décompositions

Chaîne linéaire :




$$p(x, y, z) = p(x) \cdot p(y|x) \cdot p(z|x, y)$$

Indépendance complète :

$$p(x, y, z) = p(x) \cdot p(y) \cdot p(z)$$

Indépendance conditionnelle (Y comme parent commun) :



$$p(x, y, z) = p(y) \cdot p(x|y) \cdot p(z|y)$$

**Structure alternative :**

$$p(x, y, z) = p(z) \cdot p(y|z) \cdot p(x|y, z)$$

$$p(x, y, z) = p(z|x, y) \cdot p(x) \cdot p(y)$$

$$p(x, y, z) = p(z) \cdot p(x|z) \cdot p(y|z)$$


---

## Entropie (Entropy)

### Définition formelle

#### Entropie d'une variable aléatoire discrète :

Soit  $X$  une variable aléatoire discrète prenant ses valeurs dans  $\mathcal{X} = \{x_1, x_2, \dots, x_n\}$

$$H(X) = - \sum_{x \in \mathcal{X}} p_X(x) \log_2 p_X(x) = -\mathbb{E}_{p_X}[\log p_X(x)]$$

#### Unités :

- **Base 2** ( $\alpha = 2$ ) : mesure en **bits**
- **Base e** ( $\alpha = e$ ) : mesure en **nats**

On note parfois  $H_\alpha(X)$  pour spécifier la base

## Interprétation

L'entropie mesure :

- L'**incertitude** d'une variable aléatoire discrète
- Le **caractère aléatoire** (randomness)
- Le nombre **moyen de bits** nécessaires pour encoder la variable

**Point important :**  $H(X)$  dépend uniquement de la **distribution** de  $X$ , pas des valeurs particulières prises

Notations équivalentes :

- $H(X)$
- $H(p)$
- $H(p(x))$

## Espérance et entropie

Rappel de l'espérance :

$$\mathbb{E}_{p_X}[g(X)] = \sum_{x \in \mathcal{X}} p_X(x)g(x)$$

Entropie comme espérance :

$$H(X) = \mathbb{E}_{p_X}[-\log p_X(x)]$$

---

## Entropie d'une variable binaire

**Cas binaire : Variable de Bernoulli**

Variable binaire :

$$X \in \mathcal{X} = \{0, 1\}$$

$$\mathbb{P}[X = 0] = 1 - \theta$$

$$\mathbb{P}[X = 1] = \theta$$

**Forme compacte :**

$$\mathbb{P}[X = x] = \theta^x(1 - \theta)^{1-x}$$

**Formule de l'entropie binaire**

$$H(X) = -\theta \log_2 \theta - (1 - \theta) \log_2 (1 - \theta) := H(\theta) \text{ ou } H_2(\theta)$$

**Propriétés de  $H(\theta)$**

**Symétrie :**

La fonction est **symétrique** par rapport à  $\theta = 0.5$

$$H(\theta) = H(1 - \theta)$$

**Maximum :**

Le maximum est atteint en  $\theta = 0.5$  :

$$\max_{\theta} H(\theta) = H(0.5) = 1 \text{ bit}$$

**Principe fondamental :** L'entropie est **maximale** si les symboles sont **équiprobables**

**Exemples numériques :**

- $\theta = 0.11$  :  $H(0.11) \approx 0.5$  bit
  - $\theta = 0.5$  :  $H(0.5) = 1$  bit
  - $\theta = 0.89$  :  $H(0.89) \approx 0.5$  bit
-

## Application : Compression sans perte

### Schéma de compression

Compression sans perte (Lossless) :

$$X \xrightarrow{\text{Encodeur}} R \xrightarrow{\text{Décodeur}} \hat{X}$$

Propriété :

$$\hat{X} = X \Rightarrow D = \mathbb{E}[\|X - \hat{X}\|^2] = 0$$

Compression avec perte (Lossy) :

$$\hat{X} \neq X \Rightarrow D = \mathbb{E}[\|X - \hat{X}\|^2] \neq 0$$

### Complexité de compression pour images

Problématique :

Soit une image représentée comme vecteur  $x \sim p_x(x) = p_x(x_1, x_2, \dots, x_n)$

Connaissance de la distribution source :

La **pdf/pmf jointe** est nécessaire pour la compression optimale

Défis :

1. Modélisation : la pdf multidimensionnelle est **très complexe**
2. La vraie pdf est **inconnue**
3. Simplification courante : considérer les pixels **indépendamment** (mais cela **augmente l'entropie**)
4. Le codage indépendant des symboles n'est **pas optimal** selon la théorie rate-distorsion de Shannon qui suggère un **codage par blocs**

Solution intermédiaire :

Utiliser un **codage par sous-blocs** (comme dans JPEG)

## Complexité computationnelle

### Codage par blocs de Shannon :

Complexité **exponentielle** en fonction de la longueur du bloc

### Méthodes pratiques :

Réduire la taille des blocs jusqu'à un symbole/pixel (sous-optimal mais **complexité réduite**)

---

## Taux de compression

### Définition pratique

Ratio de compression (Compression Ratio) :

$$CR = \frac{\text{Nombre de bits avant}}{\text{Nombre de bits après}}$$

### Taux de compression réels

Pour images réelles :

Compression sans perte :

$$CR \approx 2$$

Compression avec perte :

- **JPEG** :  $CR = 10$  à  $50$
  - **JPEG 2000** :  $CR$  jusqu'à  $150$
-

## Lien avec la théorie de l'information : Assignment optimale de codes

### Principe de base

#### Histogramme et indépendance :

L'histogramme est **trompeur** mais supposons que les pixels de l'image sont **discrets** et **indépendants**

#### Entropie pour variables discrètes :

$$H(X) = - \sum_{i=0}^{L-1} p_i \log p_i = \ell_{av}$$

où  $\ell_{av}$  est la **longueur moyenne** nécessaire

#### Probabilité d'observer une intensité particulière :

$$p_i = \mathbb{P}\{X(i, j) = k\} = \frac{\text{Nombre de } x(i, j) = k}{\text{Nombre total de pixels } (M \times N)}$$

**Interprétation :** Cela correspond au **nombre moyen de bits** nécessaires pour décrire chaque pixel

### Lien entre probabilité et longueur de code

#### Longueur de code pour chaque niveau :

Définir une longueur de code  $\ell_i$  pour chaque niveau de gris avec probabilité  $p_i$  :

$$\ell_i \approx -\log p_i = \log \frac{1}{p_i}$$

#### Exemples numériques :

$$p_i = 0.5 = 2^{-1} \quad : \quad \ell_i = \log \frac{1}{2^{-1}} = \log 2 = 1 \text{ bit}$$

$$p_i = 0.25 = 2^{-2} \quad : \quad \ell_i = \log \frac{1}{2^{-2}} = \log 2^2 = 2 \text{ bits}$$

## Principe du codage à longueur variable

Conclusion fondamentale :

- Les symboles **plus fréquents** se voient assigner des codes **plus courts**
- Les symboles **moins fréquents** se voient assigner des codes **plus longs**

→ **Codage à longueur variable** (Variable Length Coding)

Longueur moyenne :

$$\ell_{av} = H(X) = \sum_{i=0}^{L-1} p_i \log p_i = \sum_{i=0}^{L-1} p_i \ell_i$$

---

## Exemple : Image à 8 niveaux

Table de codage

Données :

| Niveau | Probabilité | Code longueur fixe | Code longueur variable |
|--------|-------------|--------------------|------------------------|
| 0      | 0.19        | 000                | 00                     |
| 1      | 0.25        | 001                | 11                     |
| 2      | 0.21        | 010                | 01                     |
| 3      | 0.16        | 011                | 101                    |
| 4      | 0.08        | 100                | 1001                   |
| 5      | 0.06        | 101                | 10001                  |
| 6      | 0.03        | 110                | 100001                 |
| 7      | 0.02        | 111                | 100000                 |

Calculs

Somme des probabilités :

$$\sum p_i = 1$$

Entropie de la source :

$$H = 2.6508 \text{ bits}$$

Longueur moyenne (code fixe) :

$$\ell_{av}^{\text{fixe}} = 3 \text{ bits}$$

Longueur moyenne (code variable) :

$$\ell_{av}^{\text{var}} = 2.7000 \text{ bits}$$

### Observations

1. Le code à longueur variable est **très proche** de l'entropie de la source
2. Le code à longueur fixe est **loin** de l'entropie
3. La différence peut être **significative** pour de gros fichiers :

Calcul pratique :

- Différence :  $3 - 2.65 = 0.35$  bits par symbole/pixel
- Pour une image  $1000 \times 1000 = 1$  Mio de symboles
- Différence totale :  $1 \text{ Mio} \times 0.35 = 3.5 \times 10^5 \text{ bits} = 42.7 \text{ Kbytes}$

## Codes sources pratiques : Codage de Huffman

### Principe du codage de Huffman

Objectif :

Concevoir un code qui **approche l'entropie** de la source

**Codage de Huffman :**

Code **optimal** (longueur de code minimale) pour le codage indépendant de  $N$  symboles

### Hypothèses

1. Tous les symboles sont **indépendants** (pas très réaliste)
2. Encodage **symbole par symbole**
3. La pmf de la source est **connue** (peut être estimée par histogramme)

## Algorithme de Huffman

Étapes :

**Étape 1 :** Arranger les symboles par **probabilité décroissante**. Les considérer comme des nœuds

**Étape 2 :** Fusionner les nœuds avec les **plus faibles probabilités**

**Étape 3 :** Assigner **0 et 1** aux branches supérieure et inférieure, respectivement


**Étape 4 :** Lire le code de la **racine à la feuille**

## Exemple de construction

Probabilités ordonnées :

0.25, 0.21, 0.19, 0.16, 0.08, 0.06, 0.03, 0.02

Arbre de Huffman :



Codes résultants :

| Niveau | Probabilité | Code Huffman |
|--------|-------------|--------------|
| 0      | 0.19        | 00           |
| 1      | 0.25        | 11           |
| 2      | 0.21        | 01           |
| 3      | 0.16        | 101          |
| 4      | 0.08        | 1001         |
| 5      | 0.06        | 10001        |
| 6      | 0.03        | 100001       |
| 7      | 0.02        | 100000       |

**Propriété :** Les symboles avec la **plus haute probabilité** ont la **longueur la plus courte**

## Code préfixe

### Définition

**Code préfixe (Prefix code) :**

Aucun code n'est le **préfixe** d'un autre code

### Importance du code préfixe

Pourquoi est-ce important ?

1. Pour le **décodage unique** à partir d'une chaîne sans besoin de voir le symbole suivant
2. Le code préfixe peut être décodé **instantanément**

### Exemple comparatif

**Code A (NON préfixe) :**

| Symbole | Code |
|---------|------|
| 1       | 1    |
| 2       | 00   |
| 3       | 11   |
| 4       | 110  |

**Code B (préfixe) :**

| Symbole | Code |
|---------|------|
| 1       | 0    |
| 2       | 10   |
| 3       | 110  |
| 4       | 111  |

**Exemple d'encodage : 1234321**

- **Code A** : 100011110110010 → Pas de décodage unique
- **Code B** : 010110111110100 → Décodage unique

## Entropie jointe (Joint Entropy)

### Définition

Entropie jointe de deux variables discrètes :

Soit  $X \in \mathcal{X} = \{x_1, x_2, \dots, x_n\}$  et  $Y \in \mathcal{Y} = \{y_1, y_2, \dots, y_m\}$

$$H(X, Y) = - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p_{X,Y}(x, y) \log_2 p_{X,Y}(x, y)$$

Forme espérance :

$$H(X, Y) = -\mathbb{E}_{p_{X,Y}}[\log p_{X,Y}(x, y)]$$

Propriété de symétrie

$$H(X, Y) = H(Y, X)$$

---

## Entropie conditionnelle (Conditional Entropy)

### Définition

Entropie conditionnelle de  $X$  sachant  $Y$  :

$$H(X|Y) = \sum_{y \in \mathcal{Y}} p_Y(y) H(X|Y = y)$$

Forme développée :

$$H(X|Y) = - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p_{X,Y}(x, y) \log p_{X|Y}(x|y)$$

### Entropie conditionnelle pour une valeur fixée

Pour  $Y = y$  fixé :

$$H(X|Y = y) = - \sum_{i=1}^n p_{X|Y}(x_i|y) \log p_{X|Y}(x_i|y)$$

### Développement complet

$$\begin{aligned} H(X|Y) &= - \sum_{j=1}^m p_Y(y_j) \left[ \sum_{i=1}^n p_{X|Y}(x_i|y_j) \log p_{X|Y}(x_i|y_j) \right] \\ &= - \sum_{i=1}^n \sum_{j=1}^m p_{X,Y}(x_i, y_j) \log p_{X|Y}(x_i|y_j) \end{aligned}$$

### Asymétrie

Attention :

$$H(X|Y) \neq H(Y|X)$$

L'entropie conditionnelle n'est **pas symétrique**

---

### Propriétés de l'entropie

#### Propriété 1 : Non-négativité

Entropie strictement positive :

$$H(X) \geq 0$$

$$H(X, Y) \geq 0$$

$$H(X|Y) \geq 0$$

**Justification :**

$$0 \leq p_X(x) \leq 1 \quad \Rightarrow \quad \log p_X(x) \leq 0$$

$$\Rightarrow \quad 0 \leq - \sum p_X(x) \log p_X(x)$$

De même pour  $p_{X,Y}(x,y)$  et  $p_{X|Y}(x|y)$

---

**Propriété 2 : Règle de chaîne pour l'entropie**

**Cas de 2 variables :**

$$p(x,y) = p(x|y)p(y) = p(y|x)p(x)$$

**Entropie jointe :**

$$H(X,Y) = H(X|Y) + H(Y) = H(Y|X) + H(X)$$

**Démonstration :**

$$-\log p_{X,Y}(x,y) = -\log[p_{Y|X}(y|x)p_X(x)] = -\log p_{Y|X}(y|x) - \log p_X(x)$$

$$H(X,Y) = \mathbb{E}_{p_{X,Y}}[-\log p_{X,Y}(x,y)] = \mathbb{E}_{p_{X,Y}}[-\log p_X(x)] + \mathbb{E}_{p_{X,Y}}[-\log p_{Y|X}(y|x)]$$

$$= H(X) + H(Y|X)$$

**Cas général de N variables :**

$$p(x_1, \dots, x_N) = p(x_1) \prod_{i=2}^N p(x_i | x_{i-1}, \dots, x_1)$$

$$H(X_1, X_2, \dots, X_N) = \sum_{i=1}^N H(X_i | X_{i-1}, \dots, X_1)$$

**Conséquence pour variables indépendantes :**

$$H(X_1, X_2) \leq H(X_1) + H(X_2)$$

Égalité si et seulement si les variables sont **indépendantes**

---

**Application à un vecteur d'image**

**Représentation vectorielle :**

$$X = p_x(x) = p_x(x_1, x_2, \dots, x_N)$$

$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_N \end{pmatrix}$$

**Modèle de Markov d'ordre 2 :**

$$p(x_i | x_{i-1}, x_{i-2})$$

**Entropie totale :**

$$H(X_1, X_2, \dots, X_N) = \sum_{i=1}^N H(X_i | X_{i-1}, \dots, X_1)$$

**Pour variables indépendantes :**

$$H(X_1, X_2, \dots, X_N) = \sum_{i=1}^N H(X_i)$$

---

### Propriété 3 : Augmentation de l'entropie par ajout de variables

#### Principe :

Ajouter une nouvelle variable aléatoire **augmente** l'entropie

$$H(X) \leq H(X, Y) \leq H(X, Y, Z) \leq \dots$$

#### Conditions d'égalité :

$$H(X) = H(X, Y) \Leftrightarrow Y = f(X)$$

(Y est une fonction déterministe de X)

$$H(X, Y) = H(X, Y, Z) \Leftrightarrow Z = f(X, Y)$$

#### Décomposition :

$$H(X, Y) = H(X) + H(Y|X)$$

où  $H(Y|X) \geq 0$

---

### Propriété 4 : Conditionnement réduit l'entropie

#### Principe fondamental :

Le conditionnement **réduit** (ou laisse inchangée) l'entropie

$$H(X) \geq H(X|Y) \geq H(X|Y, Z) \geq \dots$$

#### Conditions d'égalité :

$$H(X) = H(X|Y) \Leftrightarrow X \perp Y$$

(X et Y sont indépendants)

$$H(X|Y) = H(X|Y, Z) \Leftrightarrow X \perp Z|Y$$

( $X$  et  $Z$  sont conditionnellement indépendants sachant  $Y$ )

**Intuition :** Connaître  $Y$  ne peut que **réduire l'incertitude** sur  $X$

---

### Propriété 5 : Entropie maximale pour distribution uniforme

**Théorème :**

$$H(X) \leq \log_2 |\mathcal{X}|$$

**Condition d'égalité :**

Égalité si et seulement si  $X$  suit une **distribution uniforme** :

$$\mathbb{P}[X = x_i] = \frac{1}{N} = \frac{1}{|\mathcal{X}|}$$

**Démonstration :**

Soit  $\mathcal{X} = \{x_1, x_2, \dots, x_N\}$  et  $\mathbb{P}[X = x_i] = p_i$

$$\begin{aligned} H(X) &= - \sum_{x \in \mathcal{X}} \mathbb{P}[X = x] \log_2 \mathbb{P}[X = x] \\ &= -(p_1 \log_2 p_1 + p_2 \log_2 p_2 + \dots + p_N \log_2 p_N) \end{aligned}$$

**Objectif :**

Trouver la distribution  $\{p_i\}_{i=1}^N$  qui maximise  $H(X)$  sous la contrainte  $\sum p_i = 1$

**Résultat :**

La distribution uniforme  $p_i = 1/N$  maximise l'entropie

---

## Divergence de Kullback-Leibler (KLD)

### Définition

#### Entropie relative ou divergence KL :

Entre deux pmfs  $p(x)$  et  $q(x)$  :

$$D_{KL}(p\|q) = D(p\|q) = \sum_{x \in \mathcal{X}} p(x) \log_2 \frac{p(x)}{q(x)} = \mathbb{E}_{p(x)} \left[ \log_2 \frac{p(x)}{q(x)} \right]$$

### Conventions

#### Valeurs limites :

$$0 \log_2 \frac{0}{q(x)} = 0, \quad \forall q(x)$$

$$p(x) \log_2 \frac{p(x)}{0} = +\infty, \quad \forall p(x) > 0$$

### Propriétés fondamentales

#### Asymétrie :

$$D(p\|q) \neq D(q\|p)$$

La KLD n'est **pas une distance** (pas symétrique, ne vérifie pas l'inégalité triangulaire)

#### Non-négativité :

$$D(p\|q) \geq 0$$

avec égalité si et seulement si  $p(x) = q(x)$  pour tout  $x$

---

## Interprétation pratique de la KLD

### Problème de codage avec mauvaise distribution

Situation :

- Distribution réelle des données :  $p(x)$  (inconnue)
- Distribution supposée pour le codage :  $q(x)$

Longueur de code :

Pour  $q(x)$  :  $\ell_q(x) = -\log q(x)$

Pour  $p(x)$  :  $\ell_p(x) = -\log p(x)$

Longueur moyenne attendue :

Si on utilise le code conçu pour  $q(x)$  pour coder des données de  $p(x)$  :

$$\ell_{av}^q = \mathbb{E}_{X \sim p(x)}[\ell_q(X)] = \sum_x p(x) \cdot (-\log q(x))$$

### Décomposition de la longueur moyenne

$$\begin{aligned}\ell_{av}^q &= \sum_x p(x) \cdot (-\log q(x)) \\&= \sum_x p(x) \left( -\log \frac{p(x)}{q(x)} \cdot \frac{1}{p(x)} \right) \\&= \sum_x p(x) \log \frac{p(x)}{q(x)} + \sum_x p(x) \log \frac{1}{p(x)} \\&= D(p(x) \| q(x)) + H(p(x))\end{aligned}$$

Formule fondamentale :

$$\mathbb{E}_{X \sim p(x)}[\ell_q(X)] = H(p(x)) + D(p(x) \| q(x))$$

## Interprétation

### En Machine Learning :

La KLD mesure le niveau de **similarité** entre deux distributions

### En théorie du codage :

La KLD mesure l'**inefficacité** du codage conçu pour la pmf  $q(x)$  alors que les données proviennent de la pmf  $p(x)$

### Bits supplémentaires :

$$D(p(x)\|q(x))$$

représente les **bits extra** nécessaires en moyenne

### Condition optimale :

$$D(p(x)\|q(x)) = 0 \quad \Leftrightarrow \quad p(x) = q(x)$$

---

## Exemple numérique de KLD

### Configuration

#### Variables binaires :

$$x \in \mathcal{X} = \{0, 1\}$$

- $p(0) = a, p(1) = 1 - a$
- $q(0) = b, q(1) = 1 - b$

### Formules

$$D(p\|q) = \sum_{x \in \mathcal{X}} p(x) \log_2 \frac{p(x)}{q(x)} = a \log_2 \frac{a}{b} + (1 - a) \log_2 \frac{1 - a}{1 - b}$$

$$D(q\|p) = \sum_{x \in \mathcal{X}} q(x) \log_2 \frac{q(x)}{p(x)} = b \log_2 \frac{b}{a} + (1 - b) \log_2 \frac{1 - b}{1 - a}$$

### Calcul avec valeurs spécifiques

Paramètres :

$$a = 1/4, b = 1/8$$

$$D(p\|q) = \frac{1}{4} \log_2 \frac{8}{4} + \left(1 - \frac{1}{4}\right) \log_2 \frac{1 - 1/4}{1 - 1/8} = 0.0832 \text{ bit}$$

$$D(q\|p) = \frac{1}{8} \log_2 \frac{4}{8} + \left(1 - \frac{1}{8}\right) \log_2 \frac{1 - 1/8}{1 - 1/4} = 0.0696 \text{ bit}$$

Vérification :

$$D(p\|q) \neq D(q\|p)$$

---

### Cross-Entropy (Entropie croisée)

Définition

Entropie croisée entre pmfs  $p(x)$  et  $q(x)$  :

$$H(p, q) = - \sum_{x \in \mathcal{X}} p(x) \log q(x) = -\mathbb{E}_{p(x)}[\log q(x)]$$

Lien avec la KLD

Relation fondamentale :

$$H(p, q) = H(p) + D_{KL}(p\|q)$$

Démonstration :

$$\begin{aligned} D_{KL}(p\|q) &= \mathbb{E}_{p(x)} \left[ \log \frac{p(x)}{q(x)} \right] = \mathbb{E}_{p(x)}[\log p(x)] - \mathbb{E}_{p(x)}[\log q(x)] \\ &= -H(p) + H(p, q) \end{aligned}$$

## Propriété d'optimisation

### Remarque importante :

Puisque  $H(p)$  est **constant** (ne dépend pas de  $q$ ), optimiser  $H(p, q)$  par rapport à  $q(x)$  est **équivalent** à optimiser  $D_{KL}(p\|q)$

$$\min_q H(p, q) \Leftrightarrow \min_q D_{KL}(p\|q)$$

### Application en Machine Learning :

La cross-entropy est largement utilisée comme **fonction de perte** dans les réseaux de neurones pour la classification

---

## Information mutuelle (Mutual Information)

### Définition

Information mutuelle entre deux variables aléatoires  $X$  et  $Y$  :

$$I(X; Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p_{X,Y}(x, y) \log \frac{p_{X,Y}(x, y)}{p_X(x)p_Y(y)}$$

Forme espérance :

$$I(X; Y) = \mathbb{E}_{p_{X,Y}(x,y)} \left[ \log \frac{p_{X,Y}(x,y)}{p_X(x)p_Y(y)} \right]$$

Forme alternative

$$I(X; Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p_{X,Y}(x, y) \log \frac{p_{X|Y}(x|y)}{p_X(x)} \cdot p_Y(y)$$

## Propriétés fondamentales

Symétrie :

$$I(X; Y) = I(Y; X)$$

Non-négativité :

$$I(X; Y) \geq 0$$

Condition d'annulation :

$$I(X; Y) = 0 \quad \Leftrightarrow \quad X \perp Y$$

(si et seulement si  $X$  et  $Y$  sont indépendants)

---

## Information mutuelle via KL-divergence

Formulation en termes de KLD

Information mutuelle comme divergence KL :

$$I(X; Y) = D_{KL}(p_{X,Y}(x, y) \| p_X(x)p_Y(y))$$

$$= \mathbb{E}_{p_{X,Y}(x,y)} \left[ \log \frac{p_{X,Y}(x,y)}{p_X(x)p_Y(y)} \right]$$

## Interprétation

**L'information mutuelle mesure :**

À quel point la distribution jointe  $p_{X,Y}(x, y)$  diffère du produit des marginales  $p_X(x)p_Y(y)$

**Autrement dit :**

Mesure la **dépendance** entre  $X$  et  $Y$  par rapport à l'hypothèse d'**indépendance**

**Attention aux notations :**

Équivalence :  $p_{X,Y}(x, y) = p(x, y)$

## Formes conditionnelles

$$I(X; Y) = \mathbb{E}_{p(y)}[D_{KL}(p(x|y) \| p(x))]$$

$$I(X; Y) = \mathbb{E}_{p(x)}[D_{KL}(p(y|x) \| p(y))]$$

---

## Relations entre information mutuelle et entropie

### Relations fondamentales

Relation 1 :

$$I(X; Y) = H(X) - H(X|Y)$$

Relation 2 :

$$I(X; Y) = H(Y) - H(Y|X)$$

Relation 3 :


$$I(X; Y) = H(X) + H(Y) - H(X, Y)$$

Cas particulier :

$$I(X; X) = H(X)$$

car  $H(X|X) = 0$

## Diagramme de Venn des entropies



### Lecture du diagramme :

- $H(X, Y)$  : entropie jointe (tout le rectangle)
  - $I(X; Y)$  : information mutuelle (intersection)
  - $H(X|Y)$  : entropie de  $X$  sachant  $Y$  (partie gauche uniquement)
  - $H(Y|X)$  : entropie de  $Y$  sachant  $X$  (partie droite uniquement)
- 

## Information mutuelle conditionnelle

### Définition

Information mutuelle entre  $X$  et  $Y$  sachant  $Z$  :

$$I(X; Y|Z) = H(X|Z) - H(X|Y, Z)$$

Forme avec KL-divergence :

$$\begin{aligned} I(X; Y|Z) &= \mathbb{E}_{p(x, y, z)} \left[ \log \frac{p_{X, Y|Z}(x, y|z)}{p_{X|Z}(x|z)p_{Y|Z}(y|z)} \right] \\ &= \mathbb{E}_{p(x, y, z)} \left[ \log \frac{p_{X|Y, Z}(x|y, z)}{p_{X|Z}(x|z)} \right] \end{aligned}$$

### Démonstration

$$p_{X,Y|Z}(x, y|z) = p_{Y|Z}(y|z) \cdot p_{X|Y,Z}(x|y, z)$$

$$\begin{aligned} I(X; Y|Z) &= \mathbb{E}_{p(x,y,z)}[\log p_{X|Y,Z}(x|y, z)] - \mathbb{E}_{p(x,y,z)}[\log p_{X|Z}(x|z)] \\ &= -H(X|Y, Z) + H(X|Z) \end{aligned}$$

---

### Propriétés de l'information mutuelle

#### Information mutuelle conditionnelle

Diagramme :

$$\begin{array}{ccc} H(X|Z) & & H(Y|Z) \\ & \searrow & \swarrow \\ & I(X; Y|Z) & \end{array}$$

$$I(X; Y|Z) = H(X|Z) - H(X|Y, Z)$$

---

### Règle de chaîne pour l'information mutuelle

Pour N variables :

$$I(X_1, X_2, \dots, X_N; Y) = \sum_{i=1}^N I(X_i; Y|X_{i-1}, \dots, X_1)$$

Démonstration :

$$I(X_1, X_2, \dots, X_N; Y) = H(X_1, X_2, \dots, X_N) - H(X_1, X_2, \dots, X_N | Y)$$

$$\begin{aligned} &= \sum_{i=1}^N H(X_i | X_{i-1}, \dots, X_1) - \sum_{i=1}^N H(X_i | X_{i-1}, \dots, X_1, Y) \\ &= \sum_{i=1}^N I(X_i; Y | X_{i-1}, \dots, X_1) \end{aligned}$$

### **Application : Pixels d'image et label**

**Configuration :**

$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_N \end{pmatrix} \in \mathcal{X}^N$$

représente une image de  $N = n \times m$  pixels

$$Y \in \mathcal{Y}$$

représente un label

**Information mutuelle totale :**

$$I(X_1, X_2, \dots, X_N; Y) = \sum_{i=1}^N I(X_i; Y | X_{i-1}, \dots, X_1)$$


---

## Décomposition complexe

Exemple avec 2 variables et 2 labels :

$$I(X_1, X_2; Y_1, Y_2) = I(X_1; Y_1, Y_2) + I(X_2; Y_1, Y_2 | X_1)$$

Décomposition de  $I(X_1; Y_1, Y_2)$  :

$$I(X_1; Y_1, Y_2) = I(X_1; Y_1) + I(X_1; Y_2 | Y_1) = I(X_1; Y_2) + I(X_1; Y_1 | Y_2)$$

Décomposition de  $I(X_2; Y_1, Y_2 | X_1)$  :

$$I(X_2; Y_1, Y_2 | X_1) = I(X_2; Y_1 | X_1) + I(X_2; Y_2 | X_1, Y_1)$$

$$= I(X_2; Y_2 | X_1) + I(X_2; Y_1 | X_1, Y_2)$$

---

## Inégalité de traitement des données

Chaîne de Markov

Configuration :



$$p_{X,Y,Z}(x, y, z) = p_X(x) \cdot p_{Y|X}(y|x) \cdot p_{Z|Y}(z|y)$$

Notation :  $X \rightarrow Y \rightarrow Z$

## Inégalité fondamentale

Deux inégalités valides :

$$I(X; Y) \geq I(X; Z)$$

$$I(Y; Z) \geq I(X; Z)$$

Cas particulier important :

Si  $Z = g(Y)$  (fonction déterministe de  $Y$ ) :

$$I(X; Y) \geq I(X; Z)$$

## Interprétation

**Principe de non-créativité de l'information :**

La quantité d'information **ne peut pas être augmentée** par un traitement quelconque

**Ceci inclut les réseaux de neurones profonds !**

L'information mutuelle entre l'entrée et la sortie d'un réseau ne peut qu'être **inférieure ou égale** à l'information mutuelle entre l'entrée et les couches intermédiaires

---

## Démonstration de l'inégalité

En utilisant la règle de chaîne :

$$I(X; Y, Z) = I(X; Z) + I(X; Y|Z) \quad (\text{a})$$

$$I(X; Y, Z) = I(X; Y) + I(X; Z|Y) \quad (\text{b})$$

**Propriété clé :**

Pour la chaîne de Markov  $X \rightarrow Y \rightarrow Z$  :

$$X \perp Z|Y \Rightarrow I(X; Z|Y) = 0$$

**Donc de (b) :**

$$I(X; Y, Z) = I(X; Y)$$

**En combinant avec (a) :**

$$I(X; Y) = I(X; Z) + I(X; Y|Z)$$

**Conclusion :**

$$I(X; Y) \geq I(X; Z)$$

car  $I(X; Y|Z) \geq 0$

---

## **Variables continues : Entropie différentielle**

### **Motivation**

**Pour variables discrètes :**

$$P[x_k; \Delta x] = \int f_X(x) dx \approx f_X(x_k) \Delta x$$

**Entropie avec quantification :**

$$\begin{aligned} H(X; \Delta x) &= - \sum_{i=1}^N P[x_k; \Delta x] \log_2 P[x_k; \Delta x] \\ &= - \sum_{i=1}^N f_X(x_k) \Delta x \log_2 [f_X(x_k) \Delta x] \end{aligned}$$

## Décomposition

$$\begin{aligned} H(X; \Delta x) &= - \sum_{i=1}^N f_X(x_k) \Delta x \log_2 f_X(x_k) - \sum_{i=1}^N f_X(x_k) \Delta x \log_2 \Delta x \\ &= - \sum_{i=1}^N f_X(x_k) \Delta x \log_2 f_X(x_k) - \log_2 \Delta x \underbrace{\sum_{i=1}^N f_X(x_k) \Delta x}_{=1} \end{aligned}$$

Passage à la limite :

$$H(X; \Delta x) = - \int f_X(x) \log_2 f_X(x) dx - \log_2 \Delta x$$

## Problème avec la limite

Dans la limite  $\Delta x \rightarrow 0$  :

$\Delta x$  tend vers zéro pour un grand  $N$

Conséquence :

$$\log_2 \Delta x \rightarrow -\infty$$

$$\text{Donc } H(X; \Delta x) \rightarrow +\infty$$

---

## Définition de l'entropie différentielle

### Définition formelle

Entropie différentielle d'une v.a. continue  $X$  avec pdf  $f_X(x)$  :

$$h(X) = - \int_x f_X(x) \log_2 f_X(x) dx = -\mathbb{E}_{f_X}[\log_2 f_X(x)]$$

Attention :

- Notation différente :  $h(X)$  au lieu de  $H(X)$
  - Peut être **négative** (contrairement à l'entropie discrète)
  - N'a pas d'interprétation directe en termes de bits
-

## Entropie différentielle d'une gaussienne

### Variable gaussienne

Distribution :

$$X \sim \mathcal{N}(0, \sigma_X^2)$$

Entropie différentielle :

$$h(X) = -\mathbb{E}_{f_X}[\log_2 f_X(x)] = \frac{1}{2} \log_2(2\pi e \sigma_X^2)$$

### Démonstration

PDF gaussienne :

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma_X^2}} \exp\left(-\frac{x^2}{2\sigma_X^2}\right)$$

Calcul de l'entropie :

$$\begin{aligned} h(X) &= - \int f_X(x) \ln f_X(x) dx \quad [\text{nats}] \\ &= - \int f_X(x) \left[ -\frac{x^2}{2\sigma_X^2} - \ln(\sqrt{2\pi\sigma_X^2}) \right] dx \\ &= \int_{-\infty}^{\infty} f_X(x) \frac{x^2}{2\sigma_X^2} dx + \ln(\sqrt{2\pi\sigma_X^2}) \underbrace{\int_{-\infty}^{\infty} f_X(x) dx}_{=1} \end{aligned}$$

Calcul de la première intégrale :

$$\int_{-\infty}^{\infty} f_X(x) \frac{x^2}{2\sigma_X^2} dx = \frac{1}{2\sigma_X^2} \underbrace{\int_{-\infty}^{\infty} x^2 f_X(x) dx}_{=\text{Var}[X]=\sigma_X^2} = \frac{\sigma_X^2}{2\sigma_X^2} = \frac{1}{2}$$

Résultat en nats :

$$h(X) = \frac{1}{2} + \ln(\sqrt{2\pi\sigma_X^2}) = \frac{1}{2} \ln e + \frac{1}{2} \ln(2\pi\sigma_X^2)$$

$$= \frac{1}{2} [\ln e + \ln(2\pi\sigma_X^2)] = \frac{1}{2} \ln(2\pi e\sigma_X^2) \quad [\text{nats}]$$

**Conversion en bits :**

$$h(X) = \frac{1}{2} \log_2(2\pi e\sigma_X^2) \quad [\text{bits}]$$


---

## Propriétés de l'entropie différentielle

### Propriété 1 : Invariance par translation

**Translation :**

$$h(X + a) = h(X)$$

où  $a$  est une constante scalaire

**Interprétation :** Décaler une distribution ne change pas son entropie différentielle

### Propriété 2 : Effet de la mise à l'échelle

**Pour variable scalaire :**

Si  $X$  est une variable aléatoire scalaire :

$$h(aX) = h(X) + \log |a|$$

**Pour variable vectorielle :**

Si  $X$  est un vecteur aléatoire et  $A$  est une matrice :

$$h(AX) = h(X) + \log |\det(A)|$$

où  $\det(A)$  est le **déterminant** de la matrice  $A$

**Interprétation :**

- Étirer la distribution (facteur  $|a| > 1$ ) **augmente** l'entropie
  - Compresser la distribution (facteur  $|a| < 1$ ) **diminue** l'entropie
- 

## Concepts mathématiques à maîtriser

### Théorie de l'information

#### Concepts fondamentaux :

- Entropie (discrète et différentielle)
- Entropie jointe et conditionnelle
- Information mutuelle
- Divergence KL
- Cross-entropy

#### Relations :

- Règle de chaîne pour entropie
- Relations entre  $H(X)$ ,  $H(Y)$ ,  $H(X, Y)$ ,  $I(X; Y)$
- Inégalité de traitement des données

### Probabilités

#### Distributions :

- Distribution discrète vs continue
- Distribution uniforme
- Distribution gaussienne

#### Concepts :

- Indépendance
- Conditionnement
- Marginalisation

## **Codage et compression**

### **Théorie du codage :**

- Longueur de code optimale
  - Code préfixe
  - Codage de Huffman
  - Taux de compression
- 

## **Questions d'examen types**

### **Questions conceptuelles**

#### **Entropie :**

- Définir l'entropie et expliquer son interprétation
- Quelle distribution maximise l'entropie ?
- Différence entre entropie et entropie différentielle

#### **Relations :**

- Relation entre  $H(X, Y)$ ,  $H(X)$ , et  $H(Y|X)$
- Qu'est-ce que l'information mutuelle ?
- Pourquoi  $H(X|Y) \leq H(X)$  ?

#### **KLD et cross-entropy :**

- Définir la divergence KL
- Interprétation en termes de codage
- Lien entre KLD et cross-entropy

### **Questions techniques**

#### **Calculs :**

- Calculer l'entropie d'une distribution binaire
- Calculer la KLD entre deux distributions
- Calculer l'information mutuelle entre deux variables

#### **Codage :**

- Appliquer l'algorithme de Huffman
- Calculer la longueur moyenne d'un code
- Qu'est-ce qu'un code préfixe et pourquoi est-il important ?

#### Propriétés :

- Démontrer la règle de chaîne pour l'entropie
- Démontrer l'inégalité de traitement des données
- Prouver que  $I(X; Y) \geq 0$

#### Démonstrations mathématiques

#### Propriétés de l'entropie :

- Montrer que le conditionnement réduit l'entropie
- Prouver que la distribution uniforme maximise l'entropie
- Démontrer la règle de chaîne pour l'information mutuelle

#### Variables continues :

- Calculer l'entropie différentielle d'une gaussienne
- Effet de la mise à l'échelle sur l'entropie différentielle

---

### Applications en Machine Learning

#### Fonctions de perte

#### Cross-entropy comme loss :

Utilisée en classification pour minimiser la divergence entre :

- Distribution prédite par le modèle :  $q(y|x)$
- Distribution vraie (one-hot) :  $p(y|x)$

$$\mathcal{L} = - \sum_i p(y_i) \log q(y_i)$$

## Sélection de features

### Information mutuelle :

Mesurer  $I(X_i; Y)$  pour sélectionner les features les plus informatives

### Critère :

Garder les features avec  $I(X_i; Y)$  élevée

## Régularisation

### Variational AutoEncoders (VAE) :

Minimiser la KLD entre :

- Distribution encodée  $q(z|x)$
- Prior  $p(z)$  (souvent gaussien)

$$\mathcal{L}_{KL} = D_{KL}(q(z|x) \| p(z))$$

---

## Résumé des formules clés

### Entropie

$$H(X) = - \sum_x p(x) \log p(x)$$

$$H(X, Y) = - \sum_x \sum_y p(x, y) \log p(x, y)$$

$$H(X|Y) = - \sum_x \sum_y p(x, y) \log p(x|y)$$

## Relations

$$H(X, Y) = H(X) + H(Y|X) = H(Y) + H(X|Y)$$

$$H(X|Y) \leq H(X)$$

$$H(X, Y) \leq H(X) + H(Y)$$

## Information mutuelle

$$I(X; Y) = H(X) - H(X|Y) = H(Y) - H(Y|X)$$

$$I(X; Y) = H(X) + H(Y) - H(X, Y)$$

$$I(X; Y) = D_{KL}(p(x, y) \| p(x)p(y))$$

## KLD et Cross-entropy

$$D_{KL}(p \| q) = \sum_x p(x) \log \frac{p(x)}{q(x)}$$

$$H(p, q) = - \sum_x p(x) \log q(x)$$

$$H(p, q) = H(p) + D_{KL}(p \| q)$$