

Table of contents

Représentations en Haute Dimension en Data Science	2
La malédiction et la bénédiction de la dimension	2
Introduction à la Data Science en haute dimension	2
Qu'est-ce que la Data Science ?	2
Relation avec le Machine Learning	3
Flux typique de données	3
Propriétés des espaces de représentation	4
La Malédiction de la Dimension	4
Comprendre le phénomène	4
Sphère vide et cube "épineux"	4
Le paradoxe de la sphère en haute dimension	4
Interprétation intuitive	5
Distribution du volume : "l'œuf gaussien"	5
Concentration gaussienne en haute dimension	5
Visualisation du phénomène	6
Concentration des distances	7
Le théorème de Beyer et al.	7
Implications pratiques	7
Quasi-orthogonalité	7
Concentration des angles	7
Impact sur la sphère unité	8
Hubness : le phénomène des "hubs"	8
Définition et mécanisme	8
Implications négatives	9
Inégalités de concentration	9
Outils théoriques fondamentaux	9
La Bénédiction de la Dimension	10
Aspects positifs de la haute dimension	10
Lois des grands nombres	10
Loi faible des grands nombres	10
Implications importantes	11
Projections aléatoires	11
Le lemme de Johnson-Lindenstrauss	11
Applications pratiques	12
Importance en Data Science	12
Impact sur les méthodes pratiques	12
Échantillonnage	12
Défis principaux	12

Indexation et recherche	13
Problèmes des structures spatiales	13
Faut-il abandonner la Data Science en haute dimension ?	14
Pourquoi les méthodes fonctionnent quand même	14
Stratégies pour surmonter la malédiction	14
Synthèse et conclusions	14
Points clés à retenir	14
Bilan équilibré	15
Questions d’approfondissement	15
Perspectives futures	16

Représentations en Haute Dimension en Data Science

La malédiction et la bénédiction de la dimension

Introduction à la Data Science en haute dimension

La Data Science consiste à modéliser des phénomènes sous forme de données numériques, à comprendre les propriétés géométriques et statistiques de ces données, et à développer des outils pour les analyser.

Qu’est-ce que la Data Science ?

La Data Science implique :

- La modélisation de phénomènes en données numériques quantitatives
 - La compréhension des propriétés géométriques et statistiques des données
 - L’analyse de l’espace dans lequel ces données existent
 - Le développement d’outils d’analyse avec compréhension de leurs hypothèses sous-jacentes
-


Relation avec le Machine Learning

La Data Science et le Machine Learning sont étroitement liés :

- **Data Science** : étude des espaces de représentation
- **Machine Learning** : opérations dans ces espaces de représentation

Les deux domaines sont complémentaires et souvent synonymes dans la pratique.

Flux typique de données



Propriétés des espaces de représentation

L'espace de représentation Ω est généralement un sous-ensemble de $\mathbb{R}^D$ où D est la dimension.

Cet espace possède plusieurs propriétés importantes :

- C'est un espace vectoriel qui peut être muni d'un produit scalaire
- Le produit scalaire $\langle \cdot, \cdot \rangle$ induit une norme $\| \cdot \|$
- La norme induit une distance $d(\cdot, \cdot)$
- (Ω, d) forme un espace métrique où l'apprentissage est possible

Questions fondamentales :

- Que se passe-t-il quand D augmente ?
- Quel impact sur la modélisation des données ?
- Comment cela affecte-t-il l'apprentissage ?

Ces questions mènent au concept de **malédiction de la dimension**.

La Malédiction de la Dimension

Comprendre le phénomène

En dimension élevée, notre intuition géométrique basée sur les dimensions 2D et 3D devient trompeuse. Des phénomènes contre-intuitifs émergent.

Sphère vide et cube "épineux"

Le paradoxe de la sphère en haute dimension

Considérons une hypersphère $B_D(r)$ de rayon r centrée à l'origine, inscrite dans un hypercube $C_D(r) = [-r, r]^D$.

Le volume de l'hypersphère est donné par :

$$\text{vol}(B_D(r)) = \frac{2r^D \pi^{D/2}}{D\Gamma(D/2)}$$

Le volume de l'hypercube est :

$$\text{vol}(C_D(r)) = (2r)^D$$

Le ratio volume sphère/volume cube décroît rapidement avec D :

$$\text{Ratio} = \frac{\text{vol}(B_D(r))}{\text{vol}(C_D(r))} = \frac{\pi^{D/2}}{D2^{D-1}\Gamma(D/2)}$$

Le résultat surprenant :

$$\lim_{D \rightarrow \infty} \frac{\text{vol}(B_D(r))}{\text{vol}(C_D(r))} = 0$$

Interprétation intuitive

Imaginez que vous tirez des points au hasard uniformément dans le cube :

- En dimension 2, environ 78.5% des points tombent dans le cercle inscrit
- En dimension 3, ce pourcentage descend à environ 52.4%
- En dimension 10, il n'est plus que de 0.025%
- En dimension 100, il est infinitésimal

Conséquence pratique : Si vous échantillonnez uniformément dans un hypercube, la sphère inscrite sera essentiellement vide. Le volume se concentre dans les “coins” du cube.

Distribution du volume : “l'œuf gaussien”

Concentration gaussienne en haute dimension

Pour une distribution normale $N(\mu, \Sigma)$ en dimension D , considérons la densité le long d'un rayon r .

Si les coordonnées sont des variables aléatoires i.i.d. $X_i \sim N(0, 1)$, alors :


$$R^2 = \|X\|_2^2 = \sum_{i=1}^D X_i^2 \sim \chi^2(D)$$

L'espérance de R^2 est :

$$\mathbb{E}[R^2] = D$$

Implication importante : La plupart de la masse de probabilité se concentre sur une coquille sphérique de rayon $\sigma\sqrt{D}$.

Visualisation du phénomène



Concentration des distances

Le théorème de Beyer et al.

Soit un ensemble de données $X \subset \Omega$, un point x et ses k plus proches voisins $V_X^k(x)$. Notons $D_{\min}$ et $D_{\max}$ les distances aux voisins les plus proches et les plus éloignés.

Théorème : Si $\lim_{D \rightarrow \infty} \text{Var} \left(\frac{d(x,y)^p}{\mathbb{E}(d(x,y)^p)} \right) = 0$ pour $0 < p < \infty$, alors pour tout $\varepsilon > 0$:

$$\lim_{D \rightarrow \infty} P \left[\frac{D_{\max} - D_{\min}}{D_{\min}} \leq \varepsilon \right] = 1$$

Implications pratiques

Ce résultat a des conséquences importantes :

1. **Perte de pouvoir discriminant :** Tous les voisins apparaissent à peu près à la même distance
2. **Structures de voisinage sans signification :** Les structures k -NN et ε -NN perdent leur utilité
3. **Difficulté pour les algorithmes :** La discrimination basée sur la distance devient presque impossible

Exemple concret : En classification, si tous les points sont équidistants, distinguer différentes classes par proximité devient très difficile.

Quasi-orthogonalité

Concentration des angles

En haute dimension, les vecteurs aléatoires tendent à être presque orthogonaux.

Pour trois points X, Y, Z tirés indépendamment, l'angle θ entre $(X - Y)$ et $(Z - Y)$ satisfait :

$$\mathbb{E} \cos(\theta) = \frac{1}{2}$$

Ce qui implique $\theta \approx \frac{\pi}{3}$ (60°).

Interprétation : Tout triangle aléatoire en haute dimension est presque équilatéral.

Impact sur la sphère unité

Pour la sphère unité B_D , si X est un point aléatoire sur sa surface :

- Si Y est échantillonné sur la sphère : $\mathbb{E} \cos(\theta) = \frac{1}{2}$ $\theta \approx \frac{\pi}{3}$
- Si Y est échantillonné dans la boule : $\mathbb{E} \cos(\theta) = 0$ $\theta \approx \frac{\pi}{2}$

Conséquence géométrique : Le volume de la sphère est concentré à son équateur, quelle que soit la direction considérée comme “nord”.

Hubness : le phénomène des “hubs”

Définition et mécanisme

En haute dimension, certains points (appelés “hubs”) deviennent les plus proches voisins d’un nombre disproportionné d’autres points.

Pourquoi cela se produit :

- La concentration des distances rend les distances relatives peu discriminantes
 - Certains points se retrouvent par hasard à des distances “moyennes” de beaucoup d’autres points
 - Ces points apparaissent donc fréquemment dans les listes de plus proches voisins
-

Implications négatives

Le phénomène de hubness pose plusieurs problèmes :

1. **Biais dans les algorithmes** : Les hubs dominent les résultats des recherches de voisinage
 2. **Problèmes en classification** : Les hubs peuvent apparaître comme représentants de plusieurs classes
 3. **Difficulté d'interprétation** : Les relations de voisinage deviennent difficiles à interpréter
-

Inégalités de concentration

Outils théoriques fondamentaux

Les inégalités de concentration quantifient comment les mesures se concentrent autour de leur moyenne en haute dimension.

Inégalité de Markov

Pour une variable aléatoire non-négative X :

$$P(X > \epsilon) \leq \frac{\mathbb{E}X}{\epsilon}$$

Intuition : Plus l'espérance est petite, moins il est probable que X dépasse un grand seuil.

Inégalité de Chebyshev

Pour une variable aléatoire de moyenne μ et variance σ^2 :

$$P(|X - \mu| > \epsilon) \leq \frac{\sigma^2}{\epsilon^2}$$

Application : En haute dimension, les distances ont souvent une variance qui diminue, expliquant leur concentration.

Inégalité de Hoeffding

Pour des variables indépendantes $X_i \in [a, b]$:

$$P(|\bar{X} - \mu| > \epsilon) \leq 2e^{-2D\epsilon^2/(b-a)^2}$$

où $\bar{X} = \frac{1}{D} \sum_{i=1}^D X_i$.

Importance : Cette inégalité explique la convergence rapide des moyennes en haute dimension.

La Bénédiction de la Dimension

Aspects positifs de la haute dimension

Contre-intuitivement, la haute dimension offre également des avantages que l'on peut exploiter.

Lois des grands nombres

Loi faible des grands nombres

Pour un ensemble de D variables i.i.d. $\{X_l\}_{l \in [D]}$ avec $\mathbb{E}X_l = \mu$, pour tout $\epsilon > 0$:

$$\lim_{D \rightarrow \infty} P(|\bar{X} - \mu| < \epsilon) = 1$$

où $\bar{X} = \frac{1}{D} \sum_{l=1}^D X_l$.

Implications importantes

1. **Convergence garantie** : Les estimateurs convergent vers leur vraie valeur
2. **Fondement de l'estimation** : Base théorique solide pour l'estimation statistique
3. **Stabilité** : Les résultats deviennent plus stables avec l'augmentation de la dimension

Théorème central limite : La vitesse de convergence est donnée par :

$$Z_D = \frac{\sqrt{D}}{\sigma}(\bar{X} - \mu) \sim N(0, 1)$$

si $\text{Var}(X_l) = \sigma^2$.

Projections aléatoires

Le lemme de Johnson-Lindenstrauss

Énoncé : Étant donné $X \subset \Omega$, il existe une application linéaire $p : \mathbb{R}^D \rightarrow \mathbb{R}^d$ telle que pour tout $0 < \varepsilon < 1$ et pour tous $i, j \in [N]$:

$$(1 - \varepsilon)\|x_i - x_j\| \leq \|p(x_i) - p(x_j)\| \leq (1 + \varepsilon)\|x_i - x_j\|$$

avec :

$$d = O\left(\frac{\log N}{\varepsilon^2}\right)$$

Point crucial : La dimension réduite d ne dépend pas de D !

Applications pratiques

1. **Réduction de dimension efficace** : Réduire la dimension sans perdre trop d'information
2. **Recherche approximative de plus proches voisins** : Méthodes de hachage sensible à la localité (LSH)
3. **Compression** : Stockage et traitement plus efficaces des données

Avantage clé : En exploitant la quasi-orthogonalité des vecteurs en haute dimension, on peut créer des bases aléatoires qui préservent les distances.

Importance en Data Science

Impact sur les méthodes pratiques

La compréhension des phénomènes en haute dimension est cruciale pour concevoir des algorithmes efficaces.

Échantillonnage

Défis principaux

- **Parcimonie des données** : Il faut un nombre exponentiel d'échantillons pour couvrir l'espace
- **Estimation de densité** : Les inégalités de concentration guident la précision des estimateurs
- **Rejet élevé** : Dans des méthodes comme l'échantillonnage par rejet, le taux de rejet approche 100%


Conséquence : Les méthodes d'échantillonnage naïves deviennent impraticables en haute dimension.

Indexation et recherche

Problèmes des structures spatiales

Les structures de partition de l'espace (comme les kd-trees) rencontrent des difficultés :

1. **Disparition de la structure** : Si tous les voisins sont équidistants, la partition perd son sens
2. **Cellules trop grandes** : Pour couvrir l'espace, les cellules doivent atteindre la taille de la sphère englobante
3. **Recherche exhaustive** : La complexité devient $O(N)$ au lieu de $O(\log N)$



Faut-il abandonner la Data Science en haute dimension ?

Pourquoi les méthodes fonctionnent quand même

Contre toute attente, les méthodes de Data Science fonctionnent en pratique malgré la malédiction de la dimension :

1. **Les données réelles ne sont pas uniformes** : Elles occupent des sous-espaces de dimension inférieure
 2. **Les caractéristiques sont corrélées** : L'hypothèse d'indépendance est rarement vraie
 3. **Structure sous-jacente** : Les données vivent souvent sur des variétés de faible dimension
-

Stratégies pour surmonter la malédiction

- **Réduction de dimension** : PCA, autoencodeurs, t-SNE
 - **Sélection de caractéristiques** : Identifier les dimensions pertinentes
 - **Apprentissage de métriques** : Apprendre une distance adaptée aux données
 - **Méthodes spécifiques** : Conçues pour la haute dimension (comme les forêts d'isolement)
-

Synthèse et conclusions

Points clés à retenir

1. **La géométrie change radicalement** : Notre intuition 2D/3D ne s'applique pas
 2. **Les données deviennent clairsemées** : Nécessité d'échantillons exponentiels
 3. **Les distances se concentrent** : Tous les points semblent équidistants
 4. **La quasi-orthogonalité émerge** : Les directions aléatoires sont presque orthogonales
 5. **Le phénomène de hubness apparaît** : Certains points dominent les recherches de voisinage
-

Bilan équilibré

Malédiction :

- Difficultés pour l'échantillonnage, l'indexation, la recherche
- Perte de pouvoir discriminant
- Nécessité d'énormes quantités de données

Bénédiction :

- Convergence rapide des estimateurs
 - Possibilité de projections aléatoires efficaces
 - Stabilité statistique améliorée
-

Questions d'approfondissement

1. Conceptuelles :

- Qu'est-ce que la dimension intrinsèque d'un ensemble de données ?
- Comment la malédiction de la dimension affecte-t-elle les méthodes de clustering ?

2. Techniques :

- Comment le lemme de Johnson-Lindenstrauss permet-il de contourner la malédiction ?
- Quelles méthodes sont robustes à la haute dimension ?

3. Pratiques :

- Comment détecter si vos données souffrent de la malédiction de la dimension ?
 - Quelles stratégies adopter face à des données en très haute dimension ?
-

Perspectives futures

La recherche continue sur :

- Les méthodes de réduction de dimension non-linéaire
- Les algorithmes spécialisés pour la haute dimension
- L'apprentissage sur des variétés de faible dimension
- Les approches probabilistes robustes à la dimension

Leçon finale : La haute dimension n'est pas une fatalité, mais elle nécessite une compréhension fine des phénomènes en jeu et des méthodes adaptées.