

Table of contents

Exam question	1
Question	1
Introduction aux phénomènes dimensionnels	1
Première Partie : La Malédiction de la Dimension	2
La Sparsité des Données	2
La Concentration des Mesures	3
Deuxième Partie : La Bénédiction de la Dimension	6
Convergence robuste des estimateurs	6
Projections aléatoires et préservation des distances	7
Quasi-orthogonalité et séparabilité linéaire	7
Robustesse statistique et régularisation implicite	8
Synthèse et Perspectives	9
Dialectique entre malédiction et bénédiction	9
Implications pour la pratique du data science	9
Récapitulatif des fondements théoriques	10
Conclusion	10

Exam question

Question

Expliquez les aspects « parcimonie » et « concentration » de la malédiction de la dimensionnalité, leur justification théorique et leur impact pratique.

Donnez des exemples de bénédiction de la dimensionnalité et expliquez comment ils sont utilisés dans la pratique (vous pouvez rechercher d'autres exemples que ceux présentés dans les cours ou les travaux pratiques).

Introduction aux phénomènes dimensionnels

Le concept de **malédiction de la dimension** décrit les défis qui émergent lorsqu'on travaille avec des données en haute dimension. Cette notion fondamentale en data science présente deux aspects principaux : la **sparsity** (parcimonie) et la **concentration**, chacun ayant des justifications théoriques solides et des implications pratiques importantes.

Curieusement, cette même haute dimension offre également des avantages, regroupés sous le terme de **bénédiction de la dimension**, qui peuvent être exploités dans diverses applications pratiques.

Première Partie : La Malédiction de la Dimension

La Sparsité des Données

Concept fondamental

La **sparsity** fait référence à l'extrême dilution des données dans les espaces de haute dimension. Alors que le volume de l'espace croît exponentiellement avec la dimension, le nombre de points de données reste limité, créant des régions vides immenses.

Justification théorique par le volume exponentiel

Considérons un hypercube unité $[0, 1]^D$. Si nous divisons chaque dimension en k intervalles égaux, nous obtenons k^D cellules. Cette croissance exponentielle signifie que pour maintenir une densité constante de points, nous aurions besoin d'un nombre exponentiel d'échantillons.

Formellement, si nous souhaitons avoir en moyenne au moins un point par cellule :

$$N \geq k^D$$

Pour $D = 100$ et $k = 10$, cela nécessiterait 10^{100} points, ce qui illustre l'impossibilité pratique de remplir uniformément l'espace.

Le paradoxe de la sphère vide

Un résultat particulièrement contre-intuitif concerne le rapport entre le volume d'une hypersphère et celui de l'hypercube qui la contient.

Pour une hypersphère $B_D(r)$ de rayon r centrée à l'origine, inscrite dans un hypercube $C_D(r) = [-r, r]^D$:

Volume de l'hypersphère :

$$\text{vol}(B_D(r)) = \frac{2r^D \pi^{D/2}}{D\Gamma(D/2)}$$

Volume de l'hypercube :

$$\text{vol}(C_D(r)) = (2r)^D$$

Ratio sphère/cube :

$$\frac{\text{vol}(B_D(r))}{\text{vol}(C_D(r))} = \frac{\pi^{D/2}}{D2^{D-1}\Gamma(D/2)}$$

Le résultat clé :

$$\lim_{D \rightarrow \infty} \frac{\text{vol}(B_D(r))}{\text{vol}(C_D(r))} = 0$$

Cette limite montre qu'en haute dimension, presque tout le volume du cube se situe dans ses coins, laissant la sphère centrale essentiellement vide.

Impact pratique de la sparsity

Estimation de densité impossible : Pour estimer une densité de probabilité en dimension D avec une précision donnée, le nombre d'échantillons requis croît exponentiellement, rendant l'estimation non paramétrique impraticable.

Algorithme des k-plus proches voisins inefficace : Les “plus proches” voisins sont en réalité très éloignés, réduisant l'efficacité de cette méthode.

Risque accru de sur-apprentissage : Avec peu de données par rapport au nombre de dimensions, les modèles tendent à capturer le bruit plutôt que le signal sous-jacent.

Problème en recherche d'information : La similarité entre documents représentés par de nombreux termes devient difficile à évaluer de manière fiable.

La Concentration des Mesures

Concept fondamental

La **concentration** désigne le phénomène selon lequel certaines quantités, comme les distances entre points, se concentrent autour de valeurs typiques en haute dimension, perdant ainsi leur pouvoir discriminant.

Justification théorique par le théorème de concentration des distances

Soit un ensemble de données $X \subset \Omega$, un point x et ses k plus proches voisins. Notons $D_{\min}$ et $D_{\max}$ les distances aux voisins les plus proches et les plus éloignés.

Théorème (Beyer et al.) : Si $\lim_{D \rightarrow \infty} \text{Var} \left(\frac{d(x,y)^p}{\mathbb{E}(d(x,y)^p)} \right) = 0$ pour $0 < p < \infty$, alors pour tout $\varepsilon > 0$:

$$\lim_{D \rightarrow \infty} P \left[\frac{D_{\max} - D_{\min}}{D_{\min}} \leq \varepsilon \right] = 1$$

Ce résultat formel montre qu'en haute dimension, toutes les distances entre voisins deviennent relativement similaires, rendant difficile la distinction entre “proche” et “loin”.

Justification par la distribution gaussienne et le théorème central limite

Pour des variables indépendantes et identiquement distribuées (i.i.d.) $X_i \sim N(0, 1)$, considérons la norme euclidienne $R = \|X\|_2$. On a :

$$R^2 = \sum_{i=1}^D X_i^2 \sim \chi^2(D)$$

Ainsi :

$$\mathbb{E}[R^2] = D \quad \text{et} \quad \text{Var}(R^2) = 2D$$

Le coefficient de variation :

$$\frac{\sqrt{\text{Var}(R^2)}}{\mathbb{E}[R^2]} = \frac{\sqrt{2D}}{D} = \sqrt{\frac{2}{D}} \rightarrow 0 \quad \text{quand } D \rightarrow \infty$$

Cette convergence, garantie par la **Loi des Grands Nombres**, explique pourquoi les points gaussiens se concentrent sur une coquille sphérique de rayon $\sqrt{D}$.

Justification par les inégalités de concentration

Inégalité de Hoeffding : Pour des variables aléatoires indépendantes $X_1, \dots, X_D$ telles que $a \leq X_i \leq b$ presque sûrement, et pour tout $\epsilon > 0$:

$$P(|\bar{X} - \mathbb{E}[\bar{X}]| > \epsilon) \leq 2 \exp \left(-\frac{2D\epsilon^2}{(b-a)^2} \right)$$

où $\bar{X} = \frac{1}{D} \sum_{i=1}^D X_i$.

Cette inégalité montre que la moyenne empirique converge exponentiellement vite vers son espérance, ce qui explique la concentration des mesures en haute dimension.

Inégalité de Chebyshev : Pour une variable aléatoire X d'espérance μ et de variance σ^2 :

$$P(|X - \mu| \geq \epsilon) \leq \frac{\sigma^2}{\epsilon^2}$$

Quand la variance relative décroît avec D (comme c'est souvent le cas), la probabilité d'écart à la moyenne diminue.

Impact pratique de la concentration

Perte de discrimination spatiale : Dans les algorithmes de clustering (k-means) et de recherche de similarité, la concentration des distances rend difficile la distinction entre groupes naturels.

Inefficacité des index spatiaux : Les structures d'indexation comme les **k-d trees** nécessitent d'explorer une grande partie de l'espace, conduisant à une complexité proche de $O(N)$.

Phénomène de Hubness : Certains points deviennent des "hubs", apparaissant comme plus proches voisins d'un nombre disproportionné d'autres points, biaisant ainsi les systèmes de recommandation.

Difficulté en classification : Les frontières entre classes deviennent moins nettes lorsque les distances perdent leur pouvoir discriminant.

Deuxième Partie : La Bénédiction de la Dimension

Convergence robuste des estimateurs

Loi des Grands Nombres et Théorème Central Limite

Loi Faible des Grands Nombres : Pour des variables i.i.d. $X_1, \dots, X_D$ d'espérance μ , pour tout $\varepsilon > 0$:

$$\lim_{D \rightarrow \infty} P(|\bar{X} - \mu| < \varepsilon) = 1$$

Cette loi assure que la moyenne empirique converge en probabilité vers l'espérance théorique.

Théorème Central Limite (version multidimensionnelle) : Pour des vecteurs aléatoires i.i.d. $X_1, \dots, X_D$ dans $\mathbb{R}^p$ d'espérance μ et de matrice de covariance Σ , on a :

$$\sqrt{D}(\bar{X}_D - \mu) \xrightarrow{d} N(0, \Sigma) \quad \text{quand } D \rightarrow \infty$$

Ce théorème fournit non seulement la convergence, mais aussi la distribution limite, permettant de construire des intervalles de confiance.

Application pratique : Agrégation de modèles

Les méthodes d'**apprentissage par agrégation** exploitent ces théorèmes. Par exemple, les **forêts aléatoires** combinent de nombreux arbres de décision faiblement corrélés. Chaque arbre est un estimateur peu précis, mais leur moyenne bénéficie de la réduction de variance prédite par le théorème central limite.

Exemple en bioinformatique : Avec des milliers de gènes (dimensions) et seulement des centaines de patients, les forêts aléatoires fournissent des classifieurs robustes pour le diagnostic médical.

Projections aléatoires et préservation des distances

Lemme de Johnson-Lindenstrauss

Énoncé du lemme : Pour tout ensemble X de N points dans $\mathbb{R}^D$ et tout $0 < \varepsilon < 1$, il existe une application linéaire $f : \mathbb{R}^D \rightarrow \mathbb{R}^d$ avec $d = O(\varepsilon^{-2} \log N)$ telle que pour tout $x, y \in X$:

$$(1 - \varepsilon)\|x - y\|^2 \leq \|f(x) - f(y)\|^2 \leq (1 + \varepsilon)\|x - y\|^2$$

La dimension d est **indépendante** de D et ne dépend que logarithmiquement de N .

Preuve intuitive : La preuve utilise des matrices aléatoires dont les entrées sont i.i.d. selon une loi normale, et exploite la concentration des mesures (via l'inégalité de Hoeffding) pour montrer que les distances sont préservées avec haute probabilité.

Application pratique : Réduction de dimension efficace

Recherche approximative de plus proches voisins : Les algorithmes de **Locality-Sensitive Hashing (LSH)** utilisent des projections aléatoires pour indexer rapidement des milliards de points en haute dimension.

Compression de données : Les techniques de **compressed sensing** permettent de reconstruire des signaux à partir de peu de mesures en exploitant la parcimonie naturelle des signaux réels.

Exemple concret : Les systèmes de recommandation de YouTube utilisent des variantes de LSH pour trouver rapidement des vidéos similaires parmi des milliards de possibilités.

Quasi-orthogonalité et séparabilité linéaire

Phénomène de quasi-orthogonalité

En haute dimension, des vecteurs aléatoires tendent à être presque orthogonaux. Pour deux vecteurs aléatoires unitaires u, v sur la sphère en dimension D , la distribution de leur produit scalaire se concentre autour de 0.

Justification par la loi des grands nombres : Si les composantes sont i.i.d. de moyenne nulle, alors $\langle u, v \rangle = \frac{1}{D} \sum_{i=1}^D u_i v_i$ converge vers 0.

Application pratique : Machines à vecteurs de support (SVM)

Le **kernel trick** permet de projeter implicitement les données dans un espace de très haute dimension où elles deviennent linéairement séparables, sans calcul explicite de la transformation.

Exemple en vision par ordinateur : Pour la reconnaissance d'objets, les SVM avec noyau RBF séparent des classes non linéairement séparables dans l'espace d'origine.

Application pratique : Word embeddings

Les modèles comme **Word2Vec** projettent les mots dans des espaces de dimension 100 à 300 où les relations sémantiques deviennent linéairement représentables. Par exemple :

$$\text{"roi"} - \text{"homme"} + \text{"femme"} \approx \text{"reine"}$$

Cette propriété émerge naturellement en haute dimension grâce à la quasi-orthogonalité des vecteurs de mots différents.

Robustesse statistique et régularisation implicite

Phénomène de double descente

Contrairement à la intuition classique, augmenter la capacité d'un modèle (nombre de paramètres) au-delà d'un certain point peut améliorer la généralisation, un phénomène observé dans les réseaux de neurones profonds.

Explication théorique : En très haute dimension, les modèles bénéficient d'une régularisation implicite due à la concentration des mesures et à la géométrie particulière des espaces de haute dimension.

Application pratique : Apprentissage profond

Les réseaux de neurones avec des millions de paramètres généralisent souvent mieux que des modèles plus petits, en particulier lorsqu'ils sont combinés avec des techniques de régularisation appropriées.

Exemple : Les modèles de langage à grande échelle comme GPT-3, avec 175 milliards de paramètres, atteignent des performances remarquables en compréhension et génération de texte.

Synthèse et Perspectives

Dialectique entre malédiction et bénédiction

Ces deux aspects ne sont pas contradictoires mais complémentaires. La clé réside dans la compréhension des conditions sous lesquelles chaque phénomène domine :

- La **malédiction** prédomine lorsque les données sont uniformément réparties et que les dimensions sont indépendantes
 - La **bénédiction** émerge lorsque les données possèdent une structure sous-jacente (parcimonie, variétés de faible dimension) que l'on peut exploiter
-

Implications pour la pratique du data science

Stratégies pour mitiger la malédiction

- **Réduction de dimension** (ACP, t-SNE, UMAP)
- **Régularisation** (ridge, lasso) pour éviter le sur-apprentissage
- **Sélection de caractéristiques** pour conserver seulement les dimensions pertinentes
- **Algorithmes spécifiques** conçus pour la haute dimension (forêts d'isolement, one-class SVM)

Stratégies pour exploiter la bénédiction

- **Projections aléatoires** pour l'indexation et la compression
 - **Méthodes à noyau** pour la séparabilité linéaire
 - **Agrégation de modèles** pour la robustesse statistique
 - **Apprentissage de représentations** pour découvrir la structure sous-jacente
-

Récapitulatif des fondements théoriques

Pour la malédiction :

- Croissance exponentielle du volume (sparsity)
- Théorème de concentration des distances (Beyer et al.)
- Concentration des normes gaussiennes (Loi des Grands Nombres)
- Inégalités de concentration (Hoeffding, Chebyshev)

Pour la bénédiction :

- Loi des Grands Nombres et Théorème Central Limite
 - Lemme de Johnson-Lindenstrauss (préservation des distances)
 - Quasi-orthogonalité des vecteurs aléatoires
 - Séparabilité linéaire en haute dimension
-

Conclusion

La haute dimension présente un paysage complexe où coexistent des défis redoutables et des opportunités précieuses. La **sparsity** et la **concentration**, bien que problématiques pour de nombreuses méthodes classiques, peuvent devenir des alliées lorsqu'elles sont comprises et exploitées judicieusement.

Le data scientist moderne doit naviguer cette dualité en mobilisant à la fois une compréhension théorique profonde (théorèmes de concentration, lois des grands nombres, propriétés géométriques) et un arsenal de techniques pratiques (réduction de dimension, régularisation, méthodes adaptées).

La leçon essentielle est que la dimension n'est pas une fatalité mais une caractéristique du problème dont il faut comprendre les implications pour transformer les obstacles en opportunités. Cette compréhension duale est cruciale pour concevoir des systèmes qui prospèrent dans les espaces de haute dimension qui caractérisent de plus en plus les données contemporaines.