

Table of contents

Cours : Analyse en Composantes Principales (PCA)	1
Motivation	1
Formalisation	2
Maximisation de la variance	2
Formalisation mathématique	2
Solution par optimisation contrainte	3
Dualité variance-erreur	4
Interprétation physique	4
Structure de l'espace latent	5
Propriétés fondamentales	5
Transformation des données	5
Structure du modèle	5
Hypothèse sous-jacente	5
Transformation exacte	6
PCA pour la réduction de dimension	6
Approximation de bas rang	6
Géométrie de PCA	6
PCA pratique : mode d'emploi	7
Algorithme étape par étape	7
Stratégies de sélection de K	7
PCA et AutoEncodeurs Linéaires	8
Architecture d'un AutoEncodeur Linéaire	8
Fonction de coût	8
Équivalence avec PCA	8
Généralisations	8
Alternatives et extensions	8
PCA Probabiliste	8
PCA à Noyau (Kernel PCA)	9
PCA Local	9
Limitations computationnelles	9
Synthèse et conclusions	9
Questions d'approfondissement	9

Cours : Analyse en Composantes Principales (PCA)

Motivation

Les données brutes sont souvent représentées dans un espace de grande dimension, mais cette représentation n'est pas toujours optimale pour l'analyse ou la modélisation.

- Les représentations de base peuvent ne pas être optimales
- Les modèles latents permettent de révéler les facteurs sous-jacents (latents) qui gouvernent le processus étudié
- Cette approche utilise la corrélation statistique pour identifier des facteurs latents **linéaires**
- Cela permet une simplification des données par réduction dimensionnelle raisonnée

Nous allons explorer plusieurs interprétations de cette méthode fondamentale.

Lecture recommandée : [1] (chapitre 12) et [3] (chapitres 3 et 10.3)

Formalisation

Maximisation de la variance

Intuition géométrique

Étant donné un ensemble de données $X \subset \Omega$, nous cherchons à décomposer Ω en sous-espaces tels que la projection de X sur ces sous-espaces conserve le maximum d'**information**.

Question cruciale : Quelle information devrions-nous conserver ?

- Imaginez que X soit presque contenu dans un plan 2D au sein d'un espace 3D
- Un choix pertinent serait de choisir comme sous-espace ce plan, avec une base $\{\mathbf{u}_1, \mathbf{u}_2\}$

Caractéristiques clés d'une bonne base :

- Les données varient **maximum** le long de ces directions
- Les données varient **minimum** orthogonalement à ces directions (ex: $\mathbf{u}_3$)

Formalisation mathématique

Soit $\mathcal{X}$ nos données, et $\{\mathbf{u}_i\}_{i \in [D]}$ une nouvelle base orthonormale de $\mathbb{R}^D$.

- La **Première Composante Principale** $\mathbf{u}_1$ est choisie pour maximiser la variance des données projetées
- $\mathbf{u}_2$ est ensuite choisie orthogonalement à $\mathbf{u}_1$, et ainsi de suite

Modèle statistique

Pour $\mathcal{X}$, nous définissons :

- **Moyenne empirique :**

$$\bar{\mathcal{X}} = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i$$

- **Variance projetée sur $\mathbf{u}_1$:**

$$v_{\mathbf{u}_1} = \frac{1}{N} \sum_{i=1}^N (\mathbf{u}_1^T \mathbf{x}_i - \mathbf{u}_1^T \bar{\mathcal{X}})^2 = \mathbf{u}_1^T \Sigma \mathbf{u}_1$$

où $\Sigma = \frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^T$ est la **matrice de covariance**.

Nous cherchons donc :

$$\mathbf{u}_1 = \arg \max_{\mathbf{u}} \mathbf{u}^T \Sigma \mathbf{u} \quad \text{sous} \quad \mathbf{u}^T \mathbf{u} = 1$$

Solution par optimisation contrainte

Nous formons le lagrangien :

$$J(\mathbf{u}) = \mathbf{u}^T \Sigma \mathbf{u} + \lambda(1 - \mathbf{u}^T \mathbf{u})$$

Les conditions d'optimalité donnent :

$$\frac{\partial J(\mathbf{u})}{\partial \mathbf{u}} = 0 \quad \text{et} \quad \frac{\partial J(\mathbf{u})}{\partial \lambda} = 0$$

Ce qui conduit à :

$$\Sigma \mathbf{u}_1 = \lambda_1 \mathbf{u}_1 \quad \Rightarrow \quad v_{\mathbf{u}_1} = \mathbf{u}_1^T \Sigma \mathbf{u}_1 = \lambda_1$$

Interprétation clé : $(\mathbf{u}_1, \lambda_1)$ est une **paire propre** de Σ .

En poursuivant le processus, nous obtenons toutes les composantes principales comme les paires propres $\{(\mathbf{u}_i, \lambda_i)\}_{i \in [D]}$.

Nous pouvons écrire de manière compacte :

$$\Lambda = \mathbf{U}^\top \Sigma \mathbf{U}$$

avec $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_D)$ et $\mathbf{U} = [\mathbf{u}_1, \dots, \mathbf{u}_D]$.

Dualité variance-erreur

La variance projetée s'exprime comme :

$$\nu_{\mathbf{u}_1} = \frac{1}{N} \sum_{i=1}^N (\mathbf{u}_1^\top (\mathbf{x}_i - \bar{\mathbf{x}}))^2$$

Maximiser cette variance équivaut à minimiser l'erreur d'approximation quadratique :

$$\mathbf{u}_1 = \arg \min_{\mathbf{u}^\top \mathbf{u} = 1} \sum_{i=1}^N \|\mathbf{x}_i - \bar{\mathbf{x}} - [\mathbf{u}^\top (\mathbf{x}_i - \bar{\mathbf{x}})] \mathbf{u}\|_2^2$$

Équivalence fondamentale : Maximisation de variance $\Leftrightarrow$ Minimisation d'erreur.

Interprétation physique

Considérons un système physique $\mathcal{X}$ avec des masses unitaires aux positions $\mathbf{x}_i$.

- **Inertie par rapport à un point $\mathbf{a}$:**

$$I_{\mathbf{a}}(\mathcal{X}) = \sum_{i=1}^N d^2(\mathbf{a}, \mathbf{x}_i)$$

- **Théorème de Huygens :** Si $\mathbf{g}$ est le centre de masse, alors

$$I_{\mathbf{a}}(\mathcal{X}) = d^2(\mathbf{a}, \mathbf{g}) + I_{\mathbf{g}}(\mathcal{X})$$

Pour un sous-espace $\mathcal{J}$ passant par $\mathbf{g}$:

$$I_{\mathcal{J}}(\mathcal{X}) = \sum_{i=1}^N d^2(\mathcal{J}, \mathbf{x}_i)$$

où $d(\mathcal{J}, \mathbf{x}_i) = \|\mathbf{x}_i - \text{Proj}_{\mathcal{J}}(\mathbf{x}_i)\|$.

Conclusion physique : Une Composante Principale est un **sous-espace d'inertie minimale**.

Structure de l'espace latent

Propriétés fondamentales

La base $\{\mathbf{u}_1, \dots, \mathbf{u}_D\}$ de l'espace latent possède :

- **Valeurs propres ordonnées :** $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_D$
- **Variance totale :** $\sum_{d=1}^D \lambda_d = \text{Tr}(\Sigma)$
- **Décorrélation :** $\mathbf{u}_d^\top \mathbf{u}_{d'} = 0$ (orthogonalité)
- **Matrice de covariance diagonale :** Λ est diagonale

Transformation des données

Les coordonnées latentes $\mathbf{y}_i$ sont obtenues par :

$$y_i(d) = \mathbf{u}_d^\top (\mathbf{x}_i - \bar{\mathbf{x}}) \quad \Rightarrow \quad \mathbf{y}_i = \mathbf{U}^\top (\mathbf{x}_i - \bar{\mathbf{x}})$$

Cette transformation linéaire combine trois opérations :

1. **Centrage** sur $\bar{\mathbf{x}}$
2. **Rotation** via $\mathbf{U}$
3. **Mise à l'échelle** via $\Lambda^{1/2}$ (blanchiment)

Structure du modèle

Hypothèse sous-jacente

L'espace latent préserve la variance des données centrées, ce qui suppose un modèle :

$$X_i \sim \mathcal{N}(\bar{\mathbf{x}}, \Sigma)$$

Conséquence importante : PCA sera moins pertinent pour des données non-gaussiennes (ex: données clusterisées).

Transformation exacte

À ce stade, PCA est une transformation **exacte** et **inversible** :

$$\mathbf{y}_i = \mathbf{U}^\top (\mathbf{x}_i - \bar{\mathbf{x}}) \Leftrightarrow \mathbf{x}_i = \bar{\mathbf{x}} + \mathbf{U} \mathbf{y}_i$$

L'étude du **spectre** $\{\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_D\}$ est cruciale.

PCA pour la réduction de dimension

Approximation de bas rang

D'après le **théorème d'Eckart-Young**, pour $K < D$:

- **Approximation optimale** : $\Sigma_K = \sum_{d=1}^K \lambda_d \mathbf{u}_d \mathbf{u}_d^\top$
- **Erreur minimale** : $\|\Sigma - \Sigma_K\|_F^2 = \sum_{d=K+1}^D \lambda_d^2$

Par troncation :

$$\Sigma_K = \mathbf{U}_K \Lambda_K \mathbf{U}_K^\top$$

Les données transformées et reconstruites deviennent :

- **Représentation réduite** : $\tilde{\mathbf{y}}_i = \mathbf{U}_K^\top \mathbf{x}_i \in \mathbb{R}^K$
- **Reconstruction** : $\tilde{\mathbf{x}}_i = \mathbf{U}_K \mathbf{U}_K^\top \mathbf{x}_i + \bar{\mathbf{x}}$

Géométrie de PCA

Mesures de qualité

- **Contribution variance** :

$$c_d = \frac{\lambda_d}{\sum_k \lambda_k}$$

- **Alignement des données** :

$$\rho_d(\mathbf{x}_i) = \frac{(\mathbf{u}_d^\top \mathbf{x}_i)^2}{\|\mathbf{x}_i\|^2} = \cos^2(\angle(\mathbf{u}_d, \mathbf{x}_i))$$

Normalisation des échelles

Chaque dimension originale a sa propre échelle (variance σ_d^2). PCA est plus efficace quand toutes les échelles sont comparables.

Solution : Utiliser la **matrice de corrélation** plutôt que la covariance :

- **Matrice de mise à l'échelle :** $\mathbf{S} = \text{diag}[\sigma_1^2, \dots, \sigma_D^2]$
- **Métrique associée :** $d_S^2(\mathbf{x}, \mathbf{y}) = (\mathbf{x} - \mathbf{y})^\top \mathbf{S}^{-1} (\mathbf{x} - \mathbf{y})$
- **PCA sur données normalisées :** Utiliser Σ_S (matrice de corrélation)

PCA pratique : mode d'emploi

Algorithme étape par étape

1. **Calculer** la moyenne empirique $\bar{\mathbf{x}}$
2. **Centrer** les données : $\mathbf{x}_i \leftarrow (\mathbf{x}_i - \bar{\mathbf{x}})$
3. **Former** la matrice centrée $\mathbf{X}$
4. **Calculer** $\Sigma = \frac{1}{N} \mathbf{X} \mathbf{X}^\top$
5. **Décomposer** $\Sigma = \mathbf{U} \Lambda \mathbf{U}^\top$
6. **Sélectionner** K composantes
7. **Projeter** et/ou **reconstruire** les données

Stratégies de sélection de K

- **Dimension cible :** $K = d$ (dimension souhaitée)
- **Variance conservée :** Choisir K tel que

$$\frac{\sum_{d=1}^K \lambda_d}{\sum_{d=1}^D \lambda_d} \geq \tau$$

(ex: $\tau = 0.95$ pour 95% de variance)

- **Erreur de reconstruction :** Choisir K tel que

$$\mathcal{L}(\mathbf{x}) = \sum_i \|\mathbf{x}_i - \tilde{\mathbf{x}}_i\|^2 \leq \epsilon$$

PCA et AutoEncodeurs Linéaires

Architecture d'un AutoEncodeur Linéaire

- **Encodeur** : $\mathbf{z}(\mathbf{x}_i) = W_{\text{enc}}\mathbf{x}_i$
- **Décodeur** : $\tilde{\mathbf{x}}_i = W_{\text{dec}}\mathbf{z}(\mathbf{x}_i)$

Fonction de coût

$$\theta^* = \arg \min_{W_{\text{enc}}, W_{\text{dec}}} \sum_{i=1}^N \|\mathbf{x}_i - \tilde{\mathbf{x}}_i\|^2$$

Équivalence avec PCA

Théorème : Un AutoEncodeur Linéaire entraîné sur des données **centrées** réalise exactement une PCA.

- **Encodeur** : $W_{\text{enc}} = \mathbf{U}_K^\top$
- **Décodeur** : $W_{\text{dec}} = \mathbf{U}_K$

Généralisations

- **AutoEncodeurs Non-Linéaires** : Ajout de couches cachées
- **AutoEncodeurs Variationnels (VAE)** : Modification de la fonction de coût (ELBO)
- **AutoEncodeurs parcimonieux** : Contraintes de régularisation

Alternatives et extensions

PCA Probabiliste

Reformulation probabiliste avec :

- **Distribution latente** : $\mathbb{P}(\mathbf{z}) = \mathcal{N}(0, \text{Id}_K)$
- **Modèle conditionnel** : $\mathbb{P}(\mathbf{x}|\mathbf{z}) = \mathcal{N}(W\mathbf{z} + \mu, \sigma^2 \text{Id}_D)$

Avantages :

- Modélisation explicite du bruit
- Mode génératif
- Estimation par Maximum de Vraisemblance ou EM

PCA à Noyau (Kernel PCA)

Extension non-linéaire par **trick du noyau** :

- **Mapping implicite** : $\Phi(\mathbf{x}_i)$ via noyau $k(\mathbf{x}_i, \mathbf{x}_j)$
- **PCA dans l'espace de features** : $\mathbf{k}(x_i, x_j) = \Phi(x_i)^\top \Phi(x_j)$

PCA Local

PCA appliquée localement sur des voisinages de données pour capturer la **dimensionnalité intrinsèque locale**.

Limitations computationnelles

La décomposition de Σ a une complexité $O(D^3)$, ce qui peut être prohibitif pour de grandes dimensions.

Synthèse et conclusions

- **PCA** fait partie des modèles latents **linéaires**
- Il s'applique sur données **centrées** et utilise la **variance** comme critère
- C'est une décomposition **exacte** en composantes **décorrélées**
- Il suppose une distribution **normale** des données
- Il peut être formulé comme une **régression** quadratique
- Il offre une stratégie de **réduction dimensionnelle** basée sur l'approximation de bas rang
- Il peut être utilisé pour le **débruitage** (modèle gaussien)
- Il est équivalent à un **AutoEncodeur Linéaire**
- Il admet des formulations **stochastiques** et des extensions **non-linéaires**

Questions d'approfondissement

- Expliquez comment PCA utilise la variance comme critère
- Montrez l'équivalence entre maximisation de variance et minimisation d'erreur
- Expliquez l'utilisation du théorème d'Eckart-Young dans PCA
- Décrivez les étapes pratiques pour appliquer PCA sur un jeu de données
- Quelles informations PCA fournit-il sur les données ?
- Comment reconstruire des données avec $K < D$ composantes ?
- Quelles stratégies pour sélectionner le nombre de composantes à conserver ?
- PCA est-elle applicable à tout type de données ?

- Est-il pertinent d'appliquer PCA sur des données clusterisées ?
- Démontrez l'équivalence entre PCA et AutoEncodeur Linéaire