

## Table of contents

|                                                         |          |
|---------------------------------------------------------|----------|
| <b>Cours : Analyse en Composantes Principales (PCA)</b> | <b>1</b> |
| Motivation . . . . .                                    | 1        |
| Formalisation . . . . .                                 | 2        |
| Maximisation de la variance . . . . .                   | 2        |
| Formalisation mathématique . . . . .                    | 2        |
| Solution par optimisation contrainte . . . . .          | 3        |
| Dualité variance-erreur . . . . .                       | 4        |
| Interprétation physique . . . . .                       | 4        |
| Structure de l'espace latent . . . . .                  | 5        |
| Propriétés fondamentales . . . . .                      | 5        |
| Transformation des données . . . . .                    | 5        |
| Structure du modèle . . . . .                           | 5        |
| Hypothèse sous-jacente . . . . .                        | 5        |
| Transformation exacte . . . . .                         | 6        |
| PCA pour la réduction de dimension . . . . .            | 6        |
| Approximation de bas rang . . . . .                     | 6        |
| Géométrie de PCA . . . . .                              | 6        |
| PCA pratique : mode d'emploi . . . . .                  | 7        |
| Algorithme étape par étape . . . . .                    | 7        |
| Stratégies de sélection de $K$ . . . . .                | 7        |
| PCA et AutoEncodeurs Linéaires . . . . .                | 8        |
| Architecture d'un AutoEncodeur Linéaire . . . . .       | 8        |
| Fonction de coût . . . . .                              | 8        |
| Équivalence avec PCA . . . . .                          | 8        |
| Généralisations . . . . .                               | 8        |
| Alternatives et extensions . . . . .                    | 8        |
| PCA Probabiliste . . . . .                              | 8        |
| PCA à Noyau (Kernel PCA) . . . . .                      | 9        |
| PCA Local . . . . .                                     | 9        |
| Limitations computationnelles . . . . .                 | 9        |
| Synthèse et conclusions . . . . .                       | 9        |
| Questions d'approfondissement . . . . .                 | 9        |

## Cours : Analyse en Composantes Principales (PCA)

### Motivation

Les données brutes sont souvent représentées dans un espace de grande dimension, mais cette représentation n'est pas toujours optimale pour l'analyse ou la modélisation.

- Les représentations de base peuvent ne pas être optimales
- Les modèles latents permettent de révéler les facteurs sous-jacents (latents) qui gouvernent le processus étudié
- Cette approche utilise la corrélation statistique pour identifier des facteurs latents **linéaires**
- Cela permet une simplification des données par réduction dimensionnelle raisonnée

Nous allons explorer plusieurs interprétations de cette méthode fondamentale.

**Lecture recommandée :** [1] (chapitre 12) et [3] (chapitres 3 et 10.3)

## Formalisation

### Maximisation de la variance

#### Intuition géométrique

Étant donné un ensemble de données  $X \subset \Omega$ , nous cherchons à décomposer  $\Omega$  en sous-espaces tels que la projection de  $X$  sur ces sous-espaces conserve le maximum d'**information**.

**Question cruciale :** Quelle information devrions-nous conserver ?

- Imaginez que  $X$  soit presque contenu dans un plan 2D au sein d'un espace 3D
- Un choix pertinent serait de choisir comme sous-espace ce plan, avec une base  $\{\mathbf{u}_1, \mathbf{u}_2\}$

**Caractéristiques clés d'une bonne base :**

- Les données varient **maximum** le long de ces directions
- Les données varient **minimum** orthogonalement à ces directions (ex:  $\mathbf{u}_3$ )

### Formalisation mathématique

Soit  $\mathcal{X}$  nos données, et  $\{\mathbf{u}_i\}_{i \in [D]}$  une nouvelle base orthonormale de  $\mathbb{R}^D$ .

- La **Première Composante Principale**  $\mathbf{u}_1$  est choisie pour maximiser la variance des données projetées
- $\mathbf{u}_2$  est ensuite choisie orthogonalement à  $\mathbf{u}_1$ , et ainsi de suite

## Modèle statistique

Pour  $\mathcal{X}$ , nous définissons :

- **Moyenne empirique :**

$$\bar{\mathcal{X}} = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i$$

- **Variance projetée sur  $\mathbf{u}_1$  :**

$$v_{\mathbf{u}_1} = \frac{1}{N} \sum_{i=1}^N (\mathbf{u}_1^T \mathbf{x}_i - \mathbf{u}_1^T \bar{\mathcal{X}})^2 = \mathbf{u}_1^T \Sigma \mathbf{u}_1$$

où  $\Sigma = \frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^T$  est la **matrice de covariance**.

Nous cherchons donc :

$$\mathbf{u}_1 = \arg \max_{\mathbf{u}} \mathbf{u}^T \Sigma \mathbf{u} \quad \text{sous} \quad \mathbf{u}^T \mathbf{u} = 1$$

## Solution par optimisation contrainte

Nous formons le lagrangien :

$$J(\mathbf{u}) = \mathbf{u}^T \Sigma \mathbf{u} + \lambda(1 - \mathbf{u}^T \mathbf{u})$$

Les conditions d'optimalité donnent :

$$\frac{\partial J(\mathbf{u})}{\partial \mathbf{u}} = 0 \quad \text{et} \quad \frac{\partial J(\mathbf{u})}{\partial \lambda} = 0$$

Ce qui conduit à :

$$\Sigma \mathbf{u}_1 = \lambda_1 \mathbf{u}_1 \quad \Rightarrow \quad v_{\mathbf{u}_1} = \mathbf{u}_1^T \Sigma \mathbf{u}_1 = \lambda_1$$

**Interprétation clé :**  $(\mathbf{u}_1, \lambda_1)$  est une **paire propre** de  $\Sigma$ .

En poursuivant le processus, nous obtenons toutes les composantes principales comme les paires propres  $\{(\mathbf{u}_i, \lambda_i)\}_{i \in [D]}$ .

Nous pouvons écrire de manière compacte :

$$\Lambda = \mathbf{U}^\top \Sigma \mathbf{U}$$

avec  $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_D)$  et  $\mathbf{U} = [\mathbf{u}_1, \dots, \mathbf{u}_D]$ .

### Dualité variance-erreur

La variance projetée s'exprime comme :

$$\nu_{\mathbf{u}_1} = \frac{1}{N} \sum_{i=1}^N (\mathbf{u}_1^\top (\mathbf{x}_i - \bar{\mathbf{x}}))^2$$

Maximiser cette variance équivaut à minimiser l'erreur d'approximation quadratique :

$$\mathbf{u}_1 = \arg \min_{\mathbf{u}^\top \mathbf{u} = 1} \sum_{i=1}^N \|\mathbf{x}_i - \bar{\mathbf{x}} - [\mathbf{u}^\top (\mathbf{x}_i - \bar{\mathbf{x}})] \mathbf{u}\|_2^2$$

**Équivalence fondamentale :** Maximisation de variance  $\Leftrightarrow$  Minimisation d'erreur.

### Interprétation physique

Considérons un système physique  $\mathcal{X}$  avec des masses unitaires aux positions  $\mathbf{x}_i$ .

- **Inertie par rapport à un point  $\mathbf{a}$  :**

$$I_{\mathbf{a}}(\mathcal{X}) = \sum_{i=1}^N d^2(\mathbf{a}, \mathbf{x}_i)$$

- **Théorème de Huygens :** Si  $\mathbf{g}$  est le centre de masse, alors

$$I_{\mathbf{a}}(\mathcal{X}) = d^2(\mathbf{a}, \mathbf{g}) + I_{\mathbf{g}}(\mathcal{X})$$

Pour un sous-espace  $\mathcal{J}$  passant par  $\mathbf{g}$  :

$$I_{\mathcal{J}}(\mathcal{X}) = \sum_{i=1}^N d^2(\mathcal{J}, \mathbf{x}_i)$$

où  $d(\mathcal{J}, \mathbf{x}_i) = \|\mathbf{x}_i - \text{Proj}_{\mathcal{J}}(\mathbf{x}_i)\|$ .

**Conclusion physique :** Une Composante Principale est un **sous-espace d'inertie minimale**.

## Structure de l'espace latent

### Propriétés fondamentales

La base  $\{\mathbf{u}_1, \dots, \mathbf{u}_D\}$  de l'espace latent possède :

- **Valeurs propres ordonnées :**  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_D$
- **Variance totale :**  $\sum_{d=1}^D \lambda_d = \text{Tr}(\Sigma)$
- **Décorrélation :**  $\mathbf{u}_d^\top \mathbf{u}_{d'} = 0$  (orthogonalité)
- **Matrice de covariance diagonale :**  $\Lambda$  est diagonale

### Transformation des données

Les coordonnées latentes  $\mathbf{y}_i$  sont obtenues par :

$$y_i(d) = \mathbf{u}_d^\top (\mathbf{x}_i - \bar{\mathbf{x}}) \quad \Rightarrow \quad \mathbf{y}_i = \mathbf{U}^\top (\mathbf{x}_i - \bar{\mathbf{x}})$$

Cette transformation linéaire combine trois opérations :

1. **Centrage** sur  $\bar{\mathbf{x}}$
2. **Rotation** via  $\mathbf{U}$
3. **Mise à l'échelle** via  $\Lambda^{1/2}$  (blanchiment)

## Structure du modèle

### Hypothèse sous-jacente

L'espace latent préserve la variance des données centrées, ce qui suppose un modèle :

$$X_i \sim \mathcal{N}(\bar{\mathbf{x}}, \Sigma)$$

**Conséquence importante :** PCA sera moins pertinent pour des données non-gaussiennes (ex: données clusterisées).

## Transformation exacte

À ce stade, PCA est une transformation **exacte** et **inversible** :

$$\mathbf{y}_i = \mathbf{U}^\top (\mathbf{x}_i - \bar{\mathbf{x}}) \Leftrightarrow \mathbf{x}_i = \bar{\mathbf{x}} + \mathbf{U} \mathbf{y}_i$$

L'étude du **spectre**  $\{\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_D\}$  est cruciale.

## PCA pour la réduction de dimension

### Approximation de bas rang

D'après le **théorème d'Eckart-Young**, pour  $K < D$  :

- **Approximation optimale** :  $\Sigma_K = \sum_{d=1}^K \lambda_d \mathbf{u}_d \mathbf{u}_d^\top$
- **Erreur minimale** :  $\|\Sigma - \Sigma_K\|_F^2 = \sum_{d=K+1}^D \lambda_d^2$

Par troncation :

$$\Sigma_K = \mathbf{U}_K \Lambda_K \mathbf{U}_K^\top$$

Les données transformées et reconstruites deviennent :

- **Représentation réduite** :  $\tilde{\mathbf{y}}_i = \mathbf{U}_K^\top \mathbf{x}_i \in \mathbb{R}^K$
- **Reconstruction** :  $\tilde{\mathbf{x}}_i = \mathbf{U}_K \mathbf{U}_K^\top \mathbf{x}_i + \bar{\mathbf{x}}$

## Géométrie de PCA

### Mesures de qualité

- **Contribution variance** :

$$c_d = \frac{\lambda_d}{\sum_k \lambda_k}$$

- **Alignement des données** :

$$\rho_d(\mathbf{x}_i) = \frac{(\mathbf{u}_d^\top \mathbf{x}_i)^2}{\|\mathbf{x}_i\|^2} = \cos^2(\angle(\mathbf{u}_d, \mathbf{x}_i))$$

## Normalisation des échelles

Chaque dimension originale a sa propre échelle (variance  $\sigma_d^2$ ). PCA est plus efficace quand toutes les échelles sont comparables.

**Solution :** Utiliser la **matrice de corrélation** plutôt que la covariance :

- **Matrice de mise à l'échelle :**  $\mathbf{S} = \text{diag}[\sigma_1^2, \dots, \sigma_D^2]$
- **Métrique associée :**  $d_S^2(\mathbf{x}, \mathbf{y}) = (\mathbf{x} - \mathbf{y})^\top \mathbf{S}^{-1} (\mathbf{x} - \mathbf{y})$
- **PCA sur données normalisées :** Utiliser  $\Sigma_S$  (matrice de corrélation)

## PCA pratique : mode d'emploi

### Algorithme étape par étape

1. **Calculer** la moyenne empirique  $\bar{\mathbf{x}}$
2. **Centrer** les données :  $\mathbf{x}_i \leftarrow (\mathbf{x}_i - \bar{\mathbf{x}})$
3. **Former** la matrice centrée  $\mathbf{X}$
4. **Calculer**  $\Sigma = \frac{1}{N} \mathbf{X} \mathbf{X}^\top$
5. **Décomposer**  $\Sigma = \mathbf{U} \Lambda \mathbf{U}^\top$
6. **Sélectionner**  $K$  composantes
7. **Projeter** et/ou **reconstruire** les données

### Stratégies de sélection de $K$

- **Dimension cible :**  $K = d$  (dimension souhaitée)
- **Variance conservée :** Choisir  $K$  tel que

$$\frac{\sum_{d=1}^K \lambda_d}{\sum_{d=1}^D \lambda_d} \geq \tau$$

(ex:  $\tau = 0.95$  pour 95% de variance)

- **Erreur de reconstruction :** Choisir  $K$  tel que

$$\mathcal{L}(\mathbf{x}) = \sum_i \|\mathbf{x}_i - \tilde{\mathbf{x}}_i\|^2 \leq \epsilon$$

## PCA et AutoEncodeurs Linéaires

### Architecture d'un AutoEncodeur Linéaire

- **Encodeur** :  $\mathbf{z}(\mathbf{x}_i) = W_{\text{enc}} \mathbf{x}_i$
- **Décodeur** :  $\tilde{\mathbf{x}}_i = W_{\text{dec}} \mathbf{z}(\mathbf{x}_i)$

### Fonction de coût

$$\theta^* = \arg \min_{W_{\text{enc}}, W_{\text{dec}}} \sum_{i=1}^N \|\mathbf{x}_i - \tilde{\mathbf{x}}_i\|^2$$

### Équivalence avec PCA

**Théorème** : Un AutoEncodeur Linéaire entraîné sur des données **centrées** réalise exactement une PCA.

- **Encodeur** :  $W_{\text{enc}} = \mathbf{U}_K^\top$
- **Décodeur** :  $W_{\text{dec}} = \mathbf{U}_K$

### Généralisations

- **AutoEncodeurs Non-Linéaires** : Ajout de couches cachées
- **AutoEncodeurs Variationnels (VAE)** : Modification de la fonction de coût (ELBO)
- **AutoEncodeurs parcimonieux** : Contraintes de régularisation

### Alternatives et extensions

#### PCA Probabiliste

Reformulation probabiliste avec :

- **Distribution latente** :  $\mathbb{P}(\mathbf{z}) = \mathcal{N}(0, \text{Id}_K)$
- **Modèle conditionnel** :  $\mathbb{P}(\mathbf{x}|\mathbf{z}) = \mathcal{N}(W\mathbf{z} + \mu, \sigma^2 \text{Id}_D)$

#### Avantages :

- Modélisation explicite du bruit
- Mode génératif
- Estimation par Maximum de Vraisemblance ou EM



## PCA à Noyau (Kernel PCA)

Extension non-linéaire par **trick du noyau** :

- **Mapping implicite** :  $\Phi(\mathbf{x}_i)$  via noyau  $k(\mathbf{x}_i, \mathbf{x}_j)$
- **PCA dans l'espace de features** :  $\mathbf{k}(x_i, x_j) = \Phi(x_i)^\top \Phi(x_j)$

## PCA Local

PCA appliquée localement sur des voisinages de données pour capturer la **dimensionnalité intrinsèque locale**.

## Limitations computationnelles

La décomposition de  $\Sigma$  a une complexité  $O(D^3)$ , ce qui peut être prohibitif pour de grandes dimensions.

## Synthèse et conclusions

- **PCA** fait partie des modèles latents **linéaires**
- Il s'applique sur données **centrées** et utilise la **variance** comme critère
- C'est une décomposition **exacte** en composantes **décorrélées**
- Il suppose une distribution **normale** des données
- Il peut être formulé comme une **régression** quadratique
- Il offre une stratégie de **réduction dimensionnelle** basée sur l'approximation de bas rang
- Il peut être utilisé pour le **débruitage** (modèle gaussien)
- Il est équivalent à un **AutoEncodeur Linéaire**
- Il admet des formulations **stochastiques** et des extensions **non-linéaires**

## Questions d'approfondissement

- Expliquez comment PCA utilise la variance comme critère
- Montrez l'équivalence entre maximisation de variance et minimisation d'erreur
- Expliquez l'utilisation du théorème d'Eckart-Young dans PCA
- Décrivez les étapes pratiques pour appliquer PCA sur un jeu de données
- Quelles informations PCA fournit-il sur les données ?
- Comment reconstruire des données avec  $K < D$  composantes ?
- Quelles stratégies pour sélectionner le nombre de composantes à conserver ?
- PCA est-elle applicable à tout type de données ?

- Est-il pertinent d'appliquer PCA sur des données clusterisées ?
- Démontrez l'équivalence entre PCA et AutoEncodeur Linéaire