

# Table of contents

|                                                                                     |           |
|-------------------------------------------------------------------------------------|-----------|
| <b>Exam question</b>                                                                | <b>2</b>  |
| <b>Analyse en Composantes Principales (PCA) : Méthode, Calcul et Interprétation</b> | <b>2</b>  |
| Question . . . . .                                                                  | 2         |
| Introduction et Objectifs . . . . .                                                 | 2         |
| Objectifs Principaux . . . . .                                                      | 3         |
| Hypothèses Fondamentales . . . . .                                                  | 3         |
| Hypothèses Statistiques . . . . .                                                   | 3         |
| Prérequis sur les Données . . . . .                                                 | 3         |
| Calcul des Composantes Principales . . . . .                                        | 3         |
| Étape 1 : Préparation des Données . . . . .                                         | 3         |
| Étape 2 : Calcul de la Matrice de Covariance . . . . .                              | 4         |
| Étape 3 : Décomposition en Valeurs Propres . . . . .                                | 4         |
| Étape 4 : Sélection des Composantes . . . . .                                       | 6         |
| Étape 5 : Projection des Données . . . . .                                          | 8         |
| Interprétation des Résultats . . . . .                                              | 8         |
| Interprétation Géométrique . . . . .                                                | 8         |
| Charge des Composantes (Loadings) . . . . .                                         | 8         |
| Scores des Observations . . . . .                                                   | 8         |
| Cercle des Corrélations . . . . .                                                   | 9         |
| Applications et Utilisations . . . . .                                              | 9         |
| Réduction de Dimensionnalité . . . . .                                              | 9         |
| Visualisation de Données Multidimensionnelles . . . . .                             | 9         |
| Débruitage . . . . .                                                                | 9         |
| Pré-traitement pour Autres Algorithmes . . . . .                                    | 10        |
| Limitations et Précautions . . . . .                                                | 10        |
| Limitations de PCA . . . . .                                                        | 10        |
| Alternatives à Considérer . . . . .                                                 | 10        |
| Exemple d'Application Pas à Pas . . . . .                                           | 10        |
| Étape 0 : Données Initiales . . . . .                                               | 10        |
| Étape 1 : Centrage et Normalisation . . . . .                                       | 10        |
| Étape 2 : Calcul de la Matrice de Covariance . . . . .                              | 11        |
| Étape 3 : Décomposition en Valeurs Propres . . . . .                                | 11        |
| Étape 4 : Analyse des Valeurs Propres . . . . .                                     | 11        |
| Étape 5 : Décision sur le Nombre de Composantes . . . . .                           | 11        |
| Étape 6 : Projection et Interprétation . . . . .                                    | 11        |
| Conclusion . . . . .                                                                | 11        |
| <b>Choix du Nombre de Composantes en PCA</b>                                        | <b>12</b> |
| Question . . . . .                                                                  | 12        |
| Introduction au Problème de Sélection . . . . .                                     | 12        |

|                                                                  |    |
|------------------------------------------------------------------|----|
| Critères de Sélection Principaux . . . . .                       | 12 |
| Basé sur la Variance Expliquée . . . . .                         | 12 |
| Analyse du Graphique des Valeurs Propres (Scree Plot) . . . . .  | 13 |
| Règle de Kaiser (pour Données Standardisées) . . . . .           | 14 |
| Méthode Basée sur l'Erreur de Reconstruction . . . . .           | 14 |
| Implications sur la Reconstruction . . . . .                     | 15 |
| Relation Exacte entre Nombre de Composantes et Qualité . . . . . | 15 |
| Compromis Dimension-Réconstruction . . . . .                     | 15 |
| Impact sur les Applications . . . . .                            | 16 |
| Approches Avancées et Considérations . . . . .                   | 17 |
| Validation Croisée . . . . .                                     | 17 |
| Critères d'Information . . . . .                                 | 17 |
| Considérations du Domaine d'Application . . . . .                | 17 |
| Exemple Pratique . . . . .                                       | 18 |
| Scénario Typique . . . . .                                       | 18 |
| Recommandations Générales . . . . .                              | 18 |
| Démarche Conseillée . . . . .                                    | 18 |
| Pièges à Éviter . . . . .                                        | 18 |
| Conclusion . . . . .                                             | 19 |

## Exam question

### Analyse en Composantes Principales (PCA) : Méthode, Calcul et Interprétation

#### Question

Expliquez en détail la méthode d'analyse en composantes principales (ACP), y compris les hypothèses, le calcul et l'interprétation de cette technique.

#### Introduction et Objectifs

L'**Analyse en Composantes Principales (PCA)** est une méthode de réduction de dimensionnalité qui transforme un ensemble de variables potentiellement corrélées en un ensemble de variables linéairement non corrélées appelées **composantes principales**.

## Objectifs Principaux

- Réduire la dimensionnalité des données tout en conservant l'information maximale
- Identifier les directions de plus grande variance dans les données
- Décorrélérer les variables
- Visualiser des données multidimensionnelles

## Hypothèses Fondamentales

### Hypothèses Statistiques

1. **Linéarité** : Les relations entre variables sont linéaires
2. **Distribution Normale** : Les données suivent approximativement une distribution gaussienne multivariée

$$X_i \sim \mathcal{N}(\bar{\mathbf{x}}, \Sigma)$$

3. **Importance de la Variance** : La variance est une mesure appropriée de l'information contenue dans les données
4. **Orthogonalité** : Les composantes principales sont orthogonales entre elles

### Prérequis sur les Données

- Les données doivent être **centrées** (moyenne nulle)
- Les échelles des variables doivent être comparables (normalisation recommandée)
- Pas de valeurs manquantes significatives

## Calcul des Composantes Principales

### Étape 1 : Préparation des Données

**Centrage** : Soustraire la moyenne de chaque variable

$$\mathbf{x}_i^{\text{centré}} = \mathbf{x}_i - \bar{\mathbf{x}}, \quad \text{où} \quad \bar{\mathbf{x}} = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i$$

**Normalisation (optionnelle mais recommandée)** : Diviser par l'écart-type

$$\mathbf{x}_i^{\text{norm}} = \frac{\mathbf{x}_i^{\text{centré}}}{\sigma}, \quad \text{où} \quad \sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2}$$

## Étape 2 : Calcul de la Matrice de Covariance

Pour  $N$  observations avec  $D$  variables, la matrice de covariance  $\Sigma$  est :

$$\Sigma = \frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top$$

**Propriétés de  $\Sigma$  :**

- Symétrique :  $\Sigma = \Sigma^\top$
- Semi-définie positive :  $\mathbf{v}^\top \Sigma \mathbf{v} \geq 0$  pour tout  $\mathbf{v}$
- Éléments diagonaux : variances des variables
- Éléments hors-diagonaux : covariances entre variables

## Étape 3 : Décomposition en Valeurs Propres

Nous cherchons les paires propres  $(\lambda_d, \mathbf{u}_d)$  telles que :

$$\Sigma \mathbf{u}_d = \lambda_d \mathbf{u}_d, \quad d = 1, \dots, D$$

**Ordre des valeurs propres :**  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_D \geq 0$

**Matrice des vecteurs propres :**  $\mathbf{U} = [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_D]$

**Relation Fondamentale : Valeur Propre = Variance**

## Démonstration Mathématique

### Étape 1 : Variance projetée

Soit  $\mathbf{u}$  un vecteur unitaire. La projection d'une observation  $\mathbf{x}_i$  sur  $\mathbf{u}$  est :

$$p_i = \mathbf{u}^\top \mathbf{x}_i$$

### Étape 2 : Calcul de la variance

La moyenne des projections (pour données centrées) est nulle :

$$\bar{p} = \mathbf{u}^\top \bar{\mathbf{x}} = 0$$

La variance des projections est donc :

$$\text{Var}(\mathbf{u}) = \frac{1}{N} \sum_{i=1}^N (p_i)^2 = \frac{1}{N} \sum_{i=1}^N (\mathbf{u}^\top \mathbf{x}_i)^2$$

### Étape 3 : Formulation matricielle

$$\text{Var}(\mathbf{u}) = \frac{1}{N} \sum_{i=1}^N \mathbf{u}^\top \mathbf{x}_i \mathbf{x}_i^\top \mathbf{u} = \mathbf{u}^\top \left( \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i^\top \right) \mathbf{u}$$

Or  $\frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i^\top = \Sigma$

Donc :

$$\text{Var}(\mathbf{u}) = \mathbf{u}^\top \Sigma \mathbf{u}$$

### Étape 4 : Maximisation sous contrainte

Nous cherchons  $\mathbf{u}_1$  maximisant  $\mathbf{u}^\top \Sigma \mathbf{u}$  sous  $\|\mathbf{u}\| = 1$ .

Lagrangien :

$$\mathcal{L}(\mathbf{u}, \lambda) = \mathbf{u}^\top \Sigma \mathbf{u} - \lambda(\mathbf{u}^\top \mathbf{u} - 1)$$

#### Explication concise du rôle de $\lambda$

Dans la PCA, on maximise  $\mathbf{u}^\top \Sigma \mathbf{u}$  sous la contrainte  $\mathbf{u}^\top \mathbf{u} = 1$ .

Le  $\lambda$  apparaît naturellement lorsqu'on utilise la **méthode des multiplicateurs de Lagrange** pour résoudre ce problème d'optimisation contrainte.

La fonction de Lagrange s'écrit :

$$\mathcal{L}(\mathbf{u}, \lambda) = \mathbf{u}^\top \Sigma \mathbf{u} - \lambda(\mathbf{u}^\top \mathbf{u} - 1)$$

Le terme  $-\lambda(\mathbf{u}^\top \mathbf{u} - 1)$  permet d'**incorporer la contrainte directement dans la fonction objectif**. Le multiplicateur  $\lambda$  sert de **paramètre de pénalité** qui garantit que la solution respecte la contrainte de norme unitaire.

Ainsi,  $\lambda$  est essentiellement un **artifice mathématique** qui nous permet de transformer un problème d'optimisation avec contrainte en un problème sans contrainte équivalent.

Condition d'optimalité :

$$\frac{\partial \mathcal{L}}{\partial \mathbf{u}} = 2\Sigma \mathbf{u} - 2\lambda \mathbf{u} = 0$$

Soit :

$$\Sigma \mathbf{u} = \lambda \mathbf{u}$$

### Étape 5 : Interprétation

Pour un vecteur propre  $\mathbf{u}_d$  satisfaisant  $\Sigma \mathbf{u}_d = \lambda_d \mathbf{u}_d$  :

$$\text{Var}(\mathbf{u}_d) = \mathbf{u}_d^\top \Sigma \mathbf{u}_d = \mathbf{u}_d^\top (\lambda_d \mathbf{u}_d) = \lambda_d \mathbf{u}_d^\top \mathbf{u}_d = \lambda_d$$

Car  $\mathbf{u}_d^\top \mathbf{u}_d = \|\mathbf{u}_d\|^2 = 1$ .

### Conclusion

Chaque valeur propre  $\lambda_d$  est exactement la variance des données projetées sur le vecteur propre correspondant  $\mathbf{u}_d$ .

### Ordre des Composantes

Nous ordonnons par valeurs propres décroissantes :

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_D \geq 0$$

Ainsi :

- $\mathbf{u}_1$  : direction de variance maximale
- $\mathbf{u}_2$  : direction orthogonale de variance maximale restante

### Étape 4 : Sélection des Composantes

#### Critère de Variance Expliquée

## Variance Totale

- Représente **toute l'information** contenue dans les données originales
- C'est la **référence** : 100% de l'information disponible

$$\text{Variance Totale} = \sum_{d=1}^D \lambda_d = \text{Tr}(\Sigma)$$

## Variance Expliquée

- Quantifie **l'information capturée** par chaque composante principale
- Correspond directement aux **valeurs propres**  $\lambda_d$  de  $\Sigma$
- Plus  $\lambda_d$  est grand, plus la composante explique de variance
- La **variance expliquée** par la composante  $d$  est :

$$\text{VarExpliquée}_d = \frac{\lambda_d}{\sum_{k=1}^D \lambda_k}$$

## Variance Cumulée

- Somme progressive des variances expliquées composante après composante
- Montre **combien d'information** on garde en sélectionnant  $K$  composantes
- Formule :  $\frac{\lambda_1 + \lambda_2 + \dots + \lambda_k}{\text{Variance totale}}$
- Mathématiquement, la **variance cumulée expliquée** pour  $K$  composantes est :

$$\text{VarCumulée}_K = \frac{\sum_{d=1}^K \lambda_d}{\sum_{d=1}^D \lambda_d}$$

## Utilité pratique

- **Choix du nombre de composantes** : On garde assez de composantes pour expliquer disons 80-95% de la variance totale
- **Réduction de dimension** : Conserver l'essentiel de l'information avec moins de variables
- **Interprétation** : Comprendre quelles composantes portent le plus d'information

**Exemple visuel** : Si PC1 explique 60% et PC2 explique 20%, alors avec 2 composantes on capture 80% de l'information totale.

## Règles de Sélection Courantes

- **Règle du coude (Elbow Method)** : Observer le “coude” dans le graphique des valeurs propres
- **Seuil de variance** : Conserver suffisamment de composantes pour expliquer 70-95% de la variance totale
- **Critère de Kaiser** : Conserver les composantes avec valeur propre  $> 1$  (si données normalisées)

## Étape 5 : Projection des Données

La projection des données originales sur les  $K$  premières composantes est :

$$\mathbf{y}_i = \mathbf{U}_K^\top (\mathbf{x}_i - \bar{\mathbf{x}})$$

où  $\mathbf{U}_K = [\mathbf{u}_1, \dots, \mathbf{u}_K]$  contient les  $K$  premiers vecteurs propres.

## Interprétation des Résultats

### Interprétation Géométrique

- **Composante Principale 1** : Direction de plus grande variance dans les données
- **Composante Principale 2** : Direction de plus grande variance orthogonale à la première
- **Espace latent** : Nouveau système de coordonnées optimisé pour la variance

### Charge des Composantes (Loadings)

Les éléments des vecteurs propres  $\mathbf{u}_d$  sont les **charges** (loadings) :

- **Grande valeur absolue** : La variable contribue fortement à la composante
- **Signe positif/négatif** : Indique la direction de la corrélation
- **Interprétation** : Les charges permettent de comprendre quelles variables originales définissent chaque composante

### Scores des Observations

Les coordonnées  $\mathbf{y}_i$  dans l'espace latent sont les **scores** :

- **Position relative** : Observations avec des scores similaires sont similaires dans l'espace original
- **Visualisation** : Plot 2D/3D des deux/trois premières composantes



## Cercle des Corrélations

Pour les données normalisées, on peut représenter :

- **Variables** : Vecteurs dont la longueur représente la qualité de représentation
- **Angles entre vecteurs** : Corrélations entre variables
- **Projection sur axes** : Corrélation avec les composantes

## Applications et Utilisations

### Réduction de Dimensionnalité

**Objectif** : Passer de  $D$  dimensions à  $K < D$  dimensions avec perte minimale d'information

**Formule de reconstruction** :

$$\tilde{\mathbf{x}}_i = \bar{\mathbf{x}} + \mathbf{U}_K \mathbf{y}_i$$

**Erreur de reconstruction** :

$$\mathcal{L} = \sum_{i=1}^N \|\mathbf{x}_i - \tilde{\mathbf{x}}_i\|^2 = \sum_{d=K+1}^D \lambda_d$$

### Visualisation de Données Multidimensionnelles

- **Projection 2D/3D** pour exploration visuelle
- **Identification de clusters** ou de structures
- **Détection d'observations atypiques** (outliers)

### Débruitage

Si le bruit est de faible variance par rapport au signal, PCA peut séparer :

- **Signal** : Capturé par les premières composantes
- **Bruit** : Capturé par les dernières composantes

## Pré-traitement pour Autres Algorithmes

- **Accélération** d'algorithmes (moins de dimensions)
- **Amélioration** de performances (élimination de colinéarités)
- **Réduction du surapprentissage** (overfitting)

## Limitations et Précautions

### Limitations de PCA

1. **Linéarité** : Ne capture pas les relations non-linéaires
2. **Sensibilité aux outliers** : La variance est sensible aux valeurs extrêmes
3. **Interprétation difficile** quand les composantes sont des combinaisons complexes de variables originales
4. **Échelle des variables** : Requier une normalisation préalable
5. **Distribution non-gaussienne** : Moins efficace pour des distributions non-normales

### Alternatives à Considérer

- **Kernel PCA** pour des relations non-linéaires
- **t-SNE, UMAP** pour visualisation non-linéaire
- **AutoEncodeurs** pour réduction non-linéaire
- **Factor Analysis** pour modèles avec bruit explicite

## Exemple d'Application Pas à Pas

### Étape 0 : Données Initiales

Soit une matrice de données  $\mathbf{X}$  de taille  $N \times D$

### Étape 1 : Centrage et Normalisation

```
# Pseudocode pour illustration
X_centered = X - mean(X, axis=0)
X_normalized = X_centered / std(X_centered, axis=0)
```

## Étape 2 : Calcul de la Matrice de Covariance

$$\Sigma = \frac{1}{N} \mathbf{X}_{\text{norm}}^{\top} \mathbf{X}_{\text{norm}}$$

## Étape 3 : Décomposition en Valeurs Propres

Résoudre  $\Sigma \mathbf{u}_d = \lambda_d \mathbf{u}_d$

## Étape 4 : Analyse des Valeurs Propres

Tableau de variance expliquée :

| Composante | Valeur Propre | Variance Expliquée | Variance Cumulée |
|------------|---------------|--------------------|------------------|
| PC1        | $\lambda_1$   | $v_1 \%$           | $v_1 \%$         |
| PC2        | $\lambda_2$   | $v_2 \%$           | $v_1 + v_2 \%$   |
| ...        | ...           | ...                | ...              |

## Étape 5 : Décision sur le Nombre de Composantes

- Graphique des valeurs propres (scree plot)
- Seuil de variance cumulée (ex: 80%)
- Analyse des charges pour interprétabilité

## Étape 6 : Projection et Interprétation

- Calcul des scores  $\mathbf{Y} = \mathbf{X}_{\text{norm}} \mathbf{U}_K$
- Visualisation des scores
- Analyse des charges pour nommer les composantes

## Conclusion

L'Analyse en Composantes Principales est une méthode puissante mais avec des hypothèses spécifiques :

- **Forte puissance** pour les données linéaires et gaussiennes
- **Interprétation géométrique** claire (maximisation de variance)
- **Calcul efficace** via décomposition en valeurs propres
- **Large applicabilité** en pré-traitement et visualisation

## Recommandations d'usage :

1. Toujours visualiser les données avant et après PCA
2. Vérifier les hypothèses (linéarité, normalité approximative)
3. Normaliser les variables si elles sont sur des échelles différentes
4. Interpréter les composantes via les charges
5. Valider les résultats sur des données de test

La compréhension approfondie de PCA fournit une base solide pour aborder des méthodes plus avancées de réduction de dimensionnalité et d'analyse de données.

## Choix du Nombre de Composantes en PCA

### Question

Lorsqu'on effectue une analyse en composantes principales (PCA), comment choisir le nombre de vecteurs propres à conserver ? Expliquez pourquoi et discutez des implications sur la reconstruction.

### Introduction au Problème de Sélection

Lorsque nous réalisons une Analyse en Composantes Principales, une question cruciale se pose : **combien de composantes principales devons-nous conserver ?** Ce choix représente un compromis fondamental entre :

- La **réduction de dimensionnalité** (objectif principal)
- La **conservation de l'information** (mesurée par la variance expliquée)
- La **qualité de reconstruction** des données originales

### Critères de Sélection Principaux

#### Basé sur la Variance Expliquée

##### Seuil de Variance Cumulée

La méthode la plus courante consiste à conserver suffisamment de composantes pour expliquer un pourcentage prédéfini de la variance totale.

##### Calcul :

Si nous avons  $D$  valeurs propres  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_D$ , la variance totale est :

$$\text{Variance Totale} = \sum_{d=1}^D \lambda_d$$

La variance expliquée par les  $K$  premières composantes est :

$$\text{Variance Expliquée}(K) = \sum_{d=1}^K \lambda_d$$

La proportion de variance expliquée est :

$$\text{PVE}(K) = \frac{\sum_{d=1}^K \lambda_d}{\sum_{d=1}^D \lambda_d}$$

**Règle pratique :** Choisir  $K$  tel que  $\text{PVE}(K) \geq \tau$ , où  $\tau$  est un seuil typiquement entre 70% et 95%.

**Avantages :**

- Simple à comprendre et à implémenter
- Garantit une conservation minimale d'information
- Standardisé et reproductible

**Inconvénients :**

- Le choix du seuil  $\tau$  est arbitraire
- Ne tient pas compte de la structure spécifique des données

## Analyse du Graphique des Valeurs Propres (Scree Plot)

### Méthode du “Coude”

Cette méthode visuelle consiste à tracer les valeurs propres en fonction de leur ordre.

**Procédure :**

1. Tracer  $\lambda_d$  en fonction de  $d$  (pour  $d = 1, 2, \dots, D$ )
2. Identifier le point où la courbe forme un “coude” (angle prononcé)
3. Conserver les composantes avant le coude

**Interprétation :**

- Les composantes avant le coude capturent le “signal” principal
- Les composantes après le coude capturent principalement du “bruit”

**Avantages :**

- Méthode intuitive et visuelle
- Prend en compte la décroissance relative des valeurs propres

**Inconvénients :**

- Subjectif (différentes personnes peuvent identifier des coudes différents)
- Peut être ambigu pour certaines distributions de valeurs propres

**Règle de Kaiser (pour Données Standardisées)****Seuil des Valeurs Propres  $> 1$** 

Lorsque les données sont standardisées (moyenne 0, variance 1), chaque variable originale contribue 1 à la variance totale.

**Règle :** Conserver les composantes dont la valeur propre  $\lambda_d > 1$ .

**Justification :** Une composante devrait expliquer au moins autant de variance qu'une variable originale unique.

**Limitations :**

- Ne s'applique qu'aux données standardisées
- Peut être trop conservateur (trop de composantes) ou trop laxiste (trop peu)

**Méthode Basée sur l'Erreur de Reconstruction****Minimisation de l'Erreur Quadratique**

Une approche plus formelle consiste à choisir  $K$  qui minimise l'erreur de reconstruction sous une contrainte.

**Erreur de reconstruction :** Pour chaque observation  $\mathbf{x}_i$ , la reconstruction utilisant  $K$  composantes est :

$$\tilde{\mathbf{x}}_i = \bar{\mathbf{x}} + \sum_{d=1}^K (\mathbf{u}_d^\top (\mathbf{x}_i - \bar{\mathbf{x}})) \mathbf{u}_d$$

L'erreur quadratique totale est :

$$\mathcal{L}(K) = \sum_{i=1}^N \|\mathbf{x}_i - \tilde{\mathbf{x}}_i\|^2 = \sum_{d=K+1}^D \lambda_d$$

**Relation importante :** L'erreur de reconstruction est exactement la somme des valeurs propres des composantes non conservées.

**Approche :** Choisir  $K$  tel que  $\mathcal{L}(K) \leq \epsilon$ , où  $\epsilon$  est un seuil d'erreur acceptable.

## Implications sur la Reconstruction

### Relation Exacte entre Nombre de Composantes et Qualité

#### Théorème d'Eckart-Young

Ce théorème fondamental établit que l'approximation de rang  $K$  par PCA est **optimale** au sens des moindres carrés.

**Formalisation :** Soit  $\mathbf{X}$  la matrice centrée des données. La décomposition en valeurs singulières (SVD) donne  $\mathbf{X} = \mathbf{U}\Sigma\mathbf{V}^\top$ . L'approximation de rang  $K$  :

$$\mathbf{X}_K = \mathbf{U}_K \Sigma_K \mathbf{V}_K^\top$$

minimise  $\|\mathbf{X} - \mathbf{X}_K\|_F^2$  parmi toutes les matrices de rang  $K$ .

**Implication :** PCA fournit la meilleure approximation de rang  $K$  pour les données centrées.

### Compromis Dimension-Réconstruction

#### Cas Extrêmes

- $K = D$  : Reconstruction parfaite
  - $\tilde{\mathbf{x}}_i = \mathbf{x}_i$  exactement
  - Aucune réduction de dimension
  - Conservation de 100% de la variance
- $K = 0$  : Reconstruction par la moyenne seule
  - $\tilde{\mathbf{x}}_i = \bar{\mathbf{x}}$
  - Erreur maximale :  $\mathcal{L}(0) = \sum_{d=1}^D \lambda_d$
  - Aucune information sur la variabilité individuelle

## Comportement Typique

La relation entre  $K$  et la qualité de reconstruction suit généralement une **loi des rendements décroissants** :

- Les premières composantes améliorent considérablement la reconstruction
- Les améliorations deviennent progressivement plus faibles
- Au-delà d'un certain point, les gains sont négligeables

## Impact sur les Applications

### Visualisation

Pour la visualisation en 2D ou 3D :

- $K = 2$  ou  $3$  : Permet une visualisation directe
- **Implication** : Perte importante d'information si les deux premières composantes n'expliquent pas suffisamment de variance
- **Solution** : Examiner plusieurs paires de composantes si nécessaire

### Débruitage

PCA peut servir à séparer signal et bruit :

- **Signal** : Capturé par les premières composantes (valeurs propres élevées)
- **Bruit** : Capturé par les dernières composantes (valeurs propres faibles)
- **Choix de  $K$**  : Doit être suffisant pour capturer le signal mais exclure le bruit

### Compression

Pour la compression de données :

- **Taux de compression** :  $\frac{K}{D} \times 100\%$
- **Distortion** : Mesurée par  $\frac{\sum_{d=K+1}^D \lambda_d}{\sum_{d=1}^D \lambda_d} \times 100\%$
- **Compromis** : Taux de compression vs qualité de reconstruction



## Approches Avancées et Considérations

### Validation Croisée

#### Méthode de Validation

Pour éviter le surajustement, on peut utiliser la validation croisée :

1. Diviser les données en ensembles d'entraînement et de test
2. Calculer PCA sur l'ensemble d'entraînement
3. Évaluer l'erreur de reconstruction sur l'ensemble de test
4. Choisir  $K$  qui minimise l'erreur de test

**Avantage :** Plus robuste, surtout pour de petits échantillons

### Critères d'Information

#### Critère d'Akaike (AIC) et BIC

Pour des données normalement distribuées, on peut utiliser des critères d'information :

- **AIC :** Équilibre entre qualité d'ajustement et complexité
- **BIC :** Pénalise plus fortement la complexité

Ces critères formulent le choix de  $K$  comme un problème de sélection de modèle.

### Considérations du Domaine d'Application

#### Connaissances Métier

Parfois, des considérations externes guident le choix de  $K$  :

- **Interprétabilité :** Se limiter à un nombre de composantes facile à interpréter
- **Contraintes techniques :** Limitations de stockage ou de traitement
- **Exigences applicatives :** Certaines applications nécessitent un nombre spécifique de dimensions

## Exemple Pratique

### Scénario Typique

Supposons une analyse sur des données avec  $D = 50$  variables et  $N = 1000$  observations.

**Valeurs propres :**  $\lambda_1 = 15.2$ ,  $\lambda_2 = 8.1$ ,  $\lambda_3 = 4.3$ ,  $\lambda_4 = 2.1$ ,  $\lambda_5 = 1.8$ , ...  $\lambda_{50} = 0.05$

**Calculs :**

- Variance totale :  $\sum \lambda_d = 50.0$  (car données standardisées)
- PVE(1) :  $15.2/50.0 = 30.4\%$
- PVE(2) :  $(15.2 + 8.1)/50.0 = 46.6\%$
- PVE(3) :  $(15.2 + 8.1 + 4.3)/50.0 = 55.2\%$
- PVE(4) :  $(15.2 + 8.1 + 4.3 + 2.1)/50.0 = 59.4\%$
- PVE(5) :  $(15.2 + 8.1 + 4.3 + 2.1 + 1.8)/50.0 = 63.0\%$

**Décisions possibles :**

1. **Seuil 80% :** Nécessiterait environ 10 composantes (calcul supplémentaire nécessaire)
2. **Règle de Kaiser :** 5 composantes ( $\lambda_5 = 1.8 > 1$ ,  $\lambda_6 = 0.9 < 1$ )
3. **Scree plot :** Coude probable après la 3ème ou 4ème composante
4. **Erreur reconstruction < 40% :**  $K$  tel que  $\sum_{d=K+1}^{50} \lambda_d < 20$  (40% de 50)

## Recommandations Générales

### Démarche Conseillée

1. **Commencez par standardiser** les données si les variables ont des échelles différentes
2. **Examinez le scree plot** pour une intuition visuelle
3. **Calculez la variance cumulée expliquée** pour différents  $K$
4. **Considérez la règle de Kaiser** si les données sont standardisées
5. **Évaluez les besoins de votre application** en termes de compression et qualité
6. **Testez la robustesse** par validation croisée si possible
7. **Vérifiez l'interprétabilité** des composantes retenues

### Pièges à Éviter

- **Trop peu de composantes :** Perte d'information importante, reconstruction médiocre
- **Trop de composantes :** Réduction de dimension insuffisante, capture du bruit
- **Ignorer le contexte :** Le choix optimal dépend de l'application finale
- **Oublier la validation :** Sur des petits échantillons, risque de surajustement

## Conclusion

Le choix du nombre de composantes en PCA est une décision cruciale qui influence directement la qualité de la reconstruction et l'utilité de l'analyse. Aucune méthode n'est universellement meilleure ; une approche combinant plusieurs critères est généralement recommandée.

**Rappel fondamental :** L'erreur de reconstruction est exactement la somme des valeurs propres des composantes exclues. Ce lien direct entre valeurs propres et qualité d'approximation fournit une base théorique solide pour guider la sélection.

En pratique, ce choix représente toujours un compromis entre simplicité (peu de dimensions) et fidélité (reconstruction précise), et doit être adapté aux objectifs spécifiques de l'analyse.