

Table of contents

Analyse en Composantes Principales (PCA) : Méthode, Calcul et Interprétation	2
Question	2
Introduction et Objectifs	2
Objectifs Principaux	2
Hypothèses Fondamentales	3
Hypothèses Statistiques	3
Prérequis sur les Données	3
Calcul des Composantes Principales	3
Étape 1 : Préparation des Données	3
Étape 2 : Calcul de la Matrice de Covariance	4
Étape 3 : Décomposition en Valeurs Propres	4
Étape 4 : Sélection des Composantes	6
Étape 5 : Projection des Données	7
Interprétation des Résultats	7
Interprétation Géométrique	7
Charge des Composantes (Loadings)	7
Scores des Observations	8
Cercle des Corrélations	8
Applications et Utilisations	8
Réduction de Dimensionnalité	8
Visualisation de Données Multidimensionnelles	8
Débruitage	9
Pré-traitement pour Autres Algorithmes	9
Limitations et Précautions	9
Limitations de PCA	9
Alternatives à Considérer	9
Exemple d'Application Pas à Pas	9
Étape 0 : Données Initiales	9
Étape 1 : Centrage et Normalisation	10
Étape 2 : Calcul de la Matrice de Covariance	10
Étape 3 : Décomposition en Valeurs Propres	10
Étape 4 : Analyse des Valeurs Propres	10
Étape 5 : Décision sur le Nombre de Composantes	10
Étape 6 : Projection et Interprétation	10
Conclusion	11
Choix du Nombre de Composantes en PCA	11
Question	11
Introduction au Problème de Sélection	11

Critères de Sélection Principaux	12
Basé sur la Variance Expliquée	12
Analyse du Graphique des Valeurs Propres (Scree Plot)	13
Règle de Kaiser (pour Données Standardisées)	13
Méthode Basée sur l'Erreur de Reconstruction	14
Implications sur la Reconstruction	14
Relation Exacte entre Nombre de Composantes et Qualité	14
Compromis Dimension-Réconstruction	15
Impact sur les Applications	15
Approches Avancées et Considérations	16
Validation Croisée	16
Critères d'Information	16
Considérations du Domaine d'Application	16
Exemple Pratique	17
Scénario Typique	17
Recommandations Générales	17
Démarche Conseillée	17
Pièges à Éviter	17
Conclusion	18

Analyse en Composantes Principales (PCA) : Méthode, Calcul et Interprétation

Question

Expliquez en détail la méthode d'analyse en composantes principales (ACP), y compris les hypothèses, le calcul et l'interprétation de cette technique.

Introduction et Objectifs

L'**Analyse en Composantes Principales (PCA)** est une méthode de réduction de dimensionnalité qui transforme un ensemble de variables potentiellement corrélées en un ensemble de variables linéairement non corrélées appelées **composantes principales**.

Objectifs Principaux

- Réduire la dimensionnalité des données tout en conservant l'information maximale
- Identifier les directions de plus grande variance dans les données
- Décorrélérer les variables
- Visualiser des données multidimensionnelles

Hypothèses Fondamentales

Hypothèses Statistiques

1. **Linéarité** : Les relations entre variables sont linéaires
2. **Distribution Normale** : Les données suivent approximativement une distribution gaussienne multivariée

$$X_i \sim \mathcal{N}(\bar{\mathbf{x}}, \Sigma)$$

3. **Importance de la Variance** : La variance est une mesure appropriée de l'information contenue dans les données
4. **Orthogonalité** : Les composantes principales sont orthogonales entre elles

Prérequis sur les Données

- Les données doivent être **centrées** (moyenne nulle)
- Les échelles des variables doivent être comparables (normalisation recommandée)
- Pas de valeurs manquantes significatives

Calcul des Composantes Principales

Étape 1 : Préparation des Données

Centrage : Soustraire la moyenne de chaque variable

$$\mathbf{x}_i^{\text{centré}} = \mathbf{x}_i - \bar{\mathbf{x}}, \quad \text{où} \quad \bar{\mathbf{x}} = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i$$

Normalisation (optionnelle mais recommandée) : Diviser par l'écart-type

$$\mathbf{x}_i^{\text{norm}} = \frac{\mathbf{x}_i^{\text{centré}}}{\sigma}, \quad \text{où} \quad \sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2}$$

Étape 2 : Calcul de la Matrice de Covariance

Pour N observations avec D variables, la matrice de covariance Σ est :

$$\Sigma = \frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top$$

Propriétés de Σ :

- Symétrique : $\Sigma = \Sigma^\top$
- Semi-définie positive : $\mathbf{v}^\top \Sigma \mathbf{v} \geq 0$ pour tout $\mathbf{v}$
- Éléments diagonaux : variances des variables
- Éléments hors-diagonaux : covariances entre variables

Étape 3 : Décomposition en Valeurs Propres

Nous cherchons les paires propres $(\lambda_d, \mathbf{u}_d)$ telles que :

$$\Sigma \mathbf{u}_d = \lambda_d \mathbf{u}_d, \quad d = 1, \dots, D$$

Ordre des valeurs propres : $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_D \geq 0$

Matrice des vecteurs propres : $\mathbf{U} = [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_D]$

Relation Fondamentale : Valeur Propre = Variance

Démonstration Mathématique

Étape 1 : Variance projetée

Soit $\mathbf{u}$ un vecteur unitaire. La projection d'une observation $\mathbf{x}_i$ sur $\mathbf{u}$ est :

$$p_i = \mathbf{u}^\top \mathbf{x}_i$$

Étape 2 : Calcul de la variance

La moyenne des projections (pour données centrées) est nulle :

$$\bar{p} = \mathbf{u}^\top \bar{\mathbf{x}} = 0$$

La variance des projections est donc :

$$\text{Var}(\mathbf{u}) = \frac{1}{N} \sum_{i=1}^N (p_i)^2 = \frac{1}{N} \sum_{i=1}^N (\mathbf{u}^\top \mathbf{x}_i)^2$$

Étape 3 : Formulation matricielle

$$\text{Var}(\mathbf{u}) = \frac{1}{N} \sum_{i=1}^N \mathbf{u}^\top \mathbf{x}_i \mathbf{x}_i^\top \mathbf{u} = \mathbf{u}^\top \left(\frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i^\top \right) \mathbf{u}$$

Or $\frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \mathbf{x}_i^\top = \Sigma$

Donc :

$$\text{Var}(\mathbf{u}) = \mathbf{u}^\top \Sigma \mathbf{u}$$

Étape 4 : Maximisation sous contrainte

Nous cherchons $\mathbf{u}_1$ maximisant $\mathbf{u}^\top \Sigma \mathbf{u}$ sous $\|\mathbf{u}\| = 1$.

Lagrangien :

$$\mathcal{L}(\mathbf{u}, \lambda) = \mathbf{u}^\top \Sigma \mathbf{u} - \lambda(\mathbf{u}^\top \mathbf{u} - 1)$$

Explication concise du rôle de λ

Dans la PCA, on maximise $\mathbf{u}^\top \Sigma \mathbf{u}$ sous la contrainte $\mathbf{u}^\top \mathbf{u} = 1$.

Le λ apparaît naturellement lorsqu'on utilise la **méthode des multiplicateurs de Lagrange** pour résoudre ce problème d'optimisation contrainte.

La fonction de Lagrange s'écrit :

$$\mathcal{L}(\mathbf{u}, \lambda) = \mathbf{u}^\top \Sigma \mathbf{u} - \lambda(\mathbf{u}^\top \mathbf{u} - 1)$$

Le terme $-\lambda(\mathbf{u}^\top \mathbf{u} - 1)$ permet d'**incorporer la contrainte directement dans la fonction objectif**. Le multiplicateur λ sert de **paramètre de pénalité** qui garantit que la solution respecte la contrainte de norme unitaire.

Ainsi, λ est essentiellement un **artifice mathématique** qui nous permet de transformer un problème d'optimisation avec contrainte en un problème sans contrainte équivalent.

Condition d'optimalité :

$$\frac{\partial \mathcal{L}}{\partial \mathbf{u}} = 2\Sigma \mathbf{u} - 2\lambda \mathbf{u} = 0$$

Soit :

$$\Sigma \mathbf{u} = \lambda \mathbf{u}$$

Étape 5 : Interprétation

Pour un vecteur propre $\mathbf{u}_d$ satisfaisant $\Sigma \mathbf{u}_d = \lambda_d \mathbf{u}_d$:

$$\text{Var}(\mathbf{u}_d) = \mathbf{u}_d^\top \Sigma \mathbf{u}_d = \mathbf{u}_d^\top (\lambda_d \mathbf{u}_d) = \lambda_d \mathbf{u}_d^\top \mathbf{u}_d = \lambda_d$$

Car $\mathbf{u}_d^\top \mathbf{u}_d = \|\mathbf{u}_d\|^2 = 1$.

Conclusion

Chaque valeur propre λ_d est exactement la variance des données projetées sur le vecteur propre correspondant $\mathbf{u}_d$.

Ordre des Composantes

Nous ordonnons par valeurs propres décroissantes :

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_D \geq 0$$

Ainsi :

- $\mathbf{u}_1$: direction de variance maximale
- $\mathbf{u}_2$: direction orthogonale de variance maximale restante

Étape 4 : Sélection des Composantes

Critère de Variance Expliquée

Variance totale :

$$\text{Variance Totale} = \sum_{d=1}^D \lambda_d = \text{Tr}(\Sigma)$$

La **variance expliquée** par la composante d est :

$$\text{VarExpliquée}_d = \frac{\lambda_d}{\sum_{k=1}^D \lambda_k}$$

La **variance cumulée expliquée** pour K composantes est :

$$\text{VarCumulée}_K = \frac{\sum_{d=1}^K \lambda_d}{\sum_{d=1}^D \lambda_d}$$

Règles de Sélection Courantes

- **Règle du coude (Elbow Method)** : Observer le “coude” dans le graphique des valeurs propres
- **Seuil de variance** : Conserver suffisamment de composantes pour expliquer 70-95% de la variance totale
- **Critère de Kaiser** : Conserver les composantes avec valeur propre > 1 (si données normalisées)

Étape 5 : Projection des Données

La projection des données originales sur les K premières composantes est :

$$\mathbf{y}_i = \mathbf{U}_K^\top (\mathbf{x}_i - \bar{\mathbf{x}})$$

où $\mathbf{U}_K = [\mathbf{u}_1, \dots, \mathbf{u}_K]$ contient les K premiers vecteurs propres.

Interprétation des Résultats

Interprétation Géométrique

- **Composante Principale 1** : Direction de plus grande variance dans les données
- **Composante Principale 2** : Direction de plus grande variance orthogonale à la première
- **Espace latent** : Nouveau système de coordonnées optimisé pour la variance

Charge des Composantes (Loadings)

Les éléments des vecteurs propres $\mathbf{u}_d$ sont les **charges** (loadings) :

- **Grande valeur absolue** : La variable contribue fortement à la composante
- **Signe positif/négatif** : Indique la direction de la corrélation
- **Interprétation** : Les charges permettent de comprendre quelles variables originales définissent chaque composante

Scores des Observations

Les coordonnées $\mathbf{y}_i$ dans l'espace latent sont les **scores** :

- **Position relative** : Observations avec des scores similaires sont similaires dans l'espace original
- **Visualisation** : Plot 2D/3D des deux/trois premières composantes

Cercle des Corrélations

Pour les données normalisées, on peut représenter :

- **Variables** : Vecteurs dont la longueur représente la qualité de représentation
- **Angles entre vecteurs** : Corrélations entre variables
- **Projection sur axes** : Corrélation avec les composantes

Applications et Utilisations

Réduction de Dimensionnalité

Objectif : Passer de D dimensions à $K < D$ dimensions avec perte minimale d'information

Formule de reconstruction :

$$\tilde{\mathbf{x}}_i = \bar{\mathbf{x}} + \mathbf{U}_K \mathbf{y}_i$$

Erreur de reconstruction :

$$\mathcal{L} = \sum_{i=1}^N \|\mathbf{x}_i - \tilde{\mathbf{x}}_i\|^2 = \sum_{d=K+1}^D \lambda_d$$

Visualisation de Données Multidimensionnelles

- **Projection 2D/3D** pour exploration visuelle
- **Identification de clusters** ou de structures
- **Détection d'observations atypiques** (outliers)

Débruitage

Si le bruit est de faible variance par rapport au signal, PCA peut séparer :

- **Signal** : Capturé par les premières composantes
- **Bruit** : Capturé par les dernières composantes

Pré-traitement pour Autres Algorithmes

- **Accélération** d'algorithmes (moins de dimensions)
- **Amélioration** de performances (élimination de colinéarités)
- **Réduction du surapprentissage** (overfitting)

Limitations et Précautions

Limitations de PCA

1. **Linéarité** : Ne capture pas les relations non-linéaires
2. **Sensibilité aux outliers** : La variance est sensible aux valeurs extrêmes
3. **Interprétation difficile** quand les composantes sont des combinaisons complexes de variables originales
4. **Échelle des variables** : Requiert une normalisation préalable
5. **Distribution non-gaussienne** : Moins efficace pour des distributions non-normales

Alternatives à Considérer

- **Kernel PCA** pour des relations non-linéaires
- **t-SNE, UMAP** pour visualisation non-linéaire
- **AutoEncodeurs** pour réduction non-linéaire
- **Factor Analysis** pour modèles avec bruit explicite

Exemple d'Application Pas à Pas

Étape 0 : Données Initiales

Soit une matrice de données $\mathbf{X}$ de taille $N \times D$

Étape 1 : Centrage et Normalisation

```
# Pseudocode pour illustration
X_centered = X - mean(X, axis=0)
X_normalized = X_centered / std(X_centered, axis=0)
```

Étape 2 : Calcul de la Matrice de Covariance

$$\Sigma = \frac{1}{N} \mathbf{X}_{\text{norm}}^{\top} \mathbf{X}_{\text{norm}}$$

Étape 3 : Décomposition en Valeurs Propres

Résoudre $\Sigma \mathbf{u}_d = \lambda_d \mathbf{u}_d$

Étape 4 : Analyse des Valeurs Propres

Tableau de variance expliquée :

Composante	Valeur Propre	Variance Expliquée	Variance Cumulée
PC1	λ_1	$v_1 \%$	$v_1 \%$
PC2	λ_2	$v_2 \%$	$v_1 + v_2 \%$
...	...	...	...

Étape 5 : Décision sur le Nombre de Composantes

- Graphique des valeurs propres (scree plot)
- Seuil de variance cumulée (ex: 80%)
- Analyse des charges pour interprétabilité

Étape 6 : Projection et Interprétation

- Calcul des scores $\mathbf{Y} = \mathbf{X}_{\text{norm}} \mathbf{U}_K$
- Visualisation des scores
- Analyse des charges pour nommer les composantes

Conclusion

L'Analyse en Composantes Principales est une méthode puissante mais avec des hypothèses spécifiques :

- **Forte puissance** pour les données linéaires et gaussiennes
- **Interprétation géométrique** claire (maximisation de variance)
- **Calcul efficace** via décomposition en valeurs propres
- **Large applicabilité** en pré-traitement et visualisation

Recommandations d'usage :

1. Toujours visualiser les données avant et après PCA
2. Vérifier les hypothèses (linéarité, normalité approximative)
3. Normaliser les variables si elles sont sur des échelles différentes
4. Interpréter les composantes via les charges
5. Valider les résultats sur des données de test

La compréhension approfondie de PCA fournit une base solide pour aborder des méthodes plus avancées de réduction de dimensionnalité et d'analyse de données.

Choix du Nombre de Composantes en PCA

Question

Lorsqu'on effectue une analyse en composantes principales (PCA), comment choisir le nombre de vecteurs propres à conserver ? Expliquez pourquoi et discutez des implications sur la reconstruction.

Introduction au Problème de Sélection

Lorsque nous réalisons une Analyse en Composantes Principales, une question cruciale se pose : **combien de composantes principales devons-nous conserver ?** Ce choix représente un compromis fondamental entre :

- La **réduction de dimensionnalité** (objectif principal)
- La **conservation de l'information** (mesurée par la variance expliquée)
- La **qualité de reconstruction** des données originales

Critères de Sélection Principaux

Basé sur la Variance Expliquée

Seuil de Variance Cumulée

La méthode la plus courante consiste à conserver suffisamment de composantes pour expliquer un pourcentage prédéfini de la variance totale.

Calcul :

Si nous avons D valeurs propres $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_D$, la variance totale est :

$$\text{Variance Totale} = \sum_{d=1}^D \lambda_d$$

La variance expliquée par les K premières composantes est :

$$\text{Variance Expliquée}(K) = \sum_{d=1}^K \lambda_d$$

La proportion de variance expliquée est :

$$\text{PVE}(K) = \frac{\sum_{d=1}^K \lambda_d}{\sum_{d=1}^D \lambda_d}$$

Règle pratique : Choisir K tel que $\text{PVE}(K) \geq \tau$, où τ est un seuil typiquement entre 70% et 95%.

Avantages :

- Simple à comprendre et à implémenter
- Garantit une conservation minimale d'information
- Standardisé et reproductible

Inconvénients :

- Le choix du seuil τ est arbitraire
- Ne tient pas compte de la structure spécifique des données

Analyse du Graphique des Valeurs Propres (Scree Plot)

Méthode du “Coude”

Cette méthode visuelle consiste à tracer les valeurs propres en fonction de leur ordre.

Procédure :

1. Tracer λ_d en fonction de d (pour $d = 1, 2, \dots, D$)
2. Identifier le point où la courbe forme un “coude” (angle prononcé)
3. Conserver les composantes avant le coude

Interprétation :

- Les composantes avant le coude capturent le “signal” principal
- Les composantes après le coude capturent principalement du “bruit”

Avantages :

- Méthode intuitive et visuelle
- Prend en compte la décroissance relative des valeurs propres

Inconvénients :

- Subjectif (différentes personnes peuvent identifier des coudes différents)
- Peut être ambigu pour certaines distributions de valeurs propres

Règle de Kaiser (pour Données Standardisées)

Seuil des Valeurs Propres > 1

Lorsque les données sont standardisées (moyenne 0, variance 1), chaque variable originale contribue 1 à la variance totale.

Règle : Conserver les composantes dont la valeur propre $\lambda_d > 1$.

Justification : Une composante devrait expliquer au moins autant de variance qu’une variable originale unique.

Limitations :

- Ne s’applique qu’aux données standardisées
- Peut être trop conservateur (trop de composantes) ou trop laxiste (trop peu)

Méthode Basée sur l'Erreur de Reconstruction

Minimisation de l'Erreur Quadratique

Une approche plus formelle consiste à choisir K qui minimise l'erreur de reconstruction sous une contrainte.

Erreur de reconstruction : Pour chaque observation $\mathbf{x}_i$, la reconstruction utilisant K composantes est :

$$\tilde{\mathbf{x}}_i = \bar{\mathbf{x}} + \sum_{d=1}^K (\mathbf{u}_d^\top (\mathbf{x}_i - \bar{\mathbf{x}})) \mathbf{u}_d$$

L'erreur quadratique totale est :

$$\mathcal{L}(K) = \sum_{i=1}^N \|\mathbf{x}_i - \tilde{\mathbf{x}}_i\|^2 = \sum_{d=K+1}^D \lambda_d$$

Relation importante : L'erreur de reconstruction est exactement la somme des valeurs propres des composantes non conservées.

Approche : Choisir K tel que $\mathcal{L}(K) \leq \epsilon$, où ϵ est un seuil d'erreur acceptable.

Implications sur la Reconstruction

Relation Exacte entre Nombre de Composantes et Qualité

Théorème d'Eckart-Young

Ce théorème fondamental établit que l'approximation de rang K par PCA est **optimale** au sens des moindres carrés.

Formalisation : Soit $\mathbf{X}$ la matrice centrée des données. La décomposition en valeurs singulières (SVD) donne $\mathbf{X} = \mathbf{U}\Sigma\mathbf{V}^\top$. L'approximation de rang K :

$$\mathbf{X}_K = \mathbf{U}_K \Sigma_K \mathbf{V}_K^\top$$

minimise $\|\mathbf{X} - \mathbf{X}_K\|_F^2$ parmi toutes les matrices de rang K .

Implication : PCA fournit la meilleure approximation de rang K pour les données centrées.

Compromis Dimension-Réconstruction

Cas Extrêmes

- $K = D$: Reconstruction parfaite
 - $\tilde{\mathbf{x}}_i = \mathbf{x}_i$ exactement
 - Aucune réduction de dimension
 - Conservation de 100% de la variance
- $K = 0$: Reconstruction par la moyenne seule
 - $\tilde{\mathbf{x}}_i = \bar{\mathbf{x}}$
 - Erreur maximale : $\mathcal{L}(0) = \sum_{d=1}^D \lambda_d$
 - Aucune information sur la variabilité individuelle

Comportement Typique

La relation entre K et la qualité de reconstruction suit généralement une **loi des rendements décroissants** :

- Les premières composantes améliorent considérablement la reconstruction
- Les améliorations deviennent progressivement plus faibles
- Au-delà d'un certain point, les gains sont négligeables

Impact sur les Applications

Visualisation

Pour la visualisation en 2D ou 3D :

- $K = 2$ ou 3 : Permet une visualisation directe
- **Implication** : Perte importante d'information si les deux premières composantes n'expliquent pas suffisamment de variance
- **Solution** : Examiner plusieurs paires de composantes si nécessaire

Débruitage

PCA peut servir à séparer signal et bruit :

- **Signal** : Capturé par les premières composantes (valeurs propres élevées)
- **Bruit** : Capturé par les dernières composantes (valeurs propres faibles)
- **Choix de K** : Doit être suffisant pour capturer le signal mais exclure le bruit

Compression

Pour la compression de données :

- **Taux de compression** : $\frac{K}{D} \times 100\%$
- **Distortion** : Mesurée par $\frac{\sum_{d=K+1}^D \lambda_d}{\sum_{d=1}^D \lambda_d} \times 100\%$
- **Compromis** : Taux de compression vs qualité de reconstruction

Approches Avancées et Considérations

Validation Croisée

Méthode de Validation

Pour éviter le surajustement, on peut utiliser la validation croisée :

1. Diviser les données en ensembles d'entraînement et de test
2. Calculer PCA sur l'ensemble d'entraînement
3. Évaluer l'erreur de reconstruction sur l'ensemble de test
4. Choisir K qui minimise l'erreur de test

Avantage : Plus robuste, surtout pour de petits échantillons

Critères d'Information

Critère d'Akaike (AIC) et BIC

Pour des données normalement distribuées, on peut utiliser des critères d'information :

- **AIC** : Équilibre entre qualité d'ajustement et complexité
- **BIC** : Pénalise plus fortement la complexité

Ces critères formulent le choix de K comme un problème de sélection de modèle.

Considérations du Domaine d'Application

Connaissances Métier

Parfois, des considérations externes guident le choix de K :

- **Interprétabilité** : Se limiter à un nombre de composantes facile à interpréter
- **Contraintes techniques** : Limitations de stockage ou de traitement
- **Exigences applicatives** : Certaines applications nécessitent un nombre spécifique de dimensions

Exemple Pratique

Scénario Typique

Supposons une analyse sur des données avec $D = 50$ variables et $N = 1000$ observations.

Valeurs propres : $\lambda_1 = 15.2$, $\lambda_2 = 8.1$, $\lambda_3 = 4.3$, $\lambda_4 = 2.1$, $\lambda_5 = 1.8$, ... $\lambda_{50} = 0.05$

Calculs :

- Variance totale : $\sum \lambda_d = 50.0$ (car données standardisées)
- PVE(1) : $15.2/50.0 = 30.4\%$
- PVE(2) : $(15.2 + 8.1)/50.0 = 46.6\%$
- PVE(3) : $(15.2 + 8.1 + 4.3)/50.0 = 55.2\%$
- PVE(4) : $(15.2 + 8.1 + 4.3 + 2.1)/50.0 = 59.4\%$
- PVE(5) : $(15.2 + 8.1 + 4.3 + 2.1 + 1.8)/50.0 = 63.0\%$

Décisions possibles :

1. **Seuil 80% :** Nécessiterait environ 10 composantes (calcul supplémentaire nécessaire)
2. **Règle de Kaiser :** 5 composantes ($\lambda_5 = 1.8 > 1$, $\lambda_6 = 0.9 < 1$)
3. **Scree plot :** Coude probable après la 3ème ou 4ème composante
4. **Erreur reconstruction < 40% :** K tel que $\sum_{d=K+1}^{50} \lambda_d < 20$ (40% de 50)

Recommandations Générales

Démarche Conseillée

1. **Commencez par standardiser** les données si les variables ont des échelles différentes
2. **Examinez le scree plot** pour une intuition visuelle
3. **Calculez la variance cumulée expliquée** pour différents K
4. **Considérez la règle de Kaiser** si les données sont standardisées
5. **Évaluez les besoins de votre application** en termes de compression et qualité
6. **Testez la robustesse** par validation croisée si possible
7. **Vérifiez l'interprétabilité** des composantes retenues

Pièges à Éviter

- **Trop peu de composantes :** Perte d'information importante, reconstruction médiocre
- **Trop de composantes :** Réduction de dimension insuffisante, capture du bruit
- **Ignorer le contexte :** Le choix optimal dépend de l'application finale
- **Oublier la validation :** Sur des petits échantillons, risque de surajustement

Conclusion

Le choix du nombre de composantes en PCA est une décision cruciale qui influence directement la qualité de la reconstruction et l'utilité de l'analyse. Aucune méthode n'est universellement meilleure ; une approche combinant plusieurs critères est généralement recommandée.

Rappel fondamental : L'erreur de reconstruction est exactement la somme des valeurs propres des composantes exclues. Ce lien direct entre valeurs propres et qualité d'approximation fournit une base théorique solide pour guider la sélection.

En pratique, ce choix représente toujours un compromis entre simplicité (peu de dimensions) et fidélité (reconstruction précise), et doit être adapté aux objectifs spécifiques de l'analyse.