

Table of contents

Cours : Analyse Discriminante Linéaire (LDA)	1
Introduction à la LDA	1
Contexte d'Apprentissage Supervisé	2
Définition Formelle	2
Exemples de Méthodes Supervisées	2
Intuition Géométrique de la LDA	2
Le Problème Fondamental	2
Concepts Clés : Critère Inter-Classe et Intra-Classe	3
Critère Inter-Classe (Between-Class)	3
Critère Intra-Classe (Within-Class)	5
Le Critère de Fisher : Combinaison des Deux Critères	6
Conséquence pour le Critère de Fisher	8
Solution du Problème d'Optimisation	8
Généralisation à Plusieurs Dimensions	9
Visualisation des Concepts	10
Exemple en Deux Dimensions	10
Interprétation Géométrique	12
Modélisation conditionnelle en classification supervisée	12
Cadre bayésien pour la classification	12
L'Analyse Discriminante Linéaire (LDA) comme modèle génératif conditionnel	13
Dérivation de la fonction discriminante linéaire	14
Avantages et Limitations	15
Avantages de la LDA	15
Limitations	15
Alternatives et Extensions	15
Comparaison avec d'Autres Méthodes	15
LDA vs PCA	15
LDA vs Régression Logistique	16
Applications Pratiques	16
Domaines d'Application	16
Bonnes Pratiques	17
Conclusion	18

Cours : Analyse Discriminante Linéaire (LDA)

Introduction à la LDA

L'Analyse Discriminante Linéaire (LDA) est une méthode statistique supervisée qui remplit deux objectifs principaux :

- La **réduction de dimension** en trouvant les directions les plus discriminantes
- La **classification** par modélisation probabiliste des classes

Contrairement à l'Analyse en Composantes Principales (PCA) qui est non supervisée, la LDA utilise les étiquettes de classe pour trouver les directions qui maximisent la séparation entre groupes.

Contexte d'Apprentissage Supervisé

Définition Formelle

Dans un problème d'apprentissage supervisé, nous disposons de :

- Données $X \subset \Omega \subset \mathbb{R}^D$
- Étiquettes de classe $y = [M] \subset \mathbb{N}$

Nous cherchons à apprendre une fonction ϕ_θ qui minimise une perte $\mathcal{L}_{X \times y}(\theta)$ lorsqu'elle prédit les étiquettes.

Exemples de Méthodes Supervisées

- Régression logistique
- Réseaux de neurones
- Machines à vecteurs de support (SVM)

La LDA se distingue par son approche **génératrice** : elle modélise la distribution des données dans chaque classe.

Intuition Géométrique de la LDA

Le Problème Fondamental

Imaginons des points en deux dimensions appartenant à deux classes. Comment trouver la **meilleure droite** sur laquelle projeter ces points pour les séparer le plus possible ?

La LDA répond à cette question en cherchant une direction qui :

1. **Éloigne les centres** des classes (maximise la distance entre moyennes)
 2. **Rapproche les points** à l'intérieur de chaque classe (minimise la variance intra-classe)
-

Concepts Clés : Critère Inter-Classe et Intra-Classe

Notations de Base

Pour K classes :

- N_k : nombre d'observations dans la classe k
 - μ_k : moyenne de la classe k (vecteur de dimension D)
 - μ : moyenne globale
 - $x_i^{(k)}$: la i -ème observation de la classe k
-

Critère Inter-Classe (Between-Class)

Intuition

Le critère inter-classe mesure **à quel point les centres des classes sont éloignés les uns des autres**.

Plus les moyennes des classes sont distantes, plus il sera facile de les discriminer.

Formulation Mathématique

Distance entre deux classes (cas binaire) :

Pour deux classes avec moyennes μ_1 et μ_2 , la distance carrée entre leurs projections sur une direction a est :

$$\|\hat{\mu}_1 - \hat{\mu}_2\|^2 = \frac{(a^T(\mu_1 - \mu_2))^2}{\|a\|^2}$$

où $\hat{\mu}_k = \frac{a^T \mu_k}{\|a\|}$ est la projection de la moyenne de la classe k .

Cas général

La matrice capture la covariance des centres des classes par rapport à la moyenne globale.

Version Normale (Sommaire)

Formulation Pondérée

$$\Sigma_b = \sum_{k=1}^K N_k (\mu_k - \mu)(\mu_k - \mu)^T$$

Formulation Non Pondérée

$$\Sigma_b = \frac{1}{K} \sum_{k=1}^K (\mu_k - \mu)(\mu_k - \mu)^T$$

Version Matricielle

Formulation Pondérée

Soit M la matrice $D \times K$ où chaque colonne k est $\sqrt{N_k}(\mu_k - \mu)$:

$$M = [\sqrt{N_1}(\mu_1 - \mu) \quad \sqrt{N_2}(\mu_2 - \mu) \quad \cdots \quad \sqrt{N_K}(\mu_K - \mu)]$$

Alors :

$$\Sigma_b = MM^T$$

Formulation Non Pondérée

Soit M' la matrice $D \times K$ où chaque colonne k est $(\mu_k - \mu)$:

$$M' = [(\mu_1 - \mu) \quad (\mu_2 - \mu) \quad \cdots \quad (\mu_K - \mu)]$$

Alors :

$$\Sigma_b = \frac{1}{K} M' M'^T$$

Équivalence entre les Formulations

Relation

Les deux formulations donnent la même matrice à un facteur d'échelle près :

$$MM^T = \left(\sum_{k=1}^K N_k \right) \cdot \frac{1}{K} M' M'^T$$

quand $N_1 = N_2 = \dots = N_K$ (classes équilibrées).

Pour la LDA

Cette différence d'échelle n'affecte pas les directions discriminantes, seulement leur amplitude dans le critère de Fisher.

Interprétation Géométrique

Σ_b est une matrice $D \times D$ qui mesure :

- Comment les centres des classes varient autour de la moyenne globale
- La dispersion “entre” les différentes classes

La quantité $a^T \Sigma_b a$ représente la **variance inter-classes projetée** sur la direction a .

Propriété Importante

Pour K classes, la matrice Σ_b a un rang au plus $K - 1$.

Cela signifie qu'il existe au plus $K - 1$ directions indépendantes qui séparent les classes.

Critère Intra-Classe (Within-Class)

Intuition

Le critère intra-classe mesure **à quel point les points d'une même classe sont regroupés**. Plus les points d'une classe sont concentrés, plus la classe est homogène et facile à identifier.

Formulation Mathématique

Pour chaque classe k , on définit sa matrice de covariance :

$$\Sigma_k = \frac{1}{N_k} \sum_{i=1}^{N_k} (x_i^{(k)} - \mu_k)(x_i^{(k)} - \mu_k)^T$$

Matrice de dispersion intra-classes totale :

$$\Sigma_w = \sum_{k=1}^K \Sigma_k = \sum_{k=1}^K \sum_{i=1}^{N_k} (x_i^{(k)} - \mu_k)(x_i^{(k)} - \mu_k)^T$$

Interprétation

Σ_w mesure la **dispersion globale à l'intérieur de toutes les classes**.

Une petite valeur de $a^T \Sigma_w a$ indique que les projections des points sont regroupées autour de leur moyenne de classe.

Le Critère de Fisher : Combinaison des Deux Critères

Principe

Nous cherchons une direction a qui :

- Maximise la dispersion inter-classes : $a^T \Sigma_b a$ (grand)
- Minimise la dispersion intra-classes : $a^T \Sigma_w a$ (petit)

Le **critère de Fisher** combine ces deux objectifs en un seul ratio :

$$J(a) = \frac{a^T \Sigma_b a}{a^T \Sigma_w a}$$

Interprétation du Ratio

$J(a)$ représente le **rapport signal/bruit** pour la discrimination :

- **Numérateur** : “signal” = séparation entre classes
- **Dénominateur** : “bruit” = variabilité à l'intérieur des classes

Plus $J(a)$ est grand, meilleure est la direction a pour discriminer les classes.

Optimisation

Nous cherchons la direction a^* qui maximise $J(a)$:

$$a^* = \arg \max_a \frac{a^T \Sigma_b a}{a^T \Sigma_w a}$$

Ce problème d'optimisation a une solution analytique.

Projection des Critères Inter et Intra-Classes

Lorsqu'on projette sur une direction a (non nécessairement unitaire), les statistiques projetées comportent un facteur de normalisation.

Projection des Centres

Pour une direction a , la projection d'un vecteur v est donnée par :

$$\hat{v} = \frac{a^T v}{\|a\|}$$

Les moyennes projetées des classes deviennent :

$$\hat{\mu}_k = \frac{a^T \mu_k}{\|a\|}, \quad \hat{\mu} = \frac{a^T \mu}{\|a\|}$$

Critère Inter-Classes Projeté

La variance inter-classes **projetée** s'exprime comme :

$$\frac{1}{M} \sum_{k=1}^M (\hat{\mu}_k - \hat{\mu})^2 = \frac{1}{\|a\|^2} a^T \left[\frac{1}{M} \sum_{k=1}^M (\mu_k - \mu)(\mu_k - \mu)^T \right] a$$

Soit simplement :

$$\frac{1}{M} \sum_{k=1}^M (\hat{\mu}_k - \hat{\mu})^2 = \frac{1}{\|a\|^2} a^T \Sigma_b a$$

Critère Intra-Classes Projeté

Pour une classe k , la variance **projetée** est :

$$\hat{\sigma}_k^2 = \frac{1}{N_k} \sum_{i=1}^{N_k} (\hat{x}_i^{(k)} - \hat{\mu}_k)^2 = \frac{1}{\|a\|^2} a^T \Sigma_k a$$

La variance intra-classes totale **projetée** devient :

$$\sum_{k=1}^M \hat{\sigma}_k^2 = \frac{1}{\|a\|^2} a^T \left(\sum_{k=1}^M \Sigma_k \right) a = \frac{1}{\|a\|^2} a^T \Sigma_w a$$

Conséquence pour le Critère de Fisher

Le ratio de Fisher **projeté** s'écrit :

$$J(a) = \frac{\text{Variance inter-classes projetée}}{\text{Variance intra-classes projetée}} = \frac{\frac{1}{\|a\|^2} a^T \Sigma_b a}{\frac{1}{\|a\|^2} a^T \Sigma_w a}$$

Les facteurs $\frac{1}{\|a\|^2}$ s'annulent :

$$J(a) = \frac{a^T \Sigma_b a}{a^T \Sigma_w a}$$

Conclusion : Le critère de Fisher ne dépend que de la **direction** de a , pas de sa norme. On peut donc chercher a sans contrainte de normalisation, puis le normaliser si nécessaire.

Solution du Problème d'Optimisation

Dérivation Mathématique

Pour maximiser $J(a)$, nous annulons son gradient :

$$\frac{\partial J(a)}{\partial a} = \frac{2\Sigma_b a(a^T \Sigma_w a) - 2\Sigma_w a(a^T \Sigma_b a)}{(a^T \Sigma_w a)^2} = 0$$

Ce qui implique :

$$\Sigma_b a = \frac{a^T \Sigma_b a}{a^T \Sigma_w a} \Sigma_w a$$

En notant $\lambda = \frac{a^T \Sigma_b a}{a^T \Sigma_w a} = J(a)$, nous obtenons :

$$\Sigma_b a = \lambda \Sigma_w a$$

C'est un **problème généralisé de valeurs propres**.

Solution par Valeurs Propres

La solution est donnée par les vecteurs propres de $\Sigma_w^{-1}\Sigma_b$:

$$\Sigma_w^{-1}\Sigma_b a = \lambda a$$

Propriétés importantes :

- Il y a au plus $K - 1$ valeurs propres non nulles
- Les vecteurs propres correspondant aux plus grandes valeurs propres sont les directions les plus discriminantes
- La plus grande valeur propre λ_1 donne le maximum de $J(a)$

Cas Particulier : Deux Classes

Pour $K = 2$, il n'y a qu'une seule direction discriminante :

$$a \propto \Sigma_w^{-1}(\mu_1 - \mu_2)$$

Cette direction est proportionnelle à la différence des moyennes, “corrigée” par la covariance inverse.

Généralisation à Plusieurs Dimensions

Sous-Espaces Discriminants

Pour K classes, nous pouvons obtenir jusqu'à $K - 1$ directions discriminantes :

- a_1 : direction la plus discriminante (plus grande valeur propre λ_1)
- a_2 : deuxième direction la plus discriminante ($\lambda_2 < \lambda_1$)
- ...
- a_{K-1} : dernière direction discriminante

Projection sur le Sous-Espace Discriminant

La matrice de projection $W = [a_1, a_2, \dots, a_{K-1}]$ permet de réduire la dimension des données de D à $K - 1$:

$$Y = XW$$

où Y sont les données projetées dans le nouvel espace.

Interprétation des Valeurs Propres

La valeur propre λ_i mesure le **pouvoir discriminant** de la direction a_i :

- λ_i grand : forte séparation entre classes le long de a_i
- λ_i petit : faible séparation


Le pourcentage de discrimination totale expliquée par la direction a_i est :

$$\text{PVE}_i = \frac{\lambda_i}{\sum_{j=1}^{K-1} \lambda_j} \times 100\%$$

Visualisation des Concepts

Exemple en Deux Dimensions

Considérons deux classes avec distributions gaussiennes :



Interprétation Géométrique

La direction optimale a est celle qui, lorsque les données sont projetées dessus, produit :

- Des histogrammes séparés pour chaque classe
 - Des distributions avec peu de recouvrement
 - Un maximum de distance entre moyennes par rapport à la variabilité interne
-

Voici une reformulation structurée et clarifiée de votre texte, avec une mise en forme améliorée et des ajustements pour une meilleure fluidité et précision :

Modélisation conditionnelle en classification supervisée

Dans les problèmes de **classification supervisée**, l'objectif est de prédire l'étiquette de classe y associée à une observation x .

Une approche fondamentale consiste à modéliser la **probabilité conditionnelle** $P(y | x)$, c'est-à-dire la probabilité qu'une observation x appartienne à une classe y donnée.

Cadre bayésien pour la classification

Règle de Bayes et décision optimale

Le théorème de Bayes permet d'exprimer la **probabilité postérieure** qu'une observation x appartienne à une classe k comme suit :

$$P(C = k | x) = \frac{P(x | C = k) \cdot P(C = k)}{P(x)}$$

Notations :

- $P(C = k)$: **Probabilité a priori** de la classe k .
- $P(x | C = k)$: **Vraisemblance** de x sachant la classe k .
- $P(x)$: **Probabilité marginale** de x (constante pour toutes les classes).

La **règle de décision optimale** (minimisant le taux d'erreur) consiste à attribuer x à la classe k maximisant la probabilité postérieure :

$$\delta(x) = \arg \max_k P(C = k | x)$$

Puisque $P(x)$ est constante, cette règle se simplifie en :

$$\delta(x) = \arg \max_k [P(x | C = k) \cdot P(C = k)]$$

L'Analyse Discriminante Linéaire (LDA) comme modèle génératif conditionnel

Hypothèses fondamentales de la LDA

L'Analyse Discriminante Linéaire (LDA) repose sur trois hypothèses clés :

1. **Distribution gaussienne par classe :**

Chaque classe suit une loi normale multivariée :

$$P(x | C = k) \sim \mathcal{N}(\mu_k, \Sigma)$$

où μ_k est le vecteur moyen de la classe k , et Σ la matrice de covariance.

2. **Matrice de covariance commune :**

Toutes les classes partagent la **même matrice de covariance** Σ .

3. **Probabilités a priori :**

Les classes sont caractérisées par des probabilités a priori $P(C = k)$, souvent estimées par les proportions observées dans l'échantillon.

Formulation explicite du modèle LDA

Sous ces hypothèses, la densité de probabilité pour la classe k s'écrit :

$$P(x | C = k) = \frac{1}{(2\pi)^{D/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (x - \mu_k)^T \Sigma^{-1} (x - \mu_k) \right)$$

où :

- D : Dimension des données.

- μ_k : Vecteur moyen de la classe k .
- Σ : Matrice de covariance commune.

Dérivation de la fonction discriminante linéaire

Passage à la fonction de décision

En appliquant la règle de décision bayésienne et en prenant le **logarithme** (qui préserve les maxima), on obtient :

$$\delta(x) = \arg \max_k [\ln P(x | C = k) + \ln P(C = k)]$$

En développant le terme quadratique et en éliminant les constantes indépendantes de k , la fonction discriminante se simplifie en :

$$\delta(x) = \arg \max_k \left[x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \ln P(C = k) \right]$$

Forme linéaire de la frontière de décision

La fonction discriminante pour la classe k peut s'exprimer comme une **fonction linéaire** en x :

$$g_k(x) = w_k^T x + b_k$$

où :

- $w_k = \Sigma^{-1} \mu_k$: Vecteur de poids pour la classe k .
- $b_k = -\frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \ln P(C = k)$: Terme de biais.

Frontière de décision linéaire :

La frontière entre deux classes k et l est définie par l'équation :

$$\{x \mid g_k(x) = g_l(x)\} \Rightarrow (w_k - w_l)^T x + (b_k - b_l) = 0$$

Avantages et Limitations

Avantages de la LDA

- **Fondements théoriques solides** basés sur la statistique bayésienne
- **Solution analytique** (pas d'optimisation itérative)
- **Efficace** lorsque les hypothèses sont respectées
- **Interprétable** : les directions discriminantes ont une signification claire
- **Double usage** : réduction de dimension et classification

Limitations

- **Hypothèse de normalité** : nécessite des données approximativement gaussiennes
- **Homoscédasticité** : suppose la même covariance pour toutes les classes
- **Sensibilité aux valeurs aberrantes**
- **Linéarité** : ne capture pas les relations non linéaires
- **Problèmes en haute dimension** lorsque $D > N$

Alternatives et Extensions

QDA (Quadratic Discriminant Analysis)

Relâche l'hypothèse de covariance commune, permettant des frontières de décision quadratiques.

LDA Régularisée

Ajoute une régularisation pour stabiliser l'estimation de Σ^{-1} en haute dimension.

LDA par Noyaux

Utilise des fonctions noyau pour capturer des relations non linéaires.

Analyse Discriminante Flexibles

Modélise les distributions conditionnelles par des méthodes non paramétriques.

Comparaison avec d'Autres Méthodes

LDA vs PCA

Aspect	LDA	PCA
Supervision	Supervisée (utilise les étiquettes)	Non supervisée
Objectif	Maximiser la séparation entre classes	Maximiser la variance totale
Directions	Directions de discrimination	Directions de variance maximale
Interprétation	Séparation des groupes	Structure de variabilité

LDA vs Régression Logistique

Aspect	LDA	Régression Logistique
Approche	Modèle génératif	Modèle discriminant
Hypothèses	Normale avec covariance commune	Aucune sur la distribution de x
Stabilité	Plus stable avec peu de données	Peut nécessiter plus de données
Frontières	Toujours linéaire sous ses hypothèses	Linéaire par construction

Applications Pratiques

Domaines d'Application

Biologie et Médecine

- Classification de cellules cancéreuses
- Diagnostic à partir d'images médicales
- Analyse de données génomiques

Finance

- Scoring de crédit
- Détection de fraude
- Classification de clients

Vision par Ordinateur

- Reconnaissance faciale
- Classification d'images
- Reconnaissance d'écriture manuscrite

Marketing

- Segmentation de clientèle
- Analyse de préférences
- Recommandation de produits

Bonnes Pratiques

Validation des hypothèses

- Tester la normalité des données (test de Shapiro-Wilk, QQ-plots)
- Vérifier l'homogénéité des covariances (test de Box)
- Examiner les valeurs aberrantes

Pré-traitement des données

- Standardisation des variables
- Gestion des valeurs manquantes
- Équilibrage des classes si nécessaire

Validation du modèle

- Validation croisée
 - Mesures de performance adaptées (matrice de confusion, AUC, etc.)
 - Comparaison avec des méthodes de référence
-

Conclusion

L'Analyse Discriminante Linéaire est une méthode **élégante et puissante** qui repose sur des principes statistiques solides.

Son cœur réside dans l'optimisation conjointe de deux critères :

Critère inter-classe

Maximiser la séparation entre les centres des classes, rendant les classes aussi distinctes que possible.

Critère intra-classe

Minimiser la dispersion à l'intérieur de chaque classe, rendant chaque classe aussi cohérente que possible.

La combinaison de ces deux objectifs via le **critère de Fisher** permet de trouver les directions optimales pour discriminer les classes tout en réduisant la dimension des données.

Bien que reposant sur des hypothèses parfois restrictives, la LDA reste un outil précieux dans la boîte à outils du data scientist, particulièrement utile pour :

- L'exploration et la visualisation de données étiquetées
- La classification lorsque les hypothèses sont raisonnablement vérifiées
- La compréhension des variables discriminantes dans un problème

Son interprétabilité et sa simplicité conceptuelle en font une excellente introduction aux méthodes de classification et de réduction de dimension supervisée.