

Table of contents

Cours : Analyse Discriminante Linéaire (LDA)	1
Introduction	1
Apprentissage supervisé	1
Analyse Discriminante Linéaire (LDA)	2
Direction discriminante (cas à 2 classes)	2
Critère inter-classe	2
Critère intra-classe	3
Critère de Fisher (combinaison des critères)	3
Généralisation à plusieurs classes	4
Sous-espaces discriminants	4
Cas particulier : $M = 2$	4
Exemples	5
Inférence et modélisation conditionnelle	5
Modélisation gaussienne	5
Décision de classification	5
Optimalité et limites	6
Résumé	6
Questions d'exemple	6

Cours : Analyse Discriminante Linéaire (LDA)

Introduction

Ce cours introduit l'**Analyse Discriminante Linéaire (LDA)**, une méthode supervisée de modélisation de données conditionnelles et de classification.

L'objectif est de présenter une définition supervisée des facteurs latents, de proposer une modélisation conditionnelle des données et de réaliser la classification d'éléments non étiquetés..

Apprentissage supervisé

Étant donné des données $X \subset \Omega \subset \mathbb{R}^D$ associées à des étiquettes de classe $y = [M] \subset \mathbb{N}$, l'apprentissage supervisé consiste à trouver (apprendre) les paramètres θ d'un apprenant (fonction) ϕ_θ de manière à minimiser la perte $\mathcal{L}_{X \times y}(\theta)$ encourue lors de la prédiction des étiquettes de classe à l'aide de ϕ_θ .

$$\begin{aligned}\phi_\theta : \Omega &\rightarrow y \\ x_t &\mapsto \phi_\theta(x_t) = \tilde{y}_t\end{aligned}$$

Exemples :

- ϕ_θ est une régression logistique avec paramètres θ .
- ϕ_θ est un réseau de neurones avec poids θ .
- $\mathcal{L}_{X \times y}(\theta) = \sum_x \|\phi_\theta(x_t) - y_t\|_{\text{some}}^2$.

Analyse Discriminante Linéaire (LDA)

Problème : Étant donné des données multivariées X associées à des étiquettes y , nous cherchons un modèle pour ces données.

Direction discriminante (cas à 2 classes)

Nous cherchons une direction $a \in \mathbb{R}^D$ telle que la projection des données sur cette direction $\hat{X} = \text{Proj}_a(X)$ présente des propriétés optimales pour la discrimination entre classes.

Critère inter-classe

Si les projections des classes sont bien séparées, elles peuvent être facilement discriminées. Nous cherchons donc une direction a qui maximise la discrimination inter-classe.

Il est clair que a doit être colinéaire à la droite $\mu_1 - \mu_2$ reliant les centres de masse des classes, car :

$$\|\hat{\mu}_1 - \hat{\mu}_2\|^2 = \frac{1}{\|a\|^2} (a^T(\mu_1 - \mu_2))^2$$

est maximale lorsque $a = \lambda(\mu_1 - \mu_2)$.

Note : Les données originales ($x_i \in X$) ne changent pas. Seules les données projetées ($\hat{x}_i \in \hat{X}$) changent lorsque l'on fait varier a .

Le centre de masse des données projetées est la projection du centre de masse des données originales.

Critère intra-classe

Nous cherchons également à minimiser la variance intra-classe des données projetées.
Le critère de Fisher maximise :

$$\operatorname{argmax}_a \frac{\|\hat{\mu}_1 - \hat{\mu}_2\|^2}{\hat{\sigma}_1^2 + \hat{\sigma}_2^2}$$

où $\hat{\sigma}_k$ est la variance normalisée de la projection de la classe k :

$$\hat{\sigma}_k^2 = \frac{1}{N_k} \sum_{y_k=k} (\hat{x}_k - \hat{\mu}_k)^T (\hat{x}_k - \hat{\mu}_k)$$

Critère de Fisher (combinaison des critères)

Le critère de Fisher combine les critères inter et intra-classe :

$$\operatorname{argmax}_a \mathcal{L}(a) = \operatorname{argmax}_a \frac{a^\top \Sigma_b a}{a^\top \Sigma_w a}$$

où Σ_b est la matrice de covariance inter-classes et Σ_w la matrice de covariance intra-classes.

La solution est obtenue en annulant la dérivée :

$$\frac{\partial \mathcal{L}(a)}{\partial a} = \frac{\Sigma_b a (a^\top \Sigma_w a) - \Sigma_w a (a^\top \Sigma_b a)}{(a^\top \Sigma_w a)^2} = 0$$

Ce qui conduit au système généralisé de valeurs propres :

$$\Sigma_b a = \mathcal{L}(a) \Sigma_w a$$

Ainsi, a est le premier vecteur propre de $\Sigma_w^{-1} \Sigma_b$ (avec valeur propre $\lambda_1 = \mathcal{L}(a)$).

Généralisation à plusieurs classes

Pour M classes, on définit :

- La matrice des centres centrés : $B = [\mu_1 - \mu, \dots, \mu_M - \mu]$ (où $\mu = \frac{1}{N} \sum_N x_i$ et $N = \sum_k N_k$).
- La matrice de covariance inter-classes : $\Sigma_b = \frac{1}{M} B B^T$.
- On maximise sur $a \in \mathbb{R}^D$:

$$\frac{1}{M} \sum_k (\hat{\mu}_k - \hat{\mu})^T (\hat{\mu}_k - \hat{\mu}) = \frac{1}{\|a\|^2} a^T \Sigma_b a$$

Sous-espaces discriminants

Les vecteurs propres correspondant aux plus grandes valeurs propres λ_i sont les dimensions les plus discriminantes :

$a_1, a_2, \dots, a_p$ avec $\lambda_1 > \lambda_2 > \dots > \lambda_p$.

Pour M classes, on peut discriminer dans un sous-espace de dimension au plus $M-1$ (projections itératives).

Il n'y a donc que $M-1$ valeurs propres non nulles.

Cas particulier : $M = 2$

Dans ce cas :

$$B B^T = (\mu_1 - \mu)(\mu_1 - \mu)^T + (\mu_2 - \mu)(\mu_2 - \mu)^T \propto (\mu_1 - \mu_2)(\mu_1 - \mu_2)^T$$

Ainsi, $B B^T a$ est un vecteur dans la direction $(\mu_1 - \mu_2)$, et :

$$a = \lambda \Sigma_w^{-1} (\mu_1 - \mu_2)$$

Exemples

LDA trouve le sous-espace optimal pour séparer linéairement les données selon les étiquettes y_i .

Exemple concret : 7291 images 16×16 (8 bits) de chiffres de 0 à 9, soit $x_i \in \mathbb{R}^{256}$ et $y_i \in [10]$.

Inférence et modélisation conditionnelle

Modélisation gaussienne

Chaque classe est modélisée par $P(x|C = k) \sim \mathcal{N}(\mu_k, \Sigma_k)$.

On suppose un prior uniforme : $P(C = k) = 1/M$.

L'évidence $P(x_j)$ est ignorée (car constante pour tous les k).

On utilise alors le maximum de vraisemblance :

$$P(x|C = k) \simeq \exp(-(x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k))$$

Décision de classification

La règle de décision est :

$$\delta(x) = \arg \max_k P(x|C = k)$$

Optimalité et limites

- LDA est optimal lorsque les M classes sont chacune distribuées selon une loi gaussienne (critère de discrimination basé sur Σ_w et Σ_b).
 - LDA ne prend pas en compte les relations non linéaires entre variables (discrimination linéaire).
 - Pour des problèmes non linéaires, il faut utiliser des méthodes de classification non linéaires.
-

Résumé

- LDA est une technique supervisée.
 - LDA trouve les facteurs latents linéaires optimaux expliquant la discrimination (linéaire).
 - Le critère de Fisher combine la dispersion intra-classe et inter-classes.
 - LDA est résolu en trouvant les valeurs propres de $\Sigma_w^{-1}\Sigma_b$.
 - Ces facteurs latents peuvent être utilisés pour la visualisation (en tenant compte des étiquettes).
 - LDA (comme classification) est un exemple de modélisation conditionnelle : chaque classe suit une loi normale.
-

Questions d'exemple

1. Expliquer dans le cadre de l'apprentissage supervisé : pourquoi LDA est une méthode linéaire ?
2. Qu'est-ce qui caractérise une direction discriminante ? Que représente a ?
3. Quel est le critère de Fisher ?

4. Qu'est-ce que le critère inter-classes ? Expliquer son principe.
5. Comment calculer la matrice de covariance inter-classes ?
6. Qu'est-ce que le critère intra-classes ? Expliquer son principe.
7. Comment calculer la matrice de covariance intra-classes ?
8. Comment ces deux critères sont-ils combinés ?
9. Pouvez-vous justifier et expliquer la dérivation du maximum pour a ?
10. Décrire la situation multidimensionnelle ($D > 2$).
11. Comment faire de l'inférence avec LDA ?
12. Donner un exemple de modèle conditionnel de données utilisant LDA.