

Table of contents

Relation entre l'Analyse Discriminante Linéaire (LDA) et la modélisation conditionnelle pour la classification	2
Question	2
Introduction à la modélisation conditionnelle en classification	2
Le cadre bayésien pour la classification	2
Règle de Bayes pour la décision optimale	2
LDA comme modèle génératif conditionnel	3
Hypothèses fondamentales de LDA	3
Formulation explicite du modèle LDA	4
De la modélisation conditionnelle à la fonction discriminante linéaire	4
Dérivation de la fonction de décision	4
Forme explicite de la frontière de décision	4
Interprétation géométrique et lien avec le critère de Fisher	5
Projection optimale pour la discrimination	5
Équivalence avec l'approche probabiliste	5
Estimation des paramètres du modèle	6
Approche du maximum de vraisemblance	6
Avantages de l'interprétation conditionnelle de LDA	6
1. Fondements probabilistes solides	6
2. Capacité à gérer des classes déséquilibrées	6
3. Extension à la classification multi-classes	6
4. Interprétation en termes de rapport de vraisemblance	7
Limitations et extensions	7
Hypothèse restrictive de covariance commune	7
Extensions modernes	7
Exemple concret : Classification de fleurs Iris	8
Conclusion	8
Analyse Discriminante Linéaire (LDA) : Explication Complète	8
Question	8
Qu'est-ce que l'Analyse Discriminante Linéaire ?	9
Hypothèses Fondamentales de la LDA	9
Calcul et Méthodologie	10
Notations et Définitions	10
Matrices de Dispersion	10
Critère de Fisher	10
Solution du Problème d'Optimisation	11
Étapes de Calcul Détaillées	11
Interprétation des Résultats	12

Utilisation pour la Classification	12
Approche par Modélisation Probabiliste	12
Estimation des Probabilités	13
Fonctions Discriminantes Linéaires	13
Règle de Décision	13
Frontières de Décision	13
Processus de Classification d'une Nouvelle Observation	14
Estimation des Paramètres	14
Avantages et Limitations	14
Avantages	14
Limitations	14
Alternatives et Extensions	15
Exemple Concret : Classification de Fleurs Iris	15
Contexte du Problème	15
Application de la LDA	15
Conclusion	16

Relation entre l'Analyse Discriminante Linéaire (LDA) et la modélisation conditionnelle pour la classification

Question

Expliquez comment le modèle d'analyse discriminante linéaire (LDA) est lié au modèle conditionnel pour la classification.

Introduction à la modélisation conditionnelle en classification

Dans les problèmes de classification supervisée, nous cherchons à prédire l'étiquette de classe y d'une observation x .

Une approche fondamentale consiste à modéliser la **probabilité conditionnelle** $P(y|x)$, c'est-à-dire la probabilité qu'une observation x appartienne à une classe y donnée.

Le cadre bayésien pour la classification

Règle de Bayes pour la décision optimale

Selon le théorème de Bayes, la probabilité postérieure qu'une observation x appartienne à la classe k est :

$$P(C = k|x) = \frac{P(x|C = k) \cdot P(C = k)}{P(x)}$$

Où :

- $P(C = k)$ est la **probabilité a priori** de la classe k
- $P(x|C = k)$ est la **vraisemblance** de x sachant la classe k
- $P(x)$ est la probabilité marginale de x (constante pour toutes les classes)

La règle de décision optimale (minimisant le taux d'erreur) consiste à attribuer x à la classe k qui maximise la probabilité postérieure :

$$\delta(x) = \arg \max_k P(C = k|x)$$

Puisque $P(x)$ est constante, cette règle équivaut à :

$$\delta(x) = \arg \max_k [P(x|C = k) \cdot P(C = k)]$$

LDA comme modèle génératif conditionnel

Hypothèses fondamentales de LDA

L'Analyse Discriminante Linéaire repose sur trois hypothèses claires :

1. **Distribution gaussienne par classe** : Chaque classe suit une distribution normale multivariée

$$P(x|C = k) \sim \mathcal{N}(\mu_k, \Sigma)$$

2. **Matrice de covariance commune** : Toutes les classes partagent la **même** matrice de covariance Σ
3. **Probabilités a priori** : Les classes ont des probabilités a priori $P(C = k)$ (souvent estimées par les proportions dans l'échantillon)

Formulation explicite du modèle LDA

Sous ces hypothèses, la densité de probabilité pour la classe k s'écrit :

$$P(x|C = k) = \frac{1}{(2\pi)^{D/2}|\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu_k)^T \Sigma^{-1}(x - \mu_k)\right)$$

Où D est la dimension des données, μ_k est le vecteur moyen de la classe k , et Σ est la matrice de covariance commune.

De la modélisation conditionnelle à la fonction discriminante linéaire

Dérivation de la fonction de décision

En appliquant la règle de décision bayésienne et en prenant le logarithme (qui préserve les maximums), nous obtenons :

$$\begin{aligned}\delta(x) &= \arg \max_k [\ln P(x|C = k) + \ln P(C = k)] \\ &= \arg \max_k \left[-\frac{1}{2}(x - \mu_k)^T \Sigma^{-1}(x - \mu_k) + \ln P(C = k) + \text{constante} \right]\end{aligned}$$

En développant le terme quadratique et en éliminant les termes indépendants de k , on obtient la **fonction discriminante linéaire** :

$$\delta(x) = \arg \max_k \left[x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \ln P(C = k) \right]$$

Forme explicite de la frontière de décision

La fonction discriminante pour la classe k peut s'écrire comme une fonction linéaire en x :

$$g_k(x) = w_k^T x + b_k$$

Où :

- $w_k = \Sigma^{-1} \mu_k$ est le vecteur de poids pour la classe k
- $b_k = -\frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \ln P(C = k)$ est le biais pour la classe k

La frontière de décision entre deux classes k et l est alors **linéaire** :

$$\{x : g_k(x) = g_l(x)\} \Rightarrow (w_k - w_l)^T x + (b_k - b_l) = 0$$

Interprétation géométrique et lien avec le critère de Fisher

Projection optimale pour la discrimination

LDA cherche la direction de projection a qui maximise la séparation relative entre les classes. Le critère de Fisher, qui maximise :

$$J(a) = \frac{a^T \Sigma_b a}{a^T \Sigma_w a}$$

correspond exactement à trouver la direction qui maximise le rapport entre :

- Σ_b : dispersion inter-classes (à maximiser)
- Σ_w : dispersion intra-classe (à minimiser)

Équivalence avec l'approche probabiliste

Lorsque les probabilités a priori sont égales ($P(C = k) = 1/M$), la solution de LDA via le critère de Fisher est équivalente à la solution obtenue par l'approche de modélisation gaussienne avec covariance commune.

La direction optimale a est donnée par le premier vecteur propre de $\Sigma_w^{-1} \Sigma_b$, qui dans le cas à deux classes se réduit à :

$$a \propto \Sigma^{-1}(\mu_1 - \mu_2)$$

Exactement la même expression que dans l'approche bayésienne !

Estimation des paramètres du modèle

Approche du maximum de vraisemblance

À partir d'un échantillon d'apprentissage $\{(x_i, y_i)\}_{i=1}^N$, les paramètres de LDA sont estimés naturellement :

- **Moyennes par classe** : $\hat{\mu}_k = \frac{1}{N_k} \sum_{i:y_i=k} x_i$
- **Matrice de covariance commune** : $\hat{\Sigma} = \frac{1}{N-M} \sum_{k=1}^M \sum_{i:y_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^T$
- **Probabilités a priori** : $\hat{P}(C = k) = \frac{N_k}{N}$

Ces estimateurs sont **consistants** et **asymptotiquement efficaces** sous les hypothèses du modèle.

Avantages de l'interprétation conditionnelle de LDA

1. Fondements probabilistes solides

Contrairement à une simple recherche de directions discriminantes, LDA fournit un **modèle génératif complet** qui permet :

- De générer des données synthétiques pour chaque classe
- De calculer des probabilités postérieures bien calibrées
- D'incorporer des connaissances a priori sur les classes

2. Capacité à gérer des classes déséquilibrées

En utilisant les probabilités a priori $P(C = k)$, LDA peut naturellement tenir compte de fréquences de classes inégales.

3. Extension à la classification multi-classes

Le cadre probabiliste s'étend naturellement à $M > 2$ classes, alors que le critère de Fisher nécessite des généralisations.

4. Interprétation en termes de rapport de vraisemblance

La décision entre deux classes k et l peut s'exprimer comme :

$$\log \frac{P(C = k|x)}{P(C = l|x)} = (w_k - w_l)^T x + (b_k - b_l)$$

Ce qui correspond à un **test du rapport de vraisemblance** avec seuil adapté aux probabilités a priori.

Limitations et extensions

Hypothèse restrictive de covariance commune

La principale limitation de LDA est l'hypothèse que toutes les classes partagent la même matrice de covariance Σ .

Quand cette hypothèse n'est pas vérifiée, on utilise :

- **QDA (Quadratic Discriminant Analysis)** : permet des covariances différentes par classe, conduisant à des frontières quadratiques
- **Régularisations** : versions régularisées de LDA pour les données de haute dimension

Extensions modernes

- **Flexible LDA** : utilise des noyaux pour capturer des non-linéarités
 - **Sparse LDA** : introduit des contraintes de parcimonie pour la sélection de variables
 - **LDA robuste** : versions résistantes aux outliers
-

Exemple concret : Classification de fleurs Iris

Considérons le jeu de données Iris avec 3 espèces de fleurs.

LDA modélise chaque espèce par une distribution gaussienne dans l'espace des caractéristiques (longueur/largeur des pétales et sépales).

Pour une nouvelle fleur mesurée x , LDA calcule :

1. La vraisemblance $P(x|\text{setosa})$, $P(x|\text{versicolor})$, $P(x|\text{virginica})$
2. Les probabilités postérieures via la règle de Bayes
3. Attribue l'espèce avec la probabilité postérieure maximale

La frontière entre les espèces apparaît linéaire dans l'espace des caractéristiques, en raison de l'hypothèse de covariance commune.

Conclusion

L'Analyse Discriminante Linéaire est **fondamentalement un modèle conditionnel pour la classification** qui :

1. **Modélise explicitement** $P(x|C = k)$ comme des gaussiennes avec covariance commune
2. **Utilise la règle de Bayes** pour calculer $P(C = k|x)$ et prendre des décisions
3. **Se réduit à des fonctions discriminantes linéaires** grâce à ses hypothèses simplificatrices
4. **Est équivalente au critère de Fisher** sous l'hypothèse de classes équilibrées

Cette double perspective - à la fois comme modèle génératif probabiliste et comme méthode de projection discriminante - explique la puissance et la popularité durable de LDA en apprentissage statistique.

LDA illustre parfaitement comment des **hypothèses probabilistes bien choisies** peuvent conduire à des **algorithmes simples et interprétables** tout en restant théoriquement fondés et pratiquement efficaces.

Analyse Discriminante Linéaire (LDA) : Explication Complète

Question

Expliquez la méthode d'analyse discriminante linéaire (LDA), y compris les hypothèses, le calcul et l'interprétation de cette technique. Comment cette technique est-elle utilisée pour la classification ?

Qu'est-ce que l'Analyse Discriminante Linéaire ?

L'Analyse Discriminante Linéaire (LDA) est une méthode statistique supervisée qui remplit deux fonctions principales : la **classification** et la **réduction de dimension**.

Elle cherche à trouver les combinaisons linéaires des variables originales qui séparent au mieux différentes classes pré-définies.

Hypothèses Fondamentales de la LDA

Pour que la LDA fonctionne de manière optimale, elle repose sur plusieurs hypothèses clés :

Distribution Normale

Chaque classe est supposée suivre une distribution gaussienne multivariée. Formellement, pour chaque classe k , les observations sont tirées de :

$$P(x|C = k) \sim \mathcal{N}(\mu_k, \Sigma)$$

où μ_k est le vecteur moyen de la classe k et Σ est la matrice de covariance.

Homoscédasticité

Toutes les classes partagent la même matrice de covariance Σ . Cette hypothèse est cruciale car elle garantit que les frontières de décision seront linéaires.

Observations Indépendantes

Les observations sont échantillonnées de manière indépendante et identiquement distribuée à l'intérieur de chaque classe.

Séparabilité des Classes

Les centres des classes (μ_k) doivent être suffisamment distincts par rapport à la dispersion intra-classe.

Calcul et Méthodologie

Notations et Définitions

Considérons un problème à K classes :

- N_k : nombre d'observations dans la classe k
- N : nombre total d'observations, avec $N = \sum_{k=1}^K N_k$
- μ_k : vecteur moyen de la classe k (de dimension D)
- μ : vecteur moyen global de toutes les observations

Matrices de Dispersion

Matrice de dispersion intra-classes

Cette matrice mesure la variabilité à l'intérieur de chaque classe :

$$\Sigma_w = \sum_{k=1}^K \sum_{x_i \in \text{classe } k} (x_i - \mu_k)(x_i - \mu_k)^T$$

Matrice de dispersion inter-classes

Cette matrice mesure la dispersion entre les centres des différentes classes :

$$\Sigma_b = \sum_{k=1}^K N_k (\mu_k - \mu)(\mu_k - \mu)^T$$

Critère de Fisher

L'objectif de la LDA est de trouver un vecteur de projection a qui maximise la séparation relative entre les classes.

Le critère de Fisher formalise cet objectif :

$$J(a) = \frac{a^T \Sigma_b a}{a^T \Sigma_w a}$$

Le numérateur $a^T \Sigma_b a$ représente la dispersion inter-classes projetée (que l'on veut maximiser), tandis que le dénominateur $a^T \Sigma_w a$ représente la dispersion intra-classes projetée (que l'on veut minimiser).

Solution du Problème d'Optimisation

Maximiser $J(a)$ revient à résoudre un problème généralisé de valeurs propres :

$$\Sigma_b a = \lambda \Sigma_w a$$

En pratique, on calcule les vecteurs propres de $\Sigma_w^{-1} \Sigma_b$ (sous réserve que Σ_w soit inversible).

Étapes de Calcul Détaillées

Étape 1 : Calcul des statistiques descriptives

- Moyennes par classe : $\hat{\mu}_k = \frac{1}{N_k} \sum_{i:y_i=k} x_i$
- Moyenne globale : $\hat{\mu} = \frac{1}{N} \sum_{i=1}^N x_i$

Étape 2 : Calcul des matrices de dispersion

- Matrice intra-classes : $\hat{\Sigma}_w = \sum_{k=1}^K \sum_{i:y_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^T$
- Matrice inter-classes : $\hat{\Sigma}_b = \sum_{k=1}^K N_k (\hat{\mu}_k - \hat{\mu})(\hat{\mu}_k - \hat{\mu})^T$

Étape 3 : Résolution du problème de valeurs propres

- Calcul de la matrice $\hat{\Sigma}_w^{-1} \hat{\Sigma}_b$
- Extraction des vecteurs propres correspondant aux plus grandes valeurs propres

Étape 4 : Formation de l'espace discriminant

- Tri des vecteurs propres par ordre décroissant des valeurs propres
- Formation de la matrice de projection $W = [a_1, a_2, \dots, a_{K-1}]$ (au plus $K - 1$ directions non nulles)

Étape 5 : Projection des données

$$Y = XW$$

où Y représente les données projetées dans le nouvel espace discriminant.

Interprétation des Résultats

Dimensions Discriminantes

Chaque vecteur propre a_i correspond à une direction dans l'espace original le long de laquelle la séparation entre classes est maximale.

La valeur propre associée λ_i mesure le pouvoir discriminant de cette direction.

Pourcentage de Séparation Expliquée

On peut évaluer l'importance relative de chaque dimension discriminante :

$$\text{Proportion}_i = \frac{\lambda_i}{\sum_{j=1}^{K-1} \lambda_j} \times 100\%$$

Signification des Coefficients

Les coefficients du vecteur a_i indiquent l'importance relative de chaque variable originale dans la discrimination.

Un coefficient élevé en valeur absolue signifie que la variable contribue fortement à la séparation des classes le long de cette direction.

Visualisation

En projetant les données sur les deux premières dimensions discriminantes, on obtient une visualisation 2D qui permet d'apprécier la séparation entre classes.

Utilisation pour la Classification

Approche par Modélisation Probabiliste

La LDA peut être interprétée comme un modèle génératif où chaque classe est modélisée par une distribution normale :

$$P(x|C = k) = \frac{1}{(2\pi)^{D/2} |\Sigma|^{1/2}} \exp \left(-\frac{1}{2} (x - \mu_k)^T \Sigma^{-1} (x - \mu_k) \right)$$

Estimation des Probabilités

Probabilités a priori

Estimées par les proportions observées dans l'échantillon :

$$\hat{P}(C = k) = \frac{N_k}{N}$$

Règle de Bayes pour la Classification

La probabilité qu'une observation x appartienne à la classe k est donnée par :

$$P(C = k|x) = \frac{P(x|C = k)P(C = k)}{\sum_{l=1}^K P(x|C = l)P(C = l)}$$

Fonctions Discriminantes Linéaires

Pour chaque classe k , on définit une fonction linéaire :

$$g_k(x) = w_k^T x + b_k$$

avec : $w_k = \Sigma^{-1} \mu_k - b_k = -\frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \ln P(C = k)$

Règle de Décision

On attribue x à la classe qui maximise la fonction discriminante :

$$\hat{y} = \arg \max_k g_k(x)$$

Ce qui équivaut à choisir la classe avec la probabilité postérieure $P(C = k|x)$ la plus élevée.

Frontières de Décision

La frontière entre deux classes k et l est linéaire :

$$\{x : g_k(x) = g_l(x)\} \Rightarrow (w_k - w_l)^T x + (b_k - b_l) = 0$$

Cette linéarité est une conséquence directe de l'hypothèse de covariance commune.

Processus de Classification d'une Nouvelle Observation

Pour classer une nouvelle observation x_{new} :

1. **Calcul des scores** : Évaluer $g_k(x_{\text{new}})$ pour chaque classe k
2. **Décision** : Attribuer à la classe avec le score le plus élevé
3. **Option probabiliste** : Calculer les probabilités postérieures $P(C = k|x_{\text{new}})$ pour une décision probabiliste

Estimation des Paramètres

À partir d'un échantillon d'apprentissage $\{(x_i, y_i)\}_{i=1}^N$:

- Moyennes par classe : $\hat{\mu}_k = \frac{1}{N_k} \sum_{i:y_i=k} x_i$
 - Covariance commune : $\hat{\Sigma} = \frac{1}{N-K} \sum_{k=1}^K \sum_{i:y_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^T$
 - Probabilités a priori : $\hat{P}(C = k) = \frac{N_k}{N}$
-

Avantages et Limitations

Avantages

- **Fondements théoriques solides** basés sur la théorie bayésienne et le critère de Fisher
- **Efficacité computationnelle** : solution analytique sans optimisation itérative
- **Interprétabilité** : les directions discriminantes ont une signification géométrique claire
- **Double fonctionnalité** : réduction de dimension et classification intégrées
- **Robustesse** aux légères violations de la normalité

Limitations

- **Sensibilité aux valeurs aberrantes** qui affectent les estimations des moyennes et covariances
- **Hypothèse de covariance commune** parfois irréaliste dans la pratique
- **Linéarité** : ne peut capturer des relations non linéaires entre variables
- **Exigence de normalité** : performance dégradée avec des distributions fortement non gaussiennes

Alternatives et Extensions

- **QDA (Quadratic Discriminant Analysis)** : relâche l'hypothèse de covariance commune, donnant des frontières quadratiques
 - **LDA Régularisée** : introduit une régularisation pour les problèmes de haute dimension
 - **Analyse Discriminante Flexible** : utilise des fonctions de base pour capturer des relations non linéaires
 - **Machines à Vecteurs de Support (SVM)** : approche alternative pour la classification linéaire et non linéaire
-

Exemple Concret : Classification de Fleurs Iris

Contexte du Problème

Le jeu de données Iris contient 3 espèces de fleurs avec 4 caractéristiques morphologiques :

- Longueur et largeur des sépales
- Longueur et largeur des pétales

Application de la LDA

Étape 1 : Estimation des paramètres

Calcul des moyennes pour chaque espèce et de la matrice de covariance commune.

Étape 2 : Calcul des directions discriminantes

Résolution du problème de valeurs propres pour obtenir 2 directions (car $K - 1 = 2$).

Étape 3 : Projection et visualisation

Réduction des données à 2 dimensions, révélant une bonne séparation entre espèces.

Étape 4 : Classification

Construction des fonctions discriminantes permettant de classer de nouvelles fleurs avec une précision élevée (>95%).

Conclusion

L'Analyse Discriminante Linéaire est une méthode **élégante et puissante** qui allie plusieurs approches :

- Une **perspective géométrique** cherchant les directions optimales de projection
- Une **modélisation probabiliste** basée sur des distributions normales
- Une **règle de décision bayésienne** optimale sous ses hypothèses

Sa **polyvalence** (classification et réduction de dimension) et sa **grande interprétabilité** en font un outil précieux en analyse de données exploratoire et en modélisation prédictive.

Cependant, son application réussie dépend du respect raisonnable de ses hypothèses sous-jacentes.

Quand ces hypothèses sont vérifiées, la LDA offre une solution **efficace, interprétable et théoriquement fondée** aux problèmes de classification et de séparation de groupes.