

Table of contents

Data Science: Expectation-Maximization for Density Modelling & Latent Factor

Estimation	1
Motivation	1
Density Estimation	2
Méthodes	2
Modélisation par mélange gaussien	2
Interprétation probabiliste	2
Choix de la densité de base	3
Estimation par Maximum de Vraisemblance (MLE)	3
Cas de base : 1 composante, $c = 1$	3
Cas plus complexe : 2 composantes	4
Algorithme Expectation-Maximization (EM)	4
Problème des assignations manquantes	4
Étape E (Expectation)	4
Responsabilité et assignation douce (soft-assignment)	5
Exemple visuel : itérations successives des étapes E et M	5
Résultats numériques d'estimation	5
Généralisation aux mélanges à c composantes	6
Algorithme EM pour c composantes	6
Modélisation et considérations pratiques	6
Impact de la paramétrisation	6
Forme de la matrice de covariance	7
Pré-traitement par réduction de dimension (PCA)	7
Choix du nombre de composantes c	7
Exemple pratique avec un mélange à 4 composantes	8
Résumé	8
Modèles de mélange gaussien (GMM)	8
Algorithme EM	8
Questions d'exemple	8

Data Science: Expectation-Maximization for Density Modelling & Latent Factor Estimation

Motivation

Jusqu'à présent, nous avons utilisé un modèle implicite pour les données :

- Les modèles à composantes $\rightarrow$ la variance comme critère sur les données centrées (distribution normale)

- Les modèles discriminants $\rightarrow$ variance des données projetées pour les modèles intra-classe et inter-classes

La distribution est fixée (essentiellement normale) et nous recherchons ses paramètres θ (par exemple $\theta = [\mu, \Sigma]$).

Alternativement, nous pouvons rechercher un modèle pour la densité des données.

Soit $f_\theta(x) : \Omega \rightarrow \mathbb{R}$ la densité des données.

Density Estimation

Méthodes

- Méthodes des plus proches voisins (kNN)
- Fenêtres de Parzen, réseaux RBF
- Histogrammes
- Modèles de mélange

Modélisation par mélange gaussien

Dans ce cadre, nous faisons trois hypothèses :

1. Le nombre de composantes ($c \in \mathbb{N}^*$) est connu
2. La famille de fonctions $\mathcal{F}$ est connue
3. Les étiquettes (labels de classe) sont inconnues

Interprétation probabiliste

La densité $f(x)$ représente un processus aléatoire où x est tiré d'un ensemble d'états ω_j avec une probabilité a priori $\mathbb{P}(\omega_j)$.

$$f(x) = \sum_{j=1}^c \pi_j \phi(x, \theta_j)$$

$$f(x) = \mathbb{P}(x|\theta) = \sum_{j=1}^c \mathbb{P}(\omega_j) \mathbb{P}(x|\omega_j, \theta_j)$$

On obtient (par identification) :

- $\pi_j = \mathbb{P}(\omega_j)$ avec $\sum_j \pi_j = 1$
- $\phi(x, \theta_j) = \mathbb{P}(x|\omega_j, \theta_j)$ est la probabilité conditionnelle que x soit généré par l'état ω_j

Choix de la densité de base

ϕ est une fonction de densité de probabilité. Choisir la famille normale (agnostique) comme base ($\phi \in \mathbb{P} = \{\mathcal{N}(\mu, \Sigma)\}$) semble raisonnable :

$$f(x) = \sum_{j=1}^c \pi_j \mathcal{N}(x|\mu_j, \Sigma_j)$$

C'est-à-dire : $\phi_j(x) := \phi(x, \theta_j) = \mathcal{N}(x|\mu_j, \Sigma_j)$

- Peut approximer n'importe quelle densité
- Permet un système linéaire de ses paramètres lors de la maximisation de la log-vraisemblance (MLE)

Estimation par Maximum de Vraisemblance (MLE)

Cas de base : 1 composante, $c = 1$

Paramètres : $\theta = [\mu, \Sigma]$

On maximise la log-vraisemblance :

$$\hat{\theta} = \arg \max_{\theta} \sum_i \log e^{-(x_i - \mu)^T \Sigma^{-1} (x_i - \mu)}$$

Ce qui équivaut à :

$$\hat{\theta} = \arg \min_{\theta} \sum_i (x_i - \mu)^T \Sigma^{-1} (x_i - \mu)$$

On obtient les estimateurs :

$$\hat{\mu} = \frac{1}{N} \sum_i x_i$$

$$\hat{\Sigma} = \frac{1}{N} \sum_i (x_i - \hat{\mu})(x_i - \hat{\mu})^T$$

Cas plus complexe : 2 composantes

Paramètres : $\theta = [\pi_1, \theta_1, \pi_2, \theta_2] = [\pi_1, [\mu_1, \Sigma_1], \pi_2, [\mu_2, \Sigma_2]]$ avec $\pi_1 + \pi_2 = 1$

La vraisemblance s'écrit :

$$\mathbb{L}(\theta, \mathcal{X}) = \sum_i^N \log[\pi_1 \phi(x_i, \theta_1) + \pi_2 \phi(x_i, \theta_2)]$$

Difficulté : La somme à l'intérieur du logarithme rend la maximisation directe difficile.

Solution : Un algorithme itératif en 2 étapes (E-M) pour maximiser la vraisemblance incomplète. C'est l'algorithme **Expectation-Maximization (EM)**.

Algorithme Expectation-Maximization (EM)

Problème des assignations manquantes

Ce qui manque ici est l'assignation de chaque x_i à l'une des 2 composantes ϕ_j . Si nous la connaissions, nous pourrions traiter le problème comme deux fois le cas à 1 composante.

Nous introduisons des variables latentes (non observées) : l'assignation binaire $\delta_{ij} \in \{\text{true}, \text{false}\}$ de chaque x_i à la composante ϕ_j :

- $x_i \sim \phi_1 \Rightarrow \delta_{i1} = \text{true}, \delta_{i2} = \text{false}$
- $x_i \sim \phi_2 \Rightarrow \delta_{i1} = \text{false}, \delta_{i2} = \text{true}$

Mais nous ne pouvons qu'estimer $\delta_{ij} \rightarrow$ Stratégie EM.

Étape E (Expectation)

Paramètres : $\theta = [\pi_1, \theta_1, \pi_2, \theta_2] = [\pi_1, [\mu_1, \Sigma_1], \pi_2, [\mu_2, \Sigma_2]]$

Supposons que nous connaissons une valeur initiale pour $\theta^0 = [\pi_1^0, \theta_1^0, \pi_2^0, \theta_2^0]$.

Nous pouvons inférer la contribution (statistique) γ_{ij} de chaque donnée x_i à chaque composante ϕ_j (paramétrée par θ_j^0) :

$$\gamma_{ij}(\theta^0) = \mathbf{P}[\delta_{ij} = \text{true} | \theta^0, \mathcal{X}]$$

Par exemple pour la composante 1 :

$$\gamma_{i1}(\theta^0) = \frac{\pi_1^0 \phi(x_i, \theta_1^0)}{\pi_1^0 \phi(x_i, \theta_1^0) + \pi_2^0 \phi(x_i, \theta_2^0)}$$

γ_{ij} est la **responsabilité**. C'est la vraisemblance que x_i soit (purement) modélisé par la composante ϕ_j .

γ_{ij} représente la part de x_i qui est modélisée (générée) par la composante ϕ_j .

Responsabilité et assignation douce (soft-assignment)

Nous pouvons utiliser γ_{ij} pour déterminer $\delta_{ij} \rightarrow x_i$ peut être assigné à ϕ_1 ou ϕ_2 (vote maximum $\rightarrow$ binarisation) $\rightarrow$ assignation dure de type **K-means** : chaque donnée est assignée à une et une seule composante (cluster).

L'algorithme EM est plus « doux » : une donnée contribue (via γ_{ij}) à plusieurs composantes (modes de densité). EM calcule une **assignation douce** avec :

$$\sum_j \gamma_{ij} = 1 \quad \forall i$$

Exemple visuel : itérations successives des étapes E et M

(Les pages 16 à 27 du PDF original contiennent une série de figures illustrant les itérations successives de l'algorithme EM pour un mélange de deux gaussiennes. Ces figures montrent l'évolution des composantes estimées et des responsabilités au fil des itérations.)

Résultats numériques d'estimation

Paramètres réels du mélange (exemple) :

Paramètre	π_1	μ_1	Σ_1	μ_2	Σ_2
Valeur	0.75	2	2	8	1

Paramètres estimés après 10 et 20 itérations :

Itérations	π_1	μ_1	Σ_1	μ_2	Σ_2
10	0.76	2.17	1.56	7.91	1.06
20	0.76	2.15	1.98	8.01	0.98

Généralisation aux mélanges à c composantes

Variables latentes généralisées : $\delta_{i1}, \delta_{i2}, \dots, \delta_{ij}, \dots, \delta_{ic}$ où $\delta_{ij} = \text{true}$ si la donnée x_i est générée par la composante ϕ_j .

La responsabilité γ_{ij} est l'espérance de δ_{ij} sur toutes les composantes.

Paramètres à estimer : $\theta = [\pi_j, \theta_j]_{j \in [c]} = [\pi_j, [\mu_j, \Sigma_j]]_j$

Algorithme EM pour c composantes

1. **Initialisation** : $\theta^0 = \{\pi_j^0, \mu_j^0, \Sigma_j^0\}_{j \in [c]}$
 - En général : $\pi_j = 1/c$, μ_j choisi aléatoirement et $\Sigma_k = \mathbf{Id}$
 - Alternative : utiliser **K-means** pour l'initialisation
2. **Étape E** : Calculer les responsabilités pour chaque donnée $i \in [N]$ et chaque composante $j \in [c]$

$$\gamma_{ij} = \frac{\pi_j \phi(x_i, \theta_j)}{\sum_{k=1}^c \pi_k \phi(x_i, \theta_k)}$$

3. **Étape M** : Estimation des paramètres du mélange

- Moyenne : $\mu_j = \frac{\sum_{i=1}^N \gamma_{ij} x_i}{\sum_i \gamma_{ij}}$
- Covariance : $\Sigma_j = \frac{x_j \Gamma_j x_j^\top}{\text{Tr}(\Gamma_j)}$ où $\Gamma_j = \text{diag}[\gamma_{ij}, \dots, \gamma_{ij}]$ et x_j est centré sur μ_j
- Poids : $\pi_j = \frac{\sum_i \gamma_{ij}}{N}$

4. **Itérer** les étapes 2 et 3 jusqu'à convergence.

Modélisation et considérations pratiques

Impact de la paramétrisation

La paramétrisation a priori du mélange influence la convergence. Les paramètres clés sont :

1. c : le nombre de composantes
2. Σ_j : la forme des matrices de covariance (diagonale, pleine, paramétrée)

Des modèles trop flexibles ou trop rigides peuvent conduire à une mauvaise convergence, voire à une absence de convergence.

Le nombre de variables à estimer est de l'ordre de $D \times D \times c + 2 \times c$. Si N est petit, D grand et c grand $\rightarrow$ risque de **sur-paramétrisation**.

Forme de la matrice de covariance

Problème de sur-paramétrisation typique : dans un problème de reconnaissance de caractères, $x_j \in \mathbb{R}^{256}$. Il faudrait estimer $256^2 \times c$ paramètres pour la covariance (avec seulement environ 7000 points de données) !

Solutions de paramétrisation :

- Modèles sphériques : $\Sigma = \sigma \text{Id} \rightarrow 1$ paramètre
- Modèles diagonaux : $\Sigma = \text{diag}(\sigma_1, \dots, \sigma_D) \rightarrow D$ paramètres
- Modèles pleins : $\Sigma \in \mathbb{R}^{D \times D} \rightarrow O(D^2)$ paramètres

Pré-traitement par réduction de dimension (PCA)

Pour les modèles complexes, la convergence peut être impossible si p (le nombre de paramètres) est trop grand.

Une solution est d'utiliser l'**Analyse en Composantes Principales (PCA)** pour réduire la dimension des données avant d'appliquer EM.

Exemple : 50 composantes principales reconstruisent 90% du signal. On peut alors appliquer EM dans l'espace des 50 (ou 10, ou 2) premières composantes principales.

Choix du nombre de composantes c

Principe de parcimonie

Plus c est grand, moins il y a de points assignés en moyenne à chaque composante. Il faut rechercher des modèles parcimonieux, c'est-à-dire avec un petit nombre de paramètres.

Critère d'information bayésien (BIC)

Plus c est grand, meilleure est l'estimation de la vraisemblance. Il faut trouver un compromis entre la vraisemblance et la complexité du modèle.

Le BIC est défini par :

$$\text{BIC}(\theta, \chi) = -2\text{LL}(\theta, \chi) + |\theta| \log(N)$$

On cherche alors :

$$\hat{\theta} = \underset{\theta}{\text{argmin}} \text{BIC}(\theta, \chi)$$

Exemple pratique avec un mélange à 4 composantes

(Les pages 39 à 45 du PDF original contiennent une série de figures illustrant l'application de l'algorithme EM avec un mélange de 4 gaussiennes, y compris le processus de test de différents modèles et le réglage manuel.)

Remarques importantes :

- Il faut tester tous les modèles possibles
- La convergence dépend de l'initialisation
- Un réglage fin manuel est parfois nécessaire

Résumé

Modèles de mélange gaussien (GMM)

- Le modèle de mélange gaussien généralise les hypothèses sous-jacentes à l'ACP et l'ADL
- Modélisation et estimation explicite de la densité
- Également classification par MLE (non supervisée) : si les composantes sont des classes, la donnée x_j est associée à la classe j pour laquelle $\mathbb{P}(C = j|x_j) \approx \pi_j \phi_j(x_j)$ est maximale parmi toutes les classes

Algorithme EM

- Algorithme itératif pour maximiser la (log-)vraisemblance
- Principe utilisé dans de nombreux autres scénarios
- Basé sur la définition de variables non observées (latentes) (δ_{ij})
- Exemple d'autre application : **Analyse sémantique latente probabiliste (pLSA)** → EM où les variables cachées sont les concepts latents

Questions d'exemple

- Qu'est-ce qu'un modèle de mélange gaussien (GMM) ?
- Pourquoi peut-il être considéré comme une modélisation conditionnelle ?
- Comment l'utiliser pour générer des données ?
- Qu'est-ce que la responsabilité ? Comment l'interpréter ?
- Pourquoi EM pour GMM est-il un MLE ?
- Comment interpréter l'étape E ?
- Comment interpréter l'étape M ?
- Discutez de la relation entre GMM et K-means
- Que sont les assignations dures (hard) et douces (soft) ?

Il est fortement conseillé de développer l'algèbre contenue dans ce chapitre.