

Table of contents

Cours complet : Modèles de Mélange Gaussien et Algorithme EM	2
Introduction	2
Qu'est-ce qu'un modèle probabiliste ?	2
Pourquoi modéliser la densité des données ?	2
Estimation de Densité	2
Définition	2
Méthodes d'estimation de densité	3
Les Modèles de Mélange	3
Idée fondamentale	3
Formulation mathématique	3
Le Modèle de Mélange Gaussien (GMM)	4
Pourquoi les Gaussiennes ?	4
Définition formelle	4
Paramètres du GMM	4
Interprétation Probabiliste	5
Variables latentes	5
Formulation avec variables latentes	5
Estimation des Paramètres : Le Défi	5
Approche intuitive	5
Maximum de Vraisemblance (MLE)	6
Le problème technique	6
L'Algorithme Expectation-Maximization (EM)	6
L'idée géniale	6
Le Concept de Responsabilité	7
Propriétés des responsabilités	7
L'Algorithme EM en Détail	8
Pourquoi l'Algorithme EM Fonctionne ?	9
Intuition géométrique	9
Justification mathématique	10
Différence entre EM et K-means	10
K-means : Un cas particulier	10
Comparaison détaillée	10
Applications Pratiques	11
1. Clustering non supervisé	11
2. Estimation de densité	11
3. Classification	11
4. Génération de données	11
Défis et Solutions	11
1. Choix du nombre de composantes	11
2. Initialisation	12

3. Problèmes numériques	12
Types de Matrices de Covariance	12
1. Sphérique	12
2. Diagonale	12
3. Pleine	12
Exemple Complet : De la Théorie à la Pratique	13
Problème	13
Solution avec GMM et EM	13
Conclusion	14

Cours complet : Modèles de Mélange Gaussien et Algorithme EM

Introduction

Qu'est-ce qu'un modèle probabiliste ?

Un **modèle probabiliste** est une représentation mathématique d'un phénomène aléatoire. Contrairement à un modèle déterministe qui donne toujours le même résultat pour les mêmes entrées, un modèle probabiliste décrit les **probabilités** des différents résultats possibles.

Pourquoi modéliser la densité des données ?

Jusqu'à présent, nous avons souvent utilisé des modèles qui supposent que les données suivent une distribution spécifique (comme la distribution normale). Par exemple :

- **Dans l'Analyse en Composantes Principales (PCA)** : On suppose que les données sont centrées et on étudie leur variance
- **Dans l'Analyse Discriminante Linéaire (LDA)** : On compare la variance à l'intérieur des classes et entre les classes

Mais que faire si nous ne savons pas quelle distribution suivent nos données ? C'est là qu'intervient l'**estimation de densité**.

Estimation de Densité

Définition

L'**estimation de densité** consiste à construire une estimation de la fonction de densité de probabilité à partir d'un ensemble de données observées.

Si vous imaginez un histogramme, l'estimation de densité consiste à trouver la courbe lisse qui décrit le mieux la forme de cet histogramme.

Méthodes d'estimation de densité

Plusieurs approches existent :

1. **Histogrammes** : La méthode la plus simple, mais peu précise
2. **Fenêtres de Parzen (ou noyaux)** : Une généralisation des histogrammes
3. **Plus proches voisins (kNN)** : Estime la densité basée sur la distance aux k plus proches voisins
4. **Modèles de mélange** : Combine plusieurs distributions simples pour modéliser une distribution complexe

Les Modèles de Mélange

Idée fondamentale

L'idée des **modèles de mélange** est simple mais puissante : au lieu d'essayer de modéliser une distribution complexe avec une seule fonction simple, on la modélise comme une combinaison (un "mélange") de plusieurs distributions simples.

Analogique : Imaginez que vous ayez une population composée de plusieurs sous-groupes (par exemple, des hommes et des femmes, ou des jeunes et des personnes âgées). Au lieu d'essayer de décrire toute la population avec une seule courbe de taille, il serait plus précis d'avoir une courbe pour chaque sous-groupe, puis de les combiner.

Formulation mathématique

Un modèle de mélange s'écrit :

$$f(x) = \sum_{j=1}^c \pi_j \phi(x, \theta_j)$$

Décomposons cette formule :

- $f(x)$: La densité de probabilité au point x (ce que nous voulons estimer)
- c : Le nombre de composantes dans le mélange
- π_j : Le poids de la composante j (la proportion du mélange)
- $\phi(x, \theta_j)$: La densité de la composante j au point x
- θ_j : Les paramètres de la composante j

Contrainte importante : Les poids π_j doivent vérifier $\sum_{j=1}^c \pi_j = 1$ et $\pi_j \geq 0$ pour tout j .

Le Modèle de Mélange Gaussien (GMM)

Pourquoi les Gaussiennes ?

La distribution **gaussienne** (ou normale) est un choix naturel pour plusieurs raisons :

1. **Théorème Central Limite** : Beaucoup de phénomènes naturels suivent approximativement une distribution gaussienne
2. **Propriétés mathématiques** : Les gaussiennes ont des propriétés analytiques très pratiques
3. **Flexibilité** : Un mélange de gaussiennes peut approximer n'importe quelle distribution avec suffisamment de composantes

Définition formelle

Un **Modèle de Mélange Gaussien** avec c composantes s'écrit :

$$f(x) = \sum_{j=1}^c \pi_j \mathcal{N}(x|\mu_j, \Sigma_j)$$

où $\mathcal{N}(x|\mu_j, \Sigma_j)$ est la densité d'une distribution gaussienne multivariée :

$$\mathcal{N}(x|\mu_j, \Sigma_j) = \frac{1}{(2\pi)^{D/2} |\Sigma_j|^{1/2}} \exp \left(-\frac{1}{2} (x - \mu_j)^T \Sigma_j^{-1} (x - \mu_j) \right)$$

Paramètres du GMM

Un GMM a trois types de paramètres :

1. **Les poids** π_j : La proportion de chaque composante
2. **Les moyennes** μ_j : Le centre de chaque gaussienne
3. **Les matrices de covariance** Σ_j : La forme et l'orientation de chaque gaussienne

Interprétation Probabiliste

Variables latentes

Une interprétation importante du GMM est en termes de **variables latentes**. Une variable latente est une variable que nous n'observons pas directement, mais qui influence les données que nous observons.

Dans un GMM, nous pouvons imaginer le processus de génération des données :

1. **Étape 1** : Choisir une composante j avec probabilité π_j
2. **Étape 2** : Générer un point x à partir de la gaussienne $\mathcal{N}(\mu_j, \Sigma_j)$

La composante choisie à l'étape 1 est notre **variable latente** : nous ne savons pas quelle composante a généré chaque point, mais cette information serait très utile pour estimer les paramètres.

Formulation avec variables latentes

Si nous notons z la variable latente indiquant la composante ($z = j$ signifie “le point vient de la composante j ”), alors :

- Probabilité a priori : $\mathbb{P}(z = j) = \pi_j$
- Probabilité conditionnelle : $\mathbb{P}(x|z = j) = \mathcal{N}(x|\mu_j, \Sigma_j)$

La densité marginale (celle que nous observons) est alors :

$$f(x) = \sum_{j=1}^c \mathbb{P}(z = j) \mathbb{P}(x|z = j) = \sum_{j=1}^c \pi_j \mathcal{N}(x|\mu_j, \Sigma_j)$$

Estimation des Paramètres : Le Défi

Approche intuitive

Si nous connaissions les variables latentes (si nous savions quel point vient de quelle composante), l'estimation des paramètres serait simple :

- Pour estimer μ_j : Prendre la moyenne des points de la composante j
- Pour estimer Σ_j : Calculer la covariance des points de la composante j
- Pour estimer π_j : Calculer la proportion de points dans la composante j

Mais le problème est justement que nous **ne connaissons pas** les variables latentes !

Maximum de Vraisemblance (MLE)

L'approche standard pour estimer les paramètres est le **Maximum de Vraisemblance** (MLE). L'idée est de choisir les paramètres qui rendent les données observées les plus probables.

Pour N données indépendantes $x_1, \dots, x_N$, la vraisemblance est :

$$\mathcal{L}(\theta) = \prod_{i=1}^N f(x_i|\theta) = \prod_{i=1}^N \sum_{j=1}^c \pi_j \mathcal{N}(x_i|\mu_j, \Sigma_j)$$

Pour des raisons pratiques, on travaille avec la **log-vraisemblance** :

$$\log \mathcal{L}(\theta) = \sum_{i=1}^N \log \sum_{j=1}^c \pi_j \mathcal{N}(x_i|\mu_j, \Sigma_j)$$

Le problème technique

Regardez la formule de la log-vraisemblance :

$$\log \mathcal{L}(\theta) = \sum_{i=1}^N \log \left(\sum_{j=1}^c \pi_j \mathcal{N}(x_i|\mu_j, \Sigma_j) \right)$$

Le problème est le **logarithme d'une somme**. Si le logarithme était à l'intérieur de la somme, nous pourrions facilement maximiser. Mais ici, c'est l'inverse : nous avons une somme à l'intérieur du logarithme, ce qui rend l'optimisation difficile.

C'est ce problème que l'algorithme EM va résoudre.

L'Algorithme Expectation-Maximization (EM)

L'idée géniale

L'idée clé de l'algorithme EM est la suivante : plutôt que d'essayer de maximiser directement la log-vraisemblance (difficile), nous allons maximiser une fonction auxiliaire plus simple.

Comment ? En utilisant une **approche itérative en deux étapes** :

1. **Étape E (Expectation)** : Étant donné les paramètres courants, estimer les variables latentes
2. **Étape M (Maximization)** : Étant donné les estimations des variables latentes, mettre à jour les paramètres

Et nous répétons ces deux étapes jusqu'à convergence.

Le Concept de Responsabilité

Le cœur de l'algorithme EM pour le GMM est le concept de **responsabilité**.

La responsabilité γ_{ij} est la **probabilité** que le point x_i ait été généré par la composante j , étant donné les paramètres courants.

Mathématiquement :

$$\gamma_{ij} = \mathbb{P}(\text{composante } j | x_i, \theta) = \frac{\pi_j \mathcal{N}(x_i | \mu_j, \Sigma_j)}{\sum_{k=1}^c \pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k)}$$

Interprétation intuitive : Imaginez que chaque point de données est une personne dans une foule, et chaque composante gaussienne est un groupe. La responsabilité γ_{ij} répond à la question : “Si je vois cette personne x_i , quelle est la probabilité qu'elle appartienne au groupe j ?”

Propriétés des responsabilités

1. **Normalisation** : Pour chaque point i , la somme des responsabilités sur toutes les composantes vaut 1 :

$$\sum_{j=1}^c \gamma_{ij} = 1$$

Cela signifie que chaque point est “distribué” entre les différentes composantes.

2. **Continuité** : $\gamma_{ij} \in [0, 1]$, contrairement aux indicateurs binaires $\{0, 1\}$ utilisés dans des algorithmes comme K-means.
3. **Sensibilité à la distance** : Un point proche du centre d'une composante aura une forte responsabilité pour cette composante. Un point à égale distance de deux composantes aura des responsabilités similaires pour les deux.

L'Algorithme EM en Détail

Étape 0 : Initialisation

Nous commençons avec une estimation initiale des paramètres $\theta^{(0)} = \{\pi_j^{(0)}, \mu_j^{(0)}, \Sigma_j^{(0)}\}_{j=1}^c$.

Stratégies d'initialisation courantes :

- Initialiser les poids uniformément : $\pi_j^{(0)} = 1/c$
- Choisir les moyennes $\mu_j^{(0)}$ au hasard parmi les données
- Initialiser les covariances à la matrice identité : $\Sigma_j^{(0)} = I$

Étape E : Calcul des Responsabilités

À l'itération t , avec les paramètres $\theta^{(t)}$, nous calculons :

$$\gamma_{ij}^{(t)} = \frac{\pi_j^{(t)} \mathcal{N}(x_i | \mu_j^{(t)}, \Sigma_j^{(t)})}{\sum_{k=1}^c \pi_k^{(t)} \mathcal{N}(x_i | \mu_k^{(t)}, \Sigma_k^{(t)})}$$

Pour chaque point i et chaque composante j .

Pourquoi cette étape s'appelle "Expectation" ? Parce que nous calculons l'espérance (la valeur moyenne attendue) des variables latentes étant donné les données et les paramètres courants.

Étape M : Mise à Jour des Paramètres

Maintenant que nous avons les responsabilités, nous mettons à jour les paramètres :

1. Nouveaux poids :

$$\pi_j^{(t+1)} = \frac{1}{N} \sum_{i=1}^N \gamma_{ij}^{(t)}$$

Interprétation : Le nouveau poids π_j est la proportion moyenne de responsabilité attribuée à la composante j sur tous les points.

2. Nouvelles moyennes :

$$\mu_j^{(t+1)} = \frac{\sum_{i=1}^N \gamma_{ij}^{(t)} x_i}{\sum_{i=1}^N \gamma_{ij}^{(t)}}$$

Interprétation : La nouvelle moyenne μ_j est la moyenne pondérée de tous les points, avec les responsabilités γ_{ij} comme poids.

3. Nouvelles covariances :

$$\Sigma_j^{(t+1)} = \frac{\sum_{i=1}^N \gamma_{ij}^{(t)} (x_i - \mu_j^{(t+1)})(x_i - \mu_j^{(t+1)})^T}{\sum_{i=1}^N \gamma_{ij}^{(t)}}$$

Interprétation : La nouvelle covariance Σ_j est la covariance pondérée des points autour de la nouvelle moyenne.

Convergence

Nous répétons les étapes E et M jusqu'à ce que :

- Les paramètres changent très peu entre deux itérations
- OU la log-vraisemblance change très peu
- OU nous atteignons un nombre maximum d'itérations

Pourquoi l'Algorithme EM Fonctionne ?

Intuition géométrique

Imaginez que vous essayez de découper une pizza en parts de tailles différentes, mais vous ne voyez pas les bords des parts. Comment faire ?

1. Vous faites une première estimation des bords (initialisation)
2. Pour chaque morceau de pizza, vous estimez à quelle part il appartient le plus probablement (étape E)
3. En regardant tous les morceaux attribués à une part, vous redessinez le bord de cette part (étape M)
4. Vous répétez jusqu'à ce que les bords ne bougent plus

Justification mathématique

L'algorithme EM garantit que la log-vraisemblance **ne décroît jamais** à chaque itération. Mathématiquement :

$$\log \mathcal{L}(\theta^{(t+1)}) \geq \log \mathcal{L}(\theta^{(t)})$$

Cela vient d'une inégalité mathématique importante appelée **inégalité de Jensen**.

Différence entre EM et K-means

K-means : Un cas particulier

Le K-means peut être vu comme un **cas particulier** de l'algorithme EM pour un GMM avec :

1. Toutes les matrices de covariance égales à $\sigma^2 I$
2. $\sigma^2 \rightarrow 0$ (variance tendant vers zéro)
3. Tous les poids égaux : $\pi_j = 1/c$

Dans cette limite, les responsabilités deviennent des **indicateurs binaires** : $\gamma_{ij} = 1$ si j est le cluster le plus proche, 0 sinon.

Comparaison détaillée

Aspect	K-means	EM pour GMM
Type d'assignation	Dure (0 ou 1)	Douce (probabilités)
Forme des clusters	Sphères uniquement	Ellipsoïdes de formes variées
Modèle probabiliste	Non	Oui
Gestion du recouvrement	Mauvaise	Excellente
Vitesse de convergence	Rapide	Plus lente
Robustesse aux outliers	Faible	Meilleure

Applications Pratiques

1. Clustering non supervisé

Le GMM avec EM est souvent utilisé pour le clustering quand :

- Les clusters ont des formes non sphériques
- Les clusters se chevauchent
- Nous voulons une mesure de l'incertitude sur l'appartenance aux clusters

2. Estimation de densité

Pour modéliser la distribution sous-jacente des données, même quand elle est complexe et multimodale.

3. Classification

Si nous interprétons les composantes comme des classes, nous pouvons utiliser le GMM pour la classification en attribuant chaque point à la composante avec la plus haute responsabilité.

4. Génération de données

Une fois le GMM estimé, nous pouvons générer de nouvelles données réalistes :

1. Tirer une composante j selon les poids π_j
2. Tirer un point x selon $\mathcal{N}(\mu_j, \Sigma_j)$

Défis et Solutions

1. Choix du nombre de composantes

Comment choisir c (le nombre de composantes) ?

Solutions :

- Utiliser le **Critère d'Information Bayésien (BIC)** qui pénalise les modèles complexes
- Validation croisée
- Examiner l'évolution de la vraisemblance en fonction de c

2. Initialisation

EM converge vers un **optimum local**. Une mauvaise initialisation peut mener à une mauvaise solution.

Solutions :

- Multiples initialisations aléatoires
- Utiliser K-means pour une initialisation intelligente
- K-means++ pour une meilleure dispersion des centres initiaux

3. Problèmes numériques

Quand une composante reçoit très peu de points, sa matrice de covariance peut devenir singulière (non inversible).

Solutions :

- Ajouter une petite valeur à la diagonale (régularisation)
- Contraindre les formes des matrices de covariance

Types de Matrices de Covariance

1. Sphérique

$\Sigma_j = \sigma_j^2 I$: Toutes les directions ont la même variance.

Nombre de paramètres : 1 par composante

2. Diagonale

$\Sigma_j = \text{diag}(\sigma_{j1}^2, \dots, \sigma_{jD}^2)$: Chaque dimension a sa propre variance, mais pas de corrélations.

Nombre de paramètres : D par composante

3. Pleine

Σ_j : Matrice symétrique définie positive complète.

Nombre de paramètres : $D(D+1)/2$ par composante

Compromis : Plus la matrice est contrainte, moins il y a de paramètres à estimer (bon quand on a peu de données), mais moins le modèle est flexible.

Exemple Complet : De la Théorie à la Pratique

Problème

Nous avons des données de tailles et de poids d'animaux. Nous soupçonnons qu'il y a deux espèces différentes, mais nous ne savons pas quelle donnée correspond à quelle espèce.

Solution avec GMM et EM

1. **Modélisation** : Nous choisissons un GMM avec 2 composantes ($c = 2$)
2. **Initialisation** :
 - $\pi_1^{(0)} = \pi_2^{(0)} = 0.5$
 - $\mu_1^{(0)}$ et $\mu_2^{(0)}$ choisis au hasard parmi les données
 - $\Sigma_1^{(0)} = \Sigma_2^{(0)} = I$
3. **Première itération (E)** : Calcul des premières responsabilités
 - Pour un point de taille 50 cm et poids 20 kg : $\gamma_{i1} = 0.7, \gamma_{i2} = 0.3$
 - Pour un point de taille 100 cm et poids 80 kg : $\gamma_{i1} = 0.1, \gamma_{i2} = 0.9$
4. **Première itération (M)** : Mise à jour des paramètres
 - $\pi_1^{(1)} = 0.6, \pi_2^{(1)} = 0.4$ (il y a plus de points semblables à la première espèce)
 - $\mu_1^{(1)}$ devient la moyenne pondérée des points “semblables à l'espèce 1”
 - $\mu_2^{(1)}$ devient la moyenne pondérée des points “semblables à l'espèce 2”
5. **Itérations suivantes** : Répétition jusqu'à convergence
6. **Résultat final** :
 - Deux gaussiennes bien séparées
 - Pour chaque point, une probabilité d'appartenance à chaque espèce
 - Possibilité de classer les points selon l'espèce la plus probable

Conclusion

Le Modèle de Mélange Gaussien et l'algorithme EM forment un duo puissant pour l'apprentissage non supervisé. Leur force réside dans :

1. **Flexibilité** : Capacité à modéliser des distributions complexes
2. **Interprétation probabiliste** : Fournit non seulement des clusters, mais aussi des mesures d'incertitude
3. **Fondation théorique solide** : Basé sur des principes statistiques rigoureux

Le concept de **responsabilité** est particulièrement important : il transforme un problème difficile (clustering avec incertitude) en une solution élégante où chaque point participe partiellement à tous les clusters, avec des poids qui guident l'apprentissage.

Cette approche illustre une idée fondamentale en apprentissage automatique : parfois, pour résoudre un problème difficile, il faut **introduire des variables supplémentaires** (les variables latentes) qui simplifient le problème, même si ces variables ne sont pas directement observables.