

Table of contents

Cours pédagogique : Clustering et algorithme k-means	2
Comprendre le problème du clustering	2
La métaphore du “regroupement naturel”	2
L’essence de k-means	2
La double mission	2
La fonction objectif : le cœur mathématique	2
L’idée intuitive	2
Formalisation mathématique	3
La fonction à minimiser	3
Pourquoi minimiser CETTE fonction spécifique ?	4
Raison 1 : L’interprétation géométrique	4
Raison 2 : La solution analytique existe	4
Raison 3 : Connexion avec les statistiques	4
L’optimisation : comment minimiser cette fonction ?	5
Le défi	5
La stratégie : Descente de coordonnées	5
Détail des deux étapes d’optimisation	7
Étape 1 : Optimisation des affectations (E)	7
Étape 2 : Optimisation des centres (M)	7
Preuve que cette alternance diminue toujours l’erreur	8
Un argument visuel	8
Preuve mathématique	8
Conséquence importante	8
Le piège des minima locaux	9
L’analogie montagnarde	9
Pourquoi cela arrive-t-il ?	10
L’initialisation intelligente : k-means++	10
Le principe	10
Algorithme détaillé	10
Pourquoi ça marche ?	11
Relation avec les modèles gaussien	11
L’hypothèse implicite	11
Le modèle probabiliste correspondant	11
Le lien mathématique	11
Conclusion du lien	12
Synthèse pédagogique	12
Ce qu’il faut retenir	12
Pour résumer visuellement	13
Pour aller plus loin	13
Questions pour approfondir	13

Exploration interactive suggérée	13
Le mot de la fin	14

Cours pédagogique : Clustering et algorithme k-means

Comprendre le problème du clustering

La métaphore du “regroupement naturel”

Imaginez que vous regardez le ciel étoilé. Certaines étoiles semblent naturellement regroupées en **constellations**. Personne ne vous a dit quelles étoiles forment la Grande Ourse - vous le voyez par vous-même.

C’est exactement le **clustering** : découvrir des groupes naturels dans les données, sans guide préalable.

L’essence de k-means

La double mission

k-means cherche à accomplir **deux objectifs simultanés** :

1. **Trouver K centres** représentatifs
2. **Affecter chaque point** au centre le plus proche

Mais comment juger si on a bien réussi ?

La fonction objectif : le cœur mathématique

L’idée intuitive

Mesurons à quel point chaque point est **éloigné** du centre de son groupe. Plus cette distance est petite, meilleur est le regroupement.

Pour l’ensemble des données, nous calculons :

$$\text{Erreur totale} = \sum_{\text{tous les points}} (\text{distance au centre de son groupe})^2$$

Formalisation mathématique

Définissons précisément :

- **Données** : N points $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N$ dans un espace à D dimensions
- **Clusters** : K groupes (nombre choisi à l'avance)
- **Centres** : $\mu_1, \mu_2, \dots, \mu_K$ (à déterminer)
- **Affectation** : Pour chaque point i et cluster k , $z_{ik} = 1$ si le point i est dans le cluster k , 0 sinon

La fonction à minimiser

La fonction objectif (ou fonction coût) est :

$$J = \sum_{i=1}^N \sum_{k=1}^K z_{ik} \|\mathbf{x}_i - \mu_k\|^2$$

Décomposons cette formule :

Symbole	Signification	Rôle dans la formule
z_{ik}	Indicateur d'appartenance	Sélectionne seulement le cluster auquel le point appartient
$\ \mathbf{x}_i - \mu_k\ ^2$	Distance au carré	Mesure combien le point est éloigné du centre
$\sum_{i=1}^N$	Somme sur tous les points	Accumule l'erreur pour l'ensemble des données
$\sum_{k=1}^K$	Somme sur tous les clusters	Considère tous les clusters possibles

En pratique : Puisque chaque point n'appartient qu'à un seul cluster, pour un point $\mathbf{x}_i$, un seul z_{ik} vaut 1, les autres valent 0. Donc pour chaque point, on ne compte que la distance à son propre centre.

Pourquoi minimiser CETTE fonction spécifique ?

Raison 1 : L'interprétation géométrique

Si nous fixons les affectations z_{ik} , alors pour chaque cluster k :

$$J_k = \sum_{i:z_{ik}=1} \|\mathbf{x}_i - \mu_k\|^2$$

C'est exactement la **variance** des points du cluster k , multipliée par le nombre de points.

Minimiser J = Minimiser la variance intra-cluster = Rendre les clusters plus compacts

Raison 2 : La solution analytique existe

Si on dérive J par rapport à μ_k :

$$\frac{\partial J}{\partial \mu_k} = -2 \sum_{i=1}^N z_{ik} (\mathbf{x}_i - \mu_k)$$

En posant la dérivée égale à zéro :

$$\sum_{i=1}^N z_{ik} (\mathbf{x}_i - \mu_k) = 0$$

$$\Rightarrow \mu_k = \frac{\sum_{i=1}^N z_{ik} \mathbf{x}_i}{\sum_{i=1}^N z_{ik}}$$

Interprétation : Le centre optimal est la **moyenne** (centre de gravité) des points du cluster.

Raison 3 : Connexion avec les statistiques

Cette fonction correspond à la **log-vraisemblance** d'un modèle où chaque cluster est une gaussienne sphérique de même variance.

L'optimisation : comment minimiser cette fonction ?

Le défi

Nous avons deux types de variables :


1. Les **affectations** z_{ik} (variables discrètes, binaires)
2. Les **centres** μ_k (variables continues)

Le problème combinatoire est **NP-difficile** : impossible de tester toutes les combinaisons.

La stratégie : Descente de coordonnées

Au lieu d'optimiser simultanément sur toutes les variables, nous alternons :

1. **Optimiser les affectations** en fixant les centres
2. **Optimiser les centres** en fixant les affectations



Détail des deux étapes d'optimisation

Étape 1 : Optimisation des affectations (E)

Hypothèse : Les centres $\mu_1, \dots, \mu_K$ sont fixés.

Objectif : Choisir les z_{ik} pour minimiser J .

Observation : La fonction J est une somme de termes positifs. Pour minimiser une somme, on minimise chaque terme individuellement.

Pour un point $\mathbf{x}_i$ donné, nous devons choisir un seul k tel que $z_{ik} = 1$. Le terme correspondant est $\|\mathbf{x}_i - \mu_k\|^2$.

Solution optimale : Affecter $\mathbf{x}_i$ au centre le plus proche !

Formellement :

$$z_{ik} = \begin{cases} 1 & \text{si } k = \arg \min_j \|\mathbf{x}_i - \mu_j\|^2 \\ 0 & \text{sinon} \end{cases}$$

Complexité : Pour chaque point (N), comparer avec chaque centre (K) $\rightarrow O(N \times K \times D)$ opérations.

Étape 2 : Optimisation des centres (M)

Hypothèse : Les affectations z_{ik} sont fixées.

Objectif : Choisir les μ_k pour minimiser J .

Calcul : Comme vu précédemment, en dérivant par rapport à μ_k :


$$\mu_k = \frac{\sum_{i=1}^N z_{ik} \mathbf{x}_i}{\sum_{i=1}^N z_{ik}}$$

Interprétation : Le nouveau centre du cluster k est la **moyenne** (barycentre) de tous les points qui lui sont affectés.

Complexité : Pour chaque cluster (K), moyenner ses points $\rightarrow O(N \times D)$ opérations.

Preuve que cette alternance diminue toujours l'erreur

Un argument visuel



Preuve mathématique

1. **Étape E** : Pour des centres fixés $\mu_k^{(t)}$, choisir $z_{ik}^{(t+1)}$ comme l'affectation optimale garantit :

$$J(\mu^{(t)}, z^{(t+1)}) \leq J(\mu^{(t)}, z^{(t)})$$

(strictement inférieur si une affectation change)

2. **Étape M** : Pour des affectations fixées $z_{ik}^{(t+1)}$, choisir $\mu_k^{(t+1)}$ comme les moyennes optimales garantit :

$$J(\mu^{(t+1)}, z^{(t+1)}) \leq J(\mu^{(t)}, z^{(t+1)})$$

(strictement inférieur si un centre change)

3. **Conclusion** : À chaque itération complète (E puis M), l'erreur ne peut que décroître :

$$J^{(t+1)} \leq J^{(t)}$$

Conséquence importante


Puisque l'erreur est toujours positive et décroît à chaque itération, l'algorithme **converge nécessairement**.

Le piège des minima locaux

L'analogie montagnarde

Imaginez que vous cherchez le point le plus bas d'une région montagneuse, les yeux bandés. Vous descendez toujours. Vous finirez dans une vallée, mais pas nécessairement dans la vallée la plus basse !

C'est exactement ce qui arrive à k-means :



Pourquoi cela arrive-t-il ?

La fonction J n'est pas **convexe** par rapport à l'ensemble des variables. Elle a plusieurs "vallées" (minima locaux).

Exemple concret : Avec 4 points formant un carré, et $K=2$, il y a deux solutions équivalentes :

- Solution 1 : Cluster $\{(1,2)\}$, Cluster $\{(3,4)\}$
- Solution 2 : Cluster $\{(1,3)\}$, Cluster $\{(2,4)\}$

Les deux donnent la même valeur de J , mais ce sont des minima locaux différents.

L'initialisation intelligente : k-means++

Le principe

Plutôt que de choisir les centres initiaux au hasard, choisissons-les de manière à "couvrir" l'espace des données.

Algorithme détaillé

1. **Premier centre** : Choisi uniformément au hasard parmi tous les points
2. **Pour chaque centre suivant** :
 - a. Pour chaque point $\mathbf{x}_i$, calculer :

$$D(\mathbf{x}_i) = \min_{\text{centres déjà choisis}} \|\mathbf{x}_i - \mu_j\|^2$$

(Distance au carré au centre le plus proche déjà choisi)

- b. Choisir le prochain centre avec probabilité proportionnelle à $D(\mathbf{x}_i)^2$

$$P(\text{choisir } \mathbf{x}_i) = \frac{D(\mathbf{x}_i)^2}{\sum_{j=1}^N D(\mathbf{x}_j)^2}$$

3. **Répéter** jusqu'à avoir K centres

Pourquoi ça marche ?

- Les points éloignés des centres existants ont une plus grande probabilité d'être choisis
 - Cela garantit que les centres initiaux sont **répartis** dans tout l'espace
 - En pratique, cela donne de meilleurs résultats que l'initialisation purement aléatoire
-

Relation avec les modèles gaussien

L'hypothèse implicite

k-means suppose que chaque cluster suit approximativement une **distribution normale** (gaussienne) avec :

1. **Forme sphérique** : La covariance est $\sigma^2 I$ (identique dans toutes les directions)
2. **Même variance** : Tous les clusters ont la même "dispersion"
3. **Centres différents** : Chaque cluster a son propre centre μ_k

Le modèle probabiliste correspondant

Si chaque cluster k est modélisé par une gaussienne $\mathcal{N}(\mu_k, \sigma^2 I)$, alors la densité de probabilité est :

$$p(\mathbf{x} | \text{cluster } k) = \frac{1}{(2\pi\sigma^2)^{D/2}} \exp\left(-\frac{\|\mathbf{x} - \mu_k\|^2}{2\sigma^2}\right)$$

Le lien mathématique

Considérons la **log-vraisemblance** des données :

$$\log p(\mathcal{X} | \{\mu_k\}) = \sum_{i=1}^N \log \left(\sum_{k=1}^K \pi_k p(\mathbf{x}_i | \mu_k, \sigma^2 I) \right)$$

Avec $\pi_k = 1/K$ (clusters équiprobables).

Cas limite : Quand $\sigma^2 \rightarrow 0$ (distributions très "pointues"), le terme dominant dans la somme est celui du cluster le plus proche.

On obtient alors approximativement :

$$\log p(\mathcal{X}|\{\mu_k\}) \approx \text{constante} - \frac{1}{2\sigma^2} \sum_{i=1}^N \min_k \|\mathbf{x}_i - \mu_k\|^2$$

Maximiser cette vraisemblance équivaut à **minimiser** :

$$\sum_{i=1}^N \min_k \|\mathbf{x}_i - \mu_k\|^2$$

Ce qui est exactement la fonction J de k-means !

Conclusion du lien


k-means peut être vu comme un **algorithme EM** pour un mélange de gaussiennes sphériques de même variance, en prenant la limite où les distributions sont infiniment “pointues” (affectation dure).

Synthèse pédagogique

Ce qu'il faut retenir

1. **k-means minimise** : La somme des carrés des distances entre chaque point et le centre de son cluster
2. **Méthode d'optimisation** : Alternance entre deux étapes simples :
 - **Affectation** : Chaque point rejoint le centre le plus proche
 - **Mise à jour** : Chaque centre devient la moyenne de ses points
3. **Propriété garantie** : L'erreur diminue à chaque itération jusqu'à convergence
4. **Limite principale** : Converge vers un minimum local, pas nécessairement global
5. **Amélioration clé** : k-means++ pour une meilleure initialisation

Pour résumer visuellement



Pour aller plus loin

Questions pour approfondir

1. **Que se passe-t-il si on change la métrique ?** (Passer de la distance euclidienne à la distance de Manhattan)
2. **Comment adapter k-means** pour des clusters de densités différentes ?
3. **Pourquoi ne pas minimiser la somme des distances** (pas au carré) ?

Exploration interactive suggérée

Essayez mentalement cet exercice :

- Prenez 6 points formant deux triangles équilatéraux
 - Appliquez k-means avec $K=2$
 - Observez comment l'initialisation influence le résultat final
-

Le mot de la fin

k-means est comme un **chef d'orchestre** qui organise les musiciens (les points) en sections (clusters) en plaçant chaque musicien près du chef de section (centre) tout en éloignant les sections les unes des autres.

La beauté de l'algorithme réside dans sa **simplicité** : une idée simple (minimiser les distances), une méthode efficace (alternance), et des résultats interprétables.

Rappel : Comprendre la fonction objectif et son optimisation est la clé pour utiliser k-means judicieusement et interpréter correctement ses résultats !