

Table of contents

Algorithme k-means et estimation de facteurs latents discrets	1
Motivation	1
Clustering	1
Méthodes de clustering	2
Clustering hiérarchique agglomératif	2
k-means	3
Stratégie	3
Fonction de coût	3
Descente de coordonnées	4
Application à k-means	4
Algorithme k-means	5
Propriétés	5
k-means++	5
Résumé	6
Exemples de questions	6

Algorithme k-means et estimation de facteurs latents discrets

Motivation

Comprendre les propriétés géométriques et statistiques des données, les analyser et développer des outils pour cette analyse. Ici, nous nous intéressons particulièrement à l'approche non supervisée du **clustering**.

Clustering

Le clustering est une méthode non supervisée qui vise à découvrir des groupes cohérents dans les données, correspondant aux pics de densité.

Un synonyme souvent utilisé est la **Quantification Vectorielle (VQ)**.

Méthodes de clustering

Il existe de nombreuses méthodes de clustering :

- Clustering hiérarchique agglomératif
- **k-means** (algorithme de Lloyd)
- Clustering spectral
- Détection de communautés
- Clustering en haute dimension
- Cartes auto-organisatrices (SOM)
- Neural Gas

La recherche sur le clustering est active depuis au moins 50 ans.

Clustering hiérarchique agglomératif

Processus itératif :

1. Initialisation : chaque donnée est un cluster
2. Trouver la paire de clusters la plus proche
3. Fusionner ces deux clusters
4. Itérer depuis l'étape 2 jusqu'à la fin

On obtient un **dendrogramme**.

La distance entre clusters peut être définie par :

- Distance entre centres
- Distance maximale
- Distance minimale

Le nombre de clusters est **inconnu à priori**.

k-means

Stratégie

Le **k-means** postule un espace métrique (euclidien) sur les données.
C'est un algorithme d'affectation **binaire** : chaque donnée appartient à un et un seul cluster.

Modèle

Données :

$$\mathcal{X} = \{\mathbf{x}_i\}_{i \in [M]} \subset \Omega \subseteq \mathbb{R}^D$$

Nombre de clusters : $K \in \mathbb{N}^*$

Variables d'affectation binaires latentes :

$$\mathbf{Z} = \{z_{ik}\} \text{ avec } z_{ik} \in \{0, 1\}$$

Représentants des clusters :

$$\mathbf{M} = \{\mu_k\}_{k \in [K]} \text{ avec } \mu_k \in \mathbb{R}^D$$

Paramètres :

$$\theta = [M, Z]$$

Fonction de coût

Le k-means cherche à minimiser :

$$\hat{\theta} = [\hat{M}, \hat{Z}] = \underset{\theta=[M, Z]}{\operatorname{argmin}} \mathcal{L}(\theta, \mathcal{X})$$

avec :

$$\mathcal{L}(\theta, \mathcal{X}) = \sum_{i=1}^N \sum_{k=1}^K z_{ik} \|\mathbf{x}_i - \mu_k\|_2^2$$

L'optimisation exacte est **NP-difficile** → on utilise une **descente de coordonnées**.

Descente de coordonnées

Algorithme de minimisation alternée :

Soit $f : \mathbb{R}^D \mapsto \mathbb{R}$, on cherche :

$$x^* = \arg \min_{x \in \mathbb{R}^D} f(x)$$

On définit pour $d \in [D]$:

$$f_d(x, y) = f([x_{(1)}, \dots, x_{(d-1)}, y, x_{(d+1)}, \dots, x_{(D)}]^\top)$$

On minimise alternativement :

$$x_{(d)}^{(t+1)} = \arg \min_y f_d(x^{(t)}, y)$$

Application à k-means

On alterne l'optimisation de Z et M .

Pour un Z fixé, le représentant optimal d'un cluster est le **centre de masse** :

$$\mu_k = \frac{\sum_{i=1}^N z_{ik} \mathbf{x}_i}{\sum_{i=1}^N z_{ik}}$$

Pour un M fixé, on affecte chaque donnée au cluster le plus proche :

$$z_{ik} = 1 \quad \text{si } k = \arg \min_j \|\mathbf{x}_i - \mu_j\|_2^2$$

Algorithme k-means

1. Initialiser les représentants $M^{(0)}$
2. **Étape d'affectation** : étant donné $M^{(t)}$, affecter chaque donnée au représentant le plus proche $\rightarrow Z^{(t)}$
3. **Étape de mise à jour** : étant donné $Z^{(t)}$, calculer les nouveaux représentants $M^{(t+1)}$ comme centres de masse
4. Répéter jusqu'à convergence (centres stables ou affectation stable)

L'étape 2 est similaire à une **étape E** (Expectation), l'étape 3 à une **étape M** (Maximisation), en affectation dure (cf. EM).

Propriétés

- La perte décroît à chaque itération (minimisation alternée de fonctions convexes)
 - Nombre d'itérations fini (nombre fini d'affectations)
 - Étape d'affectation = construction du **diagramme de Voronoi** discret
 - Résultat = **optimum local** (problème NP-dur)
 - Sensible à l'initialisation
-

k-means++

Initialisation des représentants pour les **maximiser éloignés** :

1. Choisir μ_1^0 aléatoirement parmi les données
2. Pour chaque donnée non sélectionnée, calculer la distance au représentant le plus proche déjà choisi :
$$\Delta_j = \min_m \|\mathbf{x}_j - \mu_m^0\|_2^2$$

3. Choisir le prochain représentant avec une probabilité proportionnelle à Δ_j
4. Répéter jusqu'à avoir K représentants

Cette méthode améliore la qualité des clusters et accélère la convergence.

Résumé

- Le clustering fait partie des méthodes **non supervisées**
- **k-means** est l'une des techniques les plus populaires
- Affectation **binaire** (dure)
- Critère d'optimisation NP-dur $\rightarrow$ solution approchée par **descente de coordonnées**
- Résultat dépend de l'initialisation
- **k-means++** : initialisation heuristique efficace
- Le clustering peut être **contraint** (liens MUST/CANNOT)

Exemples de questions

- Décrire formellement le clustering
- En quoi est-ce une technique non supervisée ?
- Pourquoi k-means est-il lié à la métrique euclidienne ?
- Pourquoi dit-on que k-means suppose un modèle gaussien pour les clusters ?
- L'algorithme k-means est-il exact ?
- Quels sont les principes d'initialisation de k-means ?
- Qu'est-ce que la descente de coordonnées ?

Il est fortement conseillé de maîtriser l'algèbre présentée dans ce chapitre.