

Table of contents

Explication du problème du clustering et de l'algorithme k-means	1
Question	1
Le problème du clustering	1
Pourquoi le clustering est-il nécessaire ?	2
Définition formelle	2
L'algorithme k-means	2
Principe fondamental	2
Modélisation mathématique	2
Pourquoi cette fonction de coût ?	3
L'algorithme d'optimisation	3
Descente de coordonnées	3
Algorithme complet	4
Relation avec un modèle gaussien	4
Hypothèse sous-jacente	4
Modèle de mélange de gaussiennes (GMM)	4
Log-vraisemblance et k-means	4
Interprétation probabiliste	5
Propriétés et limitations	5
Avantages	5
Limitations	6
Solutions courantes	6
Conclusion	6

Explication du problème du clustering et de l'algorithme k-means

Question

Expliquez le problème du regroupement et décrivez l'algorithme de regroupement k-means. En particulier, discutez de la fonction qu'il minimise et de sa relation avec un modèle gaussien.

Le problème du clustering

Le **clustering** (ou regroupement) est une tâche fondamentale en analyse de données non supervisée. Son objectif est d'organiser un ensemble de données en **groupes homogènes** sans avoir recours à des étiquettes préexistantes.

Pourquoi le clustering est-il nécessaire ?

Les données réelles présentent rarement une distribution uniforme :

- Elles tendent à se regrouper en **régions de haute densité** séparées par des régions de faible densité
- Ces regroupements naturels correspondent souvent à des **sous-populations** ou **catégories intrinsèques**
- Le clustering permet de découvrir cette **structure latente** sans supervision

Définition formelle

Étant donné un ensemble de données $\mathcal{X} = \{\mathbf{x}_i\}_{i=1}^N$ avec $\mathbf{x}_i \in \mathbb{R}^D$, le clustering cherche à :

1. Partitionner les données en K groupes (clusters)
 2. Maximiser la **similarité intra-cluster** (données d'un même groupe se ressemblent)
 3. Maximiser la **dissimilarité inter-clusters** (groupes différents sont distincts)
-

L'algorithme k-means

Le **k-means** est l'algorithme de clustering le plus populaire en raison de sa simplicité et efficacité.

Principe fondamental

k-means postule que les données existent dans un **espace métrique euclidien** et que chaque cluster peut être représenté par son **centre** (moyenne des points du cluster).

L'algorithme effectue une **affectation dure** : chaque donnée appartient à un et un seul cluster.

Modélisation mathématique

Variables

- **Données** : $\mathcal{X} = \{\mathbf{x}_i\}_{i=1}^N \subset \mathbb{R}^D$
- **Nombre de clusters** : $K \in \mathbb{N}^*$ (fixé a priori)
- **Variables d'affectation latentes** : $\mathbf{Z} = \{z_{ik}\}$ où $z_{ik} \in \{0, 1\}$ avec $\sum_{k=1}^K z_{ik} = 1$
- **Représentants des clusters** : $\mathbf{M} = \{\mu_k\}_{k=1}^K \subset \mathbb{R}^D$

Fonction de coût (loss function)

k-means minimise la **somme des carrés des distances** entre chaque point et le centre de son cluster :

$$\mathcal{L}(\mathbf{M}, \mathbf{Z}; \mathcal{X}) = \sum_{i=1}^N \sum_{k=1}^K z_{ik} \|\mathbf{x}_i - \mu_k\|_2^2$$

Cette fonction mesure la **compacité** des clusters : plus la valeur est faible, plus les points sont proches de leur centre.

Pourquoi cette fonction de coût ?

1. **Interprétation géométrique** : Minimiser la variance intra-cluster
 2. **Propriété statistique** : Avec la distance euclidienne, le centre optimal est la moyenne (preuve par dérivation)
 3. **Convexité par morceaux** : Convexe en $\mathbf{M}$ pour $\mathbf{Z}$ fixé, et convexe en $\mathbf{Z}$ pour $\mathbf{M}$ fixé
-

L'algorithme d'optimisation

Descente de coordonnées

Le problème d'optimisation combinatoire est **NP-dur**. k-means utilise une **descente de coordonnées** (optimisation alternée) :

Étape E (Expectation - Affectation)

Pour des centres $\mathbf{M}^{(t)}$ fixés, on affecte chaque point à son cluster le plus proche :

$$z_{ik}^{(t+1)} = \begin{cases} 1 & \text{si } k = \arg \min_j \|\mathbf{x}_i - \mu_j^{(t)}\|_2^2 \\ 0 & \text{sinon} \end{cases}$$

Étape M (Maximization - Mise à jour des centres)

Pour une affectation $\mathbf{Z}^{(t+1)}$ fixée, on recalcule les centres comme moyennes :

$$\mu_k^{(t+1)} = \frac{\sum_{i=1}^N z_{ik}^{(t+1)} \mathbf{x}_i}{\sum_{i=1}^N z_{ik}^{(t+1)}}$$

Algorithme complet

1. **Initialisation** : Choisir K centres initiaux (aléatoirement ou par k-means++)
 2. **Étape d'affectation** : Assigner chaque point au centre le plus proche
 3. **Étape de mise à jour** : Recalculer les centres comme moyennes des points assignés
 4. **Itération** : Répéter étapes 2-3 jusqu'à convergence
 - Critère d'arrêt : Les centres ne bougent plus ou l'affectation est stable
-

Relation avec un modèle gaussien

Hypothèse sous-jacente

k-means suppose implicitement que chaque cluster suit une **distribution gaussienne isotrope** avec :

- **Même covariance** : $\Sigma_k = \sigma^2 I$ pour tous les clusters
- **Centres différents** : μ_k spécifiques à chaque cluster
- **Égale probabilité a priori** : $P(\text{cluster } k) = 1/K$

Modèle de mélange de gaussiennes (GMM)

Considérons un **mélange de gaussiennes** avec covariance sphérique :

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} | \mu_k, \sigma^2 I)$$

où $\pi_k = 1/K$ sont les poids des clusters.

Log-vraisemblance et k-means

La log-vraisemblance des données sous ce modèle est :

$$\log p(\mathcal{X} | \mathbf{M}, \sigma) = \sum_{i=1}^N \log \left(\sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_i | \mu_k, \sigma^2 I) \right)$$

Approximation “hard assignment”

k-means correspond à deux approximations :

1. **Affectation dure** : Au lieu d’affectations probabilistes, chaque point appartient entièrement à un cluster
2. **Limite de variance nulle** : Quand $\sigma^2 \rightarrow 0$, la vraisemblance est dominée par le cluster le plus proche

Dans cette limite, maximiser la log-vraisemblance équivaut à **minimiser** :

$$\sum_{i=1}^N \min_k \|\mathbf{x}_i - \mu_k\|_2^2$$

Ce qui est exactement la fonction de coût de k-means !

Interprétation probabiliste

- **k-means** EM pour GMM avec covariance sphérique et affectation dure
- **Étape E** : Affectation au cluster le plus probable (mode de la distribution postérieure)
- **Étape M** : Maximisation de la vraisemblance pour chaque cluster

Cette connexion explique pourquoi k-means :

- Fonctionne bien quand les clusters sont **sphériques** et de **taille similaire**
- Est sensible aux **outliers** (les gaussiennes décroissent exponentiellement)
- Suppose une **même échelle** dans toutes les dimensions (covariance isotrope)

Propriétés et limitations

Avantages

- **Simple et efficace** : Complexité linéaire en N par itération
- **Interprétable** : Les centres sont des “prototypes” des clusters
- **Convergence garantie** : La fonction de coût décroît à chaque itération

Limitations

- **Nombre de clusters K** : Doit être spécifié a priori
- **Initialisation sensible** : Converge vers un optimum local
- **Forme des clusters** : Suppose des clusters convexes et sphériques
- **Métrie euclidienne** : Peut ne pas convenir à tous les types de données

Solutions courantes

- **k-means++** : Initialisation intelligente pour de meilleurs résultats
- **Exécutions multiples** : Lancer l'algorithme plusieurs fois avec différentes initialisations
- **Standardisation** : Mettre les données à même échelle avant application

Conclusion

Le **clustering** adresse le problème fondamental de découvrir la structure sous-jacente dans des données non étiquetées.

L'**algorithme k-means** offre une solution efficace en minimisant la somme des carrés des distances intra-cluster via une descente de coordonnées alternée.

Son lien avec un **modèle gaussien** révèle que k-means suppose implicitement des clusters sphériques de variance égale, correspondant à un mélange de gaussiennes isotropes en limite d'affectation dure.

Cette compréhension théorique guide son application pratique : k-means excelle quand les données forment naturellement des groupes compacts et sphériques, mais nécessite des adaptations (comme k-means++ ou le choix judicieux de K) pour des cas plus complexes.