

Table of contents

Document de Révision : Concepts fondamentaux et applications en Data Science	2
Introduction à la Data Science	2
Vue d'ensemble du domaine	2
Principaux problèmes d'intérêt	2
Notations et conventions mathématiques	3
Variables aléatoires scalaires	3
Vecteurs aléatoires	4
Théorie des probabilités	5
Distributions de probabilité	5
Distributions jointes et marginales	7
Règle de chaîne et décomposition	8
Indépendance statistique	9
Modèles de Markov	12
Moments et caractéristiques des distributions	14
Moments des distributions	14
Fonction caractéristique	16
Estimation empirique des moments	18
Propriétés de la variance et covariance	21
Applications des moments	24
Algèbre linéaire pour la Data Science	25
Normes vectorielles	25
Distances et mesures de similarité	28
Interprétation géométrique	30
Produit scalaire et projections	31
Vecteurs orthogonaux et colinéaires	33
Extraction et traitement de caractéristiques	35
Principe général de l'extraction de features	35
Types d'approches	36
Techniques clés	37
Fouille de données (Information Mining)	39
Problématique	39
Applications	40

Document de Révision : Concepts fondamentaux et applications en Data Science

Introduction à la Data Science

Vue d'ensemble du domaine

La Data Science est un domaine interdisciplinaire qui combine statistiques, mathématiques, informatique et expertise métier pour extraire des connaissances et des insights à partir de données structurées et non structurées.

Principaux problèmes d'intérêt

Extraction de caractéristiques (Feature Extraction)

L'extraction de caractéristiques consiste à transformer des données brutes en descripteurs pertinents qui capturent l'information essentielle.

Objectifs principaux :

- Extraire des descripteurs pertinents des données brutes
- Réduire la dimensionnalité tout en préservant l'information
- Faciliter les tâches d'analyse ultérieures

Fouille de données (Information Mining)

La fouille de données vise à découvrir des patterns, tendances et relations cachées dans de grandes bases de données.

Caractéristiques :

- Découvrir des patterns cachés dans les données
- L'élément ou caractéristique commune est **inconnu** a priori
- Nécessite des techniques exploratoires

Reconnaissance et Classification

Objectif :

- Identifier et catégoriser des objets ou patterns
- Assigner automatiquement des catégories basées sur des caractéristiques

Recherche et Identification

Objectif :

- Retrouver et authentifier des éléments dans des bases de données
- Identifier de manière non ambiguë des objets ou personnes

Transmission et Compression

Objectif :

- Encoder et transmettre l'information efficacement
- Réduire la taille des données tout en préservant la qualité

Sécurité Multimédia

Objectif :

- Protéger et authentifier les contenus numériques
- Détecter les manipulations et falsifications

Notations et conventions mathématiques

Variables aléatoires scalaires

Notations de base

Variable aléatoire scalaire :

- X : variable aléatoire scalaire (lettre majuscule)
- x : réalisation de la variable aléatoire (lettre minuscule)
- X prend des valeurs dans l'ensemble $\mathcal{X}$

Ensembles de valeurs possibles

Variables discrètes

Les variables discrètes prennent des valeurs dans un ensemble dénombrable :

- $\mathcal{X} = \{0, 1, 2, \dots\}$ (entiers naturels)
- $\mathcal{X} = \{0, 1\}$ (binaire)
- $\mathcal{X} = \{a, b, \dots, z\}$ (alphabet)
- $\mathcal{X} = \{\text{Janvier, Février, } \dots, \text{Décembre}\}$ (catégories)

Variables continues

Les variables continues prennent des valeurs dans un ensemble continu :

- $\mathcal{X} = \mathbb{R}$ (nombres réels)
- $\mathcal{X} = \mathbb{R}^+$ (réels positifs)
- $x_i \in \mathbb{S}$ ou $\mathcal{X}$ (espace général)

Vecteurs aléatoires

Notation vectorielle

Forme colonne :

$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_N \end{pmatrix}$$

Forme ligne :

$$X = (X_1, X_2, \dots, X_N)$$

où chaque X_i est une variable aléatoire composante.

Réalisation d'un vecteur

Vecteur de réalisations :

$$x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{pmatrix}$$

avec $x_i \in \mathcal{X}$ pour tout $i = 1, \dots, N$

Conventions typographiques

Convention importante :

- Les vecteurs sont notés en gras ($\mathbf{x}$) ou avec une flèche ($\vec{x}$) selon le contexte
- Les scalaires restent en notation standard (x)
- Les matrices utilisent des lettres majuscules (A, Σ)

Représentations alternatives pour images

Lecture en zig-zag

Une image $n \times m$ peut être lue en zig-zag pour former un vecteur de dimension $N = n \times m$:

$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_N \end{pmatrix}$$

Complexité : Pour une image moderne de taille 1000×1000 , on a $N = 1,000,000$ pixels. La distribution jointe décrit toutes les relations par paires, triplets, etc.

Lecture par lignes (matrice)

$$X = \begin{pmatrix} | & | & \cdots & | \\ x_1 & x_2 & \cdots & x_m \\ | & | & \cdots & | \end{pmatrix}$$

de dimension $n \times m$, où chaque colonne x_i représente une ligne de l'image.

Image comme colonne dans une base de données

$$X = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{pmatrix}$$

où chaque x_i représente une image entière, utilisé pour analyser une collection d'images.

Théorie des probabilités

Distributions de probabilité

Variables discrètes

Fonction de masse de probabilité (pmf)

Définition :

$$p_X(x) = \mathbb{P}[X = x]$$

La pmf donne la probabilité que la variable aléatoire X prenne exactement la valeur x .

Propriétés :

- $0 \leq p_X(x) \leq 1$ pour tout x
- $\sum_{x \in \mathcal{X}} p_X(x) = 1$

Exemple : Loi binomiale

La loi binomiale modélise le nombre de succès dans M essais indépendants :

$$X \sim B(M, p)$$

$$p_X(k) = \mathbb{P}[X = k] = \binom{M}{k} p^k (1-p)^{M-k}, \quad k = 0, 1, \dots, M$$

où : - M : nombre d'essais - p : probabilité de succès - k : nombre de succès observés

Variables continues

Fonction de densité de probabilité (pdf)

Définition :

$$f_X(x)$$

La pdf caractérise la distribution d'une variable continue.

Propriété fondamentale :

$$\int_{-\infty}^{+\infty} f_X(x) dx = 1$$

Probabilité d'un intervalle :

$$\mathbb{P}[a \leq X \leq b] = \int_a^b f_X(x) dx$$

Exemple : Loi normale (gaussienne)

La loi normale est l'une des distributions les plus importantes :

$$X \sim \mathcal{N}(\mu_X, \sigma_X^2)$$

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma_X^2}} \exp\left(-\frac{(x - \mu_X)^2}{2\sigma_X^2}\right)$$

où : - μ_X : moyenne (paramètre de position) - σ_X^2 : variance (paramètre de dispersion) - σ_X : écart-type

Fonction de répartition cumulative (CDF)

Définition :

$$F_X(x) = \mathbb{P}[X \leq x] = \begin{cases} \sum_{x_i \leq x} p_X(x_i) & \text{cas discret} \\ \int_{-\infty}^x f_X(t) dt & \text{cas continu} \end{cases}$$

Propriétés :

- $F_X(-\infty) = 0$ et $F_X(+\infty) = 1$
- F_X est monotone croissante
- Pour les variables continues : $f_X(x) = \frac{d}{dx} F_X(x)$

Distributions jointes et marginales

Distribution jointe

Pour vecteurs aléatoires :

Soit $X = (X_1, X_2, \dots, X_N)$ un vecteur aléatoire.

pmf jointe (cas discret) :

$$p_X(x) = p_X(x_1, x_2, \dots, x_N) = \mathbb{P}[X_1 = x_1, X_2 = x_2, \dots, X_N = x_N]$$

pdf jointe (cas continu) :

$$f_X(x) = f_X(x_1, x_2, \dots, x_N)$$

avec la propriété :

$$\int_{\mathbb{R}^N} f_X(x_1, \dots, x_N) dx_1 \cdots dx_N = 1$$

Distribution marginale

Obtenir une marginale à partir de la jointe :

Cas discret :

$$p_{X_1}(x_1) = \sum_{x_2, \dots, x_N} p_X(x_1, x_2, \dots, x_N)$$

Cas continu :

$$f_{X_1}(x_1) = \int_{\mathbb{R}^{N-1}} f_X(x_1, x_2, \dots, x_N) dx_2 \cdots dx_N$$

Règle de chaîne et décomposition

Règle de chaîne pour probabilités jointes

Distribution jointe complète :

$$p_X(x) = p(x_1, x_2, \dots, x_N)$$

Décomposition par règle de chaîne :

$$p(x_1, x_2, \dots, x_N) = p(x_1) \cdot p(x_2|x_1) \cdot p(x_3|x_2, x_1) \cdots p(x_N|x_{N-1}, \dots, x_2, x_1)$$

Forme générale :

$$p(x_1, x_2, \dots, x_N) = \prod_{i=1}^N p(x_i|x_{i-1}, \dots, x_2, x_1)$$

avec la convention $p(x_1|\emptyset) = p(x_1)$.

Cas particulier : deux variables

Pour deux variables aléatoires :

$$p(x_1, x_2) = p(x_1)p(x_2|x_1) = p(x_2)p(x_1|x_2)$$

Règle de Bayes

Dérivation à partir de la règle de chaîne :

$$p(x_2|x_1) = \frac{p(x_2)p(x_1|x_2)}{p(x_1)} = \frac{p(x_1, x_2)}{p(x_1)}$$

où $p(x_1) = \sum_{x_2} p(x_1, x_2)$ (cas discret) ou $p(x_1) = \int p(x_1, x_2)dx_2$ (cas continu).

Interprétation :

- $p(x_2)$: probabilité a priori
- $p(x_1|x_2)$: vraisemblance (likelihood)
- $p(x_2|x_1)$: probabilité a posteriori
- $p(x_1)$: évidence (constante de normalisation)

Indépendance statistique

Variables indépendantes

Définition :

Deux variables aléatoires X_1 et X_2 sont **indépendantes** (noté $X_1 \perp X_2$) si et seulement si :

$$p(x_1, x_2) = p(x_1) \cdot p(x_2)$$

Conséquences :

- $p(x_1|x_2) = p(x_1)$: connaître x_2 n'apporte aucune information sur x_1
- $p(x_2|x_1) = p(x_2)$: connaître x_1 n'apporte aucune information sur x_2

Généralisation à N variables

Variables indépendantes et identiquement distribuées (i.i.d.) :

$$p_X(x_1, x_2, \dots, x_N) = p_X(x_1) \cdot p_X(x_2) \cdots p_X(x_N) = \prod_{i=1}^N p_X(x_i)$$

Cas avec distributions différentes :

$$p(x_1, x_2, \dots, x_N) = \prod_{i=1}^N p_i(x_i)$$

où chaque X_i suit sa propre distribution p_i .

Application pratique

Simplification majeure :

Considérons un vecteur aléatoire :

$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_N \end{pmatrix} \quad \text{avec} \quad \begin{cases} X_1 \sim p(x_1) \\ X_2 \sim p(x_2) \\ \vdots \\ X_N \sim p(x_N) \end{cases}$$

Au lieu de modéliser $p_X(x_1, x_2, \dots, x_N)$ qui a une complexité exponentielle en N , on modélise seulement N distributions univariées indépendantes.

Avantage : Réduction drastique de la complexité computationnelle et du nombre de paramètres.

Indépendance conditionnelle

Définition

Les variables aléatoires X_1 et X_3 sont **conditionnellement indépendantes** étant donné X_2 (noté $X_1 \perp X_3 | X_2$) si :

$$p(x_1, x_3 | x_2) = p(x_1 | x_2) \cdot p(x_3 | x_2)$$

Interprétation :

Une fois que X_2 est connu, X_1 et X_3 n'apportent plus d'information l'un sur l'autre.

Décomposition avec règle de chaîne

Distribution jointe complète :


$$p(x_1, x_2, x_3) = p(x_2) \cdot p(x_1, x_3 | x_2)$$

Si $X_1 \perp X_3 | X_2$:

$$p(x_1, x_2, x_3) = p(x_2) \cdot p(x_1 | x_2) \cdot p(x_3 | x_2)$$

Représentation graphique

La structure d'indépendance conditionnelle peut être représentée par un graphe :



X_2 est un “parent” commun de X_1 et X_3 . Conditionnellement à X_2 , X_1 et X_3 deviennent indépendants.

Applications :

- Réseaux bayésiens
- Modèles graphiques probabilistes
- Simplification de distributions jointes complexes

Modèles de Markov

Modèle de Markov de 1er ordre

Hypothèse markovienne

La **propriété de Markov** stipule que la dépendance est limitée à **un élément du passé** :

$$p(x_i | x_{i-1}, x_{i-2}, \dots, x_1) \stackrel{\text{Markov 1}}{=} p(x_i | x_{i-1})$$

Interprétation :

L'état présent ne dépend que de l'état immédiatement précédent, pas de tout l'historique.

Distribution jointe sous Markov 1

Décomposition :

$$p(x_1, x_2, \dots, x_N) \stackrel{\text{Markov 1}}{=} p(x_1) \prod_{i=2}^N p(x_i | x_{i-1})$$

Simplification : La modélisation d'une pmf/pdf complexe est réduite à la définition de **distributions conditionnelles par paires**.

Avantages

- Réduction du nombre de paramètres de exponentiel à linéaire en N
- Calculs plus efficaces pour l'inférence
- Applicable aux séquences temporelles et spatiales

Modèle de Markov de 2ème ordre

Hypothèse markovienne d'ordre 2

La dépendance est limitée à **deux éléments du passé** :

$$p(x_i | x_{i-1}, x_{i-2}, \dots, x_1) \stackrel{\text{Markov 2}}{=} p(x_i | x_{i-1}, x_{i-2})$$

Distribution jointe sous Markov 2

Décomposition :

$$p(x_1, x_2, \dots, x_N) \stackrel{\text{Markov 2}}{=} p(x_1) \cdot p(x_2|x_1) \prod_{i=3}^N p(x_i|x_{i-1}, x_{i-2})$$

Compromis ordre vs complexité

- **Ordre 1** : Moins de paramètres, mais hypothèse forte
- **Ordre 2** : Plus de paramètres, mais capture mieux les dépendances
- **Ordre k** : Compromis à ajuster selon le problème

Application pratique : Traitement d'images

Modèle Markovien pour images

Représentation séquentielle d'une image :

$$X = \begin{pmatrix} \vdots \\ X_{i-2} \\ X_{i-1} \\ X_i \\ \vdots \end{pmatrix} \Rightarrow p(x_i|x_{i-1}, x_{i-2})$$

Chaque pixel X_i dépend conditionnellement des deux pixels précédents X_{i-1} et X_{i-2} (selon un ordre de parcours défini).

Applications pratiques

Domaines d'application :

- Modélisation de textures
- Compression d'images
- Génération d'images
- Débruitage et restauration
- Segmentation d'images

Exemple concret :

Pour une texture régulière, un modèle de Markov peut capturer les corrélations locales entre pixels voisins, permettant de générer de nouvelles textures similaires.

Moments et caractéristiques des distributions

Moments des distributions

Définitions générales

Les moments caractérisent la forme d'une distribution de probabilité.

Pour les variables discrètes

1er moment (espérance/moyenne) :

$$\mu_X = \mathbb{E}_{p_X(x)}[X] = \sum_{i=1}^M x_i p(x_i)$$

2ème moment centré (variance) :

$$\sigma_X^2 = \text{Var}[X] = \mathbb{E}_{p_X(x)}[(X - \mu_X)^2] = \sum_{i=1}^M (x_i - \mu_X)^2 p(x_i)$$

Moment d'ordre n :

$$m_n = \mathbb{E}[X^n] = \sum_{i=1}^M x_i^n p(x_i)$$

Pour les variables continues

1er moment (espérance/moyenne) :

$$\mu_X = \mathbb{E}_{f_X(x)}[X] = \int_{x \in \mathcal{X}} x f_X(x) dx$$

2ème moment centré (variance) :

$$\sigma_X^2 = \text{Var}[X] = \mathbb{E}_{f_X(x)}[(X - \mu_X)^2] = \int_{x \in \mathcal{X}} (x - \mu_X)^2 f_X(x) dx$$

Moment d'ordre n :

$$m_n = \mathbb{E}[X^n] = \int_{-\infty}^{+\infty} x^n f_X(x) dx$$

Moments d'ordre supérieur

3ème moment : Skewness (asymétrie)

Définition :

$$\text{Skewness} = \frac{\mathbb{E}[(X - \mu_X)^3]}{\sigma_X^3}$$

Interprétation :

- **Skewness** > 0 : Distribution asymétrique avec queue à droite (right-skewed)
- **Skewness** < 0 : Distribution asymétrique avec queue à gauche (left-skewed)
- **Skewness** $= 0$: Distribution symétrique (comme la loi normale)

4ème moment : Kurtosis (aplatissement)

Définition :

$$\text{Kurtosis} = \frac{\mathbb{E}[(X - \mu_X)^4]}{\sigma_X^4}$$

Interprétation :

- **Kurtosis** > 3 : Queues épaisses (leptokurtique), plus de valeurs extrêmes
- **Kurtosis** $= 3$: Distribution normale (mesokurtique)
- **Kurtosis** < 3 : Queues fines (platykurtique), moins de valeurs extrêmes

Note : On utilise parfois l'excess kurtosis = Kurtosis - 3 pour comparer à la loi normale.

Interprétation intuitive des moments

Moyenne (μ_X) :

- Centre de gravité de la distribution
- Valeur “typique” ou “attendue”

Variance (σ_X^2) et écart-type (σ_X) :

- Mesure de dispersion autour de la moyenne
- Quantifie l'incertitude ou la variabilité

Skewness :

- Mesure de l'asymétrie
- Indique si la distribution est déséquilibrée

Kurtosis :

- Mesure de l'épaisseur des queues
- Indique la probabilité d'observer des valeurs extrêmes

Principe général : Étant donnée une pmf/pdf, on peut calculer les moments (bien que certaines distributions n'aient pas tous les moments définis).

Fonction caractéristique

Définitions

Fonction caractéristique d'une pdf

Définition :

$$\Phi(t) = \int_{-\infty}^{+\infty} f(x)e^{jtx} dx = \mathbb{E}_{f(x)}[e^{jtX}]$$

où $j = \sqrt{-1}$ est l'unité imaginaire.

Propriétés :

- $\Phi(0) = 1$
- $|\Phi(t)| \leq 1$ pour tout t
- $\Phi(-t) = \overline{\Phi(t)}$ (conjugué complexe)

Fonction génératrice des moments

Définition :

$$M(t) = \mathbb{E}_{f(x)}[e^{tX}] = \int_{-\infty}^{+\infty} f(x)e^{tx} dx$$

Relation avec la fonction caractéristique :

$$M(t) = \Phi(-jt)$$

Récupération de la pdf

La pdf peut être récupérée par **transformée de Fourier inverse** :

$$f(x) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} \Phi(t) e^{-jtx} dt$$

Théorème :

La fonction caractéristique détermine uniquement la distribution.

Développement en série de Taylor

Pour la fonction caractéristique

Développement :

$$\begin{aligned} \Phi(t) &= \mathbb{E}_{f(x)}[\exp(jtX)] = \sum_{n=0}^{\infty} \frac{(jt)^n}{n!} \mathbb{E}[X^n] \\ &= 1 + jt\mathbb{E}[X] - \frac{t^2}{2!}\mathbb{E}[X^2] - j\frac{t^3}{3!}\mathbb{E}[X^3] + \frac{t^4}{4!}\mathbb{E}[X^4] + \dots \end{aligned}$$

Pour la fonction génératrice

Développement :

$$\begin{aligned} M(t) &= \mathbb{E}_{f(x)}[\exp(tX)] = \sum_{n=0}^{\infty} \frac{t^n}{n!} \mathbb{E}[X^n] \\ &= 1 + t\mathbb{E}[X] + \frac{t^2}{2!}\mathbb{E}[X^2] + \frac{t^3}{3!}\mathbb{E}[X^3] + \frac{t^4}{4!}\mathbb{E}[X^4] + \dots \end{aligned}$$

Rappel :

$$\exp(tX) = \sum_{n=0}^{\infty} \frac{(tX)^n}{n!} = 1 + tX + \frac{(tX)^2}{2!} + \frac{(tX)^3}{3!} + \dots$$

Calcul des moments à partir de la fonction génératrice

Propriété fondamentale :

$$\mathbb{E}[X^n] = \left. \frac{d^n M(t)}{dt^n} \right|_{t=0} = M^{(n)}(0)$$

ou pour la fonction caractéristique :

$$\mathbb{E}[X^n] = \frac{1}{j^n} \left. \frac{d^n \Phi(t)}{dt^n} \right|_{t=0}$$

Point clé : Les quatre premiers moments définissent respectivement la moyenne, variance, skewness et kurtosis de la pdf $f(x)$.

Estimation empirique des moments

Moments empiriques de la pdf

Données disponibles

Hypothèse :

Séquence i.i.d. $x = (x_1, \dots, x_N)$ tirée de $f(x)$.

Estimation du n-ième moment empirique

Formule :

$$\hat{m}_n = \frac{1}{N} \sum_{i=1}^N x_i^n, \quad n \geq 1$$

Cas particuliers :

- $n = 1$: $\hat{m}_1 = \bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$ (moyenne empirique)
- $n = 2$: $\hat{m}_2 = \frac{1}{N} \sum_{i=1}^N x_i^2$ (moment d'ordre 2 empirique)

Moments théoriques correspondants

Moment théorique d'ordre n :

$$m_n = \mathbb{E}[X^n] = \int_{-\infty}^{+\infty} f(x)x^n dx$$

Variance empirique

Formule biaisée :

$$\hat{\sigma}_{\text{biaisé}}^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$$

Formule non biaisée (correction de Bessel) :

$$\hat{\sigma}^2 = \frac{1}{N-1} \sum_{i=1}^N (x_i - \bar{x})^2$$

Propriétés statistiques

$\hat{m}_n$ est une **estimation non biaisée** des vrais moments de la pdf :

$$\mathbb{E}[\hat{m}_n] = m_n$$

Convergence :

Par la loi des grands nombres, $\hat{m}_n \xrightarrow{N \rightarrow \infty} m_n$ presque sûrement.

Moments de la fonction caractéristique (CDF)

Définition des moments de la fonction caractéristique

Moment d'ordre n de la fonction caractéristique :

$$M_n = \int_{-\infty}^{+\infty} \Phi(t)t^n dt$$

Lien avec la pdf

Relation fondamentale :

$$M_n = j^n 2\pi \frac{d^n f(x)}{dx^n} \Big|_{x=0}$$

Cette relation relie les moments de la fonction caractéristique aux dérivées de la pdf évaluées à l'origine.

Estimation empirique des moments de la fonction caractéristique

Pipeline d'estimation

Étape 1 : Estimation de l'histogramme empirique

Calculer l'histogramme à M bins : $\{h(m)\}_{m=0}^{M-1}$

$$h(m) = \frac{\text{nombre d'observations dans le bin } m}{N}$$

Étape 2 : Estimation de la fonction caractéristique

Estimer $\Phi(k)$ à K points avec $K = 2^{\lceil \log_2 M \rceil}$ (puissance de 2 pour FFT) :

$$\Phi(k) = \sum_{m=0}^{M-1} h(m) \exp \left\{ -j \frac{2\pi m k}{K} \right\}, \quad k = 0, \dots, K-1$$

Cette opération correspond à une **transformée de Fourier discrète (DFT)**.

Étape 3 : Reconstruction par transformée inverse

Calcul inverse par **transformée de Fourier inverse (IDFT)** :

$$h(m) = \frac{1}{K} \sum_{k=0}^{K-1} \Phi(k) \exp \left\{ j \frac{2\pi m k}{K} \right\}, \quad m = 0, \dots, M-1$$

Étape 4 : Calcul des moments empiriques

Formule principale :

$$\hat{M}'_n = \sum_{k=0}^{K/2-1} |\Phi(k)| k^n$$

Forme alternative (borne supérieure) :

$$\hat{M}_n = \sum_{k=0}^{K-1} \Phi(k) \sin^n \left(\frac{2\pi k}{K} \right)$$

Notes importantes

Bidirectionnalité : La transformée de Fourier fonctionne dans les deux sens (pdf → fonction caractéristique), permettant de passer d'un domaine à l'autre.

Utilisation de la FFT :

Pour $K = 2^m$, on peut utiliser la **Fast Fourier Transform (FFT)** qui réduit la complexité de $O(K^2)$ à $O(K \log K)$.

Propriétés de la variance et covariance

Propriétés fondamentales de la variance

Soit X et Y des variables aléatoires, a, b, c des constantes.

Décomposition de la variance

Formule de décomposition :

$$\text{Var}[X] = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

Preuve :

$$\text{Var}[X] = \mathbb{E}[(X - \mu_X)^2] \tag{1}$$

$$= \mathbb{E}[X^2 - 2X\mu_X + \mu_X^2] \tag{2}$$

$$= \mathbb{E}[X^2] - 2\mu_X \mathbb{E}[X] + \mu_X^2 \tag{3}$$

$$= \mathbb{E}[X^2] - 2\mu_X^2 + \mu_X^2 \tag{4}$$

$$= \mathbb{E}[X^2] - \mu_X^2 \tag{5}$$

Bornes

Positivité :

$$0 \leq \text{Var}[X] \leq \mathbb{E}[X^2]$$

Cas limite :

- $\text{Var}[X] = 0$ si et seulement si X est constante presque sûrement
- $\text{Var}[X] = \mathbb{E}[X^2]$ si et seulement si $\mathbb{E}[X] = 0$

Variance d'un multiple

Propriété de scaling :

$$\text{Var}[cX] = c^2 \text{Var}[X]$$

Interprétation :

Multiplier une variable par c multiplie son écart-type par $|c|$ et sa variance par c^2 .

Variance d'une translation

Invariance par translation :

$$\text{Var}[X + c] = \text{Var}[X]$$

La variance ne dépend pas du niveau moyen, seulement de la dispersion.

Variance d'une combinaison linéaire

Formule générale :

$$\text{Var}[aX + bY] = a^2 \text{Var}[X] + 2ab \text{Cov}[X, Y] + b^2 \text{Var}[Y]$$

Cas particulier (variables indépendantes) :

Si $X \perp Y$, alors $\text{Cov}[X, Y] = 0$ et :

$$\text{Var}[aX + bY] = a^2 \text{Var}[X] + b^2 \text{Var}[Y]$$

Covariance

Définition

Covariance entre deux variables :

$$\text{Cov}[X, Y] = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)]$$

Forme développée pour variables discrètes

Calcul explicite :

$$\text{Cov}[X, Y] = \sum_{(x,y) \in \mathcal{S}_{X,Y}} p(x,y)(x - \mu_X)(y - \mu_Y)$$

où $\mathcal{S}_{X,Y}$ est l'espace des valeurs possibles de (X, Y) .

Forme alternative

Formule simplifiée :

$$\text{Cov}[X, Y] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = \mathbb{E}[XY] - \mu_X\mu_Y$$

Notation :

$$\sigma_{XY} = \text{Cov}[X, Y]$$

Propriétés de la covariance

Symétrie :

$$\text{Cov}[X, Y] = \text{Cov}[Y, X]$$

Bilinéarité :

$$\text{Cov}[aX + bY, Z] = a\text{Cov}[X, Z] + b\text{Cov}[Y, Z]$$

Covariance et indépendance :

Si $X \perp Y$, alors $\text{Cov}[X, Y] = 0$

Attention : La réciproque est fausse ! $\text{Cov}[X, Y] = 0$ n'implique pas nécessairement $X \perp Y$ (sauf pour des lois gaussiennes).

Coefficient de corrélation

Définition :

$$\rho_{XY} = \frac{\text{Cov}[X, Y]}{\sigma_X \sigma_Y} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$

Propriétés :

- $-1 \leq \rho_{XY} \leq 1$
- $|\rho_{XY}| = 1$ si et seulement si $Y = aX + b$ (relation linéaire parfaite)
- $\rho_{XY} = 0$ indique une absence de corrélation linéaire (mais pas nécessairement d'indépendance)

Applications des moments

Analyse d'images

Pipeline de traitement

Transformation par ondelettes (DWT) :

Image $\rightarrow$ DWT $\rightarrow$ Coefficients d'ondelettes $\rightarrow$ Calcul des moments (pdf/CDF)

La transformée en ondelettes discrète (DWT) décompose l'image en différentes échelles et orientations, capturant des informations multi-résolution.

Applications pratiques

Détection d'outliers :

- Identifier des images anormales par analyse des moments statistiques
- Les moments capturent des propriétés globales de la distribution des coefficients
- Une image atypique aura des moments significativement différents

Détection de fausses images (Fake detection) :

- Distinguer images authentiques vs manipulées
- Les manipulations (montages, retouches) modifient subtilement les propriétés statistiques

- Analyse des moments d'ordres supérieurs (skewness, kurtosis) particulièrement sensible

Stéganalyse :

- Détecter des messages secrets cachés dans les images (stéganographie)
- L'insertion de données modifie les statistiques naturelles de l'image
- Comparaison des moments avant/après pour détecter les anomalies

Principe général : Les moments statistiques capturent des propriétés fines de la distribution qui changent de manière caractéristique en cas de manipulation, compression, ou insertion de données cachées.

Exemple de pipeline complet

1. **Prétraitement :** Convertir l'image en niveaux de gris si nécessaire
2. **Transformation :** Appliquer la DWT (ex: Haar, Daubechies)
3. **Extraction :** Calculer les moments des sous-bandes d'ondelettes
4. **Caractérisation :** Former un vecteur de features basé sur les moments
5. **Classification :** Utiliser ces features pour la détection ou classification

Algèbre linéaire pour la Data Science

Normes vectorielles

Norme L_p générale

Définition :

$$\|x\|_p = \left(\sum_{i=1}^N |x_i|^p \right)^{1/p}, \quad p \geq 1$$

Propriétés d'une norme :

1. **Positivité :** $\|x\|_p \geq 0$ avec égalité ssi $x = 0$
2. **Homogénéité :** $\|\alpha x\|_p = |\alpha| \|x\|_p$
3. **Inégalité triangulaire :** $\|x + y\|_p \leq \|x\|_p + \|y\|_p$

Normes particulières

Norme L_1 (Manhattan)

Définition :

$$\|x\|_1 = \sum_{i=1}^N |x_i| = |x_1| + |x_2| + \dots + |x_N|$$

Interprétation géométrique :

Distance de Manhattan ou “taxi” : somme des déplacements le long de chaque axe.

Applications :

- Parcimonie (sparsity) en apprentissage automatique
- Régularisation LASSO
- Robustesse aux outliers

Norme L_2 (Euclidienne)

Définition :

$$\|x\|_2 = \sqrt{\sum_{i=1}^N x_i^2} = \sqrt{x_1^2 + x_2^2 + \dots + x_N^2}$$

Forme matricielle :

$$\|x\|_2 = \sqrt{x^T x}$$

Interprétation géométrique :

Longueur géométrique standard dans l’espace euclidien.

Applications :

- Distance standard en machine learning
- Régularisation Ridge
- Minimisation des moindres carrés

Norme L_∞ (Maximum)

Définition :

$$\|x\|_\infty = \max_{1 \leq i \leq N} |x_i| = \max\{|x_1|, |x_2|, \dots, |x_N|\}$$

Interprétation :

Composante de plus grande magnitude.

Limite :

$$\lim_{p \rightarrow \infty} \|x\|_p = \|x\|_\infty$$

Applications :

- Analyse de pire cas (worst-case analysis)
- Contrôle de systèmes
- Optimisation robuste

Normalisation (norme unitaire)

Vecteur normalisé :

$$\hat{x} = \frac{x}{\|x\|_2}$$

Propriété :

$$\|\hat{x}\|_2 = 1$$

Donne un vecteur de longueur 1 dans la même direction que x .

Applications :

- Normalisation de features en machine learning
- Calcul de similarité cosinus
- Représentation de directions

Distances et mesures de similarité

Distance euclidienne (L_2)

Définition :

$$d_2(x, y) = \|x - y\|_2 = \sqrt{\sum_{i=1}^N (x_i - y_i)^2}$$

Distance au carré :

$$d_2^2(x, y) = \sum_{i=1}^N (x_i - y_i)^2 = (x - y)^T (x - y)$$

Propriétés :

- Distance métrique : $d(x, y) \geq 0$, $d(x, x) = 0$, $d(x, y) = d(y, x)$
- Inégalité triangulaire : $d(x, z) \leq d(x, y) + d(y, z)$

Applications :

- k-NN (k plus proches voisins)
- K-means clustering
- Mesure de similarité standard

Distance L_1 (Manhattan)

Définition :

$$d_1(x, y) = \|x - y\|_1 = \sum_{i=1}^N |x_i - y_i|$$

Comparaison avec L_2 :

- Plus robuste aux outliers
- Favorise la parcimonie
- Calcul plus simple (pas de racine carrée)

Applications :

- Régression robuste
- Traitement d'images (Total Variation)
- Compressed sensing

Distance de Hamming

Définition :

$$d_H(x, y) = \sum_{i=1}^N \mathbb{1}\{x_i \neq y_i\}$$

où la fonction indicatrice est :

$$\mathbb{1}\{x_i, y_i\} = \begin{cases} 0 & \text{si } x_i = y_i \\ 1 & \text{si } x_i \neq y_i \end{cases}$$

Forme alternative (pour vecteurs binaires) :

$$d_H(x, y) = \|x \oplus y\|_1$$

où $\oplus$ est l'opération XOR bit-à-bit.

Applications :

- Théorie de l'information et codage
- Correction d'erreurs
- Hashing et recherche approximative
- Bioinformatique (comparaison de séquences)

Distance attendue pour vecteurs aléatoires

Définition :

Pour deux vecteurs aléatoires X et Y avec pdf $f(x, y)$:

$$D = \mathbb{E}_{f(x, y)}[d(X, Y)]$$

où

$$d(X, Y) = \frac{1}{N} \sum_{i=1}^N d(X_i, Y_i)$$

Interprétation :

Distance moyenne entre deux réalisations aléatoires selon la distribution jointe.

Applications :

- Théorie de l'information
- Analyse de canaux bruités
- Mesure de distorsion en compression

Interprétation géométrique

Distance entre vecteurs

Cas des images

Pour une image représentée comme vecteur :

$$x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{pmatrix}$$

Distance euclidienne entre deux images :

$$d_2(x_1, x_2) = \|x_1 - x_2\|_2 = \sqrt{\sum_{i=1}^N (x_{1i} - x_{2i})^2}$$

représente la longueur du vecteur différence $x_1 - x_2$ dans l'espace $\mathbb{R}^N$.

Proximité perceptuelle

Images perceptuellement proches :

$$\|x_1 - x_2\|_2 \text{ petit} \quad \Rightarrow \quad \text{Images visuellement similaires}$$

Images perceptuellement différentes :

$$\|x_1 - x_2\|_2 \text{ grand} \quad \Rightarrow \quad \text{Images visuellement différentes}$$

Limitation importante : La distance euclidienne ne capture pas toujours fidèlement la similarité perceptuelle humaine. Des métriques plus sophistiquées (SSIM, perceptual loss) sont souvent nécessaires.

Exemple :

Une translation d'une image d'un pixel peut donner une grande distance L_2 mais les images sont perceptuellement identiques.

Produit scalaire et projections

Lien entre distance et produit scalaire

Décomposition de la distance au carré

Formule fondamentale :

$$\|x_1 - x_2\|_2^2 = \|x_1\|_2^2 - 2x_1^T x_2 + \|x_2\|_2^2$$

Preuve :

$$\|x_1 - x_2\|_2^2 = (x_1 - x_2)^T (x_1 - x_2) \quad (6)$$

$$= x_1^T x_1 - x_1^T x_2 - x_2^T x_1 + x_2^T x_2 \quad (7)$$

$$= \|x_1\|_2^2 - 2x_1^T x_2 + \|x_2\|_2^2 \quad (8)$$

Produit scalaire (inner product)

Définition :

$$x^T y = y^T x = \sum_{i=1}^n x_i y_i \in \mathbb{R}$$

Forme matricielle :

$$x^T y = \begin{pmatrix} x_1 & x_2 & \cdots & x_n \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

Propriétés :

- Commutativité : $x^T y = y^T x$
- Bilinéarité : $(ax_1 + bx_2)^T y = ax_1^T y + bx_2^T y$
- Positivité : $x^T x \geq 0$ avec égalité ssi $x = 0$

Relation inverse

Distance petite Produit scalaire grand :

$$\|x_1 - x_2\|_2 \text{ petit} \quad \Rightarrow \quad x_1^T x_2 \text{ grand}$$

(pour des vecteurs de norme comparable)

Distance grande Produit scalaire petit :

$$\|x_1 - x_2\|_2 \text{ grand} \quad \Rightarrow \quad x_1^T x_2 \text{ petit}$$

Interprétation géométrique : Plus deux vecteurs pointent dans la même direction, plus leur produit scalaire est grand et leur distance est petite.

Similarité cosinus

Définition géométrique

Angle entre deux vecteurs :

$$x_1^T x_2 = \|x_1\|_2 \|x_2\|_2 \cos \theta$$

où θ est l'angle entre x_1 et x_2 .

Similarité cosinus :

$$\cos \theta = \frac{x_1^T x_2}{\|x_1\|_2 \|x_2\|_2}$$

Plage de valeurs :

- $\cos \theta = 1$: vecteurs colinéaires de même sens ($\theta = 0^\circ$)
- $\cos \theta = 0$: vecteurs orthogonaux ($\theta = 90^\circ$)
- $\cos \theta = -1$: vecteurs colinéaires de sens opposé ($\theta = 180^\circ$)

Avantage :

Invariant à la magnitude des vecteurs, mesure uniquement l'orientation.

Applications :

- Recherche de documents similaires
- Systèmes de recommandation
- Comparaison de features normalisées

Projection sur un vecteur unitaire

Vecteur unitaire (direction) :

$$\hat{x}_2 = \frac{x_2}{\|x_2\|_2}$$

avec $\|\hat{x}_2\|_2 = 1$.

Projection de x_1 sur $\hat{x}_2$:

$$\text{proj}_{\hat{x}_2}(x_1) = (x_1^T \hat{x}_2) \hat{x}_2$$

Longueur de la projection (composante scalaire) :

$$\|x_1\|_2 \cos \theta = x_1^T \hat{x}_2 = \frac{x_1^T x_2}{\|x_2\|_2}$$

Interprétation :

La projection mesure “combien” de x_1 est dans la direction de x_2 .

Applications :

- Décomposition de vecteurs
- PCA (composantes principales)
- Régression linéaire

Vecteurs orthogonaux et colinéaires

Vecteurs orthogonaux

Condition d'orthogonalité

Définition ($\theta = 90^\circ$) :

$$x_1 \perp x_2 \quad \Leftrightarrow \quad x_1^T x_2 = 0$$

Vérification géométrique :

$$x_1^T x_2 = \|x_1\|_2 \|x_2\|_2 \cos(90^\circ) = 0$$

Distance entre vecteurs orthogonaux

Théorème de Pythagore :

$$\|x_1 - x_2\|_2^2 = \|x_1\|_2^2 + \|x_2\|_2^2 - 2x_1^T x_2 = \|x_1\|_2^2 + \|x_2\|_2^2$$

Interprétation :

Pour des vecteurs orthogonaux, la distance au carré est simplement la somme des carrés des normes.

Systèmes orthogonaux

Base orthogonale :

Un ensemble de vecteurs $\{v_1, \dots, v_k\}$ est orthogonal si $v_i^T v_j = 0$ pour $i \neq j$.

Base orthonormale :

Orthogonale avec $\|v_i\|_2 = 1$ pour tout i .

Avantages :

- Simplification des calculs
- Indépendance des composantes
- Stabilité numérique

Vecteurs colinéaires

Condition de colinéarité

Définition ($\theta = 0^\circ$ ou 180°) :

Deux vecteurs sont colinéaires s'il existe $\lambda \in \mathbb{R}$ tel que :

$$x_1 = \lambda x_2$$

Même direction ($\theta = 0^\circ$) :

$$x_1^T x_2 = \|x_1\|_2 \|x_2\|_2 \cos(0^\circ) = \|x_1\|_2 \|x_2\|_2$$

C'est le produit scalaire maximal possible (pour des normes données).

Directions opposées ($\theta = 180^\circ$) :

$$x_1^T x_2 = -\|x_1\|_2 \|x_2\|_2$$

Cas de vecteurs identiques

Si de plus $\|x_1\|_2 = \|x_2\|_2$ et même direction :

$$\|x_1 - x_2\|_2^2 = \|x_1\|_2^2 + \|x_2\|_2^2 - 2\|x_1\|_2 \|x_2\|_2 = 2\|x_1\|_2^2 - 2\|x_1\|_2^2 = 0$$

$$\Rightarrow x_1 = x_2$$

Interprétation :

La distance est nulle si et seulement si les vecteurs sont identiques.

Extraction et traitement de caractéristiques

Principe général de l'extraction de features

Objectif

But :

Extraire des descripteurs/empreintes caractéristiques à partir de données brutes (images, textes, signaux) ayant une distribution $p_X(x)$.

Transformation :

$$\text{Données brutes } X \in \mathbb{R}^N \xrightarrow{\text{Feature Extraction}} \text{Features } Z \in \mathbb{R}^d$$

généralement avec $d \ll N$ (réduction de dimensionnalité).

Objectifs de l'extraction de features

1. **Réduction de dimensionnalité** : Passer de N à d dimensions avec $d \ll N$
2. **Invariance** : Features robustes aux transformations (rotation, translation, échelle)
3. **Discriminativité** : Maximiser la séparation entre classes
4. **Efficacité computationnelle** : Calcul rapide pour applications temps-réel

Types d'approches

Features hand-crafted (faites à la main)

Caractéristiques :

- Conçues manuellement par des experts du domaine
- Basées sur des principes physiques ou statistiques
- Optimisées pour des contraintes strictes de complexité/mémoire
- Interprétables et analysables

Exemples de descripteurs :

- **SIFT (Scale-Invariant Feature Transform)** : Descripteurs de points d'intérêt invariants à l'échelle
- **SURF (Speeded-Up Robust Features)** : Version accélérée de SIFT
- **HOG (Histogram of Oriented Gradients)** : Histogrammes de gradients orientés
- **LBP (Local Binary Patterns)** : Patterns binaires locaux pour textures
- **Moments statistiques** : Moyenne, variance, skewness, kurtosis
- **Filtres de Gabor** : Réponses à des filtres multi-échelles et multi-orientations

Avantages :

- Faible coût computationnel
- Interprétabilité
- Pas besoin de données d'entraînement

Inconvénients :

- Performance limitée sur des tâches complexes
- Nécessite une expertise du domaine
- Difficile à adapter à de nouveaux problèmes

Features learned (appries)

Caractéristiques :

- Appries automatiquement à partir des données
- End-to-end learning (bout-en-bout)
- Optimisées pour la tâche spécifique

Exemples de méthodes :

- **Features de CNNs** : Convolutions appries sur des images
- **Embeddings** : Représentations vectorielles denses (Word2Vec, BERT)
- **Autoencodeurs** : Features du bottleneck

- **Réseaux siamois** : Features pour similarité

Avantages :

- Performance état-de-l'art sur tâches complexes
- Adaptation automatique au problème
- Capture de patterns complexes et non-linéaires

Inconvénients :

- Besoin de grandes quantités de données
- Coût computationnel élevé (entraînement et inférence)
- Difficile à interpréter (“boîte noire”)
- Risque de sur-apprentissage

Techniques clés

PCA (Principal Component Analysis)

Objectif :

Trouver les directions de variance maximale dans les données.

Principe :

1. Centrer les données : $X_c = X - \bar{X}$
2. Calculer la matrice de covariance : $C = \frac{1}{N} X_c^T X_c$
3. Décomposition en valeurs propres : $C = V \Lambda V^T$
4. Projeter sur les k premiers vecteurs propres

Features PCA :

$$Z = X_c V_k$$

où V_k contient les k premiers vecteurs propres.

Applications :

- Réduction de dimensionnalité
- Visualisation de données haute dimension
- Débruitage
- Compression

ICA (Independent Component Analysis)

Objectif :

Trouver des composantes statistiquement indépendantes.

Différence avec PCA :

- PCA : décorrélation (indépendance du second ordre)
- ICA : indépendance statistique complète

Applications :

- Séparation de sources (cocktail party problem)
- Traitement de signaux biomédicaux (EEG, fMRI)
- Analyse d'images

Transformées de décorrélation

DCT (Discrete Cosine Transform)

Principe :

Décomposition en somme de cosinus de différentes fréquences.

Applications :

- Compression JPEG
- Traitement audio
- Extraction de features spectrales

DWT (Discrete Wavelet Transform)

Principe :

Décomposition multi-résolution temps-fréquence.

Applications :

- Compression d'images (JPEG2000)
- Débruitage
- Détection de contours
- Extraction de features multi-échelles

Avantages :

- Capture des informations à différentes échelles

- Localisation temps-fréquence
- Parcimonie (sparsity) naturelle

Quantification vectorielle (k-means)

Principe :

Partitionner l'espace des features en k clusters et représenter chaque point par le centre de son cluster.

Algorithme k-means :

1. Initialiser k centres aléatoirement
2. **E-step** : Assigner chaque point au centre le plus proche
3. **M-step** : Mettre à jour les centres (moyenne de chaque cluster)
4. Répéter jusqu'à convergence

Applications en feature extraction :

- Création de vocabulaires visuels (Bag of Visual Words)
- Compression de features
- Clustering de features pour analyse

Bag of Visual Words :

1. Extraire des features locales (SIFT, SURF)
2. Quantifier avec k-means $\rightarrow$ vocabulaire visuel
3. Représenter chaque image par histogramme de mots visuels

Fouille de données (Information Mining)

Problématique

Objectif principal

L'élément ou caractéristique commune est **inconnu** a priori et doit être **découvert** dans la collection ou base de données.

Différence avec classification :

- **Classification** : Les classes sont connues, on assigne des labels
- **Mining** : On découvre les patterns, structures, ou groupes cachés

Challenges

- Grandes quantités de données (Big Data)
- Haute dimensionnalité
- Bruit et données manquantes
- Patterns complexes et non-linéaires
- Interprétabilité des résultats

Applications

Images et Multimédia

Objectif :

Découvrir des patterns visuels récurrents, styles, ou catégories naturelles dans des collections d'images.

Exemples :

- Détection automatique de styles artistiques
- Identification de scènes typiques (plage