

Table of contents

Fondamentaux de la Théorie de l'Information pour la Data Science	2
Introduction et Contexte	2
Vue d'ensemble	2
Applications en Data Science	2
Notations et Conventions	2
Fondements Probabilistes	3
Rappel : Espérance mathématique	3
Règle de Chaîne pour les Probabilités	4
Exemples de Décompositions	5
Entropie : Mesure de l'Incertainité	6
Entropie Discrète	6
Cas Binaire : Variable de Bernoulli	7
Entropies Multivariées	9
Propriétés Fondamentales de l'Entropie	10
Application aux Vecteurs d'Images	15
Applications au Codage et à la Compression	16
Concepts Fondamentaux du Codage	16
Assignation Optimale de Codes	17
Codage de Huffman	19
Codes Préfixes	23
Exemple Complet : Image à 8 Niveaux	25
Complexité et Limitations	26
Mesures de Divergence et Similarité	28
Divergence de Kullback-Leibler (KL)	28
Exemple Numérique de KL Divergence	32
Cross-Entropy (Entropie Croisée)	33
Information Mutuelle	36
Définitions et Formulations	36
Propriétés Fondamentales	37
Relations avec l'Entropie	38
Information Mutuelle Conditionnelle	39
Règle de Chaîne pour l'Information Mutuelle	41
Décompositions Complexes	43
Inégalité de Traitement des Données (Data Processing Inequality)	43
Variables Continues : Entropie Différentielle	46
Motivation et Limite	46
Définition de l'Entropie Différentielle	48
Entropie Différentielle d'une Gaussienne	49
Propriétés de l'Entropie Différentielle	51

Applications en Machine Learning	54
Fonctions de Perte	54
Sélection de Features	55
Régularisation et Variational Autoencoders	57
Aide-Mémoire et Synthèse	58
Formules Essentielles	58
Propriétés Clés à Retenir	61
Questions Types d'Examen	62
Tableaux Récapitulatifs	64
Cas Particuliers Importants	65
Conseils pour l'Examen	66
Ressources et Approfondissements	67

Fondamentaux de la Théorie de l'Information pour la Data Science

Introduction et Contexte

Vue d'ensemble

La **théorie de l'information**, développée par Claude Shannon en 1948, fournit un cadre mathématique rigoureux pour quantifier l'information, l'incertitude et la dépendance entre variables aléatoires.

Applications en Data Science

Les concepts de la théorie de l'information sont fondamentaux dans de nombreux domaines :

- **Compression de données** : optimisation du stockage et de la transmission
- **Apprentissage automatique** : fonctions de perte, régularisation
- **Sélection de features** : identification des variables les plus informatives
- **Mesure de similarité** : comparaison entre distributions
- **Optimisation de réseaux de neurones** : théorie de l'information bottleneck
- **Théorie de la communication** : capacité de canal, codage

Notations et Conventions

Variables et ensembles

- X, Y, Z : variables aléatoires (majuscules)
- x, y, z : valeurs prises par les variables (minuscules)

- $\mathcal{X}, \mathcal{Y}, \mathcal{Z}$: ensembles de valeurs possibles
- $|\mathcal{X}|$: cardinalité de l'ensemble $\mathcal{X}$

Distributions de probabilité

- $p_X(x)$ ou $p(x)$: fonction de masse de probabilité (pmf) ou densité (pdf)
- $p_{X,Y}(x,y)$ ou $p(x,y)$: distribution jointe
- $p_{X|Y}(x|y)$ ou $p(x|y)$: distribution conditionnelle
- $\mathbb{P}[X = x]$: probabilité que X prenne la valeur x
- $\mathbb{E}_p[f(X)]$: espérance de $f(X)$ sous la distribution p

Symboles spéciaux

- $X \perp Y$: X et Y sont indépendants
- $X \perp Z|Y$: X et Z sont conditionnellement indépendants sachant Y
- $X \rightarrow Y \rightarrow Z$: chaîne de Markov
- $\log$: logarithme (base 2 sauf indication contraire)
- $\ln$: logarithme naturel (base e)

Unités de mesure

- **Bits** : logarithme en base 2 ($\log_2$)
- **Nats** : logarithme naturel ($\ln$ ou $\log_e$)
- Notation parfois utilisée : $H_\alpha(X)$ où α spécifie la base

Fondements Probabilistes

Rappel : Espérance mathématique

Définition générale

Pour une variable aléatoire discrète X et une fonction g :

$$\mathbb{E}_{p_X}[g(X)] = \sum_{x \in \mathcal{X}} p_X(x)g(x)$$

Pour une variable continue :

$$\mathbb{E}_{f_X}[g(X)] = \int_{\mathcal{X}} f_X(x)g(x)dx$$

Propriétés

- Linéarité : $\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$
- Pour variables indépendantes : $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$

Règle de Chaîne pour les Probabilités

Cas général : N variables

Pour N variables aléatoires $X_1, X_2, \dots, X_n$:

$$p(x_1, x_2, \dots, x_n) = p(x_1) \cdot p(x_2|x_1) \cdot p(x_3|x_2, x_1) \cdots p(x_n|x_{n-1}, \dots, x_1)$$

Forme compacte :

$$p(x_1, x_2, \dots, x_n) = \prod_{i=1}^n p(x_i|x_{i-1}, \dots, x_1)$$

avec la convention que $p(x_1|\emptyset) = p(x_1)$.

Cas particulier : 2 variables

$$p(x_1, x_2) = p(x_1)p(x_2|x_1) = p(x_2)p(x_1|x_2)$$

Cette égalité illustre la symétrie de la règle de chaîne.

Variables indépendantes

Définition de l'indépendance

Deux variables X_1 et X_2 sont **indépendantes**, noté $X_1 \perp X_2$, si et seulement si :

$$p(x_1, x_2) = p(x_1) \cdot p(x_2)$$

Conséquence

Pour des variables indépendantes :

$$p(x_2|x_1) = p(x_2) \quad \text{et} \quad p(x_1|x_2) = p(x_1)$$

Généralisation à N variables i.i.d.

Pour N variables **identiquement et indépendamment distribuées** (i.i.d.) :

$$p(x_1, x_2, \dots, x_n) = \prod_{i=1}^n p(x_i) = [p(x)]^n$$

Exemples de Décompositions

Trois variables : différentes structures

Chaîne linéaire




$$p(x, y, z) = p(x) \cdot p(y|x) \cdot p(z|y, x)$$

Si $X \rightarrow Y \rightarrow Z$ forme une chaîne de Markov : $p(z|y, x) = p(z|y)$

Indépendance complète

$$p(x, y, z) = p(x) \cdot p(y) \cdot p(z)$$

Indépendance conditionnelle (parent commun)



$$p(x, y, z) = p(y) \cdot p(x|y) \cdot p(z|y)$$

Si $X \perp Z|Y$: X et Z sont conditionnellement indépendants sachant Y

Autres structures

Décomposition alternative 1 :

$$p(x, y, z) = p(z) \cdot p(y|z) \cdot p(x|y, z)$$

Décomposition alternative 2 :

$$p(x, y, z) = p(z|x, y) \cdot p(x) \cdot p(y)$$

Décomposition avec indépendance conditionnelle :

$$p(x, y, z) = p(z) \cdot p(x|z) \cdot p(y|z)$$

(si $X \perp Y|Z$)

Entropie : Mesure de l'Incertainitude

Entropie Discrète

Définition formelle

Pour une variable aléatoire discrète

Soit X une variable aléatoire discrète prenant ses valeurs dans $\mathcal{X} = \{x_1, x_2, \dots, x_n\}$ avec une fonction de masse de probabilité $p_X(x)$.

L'**entropie** de X est définie par :

$$H(X) = - \sum_{x \in \mathcal{X}} p_X(x) \log_2 p_X(x)$$

Forme espérance

$$H(X) = \mathbb{E}_{p_X}[-\log_2 p_X(X)] = -\mathbb{E}_{p_X}[\log_2 p_X(X)]$$

Convention importante

Par convention : $0 \log_2 0 = 0$ (car $\lim_{p \rightarrow 0^+} p \log p = 0$)

Interprétations

Interprétation informationnelle

L'entropie mesure :

- L'**incertitude** moyenne associée à la variable aléatoire X
- Le **nombre moyen de bits** nécessaires pour encoder de manière optimale les réalisations de X
- Le **caractère aléatoire** (randomness) de la distribution

Interprétation en théorie du codage

$H(X)$ représente la **longueur moyenne minimale** (en bits) d'un code optimal pour encoder les symboles de X .

Propriété clé

$H(X)$ dépend **uniquement** de la distribution $p_X(x)$, pas des valeurs particulières que X peut prendre.

Notations équivalentes

Les notations suivantes sont interchangeables :

- $H(X)$: entropie de la variable X
- $H(p)$: entropie de la distribution p
- $H(p_X)$ ou $H(p(x))$: entropie de la pmf $p_X(x)$

Cas Binaire : Variable de Bernoulli

Définition

Une variable **binaire** X prend ses valeurs dans $\mathcal{X} = \{0, 1\}$ avec :

$$\begin{aligned}\mathbb{P}[X = 1] &= \theta \\ \mathbb{P}[X = 0] &= 1 - \theta\end{aligned}$$

Forme compacte :

$$\mathbb{P}[X = x] = \theta^x (1 - \theta)^{1-x}, \quad x \in \{0, 1\}$$

Formule de l'entropie binaire

$$H(X) = -\theta \log_2 \theta - (1 - \theta) \log_2 (1 - \theta)$$

On note souvent cette fonction : $H(\theta)$ ou $H_2(\theta)$ (fonction d'entropie binaire).

Propriétés de $H(\theta)$

Symétrie

La fonction d'entropie binaire est **symétrique** autour de $\theta = 0.5$:

$$H(\theta) = H(1 - \theta)$$

Maximum

Le maximum est atteint en $\theta = 0.5$:

$$\max_{\theta \in [0,1]} H(\theta) = H(0.5) = 1 \text{ bit}$$

Principe fondamental : L'entropie est maximale lorsque les deux symboles sont **équiprobables**.

Cas limites

- $H(0) = H(1) = 0$: aucune incertitude (variable déterministe)
- $H(\theta) > 0$ pour $\theta \in (0, 1)$: présence d'incertitude

Exemples numériques

θ	$H(\theta)$ (bits)
0.11	0.50
0.25	0.81
0.50	1.00
0.75	0.81
0.89	0.50

Entropies Multivariées

Entropie Jointe

Définition

Pour deux variables aléatoires discrètes $X \in \mathcal{X}$ et $Y \in \mathcal{Y}$:

$$H(X, Y) = - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p_{X,Y}(x, y) \log_2 p_{X,Y}(x, y)$$

Forme espérance

$$H(X, Y) = -\mathbb{E}_{p_{X,Y}}[\log_2 p_{X,Y}(X, Y)]$$

Propriété de symétrie

$$H(X, Y) = H(Y, X)$$

Généralisation à N variables

$$H(X_1, \dots, X_N) = - \sum_{x_1 \in \mathcal{X}_1} \dots \sum_{x_N \in \mathcal{X}_N} p(x_1, \dots, x_N) \log_2 p(x_1, \dots, x_N)$$

Entropie Conditionnelle

Définition générale

L'entropie de X sachant Y est définie par :

$$H(X|Y) = \sum_{y \in \mathcal{Y}} p_Y(y) H(X|Y = y)$$

Forme développée

$$H(X|Y) = - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p_{X,Y}(x, y) \log_2 p_{X|Y}(x|y)$$

Forme espérance

$$H(X|Y) = -\mathbb{E}_{p_{X,Y}}[\log_2 p_{X|Y}(X|Y)]$$

Entropie conditionnelle pour une valeur fixée

Pour une valeur particulière $Y = y$:

$$H(X|Y = y) = -\sum_{x \in \mathcal{X}} p_{X|Y}(x|y) \log_2 p_{X|Y}(x|y)$$

Développement complet

$$\begin{aligned} H(X|Y) &= -\sum_{y \in \mathcal{Y}} p_Y(y) \left[\sum_{x \in \mathcal{X}} p_{X|Y}(x|y) \log_2 p_{X|Y}(x|y) \right] \\ &= -\sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p_{X,Y}(x,y) \log_2 p_{X|Y}(x|y) \end{aligned}$$

Asymétrie

Attention : L'entropie conditionnelle n'est **pas symétrique** :

$$H(X|Y) \neq H(Y|X)$$

en général.

Propriétés Fondamentales de l'Entropie

Non-négativité

Énoncé

Pour toute variable aléatoire discrète :

$$H(X) \geq 0$$

$$H(X, Y) \geq 0$$

$$H(X|Y) \geq 0$$

Justification

Puisque $0 \leq p_X(x) \leq 1$, on a $\log_2 p_X(x) \leq 0$.

Donc : $-p_X(x) \log_2 p_X(x) \geq 0$ pour tout x .

Par conséquent : $H(X) = \sum_x [-p_X(x) \log_2 p_X(x)] \geq 0$.

Le même raisonnement s'applique à $H(X, Y)$ et $H(X|Y)$.

Cas d'égalité

$$H(X) = 0 \quad \Leftrightarrow \quad X \text{ est déterministe}$$

C'est-à-dire $\exists x_0 : p_X(x_0) = 1$ et $p_X(x) = 0$ pour $x \neq x_0$.

Règle de Chaîne pour l'Entropie

Cas de 2 variables

En utilisant la règle de chaîne des probabilités :

$$p(x, y) = p(x|y)p(y) = p(y|x)p(x)$$

On obtient :

$$H(X, Y) = H(X) + H(Y|X) = H(Y) + H(X|Y)$$

Démonstration

$$\begin{aligned} -\log_2 p_{X,Y}(x, y) &= -\log_2 [p_{Y|X}(y|x)p_X(x)] \\ &= -\log_2 p_{Y|X}(y|x) - \log_2 p_X(x) \end{aligned}$$

En prenant l'espérance :

$$\begin{aligned} H(X, Y) &= \mathbb{E}_{p_{X,Y}}[-\log_2 p_{X,Y}(X, Y)] \\ &= \mathbb{E}_{p_{X,Y}}[-\log_2 p_X(X)] + \mathbb{E}_{p_{X,Y}}[-\log_2 p_{Y|X}(Y|X)] \\ &= H(X) + H(Y|X) \end{aligned}$$

Cas général de N variables

Pour la distribution jointe :

$$p(x_1, \dots, x_N) = p(x_1) \prod_{i=2}^N p(x_i | x_{i-1}, \dots, x_1)$$

On a :

$$H(X_1, X_2, \dots, X_N) = \sum_{i=1}^N H(X_i | X_{i-1}, \dots, X_1)$$

avec la convention $H(X_1 | \emptyset) = H(X_1)$.

Conséquence pour variables indépendantes

Si X et Y sont indépendantes ($X \perp Y$), alors $H(Y|X) = H(Y)$, et donc :

$$H(X, Y) = H(X) + H(Y)$$

Plus généralement :

$$H(X, Y) \leq H(X) + H(Y)$$

avec égalité si et seulement si $X \perp Y$.

Augmentation de l'Entropie par Ajout de Variables

Principe

Ajouter une nouvelle variable aléatoire **augmente** (ou laisse inchangée) l'entropie jointe :

$$H(X) \leq H(X, Y) \leq H(X, Y, Z) \leq \dots$$

Conditions d'égalité

$$H(X) = H(X, Y) \Leftrightarrow Y = f(X)$$

où f est une fonction déterministe (i.e., Y est complètement déterminé par X).

$$H(X, Y) = H(X, Y, Z) \Leftrightarrow Z = g(X, Y)$$

où g est une fonction déterministe.

Justification

En utilisant la règle de chaîne :

$$H(X, Y) = H(X) + H(Y|X)$$

Puisque $H(Y|X) \geq 0$, on a $H(X, Y) \geq H(X)$.

L'égalité est atteinte si et seulement si $H(Y|X) = 0$, ce qui signifie que Y est déterministement déterminé par X .

Conditionnement Réduit l'Entropie

Principe fondamental

Le conditionnement **réduit** (ou laisse inchangée) l'entropie :

$$H(X) \geq H(X|Y) \geq H(X|Y, Z) \geq \dots$$

Interprétation intuitive

Connaître Y ne peut que **réduire l'incertitude** sur X (ou la laisser inchangée si X et Y sont indépendants).

Conditions d'égalité

$$H(X) = H(X|Y) \Leftrightarrow X \perp Y$$

(X et Y sont indépendants)

$$H(X|Y) = H(X|Y, Z) \Leftrightarrow X \perp Z|Y$$

(X et Z sont conditionnellement indépendants sachant Y)

Démonstration

En utilisant la règle de chaîne :

$$H(X, Y) = H(X) + H(Y|X) = H(Y) + H(X|Y)$$

Donc :

$$H(X) - H(X|Y) = H(Y) - H(Y|X) = I(X; Y)$$

Puisque $I(X; Y) \geq 0$ (voir section sur l'information mutuelle), on a :

$$H(X) \geq H(X|Y)$$

Entropie Maximale

Théorème

Pour une variable aléatoire discrète X prenant ses valeurs dans un ensemble $\mathcal{X}$ de cardinalité $|\mathcal{X}| = N$:

$$H(X) \leq \log_2 N$$

Condition d'égalité

L'égalité est atteinte si et seulement si X suit une **distribution uniforme** :

$$p_X(x) = \frac{1}{N} = \frac{1}{|\mathcal{X}|}, \quad \forall x \in \mathcal{X}$$

Principe

Parmi toutes les distributions sur un ensemble fini, la distribution **uniforme** maximise l'entropie.

Esquisse de démonstration

Soit $\mathcal{X} = \{x_1, x_2, \dots, x_N\}$ et $p_i = \mathbb{P}[X = x_i]$.

Objectif : Maximiser $H(X) = -\sum_{i=1}^N p_i \log_2 p_i$ sous la contrainte $\sum_{i=1}^N p_i = 1$ et $p_i \geq 0$.

En utilisant les multiplicateurs de Lagrange, on montre que l'optimum est atteint pour $p_i = 1/N$ pour tout i .

Valeur maximale :

$$H_{\max} = -\sum_{i=1}^N \frac{1}{N} \log_2 \frac{1}{N} = \log_2 N$$

Application aux Vecteurs d'Images

Représentation vectorielle

Une image peut être représentée comme un vecteur de pixels :

$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_N \end{pmatrix} \in \mathcal{X}^N$$

où $N = n \times m$ est le nombre total de pixels.

Modèle d'indépendance

Si on suppose les pixels **indépendants** :

$$p(x_1, x_2, \dots, x_N) = \prod_{i=1}^N p(x_i)$$

Alors :

$$H(X_1, X_2, \dots, X_N) = \sum_{i=1}^N H(X_i)$$

Limitation : Cette hypothèse est **irréaliste** car les pixels voisins sont généralement corrélés.

Modèle de Markov

Un modèle plus réaliste est une chaîne de Markov d'ordre k (par exemple, $k = 2$) :

$$p(x_i | x_{i-1}, x_{i-2}, \dots, x_1) = p(x_i | x_{i-1}, x_{i-2})$$

Entropie totale :

$$H(X_1, X_2, \dots, X_N) = \sum_{i=1}^N H(X_i | X_{i-1}, \dots, X_1)$$

Pour un modèle de Markov d'ordre 2 :

$$H(X_1, X_2, \dots, X_N) = H(X_1) + H(X_2 | X_1) + \sum_{i=3}^N H(X_i | X_{i-1}, X_{i-2})$$

Applications au Codage et à la Compression

Concepts Fondamentaux du Codage

Schéma de compression

Compression sans perte (Lossless)

$$X \xrightarrow{\text{Encodeur}} R \xrightarrow{\text{Décodeur}} \hat{X}$$

Propriété :

$$\hat{X} = X \quad \Rightarrow \quad D = \mathbb{E}[\|X - \hat{X}\|^2] = 0$$

La reconstruction est **parfaite**.

Compression avec perte (Lossy)

$$X \xrightarrow{\text{Encodeur}} R \xrightarrow{\text{Décodeur}} \hat{X}$$

Propriété :

$$\hat{X} \neq X \Rightarrow D = \mathbb{E}[\|X - \hat{X}\|^2] > 0$$

On accepte une **distorsion** pour un meilleur taux de compression.

Taux de compression

Définition

Le **ratio de compression** (Compression Ratio) est défini par :

$$CR = \frac{\text{Taille originale (en bits)}}{\text{Taille compressée (en bits)}}$$

Un $CR > 1$ indique une compression effective.

Exemples de taux réels

Pour images réelles :

- Compression sans perte : $CR \approx 2$ (PNG, FLAC)
- Compression avec perte :
 - JPEG : $CR = 10$ à 50
 - JPEG 2000 : CR jusqu'à 150
 - Codecs vidéo modernes : $CR > 100$

Assignment Optimale de Codes

Principe de base

Histogramme et modèle

Pour une image représentée par N pixels :

$$p_i = \mathbb{P}\{X(i, j) = k\} = \frac{\text{Nombre de pixels d'intensité } k}{N}$$

Hypothèse simplificatrice (souvent irréaliste) : les pixels sont **discrets** et **indépendants**.

Lien avec l'entropie

Pour des symboles discrets et indépendants :

$$H(X) = - \sum_{i=0}^{L-1} p_i \log_2 p_i = \ell_{\text{av}}$$

où ℓ_{av} est la **longueur moyenne minimale** de code (en bits par symbole).

Longueur de code optimale

Relation probabilité-longueur

Pour encoder optimalement un symbole de probabilité p_i , la longueur de code optimale est :

$$\ell_i \approx -\log_2 p_i = \log_2 \frac{1}{p_i}$$

Cette relation découle du théorème de codage de source de Shannon.

Exemples numériques

Probabilité p_i	ℓ_i (bits)
$0.5 = 2^{-1}$	$\log_2 2 = 1$
$0.25 = 2^{-2}$	$\log_2 4 = 2$
$0.125 = 2^{-3}$	$\log_2 8 = 3$
$0.0625 = 2^{-4}$	$\log_2 16 = 4$

Codage à longueur variable

Principe fondamental

Pour minimiser la longueur moyenne du code :

- Les symboles **plus fréquents** reçoivent des codes **plus courts**
- Les symboles **moins fréquents** reçoivent des codes **plus longs**

Ce principe est à la base du **codage à longueur variable** (Variable Length Coding).

Longueur moyenne

Pour un code optimal :

$$\ell_{\text{av}} = \sum_{i=0}^{L-1} p_i \ell_i \approx H(X)$$

Plus précisément, le théorème de Shannon garantit :

$$H(X) \leq \ell_{\text{av}} < H(X) + 1$$

Codage de Huffman

Principe général

Objectif

Concevoir un **code préfixe** qui approche l'entropie de la source, c'est-à-dire un code de longueur moyenne minimale.

Optimalité

Le codage de Huffman est un code **optimal** pour l'encodage symbole par symbole de sources discrètes.

Hypothèses

Le codage de Huffman repose sur les hypothèses suivantes :

1. **Indépendance** : tous les symboles sont indépendants (hypothèse simplificatrice)
2. **Symbole par symbole** : encodage individuel de chaque symbole
3. **Connaissance de la distribution** : la pmf $p(x)$ est connue (peut être estimée par l'histogramme)

Algorithme de construction

Étapes de l'algorithme

Étape 1 : Initialisation Arranger les symboles par **probabilité décroissante**. Considérer chaque symbole comme un nœud feuille.

Étape 2 : Fusion itérative Répéter jusqu'à obtenir un seul nœud racine : - Sélectionner les deux nœuds de **plus faible probabilité** - Les fusionner en un nouveau nœud de probabilité égale à leur somme

Étape 3 : Assignment des codes Assigner le bit **0** à la branche supérieure et **1** à la branche inférieure (ou l'inverse)

Étape 4 : Lecture des codes Lire le code de chaque symbole en parcourant le chemin de la racine à la feuille

Exemple détaillé


Données

Considérons 8 symboles avec les probabilités suivantes :

Symbole	Probabilité
1	0.25
2	0.21
0	0.19
3	0.16
4	0.08
5	0.06
6	0.03
7	0.02

Vérification : $\sum p_i = 1.00$

Construction de l'arbre



Codes résultants

Symbole	Probabilité	Code Huffman	Longueur
1	0.25	10	2
2	0.21	01	2
0	0.19	00	2
3	0.16	110	3
4	0.08	1110	4
5	0.06	11110	5
6	0.03	111111	6
7	0.02	111110	6

Propriété observée : Les symboles avec la **plus haute probabilité** ont la **longueur la plus courte**.

Calculs de performances

Entropie de la source :

$$H = - \sum_{i=0}^7 p_i \log_2 p_i = 2.6508 \text{ bits/symbole}$$

Longueur moyenne (code Huffman) :

$$\ell_{\text{av}} = \sum_{i=0}^7 p_i \ell_i = 2.7000 \text{ bits/symbole}$$

Efficacité :

$$\eta = \frac{H}{\ell_{\text{av}}} = \frac{2.6508}{2.7000} \approx 0.982 = 98.2\%$$

Codes Préfixes

Définition

Un **code préfixe** (prefix code ou prefix-free code) est un code tel qu'**aucun code n'est le préfixe d'un autre code**.

Formellement : Pour tous codes distincts c_i et c_j , c_i n'est pas un préfixe de c_j .

Importance

Décodage unique

Un code préfixe garantit un **décodage unique** sans ambiguïté :

- Pas besoin de délimiteurs entre les codes
- Pas besoin de voir le symbole suivant pour décoder
- Le décodage peut être effectué **instantanément** (symbole par symbole)

Propriété de Kraft-McMillan

Pour qu'un code préfixe existe avec des longueurs $\{\ell_1, \dots, \ell_n\}$, il faut et il suffit que :

$$\sum_{i=1}^n 2^{-\ell_i} \leq 1$$

Cette condition est appelée **inégalité de Kraft**.

Exemple comparatif

Code A (NON préfixe)

Symbole	Code
1	1
2	00
3	11
4	110

Problème : Le code “1” est un préfixe de “11” et “110”

Code B (Préfixe)

Symbole	Code
1	0
2	10
3	110
4	111

Propriété : Aucun code n'est le préfixe d'un autre

Test de décodage : séquence “1234321”

Code A (NON préfixe) : - Encodage : 100011110110010 ou 1|00|00|110|... ? -
Problème : Ambiguïté de décodage

Code B (Préfixe) : - Encodage : 010110111110100 - Décodage : 0|10|110|111|110|10|0
= 1234321 - **Décodage unique**

Exemple Complet : Image à 8 Niveaux

Configuration

Une image utilise 8 niveaux de gris (3 bits en codage fixe).

Table de codage

Niveau	Probabilité	Code fixe	Code Huffman	Longueur
0	0.19	000	00	2
1	0.25	001	10	2
2	0.21	010	01	2
3	0.16	011	110	3
4	0.08	100	1110	4
5	0.06	101	11110	5
6	0.03	110	111111	6
7	0.02	111	111110	6

Analyse des performances

Entropie de la source

$$H = - \sum_{i=0}^7 p_i \log_2 p_i = 2.6508 \text{ bits}$$

Longueur moyenne : code fixe

$$\ell_{\text{av}}^{\text{fixe}} = 3 \text{ bits}$$

(tous les symboles utilisent 3 bits)

Longueur moyenne : code variable

$$\ell_{\text{av}}^{\text{var}} = \sum_{i=0}^7 p_i \ell_i = 2.7000 \text{ bits}$$

Comparaison

Métrique	Code fixe	Code Huffman	Entropie
Longueur moyenne	3.00	2.70	2.65
Efficacité	88.4%	98.2%	100%

Impact pratique

Gain pour une grande image

Pour une image de $1000 \times 1000 = 10^6$ pixels :

Différence par pixel :

$$\Delta = 3.00 - 2.70 = 0.30 \text{ bits}$$

Gain total :

$$\text{Gain} = 10^6 \times 0.30 = 3 \times 10^5 \text{ bits} = 37.5 \text{ Ko}$$

Par rapport à l'entropie

Différence entre code fixe et entropie :

$$\Delta = 3.00 - 2.65 = 0.35 \text{ bits/pixel}$$

Gain théorique maximal :

$$\text{Gain max} = 10^6 \times 0.35 = 3.5 \times 10^5 \text{ bits} \approx 42.7 \text{ Ko}$$

Complexité et Limitations

Complexité de compression pour images

Problématique générale

Une image X peut être vue comme un vecteur :

$$X \sim p_X(x) = p_X(x_1, x_2, \dots, x_N)$$

où N est le nombre de pixels.

Défis pratiques

1. **Modélisation complexe** : la distribution jointe $p_X(x_1, \dots, x_N)$ est en dimension très élevée
2. **Distribution inconnue** : la vraie distribution est généralement inconnue
3. **Hypothèse d'indépendance** : simplifier en supposant les pixels indépendants **augmente l'entropie** (sous-optimal)
4. **Corrélations spatiales** : les pixels voisins sont corrélés, ce qui contredit l'hypothèse d'indépendance

Théorie de Shannon : codage par blocs

Codage optimal

La théorie **rate-distortion** de Shannon suggère un **codage par blocs** pour approcher l'entropie :

Encoder des blocs : $(X_1, \dots, X_k)$ au lieu de symboles individuels

Problème de complexité

Codage par blocs de longueur k : - Nécessite $|\mathcal{X}|^k$ codes différents - Complexité **exponentielle** en k

Exemple : Pour $|\mathcal{X}| = 256$ (8 bits) et $k = 10$:

$$\text{Nombre de codes} = 256^{10} \approx 10^{24}$$

Solutions pratiques

Codage par sous-blocs

Compromis entre optimalité et complexité :

- **JPEG** : blocs de 8×8 pixels
- **JPEG 2000** : ondelettes multi-échelles
- **Codecs modernes** : blocs adaptatifs

Modèles statistiques

Utiliser des modèles pour capturer les dépendances :

- **Modèles de Markov** : dépendance locale
- **Modèles contextuels** : prédiction basée sur le voisinage
- **Réseaux de neurones** : apprentissage de représentations compactes

Mesures de Divergence et Similarité

Divergence de Kullback-Leibler (KL)

Définition

Formulation générale

La **divergence KL** (ou entropie relative) entre deux distributions $p(x)$ et $q(x)$ sur le même ensemble $\mathcal{X}$ est :

$$D_{\text{KL}}(p\|q) = \sum_{x \in \mathcal{X}} p(x) \log_2 \frac{p(x)}{q(x)}$$

Forme espérance

$$D_{\text{KL}}(p\|q) = \mathbb{E}_{p(x)} \left[\log_2 \frac{p(x)}{q(x)} \right]$$

Notations alternatives

- $D(p\|q)$: notation courte
- $D_{\text{KL}}(p\|q)$: notation explicite
- $KL(p\|q)$: notation abrégée

Conventions mathématiques

Valeurs limites

Pour assurer la cohérence mathématique :

$$0 \log_2 \frac{0}{q(x)} = 0, \quad \forall q(x)$$

(par continuité : $\lim_{p \rightarrow 0^+} p \log p = 0$)

$$p(x) \log_2 \frac{p(x)}{0} = +\infty, \quad \forall p(x) > 0$$

Conséquence : Si $\exists x : p(x) > 0$ et $q(x) = 0$, alors $D_{\text{KL}}(p\|q) = +\infty$.

Support

Pour que $D_{\text{KL}}(p\|q)$ soit fini, il faut que :

$$\text{Support}(p) \subseteq \text{Support}(q)$$

C'est-à-dire : $p(x) > 0 \Rightarrow q(x) > 0$.

Propriétés fondamentales

Non-négativité (Inégalité de Gibbs)

$$D_{\text{KL}}(p\|q) \geq 0$$

avec égalité si et seulement si $p(x) = q(x)$ pour tout $x \in \mathcal{X}$.

Démonstration (esquisse)

En utilisant l'inégalité de Jensen et la concavité du logarithme :

$$-D_{\text{KL}}(p\|q) = \sum_x p(x) \log \frac{q(x)}{p(x)} \leq \log \sum_x p(x) \frac{q(x)}{p(x)} = \log 1 = 0$$

Asymétrie

$$D_{\text{KL}}(p\|q) \neq D_{\text{KL}}(q\|p)$$

en général.

Conséquence : La divergence KL **n'est pas une distance** au sens mathématique : - Elle n'est pas symétrique - Elle ne vérifie pas l'inégalité triangulaire

Additivité pour distributions indépendantes

Si $X \perp Y$ sous p et sous q :

$$D_{\text{KL}}(p(x, y)\|q(x, y)) = D_{\text{KL}}(p(x)\|q(x)) + D_{\text{KL}}(p(y)\|q(y))$$

Interprétation en théorie du codage

Problème de codage sous-optimal

Situation : - **Distribution réelle** des données : $p(x)$ (souvent inconnue) - **Distribution supposée** pour le codage : $q(x)$

Longueurs de code

Si on conçoit un code optimal pour $q(x)$:

$$\ell_q(x) = -\log_2 q(x)$$

Le code optimal pour $p(x)$ serait :

$$\ell_p(x) = -\log_2 p(x)$$

Longueur moyenne attendue

En utilisant le code conçu pour q pour encoder des données de p :

$$\ell_{\text{av}}^q = \mathbb{E}_{X \sim p}[\ell_q(X)] = \sum_x p(x) \cdot (-\log_2 q(x))$$

Décomposition

$$\begin{aligned}\ell_{\text{av}}^q &= \sum_x p(x)(-\log_2 q(x)) \\ &= \sum_x p(x) \left(-\log_2 p(x) + \log_2 \frac{p(x)}{q(x)} \right) \\ &= \underbrace{\sum_x p(x)(-\log_2 p(x))}_{H(p)} + \underbrace{\sum_x p(x) \log_2 \frac{p(x)}{q(x)}}_{D_{\text{KL}}(p\|q)}\end{aligned}$$

Formule fondamentale :

$$\mathbb{E}_{X \sim p}[\ell_q(X)] = H(p) + D_{\text{KL}}(p\|q)$$

Interprétation

La divergence KL représente les **bits supplémentaires** nécessaires en moyenne lorsqu'on utilise un code sous-optimal :

$$D_{\text{KL}}(p\|q) = \text{Perte d'efficacité (en bits)}$$

Optimum :

$$D_{\text{KL}}(p\|q) = 0 \quad \Leftrightarrow \quad p = q \quad \Leftrightarrow \quad \text{Codage optimal}$$

Interprétation en Machine Learning

Mesure de similarité

En apprentissage automatique, la divergence KL mesure à quel point deux distributions sont **similaires** ou **différentes** :

- $D_{\text{KL}}(p\|q)$ faible : p et q sont similaires
- $D_{\text{KL}}(p\|q)$ élevé : p et q sont très différentes

Applications

- **Approximation variationnelle** : trouver q qui minimise $D_{\text{KL}}(p\|q)$
- **Apprentissage génératif** : minimiser $D_{\text{KL}}(p_{\text{data}}\|p_{\text{model}})$
- **Régularisation** : pénaliser l'écart par rapport à un prior

Exemple Numérique de KL Divergence

Configuration binaire

Considérons deux distributions binaires sur $\mathcal{X} = \{0, 1\}$:

Distribution p :

$$p(0) = a, \quad p(1) = 1 - a$$

Distribution q :

$$q(0) = b, \quad q(1) = 1 - b$$

Formules

$$D_{\text{KL}}(p\|q)$$

$$D_{\text{KL}}(p\|q) = a \log_2 \frac{a}{b} + (1 - a) \log_2 \frac{1 - a}{1 - b}$$

$$D_{\text{KL}}(q\|p)$$

$$D_{\text{KL}}(q\|p) = b \log_2 \frac{b}{a} + (1 - b) \log_2 \frac{1 - b}{1 - a}$$

Calcul numérique

Paramètres : $a = 1/4 = 0.25$, $b = 1/8 = 0.125$

$$D_{\text{KL}}(p\|q)$$

$$D_{\text{KL}}(p\|q) = 0.25 \log_2 \frac{0.25}{0.125} + 0.75 \log_2 \frac{0.75}{0.875}$$

$$= 0.25 \log_2 2 + 0.75 \log_2 \frac{0.75}{0.875}$$

$$= 0.25 \times 1 + 0.75 \times (-0.2223)$$

$$= 0.25 - 0.1667 = 0.0832 \text{ bit}$$

$$D_{\text{KL}}(q\|p)$$

$$D_{\text{KL}}(q\|p) = 0.125 \log_2 \frac{0.125}{0.25} + 0.875 \log_2 \frac{0.875}{0.75}$$

$$= 0.125 \log_2 0.5 + 0.875 \log_2 1.1667$$

$$= 0.125 \times (-1) + 0.875 \times 0.2223$$

$$= -0.125 + 0.1945 = 0.0696 \text{ bit}$$

Vérification de l'asymétrie

$$D_{\text{KL}}(p\|q) = 0.0832 \neq 0.0696 = D_{\text{KL}}(q\|p)$$

Confirme que la divergence KL **n'est pas symétrique**.

Cross-Entropy (Entropie Croisée)

Définition

Formulation

L'**entropie croisée** entre deux distributions p et q est :

$$H(p, q) = - \sum_{x \in \mathcal{X}} p(x) \log_2 q(x)$$

Forme espérance

$$H(p, q) = -\mathbb{E}_{p(x)}[\log_2 q(x)]$$

Asymétrie

Comme pour la KL divergence :

$$H(p, q) \neq H(q, p)$$

en général.

Lien avec la Divergence KL

Relation fondamentale

$$H(p, q) = H(p) + D_{\text{KL}}(p \| q)$$

Démonstration

$$\begin{aligned} D_{\text{KL}}(p \| q) &= \sum_x p(x) \log_2 \frac{p(x)}{q(x)} \\ &= \sum_x p(x) \log_2 p(x) - \sum_x p(x) \log_2 q(x) \\ &= -H(p) + H(p, q) \end{aligned}$$

D'où :

$$H(p, q) = H(p) + D_{\text{KL}}(p \| q)$$

Propriété d'optimisation

Équivalence d'optimisation

Puisque $H(p)$ ne dépend **pas** de q , minimiser $H(p, q)$ par rapport à q est **équivalent** à minimiser $D_{\text{KL}}(p \| q)$:

$$\arg \min_q H(p, q) = \arg \min_q D_{\text{KL}}(p \| q)$$

Optimum

Le minimum est atteint pour $q = p$:

$$H(p, p) = H(p) + D_{\text{KL}}(p \| p) = H(p) + 0 = H(p)$$

Application en Machine Learning

Fonction de perte pour classification

En apprentissage supervisé, la cross-entropy est largement utilisée comme **fonction de perte** :

Configuration : - $p(y)$: distribution vraie (souvent one-hot en classification) - $q(y)$ ou $q(y|x)$: distribution prédite par le modèle

Fonction de perte :

$$\mathcal{L} = H(p, q) = - \sum_y p(y) \log q(y)$$

ou pour un batch :

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \sum_y p(y_i) \log q(y_i|x_i)$$

Cas de la classification binaire

Pour une classification binaire ($y \in \{0, 1\}$) :

$$\mathcal{L} = -[y \log \hat{y} + (1 - y) \log(1 - \hat{y})]$$

où $\hat{y} = q(y = 1|x)$ est la probabilité prédite.

Avantages

- **Gradient bien défini** : évite les problèmes de saturation
- **Interprétation probabiliste** : minimiser la distance entre distributions
- **Lien avec maximum de vraisemblance** : équivalent à maximiser la log-vraisemblance

Information Mutuelle

Définitions et Formulations

Définition générale

Information mutuelle entre deux variables

L'information mutuelle entre X et Y est :

$$I(X; Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p_{X,Y}(x, y) \log_2 \frac{p_{X,Y}(x, y)}{p_X(x)p_Y(y)}$$

Forme espérance

$$I(X; Y) = \mathbb{E}_{p_{X,Y}} \left[\log_2 \frac{p_{X,Y}(X, Y)}{p_X(X)p_Y(Y)} \right]$$

Formulation via divergence KL

KL divergence entre jointe et produit des marginales

$$I(X; Y) = D_{\text{KL}}(p_{X,Y}(x, y) \| p_X(x)p_Y(y))$$

Interprétation

L'information mutuelle mesure à quel point la **distribution jointe** $p_{X,Y}(x, y)$ diffère du produit des marginales $p_X(x)p_Y(y)$.

Autrement dit : mesure la **dépendance** entre X et Y par rapport à l'hypothèse d'indépendance.

Formulations alternatives

Forme conditionnelle 1

$$\begin{aligned} I(X; Y) &= \sum_{x,y} p_{X,Y}(x,y) \log_2 \frac{p_{X|Y}(x|y)}{p_X(x)} \\ &= \mathbb{E}_{p(y)} [D_{\text{KL}}(p(x|y) \| p(x))] \end{aligned}$$

Forme conditionnelle 2

$$\begin{aligned} I(X; Y) &= \sum_{x,y} p_{X,Y}(x,y) \log_2 \frac{p_{Y|X}(y|x)}{p_Y(y)} \\ &= \mathbb{E}_{p(x)} [D_{\text{KL}}(p(y|x) \| p(y))] \end{aligned}$$

Propriétés Fondamentales

Symétrie

$$I(X; Y) = I(Y; X)$$

Conséquence : Contrairement à la divergence KL, l'information mutuelle est **symétrique**.

Non-négativité

$$I(X; Y) \geq 0$$

Égalité :

$$I(X; Y) = 0 \quad \Leftrightarrow \quad X \perp Y$$

(X et Y sont indépendants)

Démonstration

Puisque $I(X; Y) = D_{\text{KL}}(p_{X,Y} \| p_X p_Y)$ et que la divergence KL est toujours non-négative, on a $I(X; Y) \geq 0$.

L'égalité est atteinte si et seulement si $p_{X,Y}(x,y) = p_X(x)p_Y(y)$ pour tout x, y , c'est-à-dire si X et Y sont indépendants.

Borne supérieure

$$I(X; Y) \leq \min\{H(X), H(Y)\}$$

Égalité : - $I(X; Y) = H(X)$ si Y détermine complètement X (i.e., $X = f(Y)$) - $I(X; Y) = H(Y)$ si X détermine complètement Y (i.e., $Y = g(X)$)

Auto-information

$$I(X; X) = H(X)$$

Justification :

$$I(X; X) = H(X) - H(X|X) = H(X) - 0 = H(X)$$

car $H(X|X) = 0$ (connaître X élimine toute incertitude sur X).

Relations avec l'Entropie

Relations fondamentales

Relation 1

$$I(X; Y) = H(X) - H(X|Y)$$

Interprétation : L'information mutuelle est la **réduction d'incertitude** sur X apportée par la connaissance de Y .

Relation 2

$$I(X; Y) = H(Y) - H(Y|X)$$

Interprétation : Par symétrie, c'est aussi la réduction d'incertitude sur Y apportée par X .

Relation 3

$$I(X;Y) = H(X) + H(Y) - H(X,Y)$$

Démonstration :

En utilisant la règle de chaîne : $H(X,Y) = H(X) + H(Y|X)$

Donc :

$$\begin{aligned} I(X;Y) &= H(Y) - H(Y|X) = H(Y) - [H(X,Y) - H(X)] \\ &= H(X) + H(Y) - H(X,Y) \end{aligned}$$


Cas d'indépendance

Si $X \perp Y$:

$$\begin{aligned} I(X;Y) &= 0 \\ H(X,Y) &= H(X) + H(Y) \end{aligned}$$

Diagramme de Venn

Les relations entre entropies peuvent être visualisées avec un diagramme de Venn :



Lecture : - **Zone totale :** $H(X,Y)$ (entropie jointe) - **Zone gauche :** $H(X|Y)$ (incertitude sur X sachant Y) - **Zone centrale** (intersection) : $I(X;Y)$ (information mutuelle) - **Zone droite :** $H(Y|X)$ (incertitude sur Y sachant X) - **Cercle gauche :** $H(X) = H(X|Y) + I(X;Y)$ - **Cercle droit :** $H(Y) = H(Y|X) + I(X;Y)$

Information Mutuelle Conditionnelle

Définition

Information mutuelle entre X et Y sachant Z

$$I(X; Y|Z) = H(X|Z) - H(X|Y, Z)$$

Formes alternatives

$$I(X; Y|Z) = H(Y|Z) - H(Y|X, Z)$$

$$I(X; Y|Z) = H(X|Z) + H(Y|Z) - H(X, Y|Z)$$

Formulation via KL divergence

$$I(X; Y|Z) = \mathbb{E}_{p(z)}[D_{\text{KL}}(p(x, y|z) \| p(x|z)p(y|z))]$$

$$= \mathbb{E}_{p(x, y, z)} \left[\log_2 \frac{p_{X, Y|Z}(x, y|z)}{p_{X|Z}(x|z)p_{Y|Z}(y|z)} \right]$$

$$= \mathbb{E}_{p(x, y, z)} \left[\log_2 \frac{p_{X|Y, Z}(x|y, z)}{p_{X|Z}(x|z)} \right]$$

Démonstration

En utilisant la décomposition :

$$p_{X, Y|Z}(x, y|z) = p_{Y|Z}(y|z) \cdot p_{X|Y, Z}(x|y, z)$$

On a :

$$I(X; Y|Z) = \mathbb{E}_{p(x, y, z)}[\log_2 p_{X|Y, Z}(x|y, z)] - \mathbb{E}_{p(x, y, z)}[\log_2 p_{X|Z}(x|z)]$$

$$= -H(X|Y, Z) + H(X|Z)$$

Diagramme

$$H(X|Z)$$

$$H(Y|Z)$$

$$I(X;Y|Z)$$

Règle de Chaîne pour l'Information Mutuelle

Énoncé général

Pour N variables

$$I(X_1, X_2, \dots, X_N; Y) = \sum_{i=1}^N I(X_i; Y | X_{i-1}, \dots, X_1)$$

Démonstration

En utilisant la règle de chaîne pour l'entropie :

$$\begin{aligned} I(X_1, \dots, X_N; Y) &= H(X_1, \dots, X_N) - H(X_1, \dots, X_N | Y) \\ &= \sum_{i=1}^N H(X_i | X_{i-1}, \dots, X_1) - \sum_{i=1}^N H(X_i | X_{i-1}, \dots, X_1, Y) \\ &= \sum_{i=1}^N [H(X_i | X_{i-1}, \dots, X_1) - H(X_i | X_{i-1}, \dots, X_1, Y)] \\ &= \sum_{i=1}^N I(X_i; Y | X_{i-1}, \dots, X_1) \end{aligned}$$

Application : analyse de features

Sélection de features

Pour sélectionner les features les plus informatives par rapport à un label Y :

Approche greedy :

1. Sélectionner $X_1 = \arg \max_{X_i} I(X_i; Y)$
2. Sélectionner $X_2 = \arg \max_{X_i} I(X_i; Y | X_1)$
3. Continuer jusqu'à obtenir k features

Information totale :

$$I(X_1, \dots, X_k; Y) = \sum_{i=1}^k I(X_i; Y | X_{i-1}, \dots, X_1)$$

Exemple : pixels d'image et label

Configuration

Une image représentée par N pixels :

$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_N \end{pmatrix} \in \mathcal{X}^N$$

avec $N = n \times m$ (dimensions de l'image).

Un label :

$$Y \in \mathcal{Y}$$

Information mutuelle totale

$$I(X_1, X_2, \dots, X_N; Y) = \sum_{i=1}^N I(X_i; Y | X_{i-1}, \dots, X_1)$$

Interprétation : Chaque terme $I(X_i; Y | X_{i-1}, \dots, X_1)$ représente l'information **additionnelle** apportée par le pixel X_i sur le label Y , sachant les pixels précédents.

Décompositions Complexes

Deux variables et deux labels

Pour X_1, X_2 et Y_1, Y_2 :

$$I(X_1, X_2; Y_1, Y_2) = I(X_1; Y_1, Y_2) + I(X_2; Y_1, Y_2 | X_1)$$

Décomposition de $I(X_1; Y_1, Y_2)$

$$I(X_1; Y_1, Y_2) = I(X_1; Y_1) + I(X_1; Y_2 | Y_1)$$

ou alternativement :

$$I(X_1; Y_1, Y_2) = I(X_1; Y_2) + I(X_1; Y_1 | Y_2)$$

Décomposition de $I(X_2; Y_1, Y_2 | X_1)$

$$I(X_2; Y_1, Y_2 | X_1) = I(X_2; Y_1 | X_1) + I(X_2; Y_2 | X_1, Y_1)$$

ou :

$$I(X_2; Y_1, Y_2 | X_1) = I(X_2; Y_2 | X_1) + I(X_2; Y_1 | X_1, Y_2)$$

Inégalité de Traitement des Données (Data Processing Inequality)

Chaîne de Markov

Configuration

Considérons une **chaîne de Markov** :



Notation : $X \rightarrow Y \rightarrow Z$

Définition formelle :

$$p_{X,Y,Z}(x, y, z) = p_X(x) \cdot p_{Y|X}(y|x) \cdot p_{Z|Y}(z|y)$$

Propriété clé :

$$X \perp Z|Y$$

c'est-à-dire : $p(x, z|y) = p(x|y)p(z|y)$

Inégalité fondamentale

Énoncés

Pour une chaîne de Markov $X \rightarrow Y \rightarrow Z$:

$$I(X; Y) \geq I(X; Z)$$

$$I(Y; Z) \geq I(X; Z)$$

Cas d'égalité

$$I(X; Y) = I(X; Z) \quad \Leftrightarrow \quad X \leftrightarrow Y \leftrightarrow Z \text{ (chaîne réversible)}$$

Cas particulier important

Fonction déterministe

Si $Z = g(Y)$ où g est une fonction déterministe :

$$I(X; Y) \geq I(X; g(Y))$$

Interprétation : Toute transformation de Y **réduit** (ou laisse inchangée) l'information mutuelle avec X .

Interprétation

Principe de non-créativité de l'information

Le traitement des données ne peut pas créer d'information :

La quantité d'information **ne peut pas être augmentée** par un traitement quelconque (transformation, filtrage, etc.).

Applications

Réseaux de neurones profonds :

Pour un réseau $X \rightarrow h_1 \rightarrow h_2 \rightarrow \dots \rightarrow h_L \rightarrow Y$:

$$I(X; Y) \leq I(X; h_L) \leq \dots \leq I(X; h_2) \leq I(X; h_1)$$

Compression :

Toute compression réduit l'information mutuelle avec la source originale.

Communication :

L'information ne peut pas être augmentée par un canal bruité.

Démonstration

Utilisation de la règle de chaîne

$$I(X; Y, Z) = I(X; Z) + I(X; Y|Z) \quad \dots(a)$$

$$I(X; Y, Z) = I(X; Y) + I(X; Z|Y) \quad \dots(b)$$

Propriété de la chaîne de Markov

Pour $X \rightarrow Y \rightarrow Z$, on a $X \perp Z|Y$, donc :

$$I(X; Z|Y) = 0$$

Conclusion

De (b) :

$$I(X; Y, Z) = I(X; Y) + 0 = I(X; Y)$$

En combinant avec (a) :

$$I(X; Y) = I(X; Z) + I(X; Y|Z)$$

Puisque $I(X; Y|Z) \geq 0$, on obtient :

$$I(X; Y) \geq I(X; Z)$$

Variables Continues : Entropie Différentielle

Motivation et Limite

Passage du discret au continu

Quantification

Pour une variable continue X avec densité $f_X(x)$, on peut l'approximer par une variable discrète en quantifiant :

$$P[x_k; \Delta x] = \int_{x_k}^{x_k + \Delta x} f_X(x) dx \approx f_X(x_k) \Delta x$$

Entropie de la version quantifiée

$$\begin{aligned} H(X; \Delta x) &= - \sum_{k=1}^N P[x_k; \Delta x] \log_2 P[x_k; \Delta x] \\ &= - \sum_{k=1}^N f_X(x_k) \Delta x \log_2 [f_X(x_k) \Delta x] \end{aligned}$$

Décomposition

En utilisant $\log(ab) = \log a + \log b$:

$$\begin{aligned} H(X; \Delta x) &= - \sum_{k=1}^N f_X(x_k) \Delta x \log_2 f_X(x_k) - \sum_{k=1}^N f_X(x_k) \Delta x \log_2 \Delta x \\ &= - \sum_{k=1}^N f_X(x_k) \Delta x \log_2 f_X(x_k) - \log_2 \Delta x \underbrace{\sum_{k=1}^N f_X(x_k) \Delta x}_{\approx 1} \end{aligned}$$

Passage à la limite

Limite continue

Lorsque $\Delta x \rightarrow 0$ et $N \rightarrow \infty$:

$$- \sum_{k=1}^N f_X(x_k) \Delta x \log_2 f_X(x_k) \rightarrow - \int_{-\infty}^{\infty} f_X(x) \log_2 f_X(x) dx$$

Problème avec le second terme

$$\log_2 \Delta x \rightarrow -\infty \quad \text{lorsque } \Delta x \rightarrow 0$$

Donc :

$$H(X; \Delta x) \rightarrow +\infty$$

Conclusion : L'entropie d'une variable continue avec la définition discrète diverge !

Définition de l'Entropie Différentielle

Définition formelle

Pour contourner le problème de divergence, on définit l'**entropie différentielle** :

$$\begin{aligned}h(X) &= - \int_{\mathcal{X}} f_X(x) \log_2 f_X(x) dx \\ &= -\mathbb{E}_{f_X}[\log_2 f_X(X)]\end{aligned}$$

Notations

- **Minuscule** $h(X)$: entropie différentielle (variables continues)
- **Majuscule** $H(X)$: entropie (variables discrètes)

Différences avec l'entropie discrète

Peut être négative

Contrairement à $H(X) \geq 0$ toujours, on peut avoir :

$$h(X) < 0$$

Exemple : Distribution uniforme sur $[0, a]$ avec $a < 1$:

$$h(X) = \log_2 a < 0$$

Pas d'interprétation directe en bits

L'entropie différentielle **n'a pas** d'interprétation directe en termes de “nombre de bits”.

Elle mesure plutôt l'**incertitude relative** ou la **dispersion** de la distribution.

Dépend des unités

Si X est mesuré en mètres et $Y = X$ en centimètres ($Y = 100X$), alors :

$$h(Y) = h(X) + \log_2 100$$

Lien avec l'entropie quantifiée

$$H(X; \Delta x) \approx h(X) - \log_2 \Delta x$$

Pour Δx petit.

Entropie Différentielle d'une Gaussienne

Variable gaussienne univariée

Distribution

$$X \sim \mathcal{N}(\mu, \sigma^2)$$

Densité de probabilité :

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Entropie différentielle

$$h(X) = \frac{1}{2} \log_2(2\pi e\sigma^2) \quad [\text{bits}]$$

ou en nats (logarithme naturel) :

$$h(X) = \frac{1}{2} \ln(2\pi e\sigma^2) \quad [\text{nats}]$$

Propriété

L'entropie différentielle d'une gaussienne **ne dépend pas** de la moyenne μ , seulement de la variance σ^2 .

Démonstration

Cas centré ($\mu = 0$)

PDF :

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{x^2}{2\sigma^2}\right)$$

Logarithme :

$$\ln f_X(x) = -\frac{1}{2} \ln(2\pi\sigma^2) - \frac{x^2}{2\sigma^2}$$

Entropie différentielle (en nats) :

$$\begin{aligned} h(X) &= - \int_{-\infty}^{\infty} f_X(x) \ln f_X(x) dx \\ &= - \int_{-\infty}^{\infty} f_X(x) \left[-\frac{x^2}{2\sigma^2} - \frac{1}{2} \ln(2\pi\sigma^2) \right] dx \\ &= \int_{-\infty}^{\infty} f_X(x) \frac{x^2}{2\sigma^2} dx + \frac{1}{2} \ln(2\pi\sigma^2) \underbrace{\int_{-\infty}^{\infty} f_X(x) dx}_{=1} \end{aligned}$$

Calcul de la première intégrale

$$\int_{-\infty}^{\infty} f_X(x) \frac{x^2}{2\sigma^2} dx = \frac{1}{2\sigma^2} \mathbb{E}[X^2] = \frac{1}{2\sigma^2} \cdot \sigma^2 = \frac{1}{2}$$

car $\mathbb{E}[X^2] = \text{Var}[X] = \sigma^2$ (puisque $\mathbb{E}[X] = 0$).

Résultat

$$\begin{aligned} h(X) &= \frac{1}{2} + \frac{1}{2} \ln(2\pi\sigma^2) = \frac{1}{2} [1 + \ln(2\pi\sigma^2)] \\ &= \frac{1}{2} [\ln e + \ln(2\pi\sigma^2)] = \frac{1}{2} \ln(2\pi e\sigma^2) \quad [\text{nats}] \end{aligned}$$

Conversion en bits

$$h(X) = \frac{1}{2} \log_2(2\pi e \sigma^2) \quad [\text{bits}]$$

Gaussienne multivariée

Pour $X \sim \mathcal{N}(\mu, \Sigma)$ avec $X \in \mathbb{R}^n$:

$$\begin{aligned} h(X) &= \frac{1}{2} \log_2[(2\pi e)^n |\Sigma|] \\ &= \frac{n}{2} \log_2(2\pi e) + \frac{1}{2} \log_2 |\Sigma| \end{aligned}$$

où $|\Sigma|$ est le déterminant de la matrice de covariance.

Propriétés de l'Entropie Différentielle

Invariance par translation

Énoncé

Pour une constante a (scalaire ou vecteur) :

$$h(X + a) = h(X)$$

Interprétation

Déplacer une distribution ne change pas son entropie différentielle.

Seule la **forme** de la distribution compte, pas sa **position**.

Démonstration

Si $Y = X + a$ avec a constant, alors :

$$f_Y(y) = f_X(y - a)$$

$$h(Y) = - \int f_Y(y) \log f_Y(y) dy = - \int f_X(x) \log f_X(x) dx = h(X)$$

(par changement de variable $x = y - a$).

Effet de la mise à l'échelle

Variable scalaire

Si $Y = aX$ avec a une constante non nulle :

$$h(Y) = h(aX) = h(X) + \log_2 |a|$$

Variable vectorielle

Si $Y = AX$ avec A une matrice inversible :

$$h(Y) = h(AX) = h(X) + \log_2 |\det(A)|$$

où $\det(A)$ est le **déterminant** de la matrice A .

Interprétation

- **Étirer** la distribution ($|a| > 1$) **augmente** l'entropie différentielle
- **Compresser** la distribution ($|a| < 1$) **diminue** l'entropie différentielle

Le facteur $\log_2 |\det(A)|$ représente le changement de “volume” dans l'espace.

Démonstration (cas scalaire)

Si $Y = aX$, alors :

$$\begin{aligned}f_Y(y) &= \frac{1}{|a|} f_X\left(\frac{y}{a}\right) \\h(Y) &= - \int f_Y(y) \log_2 f_Y(y) dy \\&= - \int \frac{1}{|a|} f_X\left(\frac{y}{a}\right) \log_2 \left[\frac{1}{|a|} f_X\left(\frac{y}{a}\right) \right] dy\end{aligned}$$

Par changement de variable $x = y/a$:

$$\begin{aligned}h(Y) &= - \int f_X(x) \log_2 \left[\frac{1}{|a|} f_X(x) \right] dx \\&= - \int f_X(x) [\log_2 f_X(x) - \log_2 |a|] dx \\&= h(X) + \log_2 |a|\end{aligned}$$

Exemple : gaussienne et mise à l'échelle

Pour $X \sim \mathcal{N}(0, \sigma^2)$ et $Y = aX$:

$$Y \sim \mathcal{N}(0, (a\sigma)^2)$$

Vérification :

$$\begin{aligned}h(Y) &= \frac{1}{2} \log_2 (2\pi e (a\sigma)^2) = \frac{1}{2} \log_2 (2\pi e \sigma^2) + \frac{1}{2} \log_2 a^2 \\&= h(X) + \log_2 |a|\end{aligned}$$

Confirme la propriété.

Maximum d'entropie sous contrainte de variance

Théorème

Parmi toutes les distributions continues sur $\mathbb{R}$ avec variance fixée σ^2 , la **gaussienne** maximise l'entropie différentielle.

$$\max_{f_X: \text{Var}[X]=\sigma^2} h(X) = \frac{1}{2} \log_2(2\pi e \sigma^2)$$

atteint pour $X \sim \mathcal{N}(\mu, \sigma^2)$ (avec μ quelconque).

Interprétation

La gaussienne est la distribution de **maximum d'incertitude** étant donné une contrainte sur la variance.

Applications en Machine Learning

Fonctions de Perte

Cross-Entropy en Classification

Configuration

Problème : Classification multi-classes avec C classes.

Pour un exemple (x, y) : - y : vrai label (encodé en one-hot : $y \in \{0, 1\}^C$ avec $\sum_c y_c = 1$) - $\hat{y} = q(y|x; \theta)$: distribution prédite par le modèle

Fonction de perte

Pour un exemple :

$$\mathcal{L}(y, \hat{y}) = - \sum_{c=1}^C y_c \log \hat{y}_c = H(y, \hat{y})$$

Pour un batch de N exemples :

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log \hat{y}_{i,c}$$

Cas binaire (Binary Cross-Entropy)

Pour $C = 2$ (ou équivalent $y \in \{0, 1\}$) :

$$\mathcal{L}(y, \hat{y}) = -[y \log \hat{y} + (1 - y) \log(1 - \hat{y})]$$

où $\hat{y} = P(y = 1|x)$ est la probabilité prédite.

Lien avec Maximum de Vraisemblance

Équivalence

Minimiser la cross-entropy est **équivalent** à maximiser la log-vraisemblance :

$$\min_{\theta} \mathcal{L} = \min_{\theta} H(p_{\text{data}}, p_{\theta}) \equiv \max_{\theta} \mathbb{E}_{(x,y) \sim p_{\text{data}}} [\log p_{\theta}(y|x)]$$

Justification

Pour un dataset $\{(x_i, y_i)\}_{i=1}^N$:

Vraisemblance :

$$\mathcal{L}(\theta) = \prod_{i=1}^N p_{\theta}(y_i|x_i)$$

Log-vraisemblance :

$$\log \mathcal{L}(\theta) = \sum_{i=1}^N \log p_{\theta}(y_i|x_i)$$

Minimisation de la cross-entropy empirique :

$$\min_{\theta} \left[-\frac{1}{N} \sum_{i=1}^N \log p_{\theta}(y_i|x_i) \right] \equiv \max_{\theta} \frac{1}{N} \log \mathcal{L}(\theta)$$

Sélection de Features

Utilisation de l'Information Mutuelle

Principe

Pour sélectionner les features les plus informatives par rapport à un label Y , on mesure :

$$I(X_i; Y)$$

pour chaque feature X_i .

Critère

Garder les features avec $I(X_i; Y)$ élevée.

Les features ayant une forte information mutuelle avec le label apportent plus d'information pour la prédiction.

Méthodes de sélection

Approche univariée

Rang par information mutuelle :

1. Calculer $I(X_i; Y)$ pour chaque feature $i = 1, \dots, d$
2. Trier les features par $I(X_i; Y)$ décroissant
3. Sélectionner les top- k features

Avantage : Simple et rapide

Limitation : Ignore les dépendances entre features (redondance)

Approche conditionnelle

Maximum Relevance Minimum Redundancy (mRMR) :

Maximiser :

$$\max_S \left[\frac{1}{|S|} \sum_{X_i \in S} I(X_i; Y) - \frac{1}{|S|^2} \sum_{X_i, X_j \in S} I(X_i; X_j) \right]$$

Objectif : Sélectionner des features pertinentes mais peu redondantes.

Approche greedy avec règle de chaîne

En utilisant la règle de chaîne :

$$I(X_1, \dots, X_k; Y) = \sum_{i=1}^k I(X_i; Y | X_1, \dots, X_{i-1})$$

Algorithme :

1. Sélectionner $X_1 = \arg \max_{X_i} I(X_i; Y)$
2. Sélectionner $X_2 = \arg \max_{X_i \notin \{X_1\}} I(X_i; Y | X_1)$
3. Continuer jusqu'à k features

Régularisation et Variational Autoencoders

Variational Autoencoders (VAE)

Architecture

Encodeur : $q_\phi(z|x)$ (distribution approximative du posterior)

Décodeur : $p_\theta(x|z)$ (distribution générative)

Prior : $p(z)$ (souvent $\mathcal{N}(0, I)$)

Fonction objectif (ELBO)

L'Evidence Lower Bound (ELBO) à maximiser :

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)] - D_{\text{KL}}(q_\phi(z|x) \| p(z))$$

Terme de régularisation KL

$$\mathcal{L}_{\text{KL}} = D_{\text{KL}}(q_\phi(z|x) \| p(z))$$

Rôle : - Force l'encodeur à produire des distributions proches du prior - Régularise l'espace latent pour qu'il soit continu et structuré - Empêche l'overfitting dans l'espace latent

Interprétation

Compromis reconstruction-régularisation :

$$\mathcal{L}_{\text{VAE}} = \underbrace{\text{Terme de reconstruction}}_{\text{fidélité aux données}} + \beta \cdot \underbrace{D_{\text{KL}}(q(z|x) \| p(z))}_{\text{régularisation}}$$

où β est un hyperparamètre (souvent $\beta = 1$).

Autres applications de la KL divergence

Distillation de connaissances

Objectif : Transférer les connaissances d'un grand modèle (teacher) vers un petit modèle (student)

Loss :

$$\mathcal{L}_{\text{distill}} = D_{\text{KL}}(p_{\text{student}}(y|x) \| p_{\text{teacher}}(y|x))$$

Policy Gradient en RL

Trust Region Policy Optimization (TRPO) :

Contrainte : $D_{\text{KL}}(\pi_{\text{old}} \| \pi_{\text{new}}) \leq \delta$

Empêche les changements trop brusques de la politique.

Adversarial Training

Génération adverse :

Minimiser : $D_{\text{KL}}(p_{\text{model}} \| p_{\text{data}})$ ou l'inverse

Aide-Mémoire et Synthèse

Formules Essentielles

Entropie

Entropie discrète

$$H(X) = - \sum_x p(x) \log_2 p(x) = \mathbb{E}[-\log_2 p(X)]$$

Entropie jointe

$$H(X, Y) = - \sum_{x,y} p(x, y) \log_2 p(x, y)$$

Entropie conditionnelle

$$H(X|Y) = - \sum_{x,y} p(x, y) \log_2 p(x|y) = \mathbb{E}_{p(Y)}[H(X|Y = y)]$$

Entropie différentielle

$$h(X) = - \int f_X(x) \log_2 f_X(x) dx$$

Entropie d'une gaussienne

$$h(X) = \frac{1}{2} \log_2(2\pi e \sigma^2)$$

Relations entre Entropies

Règle de chaîne

$$H(X, Y) = H(X) + H(Y|X) = H(Y) + H(X|Y)$$

$$H(X_1, \dots, X_N) = \sum_{i=1}^N H(X_i | X_{i-1}, \dots, X_1)$$

Inégalités fondamentales

$$H(X|Y) \leq H(X)$$

(le conditionnement réduit l'entropie)

$$H(X, Y) \leq H(X) + H(Y)$$

(égalité ssi $X \perp Y$)

$$H(X) \leq \log_2 |\mathcal{X}|$$

(égalité ssi distribution uniforme)

Information Mutuelle

Définitions équivalentes

$$I(X; Y) = H(X) - H(X|Y)$$

$$I(X; Y) = H(Y) - H(Y|X)$$

$$I(X; Y) = H(X) + H(Y) - H(X, Y)$$

$$I(X; Y) = D_{\text{KL}}(p(x, y) \| p(x)p(y))$$

Information mutuelle conditionnelle

$$I(X; Y|Z) = H(X|Z) - H(X|Y, Z)$$

Règle de chaîne

$$I(X_1, \dots, X_N; Y) = \sum_{i=1}^N I(X_i; Y | X_{i-1}, \dots, X_1)$$

Divergences

KL divergence

$$D_{\text{KL}}(p\|q) = \sum_x p(x) \log_2 \frac{p(x)}{q(x)} = \mathbb{E}_p \left[\log \frac{p(X)}{q(X)} \right]$$

Cross-entropy

$$H(p, q) = - \sum_x p(x) \log_2 q(x) = H(p) + D_{\text{KL}}(p\|q)$$

Propriétés Clés à Retenir

Propriétés de l'entropie

1. **Non-négativité** : $H(X) \geq 0$
2. **Règle de chaîne** : $H(X, Y) = H(X) + H(Y|X)$
3. **Ajout de variables augmente l'entropie** : $H(X) \leq H(X, Y)$
4. **Conditionnement réduit l'entropie** : $H(X) \geq H(X|Y)$
5. **Maximum pour distribution uniforme** : $H(X) \leq \log |\mathcal{X}|$

Propriétés de l'information mutuelle

1. **Symétrie** : $I(X; Y) = I(Y; X)$
2. **Non-négativité** : $I(X; Y) \geq 0$
3. **Annulation avec indépendance** : $I(X; Y) = 0 \Leftrightarrow X \perp Y$
4. **Auto-information** : $I(X; X) = H(X)$
5. **Data processing inequality** : $X \rightarrow Y \rightarrow Z \Rightarrow I(X; Y) \geq I(X; Z)$

Propriétés de la divergence KL

1. **Non-négativité** : $D_{\text{KL}}(p\|q) \geq 0$
2. **Asymétrie** : $D_{\text{KL}}(p\|q) \neq D_{\text{KL}}(q\|p)$
3. **Annulation** : $D_{\text{KL}}(p\|q) = 0 \Leftrightarrow p = q$
4. **Pas une distance** : ne vérifie ni la symétrie ni l'inégalité triangulaire

Propriétés de l'entropie différentielle

1. **Peut être négative** : $h(X)$ peut être < 0
2. **Invariance par translation** : $h(X + a) = h(X)$
3. **Mise à l'échelle** : $h(aX) = h(X) + \log |a|$
4. **Maximum pour gaussienne** : sous contrainte de variance fixée

Questions Types d'Examen

Questions conceptuelles

Sur l'entropie

1. Définir l'entropie et expliquer ses interprétations (incertitude, bits moyens, etc.)
2. Quelle distribution maximise l'entropie pour un ensemble fini de N symboles ?
3. Pourquoi $H(X|Y) \leq H(X)$? Donner une interprétation intuitive
4. Différence entre entropie discrète et entropie différentielle
5. Que représente $H(X, Y)$ versus $H(X) + H(Y)$?

Sur l'information mutuelle

1. Qu'est-ce que l'information mutuelle et que mesure-t-elle ?
2. Pourquoi $I(X; Y) = 0$ signifie-t-il que X et Y sont indépendants ?
3. Interpréter $I(X; Y) = H(X) - H(X|Y)$
4. Expliquer le principe du data processing inequality
5. Relation entre information mutuelle et divergence KL

Sur les divergences

1. Définir la divergence KL et ses interprétations
2. Pourquoi la KL divergence n'est-elle pas une distance ?
3. Quelle est la différence entre $D_{\text{KL}}(p\|q)$ et $D_{\text{KL}}(q\|p)$?
4. Lien entre KL divergence et cross-entropy
5. Interprétation de la KL divergence en théorie du codage

Questions de calcul

Calculs d'entropie

1. Calculer l'entropie d'une variable binaire avec $P(X = 1) = 0.3$
2. Pour X uniforme sur $\{1, 2, 3, 4\}$, calculer $H(X)$
3. Soit $X \sim \text{Bernoulli}(0.5)$ et $Y \sim \text{Bernoulli}(0.5)$ indépendants. Calculer $H(X, Y)$
4. Calculer l'entropie différentielle de $X \sim \mathcal{N}(0, 4)$

Calculs d'information mutuelle

1. Pour X et Y indépendants, que vaut $I(X; Y)$?
2. Si $Y = 2X$, que vaut $I(X; Y)$?
3. Calculer $I(X; Y)$ pour une distribution jointe donnée

Calculs de divergence

1. Calculer $D_{\text{KL}}(p\|q)$ pour deux distributions binaires données
2. Calculer $H(p, q)$ et vérifier $H(p, q) = H(p) + D_{\text{KL}}(p\|q)$

Questions de démonstration

Démonstrations essentielles

1. Démontrer la règle de chaîne : $H(X, Y) = H(X) + H(Y|X)$
2. Montrer que $H(X|Y) \leq H(X)$ (le conditionnement réduit l'entropie)
3. Prouver que $I(X; Y) \geq 0$
4. Démontrer le data processing inequality
5. Montrer que la distribution uniforme maximise l'entropie

Démonstrations pour variables continues

1. Calculer l'entropie différentielle d'une gaussienne $\mathcal{N}(0, \sigma^2)$
2. Montrer que $h(aX) = h(X) + \log |a|$
3. Prouver que $h(X + a) = h(X)$

Questions sur le codage

Codage de Huffman

1. Appliquer l'algorithme de Huffman à une distribution donnée
2. Calculer la longueur moyenne d'un code de Huffman
3. Comparer la longueur moyenne avec l'entropie de la source

Codes préfixes

1. Qu'est-ce qu'un code préfixe et pourquoi est-il important ?
2. Vérifier si un code donné est un code préfixe
3. Donner un exemple de code qui n'est pas préfixe et montrer le problème de décodage

Compression

1. Calculer le taux de compression pour un exemple donné
2. Expliquer pourquoi $H(X)$ représente la longueur minimale moyenne
3. Différence entre compression sans perte et avec perte

Questions d'application

Machine Learning

1. Expliquer le rôle de la cross-entropy comme fonction de perte
2. Comment utiliser l'information mutuelle pour la sélection de features ?
3. Rôle de la divergence KL dans les VAEs

Théorie de l'information

1. Expliquer le lien entre entropie et quantité d'information
2. Interpréter la divergence KL en termes de bits supplémentaires
3. Application du data processing inequality aux réseaux de neurones

Tableaux Récapitulatifs

Entropie : comparaison discret vs continu

Propriété	Entropie discrète $H(X)$	Entropie différentielle $h(X)$
Notation	H (majuscule)	h (minuscule)
Formule	$-\sum_x p(x) \log p(x)$	$-\int f(x) \log f(x) dx$
Signe	Toujours ≥ 0	Peut être < 0
Unités	Bits (ou nats)	Pas d'unité absolue
Interprétation	Nombre moyen de bits	Incertitude relative
Translation	N/A	Invariant : $h(X + a) = h(X)$
Mise à l'échelle	N/A	$h(aX) = h(X) + \log a $

Relation	Formule	Interprétation
----------	---------	----------------

Relations fondamentales

Relation	Formule	Interprétation
Règle de chaîne	$H(X, Y) = H(X) + H(Y X)$	Décomposition de l'entropie jointe
Info mutuelle 1	$I(X; Y) = H(X) - H(X Y)$	Réduction d'incertitude
Info mutuelle 2	$I(X; Y) = H(X) + H(Y) - H(X, Y)$	En termes d'entropies
Cross-entropy	$H(p, q) = H(p) + D_{\text{KL}}(p q)$	Décomposition
Conditionnement	$H(X) \geq H(X Y)$	Conditionnement réduit l'entropie

Inégalités importantes

Inégalité	Condition d'égalité	Signification
$H(X) \geq 0$	X déterministe	Non-négativité
$H(X Y) \leq H(X)$	$X \perp Y$	Conditionnement réduit
$H(X, Y) \leq H(X) + H(Y)$	$X \perp Y$	Sous-additivité
$I(X; Y) \geq 0$	$X \perp Y$	Non-négativité
$D_{\text{KL}}(p q) \geq 0$	$p = q$	Inégalité de Gibbs
$I(X; Y) \geq I(X; Z)$ pour $X \rightarrow Y \rightarrow Z$	$X \leftrightarrow Y \leftrightarrow Z$	Data processing

Cas Particuliers Importants

Variables binaires

Variable de Bernoulli : $X \in \{0, 1\}$ avec $P(X = 1) = \theta$

$$H(X) = H(\theta) = -\theta \log \theta - (1 - \theta) \log(1 - \theta)$$

- Maximum en $\theta = 0.5$: $H(0.5) = 1$ bit
- $H(0) = H(1) = 0$
- Symétrie : $H(\theta) = H(1 - \theta)$

Variables gaussiennes

Gaussienne univariée : $X \sim \mathcal{N}(\mu, \sigma^2)$

$$h(X) = \frac{1}{2} \log_2(2\pi e \sigma^2)$$

- Ne dépend pas de μ
- Augmente avec σ (plus de dispersion = plus d'entropie)

Gaussienne multivariée : $X \sim \mathcal{N}(\mu, \Sigma)$ avec $X \in \mathbb{R}^n$

$$h(X) = \frac{n}{2} \log_2(2\pi e) + \frac{1}{2} \log_2 |\Sigma|$$

Variables indépendantes

Si $X \perp Y$:

- $H(X, Y) = H(X) + H(Y)$
- $H(X|Y) = H(X)$ et $H(Y|X) = H(Y)$
- $I(X; Y) = 0$
- $p(x, y) = p(x)p(y)$

Conseils pour l'Examen

Stratégies de résolution

Pour les calculs d'entropie

1. **Identifier le type** : discrète ou continue ?
2. **Vérifier** : $\sum p_i = 1$ ou $\int f(x)dx = 1$
3. **Appliquer la formule** : $H(X) = -\sum p_i \log p_i$
4. **Unités** : préciser bits ou nats selon la base du log

Pour les preuves

1. **Commencer par les définitions** formelles
2. **Utiliser les propriétés** connues (règle de chaîne, etc.)
3. **Manipulations algébriques** : $\log(a/b) = \log a - \log b$
4. **Inégalités** : Jensen, Gibbs, etc.

Pour le codage de Huffman

1. **Ordonner** les symboles par probabilité décroissante
2. **Fusionner** itérativement les deux plus petits
3. **Assigner** 0 et 1 aux branches
4. **Lire** les codes de la racine aux feuilles
5. **Calculer** $\ell_{av} = \sum p_i \ell_i$

Erreurs communes à éviter

1. **Confondre** $H(X|Y)$ et $H(Y|X)$ (pas symétriques !)
2. **Oublier** que $I(X; Y) = I(Y; X)$ (symétrique)
3. **Penser** que $D_{\text{KL}}(p||q) = D_{\text{KL}}(q||p)$ (faux !)
4. **Croire** que l'entropie différentielle est toujours positive (faux)
5. **Confondre** $H(p, q)$ et $D_{\text{KL}}(p||q)$
6. **Oublier** la convention $0 \log 0 = 0$

Vérifications rapides

- **Somme de probabilités** : toujours vérifier $\sum p_i = 1$
- **Non-négativité** : $H(X) \geq 0$, $I(X; Y) \geq 0$, $D_{\text{KL}} \geq 0$
- **Bornes** : $H(X) \leq \log |\mathcal{X}|$
- **Cohérence** : si $X \perp Y$, alors $I(X; Y) = 0$
- **Unités** : toujours préciser bits ou nats

Ressources et Approfondissements

Concepts à maîtriser absolument

1. **Entropie** : définition, interprétations, propriétés
2. **Règle de chaîne** : pour probabilités et entropies
3. **Information mutuelle** : définitions multiples, lien avec entropie
4. **Divergence KL** : définition, asymétrie, interprétations
5. **Codage de Huffman** : algorithme, optimalité
6. **Data processing inequality** : énoncé et conséquences

Pour aller plus loin

Sujets avancés

- **Capacité de canal** (théorème de Shannon-Hartley)
- **Théorie rate-distortion** pour la compression avec perte
- **Entropie conditionnelle maximale** (MaxEnt)
- **Information mutuelle normalisée**
- **Divergences de Rényi et Tsallis**
- **Information de Fisher**

Applications modernes

- **Deep learning** : information bottleneck theory
- **Causal inference** : conditional independence testing
- **Neurosciences** : quantification de l'information neuronale
- **Économie** : théorie de l'information économique
- **Génomique** : mesure de l'information génétique