

# Table of contents

|                                                                            |          |
|----------------------------------------------------------------------------|----------|
| <b>Fondamentaux de la Théorie de l'Information pour la Data Science</b>    | <b>2</b> |
| Introduction et Contexte . . . . .                                         | 2        |
| Vue d'ensemble . . . . .                                                   | 2        |
| Applications en Data Science . . . . .                                     | 2        |
| Notations et Conventions . . . . .                                         | 2        |
| Fondements Probabilistes . . . . .                                         | 3        |
| Rappel : Espérance mathématique . . . . .                                  | 3        |
| Règle de Chaîne pour les Probabilités . . . . .                            | 4        |
| Exemples de Décompositions . . . . .                                       | 5        |
| Entropie : Mesure de l'Incertainité . . . . .                              | 6        |
| Entropie Discrète . . . . .                                                | 6        |
| Cas Binaire : Variable de Bernoulli . . . . .                              | 7        |
| Entropies Multivariées . . . . .                                           | 9        |
| Propriétés Fondamentales de l'Entropie . . . . .                           | 10       |
| Application aux Vecteurs d'Images . . . . .                                | 15       |
| Applications au Codage et à la Compression . . . . .                       | 16       |
| Concepts Fondamentaux du Codage . . . . .                                  | 16       |
| Assignation Optimale de Codes . . . . .                                    | 17       |
| Codage de Huffman . . . . .                                                | 19       |
| Codes Préfixes . . . . .                                                   | 23       |
| Exemple Complet : Image à 8 Niveaux . . . . .                              | 25       |
| Complexité et Limitations . . . . .                                        | 26       |
| Mesures de Divergence et Similarité . . . . .                              | 28       |
| Divergence de Kullback-Leibler (KL) . . . . .                              | 28       |
| Exemple Numérique de KL Divergence . . . . .                               | 32       |
| Cross-Entropy (Entropie Croisée) . . . . .                                 | 33       |
| Information Mutuelle . . . . .                                             | 36       |
| Définitions et Formulations . . . . .                                      | 36       |
| Propriétés Fondamentales . . . . .                                         | 37       |
| Relations avec l'Entropie . . . . .                                        | 38       |
| Information Mutuelle Conditionnelle . . . . .                              | 39       |
| Règle de Chaîne pour l'Information Mutuelle . . . . .                      | 41       |
| Décompositions Complexes . . . . .                                         | 43       |
| Inégalité de Traitement des Données (Data Processing Inequality) . . . . . | 43       |
| Variables Continues : Entropie Différentielle . . . . .                    | 46       |
| Motivation et Limite . . . . .                                             | 46       |
| Définition de l'Entropie Différentielle . . . . .                          | 48       |
| Entropie Différentielle d'une Gaussienne . . . . .                         | 49       |
| Propriétés de l'Entropie Différentielle . . . . .                          | 51       |

|                                                      |    |
|------------------------------------------------------|----|
| Applications en Machine Learning . . . . .           | 54 |
| Fonctions de Perte . . . . .                         | 54 |
| Sélection de Features . . . . .                      | 55 |
| Régularisation et Variational Autoencoders . . . . . | 57 |
| Aide-Mémoire et Synthèse . . . . .                   | 58 |
| Formules Essentielles . . . . .                      | 58 |
| Propriétés Clés à Retenir . . . . .                  | 61 |
| Questions Types d'Examen . . . . .                   | 62 |
| Tableaux Récapitulatifs . . . . .                    | 64 |
| Cas Particuliers Importants . . . . .                | 65 |
| Conseils pour l'Examen . . . . .                     | 66 |
| Ressources et Approfondissements . . . . .           | 67 |

## Fondamentaux de la Théorie de l'Information pour la Data Science

### Introduction et Contexte

#### Vue d'ensemble

La **théorie de l'information**, développée par Claude Shannon en 1948, fournit un cadre mathématique rigoureux pour quantifier l'information, l'incertitude et la dépendance entre variables aléatoires.

#### Applications en Data Science

Les concepts de la théorie de l'information sont fondamentaux dans de nombreux domaines :

- **Compression de données** : optimisation du stockage et de la transmission
- **Apprentissage automatique** : fonctions de perte, régularisation
- **Sélection de features** : identification des variables les plus informatives
- **Mesure de similarité** : comparaison entre distributions
- **Optimisation de réseaux de neurones** : théorie de l'information bottleneck
- **Théorie de la communication** : capacité de canal, codage

#### Notations et Conventions

##### Variables et ensembles

- $X, Y, Z$  : variables aléatoires (majuscules)
- $x, y, z$  : valeurs prises par les variables (minuscules)

- $\mathcal{X}, \mathcal{Y}, \mathcal{Z}$  : ensembles de valeurs possibles
- $|\mathcal{X}|$  : cardinalité de l'ensemble  $\mathcal{X}$

## Distributions de probabilité

- $p_X(x)$  ou  $p(x)$  : fonction de masse de probabilité (pmf) ou densité (pdf)
- $p_{X,Y}(x,y)$  ou  $p(x,y)$  : distribution jointe
- $p_{X|Y}(x|y)$  ou  $p(x|y)$  : distribution conditionnelle
- $\mathbb{P}[X = x]$  : probabilité que  $X$  prenne la valeur  $x$
- $\mathbb{E}_p[f(X)]$  : espérance de  $f(X)$  sous la distribution  $p$

## Symboles spéciaux

- $X \perp Y$  :  $X$  et  $Y$  sont indépendants
- $X \perp Z|Y$  :  $X$  et  $Z$  sont conditionnellement indépendants sachant  $Y$
- $X \rightarrow Y \rightarrow Z$  : chaîne de Markov
- $\log$  : logarithme (base 2 sauf indication contraire)
- $\ln$  : logarithme naturel (base  $e$ )

## Unités de mesure

- **Bits** : logarithme en base 2 ( $\log_2$ )
- **Nats** : logarithme naturel ( $\ln$  ou  $\log_e$ )
- Notation parfois utilisée :  $H_\alpha(X)$  où  $\alpha$  spécifie la base

## Fondements Probabilistes

### Rappel : Espérance mathématique

#### Définition générale

Pour une variable aléatoire discrète  $X$  et une fonction  $g$  :

$$\mathbb{E}_{p_X}[g(X)] = \sum_{x \in \mathcal{X}} p_X(x)g(x)$$

Pour une variable continue :

$$\mathbb{E}_{f_X}[g(X)] = \int_{\mathcal{X}} f_X(x)g(x)dx$$

## Propriétés

- Linéarité :  $\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$
- Pour variables indépendantes :  $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$

## Règle de Chaîne pour les Probabilités

### Cas général : N variables

Pour  $N$  variables aléatoires  $X_1, X_2, \dots, X_n$  :

$$p(x_1, x_2, \dots, x_n) = p(x_1) \cdot p(x_2|x_1) \cdot p(x_3|x_2, x_1) \cdots p(x_n|x_{n-1}, \dots, x_1)$$

### Forme compacte :

$$p(x_1, x_2, \dots, x_n) = \prod_{i=1}^n p(x_i|x_{i-1}, \dots, x_1)$$

avec la convention que  $p(x_1|\emptyset) = p(x_1)$ .

### Cas particulier : 2 variables

$$p(x_1, x_2) = p(x_1)p(x_2|x_1) = p(x_2)p(x_1|x_2)$$

Cette égalité illustre la symétrie de la règle de chaîne.

## Variables indépendantes

### Définition de l'indépendance

Deux variables  $X_1$  et  $X_2$  sont **indépendantes**, noté  $X_1 \perp X_2$ , si et seulement si :

$$p(x_1, x_2) = p(x_1) \cdot p(x_2)$$

### Conséquence

Pour des variables indépendantes :

$$p(x_2|x_1) = p(x_2) \quad \text{et} \quad p(x_1|x_2) = p(x_1)$$

### Généralisation à N variables i.i.d.

Pour  $N$  variables **identiquement et indépendamment distribuées** (i.i.d.) :

$$p(x_1, x_2, \dots, x_n) = \prod_{i=1}^n p(x_i) = [p(x)]^n$$

### Exemples de Décompositions

#### Trois variables : différentes structures

##### Chaîne linéaire




$$p(x, y, z) = p(x) \cdot p(y|x) \cdot p(z|y, x)$$

Si  $X \rightarrow Y \rightarrow Z$  forme une chaîne de Markov :  $p(z|y, x) = p(z|y)$

##### Indépendance complète

$$p(x, y, z) = p(x) \cdot p(y) \cdot p(z)$$

##### Indépendance conditionnelle (parent commun)



$$p(x, y, z) = p(y) \cdot p(x|y) \cdot p(z|y)$$

Si  $X \perp Z|Y$  :  $X$  et  $Z$  sont conditionnellement indépendants sachant  $Y$

### **Autres structures**

**Décomposition alternative 1 :**

$$p(x, y, z) = p(z) \cdot p(y|z) \cdot p(x|y, z)$$

**Décomposition alternative 2 :**

$$p(x, y, z) = p(z|x, y) \cdot p(x) \cdot p(y)$$

**Décomposition avec indépendance conditionnelle :**

$$p(x, y, z) = p(z) \cdot p(x|z) \cdot p(y|z)$$

(si  $X \perp Y|Z$ )

## **Entropie : Mesure de l'Incertitude**

### **Entropie Discrète**

#### **Définition formelle**

#### **Pour une variable aléatoire discrète**

Soit  $X$  une variable aléatoire discrète prenant ses valeurs dans  $\mathcal{X} = \{x_1, x_2, \dots, x_n\}$  avec une fonction de masse de probabilité  $p_X(x)$ .

L'**entropie** de  $X$  est définie par :

$$H(X) = - \sum_{x \in \mathcal{X}} p_X(x) \log_2 p_X(x)$$

#### **Forme espérance**

$$H(X) = \mathbb{E}_{p_X}[-\log_2 p_X(X)] = -\mathbb{E}_{p_X}[\log_2 p_X(X)]$$

#### **Convention importante**

Par convention :  $0 \log_2 0 = 0$  (car  $\lim_{p \rightarrow 0^+} p \log p = 0$ )

## Interprétations

### Interprétation informationnelle

L'entropie mesure :

- L'**incertitude** moyenne associée à la variable aléatoire  $X$
- Le **nombre moyen de bits** nécessaires pour encoder de manière optimale les réalisations de  $X$
- Le **caractère aléatoire** (randomness) de la distribution

### Interprétation en théorie du codage

$H(X)$  représente la **longueur moyenne minimale** (en bits) d'un code optimal pour encoder les symboles de  $X$ .

### Propriété clé

$H(X)$  dépend **uniquement** de la distribution  $p_X(x)$ , pas des valeurs particulières que  $X$  peut prendre.

### Notations équivalentes

Les notations suivantes sont interchangeables :

- $H(X)$  : entropie de la variable  $X$
- $H(p)$  : entropie de la distribution  $p$
- $H(p_X)$  ou  $H(p(x))$  : entropie de la pmf  $p_X(x)$

### Cas Binaire : Variable de Bernoulli

#### Définition

Une variable **binaire**  $X$  prend ses valeurs dans  $\mathcal{X} = \{0, 1\}$  avec :

$$\begin{aligned}\mathbb{P}[X = 1] &= \theta \\ \mathbb{P}[X = 0] &= 1 - \theta\end{aligned}$$

**Forme compacte :**

$$\mathbb{P}[X = x] = \theta^x (1 - \theta)^{1-x}, \quad x \in \{0, 1\}$$

## Formule de l'entropie binaire

$$H(X) = -\theta \log_2 \theta - (1 - \theta) \log_2 (1 - \theta)$$

On note souvent cette fonction :  $H(\theta)$  ou  $H_2(\theta)$  (fonction d'entropie binaire).

## Propriétés de $H(\theta)$

### Symétrie

La fonction d'entropie binaire est **symétrique** autour de  $\theta = 0.5$  :

$$H(\theta) = H(1 - \theta)$$

### Maximum

Le maximum est atteint en  $\theta = 0.5$  :

$$\max_{\theta \in [0,1]} H(\theta) = H(0.5) = 1 \text{ bit}$$

**Principe fondamental** : L'entropie est maximale lorsque les deux symboles sont **équiprobables**.

### Cas limites

- $H(0) = H(1) = 0$  : aucune incertitude (variable déterministe)
- $H(\theta) > 0$  pour  $\theta \in (0, 1)$  : présence d'incertitude

### Exemples numériques

| $\theta$ | $H(\theta)$ (bits) |
|----------|--------------------|
| 0.11     | 0.50               |
| 0.25     | 0.81               |
| 0.50     | 1.00               |
| 0.75     | 0.81               |
| 0.89     | 0.50               |



## Entropies Multivariées

### Entropie Jointe

#### Définition

Pour deux variables aléatoires discrètes  $X \in \mathcal{X}$  et  $Y \in \mathcal{Y}$  :

$$H(X, Y) = - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p_{X,Y}(x, y) \log_2 p_{X,Y}(x, y)$$

#### Forme espérance

$$H(X, Y) = -\mathbb{E}_{p_{X,Y}}[\log_2 p_{X,Y}(X, Y)]$$

#### Propriété de symétrie

$$H(X, Y) = H(Y, X)$$

#### Généralisation à N variables

$$H(X_1, \dots, X_N) = - \sum_{x_1 \in \mathcal{X}_1} \dots \sum_{x_N \in \mathcal{X}_N} p(x_1, \dots, x_N) \log_2 p(x_1, \dots, x_N)$$

### Entropie Conditionnelle

#### Définition générale

L'entropie de  $X$  sachant  $Y$  est définie par :

$$H(X|Y) = \sum_{y \in \mathcal{Y}} p_Y(y) H(X|Y = y)$$

#### Forme développée

$$H(X|Y) = - \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p_{X,Y}(x, y) \log_2 p_{X|Y}(x|y)$$

## Forme espérance

$$H(X|Y) = -\mathbb{E}_{p_{X,Y}}[\log_2 p_{X|Y}(X|Y)]$$

## Entropie conditionnelle pour une valeur fixée

Pour une valeur particulière  $Y = y$  :

$$H(X|Y = y) = -\sum_{x \in \mathcal{X}} p_{X|Y}(x|y) \log_2 p_{X|Y}(x|y)$$

## Développement complet

$$\begin{aligned} H(X|Y) &= -\sum_{y \in \mathcal{Y}} p_Y(y) \left[ \sum_{x \in \mathcal{X}} p_{X|Y}(x|y) \log_2 p_{X|Y}(x|y) \right] \\ &= -\sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p_{X,Y}(x,y) \log_2 p_{X|Y}(x|y) \end{aligned}$$

## Asymétrie

**Attention :** L'entropie conditionnelle n'est **pas symétrique** :

$$H(X|Y) \neq H(Y|X)$$

en général.

## Propriétés Fondamentales de l'Entropie

### Non-négativité

### Énoncé

Pour toute variable aléatoire discrète :

$$H(X) \geq 0$$

$$H(X, Y) \geq 0$$

$$H(X|Y) \geq 0$$

### Justification

Puisque  $0 \leq p_X(x) \leq 1$ , on a  $\log_2 p_X(x) \leq 0$ .

Donc :  $-p_X(x) \log_2 p_X(x) \geq 0$  pour tout  $x$ .

Par conséquent :  $H(X) = \sum_x [-p_X(x) \log_2 p_X(x)] \geq 0$ .

Le même raisonnement s'applique à  $H(X, Y)$  et  $H(X|Y)$ .

### Cas d'égalité

$$H(X) = 0 \quad \Leftrightarrow \quad X \text{ est déterministe}$$

C'est-à-dire  $\exists x_0 : p_X(x_0) = 1$  et  $p_X(x) = 0$  pour  $x \neq x_0$ .

### Règle de Chaîne pour l'Entropie

#### Cas de 2 variables

En utilisant la règle de chaîne des probabilités :

$$p(x, y) = p(x|y)p(y) = p(y|x)p(x)$$

On obtient :

$$H(X, Y) = H(X) + H(Y|X) = H(Y) + H(X|Y)$$

### Démonstration

$$\begin{aligned} -\log_2 p_{X,Y}(x, y) &= -\log_2 [p_{Y|X}(y|x)p_X(x)] \\ &= -\log_2 p_{Y|X}(y|x) - \log_2 p_X(x) \end{aligned}$$

En prenant l'espérance :

$$\begin{aligned} H(X, Y) &= \mathbb{E}_{p_{X,Y}}[-\log_2 p_{X,Y}(X, Y)] \\ &= \mathbb{E}_{p_{X,Y}}[-\log_2 p_X(X)] + \mathbb{E}_{p_{X,Y}}[-\log_2 p_{Y|X}(Y|X)] \\ &= H(X) + H(Y|X) \end{aligned}$$

### Cas général de N variables

Pour la distribution jointe :

$$p(x_1, \dots, x_N) = p(x_1) \prod_{i=2}^N p(x_i | x_{i-1}, \dots, x_1)$$

On a :

$$H(X_1, X_2, \dots, X_N) = \sum_{i=1}^N H(X_i | X_{i-1}, \dots, X_1)$$

avec la convention  $H(X_1 | \emptyset) = H(X_1)$ .

### Conséquence pour variables indépendantes

Si  $X$  et  $Y$  sont indépendantes ( $X \perp Y$ ), alors  $H(Y|X) = H(Y)$ , et donc :

$$H(X, Y) = H(X) + H(Y)$$

Plus généralement :

$$H(X, Y) \leq H(X) + H(Y)$$

avec égalité si et seulement si  $X \perp Y$ .

### Augmentation de l'Entropie par Ajout de Variables

#### Principe

Ajouter une nouvelle variable aléatoire **augmente** (ou laisse inchangée) l'entropie jointe :

$$H(X) \leq H(X, Y) \leq H(X, Y, Z) \leq \dots$$

### Conditions d'égalité

$$H(X) = H(X, Y) \Leftrightarrow Y = f(X)$$

où  $f$  est une fonction déterministe (i.e.,  $Y$  est complètement déterminé par  $X$ ).

$$H(X, Y) = H(X, Y, Z) \Leftrightarrow Z = g(X, Y)$$

où  $g$  est une fonction déterministe.

### Justification

En utilisant la règle de chaîne :

$$H(X, Y) = H(X) + H(Y|X)$$

Puisque  $H(Y|X) \geq 0$ , on a  $H(X, Y) \geq H(X)$ .

L'égalité est atteinte si et seulement si  $H(Y|X) = 0$ , ce qui signifie que  $Y$  est déterministement déterminé par  $X$ .

### Conditionnement Réduit l'Entropie

#### Principe fondamental

Le conditionnement **réduit** (ou laisse inchangée) l'entropie :

$$H(X) \geq H(X|Y) \geq H(X|Y, Z) \geq \dots$$

#### Interprétation intuitive

Connaître  $Y$  ne peut que **réduire l'incertitude** sur  $X$  (ou la laisser inchangée si  $X$  et  $Y$  sont indépendants).

### Conditions d'égalité

$$H(X) = H(X|Y) \Leftrightarrow X \perp Y$$

( $X$  et  $Y$  sont indépendants)

$$H(X|Y) = H(X|Y, Z) \Leftrightarrow X \perp Z|Y$$

( $X$  et  $Z$  sont conditionnellement indépendants sachant  $Y$ )

### Démonstration

En utilisant la règle de chaîne :

$$H(X, Y) = H(X) + H(Y|X) = H(Y) + H(X|Y)$$

Donc :

$$H(X) - H(X|Y) = H(Y) - H(Y|X) = I(X; Y)$$

Puisque  $I(X; Y) \geq 0$  (voir section sur l'information mutuelle), on a :

$$H(X) \geq H(X|Y)$$

### Entropie Maximale

#### Théorème

Pour une variable aléatoire discrète  $X$  prenant ses valeurs dans un ensemble  $\mathcal{X}$  de cardinalité  $|\mathcal{X}| = N$  :

$$H(X) \leq \log_2 N$$

#### Condition d'égalité

L'égalité est atteinte si et seulement si  $X$  suit une **distribution uniforme** :

$$p_X(x) = \frac{1}{N} = \frac{1}{|\mathcal{X}|}, \quad \forall x \in \mathcal{X}$$

## Principe

Parmi toutes les distributions sur un ensemble fini, la distribution **uniforme** maximise l'entropie.

## Esquisse de démonstration

Soit  $\mathcal{X} = \{x_1, x_2, \dots, x_N\}$  et  $p_i = \mathbb{P}[X = x_i]$ .

**Objectif :** Maximiser  $H(X) = -\sum_{i=1}^N p_i \log_2 p_i$  sous la contrainte  $\sum_{i=1}^N p_i = 1$  et  $p_i \geq 0$ .

En utilisant les multiplicateurs de Lagrange, on montre que l'optimum est atteint pour  $p_i = 1/N$  pour tout  $i$ .

**Valeur maximale :**

$$H_{\max} = -\sum_{i=1}^N \frac{1}{N} \log_2 \frac{1}{N} = \log_2 N$$

## Application aux Vecteurs d'Images

### Représentation vectorielle

Une image peut être représentée comme un vecteur de pixels :

$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_N \end{pmatrix} \in \mathcal{X}^N$$

où  $N = n \times m$  est le nombre total de pixels.

### Modèle d'indépendance

Si on suppose les pixels **indépendants** :

$$p(x_1, x_2, \dots, x_N) = \prod_{i=1}^N p(x_i)$$

Alors :

$$H(X_1, X_2, \dots, X_N) = \sum_{i=1}^N H(X_i)$$

**Limitation :** Cette hypothèse est **irréaliste** car les pixels voisins sont généralement corrélés.

## Modèle de Markov

Un modèle plus réaliste est une chaîne de Markov d'ordre  $k$  (par exemple,  $k = 2$ ) :

$$p(x_i | x_{i-1}, x_{i-2}, \dots, x_1) = p(x_i | x_{i-1}, x_{i-2})$$

**Entropie totale :**

$$H(X_1, X_2, \dots, X_N) = \sum_{i=1}^N H(X_i | X_{i-1}, \dots, X_1)$$

Pour un modèle de Markov d'ordre 2 :

$$H(X_1, X_2, \dots, X_N) = H(X_1) + H(X_2 | X_1) + \sum_{i=3}^N H(X_i | X_{i-1}, X_{i-2})$$

## Applications au Codage et à la Compression

### Concepts Fondamentaux du Codage

#### Schéma de compression

#### Compression sans perte (Lossless)

$$X \xrightarrow{\text{Encodeur}} R \xrightarrow{\text{Décodeur}} \hat{X}$$

**Propriété :**

$$\hat{X} = X \quad \Rightarrow \quad D = \mathbb{E}[\|X - \hat{X}\|^2] = 0$$

La reconstruction est **parfaite**.



## Compression avec perte (Lossy)

$$X \xrightarrow{\text{Encodeur}} R \xrightarrow{\text{Décodeur}} \hat{X}$$

Propriété :

$$\hat{X} \neq X \Rightarrow D = \mathbb{E}[\|X - \hat{X}\|^2] > 0$$

On accepte une **distorsion** pour un meilleur taux de compression.

## Taux de compression

### Définition

Le **ratio de compression** (Compression Ratio) est défini par :

$$CR = \frac{\text{Taille originale (en bits)}}{\text{Taille compressée (en bits)}}$$

Un  $CR > 1$  indique une compression effective.

## Exemples de taux réels

Pour images réelles :

- Compression sans perte :  $CR \approx 2$  (PNG, FLAC)
- Compression avec perte :
  - JPEG :  $CR = 10$  à  $50$
  - JPEG 2000 :  $CR$  jusqu'à  $150$
  - Codecs vidéo modernes :  $CR > 100$

## Assignation Optimale de Codes

### Principe de base

## Histogramme et modèle

Pour une image représentée par  $N$  pixels :

$$p_i = \mathbb{P}\{X(i, j) = k\} = \frac{\text{Nombre de pixels d'intensité } k}{N}$$

**Hypothèse simplificatrice** (souvent irréaliste) : les pixels sont **discrets** et **indépendants**.

## Lien avec l'entropie

Pour des symboles discrets et indépendants :

$$H(X) = - \sum_{i=0}^{L-1} p_i \log_2 p_i = \ell_{\text{av}}$$

où  $\ell_{\text{av}}$  est la **longueur moyenne minimale** de code (en bits par symbole).

## Longueur de code optimale

### Relation probabilité-longueur

Pour encoder optimalement un symbole de probabilité  $p_i$ , la longueur de code optimale est :

$$\ell_i \approx -\log_2 p_i = \log_2 \frac{1}{p_i}$$

Cette relation découle du théorème de codage de source de Shannon.

## Exemples numériques

| Probabilité $p_i$ | $\ell_i$ (bits) |
|-------------------|-----------------|
| $0.5 = 2^{-1}$    | $\log_2 2 = 1$  |
| $0.25 = 2^{-2}$   | $\log_2 4 = 2$  |
| $0.125 = 2^{-3}$  | $\log_2 8 = 3$  |
| $0.0625 = 2^{-4}$ | $\log_2 16 = 4$ |

## Codage à longueur variable

## Principe fondamental

Pour minimiser la longueur moyenne du code :

- Les symboles **plus fréquents** reçoivent des codes **plus courts**
- Les symboles **moins fréquents** reçoivent des codes **plus longs**

Ce principe est à la base du **codage à longueur variable** (Variable Length Coding).

## Longueur moyenne

Pour un code optimal :

$$\ell_{\text{av}} = \sum_{i=0}^{L-1} p_i \ell_i \approx H(X)$$

Plus précisément, le théorème de Shannon garantit :

$$H(X) \leq \ell_{\text{av}} < H(X) + 1$$

## Codage de Huffman

### Principe général

### Objectif

Concevoir un **code préfixe** qui approche l'entropie de la source, c'est-à-dire un code de longueur moyenne minimale.

### Optimalité

Le codage de Huffman est un code **optimal** pour l'encodage symbole par symbole de sources discrètes.

### Hypothèses

Le codage de Huffman repose sur les hypothèses suivantes :

1. **Indépendance** : tous les symboles sont indépendants (hypothèse simplificatrice)
2. **Symbole par symbole** : encodage individuel de chaque symbole
3. **Connaissance de la distribution** : la pmf  $p(x)$  est connue (peut être estimée par l'histogramme)

## Algorithme de construction

### Étapes de l'algorithme

**Étape 1 : Initialisation** Arranger les symboles par **probabilité décroissante**. Considérer chaque symbole comme un nœud feuille.

**Étape 2 : Fusion itérative** Répéter jusqu'à obtenir un seul nœud racine : - Sélectionner les deux nœuds de **plus faible probabilité** - Les fusionner en un nouveau nœud de probabilité égale à leur somme

**Étape 3 : Assignment des codes** Assigner le bit **0** à la branche supérieure et **1** à la branche inférieure (ou l'inverse)

**Étape 4 : Lecture des codes** Lire le code de chaque symbole en parcourant le chemin de la racine à la feuille

### Exemple détaillé


#### Données

Considérons 8 symboles avec les probabilités suivantes :

| Symbole | Probabilité |
|---------|-------------|
| 1       | 0.25        |
| 2       | 0.21        |
| 0       | 0.19        |
| 3       | 0.16        |
| 4       | 0.08        |
| 5       | 0.06        |
| 6       | 0.03        |
| 7       | 0.02        |

Vérification :  $\sum p_i = 1.00$

## Construction de l'arbre



## Codes résultants

| Symbole | Probabilité | Code Huffman | Longueur |
|---------|-------------|--------------|----------|
| 1       | 0.25        | 10           | 2        |
| 2       | 0.21        | 01           | 2        |
| 0       | 0.19        | 00           | 2        |
| 3       | 0.16        | 110          | 3        |
| 4       | 0.08        | 1110         | 4        |
| 5       | 0.06        | 11110        | 5        |
| 6       | 0.03        | 111111       | 6        |
| 7       | 0.02        | 111110       | 6        |

**Propriété observée :** Les symboles avec la **plus haute probabilité** ont la **longueur la plus courte**.

## Calculs de performances

Entropie de la source :

$$H = - \sum_{i=0}^7 p_i \log_2 p_i = 2.6508 \text{ bits/symbole}$$

Longueur moyenne (code Huffman) :

$$\ell_{\text{av}} = \sum_{i=0}^7 p_i \ell_i = 2.7000 \text{ bits/symbole}$$

Efficacité :

$$\eta = \frac{H}{\ell_{\text{av}}} = \frac{2.6508}{2.7000} \approx 0.982 = 98.2\%$$

## Codes Préfixes

### Définition

Un **code préfixe** (prefix code ou prefix-free code) est un code tel qu'**aucun code n'est le préfixe d'un autre code**.

**Formellement :** Pour tous codes distincts  $c_i$  et  $c_j$ ,  $c_i$  n'est pas un préfixe de  $c_j$ .

### Importance

## Décodage unique

Un code préfixe garantit un **décodage unique** sans ambiguïté :

- Pas besoin de délimiteurs entre les codes
- Pas besoin de voir le symbole suivant pour décoder
- Le décodage peut être effectué **instantanément** (symbole par symbole)

## Propriété de Kraft-McMillan

Pour qu'un code préfixe existe avec des longueurs  $\{\ell_1, \dots, \ell_n\}$ , il faut et il suffit que :

$$\sum_{i=1}^n 2^{-\ell_i} \leq 1$$

Cette condition est appelée **inégalité de Kraft**.

## Exemple comparatif

### Code A (NON préfixe)

| Symbole | Code |
|---------|------|
| 1       | 1    |
| 2       | 00   |
| 3       | 11   |
| 4       | 110  |

**Problème :** Le code “1” est un préfixe de “11” et “110”

### Code B (Préfixe)

| Symbole | Code |
|---------|------|
| 1       | 0    |
| 2       | 10   |
| 3       | 110  |
| 4       | 111  |

**Propriété :** Aucun code n'est le préfixe d'un autre



### Test de décodage : séquence “1234321”

**Code A (NON préfixe) :** - Encodage : 100011110110010 ou 1|00|00|110|... ? -  
**Problème :** Ambiguïté de décodage

**Code B (Préfixe) :** - Encodage : 010110111110100 - Décodage : 0|10|110|111|110|10|0  
= 1234321 - **Décodage unique**

### Exemple Complet : Image à 8 Niveaux

#### Configuration

Une image utilise 8 niveaux de gris (3 bits en codage fixe).

#### Table de codage

| Niveau | Probabilité | Code fixe | Code Huffman | Longueur |
|--------|-------------|-----------|--------------|----------|
| 0      | 0.19        | 000       | 00           | 2        |
| 1      | 0.25        | 001       | 10           | 2        |
| 2      | 0.21        | 010       | 01           | 2        |
| 3      | 0.16        | 011       | 110          | 3        |
| 4      | 0.08        | 100       | 1110         | 4        |
| 5      | 0.06        | 101       | 11110        | 5        |
| 6      | 0.03        | 110       | 111111       | 6        |
| 7      | 0.02        | 111       | 111110       | 6        |

#### Analyse des performances

##### Entropie de la source

$$H = - \sum_{i=0}^7 p_i \log_2 p_i = 2.6508 \text{ bits}$$

##### Longueur moyenne : code fixe

$$\ell_{\text{av}}^{\text{fixe}} = 3 \text{ bits}$$

(tous les symboles utilisent 3 bits)

### Longueur moyenne : code variable

$$\ell_{\text{av}}^{\text{var}} = \sum_{i=0}^7 p_i \ell_i = 2.7000 \text{ bits}$$

### Comparaison

| Métrique         | Code fixe | Code Huffman | Entropie |
|------------------|-----------|--------------|----------|
| Longueur moyenne | 3.00      | 2.70         | 2.65     |
| Efficacité       | 88.4%     | 98.2%        | 100%     |

### Impact pratique

#### Gain pour une grande image

Pour une image de  $1000 \times 1000 = 10^6$  pixels :

Différence par pixel :

$$\Delta = 3.00 - 2.70 = 0.30 \text{ bits}$$

Gain total :

$$\text{Gain} = 10^6 \times 0.30 = 3 \times 10^5 \text{ bits} = 37.5 \text{ Ko}$$

#### Par rapport à l'entropie

Différence entre code fixe et entropie :

$$\Delta = 3.00 - 2.65 = 0.35 \text{ bits/pixel}$$

Gain théorique maximal :

$$\text{Gain max} = 10^6 \times 0.35 = 3.5 \times 10^5 \text{ bits} \approx 42.7 \text{ Ko}$$

### Complexité et Limitations

#### Complexité de compression pour images

## Problématique générale

Une image  $X$  peut être vue comme un vecteur :

$$X \sim p_X(x) = p_X(x_1, x_2, \dots, x_N)$$

où  $N$  est le nombre de pixels.

## Défis pratiques

1. **Modélisation complexe** : la distribution jointe  $p_X(x_1, \dots, x_N)$  est en dimension très élevée
2. **Distribution inconnue** : la vraie distribution est généralement inconnue
3. **Hypothèse d'indépendance** : simplifier en supposant les pixels indépendants **augmente l'entropie** (sous-optimal)
4. **Corrélations spatiales** : les pixels voisins sont corrélés, ce qui contredit l'hypothèse d'indépendance

## Théorie de Shannon : codage par blocs

### Codage optimal

La théorie **rate-distortion** de Shannon suggère un **codage par blocs** pour approcher l'entropie :

Encoder des blocs :  $(X_1, \dots, X_k)$  au lieu de symboles individuels

### Problème de complexité

**Codage par blocs de longueur  $k$**  : - Nécessite  $|\mathcal{X}|^k$  codes différents - Complexité **exponentielle** en  $k$

**Exemple** : Pour  $|\mathcal{X}| = 256$  (8 bits) et  $k = 10$  :

$$\text{Nombre de codes} = 256^{10} \approx 10^{24}$$

## Solutions pratiques

## Codage par sous-blocs

Compromis entre optimalité et complexité :

- **JPEG** : blocs de  $8 \times 8$  pixels
- **JPEG 2000** : ondelettes multi-échelles
- **Codecs modernes** : blocs adaptatifs

## Modèles statistiques

Utiliser des modèles pour capturer les dépendances :

- **Modèles de Markov** : dépendance locale
- **Modèles contextuels** : prédiction basée sur le voisinage
- **Réseaux de neurones** : apprentissage de représentations compactes

## Mesures de Divergence et Similarité

### Divergence de Kullback-Leibler (KL)

#### Définition

#### Formulation générale

La **divergence KL** (ou entropie relative) entre deux distributions  $p(x)$  et  $q(x)$  sur le même ensemble  $\mathcal{X}$  est :

$$D_{\text{KL}}(p\|q) = \sum_{x \in \mathcal{X}} p(x) \log_2 \frac{p(x)}{q(x)}$$

#### Forme espérance

$$D_{\text{KL}}(p\|q) = \mathbb{E}_{p(x)} \left[ \log_2 \frac{p(x)}{q(x)} \right]$$

#### Notations alternatives

- $D(p\|q)$  : notation courte
- $D_{\text{KL}}(p\|q)$  : notation explicite
- $KL(p\|q)$  : notation abrégée

## Conventions mathématiques

### Valeurs limites

Pour assurer la cohérence mathématique :

$$0 \log_2 \frac{0}{q(x)} = 0, \quad \forall q(x)$$

(par continuité :  $\lim_{p \rightarrow 0^+} p \log p = 0$ )

$$p(x) \log_2 \frac{p(x)}{0} = +\infty, \quad \forall p(x) > 0$$

**Conséquence :** Si  $\exists x : p(x) > 0$  et  $q(x) = 0$ , alors  $D_{\text{KL}}(p\|q) = +\infty$ .

### Support

Pour que  $D_{\text{KL}}(p\|q)$  soit fini, il faut que :

$$\text{Support}(p) \subseteq \text{Support}(q)$$

C'est-à-dire :  $p(x) > 0 \Rightarrow q(x) > 0$ .

## Propriétés fondamentales

### Non-négativité (Inégalité de Gibbs)

$$D_{\text{KL}}(p\|q) \geq 0$$

avec égalité si et seulement si  $p(x) = q(x)$  pour tout  $x \in \mathcal{X}$ .

### Démonstration (esquisse)

En utilisant l'inégalité de Jensen et la concavité du logarithme :

$$-D_{\text{KL}}(p\|q) = \sum_x p(x) \log \frac{q(x)}{p(x)} \leq \log \sum_x p(x) \frac{q(x)}{p(x)} = \log 1 = 0$$

## Asymétrie

$$D_{\text{KL}}(p\|q) \neq D_{\text{KL}}(q\|p)$$

en général.

**Conséquence :** La divergence KL **n'est pas une distance** au sens mathématique : - Elle n'est pas symétrique - Elle ne vérifie pas l'inégalité triangulaire

## Additivité pour distributions indépendantes

Si  $X \perp Y$  sous  $p$  et sous  $q$  :

$$D_{\text{KL}}(p(x, y)\|q(x, y)) = D_{\text{KL}}(p(x)\|q(x)) + D_{\text{KL}}(p(y)\|q(y))$$

## Interprétation en théorie du codage

### Problème de codage sous-optimal

**Situation :** - **Distribution réelle** des données :  $p(x)$  (souvent inconnue) - **Distribution supposée** pour le codage :  $q(x)$

### Longueurs de code

Si on conçoit un code optimal pour  $q(x)$  :

$$\ell_q(x) = -\log_2 q(x)$$

Le code optimal pour  $p(x)$  serait :

$$\ell_p(x) = -\log_2 p(x)$$

### Longueur moyenne attendue

En utilisant le code conçu pour  $q$  pour encoder des données de  $p$  :

$$\ell_{\text{av}}^q = \mathbb{E}_{X \sim p}[\ell_q(X)] = \sum_x p(x) \cdot (-\log_2 q(x))$$

## Décomposition

$$\begin{aligned}\ell_{\text{av}}^q &= \sum_x p(x)(-\log_2 q(x)) \\ &= \sum_x p(x) \left( -\log_2 p(x) + \log_2 \frac{p(x)}{q(x)} \right) \\ &= \underbrace{\sum_x p(x)(-\log_2 p(x))}_{H(p)} + \underbrace{\sum_x p(x) \log_2 \frac{p(x)}{q(x)}}_{D_{\text{KL}}(p\|q)}\end{aligned}$$

**Formule fondamentale :**

$$\mathbb{E}_{X \sim p}[\ell_q(X)] = H(p) + D_{\text{KL}}(p\|q)$$

## Interprétation

La divergence KL représente les **bits supplémentaires** nécessaires en moyenne lorsqu'on utilise un code sous-optimal :

$$D_{\text{KL}}(p\|q) = \text{Perte d'efficacité (en bits)}$$

**Optimum :**

$$D_{\text{KL}}(p\|q) = 0 \quad \Leftrightarrow \quad p = q \quad \Leftrightarrow \quad \text{Codage optimal}$$

## Interprétation en Machine Learning

### Mesure de similarité

En apprentissage automatique, la divergence KL mesure à quel point deux distributions sont **similaires** ou **différentes** :

- $D_{\text{KL}}(p\|q)$  faible :  $p$  et  $q$  sont similaires
- $D_{\text{KL}}(p\|q)$  élevé :  $p$  et  $q$  sont très différentes

### Applications

- **Approximation variationnelle** : trouver  $q$  qui minimise  $D_{\text{KL}}(p\|q)$
- **Apprentissage génératif** : minimiser  $D_{\text{KL}}(p_{\text{data}}\|p_{\text{model}})$
- **Régularisation** : pénaliser l'écart par rapport à un prior

## Exemple Numérique de KL Divergence

### Configuration binaire

Considérons deux distributions binaires sur  $\mathcal{X} = \{0, 1\}$  :

**Distribution  $p$  :**

$$p(0) = a, \quad p(1) = 1 - a$$

**Distribution  $q$  :**

$$q(0) = b, \quad q(1) = 1 - b$$

### Formules

$$D_{\text{KL}}(p\|q)$$

$$D_{\text{KL}}(p\|q) = a \log_2 \frac{a}{b} + (1 - a) \log_2 \frac{1 - a}{1 - b}$$

$$D_{\text{KL}}(q\|p)$$

$$D_{\text{KL}}(q\|p) = b \log_2 \frac{b}{a} + (1 - b) \log_2 \frac{1 - b}{1 - a}$$

### Calcul numérique

**Paramètres :**  $a = 1/4 = 0.25$ ,  $b = 1/8 = 0.125$

$$D_{\text{KL}}(p\|q)$$

$$D_{\text{KL}}(p\|q) = 0.25 \log_2 \frac{0.25}{0.125} + 0.75 \log_2 \frac{0.75}{0.875}$$

$$= 0.25 \log_2 2 + 0.75 \log_2 \frac{0.75}{0.875}$$

$$= 0.25 \times 1 + 0.75 \times (-0.2223)$$

$$= 0.25 - 0.1667 = 0.0832 \text{ bit}$$



$$D_{\text{KL}}(q\|p)$$

$$D_{\text{KL}}(q\|p) = 0.125 \log_2 \frac{0.125}{0.25} + 0.875 \log_2 \frac{0.875}{0.75}$$

$$= 0.125 \log_2 0.5 + 0.875 \log_2 1.1667$$

$$= 0.125 \times (-1) + 0.875 \times 0.2223$$

$$= -0.125 + 0.1945 = 0.0696 \text{ bit}$$

### Vérification de l'asymétrie

$$D_{\text{KL}}(p\|q) = 0.0832 \neq 0.0696 = D_{\text{KL}}(q\|p)$$

Confirme que la divergence KL **n'est pas symétrique**.

### Cross-Entropy (Entropie Croisée)

#### Définition

#### Formulation

L'**entropie croisée** entre deux distributions  $p$  et  $q$  est :

$$H(p, q) = - \sum_{x \in \mathcal{X}} p(x) \log_2 q(x)$$

#### Forme espérance

$$H(p, q) = -\mathbb{E}_{p(x)}[\log_2 q(x)]$$

## Asymétrie

Comme pour la KL divergence :

$$H(p, q) \neq H(q, p)$$

en général.

## Lien avec la Divergence KL

### Relation fondamentale

$$H(p, q) = H(p) + D_{\text{KL}}(p \| q)$$

### Démonstration

$$\begin{aligned} D_{\text{KL}}(p \| q) &= \sum_x p(x) \log_2 \frac{p(x)}{q(x)} \\ &= \sum_x p(x) \log_2 p(x) - \sum_x p(x) \log_2 q(x) \\ &= -H(p) + H(p, q) \end{aligned}$$

D'où :

$$H(p, q) = H(p) + D_{\text{KL}}(p \| q)$$

### Propriété d'optimisation

### Équivalence d'optimisation

Puisque  $H(p)$  ne dépend **pas** de  $q$ , minimiser  $H(p, q)$  par rapport à  $q$  est **équivalent** à minimiser  $D_{\text{KL}}(p \| q)$  :

$$\arg \min_q H(p, q) = \arg \min_q D_{\text{KL}}(p \| q)$$

## Optimum

Le minimum est atteint pour  $q = p$  :

$$H(p, p) = H(p) + D_{\text{KL}}(p \| p) = H(p) + 0 = H(p)$$

## Application en Machine Learning

### Fonction de perte pour classification

En apprentissage supervisé, la cross-entropy est largement utilisée comme **fonction de perte** :

**Configuration** : -  $p(y)$  : distribution vraie (souvent one-hot en classification) -  $q(y)$  ou  $q(y|x)$  : distribution prédite par le modèle

**Fonction de perte** :

$$\mathcal{L} = H(p, q) = - \sum_y p(y) \log q(y)$$

ou pour un batch :

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \sum_y p(y_i) \log q(y_i | x_i)$$

### Cas de la classification binaire

Pour une classification binaire ( $y \in \{0, 1\}$ ) :

$$\mathcal{L} = -[y \log \hat{y} + (1 - y) \log(1 - \hat{y})]$$

où  $\hat{y} = q(y = 1|x)$  est la probabilité prédite.

### Avantages

- **Gradient bien défini** : évite les problèmes de saturation
- **Interprétation probabiliste** : minimiser la distance entre distributions
- **Lien avec maximum de vraisemblance** : équivalent à maximiser la log-vraisemblance

## Information Mutuelle

### Définitions et Formulations

#### Définition générale

#### Information mutuelle entre deux variables

L'information mutuelle entre  $X$  et  $Y$  est :

$$I(X; Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p_{X,Y}(x, y) \log_2 \frac{p_{X,Y}(x, y)}{p_X(x)p_Y(y)}$$

#### Forme espérance

$$I(X; Y) = \mathbb{E}_{p_{X,Y}} \left[ \log_2 \frac{p_{X,Y}(X, Y)}{p_X(X)p_Y(Y)} \right]$$

#### Formulation via divergence KL

#### KL divergence entre jointe et produit des marginales

$$I(X; Y) = D_{\text{KL}}(p_{X,Y}(x, y) \| p_X(x)p_Y(y))$$

#### Interprétation

L'information mutuelle mesure à quel point la **distribution jointe**  $p_{X,Y}(x, y)$  diffère du produit des marginales  $p_X(x)p_Y(y)$ .

**Autrement dit :** mesure la **dépendance** entre  $X$  et  $Y$  par rapport à l'hypothèse d'indépendance.

#### Formulations alternatives

### Forme conditionnelle 1

$$\begin{aligned} I(X; Y) &= \sum_{x,y} p_{X,Y}(x, y) \log_2 \frac{p_{X|Y}(x|y)}{p_X(x)} \\ &= \mathbb{E}_{p(y)}[D_{\text{KL}}(p(x|y) \| p(x))] \end{aligned}$$

### Forme conditionnelle 2

$$\begin{aligned} I(X; Y) &= \sum_{x,y} p_{X,Y}(x, y) \log_2 \frac{p_{Y|X}(y|x)}{p_Y(y)} \\ &= \mathbb{E}_{p(x)}[D_{\text{KL}}(p(y|x) \| p(y))] \end{aligned}$$

### Propriétés Fondamentales

#### Symétrie

$$I(X; Y) = I(Y; X)$$

**Conséquence :** Contrairement à la divergence KL, l'information mutuelle est **symétrique**.

#### Non-négativité

$$I(X; Y) \geq 0$$

#### Égalité :

$$I(X; Y) = 0 \quad \Leftrightarrow \quad X \perp Y$$

( $X$  et  $Y$  sont indépendants)

#### Démonstration

Puisque  $I(X; Y) = D_{\text{KL}}(p_{X,Y} \| p_X p_Y)$  et que la divergence KL est toujours non-négative, on a  $I(X; Y) \geq 0$ .

L'égalité est atteinte si et seulement si  $p_{X,Y}(x, y) = p_X(x)p_Y(y)$  pour tout  $x, y$ , c'est-à-dire si  $X$  et  $Y$  sont indépendants.

## Borne supérieure

$$I(X; Y) \leq \min\{H(X), H(Y)\}$$

**Égalité :** -  $I(X; Y) = H(X)$  si  $Y$  détermine complètement  $X$  (i.e.,  $X = f(Y)$ ) -  $I(X; Y) = H(Y)$  si  $X$  détermine complètement  $Y$  (i.e.,  $Y = g(X)$ )

## Auto-information

$$I(X; X) = H(X)$$

**Justification :**

$$I(X; X) = H(X) - H(X|X) = H(X) - 0 = H(X)$$

car  $H(X|X) = 0$  (connaître  $X$  élimine toute incertitude sur  $X$ ).

## Relations avec l'Entropie

### Relations fondamentales

#### Relation 1

$$I(X; Y) = H(X) - H(X|Y)$$

**Interprétation :** L'information mutuelle est la **réduction d'incertitude** sur  $X$  apportée par la connaissance de  $Y$ .

#### Relation 2

$$I(X; Y) = H(Y) - H(Y|X)$$

**Interprétation :** Par symétrie, c'est aussi la réduction d'incertitude sur  $Y$  apportée par  $X$ .

### Relation 3

$$I(X;Y) = H(X) + H(Y) - H(X,Y)$$

#### Démonstration :

En utilisant la règle de chaîne :  $H(X,Y) = H(X) + H(Y|X)$

Donc :

$$\begin{aligned} I(X;Y) &= H(Y) - H(Y|X) = H(Y) - [H(X,Y) - H(X)] \\ &= H(X) + H(Y) - H(X,Y) \end{aligned}$$


#### Cas d'indépendance

Si  $X \perp Y$  :

$$\begin{aligned} I(X;Y) &= 0 \\ H(X,Y) &= H(X) + H(Y) \end{aligned}$$

#### Diagramme de Venn

Les relations entre entropies peuvent être visualisées avec un diagramme de Venn :



**Lecture :** - **Zone totale :**  $H(X,Y)$  (entropie jointe) - **Zone gauche :**  $H(X|Y)$  (incertitude sur  $X$  sachant  $Y$ ) - **Zone centrale** (intersection) :  $I(X;Y)$  (information mutuelle) - **Zone droite :**  $H(Y|X)$  (incertitude sur  $Y$  sachant  $X$ ) - **Cercle gauche :**  $H(X) = H(X|Y) + I(X;Y)$  - **Cercle droit :**  $H(Y) = H(Y|X) + I(X;Y)$

#### Information Mutuelle Conditionnelle

##### Définition

### Information mutuelle entre $X$ et $Y$ sachant $Z$

$$I(X; Y|Z) = H(X|Z) - H(X|Y, Z)$$

### Formes alternatives

$$I(X; Y|Z) = H(Y|Z) - H(Y|X, Z)$$

$$I(X; Y|Z) = H(X|Z) + H(Y|Z) - H(X, Y|Z)$$

### Formulation via KL divergence

$$I(X; Y|Z) = \mathbb{E}_{p(z)}[D_{\text{KL}}(p(x, y|z) \| p(x|z)p(y|z))]$$

$$= \mathbb{E}_{p(x, y, z)} \left[ \log_2 \frac{p_{X, Y|Z}(x, y|z)}{p_{X|Z}(x|z)p_{Y|Z}(y|z)} \right]$$

$$= \mathbb{E}_{p(x, y, z)} \left[ \log_2 \frac{p_{X|Y, Z}(x|y, z)}{p_{X|Z}(x|z)} \right]$$

### Démonstration

En utilisant la décomposition :

$$p_{X, Y|Z}(x, y|z) = p_{Y|Z}(y|z) \cdot p_{X|Y, Z}(x|y, z)$$

On a :

$$I(X; Y|Z) = \mathbb{E}_{p(x, y, z)}[\log_2 p_{X|Y, Z}(x|y, z)] - \mathbb{E}_{p(x, y, z)}[\log_2 p_{X|Z}(x|z)]$$

$$= -H(X|Y, Z) + H(X|Z)$$



## Diagramme

$$H(X|Z)$$

$$H(Y|Z)$$

$$I(X;Y|Z)$$

## Règle de Chaîne pour l'Information Mutuelle

### Énoncé général

#### Pour N variables

$$I(X_1, X_2, \dots, X_N; Y) = \sum_{i=1}^N I(X_i; Y | X_{i-1}, \dots, X_1)$$

### Démonstration

En utilisant la règle de chaîne pour l'entropie :

$$\begin{aligned} I(X_1, \dots, X_N; Y) &= H(X_1, \dots, X_N) - H(X_1, \dots, X_N | Y) \\ &= \sum_{i=1}^N H(X_i | X_{i-1}, \dots, X_1) - \sum_{i=1}^N H(X_i | X_{i-1}, \dots, X_1, Y) \\ &= \sum_{i=1}^N [H(X_i | X_{i-1}, \dots, X_1) - H(X_i | X_{i-1}, \dots, X_1, Y)] \\ &= \sum_{i=1}^N I(X_i; Y | X_{i-1}, \dots, X_1) \end{aligned}$$

### Application : analyse de features

## Sélection de features

Pour sélectionner les features les plus informatives par rapport à un label  $Y$  :

### Approche greedy :

1. Sélectionner  $X_1 = \arg \max_{X_i} I(X_i; Y)$
2. Sélectionner  $X_2 = \arg \max_{X_i} I(X_i; Y|X_1)$
3. Continuer jusqu'à obtenir  $k$  features

### Information totale :

$$I(X_1, \dots, X_k; Y) = \sum_{i=1}^k I(X_i; Y|X_{i-1}, \dots, X_1)$$

### Exemple : pixels d'image et label

#### Configuration

Une image représentée par  $N$  pixels :

$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_N \end{pmatrix} \in \mathcal{X}^N$$

avec  $N = n \times m$  (dimensions de l'image).

Un label :

$$Y \in \mathcal{Y}$$

### Information mutuelle totale

$$I(X_1, X_2, \dots, X_N; Y) = \sum_{i=1}^N I(X_i; Y|X_{i-1}, \dots, X_1)$$

**Interprétation :** Chaque terme  $I(X_i; Y|X_{i-1}, \dots, X_1)$  représente l'information **additionnelle** apportée par le pixel  $X_i$  sur le label  $Y$ , sachant les pixels précédents.

## Décompositions Complexes

### Deux variables et deux labels

Pour  $X_1, X_2$  et  $Y_1, Y_2$  :

$$I(X_1, X_2; Y_1, Y_2) = I(X_1; Y_1, Y_2) + I(X_2; Y_1, Y_2 | X_1)$$

### Décomposition de $I(X_1; Y_1, Y_2)$

$$I(X_1; Y_1, Y_2) = I(X_1; Y_1) + I(X_1; Y_2 | Y_1)$$

ou alternativement :

$$I(X_1; Y_1, Y_2) = I(X_1; Y_2) + I(X_1; Y_1 | Y_2)$$

### Décomposition de $I(X_2; Y_1, Y_2 | X_1)$

$$I(X_2; Y_1, Y_2 | X_1) = I(X_2; Y_1 | X_1) + I(X_2; Y_2 | X_1, Y_1)$$

ou :

$$I(X_2; Y_1, Y_2 | X_1) = I(X_2; Y_2 | X_1) + I(X_2; Y_1 | X_1, Y_2)$$

## Inégalité de Traitement des Données (Data Processing Inequality)

### Chaîne de Markov

## Configuration

Considérons une **chaîne de Markov** :



**Notation** :  $X \rightarrow Y \rightarrow Z$

**Définition formelle** :

$$p_{X,Y,Z}(x, y, z) = p_X(x) \cdot p_{Y|X}(y|x) \cdot p_{Z|Y}(z|y)$$

**Propriété clé** :

$$X \perp Z|Y$$

c'est-à-dire :  $p(x, z|y) = p(x|y)p(z|y)$

## Inégalité fondamentale

### Énoncés

Pour une chaîne de Markov  $X \rightarrow Y \rightarrow Z$  :

$$I(X; Y) \geq I(X; Z)$$

$$I(Y; Z) \geq I(X; Z)$$

### Cas d'égalité

$$I(X; Y) = I(X; Z) \quad \Leftrightarrow \quad X \leftrightarrow Y \leftrightarrow Z \text{ (chaîne réversible)}$$

### Cas particulier important

### Fonction déterministe

Si  $Z = g(Y)$  où  $g$  est une fonction déterministe :

$$I(X; Y) \geq I(X; g(Y))$$

**Interprétation :** Toute transformation de  $Y$  **réduit** (ou laisse inchangée) l'information mutuelle avec  $X$ .

### Interprétation

#### Principe de non-créativité de l'information

**Le traitement des données ne peut pas créer d'information :**

La quantité d'information **ne peut pas être augmentée** par un traitement quelconque (transformation, filtrage, etc.).

### Applications

**Réseaux de neurones profonds :**

Pour un réseau  $X \rightarrow h_1 \rightarrow h_2 \rightarrow \dots \rightarrow h_L \rightarrow Y$  :

$$I(X; Y) \leq I(X; h_L) \leq \dots \leq I(X; h_2) \leq I(X; h_1)$$

**Compression :**

Toute compression réduit l'information mutuelle avec la source originale.

**Communication :**

L'information ne peut pas être augmentée par un canal bruité.

### Démonstration

#### Utilisation de la règle de chaîne

$$I(X; Y, Z) = I(X; Z) + I(X; Y|Z) \quad \dots(a)$$

$$I(X; Y, Z) = I(X; Y) + I(X; Z|Y) \quad \dots(b)$$

### Propriété de la chaîne de Markov

Pour  $X \rightarrow Y \rightarrow Z$ , on a  $X \perp Z|Y$ , donc :

$$I(X; Z|Y) = 0$$

### Conclusion

De (b) :

$$I(X; Y, Z) = I(X; Y) + 0 = I(X; Y)$$

En combinant avec (a) :

$$I(X; Y) = I(X; Z) + I(X; Y|Z)$$

Puisque  $I(X; Y|Z) \geq 0$ , on obtient :

$$I(X; Y) \geq I(X; Z)$$

## Variables Continues : Entropie Différentielle

### Motivation et Limite

### Passage du discret au continu

### Quantification

Pour une variable continue  $X$  avec densité  $f_X(x)$ , on peut l'approximer par une variable discrète en quantifiant :

$$P[x_k; \Delta x] = \int_{x_k}^{x_k + \Delta x} f_X(x) dx \approx f_X(x_k) \Delta x$$

## Entropie de la version quantifiée

$$\begin{aligned} H(X; \Delta x) &= - \sum_{k=1}^N P[x_k; \Delta x] \log_2 P[x_k; \Delta x] \\ &= - \sum_{k=1}^N f_X(x_k) \Delta x \log_2 [f_X(x_k) \Delta x] \end{aligned}$$

## Décomposition

En utilisant  $\log(ab) = \log a + \log b$  :

$$\begin{aligned} H(X; \Delta x) &= - \sum_{k=1}^N f_X(x_k) \Delta x \log_2 f_X(x_k) - \sum_{k=1}^N f_X(x_k) \Delta x \log_2 \Delta x \\ &= - \sum_{k=1}^N f_X(x_k) \Delta x \log_2 f_X(x_k) - \log_2 \Delta x \underbrace{\sum_{k=1}^N f_X(x_k) \Delta x}_{\approx 1} \end{aligned}$$

## Passage à la limite

### Limite continue

Lorsque  $\Delta x \rightarrow 0$  et  $N \rightarrow \infty$  :

$$- \sum_{k=1}^N f_X(x_k) \Delta x \log_2 f_X(x_k) \rightarrow - \int_{-\infty}^{\infty} f_X(x) \log_2 f_X(x) dx$$

### Problème avec le second terme

$$\log_2 \Delta x \rightarrow -\infty \quad \text{lorsque } \Delta x \rightarrow 0$$

Donc :

$$H(X; \Delta x) \rightarrow +\infty$$

**Conclusion :** L'entropie d'une variable continue avec la définition discrète diverge !

## Définition de l'Entropie Différentielle

### Définition formelle

Pour contourner le problème de divergence, on définit l'**entropie différentielle** :

$$\begin{aligned}h(X) &= - \int_{\mathcal{X}} f_X(x) \log_2 f_X(x) dx \\&= -\mathbb{E}_{f_X}[\log_2 f_X(X)]\end{aligned}$$

### Notations

- **Minuscule**  $h(X)$  : entropie différentielle (variables continues)
- **Majuscule**  $H(X)$  : entropie (variables discrètes)

### Différences avec l'entropie discrète

#### Peut être négative

Contrairement à  $H(X) \geq 0$  toujours, on peut avoir :

$$h(X) < 0$$

**Exemple** : Distribution uniforme sur  $[0, a]$  avec  $a < 1$  :

$$h(X) = \log_2 a < 0$$

#### Pas d'interprétation directe en bits

L'entropie différentielle **n'a pas** d'interprétation directe en termes de “nombre de bits”.

Elle mesure plutôt l'**incertitude relative** ou la **dispersion** de la distribution.

#### Dépend des unités

Si  $X$  est mesuré en mètres et  $Y = X$  en centimètres ( $Y = 100X$ ), alors :

$$h(Y) = h(X) + \log_2 100$$



## Lien avec l'entropie quantifiée

$$H(X; \Delta x) \approx h(X) - \log_2 \Delta x$$

Pour  $\Delta x$  petit.

## Entropie Différentielle d'une Gaussienne

### Variable gaussienne univariée

### Distribution

$$X \sim \mathcal{N}(\mu, \sigma^2)$$

Densité de probabilité :

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

### Entropie différentielle

$$h(X) = \frac{1}{2} \log_2(2\pi e\sigma^2) \quad [\text{bits}]$$

ou en nats (logarithme naturel) :

$$h(X) = \frac{1}{2} \ln(2\pi e\sigma^2) \quad [\text{nats}]$$

### Propriété

L'entropie différentielle d'une gaussienne **ne dépend pas** de la moyenne  $\mu$ , seulement de la variance  $\sigma^2$ .

### Démonstration

**Cas centré ( $\mu = 0$ )**

**PDF :**

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{x^2}{2\sigma^2}\right)$$

**Logarithme :**

$$\ln f_X(x) = -\frac{1}{2} \ln(2\pi\sigma^2) - \frac{x^2}{2\sigma^2}$$

**Entropie différentielle (en nats) :**

$$\begin{aligned} h(X) &= - \int_{-\infty}^{\infty} f_X(x) \ln f_X(x) dx \\ &= - \int_{-\infty}^{\infty} f_X(x) \left[ -\frac{x^2}{2\sigma^2} - \frac{1}{2} \ln(2\pi\sigma^2) \right] dx \\ &= \int_{-\infty}^{\infty} f_X(x) \frac{x^2}{2\sigma^2} dx + \frac{1}{2} \ln(2\pi\sigma^2) \underbrace{\int_{-\infty}^{\infty} f_X(x) dx}_{=1} \end{aligned}$$

**Calcul de la première intégrale**

$$\int_{-\infty}^{\infty} f_X(x) \frac{x^2}{2\sigma^2} dx = \frac{1}{2\sigma^2} \mathbb{E}[X^2] = \frac{1}{2\sigma^2} \cdot \sigma^2 = \frac{1}{2}$$

car  $\mathbb{E}[X^2] = \text{Var}[X] = \sigma^2$  (puisque  $\mathbb{E}[X] = 0$ ).

**Résultat**

$$\begin{aligned} h(X) &= \frac{1}{2} + \frac{1}{2} \ln(2\pi\sigma^2) = \frac{1}{2} [1 + \ln(2\pi\sigma^2)] \\ &= \frac{1}{2} [\ln e + \ln(2\pi\sigma^2)] = \frac{1}{2} \ln(2\pi e\sigma^2) \quad [\text{nats}] \end{aligned}$$

### Conversion en bits

$$h(X) = \frac{1}{2} \log_2(2\pi e \sigma^2) \quad [\text{bits}]$$

### Gaussienne multivariée

Pour  $X \sim \mathcal{N}(\mu, \Sigma)$  avec  $X \in \mathbb{R}^n$  :

$$\begin{aligned} h(X) &= \frac{1}{2} \log_2[(2\pi e)^n |\Sigma|] \\ &= \frac{n}{2} \log_2(2\pi e) + \frac{1}{2} \log_2 |\Sigma| \end{aligned}$$

où  $|\Sigma|$  est le déterminant de la matrice de covariance.

### Propriétés de l'Entropie Différentielle

#### Invariance par translation

#### Énoncé

Pour une constante  $a$  (scalaire ou vecteur) :

$$h(X + a) = h(X)$$

#### Interprétation

**Déplacer** une distribution ne change pas son entropie différentielle.

Seule la **forme** de la distribution compte, pas sa **position**.

### Démonstration

Si  $Y = X + a$  avec  $a$  constant, alors :

$$f_Y(y) = f_X(y - a)$$

$$h(Y) = - \int f_Y(y) \log f_Y(y) dy = - \int f_X(x) \log f_X(x) dx = h(X)$$

(par changement de variable  $x = y - a$ ).

### Effet de la mise à l'échelle

#### Variable scalaire

Si  $Y = aX$  avec  $a$  une constante non nulle :

$$h(Y) = h(aX) = h(X) + \log_2 |a|$$

#### Variable vectorielle

Si  $Y = AX$  avec  $A$  une matrice inversible :

$$h(Y) = h(AX) = h(X) + \log_2 |\det(A)|$$

où  $\det(A)$  est le **déterminant** de la matrice  $A$ .

### Interprétation

- **Étirer** la distribution ( $|a| > 1$ ) **augmente** l'entropie différentielle
- **Compresser** la distribution ( $|a| < 1$ ) **diminue** l'entropie différentielle

Le facteur  $\log_2 |\det(A)|$  représente le changement de “volume” dans l'espace.

### Démonstration (cas scalaire)

Si  $Y = aX$ , alors :

$$\begin{aligned}f_Y(y) &= \frac{1}{|a|} f_X\left(\frac{y}{a}\right) \\h(Y) &= - \int f_Y(y) \log_2 f_Y(y) dy \\&= - \int \frac{1}{|a|} f_X\left(\frac{y}{a}\right) \log_2 \left[ \frac{1}{|a|} f_X\left(\frac{y}{a}\right) \right] dy\end{aligned}$$

Par changement de variable  $x = y/a$  :

$$\begin{aligned}h(Y) &= - \int f_X(x) \log_2 \left[ \frac{1}{|a|} f_X(x) \right] dx \\&= - \int f_X(x) [\log_2 f_X(x) - \log_2 |a|] dx \\&= h(X) + \log_2 |a|\end{aligned}$$

### Exemple : gaussienne et mise à l'échelle

Pour  $X \sim \mathcal{N}(0, \sigma^2)$  et  $Y = aX$  :

$$Y \sim \mathcal{N}(0, (a\sigma)^2)$$

**Vérification :**

$$\begin{aligned}h(Y) &= \frac{1}{2} \log_2 (2\pi e (a\sigma)^2) = \frac{1}{2} \log_2 (2\pi e \sigma^2) + \frac{1}{2} \log_2 a^2 \\&= h(X) + \log_2 |a|\end{aligned}$$

Confirme la propriété.

### Maximum d'entropie sous contrainte de variance

## Théorème

Parmi toutes les distributions continues sur  $\mathbb{R}$  avec variance fixée  $\sigma^2$ , la **gaussienne** maximise l'entropie différentielle.

$$\max_{f_X: \text{Var}[X]=\sigma^2} h(X) = \frac{1}{2} \log_2(2\pi e \sigma^2)$$

atteint pour  $X \sim \mathcal{N}(\mu, \sigma^2)$  (avec  $\mu$  quelconque).

## Interprétation

La gaussienne est la distribution de **maximum d'incertitude** étant donné une contrainte sur la variance.

## Applications en Machine Learning

### Fonctions de Perte

#### Cross-Entropy en Classification

#### Configuration

**Problème :** Classification multi-classes avec  $C$  classes.

**Pour un exemple  $(x, y)$  :** -  $y$  : vrai label (encodé en one-hot :  $y \in \{0, 1\}^C$  avec  $\sum_c y_c = 1$ ) -  $\hat{y} = q(y|x; \theta)$  : distribution prédite par le modèle

#### Fonction de perte

Pour un exemple :

$$\mathcal{L}(y, \hat{y}) = - \sum_{c=1}^C y_c \log \hat{y}_c = H(y, \hat{y})$$

Pour un batch de  $N$  exemples :

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log \hat{y}_{i,c}$$

### Cas binaire (Binary Cross-Entropy)

Pour  $C = 2$  (ou équivalent  $y \in \{0, 1\}$ ) :

$$\mathcal{L}(y, \hat{y}) = -[y \log \hat{y} + (1 - y) \log(1 - \hat{y})]$$

où  $\hat{y} = P(y = 1|x)$  est la probabilité prédite.

### Lien avec Maximum de Vraisemblance

#### Équivalence

Minimiser la cross-entropy est **équivalent** à maximiser la log-vraisemblance :

$$\min_{\theta} \mathcal{L} = \min_{\theta} H(p_{\text{data}}, p_{\theta}) \equiv \max_{\theta} \mathbb{E}_{(x,y) \sim p_{\text{data}}} [\log p_{\theta}(y|x)]$$

#### Justification

Pour un dataset  $\{(x_i, y_i)\}_{i=1}^N$  :

**Vraisemblance :**

$$\mathcal{L}(\theta) = \prod_{i=1}^N p_{\theta}(y_i|x_i)$$

**Log-vraisemblance :**

$$\log \mathcal{L}(\theta) = \sum_{i=1}^N \log p_{\theta}(y_i|x_i)$$

**Minimisation de la cross-entropy empirique :**

$$\min_{\theta} \left[ -\frac{1}{N} \sum_{i=1}^N \log p_{\theta}(y_i|x_i) \right] \equiv \max_{\theta} \frac{1}{N} \log \mathcal{L}(\theta)$$

### Sélection de Features

#### Utilisation de l'Information Mutuelle

## Principe

Pour sélectionner les features les plus informatives par rapport à un label  $Y$ , on mesure :

$$I(X_i; Y)$$

pour chaque feature  $X_i$ .

## Critère

**Garder les features avec  $I(X_i; Y)$  élevée.**

Les features ayant une forte information mutuelle avec le label apportent plus d'information pour la prédiction.

## Méthodes de sélection

### Approche univariée

**Rang par information mutuelle :**

1. Calculer  $I(X_i; Y)$  pour chaque feature  $i = 1, \dots, d$
2. Trier les features par  $I(X_i; Y)$  décroissant
3. Sélectionner les top- $k$  features

**Avantage :** Simple et rapide

**Limitation :** Ignore les dépendances entre features (redondance)

### Approche conditionnelle

**Maximum Relevance Minimum Redundancy (mRMR) :**

Maximiser :

$$\max_S \left[ \frac{1}{|S|} \sum_{X_i \in S} I(X_i; Y) - \frac{1}{|S|^2} \sum_{X_i, X_j \in S} I(X_i; X_j) \right]$$

**Objectif :** Sélectionner des features pertinentes mais peu redondantes.



## Approche greedy avec règle de chaîne

En utilisant la règle de chaîne :

$$I(X_1, \dots, X_k; Y) = \sum_{i=1}^k I(X_i; Y | X_1, \dots, X_{i-1})$$

### Algorithme :

1. Sélectionner  $X_1 = \arg \max_{X_i} I(X_i; Y)$
2. Sélectionner  $X_2 = \arg \max_{X_i \notin \{X_1\}} I(X_i; Y | X_1)$
3. Continuer jusqu'à  $k$  features

## Régularisation et Variational Autoencoders

### Variational Autoencoders (VAE)

#### Architecture

**Encodeur :**  $q_\phi(z|x)$  (distribution approximative du posterior)

**Décodeur :**  $p_\theta(x|z)$  (distribution générative)

**Prior :**  $p(z)$  (souvent  $\mathcal{N}(0, I)$ )

#### Fonction objectif (ELBO)

L'Evidence Lower Bound (ELBO) à maximiser :

$$\mathcal{L}_{\text{ELBO}} = \mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)] - D_{\text{KL}}(q_\phi(z|x) \| p(z))$$

#### Terme de régularisation KL

$$\mathcal{L}_{\text{KL}} = D_{\text{KL}}(q_\phi(z|x) \| p(z))$$

**Rôle :** - Force l'encodeur à produire des distributions proches du prior - Régularise l'espace latent pour qu'il soit continu et structuré - Empêche l'overfitting dans l'espace latent

## Interprétation

**Compromis reconstruction-régularisation :**

$$\mathcal{L}_{\text{VAE}} = \underbrace{\text{Terme de reconstruction}}_{\text{fidélité aux données}} + \beta \cdot \underbrace{D_{\text{KL}}(q(z|x) \| p(z))}_{\text{régularisation}}$$

où  $\beta$  est un hyperparamètre (souvent  $\beta = 1$ ).

## Autres applications de la KL divergence

### Distillation de connaissances

**Objectif :** Transférer les connaissances d'un grand modèle (teacher) vers un petit modèle (student)

**Loss :**

$$\mathcal{L}_{\text{distill}} = D_{\text{KL}}(p_{\text{student}}(y|x) \| p_{\text{teacher}}(y|x))$$

### Policy Gradient en RL

**Trust Region Policy Optimization (TRPO) :**

Contrainte :  $D_{\text{KL}}(\pi_{\text{old}} \| \pi_{\text{new}}) \leq \delta$

Empêche les changements trop brusques de la politique.

### Adversarial Training

**Génération adverse :**

Minimiser :  $D_{\text{KL}}(p_{\text{model}} \| p_{\text{data}})$  ou l'inverse

## Aide-Mémoire et Synthèse

### Formules Essentielles

### Entropie

### Entropie discrète

$$H(X) = - \sum_x p(x) \log_2 p(x) = \mathbb{E}[-\log_2 p(X)]$$

### Entropie jointe

$$H(X, Y) = - \sum_{x,y} p(x, y) \log_2 p(x, y)$$

### Entropie conditionnelle

$$H(X|Y) = - \sum_{x,y} p(x, y) \log_2 p(x|y) = \mathbb{E}_{p(Y)}[H(X|Y = y)]$$

### Entropie différentielle

$$h(X) = - \int f_X(x) \log_2 f_X(x) dx$$

### Entropie d'une gaussienne

$$h(X) = \frac{1}{2} \log_2(2\pi e \sigma^2)$$

### Relations entre Entropies

### Règle de chaîne

$$H(X, Y) = H(X) + H(Y|X) = H(Y) + H(X|Y)$$

$$H(X_1, \dots, X_N) = \sum_{i=1}^N H(X_i | X_{i-1}, \dots, X_1)$$

## Inégalités fondamentales

$$H(X|Y) \leq H(X)$$

(le conditionnement réduit l'entropie)

$$H(X, Y) \leq H(X) + H(Y)$$

(égalité ssi  $X \perp Y$ )

$$H(X) \leq \log_2 |\mathcal{X}|$$

(égalité ssi distribution uniforme)

## Information Mutuelle

### Définitions équivalentes

$$I(X; Y) = H(X) - H(X|Y)$$

$$I(X; Y) = H(Y) - H(Y|X)$$

$$I(X; Y) = H(X) + H(Y) - H(X, Y)$$

$$I(X; Y) = D_{\text{KL}}(p(x, y) \| p(x)p(y))$$

### Information mutuelle conditionnelle

$$I(X; Y|Z) = H(X|Z) - H(X|Y, Z)$$

### Règle de chaîne

$$I(X_1, \dots, X_N; Y) = \sum_{i=1}^N I(X_i; Y | X_{i-1}, \dots, X_1)$$

## Divergences

## KL divergence

$$D_{\text{KL}}(p\|q) = \sum_x p(x) \log_2 \frac{p(x)}{q(x)} = \mathbb{E}_p \left[ \log \frac{p(X)}{q(X)} \right]$$

## Cross-entropy

$$H(p, q) = - \sum_x p(x) \log_2 q(x) = H(p) + D_{\text{KL}}(p\|q)$$

## Propriétés Clés à Retenir

### Propriétés de l'entropie

1. **Non-négativité** :  $H(X) \geq 0$
2. **Règle de chaîne** :  $H(X, Y) = H(X) + H(Y|X)$
3. **Ajout de variables augmente l'entropie** :  $H(X) \leq H(X, Y)$
4. **Conditionnement réduit l'entropie** :  $H(X) \geq H(X|Y)$
5. **Maximum pour distribution uniforme** :  $H(X) \leq \log |\mathcal{X}|$

### Propriétés de l'information mutuelle

1. **Symétrie** :  $I(X; Y) = I(Y; X)$
2. **Non-négativité** :  $I(X; Y) \geq 0$
3. **Annulation avec indépendance** :  $I(X; Y) = 0 \Leftrightarrow X \perp Y$
4. **Auto-information** :  $I(X; X) = H(X)$
5. **Data processing inequality** :  $X \rightarrow Y \rightarrow Z \Rightarrow I(X; Y) \geq I(X; Z)$

### Propriétés de la divergence KL

1. **Non-négativité** :  $D_{\text{KL}}(p\|q) \geq 0$
2. **Asymétrie** :  $D_{\text{KL}}(p\|q) \neq D_{\text{KL}}(q\|p)$
3. **Annulation** :  $D_{\text{KL}}(p\|q) = 0 \Leftrightarrow p = q$
4. **Pas une distance** : ne vérifie ni la symétrie ni l'inégalité triangulaire

### Propriétés de l'entropie différentielle

1. **Peut être négative** :  $h(X)$  peut être  $< 0$
2. **Invariance par translation** :  $h(X + a) = h(X)$
3. **Mise à l'échelle** :  $h(aX) = h(X) + \log |a|$
4. **Maximum pour gaussienne** : sous contrainte de variance fixée

## Questions Types d'Examen

### Questions conceptuelles

#### Sur l'entropie

1. Définir l'entropie et expliquer ses interprétations (incertitude, bits moyens, etc.)
2. Quelle distribution maximise l'entropie pour un ensemble fini de  $N$  symboles ?
3. Pourquoi  $H(X|Y) \leq H(X)$  ? Donner une interprétation intuitive
4. Différence entre entropie discrète et entropie différentielle
5. Que représente  $H(X, Y)$  versus  $H(X) + H(Y)$  ?

#### Sur l'information mutuelle

1. Qu'est-ce que l'information mutuelle et que mesure-t-elle ?
2. Pourquoi  $I(X; Y) = 0$  signifie-t-il que  $X$  et  $Y$  sont indépendants ?
3. Interpréter  $I(X; Y) = H(X) - H(X|Y)$
4. Expliquer le principe du data processing inequality
5. Relation entre information mutuelle et divergence KL

#### Sur les divergences

1. Définir la divergence KL et ses interprétations
2. Pourquoi la KL divergence n'est-elle pas une distance ?
3. Quelle est la différence entre  $D_{\text{KL}}(p\|q)$  et  $D_{\text{KL}}(q\|p)$  ?
4. Lien entre KL divergence et cross-entropy
5. Interprétation de la KL divergence en théorie du codage

### Questions de calcul

#### Calculs d'entropie

1. Calculer l'entropie d'une variable binaire avec  $P(X = 1) = 0.3$
2. Pour  $X$  uniforme sur  $\{1, 2, 3, 4\}$ , calculer  $H(X)$
3. Soit  $X \sim \text{Bernoulli}(0.5)$  et  $Y \sim \text{Bernoulli}(0.5)$  indépendants. Calculer  $H(X, Y)$
4. Calculer l'entropie différentielle de  $X \sim \mathcal{N}(0, 4)$

### Calculs d'information mutuelle

1. Pour  $X$  et  $Y$  indépendants, que vaut  $I(X; Y)$  ?
2. Si  $Y = 2X$ , que vaut  $I(X; Y)$  ?
3. Calculer  $I(X; Y)$  pour une distribution jointe donnée

### Calculs de divergence

1. Calculer  $D_{\text{KL}}(p\|q)$  pour deux distributions binaires données
2. Calculer  $H(p, q)$  et vérifier  $H(p, q) = H(p) + D_{\text{KL}}(p\|q)$

### Questions de démonstration

#### Démonstrations essentielles

1. Démontrer la règle de chaîne :  $H(X, Y) = H(X) + H(Y|X)$
2. Montrer que  $H(X|Y) \leq H(X)$  (le conditionnement réduit l'entropie)
3. Prouver que  $I(X; Y) \geq 0$
4. Démontrer le data processing inequality
5. Montrer que la distribution uniforme maximise l'entropie

#### Démonstrations pour variables continues

1. Calculer l'entropie différentielle d'une gaussienne  $\mathcal{N}(0, \sigma^2)$
2. Montrer que  $h(aX) = h(X) + \log |a|$
3. Prouver que  $h(X + a) = h(X)$

### Questions sur le codage

#### Codage de Huffman

1. Appliquer l'algorithme de Huffman à une distribution donnée
2. Calculer la longueur moyenne d'un code de Huffman
3. Comparer la longueur moyenne avec l'entropie de la source

#### Codes préfixes

1. Qu'est-ce qu'un code préfixe et pourquoi est-il important ?
2. Vérifier si un code donné est un code préfixe
3. Donner un exemple de code qui n'est pas préfixe et montrer le problème de décodage

## Compression

1. Calculer le taux de compression pour un exemple donné
2. Expliquer pourquoi  $H(X)$  représente la longueur minimale moyenne
3. Différence entre compression sans perte et avec perte

## Questions d'application

## Machine Learning

1. Expliquer le rôle de la cross-entropy comme fonction de perte
2. Comment utiliser l'information mutuelle pour la sélection de features ?
3. Rôle de la divergence KL dans les VAEs

## Théorie de l'information

1. Expliquer le lien entre entropie et quantité d'information
2. Interpréter la divergence KL en termes de bits supplémentaires
3. Application du data processing inequality aux réseaux de neurones

## Tableaux Récapitulatifs

### Entropie : comparaison discret vs continu

| Propriété        | Entropie discrète $H(X)$ | Entropie différentielle $h(X)$ |
|------------------|--------------------------|--------------------------------|
| Notation         | $H$ (majuscule)          | $h$ (minuscule)                |
| Formule          | $-\sum_x p(x) \log p(x)$ | $-\int f(x) \log f(x) dx$      |
| Signe            | Toujours $\geq 0$        | Peut être $< 0$                |
| Unités           | Bits (ou nats)           | Pas d'unité absolue            |
| Interprétation   | Nombre moyen de bits     | Incertitude relative           |
| Translation      | N/A                      | Invariant : $h(X + a) = h(X)$  |
| Mise à l'échelle | N/A                      | $h(aX) = h(X) + \log  a $      |



| Relation | Formule | Interprétation |
|----------|---------|----------------|
|----------|---------|----------------|

### Relations fondamentales

| Relation        | Formule                                | Interprétation                     |
|-----------------|----------------------------------------|------------------------------------|
| Règle de chaîne | $H(X, Y) = H(X) + H(Y X)$              | Décomposition de l'entropie jointe |
| Info mutuelle 1 | $I(X; Y) = H(X) - H(X Y)$              | Réduction d'incertitude            |
| Info mutuelle 2 | $I(X; Y) = H(X) + H(Y) - H(X, Y)$      | En termes d'entropies              |
| Cross-entropy   | $H(p, q) = H(p) + D_{\text{KL}}(p  q)$ | Décomposition                      |
| Conditionnement | $H(X) \geq H(X Y)$                     | Conditionnement réduit l'entropie  |

### Inégalités importantes

| Inégalité                                                      | Condition d'égalité                     | Signification          |
|----------------------------------------------------------------|-----------------------------------------|------------------------|
| $H(X) \geq 0$                                                  | $X$ déterministe                        | Non-négativité         |
| $H(X Y) \leq H(X)$                                             | $X \perp Y$                             | Conditionnement réduit |
| $H(X, Y) \leq H(X) + H(Y)$                                     | $X \perp Y$                             | Sous-additivité        |
| $I(X; Y) \geq 0$                                               | $X \perp Y$                             | Non-négativité         |
| $D_{\text{KL}}(p  q) \geq 0$                                   | $p = q$                                 | Inégalité de Gibbs     |
| $I(X; Y) \geq I(X; Z)$<br>pour $X \rightarrow Y \rightarrow Z$ | $X \leftrightarrow Y \leftrightarrow Z$ | Data processing        |

### Cas Particuliers Importants

#### Variables binaires

**Variable de Bernoulli** :  $X \in \{0, 1\}$  avec  $P(X = 1) = \theta$

$$H(X) = H(\theta) = -\theta \log \theta - (1 - \theta) \log(1 - \theta)$$

- Maximum en  $\theta = 0.5$  :  $H(0.5) = 1$  bit
- $H(0) = H(1) = 0$
- Symétrie :  $H(\theta) = H(1 - \theta)$

## Variables gaussiennes

**Gaussienne univariée :**  $X \sim \mathcal{N}(\mu, \sigma^2)$

$$h(X) = \frac{1}{2} \log_2(2\pi e \sigma^2)$$

- Ne dépend pas de  $\mu$
- Augmente avec  $\sigma$  (plus de dispersion = plus d'entropie)

**Gaussienne multivariée :**  $X \sim \mathcal{N}(\mu, \Sigma)$  avec  $X \in \mathbb{R}^n$

$$h(X) = \frac{n}{2} \log_2(2\pi e) + \frac{1}{2} \log_2 |\Sigma|$$

## Variables indépendantes

Si  $X \perp Y$  :

- $H(X, Y) = H(X) + H(Y)$
- $H(X|Y) = H(X)$  et  $H(Y|X) = H(Y)$
- $I(X; Y) = 0$
- $p(x, y) = p(x)p(y)$

## Conseils pour l'Examen

### Stratégies de résolution

#### Pour les calculs d'entropie

1. **Identifier le type** : discrète ou continue ?
2. **Vérifier** :  $\sum p_i = 1$  ou  $\int f(x)dx = 1$
3. **Appliquer la formule** :  $H(X) = -\sum p_i \log p_i$
4. **Unités** : préciser bits ou nats selon la base du log

#### Pour les preuves

1. **Commencer par les définitions** formelles
2. **Utiliser les propriétés** connues (règle de chaîne, etc.)
3. **Manipulations algébriques** :  $\log(a/b) = \log a - \log b$
4. **Inégalités** : Jensen, Gibbs, etc.

### Pour le codage de Huffman

1. **Ordonner** les symboles par probabilité décroissante
2. **Fusionner** itérativement les deux plus petits
3. **Assigner** 0 et 1 aux branches
4. **Lire** les codes de la racine aux feuilles
5. **Calculer**  $\ell_{av} = \sum p_i \ell_i$

### Erreurs communes à éviter

1. **Confondre**  $H(X|Y)$  et  $H(Y|X)$  (pas symétriques !)
2. **Oublier** que  $I(X; Y) = I(Y; X)$  (symétrique)
3. **Penser** que  $D_{\text{KL}}(p||q) = D_{\text{KL}}(q||p)$  (faux !)
4. **Croire** que l'entropie différentielle est toujours positive (faux)
5. **Confondre**  $H(p, q)$  et  $D_{\text{KL}}(p||q)$
6. **Oublier** la convention  $0 \log 0 = 0$

### Vérifications rapides

- **Somme de probabilités** : toujours vérifier  $\sum p_i = 1$
- **Non-négativité** :  $H(X) \geq 0$ ,  $I(X; Y) \geq 0$ ,  $D_{\text{KL}} \geq 0$
- **Bornes** :  $H(X) \leq \log |\mathcal{X}|$
- **Cohérence** : si  $X \perp Y$ , alors  $I(X; Y) = 0$
- **Unités** : toujours préciser bits ou nats

### Ressources et Approfondissements

#### Concepts à maîtriser absolument

1. **Entropie** : définition, interprétations, propriétés
2. **Règle de chaîne** : pour probabilités et entropies
3. **Information mutuelle** : définitions multiples, lien avec entropie
4. **Divergence KL** : définition, asymétrie, interprétations
5. **Codage de Huffman** : algorithme, optimalité
6. **Data processing inequality** : énoncé et conséquences

### Pour aller plus loin

### **Sujets avancés**

- **Capacité de canal** (théorème de Shannon-Hartley)
- **Théorie rate-distortion** pour la compression avec perte
- **Entropie conditionnelle maximale** (MaxEnt)
- **Information mutuelle normalisée**
- **Divergences de Rényi et Tsallis**
- **Information de Fisher**

### **Applications modernes**

- **Deep learning** : information bottleneck theory
- **Causal inference** : conditional independence testing
- **Neurosciences** : quantification de l'information neuronale
- **Économie** : théorie de l'information économique
- **Génomique** : mesure de l'information génétique