

## Table of contents

|                                                             |          |
|-------------------------------------------------------------|----------|
| <b>Entropie et diagrammes de Venn</b>                       | <b>1</b> |
| Question . . . . .                                          | 1        |
| Introduction aux concepts de base . . . . .                 | 1        |
| Propriétés fondamentales illustrées . . . . .               | 3        |
| 1. La conditionnement réduit l'entropie . . . . .           | 3        |
| 2. L'entropie jointe comme union des incertitudes . . . . . | 3        |
| 3. Sous-additivité de l'entropie jointe . . . . .           | 3        |
| 4. Relation triangulaire entre les mesures . . . . .        | 4        |
| 5. La chaîne des conditionnements successifs . . . . .      | 4        |
| Exemple concret avec un diagramme quantitatif . . . . .     | 4        |
| Applications pratiques en data science . . . . .            | 5        |
| 1. Compression de données . . . . .                         | 5        |
| 2. Apprentissage automatique . . . . .                      | 5        |
| 3. Traitement du signal . . . . .                           | 5        |
| Synthèse des propriétés clés . . . . .                      | 5        |
| Conclusion pédagogique . . . . .                            | 6        |

## Entropie et diagrammes de Venn


### Question

Expliquer les propriétés de l'entropie à l'aide des exemples de l'entropie conditionnelle  $H(X|Y)$  et de l'entropie jointe  $H(X,Y)$ .

Utiliser des diagrammes de Venn.

### Introduction aux concepts de base

Avant d'aborder les propriétés, rappelons les définitions essentielles illustrées par le diagramme de Venn suivant :



**Légende :**

- $H(X)$  : Entropie de  $X$  (incertitude totale sur  $X$ )
- $H(Y)$  : Entropie de  $Y$  (incertitude totale sur  $Y$ )
- $H(X, Y)$  : Entropie jointe (incertitude totale du couple  $(X, Y)$ )
- $H(X|Y)$  : Entropie conditionnelle (incertitude restante sur  $X$  quand on connaît  $Y$ )
- $H(Y|X)$  : Entropie conditionnelle (incertitude restante sur  $Y$  quand on connaît  $X$ )
- $I(X; Y)$  : Information mutuelle (information partagée entre  $X$  et  $Y$ )

## Propriétés fondamentales illustrées

### 1. La conditionnement réduit l'entropie

**Propriété :**  $H(X|Y) \leq H(X)$

**Explication intuitive :** Connaître Y réduit (ou au pire ne change pas) l'incertitude sur X.

**Illustration :** Dans le diagramme,  $H(X|Y)$  est la partie du cercle  $H(X)$  qui n'intersecte pas  $H(Y)$ . Cette région est toujours plus petite ou égale à  $H(X)$  tout entier.

**Cas extrêmes :**

- Si X et Y sont indépendants :  $H(X|Y) = H(X)$  (les cercles sont disjoints)
- Si Y détermine complètement X :  $H(X|Y) = 0$  (les cercles se superposent)

### 2. L'entropie jointe comme union des incertitudes

**Propriété :**  $H(X, Y) = H(X) + H(Y|X) = H(Y) + H(X|Y)$

**Explication intuitive :** L'incertitude totale sur le couple (X,Y) équivaut à l'incertitude sur X plus l'incertitude restante sur Y une fois X connu (ou vice-versa).

**Formule visuelle :**

- $H(X, Y)$  = toute l'aire des deux cercles combinés
- $H(X) + H(Y|X)$  = cercle  $H(X)$  complet + partie de  $H(Y)$  non couverte par X

### 3. Sous-additivité de l'entropie jointe

**Propriété :**  $H(X, Y) \leq H(X) + H(Y)$

**Explication intuitive :** L'incertitude totale sur (X,Y) ne peut pas dépasser la somme des incertitudes individuelles, sauf si X et Y sont indépendants (auquel cas c'est égal).

**Illustration :** L'aire d'unification de deux cercles est toujours à la somme des aires individuelles. L'égalité ( $H(X, Y) = H(X) + H(Y)$ ) se produit quand les cercles sont disjoints (X et Y indépendants).

#### 4. Relation triangulaire entre les mesures

**Propriété :**  $H(X, Y) = H(X) + H(Y) - I(X; Y)$

**Explication intuitive :** L'entropie jointe est la somme des entropies individuelles moins ce qu'elles partagent en commun (pour ne pas compter deux fois l'information partagée).

**Analogie ensembliste :** Comme en théorie des ensembles :  $|A \cup B| = |A| + |B| - |A \cap B|$

#### 5. La chaîne des conditionnements successifs

**Propriété :**  $H(X|Y) \geq H(X|Y, Z)$

**Explication intuitive :** Plus on a d'information (en conditionnant par plus de variables), plus l'incertitude restante diminue.

**Illustration étendue :** Si on ajoute un troisième cercle  $Z$  au diagramme, la région correspondant à  $H(X|Y, Z)$  est plus petite que  $H(X|Y)$ .

#### Exemple concret avec un diagramme quantitatif

Considérons deux variables binaires  $X$  et  $Y$  avec la distribution jointe suivante :

| X | Y | P(X,Y) |
|---|---|--------|
| 0 | 0 | 0.4    |
| 0 | 1 | 0.1    |
| 1 | 0 | 0.2    |
| 1 | 1 | 0.3    |

Calculons les valeurs :

- $H(X) \approx 0.971$  bits
- $H(Y) \approx 0.881$  bits
- $H(X, Y) \approx 1.846$  bits
- $H(X|Y) = H(X, Y) - H(Y) \approx 0.965$  bits
- $I(X; Y) = H(X) - H(X|Y) \approx 0.006$  bits (faible dépendance)

**Observations sur cet exemple :**

1.  $H(X|Y) = 0.965 < H(X) = 0.971$  : le conditionnement réduit légèrement l'entropie
2.  $H(X, Y) = 1.846 < H(X) + H(Y) = 1.852$  : légère sous-additivité
3.  $I(X; Y)$  est très petit : les variables sont presque indépendantes

## Applications pratiques en data science

### 1. Compression de données

- $H(X|Y)$  représente la partie de X qui ne peut pas être prédite à partir de Y
- Dans la compression avec side information, on ne code que  $H(X|Y)$  au lieu de  $H(X)$
- Exemple : compression stéréo où un canal peut être partiellement prédit à partir de l'autre

### 2. Apprentissage automatique

- Si  $H(X|Y)$  est faible, alors Y est un bon prédicteur de X
- La réduction  $H(X) - H(X|Y) = I(X; Y)$  mesure l'information que Y apporte sur X
- En sélection de caractéristiques : on choisit les Y qui minimisent  $H(X|Y)$

### 3. Traitement du signal

- Dans un système de communication,  $H(X|Y)$  représente l'incertitude restante après réception
- Si le canal est bruité,  $H(X|Y) > 0$  : il reste de l'incertitude
- Un canal parfait aurait  $H(X|Y) = 0$

## Synthèse des propriétés clés

| Propriété                | Formule                    | Interprétation visuelle                             | Condition d'égalité     |
|--------------------------|----------------------------|-----------------------------------------------------|-------------------------|
| Condition-nement réduit  | $H(X Y) \leq H(X)$         | Partie de H(X) hors intersection                    | X et Y indépendants     |
| Entropie jointe additive | $H(X, Y) = H(X) + H(Y X)$  | Union = premier cercle + partie exclusive du second | Toujours vraie          |
| Sous-additivité          | $H(X, Y) \leq H(X) + H(Y)$ | Union somme des cercles                             | X et Y indépendants     |
| Information mutuelle     | $I(X; Y) = H(X) - H(X Y)$  | Intersection des cercles                            | X et Y indépendants I=0 |

## Conclusion pédagogique

Les propriétés de l'entropie conditionnelle et jointe peuvent se résumer par une intuition géométrique simple :

- $H(X)$  est un cercle représentant l'incertitude sur  $X$
- $H(Y)$  est un autre cercle
- $H(X|Y)$  est ce qui reste du cercle  $X$  quand on retire l'intersection avec  $Y$
- $H(X,Y)$  est l'ensemble des deux cercles
- $I(X;Y)$  est la zone de chevauchement

Cette visualisation explique pourquoi :

1. Connaître  $Y$  ne peut qu'aider à réduire l'incertitude sur  $X$  (jamais l'augmenter)
2. L'incertitude sur  $(X,Y)$  est au plus la somme des incertitudes individuelles
3. L'information partagée est ce qui "économise" des bits en codage joint

Ces principes fondamentaux sont à la base de la compression de données, de l'apprentissage automatique et des communications numériques.