


Table of contents

Question : Expliquer les propriétés de l'entropie à l'aide des exemples de l'entropie conditionnelle $H(X Y)$ et de l'entropie jointe $H(X,Y)$. Utiliser des diagrammes de Venn.	1
Introduction aux concepts de base	1
Propriétés fondamentales illustrées	3
1. La conditionnement réduit l'entropie	3
2. L'entropie jointe comme union des incertitudes	3
3. Sous-additivité de l'entropie jointe	3
4. Relation triangulaire entre les mesures	4
5. La chaîne des conditionnements successifs	4
Exemple concret avec un diagramme quantitatif	4
Applications pratiques en data science	5
1. Compression de données	5
2. Apprentissage automatique	5
3. Traitement du signal	5
Synthèse des propriétés clés	5
Conclusion pédagogique	6

Question : Expliquer les propriétés de l'entropie à l'aide des exemples de l'entropie conditionnelle $H(X|Y)$ et de l'entropie jointe $H(X,Y)$. Utiliser des diagrammes de Venn.

Introduction aux concepts de base

Avant d'aborder les propriétés, rappelons les définitions essentielles illustrées par le diagramme de Venn suivant :



Légende :

- $H(X)$: Entropie de X (incertitude totale sur X)
- $H(Y)$: Entropie de Y (incertitude totale sur Y)
- $H(X, Y)$: Entropie jointe (incertitude totale du couple (X, Y))
- $H(X|Y)$: Entropie conditionnelle (incertitude restante sur X quand on connaît Y)
- $I(X; Y)$: Information mutuelle (information partagée entre X et Y)

Propriétés fondamentales illustrées

1. La conditionnement réduit l'entropie

Propriété : $H(X|Y) \leq H(X)$

Explication intuitive : Connaître Y réduit (ou au pire ne change pas) l'incertitude sur X.

Illustration : Dans le diagramme, $H(X|Y)$ est la partie du cercle $H(X)$ qui n'intersecte pas $H(Y)$. Cette région est toujours plus petite ou égale à $H(X)$ tout entier.

Cas extrêmes :

- Si X et Y sont indépendants : $H(X|Y) = H(X)$ (les cercles sont disjoints)
- Si Y détermine complètement X : $H(X|Y) = 0$ (les cercles se superposent)

2. L'entropie jointe comme union des incertitudes

Propriété : $H(X, Y) = H(X) + H(Y|X) = H(Y) + H(X|Y)$

Explication intuitive : L'incertitude totale sur le couple (X,Y) équivaut à l'incertitude sur X plus l'incertitude restante sur Y une fois X connu (ou vice-versa).

Formule visuelle :

- $H(X, Y)$ = toute l'aire des deux cercles combinés
- $H(X) + H(Y|X)$ = cercle $H(X)$ complet + partie de $H(Y)$ non couverte par X

3. Sous-additivité de l'entropie jointe

Propriété : $H(X, Y) \leq H(X) + H(Y)$

Explication intuitive : L'incertitude totale sur (X,Y) ne peut pas dépasser la somme des incertitudes individuelles, sauf si X et Y sont indépendants (auquel cas c'est égal).

Illustration : L'aire d'unification de deux cercles est toujours à la somme des aires individuelles. L'égalité ($H(X, Y) = H(X) + H(Y)$) se produit quand les cercles sont disjoints (X et Y indépendants).

4. Relation triangulaire entre les mesures

Propriété : $H(X, Y) = H(X) + H(Y) - I(X; Y)$

Explication intuitive : L'entropie jointe est la somme des entropies individuelles moins ce qu'elles partagent en commun (pour ne pas compter deux fois l'information partagée).

Analogie ensembliste : Comme en théorie des ensembles : $|A \cup B| = |A| + |B| - |A \cap B|$

5. La chaîne des conditionnements successifs

Propriété : $H(X|Y) \geq H(X|Y, Z)$

Explication intuitive : Plus on a d'information (en conditionnant par plus de variables), plus l'incertitude restante diminue.

Illustration étendue : Si on ajoute un troisième cercle Z au diagramme, la région correspondant à $H(X|Y, Z)$ est plus petite que $H(X|Y)$.

Exemple concret avec un diagramme quantitatif

Considérons deux variables binaires X et Y avec la distribution jointe suivante :

X	Y	P(X,Y)
0	0	0.4
0	1	0.1
1	0	0.2
1	1	0.3

Calculons les valeurs :

- $H(X) \approx 0.971$ bits
- $H(Y) \approx 0.881$ bits
- $H(X, Y) \approx 1.846$ bits
- $H(X|Y) = H(X, Y) - H(Y) \approx 0.965$ bits
- $I(X; Y) = H(X) - H(X|Y) \approx 0.006$ bits (faible dépendance)

Observations sur cet exemple :

1. $H(X|Y) = 0.965 < H(X) = 0.971$: le conditionnement réduit légèrement l'entropie
2. $H(X, Y) = 1.846 < H(X) + H(Y) = 1.852$: légère sous-additivité
3. $I(X; Y)$ est très petit : les variables sont presque indépendantes

Applications pratiques en data science

1. Compression de données

- $H(X|Y)$ représente la partie de X qui ne peut pas être prédite à partir de Y
- Dans la compression avec side information, on ne code que $H(X|Y)$ au lieu de $H(X)$
- Exemple : compression stéréo où un canal peut être partiellement prédit à partir de l'autre

2. Apprentissage automatique

- Si $H(X|Y)$ est faible, alors Y est un bon prédicteur de X
- La réduction $H(X) - H(X|Y) = I(X; Y)$ mesure l'information que Y apporte sur X
- En sélection de caractéristiques : on choisit les Y qui minimisent $H(X|Y)$

3. Traitement du signal

- Dans un système de communication, $H(X|Y)$ représente l'incertitude restante après réception
- Si le canal est bruité, $H(X|Y) > 0$: il reste de l'incertitude
- Un canal parfait aurait $H(X|Y) = 0$

Synthèse des propriétés clés

Propriété	Formule	Interprétation visuelle	Condition d'égalité
Condition-nement réduit	$H(X Y) \leq H(X)$	Partie de H(X) hors intersection	X et Y indépendants
Entropie jointe additive	$H(X, Y) = H(X) + H(Y X)$	Union = premier cercle + partie exclusive du second	Toujours vraie
Sous-additivité	$H(X, Y) \leq H(X) + H(Y)$	Union somme des cercles	X et Y indépendants
Information mutuelle	$I(X; Y) = H(X) - H(X Y)$	Intersection des cercles	X et Y indépendants I=0

Conclusion pédagogique

Les propriétés de l'entropie conditionnelle et jointe peuvent se résumer par une intuition géométrique simple :

- $H(X)$ est un cercle représentant l'incertitude sur X
- $H(Y)$ est un autre cercle
- $H(X|Y)$ est ce qui reste du cercle X quand on retire l'intersection avec Y
- $H(X,Y)$ est l'ensemble des deux cercles
- $I(X;Y)$ est la zone de chevauchement

Cette visualisation explique pourquoi :

1. Connaître Y ne peut qu'aider à réduire l'incertitude sur X (jamais l'augmenter)
2. L'incertitude sur (X,Y) est au plus la somme des incertitudes individuelles
3. L'information partagée est ce qui "économise" des bits en codage joint

Ces principes fondamentaux sont à la base de la compression de données, de l'apprentissage automatique et des communications numériques.