

## Table of contents

|                                                                               |          |
|-------------------------------------------------------------------------------|----------|
| <b>Entropie relative</b>                                                      | <b>1</b> |
| Question . . . . .                                                            | 1        |
| Introduction à l'entropie relative (Divergence de Kullback-Leibler) . . . . . | 2        |
| Définition et intuition . . . . .                                             | 2        |
| Propriétés fondamentales . . . . .                                            | 2        |
| 1. Non-négativité . . . . .                                                   | 2        |
| 2. Asymétrie . . . . .                                                        | 2        |
| 3. Convexité . . . . .                                                        | 2        |
| 4. Additivité pour les distributions indépendantes . . . . .                  | 3        |
| Relations avec les autres mesures d'information . . . . .                     | 3        |
| Lien avec l'entropie croisée (Cross-Entropy) . . . . .                        | 3        |
| Lien avec l'information mutuelle (Mutual Information) . . . . .               | 5        |
| Le triangle de l'information : Relations complètes . . . . .                  | 7        |
| Exemples d'utilisation en pratique . . . . .                                  | 7        |
| 1. Apprentissage automatique : Fonction de perte . . . . .                    | 7        |
| 2. Compression de données : Codes sous-optimaux . . . . .                     | 8        |
| 3. Inférence variationnelle . . . . .                                         | 8        |
| Tableau synthétique des relations . . . . .                                   | 9        |
| Exemple pédagogique complet : Le détective et son hypothèse . . . . .         | 9        |
| Applications avancées . . . . .                                               | 10       |
| 1. Régularisation par divergence KL . . . . .                                 | 10       |
| 2. Apprentissage par renforcement . . . . .                                   | 10       |
| 3. Théorie de l'information bayésienne . . . . .                              | 10       |
| Points d'attention critiques . . . . .                                        | 11       |
| 1. Asymétrie et choix de direction . . . . .                                  | 11       |
| 2. Sensibilité aux événements rares . . . . .                                 | 11       |
| 3. Alternatives symétriques . . . . .                                         | 12       |
| Conclusion synthétique . . . . .                                              | 12       |

## Entropie relative

### Question

Expliquer l'entropie relative, ses propriétés et donner quelques exemples de son utilisation.

## Introduction à l'entropie relative (Divergence de Kullback-Leibler)

L'**entropie relative**, aussi appelée **divergence de Kullback-Leibler (KLD)**, est une mesure fondamentale en théorie de l'information qui quantifie la différence entre deux distributions de probabilité. Elle joue un rôle central en lien avec l'information mutuelle et l'entropie croisée.

### Définition et intuition

Pour deux distributions discrètes  $p(x)$  et  $q(x)$  définies sur le même espace  $\mathcal{X}$  :

$$D_{\text{KL}}(p \parallel q) = \sum_{x \in \mathcal{X}} p(x) \log_2 \frac{p(x)}{q(x)} = \mathbb{E}_{p(x)} \left[ \log_2 \frac{p(x)}{q(x)} \right]$$

**Interprétation intuitive :** La KLD mesure le **nombre moyen de bits supplémentaires** nécessaires pour coder des échantillons provenant de la distribution  $p$  lorsqu'on utilise un code optimisé pour la distribution  $q$ .

### Propriétés fondamentales

#### 1. Non-négativité

$$D_{\text{KL}}(p \parallel q) \geq 0$$

L'égalité  $D_{\text{KL}}(p \parallel q) = 0$  se produit si et seulement si  $p = q$  presque partout.

#### 2. Asymétrie

$$D_{\text{KL}}(p \parallel q) \neq D_{\text{KL}}(q \parallel p)$$

La KLD **n'est pas une distance métrique** car elle n'est pas symétrique et ne satisfait pas l'inégalité triangulaire.

#### 3. Convexité

La KLD est convexe par rapport à chaque argument, ce qui est crucial pour les problèmes d'optimisation.

#### 4. Additivité pour les distributions indépendantes

Si  $p(x, y) = p_1(x)p_2(y)$  et  $q(x, y) = q_1(x)q_2(y)$ , alors :

$$D_{\text{KL}}(p \parallel q) = D_{\text{KL}}(p_1 \parallel q_1) + D_{\text{KL}}(p_2 \parallel q_2)$$

#### Relations avec les autres mesures d'information

##### Lien avec l'entropie croisée (Cross-Entropy)

Définition de l'entropie croisée :

$$H(p, q) = - \sum_x p(x) \log_2 q(x) = \mathbb{E}_{p(x)}[-\log_2 q(x)]$$

Relation fondamentale :

$$H(p, q) = H(p) + D_{\text{KL}}(p \parallel q)$$



**Interprétation pédagogique :**

- $H(p)$  : Nombre optimal de bits pour coder  $p$  (avec un code parfaitement adapté)
- $D_{\text{KL}}(p \parallel q)$  : Surcharge due à l'utilisation du code de  $q$  pour coder  $p$
- $H(p, q)$  : Total des bits utilisés = optimal + surcharge

**Exemple concret :**

Supposons qu'un étudiant doive apprendre pour un examen. Soit :

- $p$  : Distribution réelle des questions (inconnue de l'étudiant)
- $q$  : Distribution supposée par l'étudiant (basée sur ses révisions)
- $H(p)$  : Difficulté réelle de l'examen
- $D_{\text{KL}}(p \parallel q)$  : "Surprise" de l'étudiant face aux vraies questions
- $H(p, q)$  : Difficulté ressentie par l'étudiant

## Lien avec l'information mutuelle (Mutual Information)

Rappel de l'information mutuelle :

$$I(X;Y) = \sum_{x,y} p(x,y) \log_2 \frac{p(x,y)}{p(x)p(y)}$$

Relation fondamentale :

$$I(X;Y) = D_{\text{KL}}(p(x,y) \parallel p(x)p(y))$$




**Interprétation pédagogique :**


L'information mutuelle mesure “combien on apprend sur X en observant Y” (et vice-versa).  
C'est la divergence KL entre :

- La réalité : distribution jointe  $p(x, y)$  (avec dépendance potentielle)
- L'hypothèse d'indépendance :  $p(x)p(y)$  (si on pense que X et Y sont indépendants)

Exemple visuel :



## Le triangle de l'information : Relations complètes



### Exemples d'utilisation en pratique

#### 1. Apprentissage automatique : Fonction de perte

En classification, on utilise souvent la **perte d'entropie croisée** :

**Contexte :**

- $p$  : Distribution cible (one-hot encoding des labels)
- $q$  : Distribution prédite par le modèle (softmax)
- On minimise  $H(p, q)$  pour entraîner le modèle

**Pourquoi ça marche :** Minimiser  $H(p, q)$  équivaut à minimiser  $D_{\text{KL}}(p \parallel q)$  car  $H(p)$  est constant (les labels sont fixes).

**Exemple numérique :** Pour une classification binaire avec vrai label = 1 :

- $p = [0, 1]$  (distribution cible)
- Si le modèle prédit  $q = [0.1, 0.9]$  :  $H(p, q) = -\log_2(0.9) \approx 0.152$  bits
- Si le modèle prédit  $q = [0.4, 0.6]$  :  $H(p, q) = -\log_2(0.6) \approx 0.737$  bits

## 2. Compression de données : Codes sous-optimaux

**Scénario :** On conçoit un code pour une langue avec distribution  $q$ , mais on l'utilise pour une langue avec distribution  $p$ .

**Exemple :**

- Langue A ( $p$ ) : 'e'=12.7%, 't'=9.1%, 'z'=0.07%
- Langue B ( $q$ ) : 'e'=10.0%, 't'=15.0%, 'z'=1.0%
- Code optimal pour B attribue des codes courts à 't' et 'z'

**Calcul :**

$$D_{\text{KL}}(p \parallel q) = 0.127 \log_2 \frac{0.127}{0.10} + 0.091 \log_2 \frac{0.091}{0.15} + \dots$$

Cette divergence mesure l'inefficacité du code B pour la langue A.

## 3. Inférence variationnelle

**Problème :** Approximer une distribution postérieure complexe  $p(z|x)$  par une distribution simple  $q(z)$ .

**Approche :** Minimiser  $D_{\text{KL}}(q \parallel p)$  pour que  $q$  soit proche de  $p$ .

**Choix de direction :**

- $D_{\text{KL}}(q \parallel p)$  : “mode-seeking” (évite les zones où  $q > 0$  mais  $p = 0$ )
- $D_{\text{KL}}(p \parallel q)$  : “mean-seeking” (couvre tous les modes de  $p$ )



| Concept | Formule | Relation avec KLD | Interprétation |
|---------|---------|-------------------|----------------|
|---------|---------|-------------------|----------------|

### Tableau synthétique des relations

| Concept                 | Formule                                                | Relation avec KLD                  | Interprétation                       |
|-------------------------|--------------------------------------------------------|------------------------------------|--------------------------------------|
| Entropie croisée        | $H(p, q) = -\sum p \log q$                             | $H(p, q) = H(p) + D(p \  q)$       | Coût d'utilisation du mauvais modèle |
| Information mutuelle    | $I(X; Y) = \sum p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$ | $I(X; Y) = D(p(x, y) \  p(x)p(y))$ | Dépendance entre variables           |
| Entropie conditionnelle | $H(X \  Y) = H(X, Y) - H(Y)$                           | $H(X \  Y) = H(X) - I(X; Y)$       | Incertitude résiduelle               |
| Entropie jointe         | $H(X, Y) = -\sum p(x, y) \log p(x, y)$                 | $H(X, Y) = H(X) + H(Y) - I(X; Y)$  | Incertitude totale                   |

### Exemple pédagogique complet : Le détective et son hypothèse

**Scénario :** Un détective enquête sur une série de crimes.

- $p(x)$  : Distribution réelle des caractéristiques du vrai criminel
  - Âge : 30-40 ans (40%), 40-50 ans (40%), autre (20%)
  - Véhicule : Voiture (70%), Moto (30%)
- $q(x)$  : Hypothèse du détective
  - Âge : 20-30 ans (60%), 30-40 ans (30%), autre (10%)
  - Véhicule : Voiture (50%), Moto (50%)

#### Calcul de la divergence KL :

Pour chaque caractéristique, on calcule :

$$D_{\text{KL}}(p \| q) = \sum p(x) \log_2 \frac{p(x)}{q(x)}$$

#### Interprétation :

- Si  $D_{\text{KL}}$  est grande  $\rightarrow$  le détective a une mauvaise hypothèse
- Si  $D_{\text{KL}} = 0 \rightarrow$  le détective a deviné parfaitement la distribution

### Lien avec l'information mutuelle :

Supposons maintenant qu'on découvre une relation entre :

- $X$  : Type de crime
- $Y$  : Véhicule utilisé

L'information mutuelle  $I(X;Y)$  mesure si connaître le type de crime donne de l'information sur le véhicule (et vice-versa).

## Applications avancées

### 1. Régularisation par divergence KL

Dans les modèles génératifs (comme les VAEs), on utilise  $D_{\text{KL}}(q(z|x) \parallel p(z))$  pour contraindre la distribution latente à suivre une distribution a priori  $p(z)$  (souvent gaussienne).

### 2. Apprentissage par renforcement

La divergence KL est utilisée dans des algorithmes comme TRPO et PPO pour contraindre les mises à jour de politique, empêchant les changements trop brusques.

### 3. Théorie de l'information bayésienne

Dans l'inférence bayésienne,  $D_{\text{KL}}(p_{\text{post}} \parallel p_{\text{prior}})$  mesure combien l'observation des données a modifié nos croyances.

## Points d'attention critiques

### 1. Asymétrie et choix de direction



### 2. Sensibilité aux événements rares

La KLD est très sensible aux événements de faible probabilité dans  $p$  mais nuls dans  $q$  :

- $p(x) > 0$  mais  $q(x) = 0 \rightarrow D_{\text{KL}}(p \parallel q) = \infty$

### 3. Alternatives symétriques

Quand la symétrie est nécessaire :

- **Divergence de Jensen-Shannon** :  $JS(p, q) = \frac{1}{2}D(p \parallel m) + \frac{1}{2}D(q \parallel m)$  où  $m = \frac{p+q}{2}$
- **Distance de Wasserstein** : Basée sur le transport optimal

### Conclusion synthétique

L'entropie relative (KLD) est le **ciment conceptuel** qui relie les principales mesures de l'information :

1. **Avec l'entropie croisée** :  $H(p, q) = H(p) + D(p \parallel q)$ 
  - La KLD est la “surcharge” quand on utilise un mauvais modèle
2. **Avec l'information mutuelle** :  $I(X; Y) = D(p(x, y) \parallel p(x)p(y))$ 
  - La KLD mesure l'écart à l'indépendance
3. **Avec l'entropie conditionnelle** :  $H(X|Y) = H(X) - I(X; Y)$ 
  - La réduction d'incertitude grâce à Y

**Métaphore finale** : Imaginez que vous devez deviner le contenu d'une boîte : -  $H(p)$  : Nombre de questions nécessaires si vous connaissez la vraie distribution -  $H(p, q)$  : Nombre de questions si vous avez une hypothèse imparfaite  $q$  -  $D(p \parallel q)$  : Questions supplémentaires dues à votre mauvaise hypothèse -  $I(X; Y)$  : Questions économisées en écoutant un indice Y

La divergence KL quantifie ainsi le “coût de l'ignorance” - combien on paie en efficacité quand nos modèles ne correspondent pas à la réalité.