

Table of contents

Entropie relative	1
Question	1
Introduction à l'entropie relative (Divergence de Kullback-Leibler)	2
Définition et intuition	2
Propriétés fondamentales	2
1. Non-négativité	2
2. Asymétrie	2
3. Convexité	2
4. Additivité pour les distributions indépendantes	3
Relations avec les autres mesures d'information	3
Lien avec l'entropie croisée (Cross-Entropy)	3
Lien avec l'information mutuelle (Mutual Information)	4
Le triangle de l'information : Relations complètes	7
Exemples d'utilisation en pratique	7
1. Apprentissage automatique : Fonction de perte	7
2. Compression de données : Codes sous-optimaux	8
3. Inférence variationnelle	8
Tableau synthétique des relations	8
Exemple pédagogique complet : Le détective et son hypothèse	9
Applications avancées	9
1. Régularisation par divergence KL	9
2. Apprentissage par renforcement	10
3. Théorie de l'information bayésienne	10
Points d'attention critiques	10
1. Asymétrie et choix de direction	10
2. Sensibilité aux événements rares	11
3. Alternatives symétriques	11
Conclusion synthétique	11

Entropie relative

Question

Expliquer l'entropie relative, ses propriétés et donner quelques exemples de son utilisation.

Introduction à l'entropie relative (Divergence de Kullback-Leibler)

L'**entropie relative**, aussi appelée **divergence de Kullback-Leibler (KLD)**, est une mesure fondamentale en théorie de l'information qui quantifie la différence entre deux distributions de probabilité. Elle joue un rôle central en lien avec l'information mutuelle et l'entropie croisée.

Définition et intuition

Pour deux distributions discrètes $p(x)$ et $q(x)$ définies sur le même espace $\mathcal{X}$:

$$D_{\text{KL}}(p \parallel q) = \sum_{x \in \mathcal{X}} p(x) \log_2 \frac{p(x)}{q(x)} = \mathbb{E}_{p(x)} \left[\log_2 \frac{p(x)}{q(x)} \right]$$

Interprétation intuitive : La KLD mesure le **nombre moyen de bits supplémentaires** nécessaires pour coder des échantillons provenant de la distribution p lorsqu'on utilise un code optimisé pour la distribution q .

Propriétés fondamentales

1. Non-négativité

$$D_{\text{KL}}(p \parallel q) \geq 0$$

L'égalité $D_{\text{KL}}(p \parallel q) = 0$ se produit si et seulement si $p = q$ presque partout.

2. Asymétrie

$$D_{\text{KL}}(p \parallel q) \neq D_{\text{KL}}(q \parallel p)$$

La KLD **n'est pas une distance métrique** car elle n'est pas symétrique et ne satisfait pas l'inégalité triangulaire.

3. Convexité

La KLD est convexe par rapport à chaque argument, ce qui est crucial pour les problèmes d'optimisation.

4. Additivité pour les distributions indépendantes

Si $p(x, y) = p_1(x)p_2(y)$ et $q(x, y) = q_1(x)q_2(y)$, alors :

$$D_{\text{KL}}(p \parallel q) = D_{\text{KL}}(p_1 \parallel q_1) + D_{\text{KL}}(p_2 \parallel q_2)$$

Relations avec les autres mesures d'information


Lien avec l'entropie croisée (Cross-Entropy)

Définition de l'entropie croisée :

$$H(p, q) = - \sum_x p(x) \log_2 q(x) = \mathbb{E}_{p(x)}[-\log_2 q(x)]$$

Relation fondamentale :

$$H(p, q) = H(p) + D_{\text{KL}}(p \parallel q)$$



Interprétation pédagogique :

- $H(p)$: Nombre optimal de bits pour coder p (avec un code parfaitement adapté)

- $D_{\text{KL}}(p \parallel q)$: Surcharge due à l'utilisation du code de q pour coder p
- $H(p, q)$: Total des bits utilisés = optimal + surcharge

Exemple concret :

Supposons qu'un étudiant doive apprendre pour un examen. Soit :

- p : Distribution réelle des questions (inconnue de l'étudiant)
- q : Distribution supposée par l'étudiant (basée sur ses révisions)
- $H(p)$: Difficulté réelle de l'examen
- $D_{\text{KL}}(p \parallel q)$: "Surprise" de l'étudiant face aux vraies questions
- $H(p, q)$: Difficulté ressentie par l'étudiant


Lien avec l'information mutuelle (Mutual Information)

Rappel de l'information mutuelle :

$$I(X; Y) = \sum_{x, y} p(x, y) \log_2 \frac{p(x, y)}{p(x)p(y)}$$

Relation fondamentale :

$$I(X; Y) = D_{\text{KL}}(p(x, y) \parallel p(x)p(y))$$




Interprétation pédagogique :


L'information mutuelle mesure "combien on apprend sur X en observant Y" (et vice-versa).
C'est la divergence KL entre :

- La réalité : distribution jointe $p(x, y)$ (avec dépendance potentielle)
- L'hypothèse d'indépendance : $p(x)p(y)$ (si on pense que X et Y sont indépendants)

Exemple visuel :



Le triangle de l'information : Relations complètes



Exemples d'utilisation en pratique

1. Apprentissage automatique : Fonction de perte

En classification, on utilise souvent la **perte d'entropie croisée** :

Contexte :

- p : Distribution cible (one-hot encoding des labels)
- q : Distribution prédite par le modèle (softmax)
- On minimise $H(p, q)$ pour entraîner le modèle

Pourquoi ça marche : Minimiser $H(p, q)$ équivaut à minimiser $D_{\text{KL}}(p \parallel q)$ car $H(p)$ est constant (les labels sont fixes).

Exemple numérique : Pour une classification binaire avec vrai label = 1 :

- $p = [0, 1]$ (distribution cible)
- Si le modèle prédit $q = [0.1, 0.9]$: $H(p, q) = -\log_2(0.9) \approx 0.152$ bits
- Si le modèle prédit $q = [0.4, 0.6]$: $H(p, q) = -\log_2(0.6) \approx 0.737$ bits

2. Compression de données : Codes sous-optimaux

Scénario : On conçoit un code pour une langue avec distribution q , mais on l'utilise pour une langue avec distribution p .

Exemple :

- Langue A (p) : 'e'=12.7%, 't'=9.1%, 'z'=0.07%
- Langue B (q) : 'e'=10.0%, 't'=15.0%, 'z'=1.0%
- Code optimal pour B attribue des codes courts à 't' et 'z'

Calcul :

$$D_{\text{KL}}(p \parallel q) = 0.127 \log_2 \frac{0.127}{0.10} + 0.091 \log_2 \frac{0.091}{0.15} + \dots$$

Cette divergence mesure l'inefficacité du code B pour la langue A.

3. Inférence variationnelle

Problème : Approximer une distribution postérieure complexe $p(z|x)$ par une distribution simple $q(z)$.

Approche : Minimiser $D_{\text{KL}}(q \parallel p)$ pour que q soit proche de p .

Choix de direction :

- $D_{\text{KL}}(q \parallel p)$: “mode-seeking” (évite les zones où $q > 0$ mais $p = 0$)
- $D_{\text{KL}}(p \parallel q)$: “mean-seeking” (couvre tous les modes de p)

Tableau synthétique des relations

Concept	Formule	Relation avec KLD	Interprétation
Entropie croisée	$H(p, q) = -\sum p \log q$	$H(p, q) = H(p) + D(p \parallel q)$	Coût d'utilisation du mauvais modèle
Information mutuelle	$I(X; Y) = \sum p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$	$I(X; Y) = D(p(x, y) \parallel p(x)p(y))$	Dépendance entre variables
Entropie conditionnelle	$H(X \parallel Y) = H(X, Y) - H(Y)$	$H(X \parallel Y) = H(X) - I(X; Y)$	Incertitude résiduelle
Entropie jointe	$H(X, Y) = -\sum p(x, y) \log p(x, y)$	$H(X, Y) = H(X \parallel Y) + H(Y) - I(X; Y)$	Incertitude totale

Exemple pédagogique complet : Le détective et son hypothèse

Scénario : Un détective enquête sur une série de crimes.

- $p(x)$: Distribution réelle des caractéristiques du vrai criminel
 - Âge : 30-40 ans (40%), 40-50 ans (40%), autre (20%)
 - Véhicule : Voiture (70%), Moto (30%)
- $q(x)$: Hypothèse du détective
 - Âge : 20-30 ans (60%), 30-40 ans (30%), autre (10%)
 - Véhicule : Voiture (50%), Moto (50%)

Calcul de la divergence KL :

Pour chaque caractéristique, on calcule :

$$D_{\text{KL}}(p \parallel q) = \sum p(x) \log_2 \frac{p(x)}{q(x)}$$

Interprétation :

- Si D_{KL} est grande $\rightarrow$ le détective a une mauvaise hypothèse
- Si $D_{\text{KL}} = 0 \rightarrow$ le détective a deviné parfaitement la distribution

Lien avec l'information mutuelle :

Supposons maintenant qu'on découvre une relation entre :

- X : Type de crime
- Y : Véhicule utilisé

L'information mutuelle $I(X; Y)$ mesure si connaître le type de crime donne de l'information sur le véhicule (et vice-versa).

Applications avancées

1. Régularisation par divergence KL

Dans les modèles génératifs (comme les VAEs), on utilise $D_{\text{KL}}(q(z|x) \parallel p(z))$ pour contraindre la distribution latente à suivre une distribution a priori $p(z)$ (souvent gaussienne).

2. Apprentissage par renforcement


La divergence KL est utilisée dans des algorithmes comme TRPO et PPO pour contraindre les mises à jour de politique, empêchant les changements trop brusques.

3. Théorie de l'information bayésienne

Dans l'inférence bayésienne, $D_{\text{KL}}(p_{\text{post}} \parallel p_{\text{prior}})$ mesure combien l'observation des données a modifié nos croyances.

Points d'attention critiques

1. Asymétrie et choix de direction



2. Sensibilité aux événements rares

La KLD est très sensible aux événements de faible probabilité dans p mais nuls dans q :

- $p(x) > 0$ mais $q(x) = 0 \rightarrow D_{\text{KL}}(p \parallel q) = \infty$

3. Alternatives symétriques

Quand la symétrie est nécessaire :

- **Divergence de Jensen-Shannon** : $JS(p, q) = \frac{1}{2}D(p \parallel m) + \frac{1}{2}D(q \parallel m)$ où $m = \frac{p+q}{2}$
- **Distance de Wasserstein** : Basée sur le transport optimal

Conclusion synthétique

L'entropie relative (KLD) est le **ciment conceptuel** qui relie les principales mesures de l'information :

1. **Avec l'entropie croisée** : $H(p, q) = H(p) + D(p \parallel q)$
 - La KLD est la “surcharge” quand on utilise un mauvais modèle
2. **Avec l'information mutuelle** : $I(X; Y) = D(p(x, y) \parallel p(x)p(y))$
 - La KLD mesure l'écart à l'indépendance
3. **Avec l'entropie conditionnelle** : $H(X|Y) = H(X) - I(X; Y)$
 - La réduction d'incertitude grâce à Y

Métaphore finale : Imaginez que vous devez deviner le contenu d'une boîte :

- $H(p)$: Nombre de questions nécessaires si vous connaissez la vraie distribution
- $H(p, q)$: Nombre de questions si vous avez une hypothèse imparfaite q
- $D(p \parallel q)$: Questions supplémentaires dues à votre mauvaise hypothèse
- $I(X; Y)$: Questions économisées en écoutant un indice Y

La divergence KL quantifie ainsi le “coût de l'ignorance” - combien on paie en efficacité quand nos modèles ne correspondent pas à la réalité.