

Table of contents

Entropie Croisée	2
Question	2
Introduction à l'entropie croisée (Cross-Entropy)	2
Définition mathématique	2
Interprétation intuitive	2
Métaphore du code postal	3
Propriétés de l'entropie croisée	3
1. Non-symétrie	3
2. Minorée par l'entropie	4
3. Convexité par rapport à q	4
Relation fondamentale avec l'entropie relative	4
Lien mathématique	4
Interprétation détaillée	4
Exemples concrets d'utilisation	5
1. Apprentissage automatique : Classification	5
2. Compression de données	6
3. Évaluation de modèles de langage	6
Tableau comparatif : Entropie vs Entropie croisée vs Divergence KL	7
Application pratique : Fonction de perte en deep learning	8
Implémentation en PyTorch	8
Explication étape par étape	8
Visualisation du lien entre les concepts	9
Cas particuliers importants	9
1. Cas binaire (classification binaire)	9
2. Distribution uniforme comme référence	10
Pourquoi minimiser l'entropie croisée ?	10
1. Justification théorique : Principe du maximum de vraisemblance	10
2. Propriétés souhaitables	10
Exemple détaillé : Classification MNIST	10
Problème	10
Données	10
Modèle	10
Calcul de la perte	11
Évolution historique et alternatives	11
1. Perte des moindres carrés	11
2. Avantages de l'entropie croisée	11
Pièges et bonnes pratiques	11
1. Stabilité numérique	11
2. Régularisation	11
3. Données déséquilibrées	12

Synthèse pédagogique	12
L'analogie du jeu de devinettes	12
Formule mnémotechnique	12
Conclusion	12

Entropie Croisée

Question

Expliquer l'entropie croisée et donner quelques exemples de son utilisation.

Montrer le lien entre l'entropie croisée et l'entropie relative.

Introduction à l'entropie croisée (Cross-Entropy)

L'**entropie croisée** est une mesure fondamentale en théorie de l'information et en apprentissage automatique qui quantifie la différence entre deux distributions de probabilité. C'est particulièrement utile pour évaluer la performance des modèles de prédiction.

Définition mathématique

Pour deux distributions discrètes $p(x)$ et $q(x)$ définies sur le même espace $\mathcal{X}$, l'entropie croisée est définie comme :

$$H(p, q) = - \sum_{x \in \mathcal{X}} p(x) \log_2 q(x) = \mathbb{E}_{p(x)}[-\log_2 q(x)]$$

Pour des distributions continues avec densités $f(x)$ et $g(x)$:

$$H(f, g) = - \int f(x) \log_2 g(x) dx$$

Interprétation intuitive

L'entropie croisée mesure **le nombre moyen de bits nécessaires** pour coder des événements provenant de la distribution p en utilisant un code optimisé pour la distribution q .

Métaphore du code postal

Imaginez que vous devez envoyer des lettres à différentes villes : - $p(x)$: Fréquence réelle d'envoi (Paris 50%, Lyon 30%, Marseille 20%) - $q(x)$: Code que vous utilisez (optimisé pour Paris 40%, Lyon 40%, Marseille 20%) - $H(p)$: Longueur optimale du code si vous connaissiez la vraie fréquence - $H(p, q)$: Longueur réelle avec votre code imparfait



Propriétés de l'entropie croisée

1. Non-symétrie

$$H(p, q) \neq H(q, p) \quad \text{en général}$$

Contrairement à une distance, l'entropie croisée n'est pas symétrique.

2. Minorée par l'entropie

$$H(p, q) \geq H(p)$$

L'égalité $H(p, q) = H(p)$ se produit si et seulement si $p = q$.

3. Convexité par rapport à q

Pour p fixé, $H(p, q)$ est convexe en q , ce qui facilite l'optimisation.

Relation fondamentale avec l'entropie relative

Lien mathématique


$$H(p, q) = H(p) + D_{\text{KL}}(p \parallel q)$$

où : - $H(p)$ est l'entropie de la distribution p - $D_{\text{KL}}(p \parallel q)$ est la divergence de Kullback-Leibler (entropie relative)

Interprétation détaillée

Cette relation montre que l'entropie croisée se décompose en deux parties :

1. $H(p)$: L'incertitude intrinsèque de la distribution réelle
 - Minimum théorique incompressible
 - Ne dépend que de p , pas de notre modèle
2. $D_{\text{KL}}(p \parallel q)$: La pénalité due au mauvais modèle
 - Mesure combien q diffère de p
 - Réduisible en améliorant notre modèle



Exemples concrets d'utilisation

1. Apprentissage automatique : Classification

Scénario : Classification d'images avec 3 classes (chat, chien, oiseau)

Données d'entraînement : - Image 1 : vraie classe = “chat” $\rightarrow p = [1, 0, 0]$ - Image 2 : vraie classe = “chien” $\rightarrow p = [0, 1, 0]$

Prédictions du modèle : - Pour l'image 1 : $q = [0.7, 0.2, 0.1]$ - Pour l'image 2 : $q = [0.1, 0.6, 0.3]$

Calcul de l'entropie croisée : Pour l'image 1 :

$$H(p, q) = -[1 \times \log_2(0.7) + 0 \times \log_2(0.2) + 0 \times \log_2(0.1)] = -\log_2(0.7) \approx 0.514 \text{ bits}$$

Pour l'image 2 :

$$H(p, q) = -[0 \times \log_2(0.1) + 1 \times \log_2(0.6) + 0 \times \log_2(0.3)] = -\log_2(0.6) \approx 0.737 \text{ bits}$$

Perte moyenne : Moyenne sur toutes les images de l'ensemble d'entraînement.

2. Compression de données

Scénario : Compression d'un texte en anglais

Distribution réelle (p) : - 'e' : 12.7% - 't' : 9.1% - 'a' : 8.2% - ... (autres lettres)

Modèle utilisé (q) : - Modèle uniforme : chaque lettre = $1/26$ 3.85% - Modèle basé sur Shakespeare : distribution spécifique

Calcul d'efficacité : Avec le modèle uniforme :

$$H(p, q) = -\sum p(x) \log_2(1/26) = \log_2(26) \approx 4.7 \text{ bits/lettre}$$

Avec un bon modèle linguistique (q proche de p) :

$$H(p, q) \approx H(p) \approx 4.1 \text{ bits/lettre}$$

Gain : 0.6 bit par lettre, soit ~18% d'économie.

3. Évaluation de modèles de langage

Scénario : Modèle GPT évalué sur des phrases

Méthode : Perplexité = $2^{H(p, q)}$

Interprétation : - Perplexité faible $\rightarrow$ modèle prédit bien les mots suivants - Perplexité élevée $\rightarrow$ modèle est incertain




Tableau comparatif : Entropie vs Entropie croisée vs Divergence KL

Concept	Formule	Interprétation	Propriété clé
Entropie $H(p)$	$-\sum p \log p$	Incertitude intrinsèque	Minimum théorique
Entropie croisée $H(p, q)$	$-\sum p \log q$	Coût du mauvais modèle	Toujours $H(p)$
Divergence KL $D(p\ q)$	$\sum p \log(p/q)$	Pénalité du mauvais modèle	Mesure de différence

Application pratique : Fonction de perte en deep learning

Implémentation en PyTorch

```
import torch
import torch.nn as nn

# Données : 3 échantillons, 5 classes
predictions = torch.tensor([[0.1, 0.2, 0.6, 0.1, 0.0],
                             [0.8, 0.1, 0.05, 0.05, 0.0],
                             [0.05, 0.1, 0.1, 0.15, 0.6]])


true_labels = torch.tensor([2, 0, 4]) # Indices des vraies classes

# Calcul de l'entropie croisée
loss_fn = nn.CrossEntropyLoss()
loss = loss_fn(predictions, true_labels)
print(f"Perte d'entropie croisée: {loss.item():.4f}")
```

Explication étape par étape

1. Le modèle produit des logits (non normalisés)
2. Softmax convertit en probabilités q
3. Comparaison avec les labels one-hot p
4. Calcul de $H(p, q)$
5. Gradient pour ajuster les poids

Visualisation du lien entre les concepts



Cas particuliers importants

1. Cas binaire (classification binaire)

Pour $p \in \{0, 1\}$ et $q \in [0, 1]$:

$$H(p, q) = -[p \log_2 q + (1 - p) \log_2 (1 - q)]$$

C'est la **perte logistique** utilisée en régression logistique.

2. Distribution uniforme comme référence

Si q est uniforme sur N classes :

$$H(p, q) = - \sum p(x) \log_2(1/N) = \log_2 N$$

Tous les modèles sont comparés à cette baseline.

Pourquoi minimiser l'entropie croisée ?

1. Justification théorique : Principe du maximum de vraisemblance

Minimiser $H(p, q)$ équivaut à maximiser la vraisemblance des données.

Preuve : Soit p_{data} la distribution empirique, q_θ notre modèle :

$$\min_{\theta} H(p_{\text{data}}, q_\theta) \equiv \max_{\theta} \mathbb{E}_{x \sim p_{\text{data}}} [\log q_\theta(x)]$$

2. Propriétés souhaitables

- **Convexité** : Garantit des minima globaux (pour de nombreux modèles)
- **Sensibilité aux erreurs** : Pénalise fortement les erreurs de confiance
- **Interprétation probabiliste** : Directement liée aux probabilités

Exemple détaillé : Classification MNIST

Problème

Reconnaître des chiffres manuscrits (0-9).

Données

- Image 28×28 pixels
- Label : chiffre de 0 à 9

Modèle

Réseau de neurones avec sortie softmax produisant $q = [q_0, q_1, \dots, q_9]$.

Calcul de la perte

Pour une image de chiffre “3” ($p = [0, 0, 0, 1, 0, 0, 0, 0, 0, 0]$) :

- Si $q = [0, 0, 0, 0.9, 0, 0, 0, 0, 0.1, 0] \rightarrow H(p, q) = -\log_2(0.9) \approx 0.152$
- Si $q = [0.1, 0.1, 0.1, 0.2, 0.1, 0.1, 0.1, 0.1, 0.1, 0] \rightarrow H(p, q) = -\log_2(0.2) \approx 2.322$

La première prédiction est bien meilleure.

Évolution historique et alternatives

1. Perte des moindres carrés

- Anciennement populaire en régression
- Moins adaptée à la classification
- Pas de lien direct avec les probabilités

2. Avantages de l'entropie croisée

- **Gradients bien comportés** : Évite les plateaux d'apprentissage
- **Interprétation probabiliste** : Sorties sont des probabilités
- **Théorie de l'information** : Fondements solides

Pièges et bonnes pratiques

1. Stabilité numérique

Le calcul direct $\log(q)$ peut être instable pour $q \approx 0$.

Solution : Utiliser la fonction log-sum-exp :

$$H(p, q) = - \sum p(x) \left[z(x) - \log \sum \exp(z(x')) \right]$$

où $z(x)$ sont les logits.

2. Régularisation

Ajouter un terme de régularisation équivaut à :

$$H(p, q) + \lambda R(\theta)$$

Cela empêche le surapprentissage en pénalisant les modèles complexes.

3. Données déséquilibrées

Quand certaines classes sont rares :

- **Pondération** : $H_w(p, q) = - \sum w(x)p(x) \log q(x)$
- **Rééchantillonnage** : Ajuster la distribution d'entraînement

Synthèse pédagogique

L'analogie du jeu de devinettes

Imaginez un jeu où vous devez deviner un animal :

- p : Animal réel (ex: 80% chat, 20% chien)
 - q : Votre stratégie de devinette
1. **Entropie** $H(p)$: Nombre optimal de questions si vous connaissiez la vraie distribution
 2. **Entropie croisée** $H(p, q)$: Nombre de questions avec votre stratégie
 3. **Divergence KL** $D(p\|q)$: Questions supplémentaires dues à votre mauvaise stratégie

Formule mnémotechnique

“Le coût total = incertitude de base + pénalité d'ignorance”

$$H(p, q) = H(p) + D(p\|q)$$

Conclusion

L'entropie croisée est une mesure puissante qui :

1. **Évalue les modèles** : Mesure combien un modèle q est adapté à des données p
2. **Guide l'apprentissage** : Fonction de perte optimisable par gradient
3. **Relie théorie et pratique** : Connecte théorie de l'information et ML

Le lien fondamental avec l'entropie relative montre que minimiser l'entropie croisée revient à minimiser l'écart entre notre modèle et la réalité, tout en reconnaissant qu'une certaine incertitude ($H(p)$) est incompressible.

Cette compréhension unifiée explique pourquoi l'entropie croisée est devenue la fonction de perte standard pour les problèmes de classification et bien d'autres tâches en intelligence artificielle.