

Table of contents

Information mutuelle	2
Question	2
Définition de l'information mutuelle	2
Définition formelle	2
Interprétation intuitive	2
Exemple concret	3
Le diagramme de Venn : Représentation visuelle	4
Relations géométriques évidentes	5
Expressions de l'information mutuelle via les entropies	5
1. En termes d'entropies simple et conditionnelle	5
2. Expression symétrique	5
3. En termes d'entropies jointes et marginales	6
4. Expression avec les entropies conditionnelles	6
Expressions via l'entropie relative (Divergence de Kullback-Leibler)	6
1. Information mutuelle comme divergence KL	6
2. Forme conditionnelle comme espérance de divergences KL	7
3. Forme symétrique alternative	7
Tableau synthétique des expressions	7
Exemple numérique illustratif	8
Situation : Prévion météo et vente de glaces	8
Calculs :	8
Visualisation des relations	9
Cas particuliers et limites	9
1. Variables indépendantes	9
2. Variables déterministes	10
3. Relation avec la corrélation	10
Applications pratiques	10
1. Sélection de caractéristiques (Feature Selection)	10
2. Apprentissage de représentations	10
3. Neurosciences	10
Synthèse pédagogique	11
L'analogie de la conversation	11
Formules mnémotechniques	11
Conclusion	11

Information mutuelle

Question

Donner la définition de l'information mutuelle.

Expliquer le diagramme de Venn.

Démontrer différentes expressions pour l'information mutuelle via les entropies et l'entropie relative.

Définition de l'information mutuelle

L'**information mutuelle** est une mesure fondamentale en théorie de l'information qui quantifie la quantité d'information qu'une variable aléatoire apporte sur une autre, et vice-versa. C'est une mesure de la dépendance statistique entre deux variables.

Définition formelle

Pour deux variables aléatoires discrètes X et Y avec distribution jointe $p(x, y)$ et distributions marginales $p(x)$ et $p(y)$, l'information mutuelle est définie comme :

$$I(X; Y) = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x, y) \log_2 \frac{p(x, y)}{p(x)p(y)}$$

Sous forme d'espérance :

$$I(X; Y) = \mathbb{E}_{p(x, y)} \left[\log_2 \frac{p(X, Y)}{p(X)p(Y)} \right]$$

Pour des variables continues :

$$I(X; Y) = \iint p(x, y) \log_2 \frac{p(x, y)}{p(x)p(y)} dx dy$$

Interprétation intuitive

L'information mutuelle répond à la question : “**Combien apprend-on sur X en observant Y (et vice-versa) ?**”


Exemple concret

Imaginez deux personnes qui communiquent :

- $\mathbf{X}$: Message que la première personne veut envoyer
- $\mathbf{Y}$: Message que la deuxième personne reçoit
- $\mathbf{I(X;Y)}$: Quantité d'information correctement transmise

Si le canal est parfait (pas de bruit) : $I(X;Y) = H(X)$ (tout est transmis) Si le canal est complètement bruité : $I(X;Y) = 0$ (rien n'est transmis)

Le diagramme de Venn : Représentation visuelle



Légende et interprétation :

- $H(X)$: L'entropie de X - mesure l'incertitude totale sur X
- $H(Y)$: L'entropie de Y - mesure l'incertitude totale sur Y
- $H(X, Y)$: L'entropie jointe - incertitude totale du couple (X, Y)
- $I(X; Y)$: L'information mutuelle - information partagée entre X et Y

- $H(X|Y)$: L'entropie conditionnelle - incertitude restante sur X quand on connaît Y
- $H(Y|X)$: L'entropie conditionnelle - incertitude restante sur Y quand on connaît X

Relations géométriques évidentes

D'après le diagramme :

1. $H(X, Y) = H(X) + H(Y) - I(X; Y)$
 - L'union = somme des cercles - intersection (pour éviter le double comptage)
2. $H(X) = H(X|Y) + I(X; Y)$
 - Le cercle X = partie exclusive + intersection
3. $H(Y) = H(Y|X) + I(X; Y)$
 - Le cercle Y = partie exclusive + intersection

Expressions de l'information mutuelle via les entropies

1. En termes d'entropies simple et conditionnelle

$$I(X; Y) = H(X) - H(X|Y)$$

Interprétation : L'information que Y apporte sur X est la réduction d'incertitude sur X quand on connaît Y.

Démonstration :

$$\begin{aligned}
 I(X; Y) &= \sum_{x,y} p(x, y) \log_2 \frac{p(x, y)}{p(x)p(y)} \\
 &= \sum_{x,y} p(x, y) \log_2 \frac{p(x|y)}{p(x)} \quad (\text{car } p(x, y) = p(x|y)p(y)) \\
 &= \sum_{x,y} p(x, y) \log_2 p(x|y) - \sum_{x,y} p(x, y) \log_2 p(x) \\
 &= -H(X|Y) + H(X) \quad (\text{par définition des entropies})
 \end{aligned}$$

2. Expression symétrique

$$I(X; Y) = H(Y) - H(Y|X)$$

Interprétation : Identique à la précédente mais symétrique - ce que X apporte sur Y.

3. En termes d'entropies jointes et marginales

$$I(X; Y) = H(X) + H(Y) - H(X, Y)$$

Démonstration :

En partant de $I(X; Y) = H(X) - H(X|Y)$ et sachant que $H(X|Y) = H(X, Y) - H(Y)$, on a :

$$I(X; Y) = H(X) - [H(X, Y) - H(Y)] = H(X) + H(Y) - H(X, Y)$$

Interprétation : L'information mutuelle est ce qui "économise" des bits quand on code X et Y ensemble plutôt que séparément.

4. Expression avec les entropies conditionnelles

$$I(X; Y) = H(X, Y) - H(X|Y) - H(Y|X)$$

Démonstration :

De $H(X, Y) = H(X) + H(Y) - I(X; Y)$, on peut réarranger pour avoir $I(X; Y) = H(X, Y) - [H(X, Y) - H(Y)] - [H(X, Y) - H(X)]$ qui se simplifie.

Expressions via l'entropie relative (Divergence de Kullback-Leibler)

1. Information mutuelle comme divergence KL

Relation fondamentale :

$$I(X; Y) = D_{\text{KL}}(p(x, y) \parallel p(x)p(y))$$

Démonstration directe :

Par définition de la divergence KL :

$$\begin{aligned} D_{\text{KL}}(p(x, y) \parallel p(x)p(y)) &= \sum_{x, y} p(x, y) \log_2 \frac{p(x, y)}{p(x)p(y)} \\ &= I(X; Y) \quad (\text{exactement la définition de } I(X; Y)) \end{aligned}$$

Interprétation profonde : L'information mutuelle mesure l'écart à l'indépendance.

- Si X et Y sont indépendants : $p(x, y) = p(x)p(y) \rightarrow \text{divergence KL} = 0 \rightarrow I(X; Y) = 0$
- Si X et Y sont dépendants : $p(x, y) \neq p(x)p(y) \rightarrow \text{divergence KL} > 0 \rightarrow I(X; Y) > 0$

2. Forme conditionnelle comme espérance de divergences KL

$$I(X; Y) = \mathbb{E}_{p(y)} [D_{\text{KL}}(p(x|y) \parallel p(x))]$$

Démonstration :

$$\begin{aligned} I(X; Y) &= \sum_{x,y} p(x, y) \log_2 \frac{p(x|y)}{p(x)} \quad (\text{car } \frac{p(x, y)}{p(x)p(y)} = \frac{p(x|y)}{p(x)}) \\ &= \sum_y p(y) \sum_x p(x|y) \log_2 \frac{p(x|y)}{p(x)} \\ &= \mathbb{E}_{p(y)} \left[\sum_x p(x|y) \log_2 \frac{p(x|y)}{p(x)} \right] \\ &= \mathbb{E}_{p(y)} [D_{\text{KL}}(p(x|y) \parallel p(x))] \end{aligned}$$

Interprétation : Pour chaque valeur possible de Y, on mesure combien la distribution conditionnelle de X sachant Y diffère de la distribution marginale de X, puis on moyenne sur Y.

3. Forme symétrique alternative

$$I(X; Y) = \mathbb{E}_{p(x)} [D_{\text{KL}}(p(y|x) \parallel p(y))]$$

Démonstration : Similaire à la précédente par symétrie.

Tableau synthétique des expressions

Expression	Formule	Interprétation
Définition	$\sum p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$	Écart à l'indépendance
Via entropies	$H(X) - H(X Y)$	Réduction d'incertitude sur X par Y
Symétrique	$H(Y) - H(Y X)$	Réduction d'incertitude sur Y par X
Joint-marginales	$H(X) + H(Y) - H(X, Y)$	Économie de bits en codage joint
Comme KL	$D(p(x, y) \parallel p(x)p(y))$	Distance à l'indépendance
Conditionnelle	$\mathbb{E}_{p(y)} [D(p(x y) \parallel p(x))]$	Moyenne des divergences conditionnelles

Exemple numérique illustratif

Situation : Prévision météo et vente de glaces

Soit :

- **X** : Météo (0=Pluie, 1=Soleil)
- **Y** : Vente de glaces (0=Faible, 1=Forte)

Distributions :

- $p(x=0) = 0.3, p(x=1) = 0.7$
- $p(y=0) = 0.4, p(y=1) = 0.6$
- Distribution jointe :

	Y=0	Y=1
X=0	0.25	0.05
X=1	0.15	0.55

Calculs :

1. Vérification d'indépendance :

- Si indépendants : $p(0,0) = p(x=0)p(y=0) = 0.3 \times 0.4 = 0.12$
- Mais $p(0,0) = 0.25 \rightarrow$ pas indépendants

2. Entropies :

- $H(X) = -0.3 \log_2(0.3) - 0.7 \log_2(0.7) \approx 0.881$ bits
- $H(Y) = -0.4 \log_2(0.4) - 0.6 \log_2(0.6) \approx 0.971$ bits
- $H(X,Y) = -0.25 \log_2(0.25) - 0.05 \log_2(0.05) - 0.15 \log_2(0.15) - 0.55 \log_2(0.55) \approx 1.548$ bits

3. Information mutuelle :

- $I(X;Y) = H(X) + H(Y) - H(X,Y) \approx 0.881 + 0.971 - 1.548 = 0.304$ bits
- $I(X;Y) = D(p(x,y) \| p(x)p(y)) = 0.25 \log_2 \frac{0.25}{0.12} + 0.05 \log_2 \frac{0.05}{0.18} + 0.15 \log_2 \frac{0.15}{0.28} + 0.55 \log_2 \frac{0.55}{0.42} \approx 0.304$ bits

Interprétation : Connaître la météo apporte environ 0.3 bit d'information sur les ventes de glaces.

Visualisation des relations



Cas particuliers et limites

1. Variables indépendantes

Si $X \perp Y$, alors :

- $p(x, y) = p(x)p(y)$
- $\log \frac{p(x, y)}{p(x)p(y)} = \log 1 = 0$
- Donc $I(X; Y) = 0$

2. Variables déterministes

Si $Y = f(X)$ (fonction déterministe), alors :

- $H(Y|X) = 0$ (connaissant X , Y est certain)
- $I(X; Y) = H(Y)$ (toute l'information de Y vient de X)
- Mais $I(X; Y) \leq H(X)$ également

3. Relation avec la corrélation

L'information mutuelle est plus générale que la corrélation :

- Corrélation : mesure les relations linéaires
- Information mutuelle : mesure toute dépendance (linéaire ou non)

Applications pratiques

1. Sélection de caractéristiques (Feature Selection)

En machine learning, on choisit les variables Y qui maximisent $I(X; Y)$ où X est la variable cible.

Exemple : Pour prédire le prix d'une maison (X), on choisit parmi :

- Surface (Y_1)
- Nombre de pièces (Y_2)
- Année de construction (Y_3)

On calcule $I(X; Y_1)$, $I(X; Y_2)$, $I(X; Y_3)$ et on garde les plus informatives.

2. Apprentissage de représentations

Dans les autoencodeurs, on minimise $I(X; Z)$ où Z est la représentation latente, pour obtenir une représentation compacte.

3. Neuroscience

Mesurer $I(S; R)$ où S est un stimulus et R la réponse neuronale, pour comprendre quelles informations sont codées.

Synthèse pédagogique

L'analogie de la conversation

Imaginez deux amis qui parlent :

- $H(X)$: Tout ce que Pierre pourrait dire
- $H(Y)$: Tout ce que Paul pourrait entendre
- $I(X;Y)$: Ce que Paul comprend vraiment de Pierre
- $H(X|Y)$: Ce que Pierre dit que Paul ne comprend pas
- $H(Y|X)$: Ce que Paul entend mais qui ne vient pas de Pierre (bruit)

Formules mnémotechniques

1. “L’information partagée = ce qu’on sait - ce qu’on ignore”

$$I(X;Y) = H(X) - H(X|Y)$$

2. “Ensemble on est plus fort, mais on partage”

$$H(X,Y) = H(X) + H(Y) - I(X;Y)$$

3. “La dépendance est une distance à l’indépendance”

$$I(X;Y) = D(p(x,y) \parallel p(x)p(y))$$

Conclusion

L’information mutuelle est un concept central qui unit plusieurs notions de la théorie de l’information :

1. **C’est une mesure de dépendance** plus puissante que la corrélation
2. **Elle relie entropies et divergence KL** de manière élégante
3. **Son interprétation visuelle** via les diagrammes de Venn est intuitive

Le diagramme de Venn montre clairement comment l’information mutuelle est l’**intersection** des informations de X et Y, tandis que les expressions via l’entropie relative révèlent qu’elle mesure fondamentalement l’**écart entre la réalité jointe et l’hypothèse d’indépendance**.

Cette dualité de perspectives fait de l’information mutuelle un outil indispensable en science des données, apprentissage automatique, neurosciences et bien d’autres domaines.