

Table of contents

Extraction de caractéristiques	1
Question	1
Introduction	1
1. Apprentissage Supervisé	2
Principe et lien avec la théorie de l'information	2
Domaines d'application	3
2. Auto-Encodage	5
Principe et lien avec la théorie de l'information	5
Domaines d'application	6
3. Apprentissage Auto-Supervisé	7
Principe et lien avec la théorie de l'information	7
Domaines d'application	7
Tableau synthétique des liens théoriques	9
Exemples concrets intégrés	9
Cas 1 : Plateforme de streaming vidéo	9
Cas 2 : Banque en ligne	9
Conclusion : Quelle méthode choisir ?	10
Tableau comparatif et synthèse	10
Relations avec l'entropie, DKL et information mutuelle	11
Diagramme de synthèse des relations	12
Conclusion	12

Extraction de caractéristiques

Question

Expliquez les 3 concepts principaux d'extraction de caractéristiques basés sur l'apprentissage supervisé, l'auto-encodage et l'apprentissage auto-supervisé.

Donnez des exemples d'utilisation de ces caractéristiques.

Introduction

L'**extraction de caractéristiques** transforme des données brutes en représentations compactes et informatives. Trois approches principales existent :


1. **Apprentissage supervisé** : utilise des données étiquetées
2. **Auto-encodage** : reconstruit les données via un goulot d'étranglement

3. Apprentissage auto-supervisé : crée ses propres tâches d'apprentissage

Chaque méthode cherche à optimiser différents aspects de l'information, liés à l'entropie, la divergence KL et l'information mutuelle.

1. Apprentissage Supervisé

Principe et lien avec la théorie de l'information



Objectif : Maximiser l'**information mutuelle** entre les features Z et les labels Y.

Intuition : On cherche à extraire des caractéristiques qui réduisent au maximum l'incertitude sur les labels. Si Z contient beaucoup d'information sur Y , alors connaître Z réduit fortement l'entropie de Y .

Domaines d'application

Extraction (Feature Extraction)

- **Exemple** : ResNet pour images - les couches convolutives extraient hiérarchiquement des motifs (bords $\rightarrow$ textures $\rightarrow$ parties d'objets)
- **Lien théorie** : Features optimisées pour la discrimination

Mining (Exploration)

- **Exemple** : Analyse de sentiments dans des reviews clients
- **Usage** : Découvrir des thèmes récurrents dans les commentaires négatifs
- **Approche** : Classification supervisée puis analyse des features importantes

Recognition & Classification

- **Exemple** : Reconnaissance faciale pour authentification
- **Principe** : 2-ary ou M-ary classification - décider entre "personne A" vs "personne B" vs "autres"
- **Performance** : Haute précision quand beaucoup de données étiquetées

Search & Identification

- **Exemple** : Moteur de recherche de produits par image
- **Mécanisme** : Features extraites comparées par distance cosinus
- **Avantage** : Précision élevée grâce à l'apprentissage discriminatif

Transmission & Compression


- **Exemple** : Compression intelligente - ne garder que les features discriminantes
- **Approche** : Apprentissage de représentations compressées pour classification

Multimedia Security

- **Exemple** : Détection de deepfakes
 - **Principe** : Classification binaire (réel/faux) basée sur des features apprises
 - **Features** : Capture des artefacts de génération
-

2. Auto-Encodage

Principe et lien avec la théorie de l'information



Objectif : Minimiser la **divergence KL** entre la distribution des données et leur reconstruction.

Intuition : On cherche une représentation compressée Z qui préserve l'information essentielle. C'est un compromis entre compression (petit Z) et fidélité ($\hat{X}$ proche de X).

Domaines d'application

Extraction (Feature Extraction)

- **Exemple** : Réduction de dimension non-linéaire
- **Usage** : Projection de données complexes en 2D/3D pour visualisation
- **Avantage** vs PCA : Capture des relations non-linéaires

Mining (Exploration)

- **Exemple** : Découverte de communautés dans les réseaux sociaux
- **Approche** : Auto-encodeur sur matrice d'adjacence
- **Résultat** : Clusters correspondant à des communautés naturelles

Recognition & Classification

- **Exemple** : Détection d'anomalies médicales
- **Principe** : Seules les images normales se reconstruisent bien
- **Décision** : Erreur de reconstruction élevée → anomalie

Search & Identification

- **Exemple** : Système de recommandation musicale
- **Mécanisme** : Recherche par similarité dans l'espace latent Z
- **Avantage** : Capture la similarité structurelle profonde

Transmission & Compression


- **Exemple** : Codecs vidéo neuronaux (ex: BPG, VVC)
- **Principe** : Compression avec perte optimisée pour perception humaine
- **Trade-off** : Taux-distorsion - compromis taille/qualité

Multimedia Security

- **Exemple** : Watermarking robuste
- **Approche** : Encoder le watermark dans le bottleneck Z
- **Robustesse** : Survit aux transformations tant que la reconstruction est fidèle

3. Apprentissage Auto-Supervisé

Principe et lien avec la théorie de l'information



Objectif : Maximiser l'**information mutuelle** entre différentes vues d'une même donnée.

Intuition : Deux transformations d'une même image doivent avoir des représentations similaires. On apprend ainsi des features invariantes aux transformations mais discriminantes entre données différentes.

Domaines d'application

Extraction (Feature Extraction)

- **Exemple** : Modèles BERT en NLP
- **Principe** : Prédiction de mots masqués → embeddings contextuels riches
- **Usage** : Base pour de nombreuses tâches NLP

Mining (Exploration)

- **Exemple** : Découverte de catégories dans un dataset non étiqueté
- **Approche** : Pré-entraînement contrastif puis clustering
- **Résultat** : Catégories émergentes sans supervision humaine

Recognition & Classification

- **Exemple** : Diagnostic médical avec peu de données étiquetées
- **Protocole** : 1) Pré-entraînement auto-supervisé sur toutes les images médicales disponibles 2) Fine-tuning sur le petit dataset étiqueté
- **Avantage** : Réduction drastique du besoin d'annotations

Search & Identification

- **Exemple** : Recherche cross-modale image-texte (CLIP)
- **Capacité** : Trouver des images à partir de descriptions textuelles
- **Usage** : Moteurs de recherche visuels avancés

Transmission & Compression

- **Exemple** : Compression sémantique
- **Idée** : Ne transmettre que l'information sémantique essentielle
- **Approche** : Pré-entraînement auto-supervisé pour identifier ce qui est sémantiquement important

Multimedia Security

- **Exemple** : Détection de contenu généré par IA
- **Principe** : Les modèles génératifs laissent des empreintes subtiles
- **Détection** : Features auto-supervisées capturent ces patterns

Tableau synthétique des liens théoriques

Méthode	Quoi optimiser ?	Lien avec théorie de l'information	Analogie intuitive
Supervisé	Prédiction correcte des labels	Maximiser $I(Z;Y)$ - info mutuelle features/labels	“Apprendre à distinguer”
Auto-encodage	Reconstruction fidèle	Minimiser $D_{KL}(X\ X)$ - divergence entre original et reconstruction	“Apprendre à se souvenir de l'essentiel”
Auto-supervisé	Similitude entre vues augmentées	Maximiser $I(Z;Z)$ - info mutuelle entre vues d'une même donnée	“Apprendre à reconnaître malgré les transformations”

Exemples concrets intégrés

Cas 1 : Plateforme de streaming vidéo

Problème : Recommander des films à des utilisateurs

Solution hybride :

1. **Auto-supervisé :** Pré-entraînement sur toutes les vidéos (apprendre à reconnaître des scènes, actions)
2. **Supervisé :** Fine-tuning sur les notations des utilisateurs
3. **Auto-encodage :** Compression des embeddings pour recherche rapide

Applications :

- **Mining :** Découvrir des genres émergents (ex: “comédies romantiques de Noël”)
- **Search :** “Trouver des films qui ressemblent à Inception”
- **Compression :** Streaming adaptatif selon la bande passante

Cas 2 : Banque en ligne

Problème : Détecter les transactions frauduleuses

Approche :

1. **Auto-encodage :** Modèle normal sur transactions légitimes
2. **Détection :** Transactions avec haute erreur de reconstruction = potentielles fraudes
3. **Supervisé :** Validation humaine → création de labels → modèle supervisé plus précis

Sécurité : Détection en temps réel des anomalies

Conclusion : Quelle méthode choisir ?

Besoin	Méthode recommandée	Pourquoi
Beaucoup de données étiquetées	Supervisé	Performance maximale sur tâche spécifique
Compression, anomalies	Auto-encodage	Optimisé pour reconstruction fidèle
Peu de labels, beaucoup de données brutes	Auto-supervisé	Exploite la structure naturelle des données
Système complet	Combinaison des trois	Pré-entraînement auto-supervisé → fine-tuning supervisé → compression auto-encodeur

Tendance actuelle : L'apprentissage auto-supervisé devient dominant car il exploite l'abondance de données non étiquetées, suivie d'un fine-tuning supervisé pour adapter aux tâches spécifiques, avec des auto-encodeurs pour l'efficacité opérationnelle.

Tableau comparatif et synthèse


Aspect	Apprentissage supervisé	Auto-encodage	Apprentissage auto-supervisé
Données	Étiquetées	Non étiquetées	Non étiquetées
Objectif	Prédire Y	Reconstruire X	Apprendre représentations générales
Lien avec théorie info	$\text{Max } I(Z; Y)$	$\text{Min } D_{\text{KL}},$ bottleneck	$\text{Max } I(Z_1; Z_2),$ InfoNCE

Aspect	Apprentissage supervisé	Auto-encodage	Apprentissage auto-supervisé
Carac- téris- tiques	Spécifiques à la tâche	Compactes, reconstrucibles	Généralisables, transférables
Appli- cations typ- iques	Classification, régression	Compression, anomalies	Pré-entraînement, transfer learning

Relations avec l'entropie, DKL et information mutuelle

1. **Entropie** $H(\cdot)$: Mesure l'incertitude/le contenu informationnel
 - Dans tous les cas, on cherche des représentations avec une entropie appropriée (suffisamment informative mais pas trop redondante)
2. **Divergence KL** $D_{\text{KL}}(p \parallel q)$: Mesure l'écart entre distributions
 - VAE : $D_{\text{KL}}(q(z|x) \parallel p(z))$ régularise l'espace latent
 - Domain adaptation : Alignement de distributions
 - Self-supervised : Minimiser DKL entre vues augmentées
3. **Information mutuelle** $I(\cdot; \cdot)$: Mesure la dépendance
 - Supervisé : Maximiser $I(Z; Y)$
 - Self-supervised : Maximiser $I(Z_1; Z_2)$
 - Autoencodeurs : Préservation de $I(X; Z)$ sous contrainte de compression

Diagramme de synthèse des relations



Conclusion

Les trois paradigmes d'extraction de caractéristiques offrent des approches complémentaires avec des liens profonds à la théorie de l'information :

1. **L'apprentissage supervisé** maximise directement l'information mutuelle avec les étiquettes, produisant des caractéristiques hautement discriminantes pour une tâche spécifique.

2. **L'auto-encodage** implémente un bottleneck informationnel avec régularisation par divergence KL, apprenant des représentations compactes qui préservent l'information essentielle.
3. **L'apprentissage auto-supervisé** maximise l'information mutuelle entre différentes vues des données, apprenant des représentations générales et transférables.

Ces liens théoriques ne sont pas seulement académiques : ils guident le développement d'architectures plus efficaces et expliquent pourquoi certaines méthodes fonctionnent mieux que d'autres dans des contextes spécifiques. La compréhension de ces connexions permet aux praticiens de choisir l'approche appropriée pour leur problème et d'innover en combinant les forces de chaque paradigme.